

基于多分支多信息多深度复值特征融合网络的 SAR 舰船目标识别方法

王浩添, 冀振元, 化青龙*, 郭昭欣, 张 云

(哈尔滨工业大学电子与信息工程学院, 黑龙江哈尔滨 150001)

摘 要: 针对合成孔径雷达(Synthetic Aperture Radar, SAR)图像中舰船目标识别任务中存在的类内差异显著与类间相似性高的难题, 本文提出一种基于多分支多信息多深度复值特征融合网络(Multi-Branch, Multi-Information, Multi-Depth feature fusion complex-valued Network, M3Net)的舰船目标识别方法. 传统方法多依赖人工设计的幅度特征, 未能充分利用 SAR 原始数据中固有的复数特性, 忽略了相位信息及其与幅度的耦合关系, 导致对舰船精细结构的表征能力不足, 识别精度与模型泛化能力受限. 本文通过深入分析舰船目标的非圆性和复信号峰度特征, 发现两者能够有效表征舰船目标区别于海面背景的散射特性, 揭示了复数域统计量对舰船散射特性的表征优势. 在此基础上, 本文设计了深度复值特征提取模块(Complex Feature Extraction Module, CFEM), 通过复卷积运算提取幅相耦合特征, 创新性地引入实虚交融激活函数(Cross-fusion of Real and Imaginary Activation, CRIA), 通过双激活函数的交叉耦合机制实现非线性特征交互, 增强了对复数特征的表征能力. 进一步构建多分支多信息多深度融合网络 M3Net, 通过主干复数域卷积神经网络(Complex-Valued Convolutional Neural Network, CV-CNN)、预训练 CFEM 分支和实值特征分支的协同处理, 结合复数域注意力机制实现异构特征的动态加权融合, 自适应突出判别性强的特征通道. 在重构 OpenSAR-ship 数据集上的实验结果表明, 所提方法较传统 CV-CNN 提升 5.89%, 极差值降低至 6.82%, 显著改善了类别均衡性.

关键词: 合成孔径雷达; 复数域网络; 舰船目标; 识别; 复值特征

基金项目: 国家自然科学基金(No.62401183); 中国博士后科学基金(No.2024M754185, No.GZB20240967); 黑龙江省博士后面上资助项目(No.LBH-Z24138)

中图分类号: TP751

文献标识码: A

文章编号: 0372-2112(2025)10-3759-14

电子学报 URL: <http://www.ejournal.org.cn>

DOI: 10.12263/DZXB.20250356

Recognition Method of Ship Targets for SAR Based on M3Net

WANG Hao-tian, JI Zhen-yuan, HUA Qing-long*, GUO Zhao-xin, ZHANG Yun

(School of Electronics and Information Engineering, Harbin Institute of Technology, Harbin, Heilongjiang 150001, China)

Abstract: To address the challenges of significant intra-class variations and high inter-class similarities in ship target recognition within synthetic aperture radar (SAR) images, this paper proposes a novel recognition method based on a multi-branch, multi-information, multi-depth feature fusion complex-valued network (M3Net). Traditional methods predominantly rely on manually designed amplitude features, failing to fully exploit the inherent complex-valued nature of raw SAR data and neglecting the crucial phase information and its coupling relationship with amplitude. This limitation results in insufficient characterization of ships' fine structures and ultimately restricts recognition accuracy and model generalization capability. Through in-depth analysis of the noncircularity and complex signal kurtosis characteristics of ship targets, this study reveals that these features can effectively characterize the scattering properties distinguishing ships from the sea background, highlighting the representational advantages of complex-domain statistics for ship scattering characteristics. Building on this foundation, a deep complex feature extraction module (CFEM) is designed. This module employs complex-valued convolutional operations to extract amplitude-phase coupled features and innovatively introduces a cross-fusion of real and imaginary activation (CRIA) function. The CRIA mechanism, utilizing a dual-activation function cross-coupling approach, achieves nonlinear feature interactions and enhances the representational capacity for complex-valued features. Furthermore, the multi-branch, multi-information, multi-depth fusion network M3Net is constructed. M3Net synergistically in-

tegrates a core complex-valued convolutional neural network (CV-CNN) backbone, a pre-trained CFEM branch, and a real-valued feature branch. By incorporating a complex-domain attention mechanism, M3Net achieves dynamic weighted fusion of these heterogeneous features, adaptively highlighting the most discriminative feature channels. Experimental results on the reconstructed OpenSARship dataset demonstrate the effectiveness of the proposed method. Compared to the traditional CV-CNN, our approach achieves a 5.89% improvement in overall accuracy and reduces the maximum accuracy deviation across classes to 6.82%, significantly enhancing category balance.

Key words: synthetic aperture radar (SAR); complex-valued neural network; ship targets; recognition; complex-valued feature

Foundation Item(s): National Natural Science Foundation of China (No.62401183); China Postdoctoral Science Foundation (No.2024M754185, No.GZB20240967); Heilongjiang Postdoctoral Fund (No.LBH-Z24138)

1 引言

合成孔径雷达(Synthetic Aperture Radar, SAR)凭借不受天气和昼夜限制的成像特性,已成为海上舰船智能监测的重要手段^[1],在海洋监测和海上安全管理方面具有广泛应用前景。然而,舰船目标识别任务普遍面临着类内差异显著与类间相似性高的双重挑战。同一类别舰船的特征空间分布呈现高度离散化,即“类内发散”现象,其主要成因包括舰船姿态多样性、SAR成像条件变化以及复杂背景干扰的综合作用。另一方面,不同类别舰船因功能需求趋同化设计而呈现强相似性,即“类间趋同”现象。这种“类内发散、类间趋同”的特性导致难以在特征空间中建立稳定且具有判别力的分类边界,从而显著降低识别精度和算法的泛化能力。

传统舰船目标识别方法主要依赖于人工设计的特征提取技术,在挖掘SAR图像中丰富信息方面存在明显局限性。人工特征虽然能够捕捉到舰船目标的部分显著特征,但其泛化能力和稳定性受限于先验知识,难以有效适应复杂成像条件与背景干扰。随着深度学习的发展,基于实值卷积神经网络(Convolutional Neural Network, CNN)的方法通过端到端学习提升了特征表达能力。为了解决SAR舰船识别问题, Gao等人^[2]构建了一种具有双分类器的多分支嵌入网络(MultiBranch Embedding Network with Bi-Classfier, MBEN-BC)模型,通过提取多尺度特征,增强局部和全局判别信息,再结合图像级和描述符级分类提升特征空间紧凑性,但在小样本与类间高度相似场景下,多尺度特征的冗余信息可能导致分类边界模糊。Zhang等人^[3]构建了一种基于散射关键点拓扑的小样本船舶分类网络(Scattering-Point Topology for Few-shot Ship Classification, SPT-FSC),通过对散射点的拓扑信息进行编码嵌入,提高网络对成像机制的适应性。针对舰船识别的类不平衡问题, Li等人^[4]提出基于聚类的过采样方法(Clustering-Based Size-Adaptive Safer Oversampling, C-SASO),通过聚类分配过采样大小,结合安全级别指标生成新样本,减少与多数类重叠,提升分类边界清晰度。Raj J等人^[5]提出基

于单次学习的混合孪生网络,通过距离度量分类,结合预处理和特征融合技术,解决SAR船舶分类中的不平衡数据问题,但处理步骤复杂,在复杂背景下泛化能力有限。Wang等人^[6]和Li等人^[7]通过图像生成扩充数据集,缓解类别不平衡,但生成图像与真实SAR数据的散射特性差异可能导致模型过拟合,且生成模型训练成本较高。Xu等人^[8]提出分布偏移度量学习,通过引入类间分布偏移正则化项,优化特征空间分布,提升类间分离性和类内紧凑性。He等人^[9]在将密集卷积网络应用于SAR舰船分类时,通过深度度量学习使得舰船同类样本的表示更接近,异类样本的表示更远离。由于舰船不同种类之间相似性高,同种类之间差异大限制了对舰船的识别能力。同时由于舰船SAR数据集丰富度有限,使得SAR图像舰船目标识别处于小样本且类别不平衡的状态下,限制了深度网络的性能。

现有深度学习模型大多仅针对幅度数据进行设计,忽略了相位信息的重要性。相位信息不仅蕴含了目标与雷达之间的相对运动信息,还反映了目标的微观结构特征,这对于精确识别舰船类型具有重要参考意义,因此复数域深度学习也被引入到雷达信号处理中。Huang等人^[10]提出了一种针对复数SAR图像的框架Deep SAR-Net,能够同时学习地面物体的空间纹理信息和后向散射模式,以提高分类精度。Yu等人^[11]将全卷积神经网络拓展到复数域,其隐藏层仅包含卷积层,避免了复杂的池化操作并防止过拟合,引入复 1×1 卷积层以学习特征图的交叉通道信息,有效提高分类准确率。Zhang等人^[12]针对小样本失焦逆合成孔径雷达(Inverse Synthetic Aperture Radar, ISAR)图像分类提出了一种端到端的复数值图神经网络,通过复值图卷积挖掘ISAR图像实部和虚部特征之间的深层关系。Zhou等人^[13]提出了一种多尺度复值特征注意力卷积神经网络,通过设置复值注意力模块分别关注目标的幅度和相位特征,减少训练时间并增强特征表示能力。Zeng等人^[14]提出了一种基于复数值运算的多流特征融合复数域网络用于SAR目标识别,通过复数值运算块和多尺度卷积核提取目标的幅度和相位信息,增强模型能力。Wang

等人^[15]设计了一种针对单通道SAR图像目标识别的复数域卷积神经网络(Complex-Valued Convolutional Neural Network, CV-CNN),并引入数据增强方法以缓解样本量小的问题.方澄等人^[16]基于复数多尺度卷积和深度可分离模块设计了一种端到端全复数域多层级神经网络,提升了对SAR图像目标识别的分类精度和泛化能力.针对复值SAR图像中的舰船识别,Hao等人^[17]将VGG(Visual Geometry Group)网络拓展到复数域的VGG网络(Complex-valued Visual Geometry Group, CVGG),并引入基于面积对比的复值最大池化方法,有效提升识别精度.舰船的运动会导致SAR图像的散焦,从而影响识别精度,采用CV-CNN可以实现对运动散焦图像的无运动补偿分类^[18-20].上述复数域方法虽取得了一定进展,但是仍存在局限性:特征提取模块未充分挖掘复数域统计特性与幅相耦合信息,多分支特征融合多为静态拼接,缺乏动态加权机制,并且对类内差异与类间相似的平衡能力不足,类别均衡性有待提升.

因此,本文结合SAR图像包含幅度与相位信息的特点,提出一种多分支多信息多深度复值特征融合网络(Multi-Branch, Multi-Information, Multi-Depth Feature fusion complex-valued Network, M3Net)架构,通过主干CV-CNN、预训练深度复值特征提取模块(Complex Feature Extraction Module, CFEM)分支和实值特征分支的协同处理,结合复数域注意力机制实现异构特征的动态加权融合.CFEM创新性地引入虚实交融激活函数(Cross-fusion of Real and Imaginary Activation, CRIA)^[21],打破传统实虚部分离激活的局限性,通过双激活函数交叉耦合机制增强非线性表达能力.实验表明,所提方法在复数SAR舰船识别任务中展现出优越的综合性能,不仅超越了传统单一方法的识别准确率,更有效改善了类别不平衡问题.

2 SAR舰船目标复数特征分析

传统方法因低分辨率SAR条件下舰船目标呈现点散射特性而仅依赖幅度信息,但在高分辨率SAR图像中,舰船作为扩展目标表现出复杂的结构散射特征,其相位信息蕴含了目标运动引起的多普勒调制特性以及精细几何结构信息.通过联合分析复值数据的实部、虚部及相位分量,不仅能更完整地表征舰船目标的电磁散射机制,还能增强舰船的鉴别能力.因此,融合复值信息的全息化处理为高分辨率SAR舰船识别提供了从单一幅度检测到多维特征协同判别的路径.

2.1 舰船目标的复值信息提取

复信号的非圆性(NonCircularity, NC),有时也被称为非圆对称性或椭圆性,是描述复数信号一个重要的统计特性^[22].如果一个复信号是圆性的,那么它的实部和虚部在统计上是独立且同分布的,并且其相位在概

率上是均匀分布的.与完全随机的圆性信号(如高斯白噪声)不同,非圆性信号往往具有特定的相位结构或幅度-相位耦合特性.舰船目标由于刚性结构和强散射体的存在,其复信号往往表现出显著的非圆性.

为了更精确地表征非圆性的强弱,可采用归一化非圆性作为测度.如式(1)其定义为信号伪协方差与协方差的归一化比值,能够有效反映信号的非圆性强度.相较于仅判断非圆性的存在与否,归一化非圆性提供了更精细的量化指标,使得不同信号间的非圆性程度可以进行比较和分析.

$$NC = \frac{\mathbb{E}[Z^2]}{\mathbb{E}[|Z|^2]} \quad (1)$$

其中, Z 为复值随机变量.

复信号峰度(Complex Signal Kurtosis, CSK)是描述复值信号高阶统计特性的重要指标,用于衡量信号偏离高斯分布的程度.在复数域中,CSK通过分析复信号的实部与虚部之间的高阶矩关系,能够同时捕捉非高斯性和非圆性特征.与实信号峰度不同,CSK能表征复信号的幅度-相位联合分布特性:当 $CSK > 0$ 时,信号呈现超高斯性; $CSK < 0$ 时为亚高斯性; $CSK = 0$ 对应复高斯分布.

对于随时间 t 变化的复信号 $s(t)$ 的 $(l+m)$ 阶样本中心矩为

$$\alpha_{l,m} = \mathbb{E} \left[\left(s(t) - \mathbb{E}[s(t)] \right)^l \cdot \left(s(t) - \mathbb{E}[s(t)] \right)^{*m} \right] \quad (2)$$

标准化矩定义为

$$\mu_{l,m} = \frac{\alpha_{l,m}}{\sigma^{l+m}} \quad (3)$$

其中, l 和 m 为非负整数,控制实部与虚部的幂次组合; σ 为标准差, $\sigma^2 = \alpha_{1,1}$.

复信号峰度的度量定义为^[23]

$$CSK = \mu_{2,2} - 2 - \left| \mu_{2,0} \right|^2 \quad (4)$$

由式(4)可知复信号峰度本质上包含归一化的非圆性度量.由文献[24]的深入分析表明,CSK是一种能够统一表征复数信号非高斯性与非圆性的高阶统计量:非高斯性决定其符号特征,反映信号偏离高斯分布的程度;非圆性则通过调制幅值体现实虚部间的统计依赖性.

在提取复值SAR图像的复值信息图时,常用 15×15 的窗口,循环遍历图像,计算窗口内信号的非圆性测度NC与复信号峰度测度CSK.图1分别展示了各类别舰船的SAR幅度、NC特征与CSK特征.

由图1可以清晰地观察到不同舰船类型在NC和CSK特征上的显著差异.这种特征差异验证了NC与CSK在表征舰船特性方面的有效性,同时舰船与海面背景的鲜明对比实现了舰船区域与背景的清晰区分,为基于SAR图像复值信息特征的舰船检测与识别提供了可靠依据.




图1 各类舰船的NC与CSK特征图

2.2 复值信息特征的可分性分析

由上述分析可知,舰船SAR图像的NC和CSK特征能够有效地区分舰船目标与海面背景,并且可以看出舰船SAR图像的NC图与CSK图中舰船与海面背景存在着明显的区分度,目前已有基于NC与CSK的舰船检测研究^[25]. 但对基于NC与CSK的舰船识别研究较少,在之前的分析中不同舰船的NC与CSK特征图存在显著差异. 这一现象源于舰船结构的物理散射特性差异:上层建筑、甲板布局、雷达反射面等方面均会影响SAR信号的复值统计特性,而NC和CSK能够从不同角度刻画这种差异. 这也表明NC与CSK可能具备区分舰船类别的能力.

在提取SAR图像的NC与CSK特征图时需基于滑窗实现,在文献[23]的舰船检测任务中将滑窗设置为 15×15 . 对于识别任务需要更明显的特征区分度,对于滑窗大小的选择还需进一步分析. 图2展示了 128×128 舰船切片在不同滑窗尺寸($N \times N$, $N=3 \sim 17$)下的NC特征图演变规律. 从图中可以观察到三个明显的特征变化

阶段:首先,当采用极小滑窗($N=3$)时,由于特征提取窗口过小,NC特征图几乎无法区分舰船与海面背景;随着滑窗增大至 $N=5 \sim 7$,舰船轮廓开始显现,中心强散射点首次凸显,表明滑窗能有效捕获舰船主体结构;当滑窗继续增大至 $N=11 \sim 17$ 时,特征图呈现稳定变化趋势:舰船区域被逐渐放大,中心强点区域面积也逐渐增大,同时背景海面保持稳定的低值. 当 $N=3 \sim 17$ 后,特征图的细节分布保持高度一致性,说明此时滑窗已达到最优尺寸阈值,既能保证舰船与背景的高对比度,又不会因过度平滑损失关键结构信息.

当滑窗尺寸超过 $N=11$ 后,特征图信息趋于稳定,继续增大滑窗带来的特征增益有限;同时,计算复杂度与滑窗尺寸呈平方关系, $N=15$ 相比 $N=17$ 可减少约30%的计算量,而特征区分度仍保持良好. 这种折中方案既能保证特征质量,又可显著提升算法实时性. 基于以上分析,在舰船检测与识别任务中可优先采用 $N=11 \sim 15$ 的中等滑窗尺寸.




图2 不同滑窗尺寸的舰船NC特征图

尺寸 128×128 的舰船切片在不同滑窗尺寸下的CSK特征图演变规律如图3所示。整体来看,CSK特征图与NC特征图具有相似的变化趋势,但存在一定差异。在极小滑窗($N=3$)时,CSK特征图已能初步显现舰船轮廓,其表现优于同尺寸下的NC特征图;当滑窗增大至 $N=5 \sim 7$ 时,舰船轮廓变得清晰,中心强点显著凸显,表明该尺寸范围已能有效提取舰船的主体散射特性。随着滑窗继续增大至 $N=11 \sim 17$,特征图呈现出与NC特征相似的优化趋势:舰船区域被逐渐放大,中心强点区域面积增大,同时背景海面保持稳定的低CSK值。值得注意的是,与NC特征不同,CSK特征在滑窗增大过程中会逐渐淹没舰船内部结构细节,当 $N=17$ 时已完全无法辨识内部结构。对于舰船检测任务,应优先采用 $N=11 \sim 15$ 的滑窗,在保证检测精度的同时控制计算量;而对于需要保留更多结构信息的舰船识别任务,则建议选用 $N=7 \sim 13$ 的较小滑窗,既可避免内部结构被过度平滑,又能有效提升计算效率。

对于同时结合NC与CSK的舰船检测与识别任务,

两者采用相同的滑窗可以有效提高计算效率。综合以上分析,对于结合检测任务可以首先考虑 $N=11 \sim 15$ 的滑窗;而对于结合识别任务,可以首先考虑 $N=11 \sim 13$ 的滑窗。利用典型CNN对不同滑窗大小得到的舰船复值信息特征图进行识别,并统计识别率。结果显示滑窗尺寸 N 对舰船识别性能具有显著影响,且影响规律与基于图2和图3的分析相互印证。

3 基于多复值信息特征融合网络的SAR舰船目标识别方法

围绕复值SAR图像舰船识别任务,本文提出深度复值特征提取模块CFEM和多分支多信息多深度复值特征融合网络M3Net。CFEM模块通过复卷积-CRIA-自适应池化的级联结构,实现了复数SAR图像中幅相耦合特征的高效提取。M3Net则创新性地融合了多分支多信息多深度的特征表示,通过复数域注意力机制实现异构特征的动态加权融合。




图3 不同滑动尺寸的舰船CSK特征图

3.1 深度复值特征提取模块

CFEM模块如图4所示. CFEM模块采用级联式结构,首先通过复卷积层对输入复数数据进行初步特征提取,利用复数乘法的实虚通道交互特性,充分挖掘复数SAR图像中的幅相耦合信息.随后,CFEM引入CRIA复激活层,通过双激活函数的协同作用实现实虚部非线性交互.这种实虚交融机制不仅保留复数幅相关系的完整性,还通过非线性交叉增强特征表达能力,形成更丰富的特征组合.最后,CFEM采用自适应最大周长复池化层作为特征筛选阶段.该池化层基于综合幅度与相位信息的周长指标选择关键特征,并通过可学习参数自适应调整幅度与相位的权重分配.相较于传统最大幅度池化,该层能保留低幅高相位值的区域特征,同时通过自适应机制优化不同场景下的特征选择策略,能够有效缩小不同类别间的性能差异.

CFEM的特点在于通过复卷积-CRIA-自适应池化的级联处理,形成从局部特征提取到全局信息筛选的完整复数特征学习链路;各层均基于复数运算原理设计,避免实虚部信息割裂;与CVGG^[17]模块的基本结构




图4 深度复值特征提取模块

相似,可直接用作CV-CNN的特征提取模块.

CV-CFEM的网络架构如图5所示.与现有CV-CNN不同的是,CV-CFEM所有的激活层均采用CRIA激活方式,所有的池化层均采用自适应最大周长复池化. CFEM模块的核心在于通过多层次复数特征处理机制,实现复数SAR图像中舰船特征的深度提取与优化. CFEM模块涉及的复卷积层和CRIA复激活层接下来分别介绍.

3.1.1 复卷积层

复卷积层是CV-CNN提取复数数据特征信息的核心模块,通过将复卷积层的输入复数数据与可学习的复卷



图5 CV-CFEM网络架构

积核进行卷积,以获取复数据的特征信息.对于复卷积层的输入 z ,与权重为 w 的复卷积核进行卷积,最后引入复偏置 b ,得到复卷积层的输出结果.计算公式为

$$w * z + b = (\Re(w) \cdot \Re(z) - \Im(w) \cdot \Im(z) + \Re(b)) + j \cdot (\Re(w) \cdot \Im(z) + \Im(w) \cdot \Re(z) + \Im(b)) \quad (5)$$

其中, j 是虚数单位,*是卷积符号, $\Re$ 和 $\Im$ 分别表示复数的实部和虚部.

矩阵形式为

$$\begin{bmatrix} \Re(w * z + b) \\ \Im(w * z + b) \end{bmatrix} = \begin{bmatrix} \Re(w) & -\Im(w) \\ \Im(w) & \Re(w) \end{bmatrix} \begin{bmatrix} \Re(z) \\ \Im(z) \end{bmatrix} + \begin{bmatrix} \Re(b) \\ \Im(b) \end{bmatrix} \quad (6)$$

3.1.2 CRIA 复激活层

对于CV-CNN的激活层设置,通常利用实激活函数分别激活复数据的实部虚部,可以称其为实虚分离激活(Real-Imaginary Separation Activation, RISA)方式,即激活输出的实部仅取决于输入的实部,虚部仅取决于输入的虚部,其数学表达式为

$$\sigma(z) = \sigma(\Re(z)) + j \cdot \sigma(\Im(z)) \quad (7)$$

其中, σ 代表实数域激活函数.

尽管这种实现方式简单高效,但RISA的分离处理方式割裂了幅度和相位二者的内在关联.这种解耦激活可能导致是复数域信息的损失,特别是相位特征的失真.为了增强在激活时对复数数据处理的整体化,需在激活过程中融合实部与虚部的信息,通过联合输入的实部与虚部,增强网络处理复值特征信息的能力.

CV-CNN相比于CNN的核心在于在卷积层引入了基于复数乘法运算法则的实虚通道交互方法,通过引入复数乘法增强网络对复数数据的处理能力.对于激活层本文引入基于复数运算法则的交互方式来增强网络对复数数据的解析与学习能力.实虚交融激活CRIA的核心在于通过双激活函数的协同作用实现复数据实虚部的深度交互.CRIA首先采用两个具有不同非线性特性的激活函数分别作为类实部和类虚部处理单元,将输入复数的实部和虚部同时通过这两个激活函数进行处理,生成四个中间激活结果.将四个中间激活结果按照复数乘法的实实-虚虚与实虚-虚实进行两两组合,但与复数乘法不同的是组合方式为乘积取代了差和运算.这种设计既保留了复数运算的交互特性,又通过乘积运算增强了非线性表达能力.CRIA能够捕捉复数据中实部与虚部之间的复杂关联,提升网络对复数特征的

学习能力,在保持复数整体性的同时实现更强的特征表达能力.

对于输入的复数据 z ,CRIA通过如图6所示的激活流程获得复激活输出.CRIA会为输入数据的实部和虚部传递两种不同的激活函数,使输入数据的实部和虚部可以得到两种不同的激活结果,将实部对于一个激活函数的输出结果和虚部对于另一个激活函数的输出结果相乘可以得到两个联合激活结果,并将它们分别用作激活输出的实部和虚部.相较于传统的RISA实虚分离激活,CRIA的核心优势在于其激活输出的实部和虚部均由输入数据的实部和虚部共同决定,通过这种交叉耦合机制不仅保留了复数数据的整体性特征,还增强了激活层的非线性表达能力.




图6 CRIA激活流程

CRIA激活方式的计算公式为

$$a = f_{\text{CRIA}}(z) = \sigma_1(\Re(z)) \sigma_2(\Im(z)) + j \cdot \sigma_1(\Im(z)) \sigma_2(\Re(z)) \quad (8)$$

$$\phi = \arctan \left(\frac{\sigma_1(\Im(z)) \sigma_2(\Re(z))}{\sigma_1(\Re(z)) \sigma_2(\Im(z))} \right) \quad (9)$$

其中, σ_1 与 σ_2 分别代表不同的实数域激活函数; a 为激活后的输出结果.

当交换 σ_1 与 σ_2 的位置时,CRIA输出的实部和虚部反转,激活输出的幅度相同,相位变化,如下式所示:

$$\arctan \left(\frac{\sigma_2(\Im(z)) \sigma_1(\Re(z))}{\sigma_2(\Re(z)) \sigma_1(\Im(z))} \right) = \frac{\pi}{2} - \phi \quad (10)$$

图7展示了采用Sigmoid与Tanh的CRIA的激活输出情况.其中RISA_t与RISA_s分别表示采用Tanh的RISA激活、采用Sigmoid的RISA激活;CRIA_{st}表示采用

Sigmoid-ReLU 的 CRIA 激活.

CRIA 激活输出的实部变化不仅取决于输入复数实部的绝对值大小,还受到输入复数虚部非线性变换的影响;同样,输出虚部的变化也同时依赖于输入复数

实部和虚部的联合作用. 这种双向耦合机制可以更好地保留复数信号的幅相耦合特性,避免相位信息失,并且通过实虚部的非线性交互,能够提取出更丰富的跨通道特征组合.




图7 采用Sigmoid与Tanh的CRIA激活输出

CRIA 的反向传播公式为

$$\begin{aligned} \frac{\partial J}{\partial \Re(z)} &= \frac{\partial J}{\partial \Re(a)} \frac{\partial \Re(a)}{\partial \Re(z)} + \frac{\partial J}{\partial \Im(a)} \frac{\partial \Im(a)}{\partial \Re(z)} \\ &= \frac{\partial J}{\partial \Re(a)} \sigma_1'(\Re(z)) \sigma_2(\Im(z)) \\ &\quad + \frac{\partial J}{\partial \Im(a)} \sigma_1(\Im(z)) \sigma_2'(\Re(z)) \end{aligned} \quad (11)$$

$$\begin{aligned} \frac{\partial J}{\partial \Im(z)} &= \frac{\partial J}{\partial \Re(a)} \frac{\partial \Re(a)}{\partial \Im(z)} + \frac{\partial J}{\partial \Im(a)} \frac{\partial \Im(a)}{\partial \Im(z)} \\ &= \frac{\partial J}{\partial \Re(a)} \sigma_1(\Re(z)) \sigma_2'(\Im(z)) \\ &\quad + \frac{\partial J}{\partial \Im(a)} \sigma_1'(\Im(z)) \sigma_2(\Re(z)) \\ &= \frac{\partial J}{\partial \Re(a)} \sigma_2'(\Im(z)) \frac{\Re(a)}{\sigma_2(\Im(z))} \\ &\quad + \frac{\partial J}{\partial \Im(a)} \sigma_1'(\Im(z)) \frac{\Im(a)}{\sigma_1(\Im(z))} \end{aligned} \quad (12)$$

其中, J 为输出层神经元误差.

当 σ_1 取 Sigmoid 激活函数, σ_2 取 Tanh 激活函数时, CRIA 的反向传播公式为

$$\frac{\partial J}{\partial \Re(z)} = \frac{\partial J}{\partial \Re(a)} \frac{\Re(a)}{1 + e^{\Re(z)}} + \frac{\partial J}{\partial \Im(a)} \frac{4\Im(a)}{e^{2\Re(z)} - e^{-2\Re(z)}} \quad (13)$$

$$\frac{\partial J}{\partial \Im(z)} = \frac{\partial J}{\partial \Re(a)} \frac{4\Re(a)}{e^{2\Im(z)} - e^{-2\Im(z)}} + \frac{\partial J}{\partial \Im(a)} \frac{\Im(a)}{1 + e^{\Im(z)}} \quad (14)$$

在 OpenSARship 数据集进行实验,采用不同激活方式的网络在数据集分类任务中,CRIA 激活方式在整体性能上显著优于 RISA 激活方式. 其中, CRIA_{sr} 以 75.12% 的总体准确率成为最优模型,分别较 RISA_s 与 RISA_r 提升了 14.76% 与 2.35%. 基于 CFEM 进行深度特征提取的实现步骤如算法 1 所示.

3.2 多复值信息特征融合网络

针对复值 SAR 图像中的多类舰船目标识别这一具有挑战性的任务,本文构建了 M3Net 网络架构. 如图 8 所示, M3Net 采用多分支、多信息、多深度的复值特征融合设计理念,主要由三大部分构成:主干 CV-CNN 网络作为核心处理单元,负责对原始复值 SAR 图像进行端到端的深度特征学习;两个辅助分支则分别专注于特定特征类型的提取与处理. 其中,第一个辅助分支由多个预训练的 CFEM 模块组成,这些模块通过预训练策略

算法 1 深度复值特征提取模块(CFEM)

输入: CFEM输入特征图 z 、复卷积层1—2的权重 w 和偏置 b

输出: CFEM输出特征图 a

1. 根据式(5),基于复卷积层1权重 w 和偏置 b 计算得到复卷积层1输出 z_1
2. 将复卷积层1输出 z_1 输入到CRIA复激活层,根据式(8)计算得到CRIA复激活层输出 z_2
3. 将复激活层输出 z_2 输入到复卷积层2,根据式(5)计算得到复卷积层2输出 z_3
4. 将复卷积层输出 z_3 的实部和虚部分别进行批归一化,归一化结果记为 z_4
5. 根据式(8)对批归一化结果 z_4 进行复激活,得激活输出 z_5
6. 对激活输出 z_5 进行自适应池化,得到CFEM输出特征图 a

获取了强大的深度复值特征提取能力,能够有效捕捉舰船目标在复数域中的相位-幅度耦合特性. 第二个辅助分支则采用实值CNN网络专门处理经过NC和CSK特征提取算法预处理后的特征图. 在特征融合策略上, M3Net引入了复数域注意力机制与 1×1 复卷积层实现的深度特征融合与通道调整操作,使得来自不同分支、不同层次的特征能够实现最优组合. 这种多分支、多信息、多深度的协同工作机制,使得 M3Net在保持复数网

络对幅度与相位信息敏感性的同时,也兼具了复值信息统计特征方法的可解释性和稳定性,从而在复值SAR图像舰船识别任务中实现性能提升. 整体来看, M3Net由4个标记的深度特征融合模块组成,在每个模块中组合CFEM、CVGG^[17]与VGG的深度特征,其中VGG的特征为实值,为了使网络稳定运行将实值特征扩充为实部与虚部的组合复值特征.

M3Net架构的核心在于其采用的深度特征融合模块,每个模块都实现了复数域与实数域特征的协同处理. 在每个融合模块中,网络通过三个并行通路获取不同类型的特征表示:CFEM模块与CVGG模块捕捉不同的复值信息特征,而VGG模块则专门处理经过NC和CSK预处理的实值特征图. 为确保复数网络的稳定运行,系统将VGG输出的实值特征 x 扩展为具有实部与虚部的复合形式 $x+jx$,这种处理既保持了实数特征的稳定性,又使其能够无缝融入后续的复数特征融合流程. 在特征融合阶段,网络首先采用复数域注意力机制对各通道特征进行动态加权,通过可学习的复数权重参数突出贡献度高的特征通道;随后通过 1×1 复卷积层实现跨模态特征交互,该操作不仅完成了特征维度的统一调整,更在复数域中建立了不同特征空间之间的非线性映射关系.




图8 M3Net网络结构

4 实验结果分析

为了验证所提舰船目标识别方法的有效性,本文基于重构后的OpenSARship数据集开展验证实验. 本文的所有识别结果均基于多次的训练/测试集划分,并进行多次独立实验以报告统计指标.

4.1 实验数据

OpenSARship数据集是由上海交通大学基于41张不同Sentinel-1图像构建的用于SAR图像舰船目标解释的开放数据集^[26],其包含GRD与SLC两种产品. 对于原始的SLC数据部分,数据集类型分布不均,为了使其能够有效地测试算法分类识别的性能,需要对其进行筛选与重构. 基于OpenSARship数据集提供的AIS信

息,可以实现对部分SLC产品进行筛选与重构. 参考文献[27],根据AIS信息中所包含的“Ship_Type”字段对“货船”类别的样本进行进一步细分,筛选出“散货船”和“集装箱船”类别的样本. 将重构后OpenSARship数据集中类型数目最多的散货船、集装箱船与油轮三类舰船目标构建为3分类数据集. 为了便于网络处理,数据切片均被双线性插值为 128×128 的像素大小,并进行幅度零均值标准化处理. 各类目标以70%的比例划分为训练集与30%的比例划分为测试集,如表1所示.

4.2 不同复值信息特征的识别对比

在相同的网络结构下,复值信息特征相比于幅度图能获得更高的识别准确率,并且能够实现超越基础

表1 OpenSARship 舰船3分类数据集


类型	训练集	测试集	总计
散货船	466	200	666
集装箱船	802	344	1 146
油轮	339	145	484

CV-CNN的识别准确率. 对于前者,复值信息特征可以放大SAR图像中的舰船特性,使得网络能够更轻易地捕获目标特征;对于后者CV-CNN的实际输入是SAR的实部图与虚部图并通过基于复数运算的通道交互方式解析实部与虚部之间蕴含的幅度与相位信息,而复值信息特征相当于已经解析过实部与虚部之间的信息,因此能实现与基础CV-CNN相匹配的分类能力.


在完全相同的网络架构条件下,采用复值信息特征作为输入相较于传统SAR幅度图能够显著提升目标识别准确率,并且这种特征表示方式甚至能够匹配基础CV-CNN模型的性能.就特征表示层面而言,复值信息特征具有独特的优势.相较于仅包含强度信息的幅度图,复值特征解析了SAR原始数据中的幅度与相位信息,这种相位-幅度的耦合特性能够放大舰船目标的散射特征.在网络架构层面,复值信息特征与CV-CNN的结合展现出特殊的协同效应.基础CV-CNN的标准输入模式是将SAR数据的实部与虚部作为双通道输入,通过复数卷积运算来解析实虚部之间的关联性.而复值信息特征实际上已经对实部与虚部的交互信息进行了预解析,这种预处理避免了CV-CNN需要耗费大量参数解析SAR数据的复值信息,同时实现了更直观的相位-幅度耦合信息.

采用不同方法得到的3分类识别混淆矩阵如图9所示,其中NC与CSK特征图的提取采取了之前得到最高OA的 $N=13$ 的窗.通过对图9中四种SAR舰船分类方法的混淆矩阵进行深入分析,可以得出以下综合结论.幅度+CNN方法表现最弱,散货船准确率55.95%,单一幅度特征的特征局限,其27.3%的散货船-油轮误判率反映了幅度特征对几何结构相似目标的区分能力不足.相比之下,CV-CNN通过复数卷积保留完整相位信息,显著提升了油轮识别性能,NC+CSK+CNN方法在集装箱船分类达到83.40%准确率,局部散射点特征对高散射密度目标的有效性,但其36.35%的散货船误判率则暴露了局部特征在区分结构相似目标时的局限性.预训练CV-CFEM方法通过迁移学习实现84.77%的集装箱船分类准确率,同时保持各类别的均衡性能,体现了全局复值特征的特征优势.


相位敏感特征的CV-CNN更适用于具有复杂结构的油轮;局部散射特征的NC+CSK+CNN对集装箱船等高散射目标效果显著;而预训练模型(CV-CFEM)则通过高阶特征学习实现了最佳的综合性能.这种性能差




(a) 幅度+CNN



(b) CV-CNN



(c) NC+CSK+CNN



(d) 预训练CV-CFEM

图9 不同方法的3分类混淆矩阵

异本质上反映了不同特征表征维度与特定舰船目标散射特性之间的匹配程度。

综合以上分析, CV-CNN、NC+CSK+CNN 和预训练 CV-CFEM 三种 SAR 舰船分类方法在特征表征与分类性能展现出明显互补特性, 可以考虑结合三种方法以实现更综合与更平衡的识别性能。

4.3 M3Net 舰船目标识别结果分析

图 10 为采用 M3Net 得到的 3 分类识别结果。该实验采用以下配置: NC 与 CSK 特征的滑窗尺寸统一设置为 $N=13$, 以平衡特征分辨率和计算效率; 复注意力模块构建复数域挤压激励 (Complex-valued Squeeze-and-Excitation, CSE)^[28], 主干 CV-CNN 分支和实值 VGG 分支均配置 ReLU 激活函数与最大池化层, 初始学习率设为 0.01; 预训练 CV-CFEM 分支采用 0.001 的较低学习率, 并结合余弦退火学习率调度策略, 以有效缓解预训练知识遗忘问题。训练过程中设置批次大小为 32, 训练周期为 100 次, 选用带动量的随机梯度下降 (Stochastic Gradient Descent, SGD)^[29] 优化器, 并以交叉熵为损失函数。




图 10 M3Net 识别结果

结合图 9 与图 10 可以看出, M3Net 在集装箱船识别上达到 80.67% 的准确率, 相比单独的 NC+CSK 方法和预训练 CV-CFEM 虽略有下降但优于 CV-CNN, 并且在油轮识别上取得 80.55% 的最高准确率, 较 CV-CNN 和 CV-CFEM 均有提升, 显示出更好的均衡性。值得注意的是, M3Net 在最具挑战性的散货船识别任务中表现突出, 准确率达到 73.85%, 远超其他单一方法。

在识别混淆方面, M3Net 将散货船误判为集装箱船的概率降至 21.15%, 油轮误判率也控制在 7.52% 的较低水平。整体来说, M3Net 的识别准确率不仅始终优于各单一方法的最低值, 而且在多个重要分类任务中突破了单一方法的性能上限。

表 2 展示了选用不同复数域注意力机制对 M3Net 的影响, 其中最优结果用粗体表示。对比实验表明, 采用 CSE 注意力机制的 M3Net 展现出最优异的综合性能, 不仅取得了最高 OA, 同时保持了最低的极差值, 说明该注意力机制能有效平衡不同船型的分类精度。相

比之下, 无注意力机制的模型虽然 OA 达到 76.87%, 但极差值明显增大, 表明注意力机制对模型稳定性的重要作用。值得注意的是, 采用复数域高效通道注意力 (Complex-valued Efficient Channel Attention, CECA)^[13] 的模型虽然 OA 达到次优, 但极差值高达 28.88%, 反映出该注意力机制可能导致严重的类别偏差问题。而复数域坐标注意力 (Complex-valued Coordinate Attention, CCA)^[30] 的表现介于中间水平, OA 为 77.08%, 极差值 13.94%。综合上述分析, CSE 注意力机制在实现多类复值信息特征的动态加权融合的同时, 能够更好地协调不同船型的特征学习, 避免出现明显的类别偏好, 从而实现了性能与稳定性的平衡。

表 2 采用不同注意力的 M3Net 对比实验 单位: %

注意力	散货船	集装箱船	油轮	极差值	OA
M3Net (CSE)	73.85	80.67	80.55	6.82	78.66
无注意力	67.55	81.40	78.97	13.85	76.87
+CECA	59.00	87.88	83.45	28.88	78.56
+CCA	67.80	81.74	78.83	13.94	77.08

综合上述分析, M3Net 通过多分支多复值信息的深度融合, 不仅保留了各方法的专长, 更通过复数域注意力机制和特征融合策略有效弥补了单一方法的局限性, 最终实现了在保持集装箱船高识别率的同时, 显著提升了散货船和油轮的分类性能, 为复杂场景下的 SAR 舰船识别提供了更可靠的解决方案。

4.4 M3Net 消融实验

消融实验结果如表 3 所示, 其中最优结果用粗体表示, 结果表明 M3Net 模型在舰船分类识别任务中展现出卓越的性能。完整 M3Net 模型取得了 78.66% 的最高 OA, 同时保持了最小的极差值 6.82%, 这表明该模型不仅分类精度高, 而且在不同船型间的预测结果最为均衡稳定。对比实验显示, 单独使用 CV-CNN 或预训练 CFEM 模块时, 虽然能获得 72.77% 和 77.16% 的 OA, 但极差值分别达到 16.84% 和 20.72%, 说明这些模块存在明显的类别偏差问题。值得注意的是, NC+CSK 模块的极差值高达 28.25%, 反映出其特征表达的局限性。(a)+(b) 和 (a)+(c) 组合虽然 OA 有所提升, 但仍无法达到完整模型的性能水平, 且极差值明显更大。CFEM 分支未使用预训练的 M3Net 版本极差达到 22.76%, 显著高于完整模型, 这充分说明了预训练策略对 CFEM 稳定性的重要贡献。综合上述分析, M3Net 通过设计的多分支多信息多深度特征融合架构, 成功实现了分类精度和稳定性的双重提升, 为多复值信息舰船识别任务提供了一个有效融合方案。

4.5 不同方法对比试验

表 4 系统性汇总了以 CV-CNN 为骨干网络的各类改进方法的识别性能指标, 其中最优结果用粗体表示,

表3 M3Net消融实验					
单位: %					
	散货船	集装箱船	油轮	极差值	OA
CV-CNN (a)	62.75	75.73	79.59	16.84	72.77
预训练CFEM (b)	64.05	84.77	77.17	20.72	77.16
NC+CSK (c)	55.15	83.40	81.31	28.25	74.76
(a)+(b)	63.75	81.48	79.86	17.73	75.99
(a)+(c)	64.45	81.37	85.59	21.14	77.34
M3Net无预训练	61.45	81.98	84.21	22.76	76.49
M3Net	73.85	80.67	80.55	6.82	78.66

表4 以CV-CNN为骨干的识别结果对比					
单位: %					
方法	散货船	集装箱船	油轮	极差值	OA
CV-CNN	62.75	75.73	79.59	16.84	72.77
+CRIA _{sr}	66.20	78.84	78.62	12.64	75.12
+预训练	62.40	78.43	78.76	16.36	73.85
CV-CFEM	57.90	83.14	77.45	25.24	74.62
预训练CV-CFEM	64.05	84.77	77.17	20.72	77.16

其作为方法演进过程的量化记录,为后续 M3Net 的性能对比提供了基准参照.

表5展示了M3Net与VGG16、ResNet18的对比实验结果,其中最优结果用粗体表示,还引入了CVGG^[17]、复制注意力机制(Complex-valued Attention Module, CAM)^[31]与SAR船舶分类网络(HOG-ShipCLSNet)^[32]中方法在OpenSARship数据集的3分类结果.由表5的结果可以看出,M3Net展现的优异综合性能.在模型稳定性方面,M3Net以6.82%的极差值显著优于HOG-ShipCLSNet的15.19%和CResNet34的51.64%,同时保持78.66%的最高OA.具体来看,M3Net在散货船、集装箱船和油三个类别的识别精度均超过73%,实现了优异的均衡性能.与次优方法HOG-ShipCLSNet相比,M3Net在保持相近OA的同时,将极差值降低55%,特别是在散货船识别上提升3.42%.这种性能优势源于M3Net的多复值信息特征融合机制,有效解决了CResNet34等模型存在的严重类别偏差问题,为实际舰船识别应用提供了更可靠的解决方案.值得注意的是,CVGG到CVGG+CAM的改进验证了注意力机制的有效,而M3Net通过多分支、多信息、多深度的复值特征融合设计理念,在保持相近稳定性的同时,将OA进一步提升至78.66%,展现出结构的独特优势.

在数据集的划分策略上,本文采用每类样本的70%作为训练集,而非文献中的以最少类70%样本量统一限制所有类别.这种设置显著扩充了训练数据的规模和多样性,使网络能够更充分地学习复杂的复值信息特征,从而提升模型的表征能力.尽管受硬件条件限制,本文提出的M3Net网络参数量远少于对比方法,但其精简的架构设计仍能有效捕捉关键特征,同时避免了过参数化带来的计算负担.这种权衡使得在有限

表5 与其他方法的对比实验					
单位: %					
方法	散货船	集装箱船	油轮	极差值	OA
VGG16	50.50	71.80	79.31	28.81	67.20
ResNet18	55.00	62.21	78.62	23.62	63.57
CV-CNN	62.75	75.73	79.59	16.84	72.77
CResNet34 ^[17]	35.98	87.62	49.32	51.64	70.05
CVGG ^[17]	62.80	73.61	75.34	12.54	71.07
CVGG+CAM ^[27]	71.95	76.00	77.39	5.44	74.90
HOG-ShipCLSNet ^[26]	70.43	79.95	85.62	15.19	78.16
M3Net	73.85	80.67	80.55	6.82	78.66

资源下,模型仍能保持与大型网络的对比可行性,且通过数据利用率的优化弥补了参数量级的差距,为实验结果的可比性提供了合理基础.同时,在Intel(R) Core(TM) i7-11800H CPU与GeForce RTX 3060显卡的环境中,M3Net训练耗时约是CV-CNN的3.5倍.相比于CV-CNN,M3Net的结构更为复杂,训练速度较慢.相较于经典骨干网络VGG16和ResNet18,本文所提的M3Net训练总耗时略多.

5 结论

本文围绕复数SAR图像舰船识别任务,系统性地提出了深度复值特征提取模块CFEM和多复值信息特征融合网络M3Net,通过复数域特征表达与多复值信息融合,显著提升了舰船识别的精度与类别均衡性.首先,本文构建了级联式复卷积-CRIA-自适应池化结构的CFEM模块,结合预训练策略有效解决了数据不足导致的性能瓶颈,增强了复数特征提取能力.随后,系统分析了复值信息统计特征(NC与CSK)的可分性,探索了滑窗尺寸对特征提取的影响,为多复值信息融合奠定基础.在此基础上设计了M3Net网络,通过多分支、多深度特征融合架构和复数域注意力机制动态整合异构特征,在保持高识别精度的同时显著降低了类别间性能差异.实验表明,所提方法在复数SAR舰船识别任务中展现出优越的综合性能,不仅超越了传统单一方法的识别准确率,更有效改善了类别不平衡问题,为复杂场景下的目标识别提供了新的思路.

参考文献

[1] ZHANG C, ZHANG X, GAO G L, et al. Development and application of ship detection and classification datasets: A review[J]. IEEE Geoscience and Remote Sensing Magazine, 2024, 12(4): 12-45.

[2] GAO G, WANG M X, ZHOU P, et al. A multibranch embedding network with bi-classifier for few-shot ship classification of SAR images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2025, 63: 5201515.

- [3] ZHANG Y P, LU D D, QIU X L, et al. Scattering-point topology for few-shot ship classification in SAR images[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2023, 16: 10326-10343.
- [4] LI Y X, LAI X D, WANG M W, et al. C-SASO: A clustering-based size-adaptive safer oversampling technique for imbalanced SAR ship classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 5231112.
- [5] RAJ J A, IDICULA S M, PAUL B. One-shot learning-based SAR ship classification using new hybrid siamese network[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19: 4017205.
- [6] WANG L, QI Y H, MATHIOPOULOS P T, et al. An improved SAR ship classification method using text-to-image generation-based data augmentation and squeeze and excitation[J]. Remote Sensing, 2024, 16(7): 1299.
- [7] LI L, WANG C, ZHANG H, et al. SAR image ship object generation and classification with improved residual conditional generative adversarial network[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19: 4000105.
- [8] XU Y J, LANG H T. Distribution shift metric learning for fine-grained ship classification in SAR images[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2020, 13: 2276-2285.
- [9] HE J L, WANG Y H, LIU H W. Ship classification in medium-resolution SAR images via densely connected triplet cnns integrating fisher discrimination regularized metric learning[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 59(4): 3022-3039.
- [10] HUANG Z L, DATCU M, PAN Z X, et al. Deep SAR-Net: Learning objects from signals[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2020, 161: 179-193.
- [11] YU L J, HU Y H, XIE X C, et al. Complex-valued full convolutional neural network for SAR target classification[J]. IEEE Geoscience and Remote Sensing Letters, 2020, 17(10): 1752-1756.
- [12] ZHANG Y, YUAN H X, LI H B, et al. Complex-valued graph neural network on space target classification for defocused ISAR images[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19: 4512905.
- [13] ZHOU X Q, LUO C, REN P, et al. Multiscale complex-valued feature attention convolutional neural network for SAR automatic target recognition[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2024, 17: 2052-2066.
- [14] ZENG Z Q, SUN J P, HAN Z, et al. SAR automatic target recognition method based on multi-stream complex-valued networks[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 5228618.
- [15] WANG R N, WANG Z C, XIA K W, et al. Target recognition in single-channel SAR images based on the complex-valued convolutional neural network with data augmentation[J]. IEEE Transactions on Aerospace and Electronic Systems, 2023, 59(2): 796-804.
- [16] 方澄, 管方恒, 李天驰, 等. 端到端全复数域SAR目标分类神经网络[J]. 电子学报, 2024, 52(7): 2449-2460.
- FANG C, GUAN F H, LI T C, et al. End-to-end full complex-valued domain SAR target classification neural network[J]. Acta Electronica Sinica, 2024, 52(7): 2449-2460. (in Chinese)
- [17] HAO D D, ZHANG Z, LU D D, et al. CVGG-Net: Ship recognition for SAR images based on complex-valued convolutional neural network[J]. IEEE Geoscience and Remote Sensing Letters, 2023, 20: 4010805.
- [18] ZHANG Y, HUA Q L, JIANG Y C, et al. CV-Motion-Net: Complex-valued convolutional neural network for SAR moving ship targets classification[C]//2021 IEEE International Geoscience and Remote Sensing Symposium IGARSS. Piscataway: IEEE, 2021: 4280-4283.
- [19] HUA Q L, ZHANG Y, WEI C X, et al. CV-RotNet: Complex-valued convolutional neural network for SAR three-dimensional rotating ship target recognition[C]//IGARSS 2022-2022 IEEE International Geoscience and Remote Sensing Symposium. Piscataway: IEEE, 2022: 3552-3555.
- [20] 张云, 化青龙, 姜义成, 等. 基于混合型复数域卷积神经网络的三维转动舰船目标识别[J]. 电子学报, 2022, 50(5): 1042-1049.
- ZHANG Y, HUA Q L, JIANG Y C, et al. Recognition of 3D rotating ship based on Mix-CV-CNN[J]. Acta Electronica Sinica, 2022, 50(5): 1042-1049. (in Chinese)
- [21] WANG H T, JI Z Y, HUA Q L, et al. CRIA: An enhancement method for CV-CNN based on cross-fusion of complex information of real and imaginary activations[C]//2024 IEEE International Geoscience and Remote Sensing Symposium (IGARSS). Athens: IEEE, 2024: 10285-10288.
- [22] LENG X G, JI K F, ZHOU S L, et al. Noncircularity parameters and their potential in ship detection from high resolution SAR imagery[C]//2017 IEEE International Geoscience and Remote Sensing Symposium (IGARSS). Piscataway: IEEE, 2017: 1876-1879.
- [23] BRADLEY D, MORRIS J M, ADALI T, et al. On the detection of RFI using the complex signal kurtosis in microwave radiometry[C]//2014 13th Specialist Meeting on Microwave Radiometry and Remote Sensing of the Environment (MicroRad). Piscataway: IEEE, 2014: 33-38.
- [24] 冷祥光. 基于单通道SAR图像复值信息的舰船目标检

测技术研究[D]. 长沙: 国防科技大学, 2019.

LENG X G. Study on Ship Detection Technology Based on Complex-Valued Information in Single-Channel SAR Imagery[D]. Changsha: National University of Defense Technology, 2019. (in Chinese)

- [25] LENG X G, JI K F, ZHOU S L, et al. Ship detection based on complex signal kurtosis in single-channel SAR imagery[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 57(9): 6447-6461.
- [26] HUANG L Q, LIU B, LI B Y, et al. OpenSARShip: A dataset dedicated to Sentinel-1 ship interpretation[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2018, 11(1): 195-208.
- [27] ZHANG T W, ZHANG X L. Squeeze-and-excitation laplacian pyramid network with dual-polarization feature fusion for ship classification in SAR images[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19: 4019905.
- [28] MAKHIJA S, MANDAL S, PANDYA U, et al. PolSAR

image classification using complex-valued squeeze and excitation network[M]//Pattern Recognition. Cham: Springer Nature Switzerland, 2024: 270-286.

- [29] AMARI S I. Backpropagation and stochastic gradient descent method[J]. Neurocomputing, 1993, 5(4/5): 185-196.
- [30] ZHANG Y P, ZHANG Q, KANG L, et al. End-to-end recognition of similar space cone-cylinder targets based on complex-valued coordinate attention networks[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 60: 5106214.
- [31] PAN H X, YANG C, YIN Y F, et al. Feature attention complex-valued-based CNN for ship target recognition of SAR images[C]//2024 IEEE International Conference on Signal, Information and Data Processing. Piscataway: IEEE, 2025: 1-5.
- [32] ZHANG T W, ZHANG X L, KE X, et al. HOG-Ship-CLSNet: A novel deep learning network with hog feature fusion for SAR ship classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 5210322.

作者简介



王浩添 男, 2000年生, 河北沧州人. 现为哈尔滨工业大学硕士研究生. 主要研究方向为SAR图像处理.
E-mail: wanghaotian_hit@163.com



郭昭欣 男, 2001年生, 河南洛阳人. 现为哈尔滨工业大学博士研究生. 主要研究方向为雷达信号分析与智能信号处理. 中国电子学会会员编号: E190185791A.
E-mail: 1805919616@qq.com



冀振元 男, 1972年生, 黑龙江五常人. 现为哈尔滨工业大学教授、硕士生导师. 主要研究方向为海态遥感、雷达成像、目标识别.
E-mail: jizhenyuan@hit.edu.cn



张云 女, 1975年生, 黑龙江虎林人. 现为哈尔滨工业大学教授、博士生导师. 主要研究方向为雷达信号处理、SAR成像、机器学习和遥感模式分析.
E-mail: zhangyunhit@hit.edu.cn



化青龙 男, 1995年生, 安徽阜阳人. 现为哈尔滨工业大学副研究员. 主要研究方向为雷达图像处理和深度学习网络框架.
E-mail: huaqinglong@hit.edu.cn