

西安电子科技大学

硕士学位论文



基于神经网络的海杂波模型参数估计及海杂波抑制方法研究

作者姓名_____贺振鸽_____

学校导师姓名、职称_____水鹏朗 教授_____

企业导师姓名、职称_____郭永明 高工_____

申请学位类别_____工程硕士_____

学校代码 10701
分 类 号 TN95

学 号 22021211671
密 级 公开

西安电子科技大学

硕士学位论文

基于神经网络的海杂波模型参数估计及海杂波抑制方法研究

作者姓名：贺振鸽

领 域：电子信息

学位类别：工程硕士

学校导师姓名、职称：水鹏朗 教授

企业导师姓名、职称：郭永明 高工

学 院：电子工程学院

提交日期：2025 年 6 月

Research on Parameters Estimation of Sea Clutter Model and Sea Clutter Suppression Method Based on Neural Networks

A thesis submitted to
XIDIAN UNIVERSITY
in partial fulfillment of the requirements
for the degree of Master
in Electronic Information

By

He Zhengge

Supervisor: Shui Penglang Title: Professor

Supervisor: Guo Yongming Title: Senior Engineer

June 2025

摘要

对海雷达进行海面监测时,目标回波常常淹没在强的海杂波中,海杂波对雷达目标检测性能构成了严重影响。海杂波的精细化建模和准确的参数估计是实现海杂波背景下目标检测的重要前提。海杂波抑制方法是提升海杂波背景下目标检测性能的重要技术手段。近年来,神经网络凭借其强大的数据学习能力、特征提取能力、和时间序列描述能力得到了深入的研究和广泛的应用。海杂波模型参数估计和海杂波抑制是神经网络应用的两个重要方面。

对海雷达回波中常常包含了目标回波、海杂波、和雷达接收机的热噪声。一些应用场景中,如监视场景远区的海杂波噪声混合区和长时累积下多普勒域的海杂波和噪声混合区,接收机噪声不能够忽略。这种情况下需要采用海杂波加噪声模型, K -分布杂波加噪声是常用的模型之一,称作 $K+N$ 模型。然而,目前的 $K+N$ 模型参数估计多采用 2-4-6 阶矩估计方法,估计精度低而且不具备抗数据中的异常样本能力。因此,准确稳健的 $K+N$ 模型参数估计方法的研究对海面雷达的目标检测具有重要意义。此外,长观测时间下海面小目标检测研究方面,基于神经网络的海杂波时间序列建模和海杂波抑制是最早采用的技术途径之一。近年来神经网络和人工智能迎来了新的发展热潮,各种新型的神经网络被陆续构建满足不同的应用需求。尝试利用新型的神经网络实现海杂波时间序列的预测和抑制具有潜在的应用价值。针对上面两个问题,本论文开展了基于神经网络的海杂波模型参数估计和海杂波抑制方法研究。

论文主要研究内容和工作概括如下:

首先阐述了本论文的研究背景和理论基础。分别介绍了对海雷达 K -分布杂波加噪声模型参数估计和海杂波抑制方法的研究意义及国内外研究发展现状。然后介绍了复合高斯模型基本框架,对使用较为广泛的四种双参数复合高斯模型进行详细介绍,并分别对各模型的参数估计方法进行简要回顾。最后介绍了几种常见的神经网络结构。

然后针对 $K+N$ 模型现有的基于矩的参数估计方法估计精度低且不具备抗异常样本的能力的问题,提出了利用多样本分位点和截断矩的基于广义回归神经网络 (General Regression Neural Network, GRNN) 的稳健参数估计方法。首先证明了在固定杂噪比的情况下, $K+N$ 分布中分位点比和截断矩比与噪声功率无关、只和杂噪比有关的特性。基于此生成了神经网络的训练数据。之后,从训练数据训练得到的 GRNN 建立了从样本分位点和截断矩比值向量到 $K+N$ 模型的形状参数、杂噪比的非线性映射。将样本分位点和截断矩比值向量输入网络得到模型参数的估计。最后,分别利用仿真数据与实测数据对该方法在估计准确度和稳健性方面的表现进行了全面检验。

最后针对原有的基于神经网络的方法仅考虑对海杂波幅度序列进行抑制,而不能

实现针对相位序列或者复序列的有效抑制的问题,提出了基于时变自适应动目标显示(Moving Target Indication, MTI)滤波与幅度-相位双神经网络预测级联的海杂波抑制和目标检测方法。首先对数据进行重构,数据重构包括两次滑窗过程,第一次滑窗是为了满足虚警率的要求,第二次滑窗是解决训练数据不足的问题。低阶的 MTI 滤波实现了线性海杂波抑制。对于每个数据集,取 MTI 滤波后的纯杂波幅度和相位序列分别进行训练得到幅度和相位的长短时记忆(Long Short-Term Memory, LSTM)神经网络模型,使用模型进行幅度和相位的预测,再根据预测误差构建检验统计量。IPIX 实测雷达数据集的实验结果表明,检测结果和信杂比是高度依赖的。当目标回波的信杂比不低时,提出的海杂波抑制和目标检测方法能够获得更好的检测性能。

关 键 词: 海杂波时间序列, 广义回归神经网络, 长短时记忆神经网络, K-分布杂波加噪声, 参数估计, 海杂波抑制

ABSTRACT

When maritime radars surveil the sea surface, radar returns of targets of interest are often submerged into strong sea clutter and sea clutter severely affects effective detection of targets. Subtle modeling of sea clutter and accurate parameter estimation of sea clutter models are important foundations of target detection in sea clutter. Moreover, sea clutter suppression methods are important technique approach to improve target detection performance in sea clutter. In recent, owing to the strong abilities of data learning, feature extraction, and time series analysis and representation, neural networks are deeply investigated and widely applied in various fields. Parameter estimation of sea clutter models and sea clutter suppression are two important aspects of neural networks to apply.

Returns of maritime radars often contain target returns, sea clutter, and thermal noise of radar receiver. In some application scenarios, for example, in the mixture of sea clutter and noise in the far range region and the clutter-noise-mixture region in the Doppler domain for longtime coherent integration, noise cannot be ignored. The situation needs to adopt the mixture models of sea clutter plus noise and K-distributed clutter plus noise is a commonly-used model and is referred to as the K+N model. However, the parameter estimation of the K+N model mainly uses the method of the second-fourth-sixth-order moments and this method has lower accuracy and is not robust to outliers in data. Thus, it is meaningful to investigate accurate and robust parameter estimation method of the K+N model for maritime radar target detection. In addition, in maritime radar small target detection in long observation time, sea clutter time series modeling and sea clutter suppression using neural networks is one of the earliest approaches to resolve this difficulty problem. In recent years, neural networks and artificial intelligence receive new development. Various types of neural networks are constructed to meet different demands in applications. It has potential application value to try new neural networks to realize sea clutter time series prediction and sea clutter suppression. Aiming at these two issues, the thesis investigates the parameter estimation method of sea clutter models and sea clutter suppression method using neural networks.

The main research content of this thesis can be summarized as follows:

Firstly, the research background and theoretical foundation of this thesis are presented. Specifically, the research significance and the current state of domestic and international developments in parameter estimation for sea radar K-distribution clutter with added noise and sea clutter suppression methods are introduced. Then, the basic framework of the compound Gaussian model is explained, followed by a detailed introduction to the four biparametric compound Gaussian models. A brief review of the parameter estimation methods for these models is provided. Finally, several commonly used neural network structures are introduced.

Then, in view of the low estimation accuracy and lack of robustness against outlier samples in existing moment-based parameter estimation methods for the K+N model, a robust parameter estimation method based on the generalized regression neural network (GRNN) is proposed to estimate the parameters of the K+N model, which uses the ratios of the sample percentiles and the ratios of the sample truncated moments of data as input. Firstly, it was proved that the ratio of percentiles and the ratio of truncated moments are independent of noise power and only depend on the shape parameter of the K-distributed clutter and clutter-to-noise ratio (CNR) when the CNR is fixed. Based on this, the data to train the GRNN are generated, which consists of the ratio vectors attached by the shape parameter and CNR. From the training data, a GRNN is built to realize the nonlinear map from the ratio vector to the shape parameter and CNR. By replacing the ratio vector by the version using sample percentiles and truncated moments of data, an outlier-robust GRNN-based estimator is constructed. Finally, the simulated and measured data are used to verify the effectiveness of the proposed estimator in accuracy and robustness to outliers.

Finally, a view of the fact that existing neural network-based methods primarily focus on suppressing the sea clutter amplitude sequence, failing to achieve effective suppression of the phase sequence or complex sequence, a sea clutter suppression and target detection method is proposed, which is composed of a time-varying adaptive moving target indication (MTI) filter followed by amplitude-phase separate neural network predictors. Firstly, the data is reconstructed through a two-stage sliding window process. The first sliding window ensures compliance with the false alarm rate requirement, while the second addresses the issue of insufficient training data. The low-order MTI filter realizes linear sea clutter suppression. The filtered time sequence is decomposed into amplitude and phase sequences, For each dataset, the amplitude and phase sequences of the clutter-only data after MTI

ABSTRACT

filtering are separately used to train two long short-term memory (LSTM) neural networks to predict the amplitude and phase. The predicted errors are used to construct test statistics. Experimental results in the measured IPIX radar datasets show that the proposed method can obtain better detection performance when signal-to-clutter ratios (SCRs) are not very low.

Keywords: Sea clutter time series, Generalized regression neural networks, Long short-term memory neural networks, K-distributed clutter plus noise, Parameters estimation, Sea clutter suppression.

插图索引

图 2.1	基于神经网络进行参数估计的流程图	15
图 2.2	BP 神经网络模型	21
图 2.3	RBF 神经网络结构图	22
图 2.4	GRNN 模型	24
图 2.5	LSTM 神经网络模型	26
图 3.1	基于 GRNN 的反函数的预测指标	36
图 3.2	基于 GRNN 的 K+N 模型参数估计流程图	36
图 3.3	固定 CNR=-3dB 三种方法在有无异常样本仿真数据下的比较	39
图 3.4	固定 CNR=0dB 三种方法在有无异常样本仿真数据下的比较	40
图 3.5	固定 $\nu=5$ 三种方法在有无异常样本仿真数据下的比较	41
图 3.6	固定 $\nu=10$ 三种方法在有无异常样本仿真数据下的比较	42
图 3.7	CNR 为 6.46dB 的实测数据下三种估计方法的拟合结果	44
图 3.8	CNR 为 -0.58dB 的实测数据下三种估计方法的拟合结果	45
图 4.1	海杂波数据划分示意图	48
图 4.2	数据重构过程	48
图 4.3	第二次滑窗过程	48
图 4.4	基于神经网络预测海杂波幅度序列的非相干检测器结构	49
图 4.5	基于神经网络预测海杂波复序列的非相干检测器结构	50
图 4.6	时变自适应 MTI 滤波器与非相干累积级联的目标检测流程	51
图 4.7	数据预处理过程	52
图 4.8	MTI 滤波-幅度、幅度-相位双 LSTM 预测-非相干累积级联的检测流程	54
图 4.9	数据功率图和目标和杂波预测误差直方图	54
图 4.10	不同模型的检测结果对比	56
图 4.11	训练过程中的幅度与相位损失曲线	57
图 4.12	MTI-幅度、相位-LSTM 预测级联的检测结果	57
图 4.13	四种杂波抑制方法在 20 组数据集下的检测概率	58
图 4.14	SCR 较高时海杂波和含目标回波的幅度相位预测对比图	60
图 4.15	SCR 较低时海杂波和含目标回波的幅度相位预测对比图	61

表格索引

表 3.1	三种方法拟合 CNR 为 6.46dB 的实测数据的测度值.....	43
表 3.2	三种方法拟合 CNR 为-0.58dB 的实测数据的测度值	46
表 4.1	海杂波幅度序列预测非相干累积检测方法与传统非相干累积检测方法的性能对比 (N=512, 虚警率 0.001)	55
表 4.2	MTI+非相干累积检测方法与 MTI+LSTM 幅度相位预测+非相干累积检测方法在五组 IPIX 数据集上的性能对比 (N=512, 虚警率 0.001)	59

符号对照表

符号	符号名称
$f(\cdot)$	概率密度函数
$f(\cdot \cdot)$	条件概率密度函数
$F(\cdot)$	累积分布函数
$\Gamma(\cdot)$	伽马函数
$K_\nu(\cdot)$	第二类 ν 阶修正 Bessel 函数
$\exp(\cdot)$	指数函数
$\ln(\cdot)$	自然对数
$E(\cdot)$	数学期望/取均值
$ \cdot $	取模值
$[\cdot]$	取整
$\text{var}(\cdot)$	取方差
$(\cdot)^T$	转置
$()^H$	共轭转置
$()^{-1}$	求逆
$\hat{x}$	估计值
dB	分贝
Hz	赫兹
H_0	零假设
H_1	备择假设
Π	求积
$\ \cdot\ _2$	2-范数
Σ	求和

缩略语对照表

缩略语	英文全称	中文对照
BP	Back Propagation	反向传播
CCDF	Complementary Cumulative Distribution Function	互补累积分布函数
CDF	Cumulative Distribution Function	累积分布函数
CFAR	Constant False Alarm Rate	恒虚警率
CGIG	Compound Gaussian model with Inverse Gaussian textures	逆高斯纹理复合高斯模型
CGLN	Compound Gaussian model with Log-Normal textures	对数正态纹理复合高斯模型
CGM	Compound Gaussian Model	复合高斯模型
CNR	Clutter-to-Noise Ratio	杂噪比
ECCDF	Empirical Complementary Cumulative Distribution Function	经验互补累积分布函数
ECDF	Empirical Cumulative Distribution Function	经验累积分布函数
EPDF	Empirical Probability Density Function	经验幅度概率密度函数
FMoM	Fractional Method of Moments	分数矩估计方法
GMD	Geometric Mean Distance	几何平均距离
GRNN	General Regression Neural Network	广义回归神经网络
IML	Iterative Maximum Likelihood	迭代最大似然
KLD	Kullback-Leibler Divergence	K-L 散度
KSD	Kolmogorov-Smirnov Distance	K-S 距离
LSTM	Long Short-Term Memory	长短时记忆
ML	Maximum Likelihood	最大似然
MoM	Method of Moments	矩估计方法
MTI	Moving Target Indication	动目标显示
PDF	Probability Density Function	概率密度函数
RBF	Radial Basis Function	径向基函数
RCS	Radar Cross Section	雷达截面积
RNN	Recurrent Neural Network	循环神经网络
SCR	Signal-to-Clutter Ratio	信杂比

SIRV	Spherically Invariant Random Vector	球不变随机向量
STAP	Space-Time Adaptive Processing	空时自适应处理
RRMSE	Relative Root Mean Square Error	相对均方误差

目录

摘要	I
ABSTRACT	III
插图索引	VII
表格索引	IX
符号对照表	XI
缩略语对照表	XIII
第一章 绪论	1
1.1 研究背景及意义	1
1.2 国内外研究现状	3
1.2.1 参数估计相关研究进展	3
1.2.2 海杂波抑制方法相关研究进展	4
1.3 主要研究内容与章节安排	5
第二章 复合高斯模型及参数估计方法与神经网络基础	7
2.1 引言	7
2.2 常见的海杂波复合高斯模型	7
2.2.1 复合高斯模型概述	7
2.2.2 K-分布模型	9
2.2.3 广义 Pareto 分布	10
2.2.4 CGIG 分布	11
2.2.5 CGLN 分布	12
2.3 常见的海杂波分布模型的参数估计方法	13
2.3.1 K-分布参数估计方法	13
2.3.2 广义 Pareto 分布参数估计方法	16
2.3.3 CGIG 分布参数估计方法	17
2.3.4 CGLN 分布参数估计方法	19
2.4 常见的神经网络	20
2.4.1 BP 神经网络	20
2.4.2 RBF 神经网络	22
2.4.3 广义回归神经网络	23
2.4.4 LSTM 神经网络	25
2.5 本章小结	27

第三章	基于神经网络的海杂波模型的稳健参数估计.....	29
3.1	引言.....	29
3.2	K+N 分布模型.....	30
3.3	基于 GRNN 的 K+N 模型的稳健参数估计	31
3.3.1	训练数据生成.....	31
3.3.2	GRNN 有效性分析	35
3.3.3	基于 GRNN 的 K+N 模型稳健参数估计	36
3.4	实验结果与分析.....	38
3.5	本章小结.....	46
第四章	基于神经网络的海杂波抑制及目标检测方法.....	47
4.1	引言.....	47
4.2	海杂波数据重构过程.....	47
4.3	海杂波抑制及目标检测方法.....	49
4.3.1	基于神经网络预测不同输入特征的海杂波抑制方法.....	49
4.3.2	时变自适应 MTI 海杂波抑制及检测方法	50
4.3.3	时变自适应 MTI 滤波与幅度-相位双神经网络预测级联的海杂波抑制方法.....	52
4.4	实验结果与性能分析.....	54
4.5	本章小结.....	61
第五章	总结与展望.....	63
5.1	总结.....	63
5.2	展望.....	64
参考文献		65
致谢		71
作者简介		73

第一章 绪论

1.1 研究背景及意义

作为海洋大国，我国拥有辽阔的海域和丰富的海洋资源。长期以来，对海洋开展全方位、深层次的综合开发利用是我国坚定不移推进的重点战略任务。海洋在经济、军事等多领域都具有重要价值，这也致使各国在海洋领域的国际竞争愈发激烈，海洋资源的争夺也不断升级，海洋安全成为热点议题。海洋安全涵盖传统与非传统两大安全类型议题。传统安全议题包括各国在地缘政治上的竞争和对于岛礁的主权争端等；非传统安全议题与海洋灾害、海上恐怖主义活动、海洋环境污染等紧密相关。一方面，国家间对关于各岛屿归属问题争议不断，对于海洋领土的划界问题有很大分歧，这些传统安全问题频频出现。另一方面，非传统安全挑战也在持续增多，各国围绕海洋环境污染问题展开多次讨论，矛盾冲突时常发生，对海洋资源开采利用问题也颇有争议，海洋科学考察、环境保护等公共事业在推进过程中遭遇重重阻碍，海外贸易和海洋航运面临的安全风险呈上升趋势^[1]。在全球海洋安全秩序的构建进程中，中国始终秉持“维护海洋的和平与安宁，是国际社会共同的责任”这一理念，积极倡导各国海军加强海上对话交流，共同实现互利共赢的海上安全发展道路。这要求中国必须拥有强大的海上力量来维护自身的海洋权益。

雷达作为海战场中的千里眼，是一种利用电磁波反射特性进行探测的电子设备^[2]。雷达发射机产生特定频段的电磁波信号，经天线发射电磁波，电磁波传播过程中遇到目标时，部分能量反射形成目标回波，目标回波会由天线接收传至雷达接收机。由于电磁波具有穿透性强、受天气影响小等特性，这使得雷达具备远程探测和全天候工作的能力，可在复杂气象条件下对海面目标进行快速、精确的探测与跟踪。作为一种成熟且广泛应用的海面目标探测技术手段，雷达在民用海洋监测、海事交通管理、渔业资源调查以及军事海防预警、目标搜索与火控引导等领域均发挥着不可替代的重要作用。持续推动雷达技术的创新与发展，为我国海洋权益维护、海洋资源开发、海上安全保障等海洋事业的全面发展提供坚实的技术支撑，助力我国向海洋强国战略目标稳步迈进。

海杂波是雷达照射海表面后产生的后向散射回波，海杂波的统计特性与雷达工作参数、气象条件、海况参数和雷达照射关系等因素密切相关^[3,4]。海杂波建模关注的主要问题之一是海杂波的幅度/强度分布，在忽略热噪声的情况下，相关的幅度分布模型包括 Rayleigh 分布^[5]、对数正态(Lognormal)分布^[6]、和 Weibull 分布^[7]。随着对海杂波的研究逐渐深入，对海杂波的特性逐渐了解，包括 K-分布^[8]，广义 Pareto 分布^[9,10]、

CGIG (Compound Gaussian model with Inverse Gaussian textures, CGIG)分布^[11]、以及 CGLN(Compound Gaussian model with Log-Normal textures, CGLN)分布^[12]这些双参数复合高斯模型被提出用于海杂波建模。针对这些模型的参数估计的方法研究者们进行了大量研究,有矩估计方法(Method of Moments, MoM)^[9,13-17]、对数矩估计[zlogz]估计方法^[9,14,16,18]、最大似然(Maximum Likelihood, ML)估计方法^[9,18,19]、以及对含异常样本的情况下能够兼具“精确性”和“稳健性”的一系列基于分位点的参数估计方法^[20-25]。但是对海雷达回波中不仅包含了目标回波和海杂波,往往还有雷达接收机的热噪声。一些应用场景中,如监视场景远区的海杂波噪声混合区和长时累积下多普勒域的海杂波和噪声混合区,接收机噪声不能够忽略。这种情况下需要采用海杂波加噪声模型,研究发展了包括 $K+N$ ^[26,27], Pareto+N^[28,29], CGIG+N 等模型,实测数据表明,这些模型对含有噪声的海杂波数据可以实现更好的拟合效果。 $K+N$ 模型是常用的海杂波加噪声模型,目前针对 $K+N$ 模型的参数估计方法的研究较少,主要是基于矩的估计方法。基于矩的估计方法在非高斯性比较强的数据中性能较差,难以满足雷达目标检测的需要。不同于其它领域,海用雷达海杂波模型参数的估计是在非理想环境下的参数估计问题,海杂波数据样本中不可避免地存在少量由目标回波、岛礁回波、地杂波、海上其它固定目标(采油平台、风力发电塔、航标等)回波构成的异常样本,这些异常样本会导致基于矩的估计方法的估计性能急剧下降。近年来,深度学习技术持续取得新突破,结合神经网络进行参数估计也是一种新的途径。因此,准确稳健的 $K+N$ 模型参数估计方法的研究对海面雷达的目标检测具有重要意义。

此外,在长观测时间下海面小目标检测研究方面,由于海洋监视雷达监测海表面时,其回波信息不仅包含目标信息,还不可避免的混杂着海杂波,海杂波的存在会显著降低信杂比(Signal-to-Clutter Ratio, SCR),而信杂比的降低会进而导致目标检测概率的降低。具体而言,海杂波对海洋监视雷达的检测性能影响主要表现在以下两个方面:首先,海面小目标一般指雷达截面积(Radar Cross Section, RCS)较小的目标,较小的 RCS 通常意味着雷达回波微弱,在临界信杂比的情况下,使用传统的基于幅度/功率的检测方法很难实现有效检测^[6];其次,在高海况下,海杂波的幅度显著增强,将会导致海杂波背景下的目标检测变得更困难,从而增加虚警率^[30]。由于海杂波受气象、时间、位置等因素影响较大,海况、波浪等各因素都会影响目标检测,导致误判漏判的情况,因此传统方法的适应能力有限,抑制效果也存在明显的性能瓶颈。近年来,神经网络凭借其强大的数据学习能力、特征提取能力、和时间序列描述能力再次得到了深入的研究和广泛的应用,基于神经网络的海杂波抑制方法受到了广泛关注,因此,发展基于神经网络的海杂波抑制方法对后续进行目标检测具有重要意义,尝试利用新型的神经网络实现海杂波时间序列的预测和抑制具有潜在的应用价值。

1.2 国内外研究现状

1.2.1 参数估计相关研究进展

海杂波的精细化建模和准确的参数估计是实现海杂波背景下目标检测的重要前提^[3]。对于双参数海杂波幅度分布概率模型,已经存在很多不同类型的参数估计方法可以从数据样本中估计模型参数。其中,基于矩的估计方法因其数学形式简洁、计算简便且易于实现,在实际应用中被广泛采用,然而,对不同类型的非高斯性海杂波数据,基于矩的估计方法若想取得理想的估计效果,矩的阶数选择至关重要,一旦阶数选择过高,在实际应用过程中就会产生较大的误差,从而影响最终的估计准确度。最大似然估计方法通过寻找其样本集合联合概率密度的最大值点获得估计值,与矩估计不同,最大似然方法适用性更广泛,并且在纯杂波环境中,最大似然方法往往能实现极佳的估计性能。然而,在多数情形下,运用最大似然估计方法难以获取参数的显式估计形式,一般只能借助数值方法来得出参数的估计结果。并且由于海杂波数据样本中不可避免地存在少量异常样本,上述矩估计方法和最大似然估计方法在含异常样本的数据中估计性能会急剧下降。由于数据样本分位点和截断矩^[24]具有稳健特性,受异常样本影响较小,针对传统方法无法在含异常样本情况下进行稳健参数估计的问题,研究发展了一系列基于分位点和截断矩的稳健参数估计方法^[22-24,31-33],这些方法能够在含异常样本的数据中实现稳定的参数估计。

K-分布是目前应用最广泛的海杂波分布模型,其参数估计方法倍受关注^[19]。K-分布的最大似然估计方法的估计精度高,但是缺乏解析表达式,计算量过大。而采用矩估计 MoM^[34]、分数矩估计(Fractional MoM, FMoM)^[15]、对数矩估计[zlogz]^[18]来估计 K-分布杂波参数虽然易于实现,但是精度比较低。D. Iskander 等提出了 ML 和 MOM 的组合来估计 K-分布的参数^[35], J. M. Fernández 等提出利用神经网络和深度学习来估计 K-分布杂波形状参数^[36]。但是以上方法在含有异常样本的数据中估计性能会变差,为了能在含有异常样本的海杂波背景下获得良好的参数估计性能,发展出了一些稳健的参数估计方法。Yu 等人提出了 K-分布的基于分位点的估计器^[24],估计器在仿真和实测的雷达数据上表现出稳健的性能,然而,由于缺乏相应的解析表达式,基于分位点的估计器中的估计值不得不依赖于查表操作。Shi 等人提出了基于神经网络的利用分位点和矩的估计器^[25],以神经网络代替查表操作。Shui 等人利用截断的最大似然估计来减轻离群值对参数估计的影响^[37]。然而,上面对 K-分布海杂波参数估计方法是忽略了噪声的,在噪声背景下难以获得较好的估计效果,针对含噪声的海杂波数据建模,研究者们提出了包括 K+N, Pareto+N, CGIG+N 等复合高斯加噪声模型。对于 K+N 分布模型的参数估计方法研究较少,目前多采用矩估计方法, S. Watts 提出了基于整数阶矩的估计方法^[38], A. Mezache 等人在整数阶矩的基础上,提出分数阶矩

估计方法^[27]，基于矩的 $K+N$ 分布模型估计方法计算形式简单，并且计算速度较快。但是基于矩的估计方法估计精度低且不具备抗数据中的异常样本的能力。

综上，将神经网络与利用分位点及截断矩的估计方法结合是 $K+N$ 分布模型的稳健参数估计方法的方向之一。

1.2.2 海杂波抑制方法相关研究进展

海杂波抑制方法是提升海杂波背景下目标检测性能的重要技术手段，是雷达领域的重要研究方向。传统的海杂波抑制方法主要包括运动目标显示(Moving Target Indication, MTI)滤波、空时自适应处理(Space-Time Adaptive Processing, STAP)^[39]等。其中，MTI 杂波抑制方法用于抑制静止或慢速杂波，突出运动目标，能根据环境动态调整滤波器参数，以提升杂波抑制效果^[40]。STAP 方法结合了空域和时域信息，可以在复杂海杂波环境中提高目标检测性能，但是相比 MTI 滤波，STAP 更适用于阵列雷达和多通道雷达，其计算复杂度高，难以在实际应用中直接部署。MTI 滤波方法只能滤除线性杂波，对于非线性杂波抑制，可以采用使用了非线性激活函数的神经网络。基于神经网络的海杂波时间序列建模和海杂波抑制是在海面小目标检测研究方面最早采用的技术途径之一，Haykin 教授团队在海杂波时间序列分析中发现海杂波序列具有分形特性^[41]，并提出了海面小目标检测初始框架。基于分形维数的海面小目标检测方法可以看作是特征检测在海面小目标检测领域的“鼻祖”。基于海杂波序列具有的分形特征，研究者们研究了包括单分形特征、多重分形特征^[42]、多尺度分形^[43]等一系列检测方法。Haykin 教授还提出海杂波具有混沌特性，并指出海杂波具有有限相关维数以及海杂波是短期可以预测的^[44]。根据海杂波具有短期可预测的特性，首先计算嵌入维数与延迟，然后进行相空间重构，对重构后的序列构建一个非线性神经网络预测模型，然后借助预测残差实现统计检验，最终达成目标检测的目的^[45]。由于当时人工智能发展有限，选取的神经网络结构简单导致检测效果不理想，而且海杂波是否具有混沌特性尚有争议。但是这种基于神经网络的预测方法提供的异常检测思想成为本论文的一条思路。近年来，随着人工智能的飞速发展，研究者们提出了很多新的复杂神经网络。N.Xie 等人利用径向基函数(Radial Basis Function, RBF)神经网络对海杂波进行建模^[46]，但是由于 RBF 神经网络本质上是一种前馈神经网络，缺乏对时间序列数据的内在建模能力。为了进一步优化网络性能，引入了自适应人工神经网络集成方法以及改进的广义回归神经网络(General Regression Neural Network, GRNN)算法^[47,48]，这些网络都是静态网络。与这些静态网络相比，递归神经网络(Recurrent Neural Network, RNN)更适合于建模海杂波时间序列，近年来，RNN 在许多领域中都得到了广泛的应用^[49,50]，其关键特性在于能够利用前一时间步的隐藏状态来存储和传递历史信息，从而捕捉序列数据中的时间依赖关系，基于这个特点，RNN 在包括语音识别

和机器翻译等应用领域都展现了出色的效果。但是，在 RNN 训练过程中存在梯度爆炸或消失的问题。为了解决这个问题，Hochreiter 等人提出了一种称为“长短时记忆” (Long Short-Term Memory, LSTM) 的网络^[51]。相较于 RNN，LSTM 网络通过门控机制解决了梯度消失问题，能够更好地学习海杂波的复杂动态特性，提高预测精度^[52,53]。2019 年，Zhao 等人基于 LSTM 网络对海杂波功率进行了预测，对比使用反向传播 (Back propagation, BP) 神经网络，其预测误差更低^[54]。Ma 等人提出基于 LSTM 神经网络的海杂波幅度预测方法，利用 LSTM 神经网络预测海杂波幅度序列并基于预测误差进行目标检测，在一定程度上提高检测性能^[55]。近年来，一些研究尝试结合不同特征域信息，如基于时间-频率级联的神经网络模型，该方法说明联合不同特征域的信息有助于提升目标检测性能^[56]。然而，大多数研究仅关注幅度信息，忽略了相位信息，而相位信息在目标检测中具有重要作用。因此，结合自适应 MTI 滤波的线性杂波抑制能力和 LSTM 神经网络对海杂波幅度和相位的非线性预测能力，既能有效抑制杂波，又能提高小目标的检测性能。是海杂波抑制方法的一个新的方向。

1.3 主要研究内容与章节安排

本文主要研究基于神经网络的海杂波模型参数估计及海杂波抑制方法问题。针对 K+N 模型现有的基于矩的参数估计方法估计精度低且不具备抗异常样本的能力的问题，提出了利用多样本分位点和截断矩的基于 GRNN 的稳健参数估计方法，并结合仿真数据与实测数据对该方法在估计精度和稳健性方面的表现进行了全面检验。此外，针对原有的基于神经网络的方法仅考虑对海杂波幅度序列进行抑制，而不能实现对相位序列或复序列的有效抑制的问题，提出了基于时变自适应 MTI 滤波与幅度-相位双 LSTM 神经网络预测级联的海杂波抑制和目标检测方法。所提出的方法创新性添加了相位预测以达到对海杂波复序列的抑制，并且将传统杂波抑制方法和新型深度学习方法进行连接以增强海杂波抑制效果。并结合实测数据进行方法性能验证。

论文各章节的内容具体安排如下：

第一章绪论。首先阐述了本论文研究基于神经网络的海杂波模型参数估计及海杂波抑制方法的研究背景及意义，然后分别介绍对海雷达 K+N 模型参数估计方法和海杂波抑制方法的国内外研究发展现状，最后是本论文的研究内容与安排。

第二章研究基础。首先介绍复合高斯模型基本框架，然后对使用较为广泛的四种双参数复合高斯模型进行详细介绍。然后分别对这些模型的参数估计方法进行简要回顾。最后介绍了几种常见的神经网络结构。

第三章基于神经网络的海杂波模型的稳健参数估计。提出了利用多样本分位点和截断矩的基于 GRNN 的稳健参数估计方法。首先证明了在固定杂噪比(Clutter-to-Noise

Ratio, CNR)的情况下, $K+N$ 分布中分位点比和截断矩比与噪声功率无关、只和 CNR 有关的特性。基于此生成了神经网络的训练数据。将训练数据输入 GRNN 进行训练。并对训练得到的 GRNN 进行有效性分析, 然后给出了利用样本分位点和样本截断矩进行参数估计的流程。最后, 分别利用仿真数据与实测数据对该方法的估计准确度和稳健性进行检验。

第四章基于神经网络的海杂波抑制及目标检测方法。首先对数据进行重构, 包括两次滑窗处理: 第一次滑窗是为了满足预设的虚警率要求, 第二次滑窗是用于扩充训练数据以缓解数据不足的问题。然后介绍了基于海杂波幅度序列预测的海杂波抑制方法、基于海杂波复序列预测的海杂波抑制方法以及基于时变自适应 MTI 滤波的方法, 对这些方法的优势与存在的问题进行分析。并提出了基于 MTI 滤波与幅度-相位双 LSTM 神经网络预测级联的海杂波抑制方法, 该方法首先利用时变自适应 MTI 滤波实现对海杂波的线性滤波, 然后利用 LSTM 神经网络实现非线性杂波抑制, 取 MTI 滤波后的纯杂波幅度和相位序列分别进行网络训练得到幅度和相位的 LSTM 神经网络模型, 使用模型进行幅度和相位的预测, 再根据预测误差构建检验统计量。最后, 采用 IPIX 实测雷达数据集对所提方法的性能进行验证。

第五章总结与展望, 对论文所做工作进行简要的总结, 并对未来可进一步研究探索的工作进行展望。

第二章 复合高斯模型及参数估计方法与神经网络基础

2.1 引言

本论文基于神经网络分别研究了 K+N 分布模型的参数估计问题和海杂波的抑制与目标检测问题。海杂波建模及参数估计方法、神经网络的实现原理为本论文研究提供了重要的指导思想和理论依据。

海杂波的统计建模是海杂波特性分析、自适应目标检测等方面的重要基础。海杂波建模关注的主要问题之一是海杂波的幅度/强度分布。随着对海杂波形成物理机理定性认知的深入,复合高斯模型广泛应用于海杂波建模。目前,应用比较广泛的 K-分布模型、广义 Pareto 分布模型、CGIG 分布模型、CGLN 分布模型四种双参数模型的幅度分布模型,基本能够覆盖微波段雷达不同条件下海杂波数据幅度、强度分布的准确拟合。模型参数的估计精度会直接影响后续雷达信号处理的性能,针对四种双参数幅度分布模型已经存在很多不同类型的参数估计方法,随着深度学习的快速发展,神经网络凭借其强大的数据拟合能力逐渐应用在模型参数估计中。对海杂波进行抑制能够提升海杂波背景下的目标检测性能。近年来神经网络和人工智能迎来新的发展热潮,各种新型的神经网络被陆续构建满足不同的应用需求。尝试利用神经网络实现海杂波模型参数估计和海杂波时间序列的预测和抑制具有潜在的应用价值。

本章作为论文的相关研究基础,主要分为三部分。第一部分讲解复合高斯模型,首先对复合高斯模型的基本框架和结构进行介绍,然后讲解了四类双参数的海杂波复合高斯模型。第二部分对四类双参数幅度分布模型已有的参数估计方法进行系统总结,重点讨论 K-分布参数估计的相关方法。第三部分介绍预测神经网络,其中重点介绍对后续参数估计研究和海杂波抑制分别起到重要作用的 GRNN 和 LSTM 神经网络技术。

2.2 常见的海杂波复合高斯模型

2.2.1 复合高斯模型概述

复合高斯模型将海杂波描述为快变的复高斯散斑分量 $\mathbf{u}$ 与慢变的非负纹理分量 τ 的乘积,即:

$$\mathbf{c}(n) = \sqrt{\tau(n)}\mathbf{u}(n), n \in N \quad (2-1)$$

大量的微波段高分辨海杂波数据的分析表明：快变的散斑分量的去相关时间在几十毫秒内，纹理分量的相干长度可达零点几秒^[12]。在相干长度之内，随机序列可以用一个常数表示。大多数搜索和警戒雷达在每个波位的驻留时间都在几十毫秒之内，这种情况下，纹理分量可以用一个随机常数代替，CGM 将退化为球不变的随机向量模型(Spherically Invariant Random Vector, SIRV)^[57]。 N 个脉冲接收的海杂波向量表示为：

$$\mathbf{c} = \sqrt{\tau} \mathbf{u} \in \mathbb{C}^N, \tau \sim p_\tau(\tau), \mathbf{u} \sim \mathbb{CN}(\mathbf{0}, \mathbf{M}), \mathbf{M} \in \mathbf{S}_+^{N \times N} \quad (2-2)$$

其中 $\mathbb{C}^N$ 表示 N 维复向量空间， $\mathbb{CN}(\mathbf{0}, \mathbf{M})$ 表示零均值、协方差矩阵为 $\mathbf{M}$ 的复高斯随机向量， $\mathbf{S}_+^{N \times N}$ 表示 $N \times N$ 的 Hermite 对称正定矩阵构成的空间。在纹理给定的情况下，海杂波是复高斯杂波，杂波的幅度 $z = |c|$ ，杂波的强度 $I = |c|^2$ ，按照全概率公式，杂波、杂波幅度和强度的条件概率密度为：

$$\begin{aligned} p_c(c|\tau) &= \frac{1}{\pi\tau} \exp\left(-\frac{|c|^2}{\tau}\right), c \in \mathbb{C} \\ p_z(z|\tau) &= \frac{2z}{\tau} \exp\left(-\frac{z^2}{\tau}\right), z \in (0, +\infty) \\ p_I(I|\tau) &= \frac{1}{\tau} \exp\left(-\frac{I}{\tau}\right), I \in (0, +\infty) \end{aligned} \quad (2-3)$$

当纹理 τ 服从概率密度函数(Probability Density Function, PDF)为 $p(\tau)$ 时，根据全概率公式，可推导出杂波、杂波幅度及其强度的 PDF 表达式如下：

$$\begin{aligned} p_c(c) &= \frac{1}{\pi} \int_0^{+\infty} \frac{1}{\tau} \exp\left(-\frac{|c|^2}{\tau}\right) p_\tau(\tau) d\tau, c \in \mathbb{C} \\ p_z(z) &= \int_0^{+\infty} \frac{2z}{\tau} \exp\left(-\frac{z^2}{\tau}\right) p_\tau(\tau) d\tau, z \in (0, +\infty) \\ p_I(I) &= \int_0^{+\infty} \frac{1}{\tau} \exp\left(-\frac{I}{\tau}\right) p_\tau(\tau) d\tau, I \in (0, +\infty) \end{aligned} \quad (2-4)$$

研究者们提出了包括 Gamma 分布、逆 Gamma 分布、逆 Gaussian 分布、和对数正态分布者四种纹理分布，这些纹理分布分别产生了 K-分布海杂波模型、广义 Pareto 分布海杂波模型、CGIG 分布海杂波模型和对数正态纹理的海杂波模型。这四类双参数幅度模型基本能够覆盖微波段雷达不同条件下海杂波数据幅度、强度的准确拟合。

下面分别介绍这些模型的特性。

2.2.2 K-分布模型

K-分布是目前应用最为广泛的海杂波幅度分布模型，在 1976 年首次被引入到海杂波幅度建模中^[58]。K-分布中，纹理 τ 服从双参数的 Gamma 分布：

$$p(\tau; b, \nu) = \frac{\nu^\nu}{\Gamma(\nu)b^\nu} \tau^{\nu-1} \exp\left(-\frac{\nu}{b}\tau\right), \tau > 0; b, \nu \in (0, +\infty) \quad (2-5)$$

其中 $b = E\{\tau\}$ 是尺度参数和杂波的功率， ν 是纹理的形状参数。把(2-5)式的纹理概率密度带入(2-4)得到 K-分布的幅度和强度概率密度函数：

$$\begin{aligned} f(z; b, \nu) &= \frac{2\nu^\nu}{\Gamma(\nu)b^\nu} \int_0^{+\infty} z\tau^{\nu-2} \exp\left(-\left[\frac{z^2}{\tau} + \frac{\nu\tau}{b}\right]\right) d\tau \\ &= \frac{4z^\nu}{\Gamma(\nu)} \left(\frac{\nu}{b}\right)^{(\nu+1)/2} K_{\nu-1}\left(\frac{2z\sqrt{\nu}}{\sqrt{b}}\right), \\ f_I(I; b, \nu) &= \frac{2\nu^\nu}{\Gamma(\nu)b^\nu} \int_0^{+\infty} \tau^{\nu-2} \exp\left(-\left[\frac{I}{\tau} + \frac{\nu\tau}{b}\right]\right) d\tau \\ &= \frac{2I^{(\nu-1)/2}}{\Gamma(\nu)} \left(\frac{\nu}{b}\right)^{(\nu+1)/2} K_{\nu-1}\left(\frac{2\sqrt{\nu I}}{\sqrt{b}}\right), \\ K_\nu(x) &= \frac{1}{2} \int_0^{+\infty} \tau^{\nu-1} \exp\left(-\frac{x}{2}\left(\tau + \frac{1}{\tau}\right)\right) d\tau \end{aligned} \quad (2-6)$$

其中， $K_\nu(\bullet)$ 是阶数为 ν 的第二类修正的 Bessel 函数。

幅度和强度的累积分布函数为：

$$\begin{aligned} F(z; b, \nu) &= 1 - \frac{2z^\nu}{\Gamma(\nu)} \left(\frac{\nu}{b}\right)^{\nu/2} K_\nu\left(\frac{2z\sqrt{\nu}}{\sqrt{b}}\right), z > 0, \\ F(I; b, \nu) &= 1 - \frac{2I^{\nu/2}}{\Gamma(\nu)} \left(\frac{\nu}{b}\right)^{\nu/2} K_\nu\left(\frac{2\sqrt{\nu I}}{\sqrt{b}}\right), I > 0 \end{aligned} \quad (2-7)$$

当形状参数 $\nu \rightarrow +\infty$ 时，K-分布趋向于瑞利分布，即：

$$\lim_{\nu \rightarrow +\infty} \left\{ \frac{4}{\Gamma(\nu)} \sqrt{\frac{\nu}{b}} \left(z \sqrt{\frac{\nu}{b}} \right)^\nu K_{\nu-1} \left(\frac{2z\sqrt{\nu}}{\sqrt{b}} \right) \right\} = \frac{2z}{b} \exp\left(-\frac{z^2}{b}\right), \forall z > 0 \quad (2-8)$$

大多数常见的纹理概率密度函数都满足上述条件, 因此, 大多数复合高斯杂波模型形状参数趋于 $+\infty$ 时, 复合高斯杂波趋于复高斯杂波。这也是复合高斯模型中形状参数刻画了杂波非高斯性的原因。复高斯杂波可以理解为纹理概率密度函数为 $\delta(\tau-b)$ 的复合高斯杂波的特例。

K-分布的 n 阶原点矩的表达式为:

$$m_n(z; b, \nu) = E\{z^n\} = \frac{\Gamma(1+n/2)\Gamma(\nu+n/2)}{\Gamma(\nu)} \left(\frac{b}{\nu}\right)^{n/2}, n \in \mathbb{N} \quad (2-9)$$

2.2.3 广义 Pareto 分布

广义 Pareto 分布已经广泛应用于物理、工程、经济等众多领域^[59]。广义 Pareto 分布是海杂波双参数幅度/强度分布的重要类型, 其概率密度函数表达式为:

$$p_\tau(\tau; b, \nu) = \frac{(\nu-1)^\nu}{b\Gamma(\nu)} \left(\frac{b}{\tau}\right)^{\nu+1} \exp\left(-\frac{(\nu-1)b}{\tau}\right), \tau > 0; b > 0, \nu > 1 \quad (2-10)$$

形状参数 $\nu > 1$ 不是数学限制而是“海杂波功率有限”物理现实带来的限制。这种情况下, 幅度和强度的概率密度函数分别是:

$$\begin{aligned} f(z; b, \nu) &= \frac{2\nu z}{b(\nu-1)} \left[1 + \frac{z^2}{b(\nu-1)}\right]^{-(\nu+1)}, z > 0; b > 0, \nu > 1, \\ f(I; b, \nu) &= \frac{\nu}{b(\nu-1)} \left[1 + \frac{I}{b(\nu-1)}\right]^{-(\nu+1)}, I > 0; b > 0, \nu > 1 \end{aligned} \quad (2-11)$$

幅度和强度的累积分布函数分别是:

$$\begin{aligned} F(z; b, \nu) &= 1 - \left[1 + \frac{z^2}{b(\nu-1)}\right]^{-\nu}, z > 0; b > 0, \nu > 1, \\ F_I(I; b, \nu) &= 1 - \left[1 + \frac{I}{b(\nu-1)}\right]^{-\nu}, I > 0; b > 0, \nu > 1 \end{aligned} \quad (2-12)$$

不同于 K-分布, 广义 Pareto 分布的矩有时不存在, 由于其幅度和强度概率密度函数按照幂函数衰减。其幅度的 γ 阶原点矩满足:

$$m_{\gamma}(z; b, \nu) = \frac{\Gamma\left(\frac{\gamma}{2} + 1\right) \Gamma\left(\nu - \frac{\gamma}{2}\right)}{\Gamma(\nu)} b^{\frac{\gamma}{2}} (\nu - 1)^{\frac{\gamma}{2}}, 0 < \gamma < 2\nu \quad (2-13)$$

2.2.4 CGIG 分布

CGIG 分布 2012 年被引入复合高斯模型并用于高分辨海杂波的建模^[60,61]。其概率密度函数表达式为^[62]:

$$p(\tau; b, \nu) = \sqrt{\frac{b\nu}{2\pi}} \tau^{-3/2} \exp\left(-\frac{\nu\tau}{2b} \left(1 - \frac{b}{\tau}\right)^2\right), \tau > 0; b, \nu > 0. \quad (2-14)$$

其中 b 是尺度参数, ν 是形状参数。CGIG 分布的幅度和强度概率密度函数分别是:

$$\begin{aligned} f(z; b, \nu) &= \frac{2e^{\nu} z}{b\nu} \left(1 + \frac{2z^2}{b\nu}\right)^{-3/2} \left(1 + \nu\sqrt{1 + \frac{2z^2}{b\nu}}\right) \exp\left(-\nu\sqrt{1 + \frac{2z^2}{b\nu}}\right), \\ z > 0; b, \nu > 0, \\ f(I; b, \nu) &= \frac{e^{\nu}}{b\nu} \left(1 + \frac{2I}{b\nu}\right)^{-3/2} \left(1 + \nu\sqrt{1 + \frac{2I}{b\nu}}\right) \exp\left(-\nu\sqrt{1 + \frac{2I}{b\nu}}\right), \\ I > 0; b, \nu > 0 \end{aligned} \quad (2-15)$$

相应的, 复合高斯杂波的幅度和强度的累积分布函数分别是:

$$\begin{aligned} F(z; b, \nu) &= 1 - e^{\nu} \left(1 + \frac{2z^2}{b\nu}\right)^{-1/2} \exp\left(-\nu\sqrt{1 + \frac{2z^2}{b\nu}}\right), z > 0; b, \nu > 0, \\ F(I; b, \nu) &= 1 - e^{\nu} \left(1 + \frac{2I}{b\nu}\right)^{-1/2} \exp\left(-\nu\sqrt{1 + \frac{2I}{b\nu}}\right), I > 0; b, \nu > 0 \end{aligned} \quad (2-16)$$

CGIG 分布的 γ 阶原点矩满足:

$$m_{\gamma}(\tau; b, \nu) = b^{\gamma} e^{\nu} \sqrt{\frac{2\nu}{\pi}} K_{\gamma-1/2}(\nu), \gamma > 0 \quad (2-17)$$

随机变量 $z = \tau^{1/2} \varsigma$ 是两个独立随机变量的乘积, 随机变量 ς 是参数为 $\sigma = 1$ 的瑞利分布随机变量, 因此, CGIG 分布幅度的 n 阶原点矩的公式为^[11]:

$$m_n(z; b, \nu) = m_{n/2}(\tau; b, \nu) m_n(\varsigma) = b^{n/2} e^\nu \sqrt{\frac{2\nu}{\pi}} K_{n/2-1/2}(\nu) \Gamma\left(1 + \frac{n}{2}\right), n \in \mathbb{N} \quad (2-18)$$

2.2.5 CGLN 分布

对一些高分辨海杂波数据, CGLN 能够实现更好的幅度分布拟合^[60]。CGLN 分布的概率密度函数为:

$$p_\tau(\tau; b, \nu) = \sqrt{\frac{\nu}{2\pi}} \frac{1}{\tau} \exp\left(-\frac{\nu}{2} \left(\ln \frac{\tau}{b} + \frac{1}{2\nu}\right)^2\right), \tau > 0; b, \nu > 0 \quad (2-19)$$

其中尺度参数 b 是杂波功率, ν 是形状参数。CGLN 分布的幅度和强度概率密度函数为:

$$\begin{aligned} f(z; b, \nu) &= \sqrt{\frac{2\nu}{\pi}} \int_0^{+\infty} \frac{z}{\tau^2 b} \exp\left(-\left[\frac{z^2}{\tau b} + \frac{\nu}{2} \left(\ln \tau + \frac{1}{2\nu}\right)^2\right]\right) d\tau, \\ f_I(I; b, \nu) &= \sqrt{\frac{\nu}{2\pi}} \int_0^{+\infty} \frac{1}{\tau^2 b} \exp\left(-\left[\frac{I}{\tau b} + \frac{\nu}{2} \left(\ln \tau + \frac{1}{2\nu}\right)^2\right]\right) d\tau. \end{aligned} \quad (2-20)$$

上面两个带参变量的无穷积分不能给出解析表达式, 因此, 只能通过数值计算方法实现概率密度函数计算。类似地, 幅度和强度的累积分布函数分别是:

$$\begin{aligned} F(z; b, \nu) &= 1 - \sqrt{\frac{2\nu}{\pi}} \int_0^{+\infty} \frac{z}{\tau^2 b} \exp\left(-\left[\frac{z^2}{\tau b} + \frac{\nu}{2} \left(\ln \tau + \frac{1}{2\nu}\right)^2\right]\right) d\tau, \\ F(I; b, \nu) &= 1 - \sqrt{\frac{\nu}{2\pi}} \int_0^{+\infty} \frac{1}{\tau^2 b} \exp\left(-\left[\frac{I}{\tau b} + \frac{\nu}{2} \left(\ln \tau + \frac{1}{2\nu}\right)^2\right]\right) d\tau. \end{aligned} \quad (2-21)$$

两个累积分布函数也只能通过数值计算方法得到。CGLN 分布的概率密度函数和累积分布函数都用参变量无穷积分形式给出, 应用中只能用数值方法计算, 但这不影响 CGLN 分布的实际应用。K-分布概率密度函数和累积分布函数计算遇到同样问题,

只是第二类 Bessel 函数数学中研究充分带来了使用上的方便。

CGLN 分布的 n 阶原点矩的公式为：

$$m_\gamma(\tau; b, \nu) = m_{n/2}(\tau; b, \nu) m_n(\zeta) = b^{n/2} \exp\left(\frac{n(n-2)}{8\nu}\right) \Gamma\left(1 + \frac{n}{2}\right), n \in \mathbb{N} \quad (2-22)$$

2.3 常见的海杂波分布模型的参数估计方法

概率模型参数估计是信号处理和统计学中的基础问题之一。海杂波统计模型的选择首先依赖于对不同模型参数的精确估计，通过比较模型拟合实测数据的效果，从而筛选出适合描述海杂波特性的统计模型。在自适应目标检测过程中，计算检验统计量并确定检测判决门限，都离不开对模型参数的有效估计^[3,63]，准确的参数估计对于海面目标检测起着至关重要的作用。本节将对四种双参数复合高斯模型的参数估计方法进行简要的回顾和介绍。

2.3.1 K-分布参数估计方法

K-分布的参数估计方法中，基于高阶矩、分数阶矩、对数矩估计等方法具有显示表达和计算速度快的优势^[15,18,35]。采用逆形状参数时，K-分布随机变量的原点矩与参数之间的关系为：

$$m_n(z; b, \lambda) = E\{z^n\} = \frac{\Gamma(1+n/2)\Gamma(1/\lambda+n/2)}{\Gamma(1/\lambda)} (\lambda b)^{n/2}, n \in \mathbb{N}, \lambda = \frac{1}{\nu} \in (0, +\infty) \quad (2-23)$$

采用 2-4 阶矩得到了常用的矩估计方法^[15,35]：

$$\hat{\lambda} = \frac{\hat{m}_4(z)}{2\hat{m}_2^2(z)} - 1, \quad \hat{b} = \hat{m}_2(z) \quad (2-24)$$

其中 $\hat{m}_n(z)$ 是 n 阶样本矩。由于高阶样本矩在样本数目有限时估计误差大，采用低阶矩和分数阶矩的估计方法^[15]可以减小误差。按照 K-分布分数阶矩表达式，分数阶矩与 2 阶矩的联合产生了一类分数阶矩估计方法：

$$\hat{\lambda} = \frac{4\hat{m}_{\gamma+2}(z) - (4+2\gamma)\hat{m}_\gamma(z)\hat{m}_2(z)}{\gamma(\gamma+2)\hat{m}_\gamma(z)\hat{m}_2(z)}, \quad \hat{b} = \hat{m}_2(z), \gamma \in (0, 1) \quad (2-25)$$

上式取 $\gamma=1$ 对应于常用的 1-2-3 阶矩联合估计方法, 其性能由于 2-4 阶矩估计方法。1-2-3 阶矩估计方法的表达式为:

$$\hat{\lambda} = \frac{4\hat{m}_3(z)}{3\hat{m}_1(z)\hat{m}_2(z)} - 2, \quad \hat{b} = \hat{m}_2(z) \quad (2-26)$$

K-分布的对数矩估计方法使用了二阶矩、对数矩、二阶对数矩三个广义矩^[35], 其解析表达式为:

$$\hat{b} = \frac{1}{N} \sum_{n=1}^N z_n^2, \quad \hat{\lambda} = \frac{2}{N\hat{b}} \sum_{n=1}^N z_n^2 \log(z_n) - \frac{2}{N} \sum_{n=1}^N \log(z_n) - 1 \quad (2-27)$$

其中 z_n 是 K-分布的样本, N 是样本数目。对数阶矩估计比矩估计和分数阶矩估计具有更好的性能。以上的估计方法计算简单, 适用于无异常样本存在的应用场景。由于对海雷达回波数据必然包含目标、礁石等雷达回波构成的大幅值异常样本且这些异常样本难以用简单方法完全剔除, 对异常样本稳健的 K-分布参数估计方法十分必要。

由于上面的这些估计方法对于数据中存在的异常样本敏感, 实际应用中存在性能不稳健的风险。为此, 对异常样本稳健的多分位点估计方法成为实际雷达系统中 K-分布杂波模型参数估计的首选^[24]。采用对数据中的少量异常样本具有稳健性的样本分位点的参数估计方法, 具有抗异常样本的能力。按照 K-分布杂波的幅度累积分布函数, 对任意正数 $0 < \alpha < 1$, 其分位点 z_α 定义为:

$$z_\alpha = F^{-1}(\alpha; b, \lambda) \quad (2-28)$$

其中, F^{-1} 表示 $F(\cdot)$ 的反函数。在 CDF 中令 $z = \sqrt{b}$ 可得到如下关系式:

$$\begin{aligned} F(\sqrt{b}; b, \lambda) &= 1 - \frac{2}{\Gamma(1/\lambda) \lambda^{1/(2\lambda)}} K_{1/\lambda} \left(\frac{2}{\sqrt{\lambda}} \right) = \theta(\lambda), \\ z_{\theta(\lambda)} &= F^{-1}(\theta(\lambda); b, \lambda) = \sqrt{b}, \\ b &= z_{\theta(\lambda)}^2 \end{aligned} \quad (2-29)$$

上式表明在逆形状参数已知的情况下, 尺度参数 b 就是位置在 $\theta(\lambda)$ 的分位点的平方。

对于 $0 < \alpha < \beta < 1$ 及 $z \sim F(z; b, \lambda)$, 两个分位点的比值是其位置的显函数。因此, 两个分位点之比作为逆形状参数的函数可以表示为:

$$\frac{z_\beta}{z_\alpha} = \Theta_{\alpha,\beta}(\lambda), \Theta_{\alpha,\beta}(0) = \sqrt{\frac{\ln(1-\beta)}{\ln(1-\alpha)}} \quad (2-30)$$

虽然缺乏解析表达式,上述函数是 λ 的单调递增函数,其反函数存在,记为 Λ 。于是,逆形状参数是两个分位点之比的单调增加的函数:

$$\hat{\lambda} = \Lambda_{\alpha,\beta}(\hat{\mathfrak{R}}), 1 < \mathfrak{R} = \frac{z_\beta}{z_\alpha} < +\infty \quad (2-31)$$

实际应用中上述隐函数可以通过预先构造表格,通过查表法计算函数值完成。按照公式(2-29)和(2-31)可以构造 K-分布杂波对异常样本稳健的三分位点估计方法。一般上分位点的位置 β 的选择要满足 $(1-\beta)$ 要大于数据中异常样本的最大可能占比,来保持估计方法的稳健性,但是由于在真实杂波环境中异常样本的占比常常是未知的和随着空间、时间变化的,上分位点位置的选择往往是参数估计稳健性和精确性之间的折中。

由于稳健的三分位点估计方法中没有显示表达式,使用查表法计算参数带来不便,针对此问题提出了基于神经网络的稳健参数估计方法^[25],如图 2.1 是基于神经网络进行参数估计的流程图。首先估计 K-分布的形状参数。从杂波时间序列中根据原点矩公式(2-9)中提取特征向量 ξ_M ,从杂波数据中提取分位点特征向量 ξ_P ,将原点矩和分位点向量组合形成特征向量 ξ 。




图2.1 基于神经网络进行参数估计的流程图

该方法将形状参数信息全部压缩到高维特征向量中。然后,将估计问题转化为高维空间中的优化问题。其中,高维非线性函数 G 仅依赖于形状参数 ν 。通常,由于式(2-32)中的高维数和复杂的数学运算,难以获得 G 的显式表达式。最后,估计的形状参数 ν 由特征向量通过非线性函数给出,即 $G(\xi|\nu) = \hat{\nu}$:

$$\min_G \{ (G(\xi|\nu) - \nu)^2 \}, \text{ s.t. } G(\xi|\nu) > 0 \quad (2-32)$$

估计尺度参数的前提条件是已知估计的形状参数 $\hat{\nu}$ 。然后, 通过(2-33), 可以估计出尺度参数:

$$F(\sqrt{b}) = 1 - \frac{2\nu^{\nu/2}}{\Gamma(\nu)} K_\nu(2\sqrt{\nu}) = \theta(\nu) \quad (2-33)$$

$$r_{\theta(\hat{\nu})} = F^{-1}(\theta(\hat{\nu})), \quad \hat{b} = (r_{\theta(\hat{\nu})})^2.$$

值得注意的是, 形状参数依赖的分位点 $r_{\theta(\hat{\nu})}$ 可以保证尺度参数的一个明确而简单的表达式, 即分位点的平方。

2.3.2 广义 Pareto 分布参数估计方法

由于广义 Pareto 分布概率密度函数是幂函数形式的慢衰减, 其原点矩存在与形状参数值有关。此外, 在物理上海杂波总是功率有限的, 意味着用于海杂波幅度分布建模时广义 Pareto 分布的形状参数范围为 $\nu > 1$, 以便保证幅度的二阶矩存在。选择矩的阶数为 $\gamma_1 = 1$ 和 $\gamma_2 = 2$ 或 $\gamma_1 = 1/2, \gamma_2 = 2$, 可以得到广义 Pareto 分布的 MoM 和 FMoM 估计。MoM 估计表示如下^[64]:

$$\hat{b} = \hat{m}_2(z), \frac{\Gamma(\hat{\nu} - 0.5)\sqrt{\hat{\nu} - 1}}{\Gamma(\hat{\nu})} = \frac{2\hat{m}_1(z)}{\sqrt{\pi\hat{m}_2(z)}}, \hat{\nu} > 1 \quad (2-34)$$

其中 $\hat{m}_1(z)$ 和 $\hat{m}_2(z)$ 分别是幅度数据的 1 阶和 2 阶样本矩, 其中形状参数的估计需要通过查表法实现。FMoM 估计表示为^[64]:

$$\hat{b} = \hat{m}_2(z), \frac{\Gamma(\hat{\nu} - 1/4)(\hat{\nu} - 1)^{1/2}}{\Gamma(\hat{\nu})} = \frac{\hat{m}_{1/2}(z)}{\Gamma(1/4)\hat{m}_2^{1/4}(z)} \quad (2-35)$$

其中 $\hat{m}_{1/2}(z)$ 表示幅度样本的 1/2 阶样本矩。注意式(2-34)和式(2-35)中形状参数无法直接显示表达, 需要通过查表法获得。广义 Pareto 分布参数对数矩估计采用了数据的强度格式, 其表达式为^[65]:

$$\hat{b} = \hat{m}_1(I), \hat{\nu} = \frac{\hat{m}(I \ln(I)) - \hat{m}(\ln(I)) \hat{m}_1(I)}{\hat{m}(I \ln(I)) - \hat{m}(\ln(I)) \hat{m}_1(I) - \hat{m}_1(I)} \quad (2-36)$$

其中 $I = z^2$ 是回波数据的强度, $\hat{m}(f(I))$ 表示广义的样本矩。

除矩估计方法外,也可以采用最大似然估计方法进行参数估计,设杂波幅度序列为 $\{z_n, n=1,2,\dots,N\}$, 其最大似然函数为:

$$L(z_1, z_2, \dots, z_N; b, \nu) = \prod_{n=1}^N p(z_n; b, \nu) \quad (2-37)$$

代入广义 Pareto 分布的概率密度函数并计算对数似然函数的最大值点, 得到参数的 ML 估计是下面非线性方程组的解^[9]:

$$\begin{aligned} \frac{1}{N} \sum_{n=1}^N \ln \left(1 + \frac{z_n^2}{x} \right) &= \frac{1}{\nu}, \\ \frac{1}{N} \sum_{n=1}^N \frac{z_n^2}{x + z_n^2} &= \frac{1}{\nu + 1} \\ x &= b(\nu - 1) \end{aligned} \quad (2-38)$$

上述非线性方程组的解通过迭代获得, 得到的解称作参数的迭代最大似然 (Iterative Maximum Likelihood, IML) 估计。迭代算法的流程如下:

$$\begin{aligned} b_0, \nu_0 &\text{ 是参数的双分位点估计, 令 } x_0 = b_0(\nu_0 - 1) \\ x_k = x_{k-1}(\nu_{k-1} + 1) \frac{1}{N} \sum_{n=1}^N \frac{z_n^2}{x_{k-1} + z_n^2}, \nu_k &= \frac{1}{\frac{1}{N} \sum_{n=1}^N \ln \left(1 + \frac{z_n^2}{x_k} \right)} \\ \hat{\nu}_{IML} = \lim_{k \rightarrow +\infty} \nu_k, \hat{b}_{IML} &= \frac{\lim_{k \rightarrow +\infty} x_k}{\hat{\nu}_{IML} - 1} \end{aligned} \quad (2-39)$$

其收敛性目前仍未证明。一般数百次迭代后, 迭代过程就收敛到不动点。在没有异常样本和估计参数先验分布的条件下, ML 估计的误差最小。类似矩估计, ML 估计对异常样本敏感, 异常样本存在导致估计性能明显下降。

2.3.3 CGIG 分布参数估计方法

CGIG 分布参数估计采用逆形状参数形式。CGIG 分布各阶原点矩表达式为^[66]:

$$m_n(z; b, \lambda) = b^{n/2} e^{1/\lambda} \sqrt{\frac{2}{\lambda \pi}} K_{n/2-1/2} \left(\frac{1}{\lambda} \right) \Gamma \left(1 + \frac{n}{2} \right), n \in \mathbb{N}, 0 \leq \lambda = \frac{1}{\nu} < +\infty \quad (2-40)$$

其中 b 和 λ 分别是尺度参数和逆形状参数。由于包含第二类修正的 Bessel 函数，并非联立任意两阶不同的矩都能得到显式矩估计公式。从 2-4 阶矩可以得到显式 MoM^[66]：

$$\hat{\lambda} = \frac{\hat{m}_4(z)}{2\hat{m}_2^2(z)} - 1, \quad \hat{b} = \hat{m}_2(z) \quad (2-41)$$

使用高阶矩的估计方法在样本数目不足或者逆形状参数很大时估计误差大。使用 1 阶和 2 阶矩的非显式估计方法能够减小估计误差，称之为低阶矩估计方法^[66]：

$$\begin{aligned} m_1(z; \lambda, b) &= \sqrt{\frac{b}{2\lambda}} e^{1/\lambda} K_0 \left(\frac{1}{\lambda} \right) = f(\lambda, b) \\ \hat{b} &= \hat{m}_2^2(z), \quad \lambda = f^{-1}(\hat{m}_1(z), b) \end{aligned} \quad (2-42)$$

函数 $f(\lambda, b)$ 是逆形状参数的单调递减函数但缺乏解析表达式。其反函数存在，函数值计算通过查表法实现。

对于 CGIG 分布，设 $\{z_n, n=1, 2, \dots, N\}$ 是长度为 N 的独立同分布海杂波样本幅度序列，那么参数估计的似然函数和对数似然函数为：

$$\begin{aligned} L(z_1, z_2, \dots, z_N; b, \lambda) &= \prod_{n=1}^N p(z_n; b, \lambda) \\ \Psi(z_1, z_2, \dots, z_N | b, \lambda) &= N \left(\log 2 + \log \lambda + \lambda^{-1} - \log b \right) - 3 \sum_{n=1}^N \log(a_n) \\ &+ \sum_{n=1}^N \log(z_n) + \sum_{n=1}^N \log(1 + \lambda^{-1} a_n) - \lambda^{-1} \sum_{n=1}^N a_n, a_n = \frac{\sqrt{b + 2\lambda z_n^2}}{\sqrt{b}} \end{aligned} \quad (2-43)$$

对上式求逆形状参数和尺度参数的偏导，得到驻点方程组：

$$\frac{1}{N} \sum_{n=1}^N \frac{a_n^2 + 3\lambda(\lambda + a_n)}{a_n^2(\lambda + a_n)} z_n^2 = b, \quad \frac{1}{N} \sum_{n=1}^N \frac{a_n^2}{\lambda + a_n} = 1 \quad (2-44)$$

方程组是高度非线性的，用矩估计方法得到的估计值作为初始值，进行快速迭代求解^[21]：

$$\begin{aligned}
\hat{b}_0, \hat{\lambda}_0, a_n(k) &= \sqrt{\hat{b}_{k-1} + 2\hat{\lambda}_{k-1}z_n^2} / \sqrt{\hat{b}_{k-1}} \\
\hat{b}_k &= \frac{1}{N} \sum_{n=1}^N \frac{a_n^2(k) + 3\hat{\lambda}_{k-1}^2 + 3\hat{\lambda}_{k-1}a_n(k)}{a_n^2(k)(\hat{\lambda}_{k-1} + a_n(k))} \\
\hat{\lambda}_k &= \frac{1}{N} \sum_{n=1}^N \left(\frac{\hat{\lambda}_{k-1}^2}{\hat{\lambda}_{k-1} + a_n(k)} + a_n(k) - 1 \right)
\end{aligned} \tag{2-45}$$

其中 k 表示迭代次数, $\hat{b}_0$ 和 $\hat{\lambda}_0$ 表示尺度参数和逆形状参数的初始值。大量试验表明迭代过程收敛, 其收敛的点是驻点方程(2-44)的解, 也是参数的最大似然估计。因此, 上面的迭代估计称作 CGIG 分布参数的 IML 估计方法。

2.3.4 CGLN 分布参数估计方法

对服从 CGLN 幅度分布的杂波序列 $\{z_n, n=1, 2, \dots, N\}$, 结合其 n 阶原点矩的公式。通过联合 2-4 阶样本矩, 可以得到 CGLN 分布参数的 MoM^[14]:

$$\hat{b} = \hat{m}_2(z), \quad \hat{\lambda} = \ln \frac{\hat{m}_4(z)}{2\hat{m}_2(z)}, \quad \hat{\nu} = \frac{1}{\hat{\lambda}} > 0 \tag{2-46}$$

其中 λ 是形状参数, $\hat{m}_2(z)$ 和 $\hat{m}_4(z)$ 是幅度的二阶、四阶样本矩。由于采用了四阶样本矩, 逆形状参数较大、杂波非高斯性较强时, 估计误差大。通过采用分数阶矩、低阶样本矩、或者对数样本矩, 能够一定程度上改善非高斯性较强杂波的参数估计性能。FMoM 的表达式为:

$$\hat{b} = \hat{m}_2(z), \quad \hat{\lambda} = \frac{2}{\gamma} \ln \left(\frac{\hat{m}_{\gamma+1}(z)}{\hat{m}_1(z)\hat{m}_\gamma(z)} \frac{\gamma\sqrt{\pi}\Gamma(\gamma/2)}{(\gamma+1)\Gamma(\lambda/2+1/2)} \right), \quad \gamma \in (0, 1) \tag{2-47}$$

当上式中 $\gamma=2$ 时, 对应于用 1-2-3 阶样本矩进行参数估计, 也称低阶矩估计方法。对数矩估计[zlogz]的表达式为:

$$\hat{b} = \hat{m}_2(z), \quad \hat{\lambda} = \frac{4}{N} \left(\frac{1}{\hat{m}_1(z)} \sum_{i=1}^N z_i \ln z_i - \frac{1}{N} \sum_{i=1}^N \ln z_i - 1 + \ln 2 \right) \tag{2-48}$$

矩估计方法计算简单、易于实现, 但精度较低, 对数据中的异常样本敏感。

有时为了评估各种估计方法的性能, 数值最大似然估计的相对均方根误差 (Relative Root Mean Square Error, RRMSE) 常常用作评价估计性能的参照。CGLN 分布

下参数的对数最大似然函数为:

$$\begin{aligned}
 L(z_1, z_2, \dots, z_N | \lambda, b) &= \log \left[\prod_{n=1}^N f_{b, \lambda}(z_n) \right] \\
 &= 0.5N \{ \log 2 - 2 \log(b) - \log \pi - \log \lambda \} + \sum_{n=1}^N \log(z_n) \\
 &\quad + \sum_{n=1}^N \log \int_0^{+\infty} \frac{1}{\tau^2} \exp \left(- \left[\frac{z_n^2}{\tau b} + \frac{1}{2\lambda} \left(\ln \tau + \frac{\lambda}{2} \right)^2 \right] \right) d\tau
 \end{aligned} \tag{2-49}$$

由于涉及广义积分, 最大似然估计的求解非常耗时且获得的解有初值依赖性。数值最大似然估计无法用于工程实际, 其给出了数据无异常样本和参数无先验信息情况下参数估计的性能上限。

2.4 常见的神经网络

在机器学习中, 神经网络(Neural Network, NN)是受人脑神经网络的结构和功能启发的模型, 可应用于预测建模和自适应控制等。它由相互连接的神经元组成, 每个神经元从连接的神经元处接收信号, 然后处理接收信号并向其它连接的神经元发送信号, 每个神经元的输出都是由输入和称为激活函数的非线性函数计算得出, 而连接处的信号强度由权重决定, 权重会在学习过程中进行调整。近年来, 神经网络凭借其强大的数据学习能力、特征提取能力、和时间序列描述能力得到了深入的研究和广泛的应用。海杂波模型参数估计和海杂波抑制是神经网络应用的两个重要方面。下面介绍几种常见的神经网络模型。

2.4.1 BP 神经网络

BP 神经网络是一种基于误差反向传播算法训练的多层前馈网络, 具备强大的自适应性、自学习能力和非线性映射能力, 广泛用于函数逼近、模式识别与分类、数据压缩以及时间序列预测等领域。网络模型结构如图 2.2 所示。

首先根据输入 $X = \{x_n, n=1, 2, \dots, N\}$ 和期望的输出 $D = \{d_l, l=1, 2, \dots, L\}$ 来确定网络输入层、隐藏层和输出层神经元个数。然后进行各层神经元之间的连接的权值 v_{nm} 和 w_{ml} 、隐藏层阈值 $A = \{a_m, m=1, 2, \dots, M\}$ 、输出层阈值 $B = \{b_l, l=1, 2, \dots, L\}$ 的初始化。根据输入向量 X 、输入层和隐藏层连接权值 v_{nm} 以及隐藏层阈值 A , 计算隐藏层的输出:

$$y_m = f \left(\sum_{n=1}^N v_{nm} x_n - a_m \right), m=1, 2, \dots, M \tag{2-50}$$

其中， M 为隐藏层节点数， $f(\cdot)$ 为传递函数。




图2.2 BP 神经网络模型

这里我们使用 Sigmoid 激活函数作为传递函数：

$$f(x) = \frac{1}{1 + e^{-x}} \quad (2-51)$$

然后由(2-50)计算出的隐藏层的输出 Y 计算网络输出：

$$o_l = f\left(\sum_{m=1}^M w_{ml} y_m - b_l\right), l = 1, 2, \dots, L \quad (2-52)$$

计算网络实际输出与网络的期望输出之间的误差 E ：

$$E = \frac{1}{2}(D - O)^2 = \frac{1}{2} \sum_{l=1}^L (d_l - o_l)^2, l = 1, 2, \dots, L \quad (2-53)$$

得到误差 E 之后，判断误差是否在可允许范围内，如果在的话，停止训练，如果不在，更新网络权值，返回(2-50)继续训练，直到达到误差要求或训练次数。网络权值采用梯度下降法及逆行更新，更新方式如下：

$$\begin{aligned}
v_{nm} &= v_{nm} + \Delta v_{nm}, w_{ml} = w_{ml} + \Delta w_{ml} \\
\Delta w_{ml} &= -\eta \frac{\partial E}{\partial w_{ml}}, m=1,2,\dots,M; l=1,2,\dots,L, \\
\Delta v_{nm} &= -\eta \frac{\partial E}{\partial v_{nm}}, n=1,2,\dots,N; m=1,2,\dots,M
\end{aligned} \tag{2-54}$$

其中，负号表示梯度下降，常数 η 为学习率。

2.4.2 RBF 神经网络

RBF 神经网络主要应用在函数逼近、时间序列预测、控制等^[67]，网络具有一个隐藏层，隐藏层的传递函数使用 RBF，还有一个输入层和一个输出层。不同于 BP 神经网络，输入层与隐藏层之间不通过权值进行连接，而是直接映射到隐藏层。输出层输出是隐藏层输出的线性加权和。其结构如图 2.3 所示：




图2.3 RBF 神经网络结构图

当输入数据 $X=[x_1, x_2, \dots, x_N]^T$ ， N 表示输入层的神经元个数，网络期望输出 $Y=[y_1, y_2, \dots, y_Q]^T$ ， Q 代表输出层的神经元个数，隐藏层使用的 RBF 传递函数表示为：

$$h_m = \exp\left(-\frac{\|X - C_m\|_2^2}{2b_m^2}\right) (m=1, 2, \dots, M) \tag{2-55}$$

其中， h_m 为隐藏层输出， $H=[h_1, h_2, \dots, h_M]$ ； b_m 为宽度参数， $b_m=[b_{m1}, b_{m2}, \dots, b_{mN}]^T$ ， M 为隐藏层单元数。 C_m 是第 m 个隐藏层单元的中心参数矢量 $C_m=[c_{m1}, c_{m2}, \dots, c_{mN}]^T$ ，其初始化为：

$$c_{mn} = \min n + \frac{\max n - \min n}{2m} + (m-1) \frac{\max n - \min n}{m} \quad (2-56)$$

其中, $\min n$ 是训练集中第 n 个输入所有数据的最小值, $\max n$ 是训练集中第 n 个输入所有数据的最大值。

宽度参数决定了神经元对输入信息的感知范围。宽度向量的初始化方式如下:

$$b_{mn}^2 = d_f \sqrt{\frac{1}{N} \sum_{k=1}^N (x_n^k - c_{mn})^2} \quad (2-57)$$

其中, d_f 为宽度调节系数, 其取值小于 1。

网络输出 $O = [o_1, o_2, \dots, o_Q]^T$ 为隐藏层输出加权和:

$$o_q = \sum_{m=1}^M w_{qm} h_m, q = 1, 2, \dots, Q \quad (2-58)$$

其中, w_{qm} 是输出层第 q 个神经元与隐含层第 m 个神经元之间的调节权重。

RBF 神经网络权重参数的训练方法采用梯度下降法, 中心参数、宽度参数以及输出权重公式的迭代公式为:

$$\begin{aligned} w_{qm}(t) &= w_{qm}(t-1) - \eta_{rbf} \frac{\partial E}{\partial w_{qm}(t-1)} + r [w_{qm}(t-1) - w_{qm}(t-2)] \\ c_{mn}(t) &= c_{mn}(t-1) - \eta_{rbf} \frac{\partial E}{\partial c_{mn}(t-1)} + r [c_{mn}(t-1) - c_{mn}(t-2)] \\ d_{mn}(t) &= d_{mn}(t-1) - \eta_{rbf} \frac{\partial E}{\partial d_{mn}(t-1)} + r [d_{mn}(t-1) - d_{mn}(t-2)] \end{aligned} \quad (2-59)$$

其中, η_{rbf} 为学习率, E 为损失函数, r 为惯性系数。

RBF 神经网络训练步骤可以总结为: 首先对网络进行初始化, 初始化中心矢量、宽度系数以及最后一层权重, 然后计算网络输出与期望输出之间的误差值, 如果误差在接受范围内, 就停止训练, 如果不在, 利用梯度下降法更新各个参数, 并重新计算输出, 直到误差值达到允许范围。

2.4.3 广义回归神经网络

GRNN 是一种经典的无反向传播的单程学习神经网络, 具有较高的估计精度和对噪声不敏感的特点^[68]。与 BP 神经网络相比, GRNN 只需要考虑平滑因子一个变量,

优化步骤简单，能够在一定程度上减少人为因素对网络输出的影响。其基本思想是利用核密度估计来对训练样本进行建模。通过计算输入样本与各训练样本之间的距离，然后按高斯核函数（或其他平滑核函数）加权求和，最后归一化得到输出预测值。由于这种方法不需要对网络进行反向传播训练，所以网络训练过程非常迅速，并且能够以较小的误差逼近任意连续函数。GRNN 的具体结构如图 2.4 所示：




图2.4 GRNN 模型

首先进行网络初始化，网络的输入变量 $X = [X_1, X_2, \dots, X_N]$ ， N 为输入层和模式层神经元个数。模式层所采用的传递函数为径向基函数，其表达式为：

$$p_n = \exp\left(-\frac{\|X - X_n\|_2^2}{2\beta^2}\right), n = 1, 2, \dots, N \quad (2-60)$$

其中， X 代表输入向量， β 是平滑因子。

然后求和层中使用两种类型的求和函数对模式层的输出进行求和。第一种求和函数为：

$$\sum_{n=1}^N \exp\left(-\frac{\|X - X_n\|_2^2}{2\beta^2}\right) \quad (2-61)$$

上式表示模式层中所有的输出的和，其中模式层和求和层节点之间的连接权值为 1，传递函数可表示为：

$$S_D = \sum_{n=1}^N p_n \quad (2-62)$$

第二类求和表示预期的输出样本和模式层节点输出的加权和：

$$\sum_{n=1}^N Y_n \exp\left(-\frac{\|X - X_n\|_2^2}{2\beta^2}\right) \quad (2-63)$$

其中，模式层节点与求和层节点之间的连接权值为预期的输出数据，即第 n 个输出样本 Y_n 的第 k 个元素。传递函数可表示为：

$$S_{Nk} = \sum_{n=1}^N y_{nk} p_n, k=1, 2, \dots, K \quad (2-64)$$

输出层的节点数与输入向量维数相同。输出层会将分子求和单元的结果除以分母求和单元的结果，最终获取预测输出：

$$y_k = \frac{S_{Nk}}{S_D}, k=1, 2, \dots, K \quad (2-65)$$

由于 GRNN 不需要通过迭代调整权重，因此训练速度非常快，并且由于 GRNN 基于概率密度估计，其理论基础保证在足够的数据样本下能获得全局最优的逼近效果。

2.4.4 LSTM 神经网络

基本的 RNN 通过将前一时间步的隐藏状态融入当前时间步的隐藏状态更新，使其能够有效处理时间序列数据。然而，随着序列长度的增加，RNN 在训练过程中容易出现梯度消失或梯度爆炸问题，导致模型难以学习和保留长期依赖关系，从而影响训练稳定性和预测精度。这一问题的根本原因在于 RNN 依赖于循环计算，每个时间步的梯度都会不断向前传播，长序列情况下，可能会导致梯度消失或梯度爆炸的问题，使得模型无法有效调整远距离时间步的信息。

为了解决这一问题，LSTM 网络引入了门控机制，包括输入门、遗忘门和输出门，使其能够对信息的存储、更新和遗忘进行精确控制。其中，遗忘门用于决定哪些信息应当丢弃，以防止长期依赖信息过载；输入门用于选择当前时间步的重要信息并存储到细胞状态中；输出门则控制隐藏状态的更新，使得模型能够动态调整长期与短期信息的权重。通过这些机制，LSTM 神经网络能够有效缓解梯度消失问题，使得重要的历史信息得以长期保留，从而更好地捕捉时间序列中的长期依赖关系。此外，LSTM 神经网络还能增强对复杂非线性动态序列的建模能力，在处理具有长时间依赖性的信

号（如雷达海杂波预测、语音识别、金融时间序列分析等）方面表现出显著优势^[51]。LSTM 神经网络模型结构如图 2.5 所示：




图2.5 LSTM 神经网络模型

其中， C_{t-1} 和 C_t 分别是时间 $t-1$ 和时间 t 的单元状态消息， $\tilde{C}_t$ 是时间 t 的候选更新信息， h_{t-1} 和 h_t 分别是时间 $t-1$ 和时间 t 的隐藏层状态信息， X_t 是时间 t 的输入值， σ 是 Sigmoid 函数， f_t 、 i_t 和 o_t 分别是“遗忘门”、“输入门”和“输出门”的控制系数。

“遗忘门”基于 f_t 来确定在 $t-1$ 时可以保留的单元状态信息 C_{t-1} 的量。 f_t 是由 X_t 和 h_{t-1} 作为输入计算的在 $[0,1]$ 区间内的值。 f_t 越接近 0，在 C_t 中移除的消息越多，并且如果 f_t 越接近 1，则在 C_{t-1} 中保留的消息越多；控制系数 i_t 和 o_t 的影响与 f_t 相似。“输入门”的作用是决定哪些信息将被添加到 C_t 中，并与“遗忘门”一起决定 C_t 的更新。“输出门”用于在时间 t 控制隐藏层状态消息的输出 h_t 。LSTM 网络的方程表达式如下：

$$\begin{aligned}
 f_t &= \sigma(W_f, [h_{t-1}, X_t], b_f), \\
 i_t &= \sigma(W_i, [h_{t-1}, X_t], b_i), \\
 \tilde{C}_t &= \tanh \sigma(W_c, [h_{t-1}, X_t], b_c), \\
 C_t &= f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t, \\
 o_t &= \sigma(W_o, [h_{t-1}, X_t], b_o), \\
 h_t &= o_t \cdot \tanh(C_t)
 \end{aligned} \tag{2-66}$$

其中，变量 W_f ， W_i ， W_c ， W_o 表示权重，而 b_f ， b_i ， b_c ， b_o 表示偏差。

2.5 本章小结

本章介绍了三个部分的内容。首先从海杂波的统计建模出发，详细阐述了复合高斯模型的基本框架，在此基础上引入了常用的四种双参数幅度分布模型，即 K 分布模型、广义 Pareto 模型、CGIG 模型以及 CGLN 模型。这四种模型基本上能够适应各种不同环境下的海杂波数据拟合需求。在参数估计部分，本章回顾了针对上述双参数模型的多种估计方法，重点介绍了有关 K 分布的矩估计、基于分位点的稳健估计、以及利用神经网络进行参数估计的方法，并对广义 Pareto 模型、CGIG 模型以及 CGLN 模型三种模型的各种参数估计方法做了详细介绍。本章还介绍了几种常见的神经网络，作为参数估计以及海杂波抑制中用到的重要工具，本章重点讨论了 GRNN 和 LSTM 神经网络。总体来看，本章为后续基于神经网络的模型稳健参数估计方法以及基于神经网络的杂波抑制方法的研究打下了坚实的理论和方法基础。

第三章 基于神经网络的海杂波模型的稳健参数估计

3.1 引言

海杂波的幅度建模与参数估计是对海雷达信号处理的基础。目前已经相继提出了不同纹理分布类型的 CGM 来拟合各种海杂波。但是, 真实海杂波信号在雷达接收过程中通常伴随噪声, 这些噪声在实际操作中难以避免, 因此直接对无噪声 K-分布建模虽然理论上可行, 但在实际应用中存在偏差。

在真实海洋环境中, 目标、岛礁等的雷达回波较强, 偏离了海杂波幅度模型, 在海杂波参数估计中构成异常样本。从数据中消除异常样本是相当麻烦的。所以, 开发出具有异常样本稳健性的参数估计方法颇为重要。利用样本分位点和样本截断矩对少量异常样本具有稳健性的特点, 针对这四种双参数模型开发了一系列异常样本稳健的估计方法^[20-22,24]。在双参数分布中, 两个分位点的比值是形状参数的一对一函数。然而, 由于复杂或隐式的分布表达式, 一些对异常样本稳健的估计方法需要采用迭代算法或借助查表法来估计参数。对于 K-分布, 在异常样本稳健的估计方法中采用神经网络学习法可以代替查表法^[25,69], 神经网络可以代替低准确度的经验公式来改进海杂波反射系数的预测^[70]。

对于 K-分布加噪声模型, 现在并没有很好的稳健参数估计方法, 引入噪声进行海杂波建模之后, 两个分位点的比值不再是形状参数的一对一函数, 与杂噪比也有关。在本章中, 我们以样本分位点比值向量与截断矩比值向量作为输入, 提出了一种基于神经网络学习的 K+N 模型的稳健参数估计方法。我们首先证明了在固定杂噪比的情况下, 分位点比值和同阶截断矩比值只与形状参数和杂噪比有关, 与噪声功率无关的结论。接下来基于此, 我们在假设噪声功率已知的情况下, 给定一组形状参数和杂噪比, 计算其对应的分位点和截断矩, 生成了大量参数向量和对应的分位点比值和截断矩比值向量, 作为训练数据进行 GRNN 训练, 得到 GRNN 模型。然后对于参数待估计的样本数据, 将样本分位点比值与样本截断矩比值向量输入训练好的网络中, 估计出的对应的形状参数和杂噪比, 进一步求出尺度参数和噪声功率。最后, 对仿真和实测数据借助 K-S 距离(Kolmogorov-Smirnov Distance, KSD)和 K-L 散度(Kullback-Leibler Divergence, KLD)这两种评价测度来验证所提方法的性能。

本章内容安排如下。第二节介绍了 K+N 分布。第三节首先证明了在固定杂噪比的情况下, 分位点比值和同阶截断矩比值只与形状参数和杂噪比有关, 与噪声功率无关的结论。并由此建立分位点和截断矩比值向量和形状参数与杂噪比之间的映射关系, 产生模型训练数据, 然后通过实验证明训练得到 GRNN 模型的有效性, 并给出整个

基于 GRNN 的 K+N 分布模型的稳健参数估计流程。第四节通过仿真和实测数据对所提参数估计方法的估计精度和稳健性进行验证。最后，在第五节中总结全文。

3.2 K+N 分布模型

K-分布模型在 2.2.2 节已经做了详细介绍，其概率密度函数如式(2-6)所示。由于在实际的雷达探测中，接收到的信号不仅仅包含杂波成分，还受到接收机热噪声的影响。噪声通常被建模为均值为零、方差为常数的复高斯噪声，其 PDF 为：

$$f(x) = \frac{1}{\pi\sigma^2} \exp\left(-\frac{|x|^2}{\sigma^2}\right) \quad (3-1)$$

其中， $|x|$ 为复噪声的幅度， σ^2 为噪声的方差，表示噪声的功率。

K+N 模型中，给定纹理分量 τ ，海杂波的幅度 z 服从参数为 $\tau + \sigma^2$ 的瑞利分布：

$$f(z|\tau) = \frac{2z}{\tau + \sigma^2} \exp\left(-\frac{z^2}{\tau + \sigma^2}\right) \quad (3-2)$$

纹理分量和噪声功率已知时，海杂波向量 r 服从零均值的 N 维复高斯分布，其条件概率密度函数为：

$$p(r|\tau) = \frac{1}{\pi^N |\mathbf{R}_{\tau, \sigma, M}|} \exp\left(-r^H (\mathbf{R}_{\tau, \sigma, M})^{-1} r\right) \quad (3-3)$$

此时，杂波加噪声的协方差矩阵为 $\mathbf{R}_{\tau, \sigma, \mathbf{M}} = E\{rr^H\} = \tau\mathbf{M} + \sigma^2\mathbf{I}$ 。当纹理分量 τ 服从形状参数为 ν ，尺度参数为 b 的伽马分布，其概率密度函数如式(2-5)所示，海杂波建模为 K-分布杂波加噪声模型。此时，海杂波幅度 z 的概率密度函数和累积分布函数分别为：

$$\begin{aligned} f(z; \nu, b, \sigma) &= \int_0^{+\infty} f(z|\tau) p_\tau(\tau; \nu, b) d\tau \\ &= \int_0^{+\infty} \frac{2z\nu\tau^{\nu-1}}{\Gamma(\nu)(\tau + \sigma^2)b^\nu} \exp\left(-\frac{z^2}{\tau + \sigma^2} - \frac{\nu}{b}\tau\right) d\tau \\ F(z; \nu, b, \sigma) &= 1 - \int_0^{+\infty} e^{-\frac{z^2}{\tau + \sigma^2}} \frac{\nu^\nu}{\Gamma(\nu)b^\nu} \tau^{\nu-1} e^{-\frac{\nu}{b}\tau} d\tau \end{aligned} \quad (3-4)$$

对于高分辨海杂波, ν 的值通常在区域 $[0.1, +\infty]$ 中观察到, 其中 $\nu = 0.1$ 是非高斯性很强的杂波, $\nu = \infty$ 表示高斯噪声。

海杂波向量的概率密度函数为:

$$p(r) = \int_0^\infty p(r|\tau) p_\tau(\tau) d\tau = \frac{1}{\pi^N} \int_0^\infty \frac{1}{|\mathbf{R}_{\tau, \sigma, \mathbf{M}}|} \exp\left(-r^H (\mathbf{R}_{\tau, \sigma, \mathbf{M}})^{-1} r\right) p_\tau(\tau) d\tau \quad (3-5)$$

不同于 K-分布, K+N 分布模型在考虑噪声之后, 其分位点与截断矩是形状参数、尺度参数以及噪声功率的函数。

3.3 基于 GRNN 的 K+N 模型的稳健参数估计

在 K-分布下基于神经网络学习的对异常样本的稳健估计方法^[25,69]的启发下, 提出了 K+N 模型的基于神经网络学习的稳健参数估计方法。本节首先证明了在固定杂噪比的情况下, 分位点比值和同阶截断矩比值只与形状参数和杂噪比有关, 与噪声功率无关的结论, 基于此生成训练数据。然后, 利用训练数据进行 GRNN 模型训练, 并通过独立重复实验来证明网络的估计有效性。最后给出基于 GRNN 的 K+N 模型参数估计流程。

3.3.1 训练数据生成

训练样本集的生成是从待估计参数到相关比值向量的一个重要的前向过程。在野点稳健估计方法中^[20,69], 利用上分位点位置或截断比 α ($0 < \alpha < 1$) 来确保对异常值的稳健性。

对于形状参数为 ν , 尺度参数为 b , 噪声功率为 σ^2 的 K+N 模型, 记其累积分布函数为 $F(z; \nu, b, \sigma)$, 给定一个分位点位置 $0 < \alpha < 1$, 则该位置处的分位点 z_α 定义为 $F(z_\alpha; \nu, b, \sigma) = \alpha$, 记作 $z_\alpha = F^{-1}(\alpha; \nu, b, \sigma)$ 。

形状参数为 ν , 尺度参数为 b , 噪声功率为 σ^2 的 K+N 模型, 幅度 z 的 k 阶 α 截断矩定义为:

$$m_{k, \alpha}(\nu, b, \sigma) = \frac{1}{\alpha} \int_0^{F^{-1}(\alpha; \nu, b, \sigma)} z^k f(z; \nu, b, \sigma) dz \quad (3-6)$$

其中, $f(z; \nu, b, \sigma)$ 为该 K+N 模型的概率密度函数。

引理 1: 如果形状参数为 ν , 尺度参数为 b , 噪声功率为 σ^2 的 K+N 模型的 α 分位点为 $z_\alpha = F^{-1}(\alpha; \nu, b, \sigma)$, 那么形状参数为 ν , 尺度参数为 b/σ^2 , 噪声功率为 1 的 K+N

模型的 α 分位点为 $F^{-1}(\alpha; \nu, b/\sigma^2, 1) = z_\alpha/\sigma = F^{-1}(\alpha; \nu, b, \sigma)/\sigma$ 。

引理 1 证明：形状参数为 ν ，尺度参数为 b ，噪声功率为 σ^2 的 K+N 模型在 z_α 处的累积分布函数 $F(z_\alpha; \nu, b, \sigma)$ 满足：

$$\begin{aligned}
 F(z_\alpha; \nu, b, \sigma) &= 1 - \int_0^{+\infty} \exp\left(-\frac{z_\alpha^2}{\tau + \sigma^2}\right) p_\tau(\tau; \nu, b, \sigma) d\tau \\
 &= 1 - \int_0^{+\infty} \exp\left(-\frac{z_\alpha^2}{\tau + \sigma^2}\right) \frac{\nu^\nu}{\Gamma(\nu)b^\nu} \tau^{\nu-1} e^{-\frac{\nu}{b}\tau} d\tau \\
 &= 1 - \int_0^{+\infty} \frac{\nu^\nu}{\Gamma(\nu)(b/\sigma^2)^\nu} \left(\frac{\tau}{\sigma^2}\right)^{\nu-1} \exp\left(-\frac{z_\alpha^2/\sigma^2}{\tau/\sigma^2 + 1} - \frac{\nu}{b/\sigma^2} \cdot \frac{\tau}{\sigma^2}\right) d\frac{\tau}{\sigma^2} \quad (3-7) \\
 &= 1 - \int_0^{+\infty} \frac{\nu^\nu}{\Gamma(\nu)(b/\sigma^2)^\nu} \tau^{\nu-1} \exp\left(-\frac{z_\alpha^2/\sigma^2}{\tau + 1} - \frac{\nu}{b/\sigma^2} \tau\right) d\tau \\
 &= F\left(\frac{z_\alpha}{\sigma}; \nu, \frac{b}{\sigma^2}, 1\right)
 \end{aligned}$$

所以 $F(z_\alpha/\sigma; \nu, b/\sigma, 1) = F(z_\alpha; \nu, b, \sigma) = \alpha$ ，那么可以得到 $F^{-1}(\alpha; \nu, b/\sigma^2, 1) = z_\alpha/\sigma$ 。证毕。 $\square$

结论 1：对于形状参数为 ν ，尺度参数为 b ，噪声功率为 σ^2 的 K+N 模型，在杂噪比 b/σ^2 固定的情况下，其分位点比值与噪声功率 σ^2 无关。

结论 1 证明：考虑任意两个分位点，假设其分别为在 α_1 处和 α_2 处的分位点，分别记为 $F^{-1}(\alpha_1; \nu, b, \sigma) = z_{\alpha_1}$ 和 $F^{-1}(\alpha_2; \nu, b, \sigma) = z_{\alpha_2}$ 。那么其比值为

$$\frac{F^{-1}(\alpha_1; \nu, b, \sigma)}{F^{-1}(\alpha_2; \nu, b, \sigma)} = \frac{z_{\alpha_1}}{z_{\alpha_2}} = \frac{z_{\alpha_1}/\sigma}{z_{\alpha_2}/\sigma} = \frac{F^{-1}(\alpha_1; \nu, b/\sigma^2, 1)}{F^{-1}(\alpha_2; \nu, b/\sigma^2, 1)} \quad (3-8)$$

显然， $F^{-1}(\alpha_1; \nu, b/\sigma^2, 1)$ 与 $F^{-1}(\alpha_2; \nu, b/\sigma^2, 1)$ 的取值与噪声功率 σ^2 无关，因此在杂噪比 b/σ^2 固定的情况下，分位点比值与噪声功率 σ^2 无关。证毕。 $\square$

引理 2：记形状参数为 ν ，尺度参数为 b ，噪声功率为 σ^2 的 K+N 模型的概率密度函数为 $f(z; \nu, b, \sigma)$ ，那么 $f(z; \nu, b, \sigma) = \frac{1}{\sigma} f\left(\frac{z}{\sigma}; \nu, \frac{b}{\sigma^2}, 1\right)$ 。

引理 2 的证明：

$$\begin{aligned}
 f(z; \nu, b, \sigma) &= \int_0^{+\infty} \frac{2z}{\tau + \sigma^2} \exp\left(-\frac{z^2}{\tau + \sigma^2}\right) \frac{\nu^\nu}{\Gamma(\nu)b^\nu} \tau^{\nu-1} e^{-\frac{\nu}{b}\tau} d\tau \\
 &= \int_0^{+\infty} \frac{2z/\sigma^2}{\tau/\sigma^2 + 1} \exp\left(-\frac{z^2/\sigma^2}{\tau/\sigma^2 + 1}\right) \frac{\nu^\nu}{\Gamma(\nu)(b/\sigma^2)^\nu} \left(\frac{\tau}{\sigma^2}\right)^{\nu-1} e^{-\frac{\nu}{b/\sigma^2} \frac{\tau}{\sigma^2}} d\frac{\tau}{\sigma^2} \\
 &= \frac{1}{\sigma} \int_0^{+\infty} \frac{2z/\sigma}{t+1} \exp\left(-\frac{z^2/\sigma^2}{t+1}\right) \frac{\nu^\nu}{\Gamma(\nu)(b/\sigma^2)^\nu} t^{\nu-1} e^{-\frac{\nu}{b/\sigma^2} t} dt \\
 &= \frac{1}{\sigma} f\left(\frac{z}{\sigma}; \nu, \frac{b}{\sigma^2}, 1\right)
 \end{aligned} \tag{3-9}$$

证毕。 $\square$

引理 3: 如果形状参数为 ν , 尺度参数为 b , 噪声功率为 σ^2 的 K+N 模型的幅度 k 阶 α 截断矩为 $m_{k,\alpha}(\nu, b, \sigma)$, 那么形状参数为 ν , 尺度参数为 b/σ^2 , 噪声功率为 1 的 K+N 模型的幅度 k 阶 α 截断矩为 $m_{k,\alpha}(\nu, b/\sigma^2, 1) = \sigma^{-k} m_{k,\alpha}(\nu, b, \sigma)$ 。

引理 3 证明: 根据引理 1 和 2, 式(3-6)中的 k 阶 α 截断矩 $m_{k,\alpha}(z; \nu, b, \sigma)$ 可改写为

$$\begin{aligned}
 m_{k,\alpha}(\nu, b, \sigma) &= \frac{1}{\alpha} \int_0^{F^{-1}(\alpha; \nu, b, \sigma)} z^k f(z; \nu, b, \sigma) dz \\
 &= \frac{\sigma^k}{\alpha} \int_0^{\frac{1}{\sigma} F^{-1}(\alpha; \nu, b, \sigma)} \left(\frac{z}{\sigma}\right)^k f\left(\frac{z}{\sigma}; \nu, \frac{b}{\sigma^2}, 1\right) d\frac{z}{\sigma} \\
 &= \frac{\sigma^k}{\alpha} \int_0^{F^{-1}(\alpha; \nu, \frac{b}{\sigma^2}, 1)} \left(\frac{z}{\sigma}\right)^k f\left(\frac{z}{\sigma}; \nu, \frac{b}{\sigma^2}, 1\right) d\frac{z}{\sigma} \\
 &= \sigma^k m_{k,\alpha}(\nu, b/\sigma^2, 1)
 \end{aligned} \tag{3-10}$$

因此, 形状参数为 ν , 尺度参数为 b/σ^2 , 噪声功率为 1 的 K+N 模型幅度 z 的 k 阶 α 截断矩为 $m_{k,\alpha}(\nu, b/\sigma^2, 1) = \sigma^{-k} m_{k,\alpha}(\nu, b, \sigma)$, 证毕。 $\square$

结论 2: 对于形状参数为 ν , 尺度参数为 b , 噪声功率为 σ^2 的 K+N 模型, 在杂噪比 b/σ^2 固定的情况下, 其同阶截断矩比值与噪声功率 σ^2 无关。

结论 2 证明: 考虑任意两个同阶截断矩, 假设其均为 k 阶截断矩, 分别为 k 阶 α_1 截断矩和 k 阶 α_2 截断矩, 分别记为 $m_{k,\alpha_1}(\nu, b, \sigma)$ 和 $m_{k,\alpha_2}(\nu, b, \sigma)$ 。根据引理 3, 两个截断矩满足:

$$\begin{aligned}
 m_{k,\alpha_1}(\nu, b, \sigma) &= \sigma^k m_{k,\alpha_1}\left(\nu, \frac{b}{\sigma^2}, 1\right) \\
 m_{k,\alpha_2}(\nu, b, \sigma) &= \sigma^k m_{k,\alpha_2}\left(\nu, \frac{b}{\sigma^2}, 1\right)
 \end{aligned} \tag{3-11}$$

那么两个截断矩的比值为：

$$\frac{m_{k,\alpha_1}(\nu, b, \sigma)}{m_{k,\alpha_2}(\nu, b, \sigma)} = \frac{\sigma^k m_{k,\alpha_1}\left(\nu, \frac{b}{\sigma^2}, 1\right)}{\sigma^k m_{k,\alpha_2}\left(\nu, \frac{b}{\sigma^2}, 1\right)} = \frac{m_{k,\alpha_1}\left(\nu, \frac{b}{\sigma^2}, 1\right)}{m_{k,\alpha_2}\left(\nu, \frac{b}{\sigma^2}, 1\right)} \quad (3-12)$$

显然, $m_{k,\alpha_1}(\nu, b/\sigma^2, 1)$ 与 $m_{k,\alpha_2}(\nu, b/\sigma^2, 1)$ 的取值与噪声功率 σ^2 无关, 因此在杂噪比 b/σ^2 固定的情况下, 同阶截断矩比值与噪声功率 σ^2 无关。证毕。 $\square$

上面证明了分位点比值和同阶截断矩比值与噪声功率无关, 在含异常样本的稳健参数估计方法中, 上分位点位置和截断比 $\alpha (0 < \alpha < 1)$ 通常是预先给定的, 实际应用中, 对形状参数大于 20 的 K-分布复合高斯杂波可按照复高斯杂波处理, 我们设置形状参数的取值范围为 $[0.1, 20]$, 为了适应多种复杂环境的海杂波, 设置 CNR 的取值范围为 $[-10\text{dB}, 10\text{dB}]$ 。确定了形状参数和 CNR 的取值范围之后, 我们要产生分位点比值向量和截断矩比值向量, 对于给定的 α 和给定的 ν 和 CNR 的取值范围内的 (ν, CNR) , 由下式生成分位点比值向量和截断矩比值向量:

$$\begin{aligned} \mathbf{x}(\nu, \text{CNR}) &= \begin{bmatrix} \mathbf{x}_0(\nu, \text{CNR}) \\ \mathbf{x}_1(\nu, \text{CNR}) \\ \mathbf{x}_2(\nu, \text{CNR}) \end{bmatrix}, \\ \mathbf{x}_0(\nu, \text{CNR}) &= \begin{bmatrix} r_0(0.1\alpha, 0.5; \nu, \text{CNR}, 1) \\ r_0(0.2\alpha, 0.5; \nu, \text{CNR}, 1) \\ \vdots \\ r_0(\alpha, 0.5; \nu, \text{CNR}, 1) \end{bmatrix} = \begin{bmatrix} F^{-1}(0.1\alpha; \nu, \text{CNR}, 1) / F^{-1}(0.5; \nu, \text{CNR}, 1) \\ F^{-1}(0.2\alpha; \nu, \text{CNR}, 1) / F^{-1}(0.5; \nu, \text{CNR}, 1) \\ \vdots \\ F^{-1}(\alpha; \nu, \text{CNR}, 1) / F^{-1}(0.5; \nu, \text{CNR}, 1) \end{bmatrix}, \quad (3-13) \\ \mathbf{x}_1(\nu, \text{CNR}) &= \begin{bmatrix} r_1(0.1\alpha, 0.5; \nu, \text{CNR}, 1) \\ r_1(0.2\alpha, 0.5; \nu, \text{CNR}, 1) \\ \vdots \\ r_1(\alpha, 0.5; \nu, \text{CNR}, 1) \end{bmatrix}, \quad \mathbf{x}_2(\nu, \text{CNR}) = \begin{bmatrix} r_2(0.1\alpha, 0.5; \nu, \text{CNR}, 1) \\ r_2(0.2\alpha, 0.5; \nu, \text{CNR}, 1) \\ \vdots \\ r_2(\alpha, 0.5; \nu, \text{CNR}, 1) \end{bmatrix}. \end{aligned}$$

得到训练集如下:

$$\Theta_\alpha = \{\mathbf{x}(\nu, \text{CNR}), (\nu, \text{CNR})\}. \quad (3-14)$$

3.3.2 GRNN 有效性分析

GRNN 是一种经典的无反向传播的单程学习网络,在 2.4.3 节我们对 GRNN 已经做了详细介绍。 $K+N$ 模型中,分位点比值向量和截断矩比值向量与形状参数和杂噪比之间的关系没有显式的反函数表达式,因此考虑用 GRNN 来代替这个反函数。在 3.3.1 小节中,由式(3-13)得到分位点与截断矩比值向量,代入(2-60)可以得到模式层的输出为:

$$p_i = \exp\left(\frac{\|\mathbf{x} - \mathbf{x}(v_i, \text{CNR}_i)\|_2^2}{2\beta^2}\right), i = 1, 2, \dots, N \quad (3-15)$$

得到形状参数和杂噪比的预测输出为:

$$\begin{pmatrix} \hat{v} \\ \hat{\text{CNR}} \end{pmatrix} = \text{GRNN}(\mathbf{x}, \beta) = \frac{\sum_{(v_i, \text{CNR}_i) \in \Theta_\alpha} \begin{pmatrix} v_i \\ \text{CNR}_i \end{pmatrix} \exp\left(\frac{\|\mathbf{x} - \mathbf{x}(v_i, \text{CNR}_i)\|_2^2}{2\beta^2}\right)}{\sum_{(v_i, \text{CNR}_i) \in \Theta_\alpha} \exp\left(\frac{\|\mathbf{x} - \mathbf{x}(v_i, \text{CNR}_i)\|_2^2}{2\beta^2}\right)} \quad (3-16)$$

其中, $\|\cdot\|_2$ 表示二范数运算。

GRNN 只有一个超参数 β , 是高斯函数的宽度系数, 可以通过优化该参数来提高预测的精度。GRNN 只是逼近拟合比值向量与两个参数之间的反函数, 我们用一个例子来证明 GRNN 的有效性。其估计精度可以用 KSD、KLD 以及联合使用 KSD 和 KLD 作为拟合测度。KSD 和 KLD 的几何平均距离(Geometric Mean Distance, GMD)为:

$$\text{GMD} = \sqrt{\text{KSD} \times \text{KLD}} \quad (3-17)$$

如图 3.1 所示, 在对 GRNN 模型进行有效性分析实验中, 将整个空间划分为 100×100 的网格, 在 $v \in [0.1, 20], \text{CNR} \in [-10\text{dB}, 10\text{dB}]$ 的取值空间进行参数向量 (v_i, CNR_i) 的均匀取值。得到这些样本之后, 利用公式(3-13)产生分位点和截断矩比值向量, 将比值向量输入 GRNN 模型, 得到预测的 $(\hat{v}_i, \hat{\text{CNR}}_i)$ 。计算每个网格中预测值和样本值之间的平均 KLD、KSD 以及两者的几何平均 GMD, 图 3.1 分别绘制了各网格中当参数向量为 (v_i, CNR_i) 和 $(\hat{v}_i, \hat{\text{CNR}}_i)$ 时 $K+N$ 分布的平均 KSD, 如图(a)平均 KSD、(b)平均 KLD、(c)平均 GMD:




图3.1 基于 GRNN 的反函数的预测指标

可以发现：在形状参数较小或 CNR 较小时估计结果较好，而在形状参数和 CNR 均较大时估计效果较差。这是由于当形参较小时，信号的非高斯性较强，对形参的估计较为准确，从而使最终的估计误差较小。在形状参数较大且 CNR 较小时，信号呈现出了很强的高斯性，能够对形参和 CNR 同时准确估计。而当形状参数较大且 CNR 值较大时，这时杂波具有很强的高斯性，趋同于噪声，导致参数估计准确度比形状参数较小或 CNR 较小时稍低一些。不过从图中可以看到，整体来看，基于 GRNN 的参数估计方法其估计的 KLD、KSD 以及 GMD 三个测度值基本都是 10^{-2} 左右，能够有效参数估计。

3.3.3 基于 GRNN 的 K+N 模型稳健参数估计

对于 K+N 分布模型，使用 GRNN 进行参数估计的流程如图 3.2：




图3.2 基于 GRNN 的 K+N 模型参数估计流程图

首先对 K+N 分布的海杂波幅度序列样本集 $\{z_n, n=1, 2, \dots, N\}$ 进行排序得到序列：

$$z_{(1)} \leq z_{(2)} \leq \dots \leq z_{(N)} \quad (3-18)$$

对于给定的 α ，设置如下几个整数：

$$N_p = [0.1p\alpha N], p = 1, 2, \dots, 10; N_{1/2} = [0.5N] \quad (3-19)$$

其中 $[x]$ 表示距实数 x 最近的整数。

样本分位点本质上是序贯统计量：

$$z_{(N_p)}, p = 1, 2, \dots, 10 \quad (3-20)$$

从数据集合中可以得到 k -阶样本截断矩如下：

$$\hat{m}_{k,0.1p\alpha}(Z) = \frac{1}{N_p} \sum_{n=1}^{N_p} z_{(n)}^k \quad (3-21)$$

对于 $p = 1, 2, \dots, 10$ ，我们可以计算出来样本分位点的比值以及一阶和二阶的样本截断矩比值：

$$\hat{r}_0(p) = \frac{z_{(N_p)}}{z_{(N_{1/2})}}, \hat{r}_1(p) = \frac{N_{1/2}}{N_p} \frac{\sum_{n=1}^{N_p} z_{(n)}}{\sum_{n=1}^{N_{1/2}} z_{(n)}}, \hat{r}_2(p) = \frac{N_{1/2}}{N_p} \frac{\sum_{n=1}^{N_p} z_{(n)}^2}{\sum_{n=1}^{N_{1/2}} z_{(n)}^2}, \quad (3-22)$$

将这 30 个比值组合成比值向量 $\hat{\mathbf{x}}(\mathbf{z}), \mathbf{z} = \{z_1, z_2, \dots, z_N\}$ ，输入到 GRNN 模型中，得到形状参数和杂噪比的估计：

$$(\hat{\nu}, \hat{\text{CNR}}) = \text{GRNN}(\hat{\mathbf{x}}(\mathbf{z}), \beta) \quad (3-23)$$

根据(3-8)可以得到噪声功率 $\hat{\sigma}^2$ ：

$$\hat{\sigma}^2 = \left(\frac{z_\alpha}{F^{-1}(\alpha; \hat{\nu}, \hat{\text{CNR}}, 1)} \right)^2 \quad (3-24)$$

其中 z_α 是从样本数据中计算得到的分位点， $F^{-1}(\alpha; \hat{\nu}, \hat{\text{CNR}}, 1)$ 是将估计出的 $\hat{\nu}, \hat{\text{CNR}}$ 带入分位点计算公式得到的分位点估计值。

尺度参数 $\hat{b}$ 由下式计算：


$$\hat{b} = \hat{C}\hat{N}R \times \hat{\sigma}^2 \quad (3-25)$$

由于样本分位点和样本截断矩具有对小数目异常样本的稳健性，所以 GRNN 估计参数也具有稳健性，并且由于提供了更多的样本分位点和样本截断矩，GRNN 的估计性能具有稳定性。

3.4 实验结果与分析

在本节中，我们对基于 GRNN 的 K+N 模型参数估计方法的估计性能进行验证，分别通过仿真数据和实测数据进行分析，与 MoM 和 FMoM 两种方法做对比，验证基于 GRNN 的参数估计方法的性能。

首先通过仿真数据进行估计性能分析。第一个实验固定 CNR，首先固定 CNR=−3dB， ν 取值为 $\nu \in [0.1, 20]$ ，其中样本数 N 设置为 10^5 ，对于每个形状参数，进行 10^3 次独立重复实验并分别计算评估测度 KSD、KLD 以及 GMD 的平均值。对于 K+N 模型，MoM 和 FMoM 方法使用显式模型进行形状参数、尺度参数以及噪声功率三个参数的估计^[38]，基于 GRNN 的方法中，设置 $\lambda = 0.9$ 提取分位点比值向量和截断矩比值向量进行参数估计。如图 3.3 的(a)、(c)和(e)图是在不含异常样本下的基于 GRNN 估计方法、MoM 以及 FMoM 的 KSD、KLD 和 GMD。从图中可以看到，基于 GRNN 的估计方法性能最好；MoM 采用 2-4-6 阶矩估计参数，由于高阶矩带来较大的误差，其性能在个别形状参数上较好，估计起伏较大；FMoM 方法使用 0.5 阶矩代替 MoM 方法中的 6 阶矩进行形状参数估计，相比 MoM 方法性能得到了改善，但是由于其本质还是用到 4 阶高阶矩，在形参较小或较大的时候 FMoM 估计方法效果仍然较差。而 GRNN 方法的三个测度值都很小，估计效果比 MoM 和 FMoM 方法更稳定准确。图 3.3(b)、(d)和(f)是含异常样本情况下三种估计方法的性能对比，实验添加异常样本的比例为 2%，相比于不含异常样本的情况，含有异常样本的各个方法的 KSD、KLD 以及 GMD 测度值均增大，在含异常样本的情况下，各方法的参数估计性能都受到影响，MoM 和 FMoM 两种方法估计效果明显变差，这是因为异常样本会引起高阶矩值过大从而导致拟合效果变差，可以得到这两种方法对异常样本不具有稳健性的结论。由于采用具有稳健性的分位点和截断矩，基于 GRNN 的方法受异常样本的影响很小，其估计的参数拟合效果是三种方法中最好的，可以得到基于 GRNN 的方法在含异常样本的数据中是具有稳健性的结论。

图3.3 固定 $\text{CNR}=-3\text{dB}$ 三种方法在有无异常样本仿真数据下的比较

然后固定 $\text{CNR}=0\text{dB}$, ν 取值为 $\nu \in [0.1, 20]$, 如图 3.4(a)、(c)和(e)是在不含异常样本情况下三种方法的测度值对比, 从图中可以看到, MoM 方法的各测度值最大, 估计性能最差, FMoM 方法比 MoM 方法改善很多, 但是在 ν 较小时, 其估计准确度较差, 而基于 GRNN 的方法估计测度值最小, 估计最准确。从图 3.4 含异常样本的(b)、

(d)和(f)图可以看到，MoM 和 FMoM 两种方法性能明显变差，而基于 GRNN 的方法测度值变化不大，说明基于 GRNN 的方法具有抗异常样本的能力。对比固定 $\text{CNR}=-3\text{dB}$ ，可以看到三种方法的测度值整体有所增大，这是因为 CNR 较小时，信号的高斯性较强，估计的准确度更高。




图3.4 固定 $\text{CNR}=0\text{dB}$ 三种方法在有无异常样本仿真数据下的比较

第二个实验固定 ν 值,首先固定 $\nu=5$,CNR取值为 $\text{CNR} \in [-10\text{dB}, 10\text{dB}]$,其中样本数 N 设置为 10^5 ,对于每个形状参数,进行 10^3 次独立重复实验并分别计算评估测度KSD、KLD以及GMD的平均值。如图3.5(a)、(c)和(e)是在不含异常样本的数据下三种方法的测度值比较,如图3.5(b)、(d)和(f)是在含有2%异常样本数据下三种方法的测度值的比较。




图3.5 固定 $\nu=5$ 三种方法在有无异常样本仿真数据下的比较

从图 3.5 中可以看出, 在不含异常样本的情况下, 基于 GRNN 的估计方法仍是参数估计准确度最高的, FMoM 相比 MoM 方法的估计准确度改善许多, 但是在杂噪比很高的时候其估计准确度变差。相比于不添加异常样本, 三种方法的估计准确度都有一定程度的降低, 但还是可以明显看到基于 GRNN 方法的估计准确度最高, 并且相比于无异常样本变化很小, 说明基于 GRNN 的参数估计方法是对异常样本不敏感的。




图3.6 固定 $\nu=10$ 三种方法在有无异常样本仿真数据下的比较

如图 3.6 是固定 $\nu=10$ 时三种方法的测度值比较, 可以看到, 基于 GRNN 方法的估计准确度仍然是最高的。三种方法的估计测度值相比 $\nu=5$ 时有所增大, 并且在 CNR 较小时, 三种方法的估计准确度比 CNR 较大时准确度高。这是因为在形状参数较大且 CNR 较小时, 信号呈现出了很强的高斯性, 能够对形参和 CNR 同时准确估计。而当形状参数较大且 CNR 值较大时, 这时杂波具有很强的高斯性, 趋同于噪声, 导致参数估计准确度比形状参数较小或 CNR 较小时稍低一些。

下面通过实测数据进行方法性能分析。分别使用 IPIX 雷达数据库^[71]中的两组实测数据中的一个距离单元进行拟合。第一组数据如图 3.7(a)所示, 距离分辨率为 15 米, 给数据添加噪声并选取杂噪比为 6.46dB 的第 13 个距离单元; 第二组数据如图 3.8(a)所示, 距离分辨率为 30 米, 同样给数据添加噪声并选取杂噪比为 -0.58dB 的第 27 个距离单元。

首先, 对杂噪比为 6.46dB 的数据进行拟合, 如图 3.7(c)和(e)分别是不含异常样本的情况下三种方法的拟合 PDF 和拟合互补累积分布函数(Complementary Cumulative Distribution Function, CCDF), 以及数据的 EPDF 和经验互补累积分布函数(Empirical Complementary Cumulative Distribution Function, ECCDF)。从 PDF 和 CCDF 的拟合结果图难以看出来哪种方法的结果是最好的, 因此, 表 3.1 给出三种方法的拟合测度, 可以看到, 在不含异常样本的情况下, GRNN、MoM 和 FMoM 三种方法的测度值相差不大, 基于 GRNN 方法的各测度值最小, 拟合最准确。

表3.1 三种方法拟合 CNR 为 6.46dB 的实测数据的测度值

估计方法	是否含异常样本	KSD	KLD	GMD
GRNN	不含异常	0.0078	0.0697	0.0233
	含异常	0.0100	0.0618	0.0248
MoM	不含异常	0.0155	0.0769	0.0346
	含异常	0.3248	0.6816	0.4705
FMoM	不含异常	0.0421	0.1164	0.0700
	含异常	0.3915	0.7706	0.5492

接着对数据添加异常样本来验证基于 GRNN 的参数估计方法的稳健性, 如图 3.4(b)为含异常样本数据的数据幅度图, 对数据添加 2% 的异常样本, 并对数据的第 13 距离单元进行拟合, 三种方法的拟合 PDF 和 CCDF 如图 3.7(d)和(f)所示, 从图中可以明显看到, 加入异常样本之后基于 GRNN 的方法拟合 PDF 和拟合 CCDF 曲线基本和 EPDF、ECCDF 重合, 而 MoM 和 FMoM 两个方法虽然在无异常样本的情况下拟

合拟合曲线与 EPDF、ECCDF 基本重合，但是在加入异常样本之后，其拟合效果明显变差。在表 3.1 中列出了加入异常样本之后的测度值，MoM 和 FMoM 两种方法的测度值在有异常样本下由原本的 10^{-2} 左右的数值变为 10^0 左右，测度值明显变大，而基于 GRNN 的方法在有无异常样本下测度值相差不大，由此可以验证利用样本分位点和截断矩的基于 GRNN 的 K+N 模型参数估计方法在含异常样本数据中的稳健性。




图3.7 CNR 为 6.46dB 的实测数据下三种估计方法的拟合结果

接下来，对杂噪比为-0.58dB 的数据进行拟合，如图 3.8(c)和(e)分别是不含异常样本的情况下三种方法的拟合 PDF 和 CCDF，以及数据的 EPDF 和 ECCDF。




图3.8 CNR 为-0.58dB 的实测数据下三种估计方法的拟合结果

从图中可以看到三种方法的拟合效果都很好，从表 3.2 中的拟合测度值来看，在不含异常样本的数据中，GRNN 方法的测度值是最小的，达到 0.004，说明在不含异常样本的数据中，基于 GRNN 的方法估计准确度最高，拟合效果最好。如图 3.8(b)是对数据加入 2%的异常样本之后的幅度图，如图(d)和(f)分别是加入异常样本数据的

PDF 和 CCDF 拟合曲线。从图中可以看到，基于 GRNN 方法的拟合曲线基本和数据 EPDF、ECCDF 重合，而基于 MoM 和 FMoM 两种方法的拟合曲线和 EPDF、ECCDF 相差较大。从表 3.2 中的三种方法的测度值来看，加入异常样本之后，基于 GRNN 方法的测度值变化不大，而基于 MoM 和 FMoM 两种方法测度值由原本的 10^{-2} 左右变为 10^0 左右。综上，在杂噪比为 -0.58dB 的数据中，基于 GRNN 方法的拟合最准确，并且抗异常样本能力最强。

表3.2 三种方法拟合 CNR 为-0.58dB 的实测数据的测度值

估计方法	是否含异常样本	KSD	KLD	GMD
GRNN	不含异常	0.0040	0.0693	0.0166
	含异常	0.0063	0.0585	0.0192
MoM	不含异常	0.0074	0.0707	0.0228
	含异常	0.2909	0.6238	0.4260
FMoM	不含异常	0.0288	0.0925	0.0516
	含异常	0.2666	0.5727	0.3907

以上基于仿真数据和实测数据的实验结果表明，在不含异常样本的情况下，基于 GRNN 的利用分位点和截断矩比值向量进行参数估计的方法，估计的准确度最高，并且在含异常样本的情况下，其估计性能受异常样本影响不大，稳健性最好。

3.5 本章小结

本章详细介绍了基于神经网络的 K+N 模型参数估计方法，涵盖了 K+N 模型介绍、网络训练数据生成、GRNN 模型有效性分析、参数估计过程以及方法性能评估的完整流程。在本章中，我们首先介绍 K+N 分布，证明了在固定杂噪比的情况下，K+N 分布中分位点比和截断矩比与噪声功率无关、只和杂噪比有关的特性，然后产生训练数据输入 GRNN 进行网络模型训练。通过 KSD、KLD 以及两者的几何平均 GMD 三个测度验证了网络模型的有效性。最后，分别利用不含异常样本和含异常样本仿真数据和实测数据进行实验，实验结果表明本研究所提出的方法不仅能更准确的估计 K+N 分布的参数，并且在数据含有异常样本的情况下，估计稳健性最好。

综上所述，本章为 K+N 模型的参数估计提供了一种利用多样本分位点和样本截断矩的基于 GRNN 的稳健参数估计方法，本章研究内容将 GRNN 的学习能力与样本分位点、样本截断矩的稳健性能相结合，有效提高了 K+N 分布模型参数估计的准确度及稳健性，并且能够适应复杂的海面环境。

第四章 基于神经网络的海杂波抑制及目标检测方法

4.1 引言

海杂波背景下的目标检测技术聚焦于环境杂波和目标回波的差异性判别。杂波抑制可以减弱杂波强度，增大环境回波和目标回波差异，从而增强目标检测效果。因此，海杂波背景下的杂波抑制方法是雷达技术中重要的研究方向之一。

在长观测时间下海面小目标检测研究方面，基于神经网络的海杂波序列建模和海杂波抑制是最早采用的技术途径之一。近年来，神经网络和人工智能迎来了新的发展热潮，各种新型的神经网络被陆续构建以满足不同的应用需求。尝试利用新兴的神经网络实现海杂波时间序列的预测和抑制具有潜在的应用价值。此外，MTI 滤波在抑制线性杂波具有显著优势。基于此，本章提出了基于时变自适应 MTI 滤波与幅度-相位双神经网络预测级联的海杂波抑制方法，使用时变自适应 MTI 滤波实现了海杂波的线性杂波抑制，然后使用具有非线性预测能力的神经网络实现了非线性杂波抑制，增强了杂波抑制效果，进而提升了目标检测性能。4.2 节介绍了海杂波数据的重构过程，数据重构包括两次滑窗过程，均对数据进行了增强，第一次滑窗是为了满足虚警率的要求，第二次滑窗是解决训练数据不足的问题。4.3 节首先对基于神经网络输入不同信息进行海杂波抑制的方法进行分析介绍，然后介绍了基于时变自适应 MTI 滤波与非相干累积级联的海杂波抑制方法，最后提出了基于时变自适应 MTI 滤波与幅度-相位双 LSTM 神经网络预测级联的海杂波抑制方法。4.4 节采用 IPIX 数据验证了所提海杂波抑制方法的性能。4.5 节对本章进行了总结。

4.2 海杂波数据重构过程

由于神经网络预测属于典型的复杂非线性函数，因此残差序列和检验统计量的模型无法通过解析推导的途径得到，只能通过获取大量样本训练拟合得到其预测模型，实现对海杂波的抑制。但是海杂波实测数据有限，有效地利用有限的海杂波数据构建出足够的数据样本用于网络训练、网络验证、确定检测门限以及网络测试是数据处理中的核心问题。所以需要数据重构，数据重构包括两次滑窗过程，第一次滑窗处理是为了满足预设的虚警率要求，在目标检测阶段，需要根据纯杂波单元计算出足够的检验统计量来确定门限。第二次滑窗处理是因为神经网络的训练需要大量的数据，保证充足的训练数据有助于提升网络的预测能力。

下面详细介绍数据重构过程，首先对海杂波数据进行划分。如图 4.1 海杂波数据用于杂波抑制和目标检测两个过程。杂波抑制过程中用于杂波抑制的训练和验证

单元用于训练和验证网络得到杂波抑制模型。用于检测过程的包括确定判决门限单元、参考单元及待检测单元。




图4.1 海杂波数据划分示意图

然后对各距离单元进行第一次滑窗处理，如图 4.2 把各距离单元的脉冲以步长为 $Overlap$ 窗长为 N 划分为长度为 N 的脉冲块，每一个长度为 N 的脉冲块作为一个样本，后续计算一个检验统计量。接着对数据进行第二次滑窗处理，如图 4.3 将一个长度为 N 的脉冲块经过第二次滑窗后得到 $(N-\tau)*\tau$ 大小的数据样本和对应的 $(N-\tau)*1$ 大小的标签。经过两次滑窗过程，最终得到训练和验证集、确定判决门限集以及测试集：




图4.2 数据重构过程

第二次滑窗处理中，单步预测的阶数为 τ ，于是从海杂波数据 $z(n)$ 中生成单步预测的样本向量 $[z(n), z(n+1), \dots, z(n+\tau-1), z(n+\tau)]^T$ ，其中前 τ 个分量是神经网络的输入，最后一个分量 $z(n+\tau)$ 是期望的输出。




图4.3 第二次滑窗过程

以上实现了海杂波数据的重构处理,将海杂波数据进行两次滑窗处理最终得到训练和验证数据集、确定判决门限数据集,以及测试集。

4.3 海杂波抑制及目标检测方法

由于海杂波具有短时可预测的特性,可以将海杂波时间序列建模为未知系统的量测序列,海杂波背景下的目标检测问题可以表述为下面的二元假设检验问题:

$$\begin{cases} H_0: z(n) = c(n), z_p(n) = c_p(n), n = 1, 2, \dots, N_T, p = 1, 2, \dots, P, \\ H_1: z(n) = s(n) + c(n), z_p(n) = c_p(n), n = 1, 2, \dots, N_T, p = 1, 2, \dots, P \end{cases} \quad (4-1)$$

其中 $z(n)$ 是待检测单元的复时间序列, N_T 是时间序列的长度, $c(n)$ 是海杂波时间序列, $s(n)$ 是未知的目标回波信号, $z_p(n)$ 是待检测单元周围的参考单元的海杂波时间序列。

接下来将详细介绍几种海杂波抑制方法,包括基于神经网络预测海杂波幅度序列的方法、基于神经网络预测海杂波复序列的方法、使用时变自适应 MTI 滤波方法以及基于时变自适应 MTI 滤波与幅度-相位双神经网络预测级联的杂波抑制方法。

4.3.1 基于神经网络预测不同输入特征的海杂波抑制方法

按照文献[42]提出的基于神经网络预测海杂波幅度序列的海杂波中非相干目标的检测的流程如图 4.4 所示。




图4.4 基于神经网络预测海杂波幅度序列的非相干检测器结构

首先,采用 4.2 节中的数据重构方法,对数据进行第一次的滑窗处理。得到待检测单元中的一个长度为 N 的雷达回波的幅度时间序列的数据块 $y_A(n)$ 。然后利用纯海杂波幅度序列训练海杂波的幅度神经网络预测器。利用训练好的神经网络预测器,对

待检测距离单元的幅度序列进行预测并计算预测残差序列。假定神经网络预测器的阶数是 τ ，则单步预测残差序列为：

$$\begin{aligned} y_A(n) &= |z(n)|, n=1, 2, \dots, N, \\ \varepsilon_A(n) &= y_A(n) - \hat{\Phi}(y_A(n-1), y_A(n-2), \dots, y_A(n-\tau)), n=\tau+1, \tau+2, \dots, N \end{aligned} \quad (4-2)$$

目标检测是基于预测误差构造检验统计量，采用误差的平均均方误差：

$$\xi_A = \frac{1}{N-\tau} \sum_{n=\tau+1}^N \varepsilon_A^2(n) \underset{H_0}{\overset{H_1}{\geq}} T(P_{fa}) \quad (4-3)$$

在图 4.5 所示的检测方法中，雷达回波的相位信息没有在检测中发挥作用。基于此，Haykin 等人同时提出了基于雷达复回波序列混沌建模的目标检测框架^[44]。




图4.5 基于神经网络预测海杂波复序列的非相干检测器结构

原先处理框架中神经网络残差序列后是多普勒域恒虚警率(Constant False Alarm Rate, CFAR)处理^[44]。图 4.5 的处理流程中预测残差序列仍采用非相干累积构建检验统计量。将海杂波复序列实部和虚部分别作为输入训练神经网络。但是由于强行把 L 维复向量转化为 $2L$ 维的实向量，影响了雷达回波相位信息的充分利用。事实上，由于神经网络预测通过非线性函数实现，非线性滤波后的目标回波和海杂波已经不再符合加性模型，目标回波的相位序列已经发生复杂的变化，这导致传统多普勒域 CFAR 处理无法使用。

4.3.2 时变自适应 MTI 海杂波抑制及检测方法

时变自适应 MTI 滤波和非相干累积级联的 CFAR 检测是长累积时间下目标检测的技术途径之一。由于海杂波时间序列是短时可预测长时不可预测的，采用滑窗式时

变的自适应滤波器可以较好的抑制海杂波。

首先,假定待检测距离单元 $z(n)$ 周围参考单元 $z_p(n)$ 的纯海杂波数据与待检测单元的海杂波数据具有相同的统计特性。一个 L 阶的时变滤波器从 P 个参考单元的纯海杂波数据得到,时变自适应 MTI 滤波器通过求解下面优化问题得到:

$$\hat{a}_n = \arg \min_{a_n} \left\{ \sum_{p=1}^P \left| z_p(n) - \sum_{l=1}^L a_n(l) z_p(n-l) \right|^2 \right\}, \quad (4-4)$$

$$n = 1, 2, \dots, N_T; p = 1, 2, \dots, P$$

以上(4-4)滤波器可以通过递归计算的方法快速计算。显然,这样的滤波器随着时间 n 慢变,适应了海杂波时间序列的短期可预测和长期不可预测的性质。应用时变的预测滤波器到待检测单元的雷达回波时间序列,得到滤波后的复值残差序列如下:

$$\varepsilon_c(n) \equiv z(n) - \sum_{l=1}^L a_n(l) z(n-l), n = L+1, L+2, \dots, N_T \quad (4-5)$$

式(4-4)中的 MTI 滤波器属于 L 阶的滤波器,需要用前面 L 个脉冲的回波进行对消,以达到杂波抑制的目的。

非相干累积方法首先是对雷达接收的时间序列进行平方律检波,然后检波后的信号进行多脉冲检测生成检验统计量进行二元假设检验。目标检测基于残差序列的非相干累积完成,即:

$$\xi = \frac{1}{N_T - L} \sum_{n=L+1}^{N_T} |\varepsilon(n)|^2 \underset{H_0}{\overset{H_1}{\geq}} T(P_{fa}) \quad (4-6)$$

其中, ξ 表示非相干累积方法的检验统计量, $T(P_{fa})$ 是从检验统计量得到的门限。

时变自适应 MTI 滤波器与非相干累积级联的目标检测的处理流程如图 4.6 所示:




图4.6 时变自适应 MTI 滤波器与非相干累积级联的目标检测流程

参考单元的数据用于得到抑制海杂波的时变自适应滤波器，然后将其应用于待检测单元雷达回波时间序列实现海杂波的有效抑制。海杂波抑制后的残差序列进行非相干累积实现目标检测。由于海杂波抑制采用了时变的线性滤波，不会对雷达回波的相位造成影响，因此在残差序列上也可采用相干累积检测运动目标。此外，时变自适应 MTI 滤波器利用海杂波时间序列的线性相干性实现海杂波的抑制，海杂波抑制后的残差序列仍然存在非线性的依赖性，如何滤除非线性的杂波仍然是一个亟待解决的问题。

4.3.3 时变自适应 MTI 滤波与幅度-相位双神经网络预测级联的海杂波抑制方法

把时变自适应 MTI 滤波、幅度相位时间序列的神经网络预测、和预测残差的非相干累积三者相级联，可以同时实现线性杂波和非线性杂波的滤除再进行目标检测，是实现海杂波背景中小目标检测更有效的途径。首先，由式(4-4)计算得到的时变自适应 MTI 滤波器，然后对雷达回波数据的每个距离单元进行 MTI 滤波得到复值残差序列 $\varepsilon_c(n)$ ，将复值残差序列分解为幅度和相位序列。在输入网络之前要对幅度和相位序列进行预处理，预处理过程如图 4.7 所示：




图4.7 数据预处理过程

其中两次滑窗处理过程在 4.2 节做了详细介绍，经过以上数据处理过程得到训练和验证集、确定判决门限集和测试集。

首先，采用训练和验证样本集分别进行幅度和相位 LSTM 网络训练，网络学习过程可以归结为用神经网络构建一个复杂的非线性映射实现海杂波时间序列的单步预测，即：

$$\begin{aligned}\hat{A}_{p1}(\tau+1) &= F_A \left(A_{p1}(1), A_{p1}(2), \dots, A_{p1}(\tau) \middle| \hat{\Theta}_A \right) \\ \hat{\phi}_{p1}(\tau+1) &= F_\phi \left(\phi_{p1}(1), \phi_{p1}(2), \dots, \phi_{p1}(\tau) \middle| \hat{\Theta}_\phi \right)\end{aligned}\quad (4-7)$$

其中结构参数集合 $\hat{\Theta}_A$ 和 $\hat{\Theta}_\phi$ 由幅度和相位训练的两个神经网络和训练数据共同决定。

为了更有效地评估模型的预测性能, 引入相对均方误差(Relative Root Mean Square Error,RRMSE)损失函数作为训练目标。RRMSE 将预测误差相对于真实值进行归一化, 其定义为:

$$\text{RRMSE} = \frac{1}{N} \sum_{i=1}^N \frac{|\hat{x}_i - x_i|}{|x_i| + \varepsilon} \quad (4-8)$$

其中, $\hat{x}_i$ 为模型的预测输出, x_i 为真实值, N 为样本总数。 ε 是为了防止分母为零而引入的极小常数。

得到训练好的幅度和相位 LSTM 神经网络后, 将确定判决门限的纯杂波样本集中每一对幅度样本 A_{p2} 和相位样本 φ_{p2} 分别输入幅度和相位网络, 每一对样本由 MTI 滤波后的复值残差杂波序列 $A_{p2} \exp(j\varphi_{p2})$ 分解得到, 两个网络预测输出为 $\hat{A}_{p2}$ 和 $\hat{\varphi}_{p2}$, 然后将预测输出还原为复序列 $\hat{A}_{p2} \exp(j\hat{\varphi}_{p2})$, 根据(4-9)得到杂波二次残差复序列 $\varepsilon'_{p2}(n)$, 然后基于非相干累积构造检验统计量 ζ'_{p2} :

$$\begin{aligned} \varepsilon'_{p2}(n) &= \hat{A}_{p2} \exp(j\hat{\varphi}_{p2}) - A_{p2} \exp(j\varphi_{p2}), n = \tau + 1, \tau + 2, \dots, N, \\ \zeta'_{p2} &= \frac{1}{N - \tau} \sum_{n=\tau+1}^N |\varepsilon'_{p2}(n)|^2 \end{aligned} \quad (4-9)$$

计算得到样本集的所有的检验统计量之后, 将其进行排序, 根据预设虚警得到门限。

最后, 对待检测单元样本集中的每一对幅度样本 A 和相位样本 φ 按照同样方法构造检验统计量, 将检验统计量和门限值比较进行目标检测:

$$\xi' = \frac{1}{N - \tau} \sum_{n=\tau+1}^N |\varepsilon'(n)|^2 \underset{H_0}{\overset{H_1}{\geq}} T(P_{fa}) \quad (4-10)$$

其中, $T(P_{fa})$ 是由(4-9)中检验统计量得到的门限。

如图 4.8 是基于时变自适应 MTI 滤波、幅度-相位双 LSTM 神经网络预测与预测残差非相干累积级联的检测方法流程:




图4.8 MTI 滤波-幅度、幅度-相位双 LSTM 预测-非相干累积级联的检测流程

其中图中黄色代表网络训练模块，蓝色代表计算门限模块，绿色代表检测模块。

4.4 实验结果与性能分析

在本节中，用 1998 年的 IPIX 雷达数据库的数据^[71]进行实验。对 4.3.3 节提出的基于时变自适应 MTI 滤波与幅度-相位双 LSTM 神经网络预测级联的海杂波抑制方法的性能进行检验。

首先，采用 IPIX 雷达数据库 1998 年的“19980223_164055_ANTSTEP”的 VH 极化数据展示基于神经网络幅度序列预测抑制方法的性能和结果。图 4.9(a)是数据的功率图，数据包含了 34 个距离门 60 秒的数据，雷达距离分辨率 30 米，脉冲重复频率 1000Hz，配试目标为漂浮的小船，平均 SCR 是 25.6dB。




图4.9 数据功率图和目标和杂波预测误差直方图

图 4.9(a)中目标附近上下 20 个距离单元的数据用于训练和验证预测神经网络、计算 H_0 假设下检验统计量的样本、并确定判决门限。这里单步预测的阶数 $\tau=32$ ，于是从训练区域的幅度序列中生成了大量的样本向量 $[y_A(n), y_A(n+1), \dots, y_A(n+32)]^T$ ，其中前 32 个分量是训练器的输入，最后一个分量是期望的输出。预测神经网络本质上是生成一个 32 元的非线性光滑函数，属于未知非线性函数的逼近问题，这里采用了多层感知机网络^[72,73]。图 4.9(b)是在训练区域得到的检验统计量的直方图和虚警概率为 10^{-3} 时的判决门限。表 4.1 列出了在 IPIX 数据库五组数据 HV 极化下海杂波幅度序列预测非相干累积方法与传统的非相干累计方法的检测概率，其中，累计脉冲数 $N=512$ ，虚警率为 0.001。可以看出，相比于简单的非相干累积方法，基于海杂波幅度序列预测的非相干累积方法在检测性能上还要差一些。其主要原因在于其只使用了幅度信息，没有利用到相位信息，仅使用幅度信息没有幅度和相位信息联合进行杂波抑制对杂波和目标的区分度高，导致在滤除杂波的同时，降低了含目标回波的信杂比，使得目标更难检测。此外，从表 4.1 中可以看到，即使目标平均 SCR 很高，在高分辨海杂波下非相干检测仍然难以获得较高的检测概率。这种现象发生的原因有二，其一是高分辨海杂波强的非高斯性抬高了检测门限；其二是海面小目标剧烈的 RCS 和 SCR 起伏使得在一些时段目标回波弱，难以检测到。

表4.1 海杂波幅度序列预测非相干累积检测方法与传统非相干累积检测方法的性能对比
($N=512$ ，虚警率 0.001)

检测方法	#202225	#202525	#163113	#171437	#164055
平均 SCR (dB) (HV 极化)	28.54	26.27	16.75	20.45	10.13
海杂波幅度预测	0.6161	0.4484	0.1989	0.3151	0.2505
传统非相干累积	0.6172	0.5806	0.3355	0.5226	0.5290

对本论文提出的基于时变自适应 MTI 滤波与幅度-相位双神经网络的海杂波抑制方法，为了选择最适合海杂波预测任务的模型结构，对比了几种经典的时序预测模型，包括 AR 模型、CNN 模型和 LSTM 模型。训练网络阶段，利用图 4.9(a)中目标附近上下 20 个距离单元的数据用于训练和验证预测神经网络、计算 H_0 假设下检验统计量的样本、并确定判决门限。这里单步预测的阶数 $\tau=32$ ，20 个距离单元共生成 1.2×10^6 个样本向量。目标检测的实验结果如图 4.10 所示。




图4.10 不同模型的检测结果对比

AR 模型作为一种传统的线性时序预测方法，能够较好拟合线性杂波成分，但在处理非线性海杂波时表现不佳。尤其在本研究中，前置的 MTI 滤波已经完成了初步的线性滤波，AR 模型的作用在于进一步捕捉剩余的线性特征，难以有效抑制复杂的非线性杂波成分。CNN 模型虽然局部特征提取能力较强，且在某些场景下对非线性特征的捕捉较为灵活，但其缺乏显式的记忆机制，无法有效捕捉海杂波时间序列中的长期依赖关系，因此，在处理长期时间依赖和复杂非线性特征时，CNN 模型的表现不如 LSTM 模型。LSTM 模型通过其内置的记忆单元，能够更好地学习时间序列中的长期依赖关系，在整体检测性能上优于其他两种模型，更适用于海杂波背景下的目标检测任务，因此本论文采用 LSTM 模型。

对基于时变自适应 MTI 滤波与幅度-相位双 LSTM 神经网络预测级联的海杂波抑制方法，使用 IPIX 数据集下的“19980223_164055_ANTSTEP”的 VH 极化数据进行效果展示。

图 4.11 展示了在该数据集下，训练验证过程中的损失曲线。为防止过拟合，本文采用了 RRMSE 作为损失计算方式，确保模型在训练过程中能够有效地拟合数据，同时避免在验证集上出现过拟合现象。如图 4.11 所示，经过 100 个 epoch 的训练，损失曲线逐渐收敛，说明模型在不断优化过程中能够有效减少训练误差。验证损失的稳定

性也表明，模型在训练过程中没有出现显著的过拟合现象。通过这种方式，我们能够确认该方法不仅在训练数据上表现良好，同时在今后的验证数据上也能保持较好的泛化能力。




图4.11 训练过程中的幅度与相位损失曲线

图 4.12 展示了在该数据集下基于时变自适应 MTI 滤波与幅度-相位双 LSTM 神经网络预测级联的海杂波抑制方法的检测效果。




图4.12 MTI-幅度、相位-LSTM 预测级联的检测效果

如图 4.12 所示, 首先对雷达回波的复时间序列进行 2 阶时变自适应 MTI 滤波, 滤除线性杂波, 得到剩余回波。在此基础上进行基于神经网络非线性预测滤除杂波, 得到滤波后的复时间序列, 并根据式(4-9)和(4-10)计算检验统计量并得到检测门限, 绘制直方图如图 4.12(a)所示, 其中虚警概率设置为 $P_{fa}=10^{-3}$, 单步预测的阶数为 $\tau=32$, 从图中可以看到, 相比于图 4.9(b), 网络对目标的区分能力增强很多, 目标检测能力增强。图 4.12(b)是在去除受影响单元和训练单元的数据之后的检测结果图, 虚警率为 0.001, 检测概率为 0.97。可以看到未被训练的区域虚警概率也能得到很好的控制, 并且相比于表 4.1 单一的海杂波幅度预测方法检测性能也有所提升。

图 4.13 是本论文提出的基于时变自适应 MTI 滤波、幅度-相位双 LSTM 神经网络预测的非相干累积检测方法与几种经典的检测器性能对比, 包括传统分形方法^[74]、时变自适应 MTI 滤波与传统非相干累积级联方法和基于一致性因子检验方法^[75]三种方法。一致性因子检验方法利用目标与杂波之间的统计特性, 通过计算一致性因子区分信号和杂波, 但是由于缺乏对时序依赖性的建模能力, 因此其区分目标与杂波的能力有限, 导致整体检测效果不理想。




图4.13 四种杂波抑制方法在 20 组数据集下的检测概率

从图 4.13 可以看到, 在大部分数据集下, 一致性因子检验的检测效果都较差。传

统分形方法只考虑了幅度信息，没有使用相位信息，且其需要的累计脉冲数较高，观测时间较长。此外，传统分形方法计算复杂度较高，处理大规模数据时可能存在性能瓶颈。相比之下，本论文提出的基于时变自适应 MTI 滤波与幅度-相位双 LSTM 神经网络预测的非相干累积检测方法，在多数数据集上要比其它三种方法的检测概率高，在部分低信杂比的数据集上偏低一些，原因这种方法是高度依赖于信杂比的，在信杂比较低的时候，目标回波与海杂波特性相似，滤波后的非相干累积方法相对于传统的相干累积方法的性能有所下降，导致检测概率低。

为了验证基于时变自适应 MTI 滤波、幅度-相位双 LSTM 预测的非相干累积检测方法的检测性能与信杂比的依赖关系，表 4.2 列出了 IPIX 数据集中五组数据在四种极化下检测概率对信杂比的依赖情况。可以看出五组数据集中 HV、VH 极化下 SCR 较高，而 HH、VV 极化下 SCR 较低。在表 4.2 中 P_d 一栏，前者为 MTI+非相干累积检测方法，后者为 MTI+LSTM 幅度相位预测+恒虚警检测方法，加粗体的为检测性能更好的检测器。可以看到两种检测方法的检测概率高度依赖平均 SCR，在低 SCR 下，如 HH 和 VV 极化下两种检测器都未能完成有效检测。对比两种方法，发现基于时变时变自适应 MTI 滤波-幅度相位分别 LSTM 预测的恒虚警检测方法的检测概率在绝大多数情况下高于 MTI+非相干累积检测方法。

表4.2 MTI+非相干累积检测方法与 MTI+LSTM 幅度相位预测+非相干累积检测方法在五组 IPIX 数据集上的性能对比 (N=512, 虚警率 0.001)

数据	#202225		#202525		#163113		#171437		#164055	
极化	SCR	P_d	SCR	P_d	SCR	P_d	SCR	P_d	SCR	P_d
HH	10.6	0.01/ 0.28	12.2	0.08/ 0.20	-4.2	0/0	10.0	0/0 .06	6.4	0/0 .06
HV	29.7	0.76/ 0.97	28.6	0.93/ 0.95	24.9	0.59/ 0.59	29.3	0.59/ 0.75	27.4	0.81/ 0.85
VH	31.6	0.70/ 0.95	30.3	0.92/ 0.92	23.4	0.62 /0.55	27.6	0.62/ 0.80	25.6	0.82/ 0.97
VV	10.1	0.01/ 0.35	11.7	0.05/ 0.21	-5.0	0/0	9.6	0/0 .01	6.8	0/0 .12

对于所提出方法对 SCR 的依赖性关系，图 4.14 和图 4.15 分别展示了高信杂比和低信杂比情况下所提出方法的预测性能。采用 IPIX 雷达数据库 1998 年两组具有不同 SCR 的数据，第一组是 SCR 为 25.6dB 的“19980223_164055_ANTSTEP”的 VH 极化数据，第二组是 SCR 为-5dB 的“19980204_163113_ANTSTEP”的 VV 极化数据。如图 4.14 是在高 SCR 下杂波单元和目标单元的幅度和相位预测结果：




图4.14 SCR 较高时海杂波和含目标回波的幅度相位预测对比图

其中,图 4.14(a)和(b)是 0.5s 的纯海杂波序列幅度和相位序列的预测情况,可以看到:训练的神经网络能够较好预测海杂波幅度和相位序列的变化趋势。海杂波幅度序列在几十毫秒到几秒的时间内是可预测的,背后的原因在于海杂波纹理具有较长的相干时间,在相干时间内海杂波时间序列是有一定的关联性的。图 4.14(c)和(d)是目标所在单元雷达回波幅度和相位的预测结果。可以看到,训练的神经网络难以准确预测雷达目标回波的幅度和相位变化,主要原因在于高 SCR 情况下目标回波幅度、相位序列的演化并不符合海杂波幅度、相位演化的规律。

图 4.15 是在低 SCR 下杂波单元和目标单元的幅度和相位预测结果。图 4.15(a)和(b)是 0.5s 的纯海杂波序列的预测情况,图 4.15(c)和(d)是目标所在单元雷达回波幅度和相位的预测结果。可以看到:训练的神经网络不仅能够较好预测海杂波幅度和相位序列的变化趋势,也能准确预测雷达回波的幅度和相位变化,主要原因在于当 SCR 很低时,目标与杂波非常相似,含目标回波大部分也被滤除,使用非相干检测这种主要与幅度有关的检测方法,不能完成有效的检测。




图4.15 SCR 较低时海杂波和含目标回波的幅度相位预测对比图

在高信杂比数据中,所提出的基于时变自适应 MTI 滤波、幅度-相位双 LSTM 预测的非相干累积检测方法,对杂波的抑制效果较好,检测能力相比传统非相干累积的检测方法和其它基于幅度的特征检测方法提升很多。原因在于经过双重杂波抑制之后目标特征更加凸显,使得目标和杂波能够轻易区分,提升了后续非相干累积检测的检测性能。而在低信杂比数据中,目标回波与海杂波之间的幅度特征差异不大,导致低信杂比下目标检测性能较差。

4.5 本章小结

本章针对海杂波背景下小目标检测的难题,探讨了多种基于神经网络或自适应滤波的杂波抑制方法,并提出了一种基于时变自适应 MTI 滤波与幅度-相位双 LSTM 神经网络预测级联的海杂波抑制方法。首先对探讨的多种基于神经网络或自适应滤波的杂波抑制方法进行分析,基于神经网络的预测需要大量的数据,在数据不足的情况下使用幅度这一单一神经网络进行滤波很难将杂波完全滤除。而基于雷达复序列预测的检测方法虽能利用相位信息,但是非线性滤波后的目标回波和海杂波已经不再符合加性模型,目标回波的相位序列已经发生复杂变化,这导致传统多普勒域 CFAR 处理无法使用。时变自适应 MTI 滤波与非相干累积级联的目标检测方法利用海杂波时间序列的短时平稳性,通过时变自适应滤波有效抑制线性杂波。

对于本章提出的基于 MTI 滤波与幅度-相位双 LSTM 神经网络预测级联的杂波抑

制方法采用 IPIX 实测雷达数据集进行实验,实验结果表明,在高信杂比数据中,本方法的检测能力相比传统分形方法、时变自适应 MTI 滤波与传统非相干累积级联方法和基于一致性因子检验方法检测效果更好,但是在几组低信杂比数据中本方法的检测效果不佳。然后我们采用两组不同信杂比数据对提出的方法的检测效果对信杂比的依赖性进行分析,结果表明,在高信杂比下,训练的幅度和相位神经网络能够较好预测海杂波幅度和相位序列的变化趋势,而难以准确预测雷达目标回波的幅度和相位变化。而在低信杂比下,训练的神经网络对杂波和目标回波的预测都很准确,主要原因在于当 SCR 很低时,目标与杂波非常相似,含目标回波大部分也被滤除,使用非相干检测这种主要与幅度有关的检测方法,不能完成有效的检测。综上,本章提出的杂波抑制方法的检测结果和信杂比是高度依赖的,当目标回波的信杂比不低时,提出的海杂波抑制和目标检测方法能够获得更好的检测性能。

第五章 总结与展望

5.1 总结

海杂波的精细化建模和准确的参数估计是实现海杂波背景下目标检测的重要前提。由于实际雷达回波数据中不可避免的混有噪声，对于含噪声的海杂波数据建模， K -分布杂波加噪声是常用的模型之一， $K+N$ 分布模型已有的矩估计方法存在估计性能差，对含异常样本数据估计稳健性差的问题。本论文针对 $K+N$ 分布模型现有参数估计方法中存在的问题，提出一种利用多样本分位点和截断矩的基于 GRNN 的稳健参数估计方法。海杂波抑制是后续进行海面目标检测的重要环节，本论文提出结合传统时变自适应 MTI 滤波与幅度-相位双 LSTM 神经网络预测级联的海杂波抑制方法对海杂波进行抑制。原有的基于神经网络的方法仅考虑对海杂波幅度序列进行抑制，而不能实现针对相位序列或者复序列的有效抑制。所提出的方法创新性的添加了相位预测以达到对海杂波复序列的抑制，并且将传统海杂波抑制方法和新型深度学习方法进行连接，提高了海杂波抑制效果，由此改善了目标检测性能。

下面按照章节归纳本论文完成的工作：

第一章对首先阐述本论文研究基于神经网络的海杂波模型参数估计方法及海杂波抑制方法的研究背景及意义，然后对目前在海杂波模型参数估计以及海杂波抑制方法等方向取得的研究成果进行简要总结，最后是本论文的各章节主要内容与工作安排。

第二章介绍海杂波复合高斯模型基本理论、模型的参数估计方法以及几种常见的神经网络。首先对复合高斯模型的基本框架进行介绍，然后介绍了四种双参数分布模型的数学形式，并对不同模型的已有参数估计方法进行回顾。最后介绍了几种神经网络，为本论文基于神经网络提出的海杂波模型参数估计方法以及海杂波抑制方法奠定理论基础。

第三章针对 $K+N$ 分布模型已有的参数估计方法精度较低并且对异常样本不具有稳健性的问题，提出了利用多样本分位点和截断矩的基于 GRNN 的稳健参数估计方法，首先对 $K+N$ 分布模型进行简要介绍，然后证明了在固定杂噪比的情况下， $K+N$ 分布中分位点比和截断矩比与噪声功率无关、只和杂噪比有关的特性。基于此生成分位点和截断矩比值向量作为网络训练数据输入 GRNN 模型进行网络训练，基于理论产生的分位点比和截断矩比数据验证了 GRNN 模型作为形状参数、杂噪比和比值向量之间反函数的有效性。最后，通过仿真实验和实测数据对提出方法的有效性和稳健性进行检验，结果表明，提出的参数估计方法的性能较已有的方法有较大的提升，并且在有异常样本的情况下，可以实现稳健的参数估计，具有较强的应用价值。

第四章提出了基于时变自适应 MTI 滤波、幅度-相位双 LSTM 神经网络预测级联的杂波抑制方法。首先,针对实测数据样本不足的问题,采用滑窗式数据处理增加训练样本的数量。低阶的 MTI 滤波实现了第一级的海杂波抑制。MTI 滤波后的时间序列分解为幅度和相位序列,利用纯杂波单元分别训练幅度和相位的 LSTM 神经网络预测模型,然后利用该模型对待检测单元进行预测以达到杂波抑制的效果。待检测单元的预测误差用来构造目标检测的检验统计量。IPIX 实测雷达数据集的实验结果表明,当目标回波的信杂比不太低时,提出的海杂波抑制和目标检测方法能够获得更好的检测性能。

5.2 展望

本论文开展了基于神经网络的海杂波模型参数估计和海杂波抑制方法研究。分别提出 K+N 模型的基于 GRNN 的稳健参数估计方法以及基于时变自适应 MTI 滤波与幅度-相位双 LSTM 网络预测级联的海杂波抑制方法。并通过实验分别对所提方法的性能进行了验证。由于在实际应用中,海杂波模型的参数估计与杂波抑制方法具有较大的研究价值,已有的方法仍然具有较大的研究与改进空间。基于已有的研究工作,海杂波模型参数估计和抑制方法存在以下可以探索的方面:

1. 开发噪声背景下其它海杂波模型的稳健参数估计方法:在噪声背景下, K+N、GP+N、CGIG+N 以及 CGLN+N 分布模型基本能够覆盖微波段雷达不同条件下海杂波数据幅度、强度分布的准确拟合,目前对 GP+N、CGIG+N 以及 CGLN+N 模型的参数估计方法研究很少,特别是抗异常样本的稳健估计方法依然缺乏相关的研究。现有的模型参数估计方法仍存在估计效果差或稳健性差等问题。因此,未来的研究可着重于开发这些模型的稳健参数估计方法。

2. 优化神经网络模型:在参数估计中的 GRNN 模型结构简单,参数量较小,模型深度较低,所以寻找能更精确训练的非线性神经网络模型应该能够提升参数估计精度。在杂波抑制中,尽管 LSTM 网络对时间序列的预测比较准确,但仍有多个方向值得探索,在未来的研究中,可以采用更加复杂的网络结构,如多层深度 LSTM 网络或结合卷积神经网络模型,以进一步提升模型在复杂海面环境下对海杂波的预测能力。

3. 提高低信杂比下目标检测能力:虽然本文提出的方法在信杂比不低时目标检测能力有所提升,但是当信杂比较低时,其检测效果仍存在较大的提升空间。可以在后续检测中尝试使用能充分利用相位信息的检测方法,提高检测性能。可以在第一次时变自适应 MTI 滤波器中选择更高阶的 MTI 滤波器,高阶的时变自适应 MTI 滤波器可能进一步改善滤波性能。还可以利用 Transformer 或注意力机制增强网络对微弱目标的关注能力,使其在低信杂比下仍能有效提取目标特征。

参考文献

- [1] 吴蔚. 构建海洋命运共同体的法治路径[J]. 国际问题研究, 2021(02): 102-113.
- [2] 丁鹭飞, 耿富录编著. 雷达原理[M]. 西安: 西安电子科技大学出版社, 2002.
- [3] SHUI P L, LIU M, XU S W. Shape-parameter-dependent coherent radar target detection in K-distributed clutter[J]. IEEE Transactions on Aerospace and Electronic Systems, 2016, 52(1): 451-465.
- [4] WARD K D, BAKER C J, WATTS S. Maritime surveillance radar. Part 1: Radar scattering from the ocean surface[J]. IEE Proceedings F-Radar and Signal Processing, 1990, 137(2): 51-62.
- [5] CONTE E, MAIO A D, GALDI C. Statistical analysis of real clutter at different range resolutions[J]. IEEE Transactions on Aerospace and Electronic Systems, 2004, 40(3): 903-918.
- [6] TRUNK G V, GEORGE S F. Detection of targets in non-Gaussian sea clutter[J]. IEEE Transactions on Aerospace and Electronic Systems, 1970, 6(5): 620-628.
- [7] SEKINE M, OHTANI S, MUSHA T, et al. Weibull-distributed ground clutter[J]. IEEE Transactions on Aerospace and Electronic Systems, 1981, 17(4): 596-598.
- [8] WARD K D, TOUGH R, WATTS S. Sea Clutter: Scattering, the K distribution and radar performance[M]. 2nd edn., United Kingdom: Institute of Engineering Technology, 2013: 101-134.
- [9] BALLERI A, NEHORAI A, WANG J. Maximum likelihood estimation for compound-Gaussian clutter with inverse gamma texture[J]. IEEE Transactions on Aerospace and Electronic Systems, 2007, 43(2): 775-779.
- [10] FARSHCHIAN M, POSNER F L. The Pareto distribution for low grazing angle and high resolution X-band sea clutter[C]. 2010 IEEE Radar Conference, 2010: 789-793.
- [11] OLLILA E, TYLER D E, KOIVUNEN V, et al. Compound-Gaussian clutter modeling with an inverse Gaussian texture distribution[J]. IEEE Signal Processing Letters, 2012, 19(12): 876-879.
- [12] CARRETERO MOYA J, GISMERO MENOYO J, BLANCO DEL CAMPO Á., et al. Statistical analysis of a high-resolution sea-clutter database[J]. IEEE Transactions on Geoscience and Remote Sensing, 2010, 48(4): 2024-2037.
- [13] CHALABI I, MEZACHE A. Estimating the K-distribution parameters based on fractional negative moments[C]. 2015 IEEE 12th International Multi-Conference on Systems, Signals & Devices, 2015: 1-5.
- [14] CHALABI I, MEZACHE A. Estimators of compound Gaussian clutter with log-normal texture[J]. Remote Sensing Letters, 2019, 10: 709-716.
- [15] ISKANDER D R, ZOUBIR A M. Estimation of the parameters of the K-distribution using higher

- order and fractional moments[J]. IEEE Transactions on Aerospace and Electronic Systems, 1999, 35(4): 1453-1457.
- [16] MEZACHE A, BENTOUMI A, SAHED M. Parameter estimation for compound-Gaussian clutter with inverse-Gaussian texture[J]. IET Radar, Sonar & Navigation, 2017, 11: 586-596.
- [17] SHUI P L, YU H, HUANG Y. Low-order moment-based estimation of shape parameter of CGIG clutter model[J]. Electronics Letters, 2016, 52.
- [18] BLACKNELL D, TOUGH R J A. Parameter estimation for the K-distribution based on $[z\log(z)]$ [J]. IET Radar, Sonar & Navigation, 2001, 148(6): 309-312.
- [19] JOUGHIN I R, PERCIVAL D B, WINEBRENNER D P. Maximum likelihood estimation of K distribution parameters for SAR data[J]. IEEE Transactions on Geoscience and Remote Sensing, 1993, 31(5): 989-999.
- [20] FENG T, SHUI P-L. Outlier-robust tri-percentile parameter estimation of compound-Gaussian clutter with lognormal distributed texture[J]. Digital Signal Processing, 2022, 120: 103307.
- [21] SHUI P L, SHI L X, YU H, et al. Iterative maximum likelihood and outlier-robust bipercetile estimation of parameters of compound-Gaussian clutter with inverse Gaussian texture[J]. IEEE Signal Processing Letters, 2016, 23(11): 1572-1576.
- [22] SHUI P L, YU H, SHI L X, et al. Explicit bipercetile parameter estimation of compound-Gaussian clutter with inverse gamma distributed texture[J]. IET Radar, Sonar & Navigation, 2018, 12(2): 202-208.
- [23] YU H, SHUI P L, LU K, et al. Bipercetile parameter estimators of bias reduction for generalised Pareto clutter model[J]. IET Radar, Sonar & Navigation, 2020, 14(7): 1105-1112.
- [24] YU H, SHUI P L, LU K. Outlier-robust tri-percentile parameter estimation of K-distributions[J]. Signal Processing, 2021, 181: 107906.
- [25] SHI S, GAO J, CAO D, et al. Self-learning parameter estimation of K-distributed clutter using GRU network[J]. IEEE Geoscience and Remote Sensing Letters, 2023, 20: 1-5.
- [26] SAHED M, MEZACHE A, LAROUCSI T. A novel $[z\log(z)]$ -based closed form approach to parameter estimation of K-distributed clutter plus noise for radar detection[J]. IEEE Transactions on Aerospace and Electronic Systems, 2015, 51(1): 492-505.
- [27] MEZACHE A, SAHED M, SOLTANI F, et al. Estimation of the K-distributed clutter plus thermal noise parameters using higher order and fractional moments[J]. IEEE Transactions on Aerospace and Electronic Systems, 2015, 51(1): 733-738.
- [28] ROSENBERG L, BOCQUET S. Application of the Pareto plus noise distribution to medium grazing angle sea-clutter[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2015, 8(1): 255-261.

- [29] MEZACHE A, CHALABI I, SOLTANI F, et al. Estimating the Pareto plus noise distribution parameters using non-integer order moments and $[z\log(z)]$ approaches[J]. IET Radar, Sonar & Navigation, 2016, 10(1): 192-204.
- [30] NINGBO L, YUNLONG D, GUOQING W, et al. Sea-detecting X-band radar and data acquisition program[J]. Journal of Radars, 2019, 8(5): 656-667.
- [31] BELHI K, SOLTANI F, MEZACHE A. Iterative maximum likelihood estimation of the compound inverse Gaussian clutter parameters[J]. Electronics Letters 2020, 56(13): 677-678.
- [32] 水鹏朗, 田超, 封天. 逆高斯纹理复合高斯杂波对异常样本稳健的三分位点估计方法[J]. 电子与信息学报, 2023, 45(2): 542-549.
- [33] TIAN C, SHUI P-L. Outlier-robust truncated maximum likelihood parameter estimation of compound-Gaussian clutter with inverse Gaussian texture[J]. Digital Signal Processing, 2022, 14(16): 4004.
- [34] RAGHAVAN R S. A method for estimating parameters of K-distributed clutter[J]. IEEE Transactions on Aerospace and Electronic Systems, 1991, 27(2): 238-246.
- [35] ISKANDER D R, ZOUBIR A M, BOASHASH B. A method for estimating the parameters of the K distribution[J]. IEEE Transactions on Signal Processing, 1999, 47(4): 1147-1151.
- [36] FERNÁNDEZ A, MACHADO JOSÉ RAÚL. Improved shape parameter estimation in K clutter with neural networks and deep learning[J]. Interact. Multim. Artif. Intell., 2016, 3: 96-103.
- [37] SHUI P L, ZOU P J, FENG T. Outlier-robust truncated maximum likelihood parameter estimators of generalized Pareto distributions[J]. Digital Signal Processing, 2022, 127: 103527.
- [38] WATTS S. Radar detection prediction in K-distributed sea clutter and thermal noise[J]. IEEE Transactions on Aerospace and Electronic Systems, 1987, 23: 40-45.
- [39] JOSEPH G. Space-time adaptive processing for radar, Second Edition[M]. Artech, 2014: 1.
- [40] HAYKIN S. Adaptive radar signal processing[M]. 2006: 1-230.
- [41] LEUNG H, LO T. Chaotic radar signal processing over the sea[J]. IEEE Journal of Oceanic Engineering, 1993, 18(3): 287-295.
- [42] GUAN J, LIU N, ZHANG J, et al. Multifractal correlation characteristic for radar detecting low-observable target in sea clutter[J]. Signal Processing, 2010, 90(2): 523-535.
- [43] K APLAN L M, KUO C-C J. Texture roughness analysis and synthesis via extended self-similar (ESS) model[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 1995, 17: 1043-1056.
- [44] HAYKIN S, XIAO BO L. Detection of signals in chaos[J]. Proceedings of the IEEE, 1995, 83(1): 95-122.
- [45] 许述文, 白晓惠, 郭子薰等. 海杂波背景下雷达目标特征检测方法的现状与展望[J]. 雷达

- 学报, 2020, 9(4): 684.
- [46] NAN X, HENRY L, HING C. A multiple-model prediction approach for sea clutter modeling[J]. IEEE Transactions on Geoscience and Remote Sensing, 2003, 41(6): 1491-1502.
- [47] GAO Z, CHEN L. Sea clutter sequences regression prediction based on PSO-GRNN method[C]. 2015 8th International Symposium on Computational Intelligence and Design, 2015: 72-75.
- [48] TOMANDL D, SCHOBEL A. A Modified General Regression Neural Network (MGRNN) with new, efficient training algorithms as a robust ‘black box’-tool for data analysis[J]. Neural Networks, 2001, 14: 1023-1034.
- [49] WANG Y, YANG Z, LIU Q, et al. An input sampling scheme to radar echo extrapolation for RNN-based models[C]. 2022 IEEE Intl Conf on Dependable, Autonomic and Secure Computing, Intl Conf on Pervasive Intelligence and Computing, Intl Conf on Cloud and Big Data Computing, Intl Conf on Cyber Science and Technology Congress (DASC/PiCom/CBDCCom/CyberSciTech), 2022: 1-5.
- [50] SAGAYARAJ M J, JITHESH V, ROSHANI D. Comparative study between deep learning techniques and random forest approach for HRRP based radar target classification[C]. 2021 International Conference on Artificial Intelligence and Smart Systems (ICAIS), 2021: 385-388.
- [51] HOCHREITER S, SCHMIDHUBER J. Long Short-Term Memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [52] WANG M, GUO X, SHE Y, et al. Advancements in deep learning techniques for time series forecasting in maritime applications: a comprehensive review[J]. Information, 2024, 15(8): 507.
- [53] YU J, PAN B, YU Z, et al. Sea Clutter suppression based on chaotic prediction model by combining the generator and Long Short-Term Memory Networks[J]. Remote Sensing, 2024, 16(7): 1260.
- [54] ZHAO J, WU J, GUO X, et al. Prediction of radar sea clutter based on LSTM[J]. Journal of Ambient Intelligence and Humanized Computing, 2023, 14(11): 15419-15426.
- [55] MA L, WU J, ZHANG J, et al. Sea clutter amplitude prediction using a Long Short-Term Memory neural network[J]. Remote Sensing, 2019, 11(23): 2826.
- [56] CHEN V C, HAO L. Joint time-frequency analysis for radar signal and image processing[J]. IEEE Signal Processing Magazine, 1999, 16(2): 81-93.
- [57] CONTE E, LONGO M. Characterisation of radar clutter as a spherically invariant random process[J]. Remote Sensing Letters, 1987, 134(2): 191-197.
- [58] JAKEMAN E, PUSEY P. A model for non-Rayleigh sea echo[J]. IEEE Transactions on Antennas and Propagation, 1976, 24(6): 806-814.
- [59] OANCEA B, ANDREI T, PIRJOL D. Income inequality in Romania: The exponential-Pareto distribution[J]. Physica A: Statistical Mechanics and its Applications, 2017, 469: 486-498.

- [60] MEZACHE A, SOLTANI F, SAHED M, et al. Model for non-Rayleigh clutter amplitudes using compound inverse gaussian distribution: an experimental analysis[J]. IEEE Transactions on Aerospace and Electronic Systems, 2015, 51(1): 142-153.
- [61] MEZACHE A, BENTOUMI A, SAHED M. Parameter estimation for compound-Gaussian clutter with inverse-Gaussian texture[J]. IET Radar, Sonar & Navigation, 2017, 11(4): 586-596.
- [62] CESLIE J R. The inverse Gaussian distribution: theory, methodology, and applications[J]. Journal of the Royal Statistical Society Series C: Applied Statistics, 1990, 39(2): 259-260.
- [63] SHI S N, SHUI P L, LIU M, et al. Subband adaptive coherent detection of weak moving targets in K-distributed sea clutter[C]. 2016 CIE International Conference on Radar, 2016: 1-4.
- [64] SANGSTON K J, GINI F, GRECO M S. Coherent radar target detection in heavy-tailed compound-Gaussian clutter[J]. IEEE Transactions on Aerospace and Electronic Systems, 2012, 48(1): 64-77.
- [65] XU S W, WANG L, SHUI P L, et al. Iterative maximum likelihood and zFlogz estimation of parameters of compound-Gaussian clutter with inverse gamma texture[C]. 2018 IEEE International Conference on Signal Processing, Communications and Computing, 2018: 1-6.
- [66] YU H, SHUI P L, HUANG Y T. Low-order moment-based estimation of shape parameter of CGIG clutter model[J]. Electronics Letters, 2016, 52(18): 1561-1563.
- [67] JIANG R. Using the integrated neural network of radial basis function (RBF) via optimization algorithms to estimate pile settlement range[J]. Journal of Intelligent & Fuzzy Systems, 2022, 43(5): 6683-6695.
- [68] SPECHT D F. A general regression neural network[J]. IEEE Transactions on Neural Networks, 1991, 2(6): 568-576.
- [69] XUE J, SUN M, LIU J, et al. Shape parameter estimation of K-distributed sea clutter using neural network and multisample percentile in radar industry[J]. IEEE Transactions on Industrial Informatics, 2023, 19(6): 7602-7612.
- [70] SHUI P L, SHI X F, LI X, et al. GRNN-Based predictors of UHF-band sea clutter reflectivity at low grazing angle[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19: 1-5.
- [71] Cognitive Systems Laboratory, McMaster University, Canada. The IPIX radar database[OL]. <http://soma.mcmaster.ca/ipix.php>. 2012.10.11.
- [72] PAL S K, MITRA S. Multilayer perceptron, fuzzy sets, and classification[J]. IEEE Transactions on Neural Networks, 1992, 3(5): 683-697.
- [73] BOUGHRARA H, CHTOUROU M, AMAR C B, et al. MLP neural network using modified constructive training algorithm: Application to face recognition[C]. International Image Processing, Applications and Systems Conference, 2014: 1-6.

- [74] JING H, WEN WEN T, JIANBO G. Detection of low observable targets within sea clutter by structure function based multifractal analysis[J]. IEEE Transactions on Antennas and Propagation, 2006, 54(1): 136-143.
- [75] SHI Y L, XIE X Y, LI D C. Range distributed floating target detection in sea clutter via feature-based detector[J]. IEEE Geoscience and Remote Sensing Letters, 2016, 13(12): 1847-1850.



西安电子科技大学
XIDIAN UNIVERSITY

地址：西安市太白南路2号

邮编：710071

网址：www.xidian.edu.cn