

分类号_____ 密级_____
UDC _____ 编号_____



云南师范大学
YUNNAN NORMAL UNIVERSITY

专业硕士研究生 学位论文

论文题目: 复值合成孔径雷达图像
目标识别方法研究

英文题目: Research on Target
Recognition Methods in
Complex-Valued Synthetic
Aperture Radar Images

学 院 _____ 物理与电子信息学院

专业学位类别 _____ 专业硕士

专业学位领域 _____ 电子信息

研究生姓 名 _____ 侯光宇 _____ 学 号 2224090004

导 师 姓 名 _____ 辛志慧 _____ 职 称 _____ 副教授

2025 年 6 月 5 日

摘要

合成孔径雷达（Synthetic Aperture Radar, SAR）是一种具备高分辨率的相干成像雷达系统。与红外、可见光等传统成像技术相比，SAR 能够实现全天时、全天候的工作能力。在传统的 SAR 图像目标识别方法中，主要依赖于人工设计的特征来进行区分。然而，在处理复杂 SAR 图像时，这类技术往往会在预处理和特征提取阶段丢失大量信息，导致流程繁琐且效率低下，存在诸多局限性。近年来，随着深度学习技术的迅速发展，其强大的自动特征提取能力为 SAR 图像目标识别带来了新的突破。深度学习模型可以通过对数据的多层次分析，自主挖掘不同目标的关键属性，从而显著提高目标识别的准确性，有效弥补了传统方法的不足。基于卷积神经网络（CNN）的分类算法已在 SAR 自动目标识别（ATR）领域取得了显著的成功。然而，SAR 图像由于其独特的成像机制而具有特殊的物理散射特性。现有的许多深度学习算法仅利用幅度信息而忽略了相位信息，这可能会牺牲原始复值 SAR 图像中的一些有用信息，从而导致性能不佳。为此，本文基于深度学习开展复值 SAR 图像目标识别的相关研究，其具体内容与研究重点包括：

（1）由于相干散斑噪声的干扰导致目标像素的色散，SAR 图像中的目标可分离性较差，仅仅依靠幅度信息难以实现高精度的目标识别。然而，SAR 图像中蕴含的丰富复值信息为深度学习方法提供了新的研究方向，特别是复值卷积神经网络的应用潜力引起了广泛关注。因此，本文提出了复值残差 Mish 激活和卷积注意模块网络（CRMC-Net）。它有效利用了复值 SAR 数据中的实部和虚部信息，充分挖掘了 SAR 图像的物理散射特征，以提高模型对目标特征的表示能力。通过引入不同大小的卷积核来提取场景中的多尺度信息，进一步增强了目标的特征表示能力。复值残差块（CReLBlock）与复值 Mish（CMish）激活函数的结合，显著增强了模型的特征提取能力和训练过程的稳定性，进一步提高了模型捕捉复杂特征和信息流的效率。最后，构建复值通道和空间注意模块（CCBAM），帮助模型在相干散斑噪声的干扰下更好地区分不同的目标和背景，从而在复杂 SAR 图像中取得更高的识别率。

（2）在深入挖掘 SAR 图像复值特性的基础上，进一步考虑其幅度与相位信息的互补性，可以显著提升目标识别的准确性。当前多数深度学习方法主要集中在

在幅度数据的建模上，往往忽略了相位信息中蕴含的结构特征和散射特性。这种忽略限制了模型的整体表达能力，并可能导致关键信息的丢失。然而，考虑到 SAR 图像的独特性质，幅相型卷积神经网络通过同时利用振幅和相位信息进行训练，理论上能够显著提高分类精度。为了充分利用这两种信息，本文提出了一种基于幅相型 SE 模块、自注意力机制和 GELU 激活函数网络（AP-SSGNet），旨在充分利用 SAR 图像中的幅度和相位信息，以提高目标特征的代表能力和分类精度。首先，引入了 self-attention 机制，增强了模型对全局上下文信息的理解能力，有助于捕捉长距离依赖关系，从而提升特征提取的效果。其次，集成了 SE 模块，该模块可以自适应地重新校准通道间的权重，进一步优化特征表示，增强模型对重要特征的关注度。最后，采用了 GELU 激活函数，相比于传统的 ReLU 等激活函数，GELU 具有更好的非线性拟合能力和平滑特性，有助于缓解梯度消失问题，加速训练过程并提高模型性能。

关键词：合成孔径雷达；深度学习；复值卷积神经网络；相位；目标识别

Abstract

Synthetic Aperture Radar (SAR) is a high-resolution coherent imaging radar system. Compared with traditional imaging technologies such as infrared and visible light, SAR offers all-weather, all-day imaging capabilities. In conventional SAR target recognition methods, classification typically depends on manually designed features. However, when dealing with complex SAR images, such approaches often suffer significant information loss during preprocessing and feature extraction, resulting in cumbersome, inefficient processes with notable limitations. In recent years, the rapid advancement of deep learning has brought transformative breakthroughs to SAR target recognition, owing to its powerful ability to automatically extract features. Deep learning models can autonomously capture key attributes of various targets through multi-level data analysis, significantly improving recognition accuracy and effectively compensating for the limitations of traditional methods. In particular, convolutional neural network (CNN)-based classification algorithms have achieved remarkable success in the field of SAR automatic target recognition (ATR). Nevertheless, due to the unique imaging mechanism of SAR, its images exhibit specific physical scattering characteristics. Many existing deep learning methods focus solely on amplitude information while neglecting phase information. This omission may lead to the loss of valuable information embedded in the original complex-valued SAR data, ultimately compromising model performance. To address this issue, this paper conducts a comprehensive study on complex-valued SAR image target recognition based on deep learning. The key research objectives and contributions include:

(1) Due to the dispersion of target pixels caused by the interference of coherent speckle noise, the separability of targets in SAR images is poor, and it is difficult to achieve high-precision target recognition relying solely on amplitude information. However, the rich complex-valued information contained in SAR images provides a new research direction for deep learning methods, especially the application potential of complex-valued convolutional neural networks has attracted widespread attention.

Therefore, this paper proposes a complex-valued residual Mish activation and convolutional attention module network (CRMC-Net). It effectively utilizes the real and imaginary information in complex-valued SAR data and fully exploits the physical scattering characteristics of SAR images to improve the model's ability to represent target features. By introducing convolution kernels of different sizes to extract multi-scale information in the scene, the feature representation ability of the target is further enhanced. The combination of the complex-valued residual block (CReLBlock) and the complex-valued Mish (CMish) activation function significantly enhances the model's feature extraction ability and the stability of the training process, further improving the model's efficiency in capturing complex features and information flows. Finally, a complex-valued channel and spatial attention module (CCBAM) is constructed to help the model better distinguish different targets and backgrounds under the interference of coherent speckle noise, thereby achieving a higher recognition rate in complex SAR images.

(2) On the basis of deeply exploring the complex-valued characteristics of SAR images, further considering the complementarity of its amplitude and phase information can significantly improve the accuracy of target recognition. Most current deep learning methods focus on the modeling of amplitude data, often ignoring the structural features and scattering characteristics contained in the phase information. This neglect limits the overall expression ability of the model and may lead to the loss of key information. However, considering the unique properties of SAR images, the amplitude-phase convolutional neural network can theoretically significantly improve the classification accuracy by simultaneously using amplitude and phase information for training. In order to make full use of these two types of information, this paper proposes a network based on the amplitude-phase SE module, self-attention mechanism and GELU activation function (AP-SSGNet), which aims to make full use of the amplitude and phase information in SAR images to improve the representation ability and classification accuracy of target features. First, the self-attention mechanism is introduced to enhance the model's ability to understand global context information, which helps to capture long-distance dependencies and thus improve the effect of feature extraction. Second, the SE module is integrated, which can adaptively

recalibrate the weights between channels, further optimize feature representation, and enhance the model's attention to important features. Finally, the GELU activation function is used. Compared with traditional activation functions such as ReLU, GELU has better nonlinear fitting ability and smoothness characteristics, which helps to alleviate the gradient vanishing problem, accelerate the training process and improve model performance.

Keywords: Synthetic aperture radar; Deep learning; Complex-valued convolutional neural network; Phase; Target Recognition.

目 录

第 1 章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 传统的目标识别方法.....	3
1.2.2 基于深度学习的目标识别方法.....	5
1.2.3 基于复值 SAR 图像的目标识别方法.....	6
1.3 论文结构安排.....	8
第 2 章 SAR 成像及深度学习基本原理	9
2.1 SAR 图像成像原理.....	9
2.2 卷积神经网络.....	10
2.2.1 卷积层.....	11
2.2.2 池化层.....	12
2.2.3 全连接层.....	13
2.2.4 CNN 关键函数	13
2.3 图像预处理.....	16
2.4 特征提取.....	17
2.5 SAR 图像目标检测识别评价指标和实验设置.....	19
2.6 小结.....	20
第 3 章 基于复值卷积神经网络的 SAR 图像目标识别方法	21
3.1 CRMC-Net 网络结构.....	21
3.1.1 复值卷积块.....	23
3.1.2 复值池化层.....	26
3.1.3 复值全连接层.....	26
3.1.4 复值残差模块.....	26
3.1.5 复值 Mish 激活函数	27
3.1.6 复值通道和空间注意力机制.....	28
3.2 MSTAR 数据集介绍	29
3.3 SAR 图像目标识别结果分析.....	32
3.3.1 训练参数设置.....	32
3.3.2 消融实验.....	32
3.3.3 实验对比分析.....	34
3.3.4 所提方法与实值版本网络的比较分析	38
3.4 小结.....	42
第 4 章 基于幅相型卷积神经网络的 SAR 图像目标识别	43

4.1 AP-SSGNet 网络架构	43
4.1.1 通道注意力机制(Squeeze-and-Excitation,SE)模块.....	45
4.1.2 自注意力机制(Self-Attention).....	47
4.1.3 GELU 激活函数	48
4.2 数据集介绍.....	49
4.3 目标分类结果分析	51
4.3.1 训练参数设置.....	51
4.3.2 消融实验.....	51
4.3.3 与基于 CNN 方法的识别结果对比	52
4.3.4 所提方法与对应幅度网络的比较分析	56
4.4 小结.....	58
第 5 章 总结与展望	59
5.1 全文总结.....	59
5.2 工作展望.....	61
参考文献.....	62

第 1 章 绪论

1.1 研究背景及意义

合成孔径雷达（Synthetic Aperture Radar, SAR）是一种先进的主动微波成像传感器，具备高分辨率的相干成像能力^[1]。相较于传统的红外线和可见光成像技术，SAR 能够在任何时间、恶劣天气和夜间条件下进行观测，捕捉地球表面的丰富信息^[2]。其独特的微波成像机制使其能够穿透植被或沙土覆盖的目标，展现出显著优势。SAR 系统通常搭载于飞机、卫星、无人机或导弹等平台，克服了光学和红外系统的局限性，适用于复杂环境下的大区域检测^[3]。因此，SAR 技术在诸多领域均展现出了广泛的应用前景与重要价值，涵盖了农业、海洋研究、林业管理、物种识别以及检测等多个方面。无论是在民用范畴还是军事应用上，SAR 技术均显示出较高的研究价值与实际应用潜力^[4-5]。

随着 SAR 技术的持续进步，其性能日益提升，应用领域也在不断拓展。然而，在实际部署和使用过程中，仍然存在诸多具有挑战性的问题。John Mills 在研究报告中指出，美国通过 SAR 系统采集的大量图像数据中，有超过 50% 的原始数据因未经过必要的处理，难以被直接应用于后续任务分析^[6]。这一现象的主要原因包括以下几个方面：（1）SAR 图像与光学图像存在显著差异。光学图像基于可见光及部分红外波段，记录多波段灰度信息，为特征提取和目标识别提供了便利。然而，SAR 传感器的工作频率局限于微波波段，且所采集的回波数据通常以二进制复数的格式表示，并且仅涵盖单一频段的信息内容，每个像素包含振幅和相位信息。由于 SAR 图像的振幅信息受目标对雷达信号的响应影响较大，其成像质量与光学图像存在差距，导致相同目标在两种图像中的信息特性截然不同。这种差异使得 SAR 图像解译变得极为困难。（2）SAR 图像通常伴随着显著的相干性散斑噪声，其产生主要源于 SAR 特有的成像机制。这类噪声在图像中不可避免地掩盖了物体的边缘特征与细节纹理，从而在很大程度上加大了图像分割、目标检测以及识别任务的复杂性^[7]。（3）SAR 系统在运行过程中会持续生成海量影像数据，若缺乏高效的处理与管理机制，这些信息往往难以实现充分挖掘与应用。面对如此庞大的数据体量，传统的目标识别方法在计算能力与泛化性能方面均表现出一定的局限性，这也是当前 SAR 图像目标识别技术进展缓慢的

重要制约因素之一。

在早期阶段，SAR 图像的解译工作主要依靠人工判读完成。研究人员通常借助自身的专业知识与经验，从图像中分析提取目标的方位、尺度、灰度及姿态等特征。然而，这种方式不仅存在较强的主观性，影响信息提取的准确性，而且处理效率低，难以适应当前对海量数据的处理需求^[8-11]。在此背景下，SAR 图像解译逐步朝着自动化方向演进，促使 SAR 自动目标识别（Automatic Target Recognition, ATR）技术应运而生。SAR-ATR 系统可在无需人工干预的情况下，对图像中是否存在目标及其类型进行判别，并通过机器学习、模型识别等方法实现目标的自动分类^[12]。

近年来，深度学习（Deep Learning, DL）作为一种新兴的机器学习方向，凭借其强大的学习能力，在人脸识别、图像与文字识别、智能监控以及语音识别等领域取得了显著成果^[13]。深度学习通过构建多层神经网络模型，逐层对输入数据进行特征提取与变换，从而自动从简单特征中提取复杂特征，最终实现高效权重学习。其中，深度置信网络（Deep Belief Network, DBN）^[14]、稀疏自动编码器（Sparse Automatic Encoder, SAE）^[15]和卷积神经网络（Convolutional Neural Network, CNN）^[16]是特征提取过程中最具代表性的深度学习算法模型。特别是在图像处理领域，CNN 表现出优异的效果，已成为目标识别的核心算法之一。将深度学习方法引入 SAR 图像目标识别领域，不仅解决了传统方法在处理海量数据时的局限性，还推动了 SAR-ATR 技术的快速发展。这一技术突破使 SAR 图像识别与最新人工智能成果深度融合，在军事和民用领域展现出更加广阔的应用前景^[17-18]。未来，随着算法优化和硬件性能的提升，SAR 图像目标识别技术有望进一步提高精度和效率，为科学研究和社会发展提供更有力的支持。

1.2 国内外研究现状

合成孔径雷达(SAR)的概念最早可追溯至 20 世纪 50 年代,由美国 Goodyear 宇航公司的 Carl Wiley 首次提出“合成孔径”概念,为 SAR 系统的发展奠定了理论基础^[19]。此后,凭借其独特的成像能力和广泛应用潜力,各国相继投入到 SAR 系统的研发中,并诞生了一系列高性能的机载或星载 SAR 系统。例如,意大利的 COSMO-SkyMed 卫星、加拿大的 RADARSAT-2 卫星以及我国的高分三号卫星等,均实现了米级高分辨率成像能力。目前,先进的机载 SAR 系统空间分辨

率已达到 0.1-1 米，具备大面积观测及目标自动检测的能力。

自 1953 年世界上第一张 SAR 图像诞生以来，SAR 图像分辨率不断提高，基于 SAR 的图像处理技术也从简单的去噪发展到复杂的目标检测与识别。MIT 林肯实验室是最早开展 SAR-ATR 技术研究的机构之一。随后，国外从事目标检测与识别研究的机构逐渐增多，包括美国 MBVLAB、加拿大遥感中心和斯坦福大学等。由于 SAR 数据源的限制，国内对 SAR-ATR 技术的研究起步稍晚，但如今众多高校和研究机构已积极投身于该领域的研究^[20-23]。

在 SAR 图像目标识别技术的发展过程中，公开数据集起到了至关重要的推动作用。1994 年，美国推出的 MSTAR 数据集标志着该领域的一个重要里程碑。MSTAR 专为 SAR 图像目标识别设计，通过高分辨率 SAR 传感器捕获地面军事目标（如坦克、装甲车、导弹发射装置）的多角度、多方位成像数据，同时融入部分遮挡、伪装及复杂背景干扰等真实场景，为研究者提供了全面且标准化的实验资源。MSTAR 数据集因其多样性和贴近实际应用的特点，成为验证和优化 SAR 图像目标识别算法的关键基准，广泛应用于传统特征提取方法及深度学习技术的性能评估^[24]。随着 SAR 技术的持续进步，针对特定应用场景的数据集不断涌现。2023 年发布的 OpenSARship2.0 (OPS2.0) 数据集，作为 SAR 舰船监测和识别领域的最新成果，由多国研究机构合作构建，展现了全球多海域的高分辨率 SAR 图像，覆盖不同分辨率、极化方式及海况条件，特别增加了夜间与恶劣天气下的样本，显著增强了模型在复杂环境下的泛化能力^[25]。OPS2.0 不仅大幅扩充样本量，还优化了标注精度，提供像素级目标边界框和语义分割标签，支持细粒度目标分析。数据集涵盖从小型渔船到大型货轮的多种舰船类型，每种类型均展现丰富的姿态变化和尺度差异，充分模拟了实际应用场景的复杂性，成为当前 SAR 舰船检测和识别领域最具挑战性和代表性的公开数据集，为传统与深度学习方法的研究提供了坚实基础。

1.2.1 传统的目标识别方法

传统方法一般包括基于模板匹配的方法、基于模型的方法和基于机器学习的方法。模板匹配技术，作为模式识别领域的一项基础性方法，其核心机制在于预先构建一系列模板，并将这些模板与目标图像中的特定感兴趣区域（ROI）进行逐一对比分析。这一匹配过程的核心在于计算模板与 ROI 之间的相似度度量，

这些度量指标包括但不限于相关系数和均方误差等,它们为评估模板与目标图像之间的匹配程度提供了量化依据。通过遍历所有潜在的匹配位置,并选取相似度最高的模板,即可确定目标所属的类别,从而实现分类目的。这一方法因其直观性和易于理解的特点而广受关注^[26-27]。然而,模板匹配技术也存在不容忽视的局限性。由于需要对所有潜在位置进行全面搜索和匹配,这一过程计算成本高昂,处理效率低下。此外,为了有效应对目标可能存在的变形、旋转以及尺度变化等问题,通常需要基于大量样本生成涵盖不同角度和尺度的模板库,这无疑进一步增加了计算的复杂性和资源消耗。在实际应用中,特别是在 SAR 图像识别任务中,由于 SAR 图像固有的特殊性,如噪声干扰、几何失真以及复杂的背景信息等,模板匹配方法的实现变得尤为困难,其性能往往受到严重制约。

相较于模板匹配技术,基于模型的方法则更加注重于通过构建物理模型和概念模型来实现目标的识别^[28]。这类方法通过深入理解和模拟目标的物理特性和行为模式,展现出了强大的鲁棒性和适应性。它们能够有效应对目标姿态和配置的变化,同时提取出复杂的特征信息,从而提高识别的准确性和可靠性。然而,基于模型的方法也面临着一些挑战。模型构建和特征提取过程的复杂性较高,需要丰富的专业知识和计算资源支持。此外,对于 SAR 图像识别而言,由于 SAR 图像的复杂性和特殊性,模型构建的难度进一步加大,限制了这类方法在 SAR 识别领域的广泛应用。

近年来,机器学习方法,特别是深度学习的兴起,为 SAR 图像识别提供了新的解决思路和途径。这类方法通过从 SAR 图像中自动提取特征,并利用先进的算法进行训练和分类,实现了识别和分类的自动化和智能化^[29-30]。在机器学习方法中,设计合适的特征提取器成为了一项关键任务。特征提取器的性能直接影响到后续分类的准确性和效率。然而,机器学习方法的实施同样面临着诸多挑战。首先,需要大量高质量的标记数据来训练模型,这对于 SAR 图像识别而言是一个巨大的挑战。其次,高昂的计算资源消耗也是制约机器学习方法广泛应用的一个重要因素。此外,深厚的专业知识储备也是实施机器学习方法不可或缺的条件之一。传统的 SAR 识别方法主要依赖于人工设计的特征进行识别和分类。这些特征通常基于领域知识和经验进行选取和优化。然而,在处理复杂的 SAR 图像时,由于图像中的噪声、杂波以及目标间的相互遮挡等因素的干扰和影响,人工设计的特征往往难以达到最佳的识别效果。此外,传统的预处理和特征提取步骤可能会丢失一些关键信息,从而进一步限制了识别性能的提升和优化空间。

1.2.2 基于深度学习的目标识别方法

近年来,深度学习理论的迅猛发展为计算机视觉领域带来了革命性的突破,其中卷积神经网络作为深度学习的核心架构之一,在图像分类任务中展现出了前所未有的优势^[31-33]。特别是在 SAR 图像分类领域,深度学习方法凭借其强大的自动特征提取能力,已成为主流的技术趋势,推动了智能信息提取技术的发展^[34, 35]。与传统的图像分类算法相比,后者通常需要依赖手工设计特征并结合复杂的物理模型来完成分类任务,而深度学习方法能够从原始数据中自动提取高层次的抽象特征,无需人工干预,从而极大地简化了特征提取过程。这一特性使得深度学习在性能上超越传统方法,成为 SAR 图像分类领域的全新标杆^[36, 37]。Hinton 等人在文献[38]中首次系统性地提出了深度学习的概念,并强调了 CNN 在自动特征提取中的核心地位,为后续的研究奠定了坚实的理论基础。

众多研究表明,基于深度神经网络的方法在各类 SAR 目标识别任务中均取得了令人瞩目的性能。例如,文献[39]提出了一种创新的基于多核大小特征融合 (Multi-Kernel Size Feature Fusion Convolutional Neural Network, MKSFF-CNN) 的 SAR 目标分类模型。该模型通过融合不同尺寸卷积核提取的特征,有效提升了模型的泛化能力,在对十类目标的 MSTAR 数据集进行分类时,准确率高达 97.44%。此外,Chen 等人在文献[40]中设计了一种完全卷积网络 (A-ConvNets),通过优化网络结构进一步提高了识别任务的准确率,充分展现了深度学习方法在 SAR 图像分类中的巨大潜力。为了应对小样本 SAR 目标分类的挑战,文献[41]提出了一种新颖的基于全局和局部描述子的度量网络 (Global and Local Descriptor Metric Network, GLMnet)。该网络通过结合全局和局部特征,有效提升了小样本条件下的分类性能。同时,文献[42]提出了一种基于多层自编码器 (Autoencoder) 和超像素分割 (Superpixel Segmentation) 的方法。该方法首先利用自编码器学习图像的低维表示,然后结合超像素技术进行图像分割,显著提高了图像分类的准确率以及不同类别之间的区分度。文献[43]的研究表明,ResNet18 模型在 MSTAR 数据集上取得了 99% 的整体分类准确率,再次验证了深度学习方法在 SAR 图像分类中的卓越性能。为了解决跨域分类问题,文献[44]提出了一种名为渐进原型细化 (Progressive Prototype Refinement, PPR) 的方法。该方法通过逐步细化目标域的原型表示,显著提升了跨域分类的性能,为多目标域自适应问题提供了新的解决方案。为了进一步提升深度学习在 SAR 目标识别

中的性能, 研究人员不断探索新型网络架构。例如, Wang 等人在文献[45]中提出了一种改进的 GoogLeNet 结构网络, 通过优化网络架构和参数设置, 取得 99.72% 的识别结果进一步提升了模型的识别性能。此外, 文献[46]提出了一种由多尺度局部分类网络 (Multi-Scale Local Classification Network, MLC-Net) 和特征生成与校准网络 (Feature Generation and Calibration Network, FGC-Net) 组成的 LcFGC 框架。该框架通过多尺度特征提取和特征校准机制, 有效解决了小样本 SAR 目标分类中的关键问题, 为 SAR 图像分类领域提供了新的研究方向和思路。

1.2.3 基于复值 SAR 图像的目标识别方法

尽管基于深度学习的方法在 SAR 图像分类任务中表现出色, 但这些方法主要依赖于仅使用幅度信息而忽略相位信息的实值网络, 这一局限性显著限制了其取得最佳识别结果的能力。当前大多数深度学习模型的核心结构是基于实值表示的, 这意味着它们在处理 SAR 图像时通常将数据的幅度信息作为输入, 而忽略了相位信息的利用^[47-49]。然而, 相位信息是 SAR 图像的重要特征之一, 在许多 SAR 应用中扮演着关键角色^[50, 51]。具体而言, 相位信息能够提供关于物体材质、形状边界以及表面粗糙度等细节的关键线索, 而幅度信息则主要用于编码能量分布, 反映物体对电磁波的反射强度^[52, 53]。因此, 单纯依靠幅度信息难以全面捕捉目标的复杂特性, 从而可能导致分类性能的不足。

为了解决这一问题, 复值卷积神经网络 (Complex-Valued Convolutional Neural Network, CVCNN) 被引入到 SAR 图像分类领域。CVCNN 的核心优势在于能够同时利用幅度和相位信息, 从而显著提升分类性能^[54-56]。为了有效挖掘 SAR 目标中的相位信息, 文献[57, 58]对 CVCNN 的数学原理进行了深入分析, 揭示了复值网络在处理 SAR 数据时的独特能力。近年来, 多项研究表明, 相位信息在 SAR 图像分类中的重要性不仅体现在其性能优于单纯的幅度信息, 还体现在其在极化 SAR (Polarimetric SAR, PolSAR) 图像分类中的特殊作用。相位信息对于区分 PolSAR 图像中不同类型的散射体具有显著价值, 这促使研究者积极探索将 CVCNN 应用于 PolSAR 图像分类。在 PolSAR 图像分类领域, 复值网络展现出了卓越的性能。例如, 文献[59]提出了一种基于 CVCNN 的 PolSAR 图像地形分类方法, 该方法通过充分利用相位信息显著降低了分类错误率。文献[60]构建了一个多尺度深度 Contourlet 滤波器组, 结合相位和幅度信息实现了高效的

PolSAR 图像分类。此外，曹等人在文献[61]中设计了一种完全卷积神经网络（Fully Convolutional Neural Network, FCNN），并在基于 PolSAR 数据集的实验中取得了令人满意的分类结果，进一步验证了复值网络在极化信息处理中的潜力。

除了 PolSAR 图像分类，复值网络在 SAR-ATR 领域也取得了显著进展。文献[62]提出了一种用于单通道 SAR 图像目标识别的复值 CNN，该方法通过整合幅度和相位信息提升了目标识别的准确性。文献[63]进一步提出了一种改进的 CVCNN，在 MSTAR 数据集上的实验表明，其识别率达到 98.97%，显著优于许多传统的实值 CNN 算法。此外，文献[64]提出了一种新的复值全卷积神经网络（Complex-Valued Fully Convolutional Neural Network, CV-FCNN），通过用卷积层替代池化层和全连接层，进一步优化了网络结构。实验结果表明，CV-FCNN 在目标识别任务中表现优于传统的 CVCNN，展现了更高的效率和鲁棒性。为了进一步提升 SAR 图像中固有的复值信息利用率，文献[65]开发了一种多流复值网络（Multi-Stream Complex-Valued Networks, MS-CVNets）。该方法通过多路径特征提取机制有效增强了网络的表达能力，并在 MSTAR 数据集上取得了 99.79% 的分类性能。文献[66]提出了一种基于复值网络的 SAR 图像目标检测方法（Complex-Valued SAR Detection, CV-SAR-Det），通过充分利用相位信息显著提高了目标检测的精度。此外，文献[67]中 Wang 等人提出了一种子孔径分解引导的复值网络（Complex-Valued Guided Subaperture Network, CGS-net），该方法通过结合子孔径分解技术与复值网络的优势，有效提升了相位信息的利用效率。最新的研究成果[68-70]进一步验证了 SAR 图像中相位信息的重要性及其在实际应用中的可行性。一种幅相型卷积神经网络（AP-CNN）在文献[71]被提出，在 MSTAR 数据集达到了 99.64% 的目标识别效果。在文献[72]中提出了一种改进网络的复值 SAR 图像舰船目标识别方法和在文献[73]中提出的一种基于多流形特征融合（MMFF）深度学习框架，进一步体现出了利用复值 SAR 图像的优越性，为后续复数信息研究提供参考和思路。

这些研究表明，复值网络不仅能够更好地捕捉 SAR 图像的内在特性，还在小样本条件下表现出更强的泛化能力。未来的研究将进一步探索复值网络在 SAR 图像分类与目标识别中的潜力，包括网络架构优化、训练策略改进以及跨域自适应能力的提升。通过充分挖掘 SAR 图像中的复值信息，有望实现更高精度的目标检测与分类，为军事侦察、灾害监测及民用领域提供更强大的技术支持。

1.3 论文结构安排

随着 SAR 图像处理技术的持续发展,传统方法在图像预处理与特征提取过程中,常常面临信息丢失严重以及特征提取能力不足等问题,难以满足高精度目标识别任务的需求。尤其是在处理复值 SAR 图像时,传统实值网络仅利用幅度信息,无法有效捕捉相位等复值信息,进一步限制了模型性能的提升。本文结合深度学习从图像分类和复值信息两个方面优化网络模型。本文主要提出了复值残差 Mish 激活和卷积注意模块网络(CRMC-Net)和基于幅相型 SE 模块、自注意力机制和 GELU 激活函数网络(AP-SSGNet)。具体的论文结构安排如下:

第1章:绪论。首先介绍了 SAR 图像目标识别的研究背景及意义,然后梳理总结了传统方法、深度学习以及利用复值 SAR 图像信息的卷积神经网络三个方面的国内外研究现状,最后说明本文结构安排。

第2章:SAR 成像及深度学习基本原理。本章首先介绍 SAR 图像的成像原理,其次对 CNN 的基本原理进行介绍,接着介绍图像预处理和特征提取过程,最后介绍了本文实验结果的评价指标。

第3章:基于复值卷积神经网络的 CRMC-Net 的 SAR 图像目标识别。首先介绍 CRMC-Net 的基本原理和框架,然后介绍注意力机制原理,接着介绍 MSTAR 数据集,最后基于 MSTAR 数据集与先进算法进行实验结果对比分析。实验结果表明,所提出的方法提高了对复杂背景下目标的分类能力,取得了更好的目标识别性能。

第4章:基于改进的幅相型卷积神经网络 AP-SSGNet 的 SAR 图像舰船目标识别。首先介绍介绍基于 AP-SSGNet 的优化算法原理和模型框架,其次介绍 OpenSAR2.0 数据集,然后基于 OpenSAR2.0 与经典的深度学习方法进行识别性能对比,验证了我们的方法的鲁棒性。

第5章:总结与展望。总结全文研究工作,探讨 SAR 图像目标识别存在的问题,最后对未来的工作进行展望。

第2章 SAR 成像及深度学习基本原理

本章内容包括以下几个方面：首先简要阐述了 SAR 图像的成像原理，为后续研究提供理论基础。随后介绍了 CNN 的基本概念，包括其工作原理、网络结构及训练流程。接着介绍了图像预处理方法以及特征提取过程。最后对用于评估 SAR 图像目标识别性能的常用评价指标进行了详细说明。

2.1 SAR 图像成像原理

在利用 SAR 进行地物探测时，首先需对接收到的回波信号进行模数转换（A/D 转换），即将连续的模拟信号转化为可供处理的数字信号。随后，借助 SAR 成像算法对这些数字信号进行处理，最终生成对应的 SAR 图像。机载 SAR 系统的成像原理如图 2.1 所示。




图 2.1 机载 SAR 成像原理

由图 2.1 知，飞机的高度为 H ，目标 P 到飞机的距离为 Y_p ，如果飞机速度为 V ，则任意时刻 T ，飞机与 P 的斜距近似为：

$$R \approx \sqrt{H^2 + Y_p^2} + \frac{V^2}{2\sqrt{H^2 + Y_p^2}}(T - T_0)^2 \quad (2-1)$$

SAR 系统发射信号为 $s(t)$,

$$s(t) = \sum_{n=-\infty}^{\infty} p(t - n * PRT) \quad (2-2)$$

$$P(t) = \Pi\left(\frac{t}{T_r}\right) \exp(j\pi f_c t + j\pi K_r t^2) \quad (2-3)$$

式中, T_r 表示电磁波脉冲持续的时间, Π 表示单位矩形窗函数, PRT 表示脉冲重复频率, f_c 表示信号的载频, K_r 表示距离向调频率。则在时间 t , P 点的回波信号为:

$$s_r(t) = \sum_{n=-\infty}^{\infty} \delta w p(t - n * PRT - \tau_n) \quad (2-4)$$

上式中, δ 表示散射系数, w 表示 P 点的方位函数, τ_n 表示发射的第 N 个脉冲信号时回波信号的时间延迟, 其表达式为 $\tau_n = \frac{2 * R}{c}$, 则点目标的回波信号为:

$$s_r(t) = \sum \delta w \Pi\left(\frac{t - n * PRT - 2 * R / c}{T_r}\right) * \exp(j\pi K_r [t - n * PRT - 2 * R / c]^2) * \exp\left(-j\pi \frac{4\pi}{\lambda} R\right) * \exp(j2\pi f_c [t - n * PRT - 2 * R / c]) \quad (2-5)$$

SAR 技术需要将回波信号 $s_r(t)$ 进行 A/D 转换, 然后使用 SAR 成像算法生成 SAR 图像。RD 算法首先对回波信号进行距离向压缩, 然后通过距离徙动校正消除由于目标位置变化引起的相位误差, 最后在方位向上进行压缩, 生成高分辨率的 SAR 图像^[74]。SAR 图像能够提供地表物体的详细信息, 具有极高的空间分辨率。这种特性使得 SAR 技术在军事、环境、气象多个领域得到了广泛应用。

2.2 卷积神经网络

神经网络是一种受生物视觉系统启发的“仿生”网络, 旨在模拟人体视网膜的信息处理机制。图 2.2 展示了 CNN 模型的基本框架。首先, 将包含目标信息的 SAR 图像输入至卷积层, 用于提取与目标相关的关键特征信息。随后, 将提取到

的特征图被传递至池化层，以进一步压缩数据维度并保留主要特征，从而为后续的特征学习与分类提供基础。最终，详细的特征信息会被送入全连接层进行分类处理，从而得到最终的分类结果。整个过程通过反复提取特征和逐步下采样，确保了模型能够高效地捕捉目标的详细特征，并在分类任务中取得优异表现。




图 2.2 卷积神经网络基本框架

2.2.1 卷积层

在 SAR 图像的目标识别过程中，卷积操作是实现特征提取的关键手段之一。为充分捕捉目标的深层次特征信息，卷积神经网络的每一层通常包含多个卷积核。每个卷积核以滑动窗口的方式在输入图像上进行局部感知操作，其滑动区域的大小即为感受野，用于控制网络对空间信息的接收范围。通过调整感受野的大小，可以有针对性地提取不同层次的目标信息。在特征提取过程中，小的感受野适用于精细地提取目标的局部特征，如边缘、纹理等；而大的感受野则更适合于获取目标的整体结构和上下文信息。图 2.3 展示了二维图像卷积运算的示意图。




图 2.3 卷积示意图

从图中可以看出，SAR 图像特征提取的本质是将输入图像与对应卷积核在特定范围内的元素进行逐点相乘后再求和的过程。卷积操作前后图像大小的变化如下所示：

$$L' = \frac{(L - K + 2P)}{S} + 1 \quad (2-6)$$

式中， L 为输入图像尺寸大小， L' 为卷积后输出图像尺寸大小， P 为图像边缘填充 0 的圈数， K 为卷积核大小， S 为卷积核滑动的步长。图 2.3 中没有进行边缘填充，所以 $P=0$ ，卷积后的图像 $L'=3$ 。

2.2.2 池化层

在网络模型中，池化层通常紧跟卷积层之后使用。图 2.4 展示了池化操作的基本原理。具体来说，池化操作是对卷积层输出的特征图进行分块处理，每个分块区域由一个代表性值代替。根据所采用的具体方法不同，池化操作可以分为最大池化和平均池化两种形式。前者是在每个局部区域内选取最大值作为代表，而后者则是计算该区域内的平均值来表示整个分块。通过这种方式，池化层有效地降低了数据维度，并增强了模型对重要特征的聚焦能力。这样的处理方式对于提高 SAR 图像分析的有效性和准确性至关重要。




图 2.4 池化示意图 (a)最大池化, (b)平均池化

2.2.3 全连接层

全连接层将通过卷积和池化操作提取到的目标深度特征，经由线性变换转换为一维向量，然后输入到分类器中进行最终的分类。在全连接层中，输入层和输出层所含神经元的数量分别由输入特征的维度和目标类别的数量决定。隐含层通过对前一层输入向量进行加权求和，并加上偏置项，再经过激活函数处理后生成最终输出。假设，第 l 层为全连接层，则第 l 层的输出表达式为：

$$x_j^l = f\left(\sum_{i=1}^n w_{ji}^l x_i^{l-1} + b_j^l\right) \quad (2-7)$$

式中， x_i^{l-1} 表示 l 层的第 i 个神经元输出， x_j^l 表示第 l 层、第 j 个元素的输出， b_j^l 表示第 l 层的偏置项， w 表示权重矩阵。

2.2.4 CNN 关键函数

激活函数在增强神经网络的非线性建模能力方面起着关键作用，使神经网络能够学习并表达复杂的特征和模式。通过引入非线性变换，激活函数使得模型具备更强的特征表达能力和更高的灵活性。下面将分别介绍几种常用的激活函数：

最早的激活函数是 Sigmoid，其表达式为

$$f(x) = \frac{1}{1 + e^{-x}} \quad (2-8)$$

该函数的梯度函数为：

$$f'(x) = \frac{e^{-x}}{(1 + e^{-x})^2} \quad (2-9)$$

图 2.5 展示了 Sigmoid 函数及其导数的示意图。其中，图（a）显示该函数为单调递增型，输出值范围在 $[0,1]$ 之间，但其收敛速度相对较慢，可能影响模型的训练效率。从图（b）可以观察到，当输入值趋于较大或较小时，函数梯度逐渐变得平缓，易引发梯度消失问题。此外，Sigmoid 函数本身的计算复杂度较高，也在一定程度上制约了其在深层网络中的应用。

Tanh 函数表达式为：

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2-10)$$

该函数的梯度函数为：

$$f'(x) = \frac{4}{(e^x + e^{-x})^2} \quad (2-11)$$

图 2.6 展示了 Tanh 激活函数及其导函数的示意图。其中，图（a）表明 Tanh 函数是单调递增的，其输出范围位于 $[-1,1]$ 区间。相比 Sigmoid 函数，Tanh 在一定程度上提升了模型的收敛速度，如图（b）所示，在输入绝对值较大时，梯度趋近于零，易导致梯度消失，其计算复杂度也未得到显著改善。




图 2.5 (a)Sigmoid 示意图, (b)导函数示意图




图 2.6 (a)Tanh 函数示意图, (b)导函数示意图

ReLU 激活函数在一定程度上克服了 Sigmoid 与 Tanh 函数存在的梯度消失及计算复杂度较高的问题，其表达式如下所示：

$$f(x) = \max(0, x) \quad (2-12)$$

图 2.7 分别展示了 ReLU 激活函数及其导函数的示意图。由图（a）可见，ReLU 函数在输入大于零时呈线性增长，其输出范围为 $[0, +\infty]$ ，能够有效缓解梯度消失问题。然而，当输入为负时，函数输出恒为零，导致在该区间内神经元无法更新参数，从而可能影响模型的训练效果。

为了解决 Relu 函数输入小于 0 时无法进行参数优化问题，Leaky-Relu 函数

被提出，其数学表达式为：

$$f(x) = \max(\alpha x, x) \quad (2-13)$$

Leaky-Relu 函数示意图以及导函数示意图如图 2.8 所示。由图可知，输入大于 0 时，Leaky-Relu 函数为线性函数。输入小于 0 时，Leaky-Relu 函数存在一个梯度，使网络模型也可以进行参数优化。




图 2.7 (a)Relu 函数示意图, (b)导函数示意图




图 2.8 (a)Leaky-Relu 函数示意图, (b)导函数示意图

神经网络训练的核心目标是通过优化过程将损失函数值降至最低，从而使得模型能够准确地拟合训练数据。因此，选择合适的损失函数对于 SAR 图像目标检测与识别任务至关重要。当损失值越小时，训练模型的拟合效果就越好，进而提高目标检测和分类的准确性。常见的损失函数包括均方误差（Mean Squared Error, MSE）^[75]和交叉熵（Cross Entropy, CE）^[76]。均方误差和交叉熵的计算公式可分别表示为：

$$H(p, q) = -\sum_x p(x) \log q(x) \quad (2-14)$$

式中， p 为实际的概率分布， q 是预测的概率分布。

$$MSE = \frac{\sum_{i=1}^n (y_i - y'_i)^2}{n} \quad (2-15)$$

式中, n 表示样本个数, y_i 表示实际值, y_i' 表示预测值。

2.3 图像预处理

在传统 SAR 图像目标识别中, 图像预处理是非常关键的一步, 预处理的目的是保留特征区域、目标信息等关键信息, 也可用来提高信噪比, 降低图像噪声对后续识别的不利影响, 同时可以对图像中感兴趣区域目标进行增强, 以便于后续的特征提取^[77-79]。

在 SAR 图像的预处理过程中通常包含以下关键步骤: 对数变换、灰度阈值分割、密度平滑处理、掩膜操作以及目标区域提取。通过对数变换, 可以将 SAR 图像中的乘性相干斑噪声转换为加性形式, 从而简化后续处理流程。接下来, 通过设定适当的灰度阈值, 可实现目标区域与背景的有效分离。为了消除因阈值分割导致的孤立亮点干扰, 还需进行密度平滑处理操作, 以确保仅保留目标区域的关键信息。此外, 结合掩膜操作和灰度归一化技术, 能够进一步提升目标区域的视觉清晰度, 为后续分析提供更优质的输入数据。最终, 目标区域提取步骤完成对感兴趣区域的精确定位, 为分类器的目标识别任务奠定基础。尽管这些传统方法在一定程度上提升了目标识别的精度, 但随着 SAR 图像数据量的快速增长, 其复杂的流程显著增加了计算成本, 在大规模数据处理场景中难以满足高效性需求。

在深度学习模型训练之前, SAR 图像需要经过一系列预处理步骤, 以优化数据质量并增强模型的学习能力。首先, 由于原始 SAR 图像通常涵盖较大的地理范围, 直接用于训练可能引入冗余信息, 因此需对其进行分块处理。这一过程不仅有助于后续的目标提取和标注操作, 还能提高数据管理的效率。其次, 不同深度学习网络对输入图像的尺寸和分辨率有特定要求, 因此需要对分割后的图像进行进一步裁剪和调整。此外, 在分块过程中, 部分目标可能会因位置偏移而偏离图像中心区域。为确保目标信息的完整性, 并优化先验框的计算精度, 可适当调整目标的位置, 从而提升模型训练的效果。最后, 高质量的标签信息是监督学习方法的核心需求。因此, 在模型训练前, 需为数据集中的每个样本提供准确的目标类别及位置信息。除了利用官方提供的基础标签外, 还需通过人工校正的方式补充和完善标注内容, 以保证数据的一致性和准确性, 为模型训练提供可靠的

指导信号。

鉴于深度学习模型对庞大数据集的依赖性,数据增强技术成为提升模型泛化能力、增加数据多样性的有效手段。数据增强策略可被细分为两大类别:几何变换与颜色调整。几何变换方面,包括镜像反转、角度旋转等操作,这些处理不改变图像的物理尺寸,仅调整目标的方向性,从而促使深度学习模型学习到不同视角下的特征表示。此外,随机裁剪与缩放技术也被广泛采用,以增强数据的多样性;然而,这些方法可能导致目标信息的部分丢失,因此需在模型训练阶段进行精细优化,而在测试阶段则通常仅应用旋转或翻转操作以保持信息的完整性。至于颜色变换,鉴于 SAR 图像多为灰度图像,其颜色变化范围受限,故可采用添加噪声、区域填充等策略进行数据增强,旨在提高模型对外界干扰的鲁棒性。

SAR 图像预处理在目标识别任务中扮演着至关重要的角色。尽管传统预处理技术能够显著提升目标信息的显著性并有效抑制背景噪声,但其较高的计算复杂度却成为了在大规模数据处理应用中的一大障碍。随着深度学习技术的不断进步,通过结合数据增强技术和优化的数据处理方案,我们能够在不扩大数据集规模的前提下,显著增强模型的训练效能,从而为 SAR 图像的目标识别问题提供更加高效且优质的解决方案。

2.4 特征提取

在 SAR 图像目标识别过程中,图像特征提取是至关重要的一步,其结果直接影响最终分类与识别的性能。特征提取的目标是从复杂的图像数据中获取能够代表目标特性的信息,从而提升识别的准确性和效率。以下从传统方法和深度学习方法两个方面对 SAR 图像特征提取技术进行系统梳理。

传统 SAR 图像特征提取方法主要依赖于手工设计的特征提取算法,这些方法虽然简单直观,但在复杂场景下的表现可能受到一定限制。主要包含以下几种方法:(1)主成分分析(Principal Component Analysis, PCA)是一种常用的数据降维和压缩技术,通过特征值分解提取数据的主要成分,剔除作用较小的信息^[80]。在 SAR 图像特征提取中,PCA 能够有效去除噪声干扰,保留图像的主要特征信息。然而,由于 PCA 是一种非监督学习方法,其特征提取过程需要大量带标签的样本支持,且可能丢失部分重要特征。此外,PCA 提取的各成分之间相互正交,能够消除特征间的相互影响,从而更全面地保留图像信息。(2) Gabor 特征

提取是一种基于线性滤波器的方法，广泛应用于纹理分析和目标识别任务中。该方法通过设计不同方向和尺度的 Gabor 滤波器，对图像进行卷积变换，从而提取出颜色、纹理、方向等统计信息^[80-82]。具体而言，Gabor 滤波器能够分析图像是否存在特定频率的内容，并在滤波完成后从图像的不同方向获取灰度分布信息。通过选取具有象征性的特征，Gabor 方法能够有效完成目标识别任务。（3）方向梯度直方图（Histogram of Oriented Gradients, HOG）通过计算图像局部区域的方向梯度直方图来描述目标的形状特征。局部二值模式（Local Binary Pattern, LBP）提取图像的纹理特征，适用于描述地物表面的粗糙程度和结构特性。尺度不变特征变换（Scale-Invariant Feature Transform, SIFT）提取图像的尺度不变特征点，能够抵抗图像缩放、旋转和光照变化的影响。尽管这些传统方法在某些特定场景下表现出色，但由于其对噪声分布敏感以及计算量较大，在实际应用中可能受到一定限制，尤其是在面对大规模 SAR 图像数据时，处理速度和识别准确性往往难以满足需求。

近年来，随着深度学习技术的快速发展，其在 SAR 图像特征提取中的应用逐渐成为主流。深度学习方法通过自动学习高层次的抽象特征，显著提升了特征提取的效率和鲁棒性。CNN 是深度学习领域中最常见的特征提取方式，其核心机制包括局部感知、参数共享和池化。SAR 图像中的目标通常具有局部相关性，即某一区域的目标特性与其附近的像素关系更为密切，而与其他相距较远的像素关联较小。基于这一特性，CNN 采用局部感知机制，通过小尺寸的卷积核聚焦于图像的局部区域，整合局部信息以推断整幅图像的全局特性。这种方法不仅有效减少了权重计算量，还避免了全局感知时可能引入的冗余信息。在卷积操作中，卷积核的权值参数在整个图像上保持不变，这种参数共享机制确保了卷积过程的稳定性和一致性，同时显著降低了模型的参数规模。通过使用相同的权值参数处理图像中具有相似特征的不同目标，CNN 能够在保证计算效率的同时避免冗余计算。此外，通过多核或多通道的设计，CNN 可以同时提取不同类型的特征，并通过对这些特征的融合实现综合考虑。池化（Pooling），也称为下采样，是一种用于降低卷积后输出向量维度的技术。其核心思想是在保留图像主要特征的前提下减少数据量，从而提高计算效率并增强模型的鲁棒性。最常用的池化方式包括最大值池化（Max Pooling）和平均池化（Average Pooling）。池化操作通常以 2×2 大小的窗口进行，使输出特征图相对于原图像缩小 4 倍。通过这种方式，CNN 能够在降低计算复杂度的同时保留关键信息。

在实际应用中,CNN 通过上述步骤提取图像特征,并结合激活函数(如 ReLU)形成网络单元。多个这样的网络单元堆叠在一起,构成深度神经网络。对于多类别检测任务,CNN 利用反向传播算法(Back Propagation, BP)对网络权值进行自适应调整,从而实现权重更新和模型优化。

无论采用哪种方法,特征的选择与提取都应满足以下几个关键要求:(1)可区分性:所提取的特征应能够有效区分不同的目标类别,避免因特征混淆导致分类错误。(2)稳定性:特征应具备较强的抗噪能力,能够在存在相干斑点噪声或其他干扰的情况下保持稳定。(3)相互独立性:提取的特征之间应尽量减少冗余,确保每种特征都能提供独特的信息。

SAR 图像特征通常包括纹理特征、几何特征和地物的光谱特征。其中,纹理特征对 SAR 地物目标信息的表达能力较强;几何特征便于提取和处理,但受相干斑点噪声影响较大;光谱特性则为分类识别提供了重要的可区分性和代表性依据。与传统方法相比,深度学习方法在特征提取方面展现出显著优势。深度学习能够自动从原始数据中学习高层次的抽象特征,无需人工干预,从而大幅简化了特征提取流程。此外,深度学习模型通过多层次的特征提取和融合,展现出更强的鲁棒性和适应性,更适合应对 SAR 图像中复杂的噪声环境和多样化的目标类型。未来的研究将进一步探索如何结合深度学习与传统方法的优点,开发更加高效、精确的 SAR 图像特征提取技术,为军事侦察、灾害监测及民用领域提供更强大的技术支持。

2.5 SAR 图像目标检测识别评价指标和实验设置

本文对 SAR 图像目标识别结果的评价指标包括以下内容。其中包括准确率(Accuracy)、平均交叉熵损失(CEL)、精确率(Precision)、召回率(Recall)和 F1。其定义可以写为:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (2-16)$$

$$CEL = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \log(\hat{y}_{i,c}) \quad (2-17)$$

$$Precision = \frac{TP}{TP + FP} \quad (2-18)$$

$$Recall = \frac{TP}{TP + FN} \quad (2-19)$$

$$F_1 = \frac{2 \times Precision \times Recall}{Precision + Recall} \quad (2-20)$$

式中， TN 和 TP 分别代表测试样本中正确阴性和阳性的数量； FN 和 FP 分别表示测试样本中假阴性和假阳性的数量。其中 N 是样本数量（批量大小）， C 是类别数量， $y_{i,c}$ 是样本 i 对类别 c 的真实标签， $\hat{y}_{i,c}$ 是模型预测的样本 i 对类别 c 的概率分布。F1 是精度和召回率的调和平均值，可以衡量检测器的综合性能。其值介于 0 和 1 之间，越接近 1，检测器性能越好。P 是精确率，R 是召回率，

实验设置如表 2.1 所示。

表 2.1 实验设置

Name	Configuration
CPU	I9-10920X
RAM	64GB
GPU	RTX3080 TI
Operating system	Windows10
Deep learning platform	Pytorch

2.6 小结

本章首先介绍了 SAR 图像的成像原理以及 CNN 的基本工作机制。随后系统地介绍了图像预处理和特征提取过程。最后对用于评估 SAR 图像目标识别性能的评价指标进行了介绍说明，为后续实验结果分析奠定基础。

第3章 基于复值卷积神经网络的 SAR 图像目标识别方法

由于相干散斑噪声的干扰导致目标像素的色散, SAR 图像中的目标可分离性较差, 仅仅依靠幅度信息难以实现高精度的目标识别。正是 SAR 图像所蕴含的丰富复值信息促使我们深入探索复值 CNN 的应用。然而, 现有的复值卷积神经网络仍存在未能充分提取目标特征信息, 识别精度较低的问题。因此, 本文提出了一种基于复值运算的 SAR 目标识别方法, 称为复值残差 Mish 激活和卷积注意模块网络(CRMC-Net)。CRMC-Net 有效利用了复值 SAR 数据中的幅度和相位信息, 充分挖掘 SAR 图像的物理散射特征, 以提高模型对目标特征的代表能力。

基于以上分析, 首先将 CNN 的所有元素, 包括输入输出层、卷积层、和池化层都扩展到了复值域。为了网络能够适应不同大小的目标信息, 通过应用不同尺寸的卷积核来提取多尺度信息, 以生成更丰富的特征表达。其次 CReLBlock 与 CMish 的结合, 使得模型的特征提取能力和训练过程的稳定性得到明显提升, 进一步优化了捕获复杂特征和信息流的效率。最后构建了复值空间和通道注意力机制模块(CCBAM), 帮助模型在相干散斑噪声的干扰下, 能够更精细地区分不同的目标和背景, 从而在复杂的 SAR 图像中实现更高的识别率。

3.1 CRMC-Net 网络结构

本节系统地阐述了 CRMC-Net 的构建方法。图 3.1 展示了所提出的 CRMC-Net 架构, 该网络由五个复值卷积块、三个复值残差模块、一个复值通道和空间注意力机制模块、五个全局平均池化层以及一个复值全连接层组成。所提出的网络采用 3×3 、 5×5 、 7×7 不同尺寸的卷积核以提取多尺度信息, 从而生成更加丰富的特征表达。

为进一步增强网络的特征学习能力, 我们引入了复值残差模块(CReLBlock)和 CMish 激活函数。CReLBlock 通过残差连接增强了模型的特征表示能力, 而 CMish 激活函数通过平滑的非线性变换改善了信息流动, 提升了特征提取的鲁棒性和训练稳定性。两者的结合显著提升了模型的特征表达和分类性能。此外, 在

网络的最后一个卷积模块后引入了复值通道注意力机制（CCBAM），进一步优化了关键特征的提取，增强了模型在复杂场景下的分类鲁棒性和泛化能力。表 3.1 详细列出了该网络的参数配置，包括每个模块的卷积核尺寸、步幅和特征图输出大小等关键信息。此外，CRMC-Net 是一种专为处理 SAR 图像中的复数数据而设计的复值卷积神经网络。网络的所有层均为复值层，能够通过复值卷积层有效提取 SAR 图像中幅度和相位信息所包含的目标特征。与实值网络方法相比，复值计算能够提取更加丰富的特征，从而显著提升识别任务的性能。这些子结构详细说明如下：

表 3.1 所提出的 CRMC-Net 参数配置

Image Name	Kernel size	Stride	Output size
Image			64×64
Complex Conv1 Block	3×3	1	64×64
Complex Residual Block	3×3	1	64×64
Complex Avg-pooling	2×2	2	32×32
Complex Conv2 Block	5×5	1	32×32
Complex Residual Block	3×3	1	32×32
Complex Avg-pooling	2×2	2	16×16
Complex Conv3 Block	7×7	1	16×16
Complex Residual Block	3×3	1	16×16
Complex Avg-pooling	2×2	2	8×8
Complex Conv2 Block	5×5	1	4×4
Complex Avg-pooling	2×2	2	2×2
Complex Conv1 Block	3×3	1	2×2
Complex CBAM Attention	3×3	1	2×2
Complex Avg-pooling	2×2	2	1×1
Complex FC			




图 3.1 CRMC-Net 网络架构

3.1.1 复值卷积块

复值卷积块由复值卷积层、复值批量归一化层和复值激活函数层组成，如图 3.2 所示。




图 3.2 复值卷积块

(1) 复值卷积层

复值卷积（CV-Conv）是在实值卷积（RV-Conv）的基础上扩展而来。与实值卷积仅从幅度信息中提取特征不同的是，复值卷积通过使用复值 SAR 图像中存在的幅度和相位信息同时来提取目标特征。CV-Conv 的本质是复值运算与卷积运算的结合，为了实现复值域上的卷积运算，在实值网络的卷积中进行复值运算的模拟。在传统的卷积操作中，当使用实值卷积来提取特征时，特征图上每个小区域的元素与卷积核逐一相乘，然后将这些乘积相加，得到特征图中的一个值。

因此,当卷积运算扩展到复数领域时,根据复数运算进行相应的元素乘法和求和。具体来说,复值卷积运算可以等效为如下

$$\begin{aligned} W * H &= (A + iB) * (C + iD) \\ &= (A * C - B * D) + i(A * D + B * C) \end{aligned} \quad (3-1)$$

卷积运算的矩阵版本可以由下式给出

$$\begin{bmatrix} \Re(W * H) \\ \Im(W * H) \end{bmatrix} = \begin{bmatrix} A & -B \\ B & A \end{bmatrix} * \begin{bmatrix} C \\ D \end{bmatrix} \quad (3-2)$$

其中 $W = A + iB$ 表示复值卷积核, $H = C + iD$ 表示复值特征层, A 、 B 、 C 、 D 分别表示对应的实部和虚部。复值卷积运算后生成的新特征层,其实部和虚部是从复值卷积的实部和虚部中提取的特征。因此,这些复值特征层包含了更丰富的幅度和相位信息。为了更清楚地描述该过程,复值卷积的整体计算如图 3.3 所示。




图 3.3 复值卷积结构示意图

(2) 复值批量归一化

在深度神经网络中,批量归一化(BN)是一种广泛使用且有效的模型优化技术。它通常用于稳定每层的中间输出值,可以加速网络的学习过程,促进模型收敛,并减轻过拟合的风险。BN在一定程度上还可以防止训练过程中梯度消失

和爆炸的问题。然而,传统的 BN 算法主要基于实值计算算法,对复值数据的处理存在局限性。为了实现复值批量归一化(CBN),通过引入 CBN 运算,可以将复值神经网络中的数据结果 x 被标准化为服从均值为 0、协方差为 1 的标准正态复数分布。这种标准化表示为

$$\mathbf{x} = \mathbf{V}^{-\frac{1}{2}}(\mathbf{x} - E[\mathbf{x}]) \quad (3-3)$$

$$\begin{aligned} \mathbf{V} &= \begin{pmatrix} \mathbf{V}_{rr} & \mathbf{V}_{ri} \\ \mathbf{V}_{ir} & \mathbf{V}_{ii} \end{pmatrix} \\ &= \begin{pmatrix} \text{Cov}(\Re(\mathbf{x}), \Re(\mathbf{x})) & \text{Cov}(\Re(\mathbf{x}), \Im(\mathbf{x})) \\ \text{Cov}(\Im(\mathbf{x}), \Re(\mathbf{x})) & \text{Cov}(\Im(\mathbf{x}), \Im(\mathbf{x})) \end{pmatrix} \end{aligned} \quad (3-4)$$

其中 $\mathbf{V}$ 是协方差矩阵, $\text{Cov}(\cdot)$ 和 $E[\cdot]$ 分别表示协方差计算和期望运算。

将实值 BN 扩展到具有两个参数的复值域,即缩放参数 γ 和平移参数 β 。那么复值批量归一化可以定义为

$$\text{BN}(\mathbf{x}) = \gamma \mathbf{x} + \beta \quad (3-5)$$

具体来说,平移参数 β 是一个复数,具有可学习的实部和虚部。缩放参数 γ 是一个 2×2 的对称半正定矩阵,包含三个可学习的分量,分别是 γ_{rr} 、 γ_{ii} 和 γ_{ri} ,其由下式给出

$$\gamma = \begin{pmatrix} \gamma_{rr} & \gamma_{ri} \\ \gamma_{ri} & \gamma_{ii} \end{pmatrix} \quad (3-6)$$

归一化后, x 的实部和虚部方差均为 1。因此,为保证 x 的方差模为 1, γ_{rr} 和 γ_{ii} 分别初始化为 $\frac{1}{\sqrt{2}}$ 。 β 和 γ_{ri} 的实部和虚部被初始化为 0。

(3) 复值激活函数层

在传统 CNN 中,一般使用一些常见的实值激活函数,例如 *ReLU*、*Sigmoid* 等。为了处理复值表示,需要考虑目标的幅度信息与相位信息之间的联系。在复值 CNN 中,将传统的 *ReLU* 激活函数扩展到复值域,分别在实部和虚部上使用两个 *ReLU* 激活函数,即:

$$\mathbb{C}\text{ReLU}(z) = \text{ReLU}(\Re(z)) + i\text{ReLU}(\Im(z)) \quad (3-7)$$

3.1.2 复值池化层

复值池化层 (Complex Pooling Layer) 在 CVCNN 中用于降维和特征提取。其原理与实值神经网络中的池化操作类似,但需要处理复数的实部和虚部。复值池化通过压缩特征信息,去除冗余部分,同时保留关键的幅度和相位信息,从而提高复值神经网络的性能。这一过程确保了重要特征的保留,有助于更有效地捕捉和表示数据的复值模式。

在复值池化中,常用的操作有复值最大池化 (CMax-Pooling) 和复值平均池化 (CAvg-Pooling)。复值最大池化选择特征图块中幅度最大的复数值,而复值平均池化则对特征图块中的复数值求平均。对于给定输入特征图 $Z = Z_r + iZ_i$, 其中 Z_r 和 Z_i 分别是实部和虚部,复值最大池化操作可以表示为:

$$Z_{\max} = \max(|Z|) \quad (3-8)$$

其中 $|Z|$ 表示复数的幅度

复值平均池化的公式则为:

$$Z_{\text{avg}} = \frac{1}{n} \sum_{k=1}^n Z_k \quad (3-9)$$

其中 Z_k 是复值特征图, n 是特征图的元素数量。

3.1.3 复值全连接层

与复值卷积运算类似,复值全连接层是实值全连接层在复数领域的延伸。它在识别任务中,通过整合复值输入特征,能够处理并保留这些特征中的复值信息,从而更有效地获得识别输出。假设有复数权重矩阵 $W = W_r + iW_i$, 输入向量为 $X = X_r + iX_i$, 复值全连接层的公式表示如下:

$$y = (W_r X_r - W_i X_i) + i(W_r X_i + W_i X_r) \quad (3-10)$$

其中 W_r 和 W_i 分别表示权重的实部和虚部, X_r 和 X_i 分别为向量的实部和虚部

3.1.4 复值残差模块

为充分发挥残差结构在传统实值卷积神经网络中的优势,我们将其扩展至复数域,并在 CRMC-Net 中引入了复值残差模块。如图 3.4 所示,复值残差模块的

设计与传统残差模块相似，卷积层和激活层均采用复值结构。主干网络由两个 3×3 复值卷积层组成，负责提取 SAR 图像中的复数特征。分支网络通过下采样层对输入数据进行调整，以确保其在通道数和尺寸上与复值卷积层的输出相匹配，从而保证复值残差模块的正常运作。跳跃连接的引入进一步缓解了深层网络中的梯度消失和退化问题，保证了训练的稳定性。通过这种设计，网络能够有效整合复数信息，精准提取和处理复数数据中的幅度和相位特征，确保特征的完整性，显著提升特征提取效果。总体而言，复值残差模块的引入大幅增强了 CRMC-Net 的鲁棒性和识别性能，使其在处理复值 SAR 图像任务中表现更加出色。




图 3.4 复值残差模块结构示意图

3.1.5 复值 Mish 激活函数

Mish 激活函数图像如图 3.5 所示。与 ReLU 函数在 0 点不平滑相比，Mish 函数处处平滑，有利于网络的收敛。Mish 激活函数因其平滑的非线性变换和连续可微性，有助于网络在训练过程中保持稳定的梯度流动，避免 ReLU 函数中的梯度消失和 Dying ReLU 问题^[83]。复值 Mish（CMish）激活函数是 Mish 激活函数在复数域中的扩展，用于增强复值神经网络的表达能力和训练效果。CMish 函数通过对实部和虚部分别进行非线性变换，不仅继承了以上 Mish 函数优点，还在复数域中进一步提高了信息流通和梯度传递的顺畅性。这一设计有效提升了复值神经网络的训练性能，能够更准确地提取和保留复数特征，从而显著提升网络的鲁棒性和泛化能力。其中，对于 $x \in \mathbb{R}$ ，Mish 函数可以表示为

$$\text{Mish}(x) = x \cdot \tanh\left(\ln(1 + e^x)\right) \quad (3-11)$$

与[44]中定义的 $\mathbb{C}\text{ReLU}$ 激活函数类似, 所提出的 $\mathbb{C}\text{Mish}$ 实际上将 Mish 函数分别应用于实部和虚部。对于 $z = x + iy$, $\mathbb{C}\text{Mish}$ 函数由下式给出

$$\begin{aligned} \mathbb{C}\text{Mish}(z) &= \text{Mish}(\Re(z)) + i \cdot \text{Mish}(\Im(z)) \\ &= x \tanh\left(\ln(1 + e^x)\right) + i \cdot y \tanh\left(\ln(1 + e^x)\right) \end{aligned} \quad (3-12)$$




图 3.5 Mish 激活函数图像

3.1.6 复值通道和空间注意力机制

在 CRMNet 中, 引入了 CCBAM 来进一步提升模型对 SAR 图像复值特征的代表和提取能力。CCBAM 包含两个不同的组件: 复值通道注意力和复值空间注意力, 分别在通道和空间维度上对复值特征进行加权处理。如图 3.6 所示, 复值通道注意力模块 (CCAM) 首先通过最大池化和平均池化操作对输入特征进行处理。其中, CAvgpool 计算复值特征的平均值并输出实部和虚部, 而 CMaxpool 选择模数最大的复数并最终输出实数。为了有效地融合这三类信息, CCAM 通过共享的 MLP 对 CAvgpool 和 CMaxpool 的实部、虚部和幅度结果进行加权处理, 计算通道注意力。随后通过 sigmoid 生成通道权重, 分别作用于输入特征的实部和虚部, 自适应调整不同通道的重要性, 凸显关键的幅度和相位信息。复值

空间注意机制关注特征图的空间位置,使网络能够更准确地捕捉图像中的关键细节。通过同时在通道和空间维度上进行操作,CCBAM 增强了网络在复杂数据集中识别和处理显著特征的能力,最终提升了分类性能。




图 3.6 复值 CBAM 模块

3.2 MSTAR 数据集介绍

在本研究中,我们使用了广泛应用于 SAR-ATR 任务的 MSTAR (Moving and Stationary Target Acquisition and Recognition) 数据集。MSTAR 数据集由国防高级研究计划局 (DARPA) 支持,使用 X 波段 SAR 传感器采集,具有 $0.3\text{ m} \times 0.3\text{ m}$ 的分辨率,涵盖了多种目标信息,包括类别、序列号、数量、方位角和俯角,因而成为评估 SAR 图像识别算法的标准基准。具体来说,该数据集包含十种不同类型的地面车辆目标,包括 2S1、BMP2、BRDM2、BTR60、BTR70、T62、T72、ZSU234、D7 和 ZIL131。需要注意的是,复值网络中使用的实验数据是具有复值分量的原始 MSTAR 数据。实值网络中使用的数据也是从该数据集处理而来。MSTAR 数据集中的具体信息如表 3.2 所示。它们的光学图像和相应的 SAR 图像如图 3.7 所示。MSTAR 的目标切片可分为标准操作条件 (SOC) 和扩展操作条件 (EOC)。我们使用三个复值数据集,即 SOC-10、SOC-3 和 EOC-VV-4。

(1) SOC-10 (Standard Operating Condition - 10 Classes): SOC-10 包含在标准操作条件下采集的所有目标类型的 SAR 图像。表 3.3 为 SOC-10 实验配置,训练集有 2747 个俯角为 17° 的样本,测试集有 2425 个俯角为 15° 的样本。SOC-10 用于评估模型在所有目标类别上的整体性能,提供了全面的标准测试基

准。



图 3.7 十类军事目标。（上）光学图像。（左下）实部。（右下）虚部。

表 3.2 所用数据集的具体细节

Datasets	Training targets	Testing targets	Description
SOC-10	1-2s1, 2-BMP2(SN9563), 3-BRDM2, 4-BTR-60, 5-BTR-70, 6-D7, 7-T62, 8-T72(SN132), 9-ZIL131, 10-ZSU234		Training at 17° and testing at 15°
SOC-3	All variants within the categories BMP2, BTR70, and T72		Training at 17° and testing at 15°
EOC-VV-4	2-BMP2(SN9563), 4-BTR-60, 7-T62, 8-T72(SN132)	2-BMP2(SN9566), 2-BMP2(c21), 4-BTR-60, 7-T62, 8-T72(SN812), 8-T72(S7),	Training at 17° Testing at 15° against BMP2 and T72 version variants

表 3.3 SOC-10 实验配置

Class	Serial No.	Training set 17 °	Testing set 15 °
1-2S1	B01	299	274
2-BMP2	SN9563	233	195
3-BRDM2	E-71	298	274
4-BTR-60	Kl0yt7532	256	195
5-BTR-70	C71	233	196
6-D7	92v13015	299	274
7-T62	A51	299	273
8-T72	SN132	232	196
9-ZIL131	E12	299	274
10-ZSU234	D08	299	274
Total		2747	2425

(2) SOC-3 (Standard Operating Condition - 3 Classes) : SOC-3 是 SOC-10 的简化版本, 包含 3 类目标车辆 BMP2、BTR70 和 T72, 用于验证模型在类别数量较少情况下的泛化能力。SOC-3 数据集的具体配置如表 3.4 所示。训练集和测试集分别有 1622 个 17°和 1365 个 15°的目标样本。

表 3.4 SOC-3 实验配置

Class	Serial No.	Training set 17 °	Testing set 15 °
2-BMP2	SN9563	233	195
	SN9566	232	196
	C21	233	196
5-BTR-70	C71	233	196
8-T72	SN132	232	196
	SN812	231	195
	S7	228	191
Total		1622	1365

(3) EOC-VV-4 (Extended Operating Condition - Variation in Version 4) : EOC 数据集用于测试模型在更复杂的条件下的鲁棒性。为了证明所提出模型的优越性, 在 EOC 下进行了类似的实验。与 SOC 不同的是, EOC-VV-4 在测试集中使用的目标与训练集中同类型目标的序列号或版本不同。由于 SAR 特殊的成像机制, 不同版本的目标在外观和雷达反射特性上可能存在细微差异, 这种变化增加了模型识别任务的难度, 因此, 有必要验证识别方法在目标版本变化条件下的性能表现。表 3.5 显示了 EOC-VV-4 数据集中的四类军用车辆, 其中 BMP2 和 T72 目标具有不同的序列号变体。

表 3.5 EOC-VV-4 实验配置

	Class	Serial No.	No.	Total
Training set 17°	2-BMP2	SN9563	233	1020
	4-BTR-60	Kl0yt7532	256	
	7-T62	A51	299	
	8-T72	SN132	232	
Testing set 15°	2-BMP2	SN9566	196	1246
	2-BMP2	C21	196	
	4-BTR-60	Kl0yt7532	195	
	7-T62,	A51	273	
	8-T72	SN812	195	
	8-T72	S7	191	

3.3 SAR 图像目标识别结果分析

3.3.1 训练参数设置


在本研究中,以 Windows 10 为操作系统,采用 PyTorch 作为深度学习框架,实验运行在一台配备了 Intel i9-10920X 处理器、64GB 内存和 Nvidia RTX 3080 Ti 图形处理器的个人计算机上。在训练过程中,采用交叉熵损失函数进行误差评估,并使用随机梯度下降(SGD)优化器来优化损失函数。具体配置如下:初始学习率设置为 0.0005,模型训练批量大小为 32,训练周期设定为 350 个 epoch。

3.3.2 消融实验


为了评估各模块对目标识别的影响,使用 SOC-10 数据集进行消融实验,实验结果如表 3.6 所示。实验结果表明,CVCNN 的改进版本的准确率达到 99.62%,损失为 0.0306。引入 CReLBlock 后,准确率有所提升,达到了 99.67%,损失值也降低至 0.0198,这主要得益于深度网络中梯度消失与退化问题得到有效缓解,保证了训练的稳定性。此外,与改进 1 相比,加入 CMish 后,改进 2 的准确率提升至 99.71%,损失值进一步降低至 0.0169,这主要得益于 CMish 增强了模型

的非线性表达能力,从而提升了整体性能。此外,为了便于在复杂数据集中更精确地定位和处理显著特征,在改进 2 的基础上引入了 CCBAM 模块,使准确率提高了 0.12%,比原 CVCNN 的改进版提高了 0.21%,损失值也从 0.0306 降至 0.0114。

图 3.8 为训练阶段得到的测试准确率曲线与测试损失。为了直观地展示改进模块的有效性,我们选取 BTR-70 对本文模型第二卷积层的特征图进行可视化实验。可视化结果如图 3.9 所示,随着各个模块的加入,模型不断强化特征表达,最终实现对目标区域的准确识别。结果表明,各个复值模块的加入使得识别性能有明显的提升。此外,本文方法能够达到最高准确率的原因还在于它有效利用了图像固有复值信息所蕴含的物理散射特性。



(a)



(b)

图 3.8. 消融实验中训练阶段的测试准确率 (a) 和损失 (b)




图 3.9. 一些可视化结果 (a) 原始图像, (b) CVCNN 改进, (c) 改进 1, (d) 改进 2, (e) 改进方法

表 3.6 消融实验

Method	CReLBlock	CMish	CCBAM	Accuracy(%)	Loss
CVCNN Improvement				99.62	0.0306
Improvement1	√			99.67	0.0198
Improvement2	√	√		99.71	0.0169
Proposed	√	√	√	99.83	0.0114

3.3.3 实验对比分析

为了验证本文提出的 CRMC-Net 的性能, 本节的对比实验选取了几种著名且常用的实值深度学习识别方法进行比较, 具体包括传统 CNN、VGG16、ResNet18、DenseNet121、CVCNN、CV-FCNN 和 CV-Net。传统 CNN 方法是指具有四个卷积层的小型实值网络结构, CVCNN 是其对应网络的复值版本。对比实验在 SOC-10、SOC-3 和 EOC-VV-4 数据集上进行, 反映了模型针对所有类别、某些特定目标以及版本变化的能力。

(1) SOC-10 数据集对比实验: 表 3.7 显示了 SOC-10 数据集上八种 SAR 目标识别模型的定量测试结果。从中可以看出, 这些模型的识别准确率从高到低依次为: CRMC-Net (99.83%), CV-Net (99.67%), CV-FCNN (99.17%), CV-CNN (98.59%), VGG16 (97.65%), DenseNet121 (97.32%), ResNet18 (96.82%),

传统 CNN (96.25%)。CRMC-Net 在 SOC-10 数据集上的表现尤为突出, 准确率超越了其余七种模型。在测试损失方面, CRMC-Net 的表现同样优异, 其损失值为 0.0114, 远低于其他模型, CV-CNN 的损失值为 0.0655, 次之。测试损失反映了模型在处理目标样本时的拟合程度, 损失值越低, 意味着模型能够更准确地捕捉到目标样本的特征, 从而表现出更好的拟合效果。为了科学、清晰地评估实验结果, 采用了混淆矩阵来进一步证明所提方法的性能。如图 3.10 所示, CRMC-Net 在 SOC-10 数据集上的混淆矩阵表明, 该模型对 BMP2、BTR60、BTR70、T62、ZSU234、T72 和 ZIL131 七类目标实现了 100% 的识别准确率, 而对 2S1、BRDM2 和 D7 的识别准确率分别为 99.64%、99.64%、和 99.27%。结果表明, 所提出的方法对于识别任何类别目标都具有出色的性能。这充分展示了 CRMC-Net 在目标识别方面的卓越性能。

表 3.7 SOC-10 数据集的定量测试结果

Datasets	Models	Model Type	Loss	Accuracy(%)
SOC-10	Traditional CNN	real-valued	0.3546	96.25
	VGG16	real-valued	0.0866	97.65
	ResNet18	real-valued	0.1469	96.82
	DenseNet121	real-valued	0.1084	97.32
	CVCNN	complex-valued	0.0655	98.59
	CV-Net [62]	complex-valued	0.0225	99.67
	CV-FCNN [64]	complex-valued	0.0439	99.17
	Proposed	complex-valued	0.0114	99.83

True Label	2S1	BMP2	BRDM2	BTR60	BTR70	D7	T62	T72	ZIL131	ZSU234	Recall
2S1	273.00	0.00	1.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	100.00
BMP2	0.00	195.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	100.00
BRDM2	0.00	0.00	273.00	0.00	1.00	0.00	0.00	0.00	0.00	0.00	99.64
BTR60	0.00	0.00	0.00	195.00	0.00	0.00	0.00	0.00	0.00	0.00	100.00
BTR70	0.00	0.00	0.00	0.00	196.00	0.00	0.00	0.00	0.00	0.00	99.49
D7	0.00	0.00	0.00	0.00	0.00	272.00	0.00	0.00	0.00	2.00	100.00
T62	0.00	0.00	0.00	0.00	0.00	0.00	273.00	0.00	0.00	0.00	100.00
T72	0.00	0.00	0.00	0.00	0.00	0.00	0.00	196.00	0.00	0.00	100.00
ZIL131	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	274.00	0.00	100.00
ZSU234	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	274.00	99.28
Recall	99.64	100.00	99.64	100.00	100.00	99.27	100.00	100.00	100.00	100.00	99.83
Predicted Label	2S1	BMP2	BRDM2	BTR60	BTR70	D7	T62	T72	ZIL131	ZSU234	Precision

图 3.10 SOC-10 数据集上 CRMC-Net 的混淆矩阵

(2) SOC-3 数据集对比实验: 通过 SOC-3 数据集的测试, 可以清晰地反映模型对特定目标上的学习和表示能力。表 3.8 和图 3.11 分别列出了 SOC-3 数据集上的定量测试结果和相应的混淆矩阵。测试结果表明, CRMC-Net 取得了 100.00% 的准确率, 显著优于其他五种先进的目标识别方法。对比网络的识别准确率依次为 CV-Net (99.83%), CV-FCNN (99.57%), Traditional-CNN (99.41%)、CV-CNN (99.26%)、DenseNet (99.12%)、ResNet18 (99.05%) 和 VGG16 (98.97%)。在测试损失方面, CRMC-Net 的误差最低, 仅为 0.0029。图 3.11 混淆矩阵进一步说明, CRMC-Net 对 BMP2、BTR70 和 T72 目标实现了 100.00% 的识别准确率。总体而言, CRMC-Net 在目标识别精度和目标拟合误差方面均表现出卓越的性能, 超越了现有的目标识别方法。实验结果进一步证明了相位信息的引入对目标识别性能的提升具有积极作用, 同时表明复值网络在挖掘复值 SAR 数据中的目标信息方面非常有效, 从而显著提高了识别性能。

表 3.8 SOC-3 数据集的定量测试结果

Datasets	Models	Model Type	Loss	Accuracy(%)
SOC-3	Traditional CNN	real-valued	0.0273	99.41
	VGG16	real-valued	0.0315	98.97
	ResNet18	real-valued	0.0358	99.05
	DenseNet121	real-valued	0.0324	99.12
	CVCNN	complex-valued	0.0329	99.26
	CV-Net [62]	complex-valued	0.0076	99.83
	CV-FCNN [64]	complex-valued	0.0225	99.57
	Proposed	complex-valued	0.0029	100

(3) EOC-VV-4 数据集对比实验: 在 SAR-ATR 应用中, 战场条件的动态性和不断变化的任务要求对 SAR 目标识别提出了重大挑战。针对这一问题, 本节利用 EOC-VV-4 数据集评估 VV 对各种目标识别模型的影响。在 EOC-VV-4 数据集上测试的各个模型所达到的准确度如表 3.9 所示。传统 CNN 模型的准确率为 91.33%, 损失函数为 0.3316。VGG16 模型的准确率为 88.68%, 损失函数为 0.3849。ResNet18 和 DenseNet121 模型分别达到了 89.97% 和 91.89% 的准确率, 损失函数分别为 0.5477 和 0.3471。CVCNN 模型的准确率为 93.09%, 损失函数为 0.2451; CV-FCNN 模型的准确率为 93.26%, 损失函数为 0.2226, 模型性能有所提高; CV-Net 模型的准确率为 94.86%, 损失函数为 0.1727; 但本文提出的模型性能最好, 准确率为 95.02%, 损失函数为 0.1383。相比之下, 本文提出的 CRMC-Net 模型对 SAR 目标的 VV 具有更优异的泛化能力。

表 3.9 EOC-VV-4 数据集的定量测试结果

Datasets	Models	Model Type	Loss	Accuracy(%)
EOC-VV-4	Traditional CNN	real-valued	0.3316	91.33
	VGG16	real-valued	0.3849	88.68
	ResNet18	real-valued	0.5477	89.97
	DenseNet121	real-valued	0.3471	91.89
	CVCNN	complex-valued	0.2451	93.09
	CV-Net [62]	complex-valued	0.1727	94.86
	CV-FCNN [64]	complex-valued	0.2226	93.26
	Proposed	complex-valued	0.1383	95.02




图 3.11 SOC-3 数据集上 CRMC-Net 的混淆矩阵

我们比较了几个复值激活函数 (CTanh, CElu, CReLU 和 CMish) 来评估它们在复值网络中的性能。这些复值激活函数是实值激活函数 Tanh, Elu, ReLU 和 Mish 的扩展, 以处理复数输入。利用本文提出的模型测试了这四个激活函数在 SAR 图像识别任务中的性能。从表 3.10 的实验结果来看, CTanh 表现不佳, 识别率为 98.56%, 对应的损失值为 0.0535, 明显低于其他激活函数。其次, CElu 表现稍好, 识别率为 98.80%, 损失值为 0.0471。虽然它优于 CTanh, 但仍未能明显优化网络性能。CReLU 激活函数在复值网络中取得了比较理想的效果, 识别准确率达到 99.59%, loss 值为 0.0210, 表现出了比较明显的优势。而 CMish 激活函数在各项测试中表现最好, 识别准确率达到 99.83%, loss 值仅为 0.0114, 明显优于其他激活函数。这说明 CMish 作为复值网络的激活函数在捕捉复值特征、提升模型性能方面具有更好的适应性。

表 3.10 不同复值激活函数的比较

	CTanh	CElu	CRelu	CMish
Accyarcy(%)	98.56	98.80	99.59	99.83
loss	0.0535	0.0471	0.0210	0.0114

3.3.4 所提方法与实值版本网络的比较分析

为了进一步验证复值网络在 SAR 目标识别中的优势,我们将模型修改为相应的实值版本 RMC-Net,并使用 SOC-10, SOC-3 和 EOC-VV-4 数据集进行对比分析,结果总结在表 3.11 中。结果表明,CRMC-Net 模型在所有测试数据集上都表现出优于实值网络(RMC-Net)的性能。其中,对于 SOC-10 数据集,CRMC-Net 的准确率达到 99.83%,明显高于 RMC-Net 的 98.97%的准确率,而且损失值从 0.0504 降低到 0.0114。随后,在 SOC-3 数据集上,CRMC-Net 的准确率达到 100%,而 RMC-Net 的准确率为 99.78%,损失值也降低到 0.0029。此外,在复数 EOC-VV-4 数据集上,CRMC-Net 表现出了较强的泛化能力,达到了 95.02%的准确率,损失值为 0.1383。而 RMC-Net 的准确率则为 92.70%,损失值为 0.2503。CRMC-Net 和 RMC-Net 的准确率与损失曲线如图 3.12 所示。从图 3.12 可以看出,准确率曲线均呈上升趋势,而损失曲线则呈下降趋势并最终收敛。但与 RMC-Net 相比,CRMC-Net 的准确率明显更高,损失更小。

图 3.13 为 RMC-Net 和 CRMC-Net 第二卷积层特征图的可视化。从图 3.13 可以看出,RMC-Net 特征图中目标区域的特征比较模糊,而 CRMC-Net 的实部特征图更加突出,目标区域的特征明显增强。虚部特征图提供了额外的散射信息,进一步增强了目标区域的识别。复值网络通过结合实部和虚部特征,可以更好地捕捉 SAR 图像中的物理散射特性,从而提高目标识别的准确率。复值网络的利用可以更有效地捕捉和利用复值信号固有的相位信息,从而明显提高模型的准确率,减少误差,鲁棒性增强。

表 3.11 三个数据集的定量评估结果

Datasets	Models	Loss	Accuracy(%)
SOC-10	RMC-Net	0.0504	98.97
	CRMC-Net	0.0114	99.83
SOC-3	RMC-Net	0.0109	99.78
	CRMC-Net	0.0029	100
EOC-VV-4	RMC-Net	0.2503	92.70
	CRMC-Net	0.1383	95.02




图 3.12 CRMC-Net 和 RMC-Net 的准确度曲线和损失曲线 (a)基于 SOC-10 数据集的准确度曲线, (b)基于 SOC-10 数据集的损失曲线, (c)基于 SOC-3 数据集的准确度曲线, (d)基于 SOC-3 数据集的准确度曲线




图 3.13 (a)原始图像, (b) RMC-Net 特征图可视化, (c) CRMC-Net 实部特征图可视化, (d) CRMC-Net 虚部特征图可视化

我们将 CRMC-Net 与 RMC-Net, VGG16, ResNet18 等其他模型进行了计算性能的比较。表 3.12 是在 SOC-10 数据集上测试的四个网络的定量比较, 包括权重参数#Params, 浮点运算 (FLOPs)。首先, 就 Params 而言, CRMC-Net 的参数数为 25.8MB, 略高于 RMC-Net 的 14.6MB, 但明显低于 VGG16 的 138.4MB

和 ResNet18 的 47.8MB。这表明虽然复值运算引入了一些额外的参数,但与更经典的深度实值模型相比,CRMC-Net 的参数数量仍在合理范围内。从计算复杂度来看,CRMC-Net 的 FLOP 数为 1.31G,与 ResNet18、VGG16 相当,高于 RMC-Net (0.22G)。虽然 CRMC-Net 的计算开销高于 RMC-Net,但其能够融合幅度和相位信息,显著提升目标识别精度。与经典实值网络相比,RMC-Net 和 CRMC-Net 在性能提升与计算成本的平衡上均实现了有效的优化。

表 3.12 不同模型的参数比较

Models	Params(MB)	Flops(G)
ResNet18	47.8	1.27
VGG16	138.4	1.42
RMC-Net	14.6	0.22
CRMC-Net	25.8	1.31

此外,为了评估所提网络在其他数据集的适用性,如图 3.14 所示,选取 OpenSARShip2.0 (OPS2.0) 数据集对所提模型进行验证。OPS2.0 是专为海上船舶识别任务构建的高分辨率 SAR 图像数据集,涵盖多种典型船舶类型,为了在不同极化方向图的 SAR 数据集上评估所提出的 CRMC-Net 模型,选取双极化 VH/VV 下的 OPS2.0 单视合成 (SLC) 产品。选取数量较多的三类船舶目标,即货船、油轮和其他类型船舶进行研究,丢弃数量较少的船舶目标。对三类船舶目标进行筛选并进行数量平衡,每类目标总数为 510 个,测试集样本数为 51 个,因此将每种船舶按照 9:1 的比例随机分为训练集和测试集。

表 3.13 OPS2.0 数据集的定量评估结果

Datasets	Models	Model Type	Accuracy(%)
OPS 2.0	ResNet18	real-valued	69.93
	VGG16	real-valued	69.28
	RMC-Net	real-valued	68.63
	CVCNN	complex-valued	69.84
	CRMC-Net	complex-valued	70.59

表 3.14 RMC-NET 和 CRMC-NET 在三个类别中的准确率、召回率和 F1 比较

Type	Precision(%)		Recall(%)		F1	
	RMC-Net	CRMC-Net	RMC-Net	CRMC-Net	RMC-Net	CRMC-Net
Cargo	64.18	59.49	84.31	92.16	72.84	72.31
Tanker	71.15	83.72	72.55	70.59	71.84	76.60
Other	73.53	80.65	49.02	49.02	58.96	60.98

本次实验中，我们与 VGG16、ResNet18、RMC-Net 和 CVCNN 四个基线模型进行了对比，以验证所提 CRMC-Net 模型的性能。表 3.13 中的实验结果显示，CRMC-Net 的准确率为 70.59%，略高于 ResNet18（69.93%）、CVCNN（69.84）和 VGG16（69.28%），明显优于 RMC-Net（68.63%）。这些结果表明，与经典实值网络相比，CRMC-Net 模型在复值网络中具有更强的特征表达能力和更好的分类性能。为了进一步凸显复值网络的优越性，表 3.14 给出了 RMC-Net 和 CRMC-Net 三类目标的准确率、召回率和 F1。从表 3.14 可以看出，CRMC-Net 与 RMC-Net 在 Cargo 和 Other 类型目标上的 F1 得分相近，但 Tanker 的 F1 明显高于 RMC-Net。通过引入复值运算，可以同时利用幅度和相位信息，从而增强对目标物理散射特性的捕捉能力，从而更有效地提取复杂背景和多极化信息下的目标特征。复值运算不仅提高了模型的分类性能，还增加了模型在复杂场景下的鲁棒性和适应性。




图 3.14 OPS2.0 的示例图像 (a) VH 极化实部, (b) VH 极化虚部, (c) VV 极化实部, (d) VV 极化虚部

3.4 小结

随着深度学习技术的迅速发展,基于卷积神经网络的算法在 SAR-ATR 领域取得了显著的进展。然而,SAR 图像独特的物理散射特性往往未被充分利用,尤其是相位信息。许多现有的深度学习方法通常将 SAR 图像简单地视为光学图像,仅仅依靠幅度信息从实值 SAR 图像中提取特征。这在一定程度上限制了模型的识别性能,对于 SAR 目标识别任务来说无疑是一个重大挑战,极大地制约了深度学习方法的进一步发展。为了应对这些挑战,本文提出了一种基于复值运算的 SAR 目标识别方法 CRMC-Net。该方法通过在复值域中扩展 CNN 的所有关键组成部分,如输入输出层、卷积层、激活函数和池化层,充分挖掘了复值 SAR 数据中的幅度和相位信息。此外,CRMC-Net 通过采用多尺度卷积核和引入复值残差链接块(CVReLBlock)、CMish 激活函数及复值空间通道注意力块(CCBAM),大大增强了模型的代表能力和鲁棒性。实验结果表明,CRMC-Net 在 MSTAR 和 OPS2.0 数据集上表现优异,超越了传统的实值卷积神经网络,显著降低了分类误差,提升了识别性能。通过充分利用 SAR 图像中的相位信息,复值 CNN 在目标识别任务中具有明显的优势。未来,我们会将复值 CNN 扩展到更多领域,例如 SAR 目标检测。

第4章 基于幅相型卷积神经网络的 SAR 图像目标识别

近年来,卷积神经网络、全卷积网络学习框架用于 SAR 图像目标识别中,都取得了较好的结果。但目前应用于 SAR 图像识别的深度学习框架,都是针对其幅度信息。并且大多数学者在采用深度学习方法对 SAR 图像进行研究时,认为其包含的相位信息服从均匀分布因此不具备有用信息,故将其当作光学图像对待,只研究幅度信息。典型的 SAR 目标分类网络仅使用振幅数据模仿光学图像上的网络。例如,在对 OpenSARship2.0 数据集进行舰船目标识别时多采用的是地距多视(GRD)产品,在对斜距单视复数(SLC)产品也只是将其转换为幅度图去使用,从而忽略了 SAR 图像特有的复数信息。但是,考虑到 SAR 图像的特殊性,幅相型卷积神经网络同时使用幅度和相位进行训练,从理论上讲,这可以提高分类精度。

本文提出了一种基于幅相型 SE 模块、自注意力机制(Self-Attention)和 GELU 激活函数网络(AP-SSGNet)的方法,旨在充分利用 SAR 图像中的幅度和相位信息,以提高目标特征的表示能力和分类精度。首先,引入了 self-attention 机制,增强了模型对全局上下文信息的理解能力,有助于捕捉长距离依赖关系,从而提升特征提取的效果。其次,集成了 SE 模块,该模块可以自适应地重新校准通道间的权重,进一步优化特征表示,增强了模型对重要特征的关注度。最后,采用了 GELU 激活函数,相比于传统的 ReLU 等激活函数,GELU 具有更好的非线性拟合能力和平滑特性,有助于缓解梯度消失问题,加速训练过程并提高模型性能。

4.1 AP-SSGNet 网络架构

我们系统地阐述了 AP-SSGNet 的构建方法。图 4.1 展示了所提出的 AP-SSGNet 架构,该网络由四个卷积块、四个残差模块、两个 Self-Attention 模块、两个 SE 模块、四个全局平均池化层以及一个全连接层组成。所提出的网络采用了 5×5 和 7×7 卷积核,在每个卷积层后均紧跟一个残差模块。残差模块通过残差连接有效地缓解了深层网络中的梯度消失问题,增强了信息流动性,从而提升了模型的特征表达能力。该设计不仅增强了网络的非线性拟合能力,还改善了深

层特征的传递和学习效果，避免了模型的过拟合现象。




图 4.1 AP-SSGNet 模型框架

为了进一步提升网络的特征表达能力和训练稳定性，网络的第一层和第二层分别引入了 SE 模块。SE 模块通过引入全局信息，自动调整各通道的重要性，增强了模型对关键特征的关注，从而提高了特征的表达能力。这能够使网络自适应地动态调整各通道之间的权重，有效避免了无关特征对网络学习的干扰，提升了网络的鲁棒性和泛化能力。Self-Attention 模块被引入到网络的第三层和第四层来进一步提升网络的全局感知能力。Self-Attention 机制能够捕捉图像中的长程依赖关系，显著提升了模型的全局特征学习能力。具体而言，Self-Attention 能够在局部特征和全局特征之间建立关联，使得网络能够更好地聚焦于重要的区域和特征，有效提升了对复杂背景的区别能力，从而进一步提高了目标识别的精度。在激活函数的选择上，本网络采用了 GELU 激活函数。GELU 作为一种平滑的非线性激活函数，相比传统的 ReLU，能够提供更加平滑的梯度传播，避免了 ReLU 可能导致的“死神经元”问题。GELU 激活函数通过其连续的误差函数形式，增强了模型的非线性拟合能力，使得训练过程中信息的流动更加平滑，显著提升了模型在复杂数据集上的训练稳定性和收敛速度。

SAR 图像包含丰富的物理信息，其中幅度和相位信息均为识别任务提供了重要价值。传统的 SAR 图像识别方法往往仅依赖幅度信息，忽略了相位信息的潜在价值，认为相位信息主要表现为噪声或不具有有效性。然而，实际情况下，SAR 图像中的相位信息不仅包含目标的形态和散射特征，而且在复杂背景和低对比度条件下，对提升目标识别精度具有显著作用。AP-SSGNet 通过同时利用幅度和相位信息，突破了传统方法的局限，能够捕捉到更多的特征信息，从而显著

提高了目标分类的精度，特别是在复杂背景 SAR 图像中，AP-SSGNet 显示出更为优异的识别性能。

综上所述，AP-SSGNet 通过结合 SE 模块、Self-Attention 和 GELU 激活函数，充分提升了模型在 SAR 图像目标识别任务中的表现。通过同时利用 SAR 图像的幅度和相位信息，AP-SSGNet 能够更有效地适应 SAR 图像的特殊性，增强目标特征的表达和区分能力，从而在多种复杂场景下实现更高的分类精度和鲁棒性。

4.1.1 通道注意力机制（Squeeze-and-Excitation, SE）模块

SE 模块是一种有效的通道级特征重标定机制，旨在通过自适应地调整不同通道的特征权重来提升模型的表达能力。在卷积神经网络中，通道间的特征可能存在不平衡的情况，不同通道所携带的特征对于最终任务的重要性是不同的。因此，SE 模块通过引入全局信息来动态地调整每个通道的重要性，从而使得模型能够更加聚焦于关键通道并抑制不相关通道的特征^[84]。




图 4.2 SE 模块结构图

SE 模块的核心思想是通过对每个通道的特征进行“压缩”(Squeeze)和“激活”(Excitation)操作如图 4.2 所示，实现自适应的通道特征重标定。具体来说，SE 模块的工作流程可以分为以下几个步骤：

(1) Squeeze 操作

Squeeze 操作的目的是通过全局平均池化（Global Average Pooling, GAP）对输入的特征图进行空间压缩，将每个通道的空间维度（宽度和高度）汇聚成一个数值。假设输入特征图的尺寸为 $H \times W \times C$ （其中 H 是高度， W 是宽度， C 是通

道数)，全局平均池化操作会计算每个通道的平均值，从而生成一个 $1 \times 1 \times C$ 的特征向量，表示每个通道的全局信息。这一操作可以捕捉到各个通道的整体统计信息，帮助网络捕捉图像中的全局依赖关系。

$$z_c = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W x_{ijc} \quad (4-1)$$

其中， z_c 是通道 c 的全局平均值， x_{ijc} 是位置 (i, j) 上的通道 c 的值

(2) Excitation 操作

Excitation 操作的目的是根据 Squeeze 操作得到的全局信息，通过一个全连接层生成每个通道的权重系数。这些权重系数用于对输入特征图的各个通道进行自适应加权，以突出重要通道的特征，抑制不重要通道的特征。Excitation 操作可以通过一个简单的两层全连接网络来实现。第一层全连接将 C 维向量压缩到一个较小的维度 C/r ，其中 r 是压缩比，以减少计算复杂度。第二层全连接将维度重新扩展回 C ，生成每个通道的权重系数。通过这种方式，SE 模块学习到的通道权重可以动态地调整每个通道的重要性。

$$S_c = \sigma(W_2 \delta(W_1 z)) \quad (4-2)$$

其中， W_1 和 W_2 是全连接层的权重矩阵， δ 是 ReLU 激活函数， σ 是 Sigmoid 激活函数，用于将输出映射到 $[0, 1]$ 的范围内，以确保权重系数的合理性。

(3) 重标定操作

在获得通道权重 x 后，重标定操作会将这些权重应用于输入特征图中的每个通道。具体来说，输入特征图 X 的每个通道会乘以相应的权重 x ，从而调整各个通道的特征强度。这个过程可以表示为：

$$\hat{x}_c = s_c \cdot x_c \quad (4-3)$$

其中， $\hat{x}_c$ 是经过加权的输出特征图的通道 c ， x_c 是输入特征图的通道 c ，而 s_c 是通过 Excitation 操作得到的通道权重。

SE 模块通过引入全局信息实现了对通道特征的自适应重标定，能够自动学习并调整通道的权重，提升模型对重要特征的关注，抑制不相关特征的影响。该模块在网络中增加的计算量和参数非常少，但通过动态调整通道的权重，显著提升了网络的特征表达能力和鲁棒性。借助 SE 模块，模型能够更加有效地挖掘输入数据中的有用信息，从而提高在目标识别、分类、分割等任务中的表现，增强模型的泛化能力和准确性。

4.1.2 自注意力机制 (Self-Attention)

自注意力机制最早由谷歌团队于 2017 年提出,文献[85]详细介绍了该机制的原理及其应用。其主要思想是通过动态计算特征中不同位置之间的权重关系,从而强化模型对全局上下文信息的建模能力。图 4.3 为自注意力模块计算图,假设经过上层卷积运算提取的特征为 x , 其维度为 $c \times w \times h$ (其中 c 表示通道数, w 和 h 分别表示特征图的宽度和高度)。




图 4.3 自注意力模块

自注意力模块首先通过三个卷积核大小为 1×1 的卷积层分别生成 Query (Q)、Key (K) 和 Value (V) 矩阵。其中,前两个卷积操作对通道数进行压缩,生成矩阵 Q 和 K ,并将特征图展平为二维矩阵。第三个卷积保持原始通道数不变,用于生成矩阵 V ,并进行展平操作。随后,通过矩阵转置及相乘操作,计算得到尺度相关性矩阵,并在列维度上应用 Softmax 函数进行归一化处理,得到的注意力图的矩阵元素为:

$$n_{j,i} = \exp(E_{ij}) / \sum_{i=1}^N \exp(E_{ij}) \quad (4-4)$$

式中注意力图矩阵中元素个数为 $n_{j,i}$, 尺度特征图矩阵中各元素为 E_{ij} , N 为元素个数。最后将注意力图矩阵与第一次卷积运算得到的矩阵作相乘操作,得

到输出。

自注意力机制的优势在于其能够增强模型的全局感知能力,通过计算 Query 和 Key 的相关性动态调整特征重要性,使模型聚焦于关键区域,同时捕捉特征图中不同位置之间的依赖关系。相比传统卷积操作仅关注局部信息,自注意力机制可以在全局范围内建模空间相关性,灵活调整对复杂背景或多模式图像的关注,避免过多关注不相关区域,从而提升模型的特征表达能力和泛化性能。此外,结合残差连接进一步提升了训练效率和稳定性,使其在处理复杂数据时表现出显著优势。

4.1.3 GELU 激活函数

GELU 是一种激活函数,由 Hendrycks 和 Gimpel 在 2016 年提出^[86],旨在通过引入高斯分布的近似来改进深度神经网络中的非线性转换。如图 4.4 所示与传统的 ReLU 等激活函数相比,GELU 通过提供更平滑的非线性变换,提升了模型在处理复杂数据时的表现。GELU 函数的数学表达式为:

$$GELU(x) = x \cdot \Phi(x) \quad (4-5)$$

其中, x 是输入值。 $\Phi(x)$ 表示标准正态分布的累积分布函数 (Cumulative Distribution Function, CDF), 其定义为:

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt \quad (4-6)$$

为了便于计算,GELU 也可以通过数值近似表示为

$$GELU(x) = 0.5x \left(1 + \tanh \left[\sqrt{\frac{2}{\pi}} (x + 0.044715x^3) \right] \right) \quad (4-7)$$

GELU 的核心在于其基于高斯误差函数的设计,通过平滑削减负值输入,有效避免了 ReLU 在负值区域硬性截断的问题。这种平滑过渡特性使得 GELU 能够在负值与零之间提供更自然的映射,减少梯度的突然变化,从而提升训练过程的稳定性。相比之下,ReLU 可能导致“死神经元”问题,即当某些神经元的输入始终为负时,其输出恒为零,不再参与训练。而 GELU 通过对负值进行平滑处理,确保所有神经元都能有效参与训练,避免了这一缺陷。

此外,GELU 通过对正值和负值输入的平滑处理,能够更稳定地进行梯度传

播,显著降低梯度消失的风险。这使得深层网络可以更高效地学习复杂的数据模式,在大规模网络和深度模型中尤其表现出色,通常能够加速收敛并提高训练效率。GELU 的平滑特性还使其在网络中更好地捕捉全局特征,特别是在自然语言处理(NLP)和计算机视觉任务中表现优异。它能够增强网络对输入特征的表达能力,灵活调整对不同区域的关注,从而提升模型的全局感知能力和特征提取能力。

GELU 激活函数通过引入高斯误差函数,提供了一种平滑的非线性映射方式,解决了 ReLU 的硬截断问题,显著提升了模型的训练效率和稳定性。在涉及 Self-Attention 模块的复杂网络中,GELU 能够进一步增强特征提取能力、梯度传播稳定性和全局感知能力,同时有效减少“死神经元”问题和梯度消失风险。这些优势使得 GELU 成为处理复杂数据和大规模模型的理想选择,并在自然语言处理、计算机视觉等领域展现出卓越的性能和泛化能力。




图 4.4 GELU 激活函数图

4.2 数据集介绍

OpenSARship 2.0 (OPS2.0) 是一款专门用于 SAR 船舶目标检测与识别的开源数据集,旨在促进 SAR 领域的目标分类和海洋监测研究。该数据集由 Sentinel-1 卫星采集,包含 VV 和 VH 极化模式的 GRD 以及 SLC 产品。这些数据能够提供丰富的强度信息和相位信息,适用于目标分类、目标检测和船舶监测等任务。

OPS2.0 数据集共包含 34528 个船舶图像补丁 (patches),涵盖了 17 种不同类型的船舶目标,包括货船 (Cargo)、油轮 (Tanker)、集装箱船 (Container Ship)、

拖船 (Tug)、渔船 (Fishing Boat) 和其他 (Other type) 等多种海洋船舶类别。每个补丁均经过人工筛选和标注, 确保数据的准确性和代表性, 并包含幅度信息和相位信息, 以支持更精细的极化分析和散射特征提取。

为了便于后续的研究和实验, 本研究选取了数据集中数量较多且类别分布较均衡的三类船舶目标, 其中包括货船 (Cargo)、油轮 (Tanker) 和其他类型船舶 (Other) 作为研究对象。为了保证模型训练的稳定性 and 类别均衡性, 我们对数据进行了筛选和均衡采样, 最终构建的实验数据集包含 1050 张船舶 SAR 图像, 其中每类各 350 张。这些图像以 64×64 像素大小的图像块 (patch) 作为输入, 确保模型能够在不同尺度和分辨率条件下进行有效学习。此外, 本研究在实验中同时考虑了幅度信息和相位信息, 以充分利用 SAR 图像的物理散射特性, 从而提升目标识别的准确性和泛化能力。图 4.5 展示了所选三类船舶目标的 SAR 幅度图像和相位图像示例, 直观体现了不同船舶类别在 SAR 影像中的散射特征差异。




图 4.5 OPS2.0 数据集图像 (a) VH 极化幅度, (b) VH 极化相位, (c) VV 极化幅度, (d) VV 极化相位

4.3 目标分类结果分析

4.3.1 训练参数设置

本研究采用 Windows 10 操作系统，并基于 PyTorch 深度学习框架进行模型的训练与测试。实验在一台配备 Intel i9-10920X 处理器、64GB 内存和 NVIDIA RTX 3080 Ti 图形处理器的个人计算机上运行，以确保高效的计算能力和训练速度。在训练过程中，我们使用交叉熵损失函数（Cross-Entropy Loss）进行误差评估，并采用 Adam 优化器进行梯度更新，以加速收敛并提升训练稳定性。具体的训练参数设置如下：初始学习率设定为 0.0001，批量大小（Batch Size）为 32，训练周期（Epoch）设定为 100。这些参数设置不仅保证了训练的充分性，还在计算成本与模型性能之间取得了良好的平衡。

4.3.2 消融实验

为了评估不同模块对目标识别任务的影响，我们使用样本数为 1050 张的 OPS2.0 数据集，训练集和测试集按照 9:1 的比例进行了消融实验。实验结果如表 4.1 所示。实验分别考察了 SE 模块、Self-Attention 模块和 GELU 激活函数对模型识别精度的影响。

在没有引入任何改进的情况下，基础的 Res-CNN 模型的准确率为 68.57%。这表明仅使用标准的卷积神经网络在该数据集上的表现相对较差，缺乏提取特征的能力。在改进模型中，我们首先引入了 SE 模块，准确率提高至 70.48%。SE 模块通过引入通道注意力机制，能够根据输入特征的重要性动态调整其权重，从而增强了特征的表达能力，帮助模型更好地聚焦于关键区域。SE 模块的加入为网络带来了显著的性能提升，表明通道注意力机制在增强模型感知重要特征方面的有效性。在改进 1 基础上引入 Self-Attention 模块后，模型的准确率提升至 71.43%。Self-Attention 模块通过建模特征图中各个位置之间的关系，增强了网络的全局感知能力，使得模型不仅关注局部区域，还能捕捉全局信息，特别在处理复杂数据时能够提高模型的表现。其提升表明，Self-Attention 能够有效改善特征提取过程，帮助模型更好地理解输入数据中的长程依赖关系。在改进 2 基础上结合 GELU 激活函数，达到了 72.38% 的准确率。引入 GELU 激活函数使得网络的

非线性变换更加平滑，避免了 ReLU 可能引起的梯度消失或“死神经元”问题，并在大规模网络训练中提供了更好的收敛性。结合 SE 和 Self-Attention 模块，模型的特征表达能力和全局感知能力得到了极大的提升，进一步提高了识别性能。

随着 SE 模块、Self-Attention 模块和 GELU 激活函数的逐步引入，模型的准确率持续提升。具体而言，SE 模块有效增强了模型的特征选择能力，通过动态调整通道权重，使模型能够更好地聚焦于关键特征；Self-Attention 模块加强了模型对全局信息的理解，使其不仅关注局部细节，还能捕捉全局上下文信息，提升了模型在复杂数据集上的表现；GELU 激活函数通过更平滑的非线性变换，提高了训练过程的稳定性和收敛速度，避免了 ReLU 可能引起的梯度消失问题。相比于基础的 Res-CNN 模型，提出的改进方案提高了约 3.81% 的准确率，展示了这些模块组合的显著效果。消融实验结果表明，加入不同模块（SE、Self-Attention 和 GELU）对模型性能的提升均具有显著作用。提出的改进方案在提高准确率的同时，也进一步证明了利用复值信息和物理散射特性的有效性。

表 4.1 消融实验

方法	SE	Self attention	GELU	Accuracy(%)
Res-CNN				68.57
改进 1	√			70.48
改进 2	√	√		71.43
改进方法	√	√	√	72.38

4.3.3 与基于 CNN 方法的识别结果对比

为了探究不同深度学习模型在不同训练集比例下的分类性能，我们选择了 DenseNet、VGG16、ResNet18 与 AP-SSGNet 进行对比，并按 3:7、5:5、7:3 和 9:1 四种训练和测试集划分比例下进行了系统性实验，以验证模型在数据量增加时是否能稳定提升性能，同时确保所提模型不受样本划分比例的显著影响。

由表 4.2 所示，随着训练数据量的增加，各模型的分类精度普遍提升。具体而言，在训练集占比 30%（测试集 70%）的情况下，各模型表现较为一般，其中 AP-SSGNet 取得了最高准确率为 67.32%，显示出较强的特征学习能力。而 DenseNet 由于训练数据不足，精度效果表现最差为 62.86%。随着训练集占比提升至 50%，所有模型的准确率均有提升，特别是 DenseNet 的提升幅度较大，表明适当增加训练数据可以弥补部分模型对小样本数据的敏感性。当训练集占比增

至70%时,所有模型的识别精度进一步提高,且AP-SSGNet继续保持70.79%的最佳性能,其他模型之间的差距逐渐缩小,表明数据量的增加可以在一定程度上缓解模型结构带来的性能差异。最终,在训练数据占比达到90%时,各模型的分​​类准确率达到本实验的最高水平,AP-SSGNet以72.38%依然领先,而ResNet18、VGG16和DenseNet也分别提升至68.67%、68.38%和67.97%。

表4.2 基于OPS2.0数据集(1050样本数)的实验结果对比

Dataset	DenseNet	VGG16	ResNet18	AP-SSGNet
30% for Training	62.86	63.81	64.71	67.32
50% for Training	64.76	65.36	65.67	68.57
70% for Training	65.36	65.71	66.03	70.79
90% for Training	67.97	68.38	68.67	72.38

图4.6比较了不同模型在不同比例的训练数据上的整体测试准确率。结果表明,本文所提模型AP-SSGNet在每一个比例的训练数据上都优于其他网络模型,均表现出最强的特征学习与泛化能力。AP-SSGNet作为幅相型网络,能够充分利用SAR图像中的相位信息,捕获目标的物理散射特性,为目标分类提供了更丰富的判别信息,从而提升识别精度。相比之下,其他模型仅依赖于幅度信息,难以全面刻画目标的电磁散射特征,因此在分类任务上的表现略逊一筹。实验结果进一步验证了相位信息在SAR目标识别任务中的重要性,并证明了AP-SSGNet在充分挖掘和利用相位特征方面的优势。

为了进一步探究AP-SSGNet作为幅相型网络在利用相位信息方面的有效性,将原始数据集规模从1050张图像增加至1530张,并在多种训练测试集划分比例下进行系统性实验。由表4.3所示,显示出了AP-SSGNet在网络结构设计上的显著优势和目标分类任务中的强大泛化能力。

表4.3 基于OPS2.0数据集(1530样本数)的实验结果对比

Dataset	DenseNet	VGG16	ResNet18	AP-SSGNet
30% for Training	65.33	66.10	66.67	70.48
50% for Training	66.03	67.97	67.62	71.43
70% for Training	67.67	68.33	69.84	73.67
90% for Training	69.33	69.93	70.33	74.51

在训练集占比30%(测试集70%)时,AP-SSGNet以70.48%的准确率保持最佳表现,相较于原始数据集提升了3.16%,这表明其在小样本环境下仍具备较强的特征学习能力。当训练集比例增加至50%时,AP-SSGNet取得71.43%的最高分类精度,而DenseNet、VGG16和ResNet18分别提升至66.03%、67.97%和

67.62%，这表明在中等规模的数据集下，AP-SSGNet 的特征提取能力得到了显著增强，分类性能更加稳定。随着训练集比例增加至 70%，AP-SSGNet 的精度达到 73.67%，较 50%训练数据时提升 2.24%，展现了较强的泛化能力；与此同时，VGG16 和 ResNet18 的精度分别提升至 68.33%和 69.84%，而 DenseNet 也达到了 67.67%。在训练集占比 90%（测试集 10%）时，AP-SSGNet 达到 74.51%的最高精度，DenseNet、VGG16 和 ResNet18 分别达到 69.33%，69.93%和 70.33%，但 AP-SSGNet 的表现尤为突出。

图 4.7 比较了不同模型在不同比例的训练数据上的整体测试准确率。AP-SSGNet 在所有训练集比例下均表现最佳，展示了其在网络结构设计上的优越性和在 SAR 目标分类任务中的强大泛化能力。由于 AP-SSGNet 结合了幅度与相位信息，能够更全面地捕捉目标的物理散射特性，为分类提供更加丰富的判别信息，因此在所有实验设置下均保持领先。AP-SSGNet 通过充分利用 SAR 图像中的相位信息，不仅增强了模型对复杂特征的学习能力，还显著提高了分类精度。实验结果进一步验证了相位信息在 SAR 目标识别任务中的重要性，并证明了 AP-SSGNet 在充分挖掘和利用复值信息的卓越表现。

表 4.4 MSTAR 数据集 SOC-10 的定量测试结果

Datasets	Models	Model Type	Loss	Accuracy(%)
SOC-10	DenseNet	amplitude	0.1084	97.32
	VGG16	amplitude	0.0866	97.65
	ResNet18	amplitude	0.1469	96.82
	AP-SSGNet	amplitude-phase	0.0368	99.26

为了进一步验证模型识别性能和泛化能力，表 4.4 展示了在 MSTAR 数据集 SOC-10 上四种典型模型的目标识别性能。可以看出，AP-SSGNet 在所有模型中表现最优，达到了 99.26%的识别精确率和 0.0368 的最小测试损失，显著优于 DenseNet（97.32%）、VGG16（97.65%）和 ResNet18（96.82%）等传统幅度型网络。如图 4.8 所示，绘制了 AP-SSGNet 在 SOC-10 数据集上的混淆矩阵。结果表明，该模型在 BTR70、T62、T72、ZSU234 四类目标上实现了 100%的识别率，在 BRDM2、BMP2、ZIL131、BTR60 目标类别上识别率也达到 99.64%、99.49%、99.64%和 96.92%。对于识别难度稍高的 D7 和 2S1，识别率分别为 97.45%和 99.27%，同样保持在较高水平。这些结果充分表明，AP-SSGNet 不仅在整体精度上领先，同时在全类目标的识别效果上表现稳定，更进一步验证了幅相型网络的优越性。




图 4.6 基于 OPS2.0 数据集（1050 样本数）不同训练数据比例下的测试精度曲线图




图 4.7 基于 OPS 2.0 数据集（1530 样本数）不同训练数据比例下的测试精度曲线图

True Label \ Predicted Label	251	BMP2	BROM2	BTR60	BTR70	D7	T62	T72	ZL131	ZSU234	Precision
251	272.00	0.00	0.00	0.00	0.00	0.00	2.00	0.00	0.00	0.00	99.63
BMP2	0.00	194.00	0.00	1.00	0.00	0.00	0.00	0.00	0.00	0.00	100.00
BROM2	0.00	0.00	273.00	0.00	0.00	0.00	0.00	0.00	1.00	0.00	100.00
BTR60	0.00	0.00	0.00	189.00	4.00	0.00	0.00	2.00	0.00	0.00	99.47
BTR70	0.00	0.00	0.00	0.00	196.00	0.00	0.00	0.00	0.00	0.00	98.00
D7	1.00	0.00	0.00	0.00	0.00	267.00	0.00	0.00	1.00	5.00	100.00
T62	0.00	0.00	0.00	0.00	0.00	0.00	273.00	0.00	0.00	0.00	99.27
T72	0.00	0.00	0.00	0.00	0.00	0.00	0.00	196.00	0.00	0.00	98.99
ZL131	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	273.00	1.00	99.27
ZSU234	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	0.00	274.00	97.86
Recall	99.27	99.49	99.64	96.92	100.00	97.45	100.00	100.00	99.64	100.00	99.26

图 4.8 SOC-10 混淆矩阵

4.3.4 所提方法与对应幅度网络的比较分析

为了进一步验证幅相型网络在 SAR 目标识别中的优越性，我们将模型修改为对应的幅度版本，即 A-SSGNet，并使用 OPS2.0 数据集（1050 和 1530 样本数）进行对比分析，如表 4.5 所示，AP-SSGNet 相较于 A-SSGNet 在不同数据集规模下均表现出更优的分类性能，验证了幅相型网络在目标识别任务中的有效性。在原始数据集 1050 张图像的情况下，AP-SSGNet 的整体精度为 72.38%，比 A-SSGNet 的 69.52%高出 2.86%。当数据集扩充至 1530 张图像时，AP-SSGNet 的精度进一步提升至 74.51%，相比 A-SSGNet 的 69.93%有 4.58%的显著增长。实验结果表明，AP-SSGNet 能更充分地利用额外的数据，提高特征提取能力，从而实现更高的分类精度。

表 4.5 A-SSGNET 与 AP-SSGNET 在 OPS2.0 数据集精确率对比

No.	Models	Accuracy(%)
1050	A-SSGNet	69.52
	AP-SSGNet	72.38
1530	A-SSGNet	69.93
	AP-SSGNet	74.51

为了进一步分析模型在不同类别上的表现,图4.9展示了不同数据集样本的混淆矩阵。由表4.6和表4.7所示,AP-SSGNet在1050和1530数据集下的Precision、Recall和F1指标均优于A-SSGNet,特别是在Recall和F1分数上表现突出。在数据集1530样本数上,Cargo类别的F1值由A-SSGNet的75.63%提高至78.33%,Tanker类别由70.10%提升至77.08%,Other类别的F1值也从62.22%增长至66.67%。AP-SSGNet在所有类别上均优于A-SSGNet,尤其是在Recall指标上的提升更为明显,这表明其具备更强的目标识别能力。




图 4.9 (a) A-SSGNet-1050 混淆矩阵, (b) AP-SSGNet-1050 混淆矩阵, (c) SSGNet-1530 混淆矩阵, (d) AP-SSGNet-1530 混淆矩阵

实验结果表明了 AP-SSGNet 作为幅相型网络的优势。相比于仅依赖幅度信息的 A-SSGNet, AP-SSGNet 通过引入相位信息,能够更全面地刻画目标的物理散射特性,使得模型在识别复杂目标时具有更强的判别能力。这一优势在数据集规模扩展后更加明显,说明相位信息在提升目标识别精度方面起到了关键作用。AP-SSGNet 在所有实验条件下均优于 A-SSGNet,进一步证明了幅相型网络在 SAR 图像目标分类中的有效性。

表 4.6 A-SSGNET 与 AP-SSGNET 在 OPS2.0 数据集 (1050 样本) 中结果对比

Type	Precision(%)		Recall(%)		F1	
	A-SSGNet	AP-SSGNet	A-SSGNet	AP-SSGNet	A-SSGNet	AP-SSGNet
Cargo	65.79	68.29	71.43	80.00	68.49	73.68
Tanker	70.59	77.42	68.57	68.57	69.57	72.73
Other	69.70	72.73	65.71	68.57	67.65	70.59

表 4.7 A-SSGNET 与 AP-SSGNET 在 OPS2.0 数据集 (1530 样本) 中结果对比

Type	Precision(%)		Recall(%)		F1	
	A-SSGNet	AP-SSGNet	A-SSGNet	AP-SSGNet	A-SSGNet	AP-SSGNet
Cargo	66.18	68.12	88.24	92.16	75.63	78.33
Tanker	73.91	82.22	66.67	72.55	70.10	77.08
Other	71.80	76.92	54.90	58.82	62.22	66.67

4.4 小结

本章提出了一种改进的幅相型神经网络 AP-SSGNet,旨在充分利用 SAR 图像中的幅度和相位信息,以提升目标特征的代表能力和分类精度。首先,我们添加了 SE 模块,通过自适应地校准通道权重,优化特征表示,使模型更关注重要的目标特征,从而提升分类性能。其次,引入了 Self-Attention 机制,增强了模型的全局上下文理解能力,使其能够捕捉长距离依赖关系,提高特征提取的有效性。最后,采用 GELU 激活函数,相比传统 ReLU 激活函数, GELU 具备更优的非线性拟合能力和平滑特性,能够有效缓解梯度消失问题,加速训练收敛,并提升模型整体性能。在 OPS2.0 数据集上,我们对 AP-SSGNet 和传统幅度网络进行了对比实验。实验结果表明,相较于仅使用幅度信息的网络, AP-SSGNet 在不同训练数据比例下均取得了更高的分类精度,验证了利用复值信息能够增强对目标物理散射特征的提取能力,提高模型的特征表达能力和识别精度。

第5章 总结与展望

5.1 全文总结

随着 SAR 图像处理技术的发展,传统方法在图像预处理和特征提取过程中存在诸多不足。这些方法往往导致大量信息丢失,流程重复且复杂,难以充分利用 SAR 图像中的丰富细节。为了克服这些问题,本文结合深度学习技术,从图像分类和复值信息两个方面对网络模型进行了优化。提出了一种基于复值卷积神经网络的 CRMC-Net 和一种改进的幅相型卷积神经网络 AP-SSGNet,通过对幅度和相位信息进行结合处理,增强了模型对目标物理散射特性的捕捉能力,从而提升了分类精度和泛化性能。本文的主要工作总结如下:

(1) 本文简单介绍了 SAR 成像和深度学习的基本原理。首先介绍 SAR 图像的成像原理,其次对 CNN 进行了介绍,包括 CNN 的工作原理、结构组成、训练过程。然后详细介绍了 SAR 图像预处理和特征提取过程。最后对 SAR 图像目标识别实验结果评价指标进行了介绍。

(2) 本文提出了一种基于复值运算的 SAR 目标识别网络 CRMC-Net。该方法通过在复值域中扩展 CNN 的关键组成部分(包括输入输出层、卷积层、激活函数和池化层),充分挖掘 SAR 数据中的幅度和相位信息,以提升特征表达能力和识别精度。此外,CRMC-Net 结合了多尺度卷积核设计,并引入 CVReLBlock、CMish 激活函数及 CCBAM,进一步增强模型的特征学习能力和鲁棒性。实验结果表明,CRMC-Net 在 MSTAR 和 OPS2.0 数据集上的分类性能优于传统实值 CNN,能够有效降低分类误差,提高识别精度,验证了复值 CNN 在 SAR 目标识别任务中的优势。

(3) 本文提出了一种幅相型 AP-SSGNet 网络,以提升目标特征的表示能力和分类精度。首先,引入 SE 模块,通过自适应地校准通道权重,优化特征表示,使模型更关注重要的目标特征,从而提升分类性能。其次,加入 Self-Attention 机制,增强模型的全局上下文理解能力,使其能够捕捉长距离依赖关系,提高特征提取的有效性。最后,采用 GELU 激活函数,相比传统 ReLU, GELU 具有更优的非线性拟合能力和平滑特性,能够有效缓解梯度消失问题,加速训练收敛,并

提升模型整体性能。在 OPS2.0 和 MSTAR 数据集上对 AP-SSGNet 和传统幅度网络进行了对比实验。实验结果表明,相较于仅使用幅度信息的网络,AP-SSGNet 在不同训练数据比例下均取得更高的分类精度,验证了复值信息的引入能够增强目标物理散射特征的提取能力,提高模型的特征表达能力和识别精度。

5.2 工作展望

本文提出的 CRMC-Net 和 AP-SSGNet 在 SAR 目标识别任务中均表现优异，验证了复值信息的有效性以及相位信息在目标特征提取中的重要性。尽管所提网络模型在实验中均表现良好，但仍然存在一些局限性和可优化的方向。本文对以上的内容有如下展望：

（1）大规模 SAR 数据集的适应性仍需进一步验证。目前，公开的大规模复值 SAR 数据集较为稀缺，这在一定程度上限制了对 CRMC-Net 和 AP-SSGNet 泛化能力的评估。未来的研究需要在更大规模、多场景、多类别的 SAR 目标识别任务上测试这两种网络，以优化其在不同数据分布下的稳定性和鲁棒性。

（2）优化计算复杂度，以提升模型的实际应用能力。在保持分类精度的前提下，将探索轻量化模型结构，设计更高效的复值卷积计算方式，以减少计算资源消耗。

（3）为了更充分地利用相位信息，提高模型在复杂背景下的泛化能力和鲁棒性，未来将进一步研究更符合相位特征的注意力机制，优化对相位信息的建模方式。并结合多尺度特征融合，以更精准地捕捉目标细节，同时增强全局上下文理解，从而在 SAR 目标检测、远程感知和自动化监测等任务中实现更高效的检测性能。

参考文献

- [1] 皮亦鸣, 杨建宇, 付毓生. 合成孔径雷达成像原理[M]. 成都: 电子科技大学出版社, 2007.
- [2] 陈文婷, 邢相薇, 计科峰. SAR 图像舰船目标识别综述[J]. 现代雷达, 2012, 34(11): 53-58.
- [3] 郭倩, 王海鹏, 徐丰. SAR 图像飞机目标检测识别进展[J]. 雷达学报, 2020, 9(03): 497-513.
- [4] 严利华, 姬宪法, 梅金国. 机载雷达原理与系统[M]. 航空工业出版社, 2010.
- [5] 杨建宇. 雷达技术发展规律和宏观趋势分析[J]. 雷达学报, 2012, 1(1).
- [6] 匡纲要, 高贵, 蒋咏梅. 合成孔径雷达目标检测理论、算法及应用[M]. 国防科技大学出版社, 2007.
- [7] T. D. Ross, J. J. Bradley, M. P. O'Connor. SAR ATR: So what's the problem? An MSTAR perspective[J]. Proceedings of SPIE-The International Society for Optical Engineering, 1999, 3721(30): 606-610.
- [8] S. Stramondo, C. Bignami, M. Chini, et al. Satellite radar and optical remote sensing for earthquake damage detection: results from different case studies[J]. International Journal of Remote Sensing, 2006, 27(20): 4433-4447.
- [9] F. Pacifici, F. D. Frate, W. J. Emery, et al. Urban mapping using coarse SAR and optical data: Outcome of the 2007 GRSS data fusion contest[J]. IEEE Geoscience and Remote Sensing Letters, 2008, 5(3): 331-335.
- [10] M. Schlund, F. V. Poncet, D. H. Hoekman, et al. Importance of bistatic SAR features from Tan DEM-X for forest mapping and monitoring [J]. Remote Sensing of Environment, 2014, 151: 16-26.
- [11] H. Sportouche, F. Tupin, L. Denise. Building detection by fusion of optical and SAR features in metric resolution data[C]. IEEE International Geoscience and Remote Sensing Symposium. 2009, 769-772.
- [12] 李补莲. 自动目标识别(ATR)技术发展述评[J]. 现代防御技术, 2000, 28(2): 10-15.
- [13] 张翠, 邹涛, 王正志. 一种高分辨率 SAR 图像快速目标检测算法[J]. 遥感学报, 2005(01): 45-49.
- [14] Hua Y, Guo J, Zhao H. Deep belief networks and deep learning[C]. Proceedings of 2015 international conference on intelligent computing and internet of things. 2015: 1-4.
- [15] Sun W, Shao S, Zhao R, et al. A sparse auto-encoder-based deep neural network approach for induction motor faults classification[J]. Measurement, 2016, 89: 171-178.
- [16] Ding J, Chen B, Liu H, et al. Convolutional neural network with data augmentation for SAR target recognition[J]. IEEE Geoscience and remote sensing letters, 2016, 13(3): 364-368.
- [17] Baraha S, Sahoo A K. Synthetic aperture radar image and its despeckling using variational methods: A review of recent trends[J]. Signal Processing, 2023, 212: 109156.
- [18] El-Darymli K, Gill E W, Mcguire P, et al. Automatic target recognition in synthetic aperture radar

- imagery: A state-of-the-art review[J]. IEEE access, 2016, 4: 6014-6058.
- [20] 宋建社, 郑永安, 袁礼海. 合成孔径雷达图像理解与应用[M]. 北京: 科学出版社, 2008, 1-6.
- [21] Thompson A A, Luscombe A P, James K. New modes and techniques of the SAR[C]. IEEE International Geoscience & Remote Sensing Symposium. Istanbul, Turkey, 2014: 451-454.
- [22] Torre A, Calabrese D, Porfilio M. COSMO-SkyMed: Image quality achievements[C]. Proceedings of 5th International Conference on Recent Advances in Space Technologies, Istanbul, Turkey, 2011: 861-864.
- [23] Covello F, Battazza F, Coletta A. COSMO-SkyMed an existing opportunity for observing the Earth[J]. Journal of Geodynamics, 2010, 49(3-4): 171-180.
- [24] Hajnsek I, Krieger G, Werner M. A Satellite Formation for High-Resolution SAR Interferometry[J]. IEEE Transactions on Geoscience and Remote Sensing, 2007, 45(11): 3317-3341.
- [25] Keydel E R, Lee S W, Moore J T. MSTAR extended operating conditions: A tutorial[J]. Algorithms for Synthetic Aperture Radar Imagery III, 1996, 2757: 228-242.
- [26] Li B, Liu B, Huang L, et al. OpenSARShip 2.0: A large-volume dataset for deeper interpretation of ship targets in Sentinel-1 imagery[C]. 2017 SAR in Big Data Era: Models, Methods and Applications (BIGSAR DATA). IEEE, 2017: 1-5.
- [27] Hashemi N S, Aghdam R B, Ghiasi A S B, et al. Template matching advances and applications in image analysis[J]. arxiv preprint arxiv: 1610.07231, 2016.
- [28] Cheng J, Wu Y, AbdAlmageed W, et al. QATM: Quality-aware template matching for deep learning[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 11553-11562.
- [29] Somogyi F A, Asztalos M. Systematic review of matching techniques used in model-driven methodologies[J]. Software and Systems Modeling, 2020, 19(3): 693-720.
- [30] Balnarsaiah B, Rajitha G. Denoising and Optical and Sar Image Classifications Based on Feature Extraction and Sparse Representation[J]. arxiv preprint arxiv: 2106.01896, 2021.
- [31] Gao F, Huang T, Sun J, et al. A new algorithm for SAR image target recognition based on an improved deep convolutional neural network[J]. Cognitive Computation, 2019, 11: 809-824.
- [32] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [33] Chollet F. Xception: Deep learning with depthwise separable convolutions[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1251-1258.
- [34] Pei J, Huo W, Wang C, et al. Multiview deep feature learning network for SAR automatic target recognition[J]. Remote Sensing, 2021, 13(8): 1455.
- [35] Ding J, Chen B, Liu H, et al. Convolutional neural network with data augmentation for SAR target recognition[J]. IEEE Geoscience and remote sensing letters, 2016, 13(3): 364-368.
- [36] Su F, Lv Q, Luo R. Review of image classification based on deep learning[J]. Telecommunication science, 2019, 35(11): 58-74.
- [37] He K, Zhang X, Ren S, et al. Delving deep into rectifiers: Surpassing human-level performance on imagenet classification[C]. Proceedings of the IEEE international conference on computer vision.

- 2015: 1026-1034.
- [38] Feng X, Haipeng W, Yaqiu J. Deep learning as applied in SAR target recognition and terrain classification[J]. 雷达学报, 2017, 6(2): 136-148.
- [39] Hinton G E, Salakhutdinov R R. Reducing the dimensionality of data with neural networks[J]. science, 2006, 313(5786): 504-507.
- [40] Zhu Y, Ai J, Wu L, et al. An active multi-target domain adaptation strategy: Progressive class prototype rectification[J]. IEEE Transactions on Multimedia, 2024.
- [41] Chen S, Wang H, Xu F, et al. Target classification using the deep convolutional networks for SAR images[J]. IEEE transactions on geoscience and remote sensing, 2016, 54(8): 4806-4817.
- [42] Ai J, Mao Y, Luo Q, et al. SAR target classification using the multikernel-size feature fusion-based convolutional neural network[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 60: 1-13.
- [43] Hou B, Kou H, Jiao L. Classification of polarimetric SAR images using multilayer autoencoders and superpixels[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2016, 9(7): 3072-3081.
- [44] Soldin R J. SAR target recognition with deep learning[C]. IEEE Applied Imagery Pattern Recognition Workshop (AIPR). IEEE, 2018: 1-8.
- [45] Wang S, Wang Y, Liu H, et al. A few-shot SAR target recognition method by unifying local classification with feature generation and calibration[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 62: 1-19.
- [46] Wang Z, Xin Z, Liao G, et al. Land-sea target detection and recognition in SAR image based on non-local channel attention network[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1-16.
- [47] Zheng J, Li M, Li X, et al. Revisiting local and global descriptor-based metric network for few-shot SAR target classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-14.
- [48] Agadacos I, Agadacos N, Polakis J, et al. Deep complex networks for protocol-agnostic radio frequency device fingerprinting in the wild[J]. arxiv preprint arxiv:1909.08703, 2019.
- [49] Zhao B, Song Q, Li J, et al. High-frequency-link DC transformer based on switched capacitor for medium-voltage DC power distribution application[J]. IEEE Transactions on Power Electronics, 2015, 31(7): 4766-4777.
- [50] Wang Z, Wang R, Fu X, et al. Unsupervised ship detection for single-channel SAR images based on multiscale saliency and complex signal kurtosis[J]. IEEE Geoscience and Remote Sensing Letters, 2021, 19: 1-5.
- [51] Macchiarulo V, Giardina G, Milillo P, et al. Integrating post-event very high resolution SAR imagery and machine learning for building-level earthquake damage assessment[J]. Bulletin of Earthquake Engineering, 2024: 1-27.
- [52] Bi H, Bi G, Zhang B, et al. Complex-image-based sparse SAR imaging and its equivalence[J]. IEEE Transactions on Geoscience and Remote Sensing, 2018, 56(9): 5006-5014.

- [53] Chakraborty R. Manifoldnorm: Extending normalizations on riemannian manifolds[J]. arxiv preprint arxiv:2003.13869, 2020.
- [54] Raeker B O, Grbic A. Compound metaoptics for amplitude and phase control of wave fronts[J]. Physical Review Letters, 2019, 122(11): 113901.
- [55] Wilmanski M, Kreucher C, Hero A. Complex input convolutional neural networks for wide angle SAR ATR[C]. IEEE Global Conference on Signal and Information Processing (GlobalSIP). IEEE, 2016: 1037-1041.
- [56] Ding B, Wen G. Target reconstruction based on 3-D scattering center model for robust SAR ATR[J]. IEEE Transactions on Geoscience and Remote Sensing, 2018, 56(7): 3772-3785.
- [57] Li T, Du L. Target discrimination for SAR ATR based on scattering center feature and K-center one-class classification[J]. IEEE Sensors Journal, 2018, 18(6): 2453-2461.
- [58] Guberman N. On complex valued convolutional neural networks[J]. arxiv preprint arxiv:1602.09046, 2016.
- [59] Trabelsi C, Bilaniuk O, Zhang Y, et al. Deep complex networks[J]. arxiv preprint arxiv:1705.09792, 2017.
- [60] Zhang Z, Wang H, Xu F, et al. Complex-valued convolutional neural network and its application in polarimetric SAR image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2017, 55(12): 7177-7188.
- [61] Li L, Ma L, Jiao L, et al. Complex contourlet-CNN for polarimetric SAR image classification[J]. Pattern Recognition, 2020, 100: 107110.
- [62] Cao Y, Wu Y, Zhang P, et al. Pixel-wise PolSAR image classification via a novel complex-valued deep fully convolutional network[J]. Remote Sensing, 2019, 11(22): 2653.
- [63] Wang R, Wang Z, et al. Target recognition in single-channel SAR images based on the complex-valued convolutional neural network with data augmentation[J]. IEEE Transactions on Aerospace and Electronic Systems, 2022, 59(2): 796-804.
- [64] Sun Z, Xu X, Pan Z. SAR ATR using complex-valued CNN[C]. 2020 Asia-Pacific Conference on Image Processing, Electronics and Computers (IPEC). IEEE, 2020: 125-128.
- [65] Yu L, Hu Y, et al. Complex-valued full convolutional neural network for SAR target classification[J]. IEEE Geoscience and Remote Sensing Letters, 2019, 17(10): 1752-1756.
- [66] Zeng Z, Sun J, Han Z, et al. SAR automatic target recognition method based on multi-stream complex-valued networks[J]. IEEE transactions on geoscience and remote sensing, 2022, 60: 1-18.
- [67] Wang Z, Wang R, Kang H, et al. CV-SAR-Det: Target Detection for SAR Images via Deep Complex-Valued Network[J]. IEEE Transactions on Aerospace and Electronic Systems, 2024.
- [68] Wang R, Wang Z, Chen Y, et al. Target recognition in SAR images using complex-valued network guided with sub-aperture decomposition[J]. Remote Sensing, 2023, 15(16): 4031.
- [69] Zhao D, Zhang Z, Lu D, et al. Cvvgg-net: Ship recognition for sar images based on complex-valued convolutional neural network[J]. IEEE Geoscience and Remote Sensing Letters, 2023, 20: 1-5.
- [70] Hua Q, Zhang Y, Jiang Y, et al. CV-CFUNet: Complex-valued channel fusion UNet for refocusing of ship targets in SAR images[J]. IEEE Transactions on Aerospace and Electronic Systems, 2023,

- 59(4): 4478-4492.
- [71] Li C, Du L, Li Y, et al. A novel SAR target recognition method combining electromagnetic scattering information and GCN[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19: 1-5.
- [72] Deng J, Bi H, Zhang J, et al. Amplitude-phase CNN-based SAR target classification via complex-valued sparse image[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2022, 15: 5214-5221.
- [73] 雷禹, 冷祥光, 周晓艳. 基于改进 ResNet 网络的复数 SAR 图像舰船目标识别方法[J]. 系统工程与电子技术, 2022, 44(12): 3652-3660.
- [74] Liu Q, Lang L. MMFF: Multi-manifold feature fusion based neural networks for target recognition in complex-valued SAR imagery[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2021, 180: 151-162.
- [75] 贺丰收, 何友, 刘准钊, 徐从安. 卷积神经网络在雷达自动目标识别中的研究进展[J]. 电子与信息学报, 2020, 42(01): 119-131.
- [76] Tüchler M, Singer A C, Koetter R. Minimum mean squared error equalization using a priori information[J]. IEEE Transactions on Signal Processing, 2002, 50(3): 673-683.
- [77] Boer P T D, Kroese D P, Mannor S, et al. A tutorial on the cross-entropy method[J]. Annals of Operations Research, 2005, 134(1): 19-67.
- [78] Gan Y, Cong X, Yang Y. Structure-aware interrupted SAR imaging method for change detection[J]. IEEE Access, 2019, 7: 136391-136398.
- [79] Liu L, Jia Z, Yang J, et al. SAR image change detection based on mathematical morphology and the K-means clustering algorithm[J]. IEEE Access, 2019, 7: 43970-43978.
- [80] Wei Z, Zhang B, Wu Y. A SAR imaging method based on generalized minimax-concave penalty[J]. Science China. Information Sciences, 2019, 62(2): 29305.
- [81] 史鹤欢, 许悦雷, 马时平. PCA 预训练的卷积神经网络目标识别算法[J]. 西安电子科技大学学报, 2016, 43(3): 161-166.
- [82] 张敏, 许廷发. 基于 Gabor 小波纹理特征的目标识别新方法[J]. 物理实验, 2004, 24(4): 12-15.
- [83] 王璐, 张帆, 李伟. 基于 Gabor 滤波器和局部纹理特征提取的 SAR 目标识别算法[J]. 雷达学报, 2015, 4(6): 658-665.
- [84] Mish M D. A Self Regularized Non-Monotonic Activation Function. 2019[J]. arxiv preprint arxiv:1908.08681, 1908.
- [85] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.
- [86] Zhao H, Jia J, Koltun V. Exploring self-attention for image recognition[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 10076-10085.
- [87] Hendrycks D, Gimpel K. Gaussian error linear units (gelus)[J]. arxiv preprint arxiv:1606.08415, 2016.