

复杂杂波背景 SAR 图像舰船目标检测算法研究

作者姓名 王焱

指导教师姓名、职称 刘宏伟 教授

申请学位类别 工学博士

学校代码 10701
分类号 TP391

学号 20021110104
密级 公开

西安电子科技大学

博士学位论文

复杂杂波背景 SAR 图像舰船目标检测算法研究

作者姓名：王垚

一级学科：信息与通信工程

二级学科（研究方向）：信号与信息处理

学位类别：工学博士

指导教师姓名、职称：刘宏伟 教授

学 院：电子工程学院

提交日期：2025 年 6 月

Research on Algorithms for Ship Target Detection in SAR Images with Complex Clutter Backgrounds

A Thesis submitted to
XIDIAN UNIVERSITY
in partial fulfillment of the requirements
for the degree of Doctor
in Information and Communication Engineering

By
Wang Yao
Supervisor: Liu Hongwei Title: Professor
Jun 2025

摘要

合成孔径雷达 (Synthetic Aperture Radar, SAR) 具备穿透云雾、全天候成像的独特优势, 已成为当前海上舰船监测、海洋管理与海事安防等领域的重要遥感手段。SAR 成像遵循微波散射机制, 其图像在视觉特性上与光学图像存在本质差异。SAR 图像表现出强斑点噪声干扰、灰度值动态范围变化剧烈、结构纹理模糊等特性, 严重制约了舰船目标的精准识别与定位。SAR 图像中的舰船目标通常尺度较小、边界模糊, 且易被淹没在背景杂波中, 进一步加大了检测难度。受不同地理与气象条件影响, 海面电磁散射特性变化显著, 导致海杂波的统计分布呈现出高度非均质性与不可预测性, 显著增加了背景建模与特征提取的难度。在近岸或港口区域, 大量建筑物、码头、集装箱等强散射体的特征与真实舰船高度相似, 易造成伪目标干扰与目标遮挡, 模型在此类场景中出现较高的虚警率与漏检率。此外, SAR 数据的获取与标注成本显著高于光学图像, 导致可用于训练的高质量样本数量有限。受此影响, 训练数据在空间与场景分布上普遍稀疏, 且样本之间在难易程度上存在明显不均衡。这种样本数量不足与分布失衡的现象, 严重制约了数据驱动检测算法在复杂环境下的泛化能力与鲁棒性。杂波抑制、斑点噪声去除与目标检测通常被分离为独立任务进行训练, 缺乏跨任务的协同优化。这种割裂的训练方式在复杂杂波背景下难以充分发挥各任务间的互补优势, 导致网络表征能力受限、监督信号难以有效传导, 最终影响目标检测的精度与鲁棒性。目前, 大多数 SAR 目标检测方法仍直接借鉴光学图像的检测范式, 普遍忽视了 SAR 图像中存在的目标与背景对比度低、传统标签分配策略依赖超参数缺乏对模型学习状态的动态适应、小目标占比较大、近岸伪目标干扰频发等关键问题。为应对上述挑战, 本文结合 SAR 图像的成像机理与干扰特性, 围绕舰船目标专用检测算法开展系统性研究, 分别从模型优化、数据增强、任务辅助与上下游联合学习等层面切入, 致力于突破传统方法在复杂杂波环境下的性能瓶颈, 提升舰船目标检测的精度与鲁棒性。本文核心工作与创新主要包括以下四个方面:

- 1、针对 SAR 图像中小目标占比多检测难度大以及传统检测方法的固定标签分配策略导致训练与测试目标不一致的问题, 本文提出了一种预测感知的 SAR 检测模型改进策略。本文的标签分配策略旨在利用模型预测结果来自适应分配正样本, 并同时考虑候选框的置信度、定位精度以及先验信息设计综合评价函数, 从而选择最优正样本。训练过程中正负样本的划分自动完成, 从而避免了人工设定划分样本规则的局限性, 也避免超参数的引入带来的额外工作和超参数不当设置导致的性能下降。预测感知的 SAR 检测模型改进策略设计了一种新的特征金字塔网络, 采用并行通道

分别综合低分辨率与高分辨率特征，并通过自适应空间特征融合模块实现跨层信息融合与增强，进一步提升目标多尺度检测能力。实验结果显示，该方法显著提高了多个检测模型的目标检测精度和定位准确性，在不同公开数据集上都有检测性能的明显提升。预测感知的 SAR 检测模型改进策略可以移植到不同检测范式，具有很好的可移植性和通用性。

2、针对 SAR 舰船数据标注困难、背景类型单一、缺乏复杂海况信息等问题，本文提出了杂波随机采样融合的 SAR 数据增强策略，旨在增加训练数据多样性与复杂程度。首先杂波随机采样融合的 SAR 数据增强策略从实测数据中提取杂波（即不含目标区域），也可以利用统计模型生成仿真杂波，构建具有多样性与代表性的杂波集。然后，所提方法通过设计三种不同的杂波与 SAR 样本融合方式自适应增强数据。上述数据增强模式包括：加法融合（线性叠加真实杂波与原图）、乘法融合（利用非线性乘法模拟复杂干扰）以及目标保护（在融合过程中保持目标区域不变）三种模式。杂波随机采样融合的 SAR 数据增强策略将杂波信息动态注入到 SAR 图像中，显著扩充了原始样本中的杂波强度及种类。并且所提方法数据增强后，目标位置未曾发生改变，也没有引入任何虚假目标。因此原始标注可以在直接使用。杂波随机采样融合的 SAR 数据增强策略使得生成样本复杂程度明显提升，完成训练后模型应对极端状况的能力得到大幅度提高。杂波随机采样融合的 SAR 数据增强策略可任意选取在线或离线模式，并且在线模式训练批次每次迭代数据增强情况都不相同，所提方法这一特点可以有效缓解过拟合。大量实验结果表明，杂波随机采样融合的 SAR 数据增强策略大幅提升检测模型准确率与召回率，并且没有引入额外的模型参数和推理时间。

3、针对近岸场景因陆地引发的强杂波干扰问题，本文提出背景移除辅助的 SAR 舰船检测策略。所提方法由背景去除子网络和检测子网络组成一个统一框架联合训练。背景移除模块采用 U-Net 范式结构，结合多分辨率输出策略在不同尺度实施高效监督学习。背景去除网络在抑制杂波干扰与噪声污染时，有效保护舰船目标的空间结构特征与电磁散射特征。经过背景移除处理得到的结果直接输入检测网络。杂波和噪声影响了目标边界，检测网络的精度提升需要联合优化机制，本研究为此设计了新的检测辅助一致性损失（Detection-Assisted Consistency Loss, DACL）。DACL 利用背景去除结果与 Ground Truth 输入检测网络所得的置信度及定位信息，动态指导背景去除模块进行训练，去背景后的图像不单视觉清晰度提高，其包含的语义信息亦倾向于检测任务的需要。经由端到端联合优化降低原始图像中背景干扰，凸显目标信息。所提方法的模块化设计有着高度灵活性，使其易于集成到其它检测网络、具备广泛的适应性与持续更新能力。实验结果显示背景移除辅助的 SAR 舰船检测策略能显著降低误检和漏检、明显提升平均准确率。

4、针对实测数据中目标易被遮挡，舰船与杂波难以进行区分，现有方法存在鲁

棒性不足的问题，本文构建了杂波抑制与舰船检测联合学习策略，以实现对 SAR 数据进行杂波注入、杂波抑制和目标检测。杂波注入可以模拟极端复杂杂波场景，杂波抑制与目标检测任务在端到端框架内协同优化。所提方法将杂波注入、杂波抑制和目标检测三个阶段有机整合，通过杂波增强学习策略，实现各模块之间的互相反馈与共同进步。具体方法是：首先利用杂波注入模块生成高复杂度训练样本，再由杂波抑制模块进行杂波与噪声的去除，最后由检测网络完成目标的定位与分类。实验表明，在不同数据集中，杂波抑制与舰船检测联合学习策略带来明显的性能提升。并且由于杂波抑制网络的轻量化设计，所提方法引入的额外计算开销有限，易于实际部署与落地应用。

关键词：复杂场景， 舰船检测， 标签分配策略， 数据增强， 多任务联合

ABSTRACT

Synthetic Aperture Radar (SAR) possesses unique advantages such as cloud-penetrating and all-weather imaging capabilities, making it an important remote sensing tool in maritime ship monitoring, ocean management, and maritime security. SAR imaging follows the microwave scattering mechanism, resulting in fundamental differences in visual characteristics compared to optical images. SAR images typically exhibit severe speckle noise interference, dramatic variations in grayscale dynamic range, and blurred structural textures, which significantly hinder the accurate identification and localization of ship targets. Ships in SAR images are generally small in scale, with indistinct boundaries, and are often submerged in complex background clutter, further increasing detection difficulty. Due to variations in geography and weather conditions, sea surface electromagnetic scattering characteristics change significantly, causing the statistical distribution of sea clutter to be highly non-homogeneous and unpredictable, which greatly complicates background modeling and feature extraction. In near-shore or port areas, strong scatterers such as buildings, docks, and containers often exhibit similar scattering features to real ships, easily leading to false targets and occlusion interference, resulting in high false alarm and missed detection rates. Moreover, the acquisition and annotation costs of SAR data are significantly higher than those of optical images, leading to a limited number of high-quality samples available for training. As a result, the training data is generally sparse in spatial and scene distribution, and there is a noticeable imbalance in sample difficulty. This scarcity and imbalance of training samples severely constrain the generalization and robustness of data-driven detection algorithms in complex environments. Speckle suppression, noise removal, and target detection are typically handled as independent tasks, lacking collaborative optimization across them. This separate training approach fails to exploit the complementary advantages among tasks under complex clutter conditions, thus limiting the network's representational capacity and weakening the effectiveness of supervisory signals, ultimately degrading detection accuracy and robustness. At present, most SAR target detection methods directly adopt the detection paradigms of optical imagery, generally neglecting key challenges such as the low contrast between targets and background in SAR images, the use of fixed label assignment strategies that rely on hyperparameters and lack dynamic adaptation to the model's learning status, the predominance of small targets, and frequent false target interference in near-shore scenarios. To address these challenges, this paper conducts systematic research on ship-specific detection

algorithms based on SAR imaging mechanisms and interference characteristics. From the perspectives of model optimization, data augmentation, task assistance, and joint learning of upstream and downstream tasks, this work aims to overcome the performance bottlenecks of traditional methods in complex cluttered environments and enhance the accuracy and robustness of ship target detection. The main contributions and innovations of this paper are summarized in the following four aspects:

1. To address the challenge of detecting small targets in SAR images, where small targets occupy a large proportion, and the issue of fixed label assignment in traditional detection methods that leads to inconsistencies between training and testing targets, this dissertation proposes a prediction-aware SAR detection model improvement strategy. The proposed label assignment strategy adapts the allocation of positive samples based on the model's prediction results. It simultaneously considers the confidence, localization accuracy, and prior information of candidate boxes, designing a comprehensive evaluation function to select the optimal positive samples. During training, the division of positive and negative samples is automatically completed, avoiding the limitations of manually set sample division rules and the additional workload and performance degradation caused by improper hyperparameter settings. The predictive-aware SAR detection model improvement strategy designs a novel feature pyramid network, which uses parallel channels to integrate low-resolution and high-resolution features. The adaptive spatial feature fusion module is employed to achieve cross-layer information fusion and enhancement, further improving the model's multi-scale detection ability. Experimental results show that this method significantly improves the target detection accuracy and localization precision of multiple detection models, with clear performance improvements across various publicly available datasets. The prediction-aware SAR detection model improvement strategy is highly portable and can be applied to different detection paradigms.

2. To address the challenges of difficult data annotation, limited background types, and lack of complex sea conditions in SAR ship data, this dissertation proposes a clutter random sampling transfer-based SAR data augmentation strategy aimed at increasing the diversity and complexity of training data. The proposed strategy first extracts clutter (areas without targets) from real-world data, or generates simulated clutter using statistical models, thereby constructing a diverse and representative clutter set. Then, the method employs three different clutter and SAR sample fusion methods to adaptively augment the data. The three data augmentation modes include: additive fusion (linear superposition of real clutter and original image), multiplicative fusion (non-linear multiplication to simulate complex inter-

ference), and target protection (maintaining the target region unchanged during fusion). The clutter random sampling fusion-based SAR data augmentation strategy dynamically injects clutter information into SAR images, significantly expanding the clutter intensity and variety in the original samples. Moreover, after the data augmentation, the target positions remain unchanged, and no false targets are introduced, thus allowing the original annotations to be directly used. This strategy significantly enhances the complexity of the generated samples, improving the model's ability to adapt to extreme scenarios after training. The data augmentation strategy can be used in both online and offline modes, and in the online mode, the data augmentation condition for each iteration varies, effectively mitigating overfitting. Extensive experimental results show that the clutter random sampling fusion-based SAR data augmentation strategy greatly improves the detection model's accuracy and recall rate without introducing additional model parameters or inference time.

3. To address the strong clutter interference caused by land in inshore scenes, this dissertation proposes a background removal-aided SAR ship detection strategy. The proposed method consists of a background removal sub-network and a detection sub-network, forming a unified framework for joint training. The background removal module adopts a U-Net structure, combined with a multi-resolution output strategy to implement efficient supervised learning at different scales. The background removal network effectively suppresses clutter interference and noise pollution while protecting the spatial and electromagnetic scattering characteristics of ship targets. The result of background removal is directly input into the detection network. Since clutter and noise affect target boundaries, the detection network's precision needs joint optimization. To address this problem, this study designs a novel Detection-Assisted Consistency Loss (DACL). DACL dynamically guides the training of the background removal module by utilizing the confidence and localization information obtained from the background removal results and Ground Truth input into the detection network. The background-removed images not only exhibit improved visual clarity but also align with the semantic requirements of the detection task. Through this end-to-end joint optimization mechanism, the background removal module effectively reduces background interference in the original image, highlighting target information. The modular design of the proposed method provides high flexibility, making it easy to integrate with other detection networks and ensuring broad adaptability and continuous update capability. Experimental results show that the background removal-aided SAR ship detection strategy significantly reduces false detections and missed detections while improving the mean accuracy.

4. To address the issue of target occlusion in real-world data and the difficulty of distinguish-

ing ships from clutter, leading to insufficient robustness in existing methods, this dissertation constructs a joint learning strategy for clutter suppression and ship detection to perform clutter injection, clutter suppression, and target detection on SAR data. Clutter injection simulates extremely complex clutter scenarios, and the clutter suppression and target detection tasks are optimized in an end-to-end framework. The proposed method integrates clutter injection, clutter suppression, and target detection into three stages, achieving mutual feedback and joint progress among the modules through a clutter enhancement learning strategy. Specifically, the method first uses the clutter injection module to generate high-complexity training samples, then applies the clutter suppression module to remove clutter and noise, and finally uses the detection network for target localization and classification. Experimental results show that the joint learning strategy for clutter suppression and ship detection brings significant performance improvements across different datasets. Additionally, due to the lightweight design of the clutter suppression network, the proposed method introduces minimal additional computational overhead, making it suitable for practical deployment and real-world applications.

Keywords: Complex environment, Ship detection, Label assignment strategy, Data augmentation, Multi-task collaboration

插图索引

图 1.1	上海地区 GF-3 号星载场景	1
图 1.2	美国北卡罗来纳州沿海地区 AIRSAR 机载场景	2
图 1.3	小目标样本, 图片来自 SSDD 数据集	9
图 1.4	常用 SAR 舰船数据集目标尺度分布统计	10
图 1.5	标注软件 LabelImg 界面展示	11
图 1.6	复杂杂波样本, 图片来自 SSDD 数据集	12
图 1.7	常用 SAR 舰船数据集信杂比分布统计	12
图 1.8	论文组织结构框图	13
图 2.1	杂波统计建模与 CFAR 结果分析, 图片来自 SSDD 数据集	20
图 2.2	单阶段与两阶段检测框架对比图	22
图 2.3	CerterNet 预测输出结果	24
图 2.4	SAR 深度学习舰船检测算法框图	25
图 2.5	FPN、PANet 与 BiFPN 结构对比图	28
图 2.6	IoU 与 DIoU 计算过程示意图	29
图 2.7	NMS 结果示意图	30
图 2.8	SSDD 数据集舰船目标的数据统计分析	33
图 2.9	HRSID 数据集舰船目标的数据统计分析	35
图 3.1	训练目标与测试目标严重不一致的可视化实例	40
图 3.2	预测和先验信息引导的标签分配	41
图 3.3	置信度与交并比预测之间的差异	43
图 3.4	先验知识计算的示意图	45
图 3.5	3*3 标准卷积和可变形卷积的采样位置示意图	48
图 3.6	特征金字塔网络设计对比图	49
图 3.7	MSDNet 网络结构图	50
图 3.8	ASFF 模块示意图	51
图 3.9	不同特征金字塔在 HRSID 数据集上的检测可视化结果。	55
图 3.10	YOLO V4 中所有正确检测到的目标与所提方法的平均 IoU 比较图 . .	62
图 3.11	SSDD 数据集上 YOLO V4 与 MSDNet (PPIG) 的可视化检测结果对比	63
图 3.12	HRSID 数据集上 YOLO V4 与 MSDNet (PPIG) 的可视化检测结果对比	64
图 3.13	不同检测网络的 FLOPs、模型大小和参数大小	65

图 3.14	MSDNet 与其它方法在检测速度、模型参数量及平均精度上的综合对比	66
图 3.15	MSDNet (PIIG) 失败案例可视化	67
图 4.1	光学图像和 SAR 图像舰船目标的比较	70
图 4.2	SAR 图像中噪声与杂波的比较	71
图 4.3	SAR 舰船检测中的简单和复杂场景	72
图 4.4	两种常用的光学数据增强技术的可视化结果	72
图 4.5	SAR 图像与杂波随机采样与自适应融合的舰船检测算法	74
图 4.6	五种基于统计模型生成的海杂波与真实海杂波的对比	75
图 4.7	WGAN 生成的杂波数据	78
图 4.8	CRSA 算法框架	79
图 4.9	CRSA 融合过程中统计模型生成的杂波的可视化结果	82
图 4.10	CRSA 融合过程中真实杂波的可视化结果	83
图 4.11	去斑结果可视化	85
图 4.12	不同去斑方法在 SSDD 数据集检测性能比较	85
图 4.13	叠加统计模型生成杂波的结果可视化	86
图 4.14	SSDD 数据集中叠加不同统计模型杂波的性能比较	87
图 4.15	YOLO V7 模型部署、不部署 CRSA 在不同数据集上损失下降情况	96
图 5.1	MSDNet 的近岸场景中检测失败案例	100
图 5.2	本章提出方法 SAR-BRADet 示意图	101
图 5.3	来自 HRSID 数据集的近岸场景分析	103
图 5.4	背景移除网络具体结构图	105
图 5.5	背景移除辅助的 SAR 近岸舰船检测框架图	106
图 5.6	背景移除标签获取过程	108
图 5.7	杂波抑制方法和本章背景抑制结果可视化	109
图 5.8	海陆分割结果、对应原始 SAR 图像与背景过滤图片实例	111
图 5.9	比较原始 SAR 图片、背景移除结果与背景移除 GT	116
图 5.10	本章方法检测结果示例	117
图 6.1	杂波抑制与舰船检测联合框架图	123
图 6.2	Rolling-Unet 的整体架构图	124
图 6.3	DOR 整体架构图	125
图 6.4	Lo2 结构图	126
图 6.5	杂波抑制输入与标签可视化	127
图 6.6	本章方法的检测结果示例	130

表格索引

表 1.1	不同平台搭载的 SAR 系统	3
表 1.2	SAR 舰船检测数据集切片数量与目标数量	11
表 2.1	不同特征提取网络在 YOLO V4 目标检测框架下的性能对比	26
表 2.2	SAR 舰船检测中的混淆矩阵指标定义	37
表 3.1	可变形卷积的小舰船检测网络在 SSDD 数据集实验结果	48
表 3.2	使用不同指标作为候选框得分的实验结果	52
表 3.3	不同模块对 SSDD 上检测性能的影响	53
表 3.4	PANet 与 MLFF 在 SSDD 上检测性能的对比实验结果	54
表 3.5	PPIG 模块在不同检测框架上的实验结果	56
表 3.6	不同标签分配方法的性能对比	57
表 3.7	本章所提方法在 HRSID 数据集上的影响	58
表 3.8	标签分配方法的研究结果	59
表 3.9	基于 CNN 方法在 SSDD 数据集上的检测结果对比	60
表 3.10	基于 CNN 方法在 HRSID 数据集上的检测结果对比	61
表 4.1	CRSA 与数据增强技术在 SSDD 数据集中的性能比较	88
表 4.2	融合真实杂波的 CRSA 在 SSDD 上的实验结果	90
表 4.3	融合真实杂波的 CRSA 在 HRSID 上的实验结果	92
表 4.4	融合仿真杂波的 CRSA 在 SSDD 上的实验结果	93
表 4.5	融合仿真杂波的 CRSA 在 HRSID 上的实验结果	94
表 5.1	杂波抑制方法与所提方法在 SSDD 性能对比	110
表 5.2	本章方法与海陆分割方法对比结果	112
表 5.3	SAR-BRADet 在 SSDD 近岸数据集上的消融实验结果	113
表 5.4	SAR-BRADet 在 HRSID 近岸数据集上的消融实验结果	114
表 5.5	不同检测模型在 SSDD 数据集上的性能对比	115
表 6.1	SSDD 数据集上的实验结果	128
表 6.2	HRSID 数据集上的实验结果	128
表 6.3	SAR-CSNet 在 HRSID 数据集上的计算复杂度分析	129

符号对照表

符号	符号名称
TP	正确检测出的舰船目标数目
FP	错误地将背景或其他非舰船目标误检测为舰船的数目
FN	实际存在但未被检测器检测出的舰船目标数目
AP	平均准确率
$p(r)$	召回率为 r 时的准确率
β	尺度参数
$f(\cdot)$	概率密度函数
α	形状参数
$I(x, y)$	图像强度
$S(x, y)$	目标或地物的真实散射系数
$N(x, y)$	乘性噪声或散斑噪声
$conf(\omega, i)$	相应候选锚框的预测置信度得分
$pred_IoU(\omega, i)$	锚框与目标之间的预测交并比
$\delta(\omega, i)$	候选框评分函数
$\mathcal{R}$	卷积核的标准采样区域
$w(p_n)$	卷积核权重
Δp_n	网络通过反向传播自动学习得到的偏移量
$X^{P_a \rightarrow P_b}$	从 P_a 调整到 P_b 后的特征图
$L_{mse}(\cdot)$	均方误差损失函数
$L_{SSIM}(\cdot)$	结构相似度损失函数
DAKL	检测辅助一致性损失函数

缩略语对照表

缩略语	英文全称	中文对照
SAR	Synthetic Aperture Radar	合成孔径雷达
CFAR	Constant False-Alarm Rate	恒虚警率
LBP	Local Binary Pattern	局部二值模式
DSC	Depthwise Separable Convolution	深度可分离卷积
FPN	Feature Pyramid Network	特征金字塔网络
AP	Average Precision	平均准确率
GAN	Generative Adversarial Network	生成对抗网络
SNR	Signal-to-Noise Ratio	信噪比
SCR	Signal-to-Clutter Ratio	信杂比
PDF	Probability Density Function	概率密度函数
MSE	Mean Square Error	均方误差
SE	Squeeze-and-Excitation	挤压-激励
NAS	Neural Architecture Search	神经架构搜索
LC	Lateral Connections	横向连接
BPA	Bottom-up Path Augmentation	自底向上的信息流
AFP	Adaptive Feature Pooling	自适应特征池化
PANet	Path Aggregation Network	路径聚合网络
BiFPN	Bidirectional Feature Pyramid Network	双向特征金字塔网络
BCF	Bidirectional Cross-Scale Fusion	双向特征融合
LWF	Learnable Weighted Fusion	可学习的特征融合权重
EFR	Efficient Feature Refinement	冗余连接优化
LD	Lightweight Design	轻量化设计
IoU	Intersection over Union	交并比
DIoU	Distance Intersection over Union	距离交并比
NMS	Non-Maximum Suppression	非极大值抑制
RPN	Region Proposal Network	区域提议网络
RoI	Region of Interest	感兴趣区域
RoI Align	Region of Interest Alignment	感兴趣区域对齐
YOLO	You Only Look Once	你只看一次

SSD	Single Shot Multibox Detector	单次检测多框检测器
R-CNN	Regions with CNN features	区域卷积神经网络
FCOS	Fully Convolutional One-Stage	全卷积单阶段
mAP	Mean Average Precision	均值平均准确率
SSDD	SAR Ship Detection Dataset	SAR 舰船检测数据集
HRSID	High-Resolution SAR Image Dataset	高分辨率 SAR 图像数据集
NLM	Non-Local Means	非局部均值
DC	Deformable Convolution	可变形卷积
BN	Batch Normalization	批量归一化
GN	Group Normalization	组归一化
PSFF	Shallow Feature Fusion Module	浅层特征融合模块
FPS	Frames Per Second	帧率
PPIG	Prior and Prediction Information Guided	预测与先验信息引导
MSDNet	Multi-scale Ship Detection Network	多尺度舰船检测网络
ASFF	Adaptive Spatial Feature Fusion Module	自适应空间特征融合模块
MLFF	Multi-Level Feature Fusion	多层特征融合
ATSS	Adaptive Training Sample Selection	自适应训练样本选择
o2o	One-to-One Label Assignment	一对一标签分配
POTO	Prediction-aware One-To-One	预测感知一对一分配
GPU	Graphics Processing Unit	图形处理单元
CPU	Central Processing Unit	中央处理器
CUDA	Compute Unified Device Architecture	统一计算设备架构
cuDNN	CUDA Deep Neural Network library	CUDA 深度神经网络库
SAR	Synthetic Aperture Radar	合成孔径雷达
BRNet	Background Removal Network	背景移除网络
DACL	Detection-assisted Consistency Loss	检测辅助一致性损失
DSP	Down-Sampling Process	下采样过程
USP	Up-Sampling Process	上采样过程
SSIM	Structural Similarity Index Measure	结构相似性指标
GT	Ground Truth	地面真实标签
SmoothL1	Smooth L1 Loss	平滑 L1 损失
CNN	Convolutional Neural Network	卷积神经网络
MSDNet	Multi-scale Ship Detection Network	多尺度舰船检测网络
AWF	Adaptive Wiener Filter	自适应维纳滤波器

缩略语对照表

R-MLP	Rolling-MLP	滚动多层感知机模块
MLP	Multilayer Perceptron	多层感知机
OR-MLP	Orthogonal Rolling-MLP	正交滚动多层感知机模块
DOR-MLP	Double Orthogonal Rolling-MLP	双正交滚动多层感知机模块
Lo2	Long-Local Block	长局部块
LayerNorm	Layer Normalization	层归一化
CM	Channel Mixing	通道混合操作
STAP	Space-Time Adaptive Processing	空间-时间自适应处理
RSVA	Robust Spatially Variant Apodization	鲁棒空间变窗加权函数
SRGAN	Super Resolution GAN	超分辨率生成对抗网络
RDN	Residual Dense Network	残差密集网络
SAR-CSNet	SAR Clutter Suppression Network	SAR 杂波抑制网络
GFLOPs	Giga Floating-point Operations	十亿次浮点运算
DPM	Deformable Parts Model	可变形部件模型
HOG	Histogram of Oriented Gradients	方向梯度直方图
SIFT	Scale-Invariant Feature Transform	尺度不变特征变换

目 录

第一章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	3
1.2.1 图像视觉目标检测算法.....	4
1.2.2 数据驱动的 SAR 舰船检测算法.....	6
1.3 面临的问题与挑战.....	8
1.3.1 场景大目标小.....	9
1.3.2 数据多标注难.....	10
1.3.3 背景强目标弱.....	11
1.3.4 上下游任务缺少关联.....	13
1.4 本文主要内容与章节安排	14
1.4.1 论文主要内容.....	14
1.4.2 章节安排.....	16
第二章 SAR 舰船检测算法基础.....	19
2.1 SAR 舰船检测典型算法原理.....	19
2.1.1 统计建模的 SAR 目标检测算法.....	19
2.1.2 算法框架.....	21
2.1.3 模型结构概述.....	25
2.1.4 学习策略.....	31
2.2 SAR 舰船检测数据集.....	32
2.2.1 SSDD 数据集介绍	32
2.2.2 HRSID 数据集介绍.....	34
2.3 SAR 舰船检测评价指标.....	36
2.4 本章小结.....	37
第三章 预测感知的 SAR 多尺度目标检测模型	39
3.1 引言.....	39
3.2 模型预测与先验信息引导的标签分配策略	41
3.2.1 原理介绍.....	41
3.2.2 交并比预测.....	42
3.2.3 标签分配方法实现.....	44
3.3 多尺度舰船检测框架.....	46
3.3.1 可变形卷积的舰船检测网络.....	46
3.3.2 多尺度目标检测网络结构.....	49
3.4 实验结果分析.....	52

3.4.1 实验设置.....	52
3.4.2 消融实验结果与分析.....	52
3.4.3 对比实验结果与分析.....	58
3.4.4 计算复杂度分析.....	65
3.4.5 失败案例分析.....	66
3.5 本章小节.....	68
第四章 杂波随机采样迁移的 SAR 数据增强技术	69
4.1 引言.....	69
4.1.1 SAR 图像中杂波形成分析.....	70
4.1.2 样本分布不均衡问题.....	71
4.1.3 视觉图像的样本增强技术.....	72
4.2 杂波迁移的数据增强策略	73
4.2.1 算法整体框架.....	74
4.2.2 杂波特性分析.....	75
4.2.3 杂波随机融合的样本扩充方法.....	79
4.3 实验设置说明.....	84
4.4 实验结果与分析.....	84
4.4.1 与去斑检测级联策略的性能对比.....	84
4.4.2 与直接叠加杂波策略的性能对比.....	86
4.4.3 与通用数据增强方法的性能对比.....	88
4.4.4 真实杂波随机采样融合的实验结果	89
4.4.5 统计分布采样迁移的实验结果.....	92
4.4.6 损失下降情况说明.....	95
4.4.7 实验小结.....	96
4.5 本章小结.....	97
第五章 SAR 图像背景移除辅助的目标检测方法	99
5.1 引言.....	99
5.1.1 问题描述.....	100
5.1.2 相关方法简介.....	102
5.2 背景移除辅助的目标检测方法	104
5.2.1 背景移除网络的作用与设计.....	104
5.2.2 SAR 近岸舰船检测框架.....	105
5.2.3 训练策略.....	106
5.3 实验结果分析.....	109
5.3.1 实验设置细节.....	109
5.3.2 与杂波抑制方法的性能对比.....	110
5.3.3 与海陆分割方法的性能对比.....	111
5.3.4 消融实验.....	112

5.3.5 对比实验.....	114
5.4 本章小结.....	116
第六章 SAR 图像杂波抑制与目标检测联合学习策略	119
6.1 引言.....	119
6.2 杂波抑制与舰船检测联合学习策略	122
6.2.1 整体框架.....	122
6.2.2 杂波抑制网络.....	123
6.3 实验结果分析.....	126
6.3.1 实验设置细节.....	126
6.3.2 实验结果与分析.....	127
6.3.3 计算复杂度分析.....	129
6.4 本章小结.....	130
第七章 总结与展望	131
7.1 总结.....	131
7.2 展望.....	132
7.2.1 多模态数据融合不足.....	132
7.2.2 轻量化网络设计挑战.....	132
7.2.3 实时性检测的难题.....	132
7.2.4 硬件加速与软硬协同设计.....	133
参考文献.....	135

第一章 绪论

1.1 研究背景与意义

合成孔径雷达（Synthetic Aperture Radar, SAR）技术因其全天候、全天时成像能力^[1]，已成为海洋监测、军事侦察与环境感知的核心技术手段。SAR 舰船检测是遥感数据解译领域最具挑战性的问题之一，也是计算机视觉^[2]、雷达信号处理^[3]、海洋科学等跨学科协作的研究方向，应用价值则涵盖国家安全、海运、渔业管控、应急管理^[4]等。当前，星载 SAR 与机载 SAR 系统在全球范围内均得到了广泛应用，并在海洋监测、军事侦察、环境遥感等领域发挥着重要作用^[4]。星载 SAR 系统依托卫星平台，实现大范围、周期性观测，代表性系统包括欧洲的 Sentinel-1^[5]、加拿大的 RADARSAT 系列等^[6]。星载系统依托轨道高度优势，实现大范围、周期性的海洋监测。上海地区 GF 星载场景如图 1.1 所示。星载 SAR 系统受限于平台高度与入射角约束，目标散射特征呈现规律性衰减，导致小尺寸舰船易被海杂波淹没。此外，星载 SAR 系统由于其固定重访周期的特性导致难以捕捉高速机动目标的轨迹变化。



图 1.1 上海地区 GF-3 号星载场景

机载 SAR 系统则凭借灵活的任务规划和高分辨率成像能力^[7]，广泛用于战术侦察和精细目标识别，例如美国的 UAVSAR^[8]、德国的 E-SAR^[9] 和中国的 CASMSAR^[10]

等。随着传感器技术的进步,星载与机载 SAR 正向多频段、多极化和干涉测量方向发展^[11],不断提升 SAR 传感器在复杂环境下的探测能力和信息获取精度。美国北卡罗来纳州沿海地区 AIRSAR 机载场景如图1.2所示。机载系统通常可以保持飞行高度 3-12km 并通过灵活的航迹规划,可获取更高分辨率与多角度观测数据。机载 SAR 图像细节能清晰反映舰船结构特征,在近岸复杂环境,特别是港口、岛屿群中具有精细目标识别优势。但机载 SAR 系统易受平台运动稳定性限制,获得的图像易受大气扰动与姿态漂移影响,导致广域连续监测能力较弱^[12]。




图 1.2 美国北卡罗来纳州沿海地区 AIRSAR 机载场景

星载数据侧重舰船宏观语义信息^[13],而机载数据依赖局部纹理与几何特征解析^[14]。因此,星载场景检测需平衡计算效率与广域覆盖^[15],而机载场景检测强调复杂背景抑制与特征增强^[16]。对于应用领域,星载更多服务于海洋态势感知,而机载较多聚焦战术级目标辨识,如可疑船只分类^[2]。

随着星载、机载与无人机载 SAR 传感器的快速发展,全球 SAR 数据量呈现指数级增长。以欧洲航天局 (ESA) 的 Sentinel-1 为例,自 2014 年部署以来,已累计获取超过 10PB 的海洋与陆地观测数据^[17],覆盖极地至赤道区域,重访周期缩短至 6 天,空间分辨率达 5 米^[18]。此外,高分辨率商业卫星 (如德国 TerraSAR-X^[19]、意大利 COSMO-SkyMed^[20]、中国 GF-3^[21]) 及机载系统 (如美国 UAVSAR^[22]、中国 CASMSAR^[23]) 的广泛应用,推动了 SAR 技术向多频段 (L/C/X/Ku)、多极化 (全极化、双极化) 及多模式 (聚束、条带、扫描) 方向演进^[24]。例如,中国 GF-3 卫星的 C 波段全极化数据可实

现舰船目标与海洋杂波的高对比度分离^[25]，而阿根廷 SAOCOM 卫星的 L 波段数据在植被覆盖区域的穿透性优势显著^[26]，为近岸复杂环境监测提供了新途径。表1.1系统梳理了当前主流 SAR 平台的技术参数。从 1978 年首颗星载 SAR 卫星 SEASAT(HH 极化)^[27] 到 2023 年即将发射的 NISAR(L/S 双频全极化)^[28]，SAR 系统在频段选择、极化方式和工作模式等方面持续创新。值得注意的是，无人机载系统发展迅猛，美国 Lynx SAR(X 波段)^[29] 和中国 C-SAR(X 波段全极化)^[30] 已实现 <0.5m 分辨率下的实时成像，为战术级海洋监测提供新的解决方案。

表 1.1 不同平台搭载的 SAR 系统

名称	国家/地区	启用/发射时间	极化方式	研发机构
星载 SAR 系统				
SEASAT	美国	1978	单极化 (HH)	NASA/JPL
SIR-C	美国	1994	多频多极化 (L/C/X 波段)	NASA/JPL
RADARSAT-1	加拿大	1995	单极化 (HH)	CSA/MDA
ENVISAT-ASAR	欧洲	2002	双极化 (HH/HV 或 VV/VH)	ESA
ALOS-PALSAR	日本	2006	全极化 (L 波段)	JAXA
TerraSAR-X	德国	2007	全极化 (X 波段)	DLR/Airbus
COSMO-SkyMed	意大利	2007-2010	双极化 (X 波段)	ASI/Thales Alenia Space
RADARSAT-2	加拿大	2007	全极化 (C 波段)	CSA/MDA
Sentinel-1	欧洲	2014-2016	双极化 (C 波段)	ESA
GF-3	中国	2016	全极化 (C 波段)	中国航天科技集团
SAOCOM-1A/1B	阿根廷	2018/2020	全极化 (L 波段)	CONAE
NISAR	美国/印度	2023 (计划)	全极化 (L/S 波段)	NASA/ISRO
RADARSAT Constellation	加拿大	2019	全极化 (C 波段)	CSA/MDA
机载 SAR 系统				
AIRSAR	美国	1988	全极化 (P/L/C 波段)	NASA/JPL
E-SAR	德国	1990s	L 波段 (全极化)	DLR
UAVSAR	美国	2009	全极化 (L 波段)	NASA/JPL
PISAR	日本	1996	全极化 (L 波段)	JAXA/NICT
CASMSAR	中国	2010s	全极化 (X/C 波段)	中科院电子所
MEMPHIS	法国	2000s	全极化 (X 波段)	ONERA
无人机载 SAR 系统				
Lynx SAR	美国	2000s	X/Ku 波段 (MQ-9 主要为 X 波段)	General Atomics
MiniSAR	美国	2006	单极化/双极化 (X 波段)	Sandia National Laboratories
C-SAR	中国	2010s	全极化 (X 波段)	CETC 38 所
Heron SAR	以色列	2010s	单极化 (X 波段)	IAI/ELTA Systems
SABER	英国	2018	双极化 (Ku 波段)	BAE Systems

1.2 国内外研究现状

目标检测作为计算机视觉的核心任务，经历了从手工特征到深度学习的范式革新。早期研究以可变形部件模型 (Deformable Parts Model, DPM) 为代表，常用特征算法包括方向梯度直方图 (Histogram of Oriented Gradients, HOG) 和尺度不变特征变换 (Scale-Invariant Feature Transform, SIFT) 等。上述人工设计特征结合滑动窗口与 SVM 分类器实现目标定位，但其依赖特征工程且对尺度、形变敏感。随着深度学习兴起，CNN 彻底改变了目标检测技术路径：R-CNN 系列通过区域提议网络与特征金

字塔实现端到端检测，YOLO 系列提出单阶段检测框架兼顾速度与精度，SSD 则融合多尺度特征提升小目标检测能力。近年来，轻量化设计成为重要方向，MobileNet、ShuffleNet 等网络通过新的卷积方式降低计算量，知识蒸馏与模型剪枝技术进一步压缩模型计算量，推动检测算法在移动端与嵌入式设备的落地。

1.2.1 图像视觉目标检测算法

HOG 特征作为一种高效的图像描述子，凭借其对局部形状和边缘信息的敏感性，成为早期目标检测的重要基础。在 DPM 等方法中，HOG 特征通常作为输入，其主要思想是通过捕捉图像中梯度方向的分布来描述局部几何结构。HOG 的提出解决了传统像素强度直接使用时容易受到光照、阴影等干扰的问题。HOG 特征提取过程主要包括以下几个步骤：梯度计算、单元格划分、直方图统计与归一化、特征向量构建。HOG 特征具备对局部形状、边缘信息的高敏感度和较强的抗干扰能力，尤其在行人检测和车辆检测中取得了良好的效果。HOG 特征主要缺点在于对于尺度变化和旋转的不变性较差，需要借助金字塔检测策略或其他后续处理手段进行补偿。HOG 的成功也推动了其他特征描述子如 SIFT 的出现，并为后来的深度学习模型中卷积核设计提供了直观启发。

SIFT 特征作为一种局部不变性描述子，其在尺度、旋转甚至部分视角变化下保持稳定，成为图像匹配、目标识别及三维重建等任务中的重要工具。在传统计算机视觉方法中，图像匹配和特征点检测一直是关键问题。SIFT 通过构建尺度空间和利用差分高斯（Difference of Gaussians, DoG）方法来检测关键点，并为每个关键点生成高维描述子，有效解决了尺度和旋转变化问题。SIFT 的算法流程主要包括以下步骤：尺度空间构建、关键点定位、方向分配、描述子生成。SIFT 特征具有良好的尺度、旋转和部分视角不变性，在复杂场景下能保持较高的匹配准确率，是图像配准、物体识别和医学图像处理等领域的主流方法。但其计算复杂度较高，尤其是在构建尺度空间和生成高维描述子时，对实时性要求较高的应用场景存在一定限制。SIFT 的成功不仅推动了局部特征描述领域的发展，也为后续基于深度学习的特征提取和匹配方法提供了重要理论基础。

DPM 模型的提出主要是为了解决传统滑动窗口检测器在应对目标形变、局部遮挡以及背景干扰时的不足。DPM 在一定程度上继承了 HOG 特征的优势，通过将目标分解为多个局部部件来捕捉目标的内部结构信息。早期的目标检测方法往往将整个目标视为一个整体，但这种方法对姿态变化和部分遮挡极为敏感。DPM 的创新在于引入了“隐变量”来描述各部件间的相对位移，从而能够适应目标在真实场景中由于视角变化或非刚性变形而产生的局部位移。DPM 首先利用 HOG 特征将图像转换为描述边缘和纹理的梯度特征图，然后将目标划分为若干部件（如头部、躯干、四肢

等), 每个部件都有自己的 HOG 描述符。在分类过程中, 模型采用滑动窗口方法在不同尺度和位置上搜索目标, 同时利用隐变量支持向量机 (Latent SVM) 对每个部件的最佳位置进行自适应调整。数学上, DPM 将目标得分表示为全局模型得分与局部部件得分之和, 同时引入位移惩罚项, 以确保部件位置的合理性。

$$f(x) = \max_{z \in Z(x)} \left(\sum_{i=0}^n w_i \cdot \phi(x, z_i) - \sum_{i=1}^n d(z_i) \right),$$

其中 x 表示输入图像窗口, $z = \{z_0, z_1, \dots, z_n\}$ 表示目标部件的配置, z_0 为根滤波器位置, $z_1, \dots, z_n$ 为各局部部件位置。函数 $\phi(x, z_i)$ 表示在图像 x 的位置 z_i 提取的特征向量 (通常采用 HOG 特征), w_i 是相应的权重向量, 而 $d(z_i)$ 则用于衡量部件位置 z_i 与理想位置之间的偏离程度, 从而起到形变惩罚的作用。整个公式通过在所有可能的部件配置中选择使得得分最大的 z 来实现目标检测, 从而在综合各部件检测响应的同时, 约束部件间的空间关系, 提高了模型对目标形变、部分遮挡和复杂背景干扰的鲁棒性。

CNN 在目标检测领域的应用最早可追溯至 20 世纪 90 年代, 但受限于当时的计算能力和训练数据的匮乏, 基于 CNN 的目标检测算法在 2012 年之前进展较为缓慢。直到 2012 年, AlexNet 在 ImageNet 挑战赛中的突破性表现, 使 CNN 重新成为研究热点, 并推动了目标检测技术在精度和速度取得显著提升。基于深度学习的目标检测算法利用 CNN 代替传统的经验设计特征, 目标检测是计算机视觉领域的一个长期课题, 更加精确的检测性能是研究人员一直以来的追求。随着研究人员在 Backbone、数据增广策略、损失函数、自注意力机制、NMS 等方向不断提出改进, 现有目标检测算法的性能可以很好的平衡准确与实时性。

AlexNet 通过 ReLU 激活函数与 Dropout 正则化策略, 首次验证了深度卷积网络可显著提升图像识别效果, 通过 GPU 并行训练与 ReLU 激活函数缓解梯度消失的难题。AlexNet 的架构创新直接启发了 OverFeat^[31] 的多尺度滑动窗口检测与分类网络结合的思想, OverFeat 的实验结果证明 CNN 可胜任分类与定位任务。R-CNN^[32] 将选择性搜索与 CNN 结合, 表明候选区域与深度特征融合能大幅提升检测精度, 并将高层语义引入检测。SPPnet^[33] 通过空间金字塔池化层, 能减少对输入尺寸的依赖并显著加快检测速度。Fast R-CNN^[34] 引入 ROI Pooling 层, 多任务训练可大幅提升效率与精度。Faster R-CNN^[35] 创新的提出候选区域生成与检测网络可共享特征, 即区域建议网络 (Region Proposal Network, RPN), 使检测速度和精度都有显著提升。

YOLO^[36] 新颖的将检测视为单次回归问题, 提出的单阶段架构极大提升实时性。2018 年的 YOLOv3^[37] 证明在多尺度预测有助于小目标检测, 并使用 Darknet-53 作为特征提取网络。SSD^[38] 创新的设计多层输出结构, 通过 6 层特征图融合兼顾速度与精度。EfficientDet^[39] 提出复合缩放策略与双向特征融合, 设计高效的特征提取网络

与 BiFPN 能在减少参数的同时保持高精度。YOLO V4^[40] 集成多种训练技巧可在速度与精度间取得新平衡，主要创新包括 CSPNet、Mish 等；2020 年的 YOLO V5^[41] 减少计算冗余，同时提升特征提取效率，在实际设备部署与推理速度上具备显著优势。Mask R-CNN^[42] 扩展 Faster R-CNN 架构，首次提出 ROI Align 与分割分支，保持两阶段检测框架并可输出像素级掩码。RetinaNet^[43] 证明 Focal Loss 可以有效缓解样本不平衡问题。Cascade R-CNN^[44] 提出级联训练策略，多级回归与分类能持续优化检测结果，开创多阶段检测的思想。

DETR^[45] 首次将自然语言处理中的 Transformer 模型引入检测任务，可完全摒弃 Anchor 以自注意力机制实现检测，但存在训练时间长收敛困难与计算量大的缺陷。RT-DETR^[46] 通过混合编码策略，大幅简化 Transformer 架构后可在嵌入式设备实现实时检测。DINO^[47] 引入多尺度融合与改进正负样本匹配可显著提升模型对小目标感知能力。YOLOX^[48] 用更灵活的标签分配与训练策略可在无额外复杂度下提升检测；2022 年的 YOLO V7^[49] 通过 E-ELAN、模型缩放等进一步刷新实时检测性能。YOLO V8^[50] 主要创新在改进的特征融合模块并引入可编程梯度信息模块，结合部分 Transformer 思想进一步提升轻量化与推理速度。2024 年，YOLO V9^[51] 提出 GELAN，是一种基于梯度路径规划的轻量级网络架构，旨在优化特征提取过程。与传统的深度卷积网络相比，GELAN 在保持高效计算的同时，能够更好地保留和聚合多层次特征信息。Swin Transformer^[52] 通过层次化窗口注意力机制能兼顾全局与局部特征，实现移动窗口机制与多尺度融合。

1.2.2 数据驱动的 SAR 舰船检测算法

CNN 为目标检测任务提供了具有强大特征学习能力的网络结构。模型驱动的目标检测方法多依赖人根据经验设计的特征提取方法，而 CNN 通过多层的卷积操作，自动学习从低级到高级的图像特征，极大地提升了目标检测的精度。在 SAR 舰船检测任务中，基于 CNN 的单阶段或两阶段检测方法成为了研究的热点，并展示了优异的性能。

Faster R-CNN 凭借候选区域提取网络与精细分类回归两阶段的检测策略取得了当时有竞争性的检测结果。首阶段通过 RPN 生成候选区域，第二阶段通过精细化特征分类实现目标判别，这种“粗筛+精检”的机制能有效应对 SAR 图像中舰船目标信杂比低、形态多变的特点。在 SAR 舰船检测中，不少研究针对 Faster R-CNN 进行轻量化或其它针对性优化，以解决海杂波和小目标带来的检测难题。赵林^[53] 采用挤压激励（Squeeze-and-Excitation, SE）模块对通道注意力进行加权，同时在 RPN 中融入特征降维策略。即使在海浪强烈或岸线干扰明显的场景下，所提方法也能维持稳定的检测性能。单阶段检测方法如 YOLO、SSD 等在光学图像中已得到广泛应用，针对

SAR 图像的研究也异常火热。秦皓楠^[54] 针对大场景下的小目标与高背景杂波难题进行优化, 引入多尺度特征金字塔与交并比 (Intersection of Union, IoU) 自适应判别策略, 提高单阶段网络在 SAR 舰船检测中的精确度。杨曦^[55] 提出在大尺寸 SAR 图像中以金字塔特征融合与难样本挖掘相结合的方式, 解决多尺度舰船目标的漏检问题, 实验结果显示该方法在离岸较近的复杂场景中也可保持较低虚警率。

随着 SAR 图像分辨率不断提升, 目标检测算法在计算准确性的要求也随之提升。实际应用比如实时监控和大范围场景目标搜索对检测算法的实时性提出了更高的要求。因此, 在 SAR 舰船检测领域中, 如何优化模型的复杂度与计算效率, 使其能够在资源受限的边缘设备上高效部署, 成为检测算法能否落地的关键问题。轻量化检测方法旨在减少模型参数量, 降低计算复杂度, 同时尽量保持检测精度。常用的轻量化方法包括网络剪枝、知识蒸馏、卷积替换等。卷积操作是 CNN 中占用计算量最为密集的部分, 卷积操作的替换和优化可以显著减少模型的计算量。一种常见的卷积改进方法是深度可分离卷积 (Depthwise Separable Convolution, DSC), DSC 将标准卷积分解为深度卷积和逐点卷积两个步骤, 大幅降低了计算复杂度和参数数量。DSC 在轻量化模型中获得广泛应用。以 MobileNet 为代表的轻量化模型在保持较高准确率的同时实现了较低的计算复杂度。张天文^[56] 仅使用 20 层卷积网络, 通过网络结构压缩与特征融合模块, 达到在海上场景下的实时检测。20 层卷积网络主要创新点在于引入分组卷积和瓶颈结构, 保证精度的同时将参数量大幅减少。张筱晗^[57] 则从特征层面优化网络结构, 对高维特征进行降维处理, 辅助注意力机制来增强目标响应。该方法在近岸小目标场景中取得不俗表现。

在 SAR 舰船检测中, 舰船目标常常具有显著的尺度变化, 尤其在大范围海域监测任务中, 目标的大小差异常常可以达到几个数量级。因此, 多尺度特征融合策略逐渐成为提升 SAR 舰船检测性能的一个重要手段。通过有效地融合多尺度的图像特征, 检测算法可以在不同尺度上增强对目标的辨识能力, 尤其是兼顾小目标和大目标的识别能力, 从而提高检测精度, 降低虚警率。多尺度特征融合的核心思想是有效地利用不同尺度特征图中包含的不同层次的目标信息。特征金字塔网络 (Feature Pyramid Network, FPN) 通过在网络的多个层次上生成不同尺度的特征图, 并将这些特征图进行融合提高模型对多尺度目标的适应能力。至于 SAR 舰船检测任务, FPN 能够有效处理海洋图像中舰船目标的多样性, 尤其是舰船在不同海况下呈现的大小和角度变化。近年来, 注意力机制 (Attention Mechanism) 逐渐被引入到多尺度特征融合中。通过引入各种注意力机制, 模型能够在多尺度特征融合的过程中, 自动识别出包含目标的关键区域并加强网络对这些重要区域的关注, 从而增强模型在复杂背景下的鲁棒性。洪中华^[58] 采用多尺度 YOLO V3 架构, 对 SAR 与光学图像进行特征层级对齐, 并在检测头中融合多尺度预测输出, 有效缓解大中小目标混杂造成的漏检现象。

崔宗勇^[59]引入稠密金字塔和注意力模块,分层次对特征进行精细化处理,在杂波强度变化显著的场景下仍能稳定识别不同尺度的舰船目标。

在 SAR 舰船检测任务中,虚警通常是由复杂背景干扰引起的,这些背景干扰包括海浪、岸线、金属、岛屿以及其它景物^[60]。背景干扰在 SAR 图像中呈现出与舰船目标相似的散射特征,进而导致检测算法将其误判从而导致虚警^[61]。因此,杂波抑制与复杂背景建模成为 SAR 舰船检测中的一个重要研究方向^[62]。杂波抑制主要涉及两方面的研究:背景建模和后处理技术。背景建模的核心是建立对背景杂波的准确估计模型,从而在检测过程中减少误判。后处理技术则主要用于对检测结果进行修正和优化,进一步减少虚警^[63]。杨荣^[64]结合图像纹理特征与目标形态先验,对 CNN 输出的候选框进行二次判别,减少高强度海浪带来的虚警。研究结果显示,上述方法在风暴或极端海况中虚警率可明显下降。张天文^[65]通过在训练数据中均衡近岸与远海场景,并利用自适应阈值修正策略,平衡了不同海域下的杂波统计特征,降低岸线干扰导致的虚警。

随着遥感技术的飞速发展, SAR 图像数据已经不能满足日益增长的舰船检测任务需求。除去传统的卫星平台外,近年来机载、无人机平台的应用在舰船检测中也展现了其独特优势。多源数据融合通过结合不同来源的数据,能够有效提高舰船检测的鲁棒性和适应性,尤其是在复杂环境下。通过将不同类型的数据(如 SAR、光学、红外图像等)结合,可以利用各个数据源的优势,从而解决单一数据源的局限性,如背景噪声大、图像分辨率低等问题。因此,越来越多的研究开始致力于多源数据融合方法的探索,并在舰船检测任务中取得了显著的成果。光学图像和红外图像能够提供目标的形状、颜色、温度等信息,而 SAR 图像则具有穿透云层和雨水的优势,适合在复杂天气条件下进行监测。通过结合这些信息,检测系统可以同时利用各类数据源的互补性,在不同的检测场景中提升性能。除了多模态数据融合外,利用多时间或多视角的数据融合也成为了舰船检测的重要研究方向。由于舰船目标通常在不同的时间和不同的视角下呈现出不同的形态或特征,通过多时刻、多视角的图像数据融合,可以补充单一时刻或视角下检测的不足,从而提高检测模型的稳定性和鲁棒性。高等^[66]提出在机载高分辨率 SAR 数据中,通过与红外或光学信息进行配准,对检测到的候选目标进行互补验证,显著减少海杂波引起的虚警。任沂斌^[67]在检测同时提取舰船尺寸等语义信息,通过多源数据(如 AIS 航运信息)进行比对校验,验证检测结果的可靠性。

1.3 面临的问题与挑战

在复杂场景中, SAR 舰船检测面临众多挑战,特别是在小目标特征不明显、背景杂波干扰严重、标注数据有限且样本种类单一以及杂波抑制与检测分别运行导致

性能提升有限等。为了有效提升检测性能,解决上述问题至关重要。本文对复杂杂波背景 SAR 图像舰船目标检测算法开展研究,详细分析上述难点并设计解决方案。

1.3.1 场景大目标小

在 SAR 图像中,舰船目标通常呈现出小尺寸、高混杂、低对比的特征,尤其是在远海和近岸等复杂场景中,这一问题更加显著。由于舰船的雷达反射信号较弱,且常与海面背景杂波具有相似的散射特性,导致其在图像中难以与复杂背景有效区分。特别是尺寸较小的舰船目标,其在图像中的长度与宽度往往仅占据几个像素,如图1.3所示。小目标极易被淹没在强烈的背景杂波中,从而出现漏检的情况。




图 1.3 小目标样本, 图片来自 SSDD 数据集

成像分辨率的限制是导致目标不易识别的根本因素之一。尽管当前 SAR 系统在空间分辨率方面已取得显著提升,但在远距离观测或近岸区域成像时,小型舰船目标在图像中的像素占比依然非常有限,其信号在空间上呈现出模糊边缘和低对比度,致使从复杂背景中提取有效特征变得困难。低分辨率带来的直接后果是目标区域的有效像素数量减少,空间结构信息和边缘轮廓被严重压缩甚至丢失,导致目标的几何形状难以辨识,从而大幅削弱了传统检测算法和深度神经网络提取语义特征的能力。SAR 图像中的目标特征包括结构边缘、轮廓梯度、强散射点分布等,这些都依赖于一定的像素覆盖范围才能被网络有效感知。当目标只占据几个像素时,其上下文信息不足、纹理特征不完整、形状信息不连续,使得网络难以形成稳定的特征表征。以卷积神经网络为例,其感受野的有效覆盖通常需要多个卷积层的堆叠,当目标尺度小于最小感受野时,其信号会在下采样过程中逐渐淹没,最终导致高层语义表示中目标信息的缺失。因此,分辨率不足不仅影响图像质量,还从根本上限制了模型在特征空间中对小目标的建模能力。此外,小目标在训练阶段也面临着显著的优化难度。由于其在正负样本划分中占比极低,且容易被忽视或误标为背景区域,导致网络学习到的判别边界偏向中大目标,进一步加剧了对小目标的检测不敏感问题。尤其是在目标尺度变化剧烈或分布不均的场景中,统一尺度下的特征提取和分类回归策略更易

对小目标产生不公平学习偏倚。

为应对上述挑战，近年来深度学习技术在 SAR 舰船检测领域取得了显著进展。以 YOLO、Faster R-CNN 等代表性的卷积神经网络为例，这些方法通过多层次、多尺度的特征提取机制，显著增强了对小目标的建模能力。同时，特征金字塔结构和注意力机制的引入进一步提升了网络对局部细节和关键区域的关注能力，增强了对弱小目标的检测灵敏度。然而，尽管深度学习方法在整体检测精度方面取得了较大提升，其在面对尺度变化大的目标检测任务时仍存在明显不足。舰船目标的尺度差异大，加上海况复杂多变，使得在同一场景中常常同时存在大中小多种尺度的目标。如何实现对不同尺度目标的统一建模，特别是在不牺牲小目标检测精度的前提下兼顾大目标，是当前方法面临的关键难点。为进一步验证 SAR 舰船检测任务中“小目标难检测”的现实问题，本章基于 COCO 数据集中关于目标尺寸的划分标准（小目标：面积小于 32^2 ，中目标： 32^2 至 96^2 之间，大目标：大于 96^2 ），对当前主流 SAR 舰船检测数据集——SSDD 和 HRSID 中的目标尺寸分布进行了统计分析。如图1.4所示，两大数据集中小目标的占比较高，尤其是在 HRSID 数据集中，小目标比例超过了 60%，呈现出明显的“小目标密集”特征。这一统计结果揭示了 SAR 图像中舰船目标尺寸偏小的客观现象，同时也揭示了数据驱动的舰船检测算法亟需在小目标建模方面进行优化。




图 1.4 常用 SAR 舰船数据集目标尺度分布统计

1.3.2 数据多标注难

尽管 SAR 技术能高效获取海量图像数据，但由于标注过程繁琐且耗时，导致实际可用于训练的标注样本数量相对有限。SAR 舰船检测数据标注核心难点源于 SAR 成像机制与目标特性的双重制约。首先，SAR 的极化、多角度成像特性导致目标形态高度多样：同一舰船在不同方位角下可能呈现十字亮斑、双峰或模糊轮廓等形态差异，而斑点噪声与海杂波干扰进一步加剧目标边缘模糊，要求标注人员具备 SAR 物理特性知识以区分真实目标与虚警亮斑。SAR 常用的舰船检测数据集信息如表1.2所

示。SAR-Ship-Dataset 包含 43,819 张切片和 59,535 个实例，标注耗时差异大。小目标占比多的特点进一步加剧标注难度，这些因素共同导致 SAR 舰船标注成本高。

表 1.2 SAR 舰船检测数据集切片数量与目标数量

数据集名称	切片数	目标数
SSDD	1,160	2,456
HRSID	5,604	16,951
AIR-SARShip-1.0	31	461
SAR-Ship-Dataset	43,819	59,535

尽管 SAR 技术能高效获取海量图像数据，但标注流程的复杂性严重制约了可用训练样本的规模。现有标注工具虽支持多边形框选、网格化分块等交互方式，但人工标注仍需专家逐帧校验目标位置、尺寸及类型，导致单张图像标注耗时长。如图 1.5 所示，复杂场景中舰船与岛礁亮斑的灰度相似性、小目标的边界模糊等问题，迫使标注人员反复调整框选区域，人工成本较光学数据集（如 COCO）增加 3 倍以上。




图 1.5 标注软件 LabelImg 界面展示

1.3.3 背景强目标弱

背景杂波的干扰是限制 SAR 舰船目标检测性能的关键因素之一，尤其在复杂海上环境中，其影响尤为显著。海面作为一个典型的非规则、非平稳反射背景体，其散射特性会随自然环境变化而剧烈波动，从而显著增加了目标与背景的可分性难度。如图 1.6 所示，在真实海洋场景中，背景杂波主要来源于海浪、潮汐、风场和岸线等因素的耦合作用，其在 SAR 图像中表现出显著的非均匀性、非平稳性和高动态性，这些复杂特性严重干扰了舰船目标的判别和提取。杂波与目标信号之间的雷达散射特性高度相似，尤其在低信噪比条件下，舰船目标与海面杂波在幅度、纹理、局部结构等方面差异极小，使得基于卷积的特征提取机制难以有效区分两者。由于近岸区域往

往伴随着高反射物体（如建筑、码头等）和复杂的岸型结构，导致背景散射强度显著增强，容易出现“强杂波淹没弱目标”的现象，从而引发检测系统的虚警率上升和漏检风险加剧。




图 1.6 复杂杂波样本，图片来自 SSDD 数据集

为进一步量化背景杂波对图像整体质量的影响，本章对两个经典 SAR 舰船检测数据集——SSDD 和 HRSID 中的图像整体信杂比（Signal-to-Clutter Ratio, SCR）进行了统计分析，如图1.7所示。SCR 作为衡量目标信号与背景杂波干扰强弱关系的重要指标，其数值越高，表示目标在背景中的可分性越强，图像对舰船目标的表征能力越突出。统计结果表明，两数据集中大多数图像的 SCR 均处于较低水平，反映出目标信号在背景杂波中的可分性较差。背景杂波的干扰不仅导致图像整体对比度下降，更体现为目标与背景在散射特性上的高度耦合，使得二者难以区分。这种耦合关系在数据分布层面直接削弱了深度模型对目标特征的判别能力，进而影响检测的准确性与训练的稳定性。因此，如何有效抑制背景杂波、提升图像的信杂比，已成为 SAR 舰船检测任务中亟待解决的重要挑战之一。




图 1.7 常用 SAR 舰船数据集信杂比分布统计

1.3.4 上下游任务缺少关联

在 SAR 目标检测领域，图像增强算法（如超分辨率重建与相干斑噪声抑制）与目标检测模型长期处于割裂状态，形成了制约实际应用效能的结构性矛盾。当前主流方法通常采用“前处理-后检测”的两阶段范式：即先利用独立优化的超分辨率算法或去斑滤波器提升图像质量，再将处理后的图像输入检测网络进行训练与推理。然而，这种分离式处理流程存在多方面的问题。首先，任务目标的错位导致图像增强与检测需求之间存在不匹配。超分辨率算法往往关注像素级的空间细节恢复，如边缘锐化和纹理增强，但检测任务更关注目标的几何结构完整性和类别判别特征，两者关注点并不一致。同时，噪声抑制方法如基于小波变换的频域滤波，虽能去除相干斑噪声，却可能破坏目标边缘连续性，降低检测效果。这些图像增强手段并未与检测性能指标（如边界框精度与分类置信度）建立明确的优化关联，因而增强效果与检测增益之间往往缺乏一致性。其次，由于缺乏联合优化机制，该流程容易引发级联误差的累积。图像增强阶段的参数（如超分辨率倍数、去噪强度）通常需要依赖检测结果反馈进行人工调试。这种“检测驱动增强”的逆向适配过程不仅效率低下，而且容易放大前一阶段处理中的误差。例如，过度的超分辨率处理可能加剧噪声残留，而强烈的去斑则可能扭曲目标形态，尤其在密集目标或强干扰场景中，会严重影响检测系统的鲁棒性与可靠性。最后，计算资源分配不合理也成为制约其实时应用的一大瓶颈。由于图像增强与目标检测模型各自占用独立的计算单元，整个流程的推理延迟相较于端到端方案明显增加，从而不利于部署在对响应速度要求严格的实际应用场景中。




图 1.8 论文组织结构框图

1.4 本文主要内容与章节安排

在复杂海上场景中，SAR 舰船检测面临着多重挑战，包括小目标特征不明显、背景杂波干扰严重、数据样本单一以及训练-测试目标不一致等问题。为了应对这些挑战，本文围绕“复杂海上场景下鲁棒 SAR 舰船检测”这一核心问题，提出了一种层次化的多角度递进研究策略，旨在提升检测的鲁棒性和精度。本文的研究工作主要分为四个层次，具体内容包括以下四个方面：为解决小目标检测困难和训练-测试的目标不一致问题，本文改进标签分配策略并对网络结构优化；为提升训练样本背景复杂性与多样性，本文利用杂波统计模型和实测杂波数据对 SAR 图像进行数据增强；为避免杂波与噪声的干扰，本文设计专用的背景移除网络进行去除，并提出检测辅助一致性损失实现近岸困难场景下的精准检测；为提高模型对杂波的鲁棒性，本文构建杂波增强-抑制-检测联合框架，通过杂波污染、抑制、检测的端到端联合训练，实现杂波抑制与目标检测的协同提升。

1.4.1 论文主要内容

内容一. 预测感知的 SAR 多尺度目标检测模型

问题描述：在数据驱动的舰船检测算法中，标签分配决定训练模型的目标，直接影响模型对正负样本的表征学习效率与最终检测性能。传统方法依赖研究人员基于经验设计的静态规则，比如固定 IoU 阈值、正负样本比例等。传统标签分配方法虽在一定程度上缓解样本不均衡问题，却因超参数敏感性，需要研究人员不断调整超参数，不恰当的设置会降低模型性能。此外，在 SAR 舰船检测中，尤其是在复杂海上场景中，小目标的特征通常非常模糊，且与背景杂波相似，因此多尺度目标检测一直是本领域的难点。

解决思路：为了解决上述问题，本文提出了预测感知的 SAR 多尺度目标检测模型。首先，本文设计交并比预测分支并将结果指定为定位精度的估计。通过分类和定位的组合来综合评估候选框的质量。综合评估减少了训练和测试目标之间的不一致性。此外，所提标签分配策略同时利用当前模型的学习状态和候选框的先验信息。以自适应的方式选择最佳正样本。本文设计了一种多尺度舰船目标检测网络，重点关注包含小型舰船丰富的上下文信息的特征图。在不同尺度上进行特征融合和特征增强后，多尺度舰船目标检测网络将浅层纹理和深层语义信息相结合，以提升多尺度舰船目标检测性能。

内容二. 杂波随机采样迁移的 SAR 数据增强技术

问题描述：困难检测场景中一个显著问题是背景杂波的高度非平稳性和复杂性。海浪、风浪、潮汐等自然因素对背景杂波的影响极大，造成目标信号与背景的高度相似。小目标的特征不明显导致检测模型难以从图像中区分目标与背景。传统的数据增

强方法主要依赖于对图像本身的变换，如旋转、缩放、平移、翻转、剪裁等方式，上述方法虽然在一定程度上增加了样本的多样性，但对背景杂波的处理较为薄弱。

解决思路：为了提升训练数据的复杂性与多样性，本文将实测杂波数据和模拟杂波整合到 SAR 数据中以增强目标检测性能。通过利用杂波的统计特性，杂波随机采样融合的 SAR 目标检测方法在保持检测网络原始端到端架构的同时增强训练数据。杂波集由统计模型和实测杂波数据组成。本文提出的三种增强模式对杂波集和原始训练数据进行随机采样和自适应融合。这一过程在数据集的规模和复杂性上都进行了扩展。由于增强前后目标位置保持不变，仅背景变得更加复杂，因此原始目标标注得以保留并用于模型训练。杂波随机采样融合的 SAR 目标检测方法采用三种融合模式：加法融合、乘法融合和目标保护。加法融合通过将真实杂波与 SAR 数据相结合，增加了数据集的复杂性，生成了多样化的样本，从而增强了模型的泛化能力并减轻了过拟合。这种融合方式丰富了背景，使检测任务更具挑战性，并促使模型专注于从复杂背景中区分目标。乘法融合引入了 SAR 数据与杂波之间的非线性交互，模拟了更复杂的环境条件。这种融合方法增加了背景的复杂性，促进了稳健的特征提取，并提高了在各种 SAR 环境中的检测性能。目标保护方式确保在融合过程中目标区域保持完整，保留了重要的目标信息，同时丰富了背景杂波。这种策略使模型能够在具有挑战性的背景下学习，同时不损害目标的电磁散射特征。

内容三.SAR 图像背景移除辅助的目标检测方法

问题描述：在复杂海洋环境下，SAR 舰船检测系统面临近岸场景性能退化的严峻挑战：海浪、岸线结构、港口设施等多重干扰源导致背景杂波强度动态波动，加之目标与杂波的电磁散射特性相似性。现有背景抑制方法虽能降低全局杂波功率谱密度，却因任务分离设计引发两大核心问题：目标信息损失，如滤波过程模糊边缘与微动特征，导致小目标召回率大幅下降；与训练-测试偏差，即独立优化的杂波抑制网络与检测模型缺乏协同约束，致使模型在真实场景中易受残余杂波干扰。

解决思路：为了克服这一问题，本文将背景移除和目标检测两个任务结合起来，通过端到端可微分架构与多任务一致性约束损失，实现杂波抑制与目标检测的协同优化。通过背景移除网络得到干净图像，检测模型可以准确地从复杂背景中分离出舰船目标，并通过检测辅助一致性损失函数确保背景移除的结果服务于检测任务的需要。具体来说，背景移除模块首先利用深度卷积网络对 SAR 图像中的背景进行去除，然后通过检测辅助一致性损失函数，确保背景移除过程不影响目标信息的提取。这种任务协同优化机制打破了传统方法的“任务分离”瓶颈，使模型在去除背景的同时，保留目标电磁散射特性与纹理信息，从而在近岸复杂场景下实现准确性的显著提升。SAR 图像背景移除辅助的舰船检测方法提供了从“被动抑制”到“主动认知背景-目标交互关系”的新范式。

内容四.SAR 图像杂波抑制与目标检测联合学习策略

问题描述：在复杂海洋环境中，SAR 舰船检测系统面临背景杂波非平稳性与目标易被遮挡的双重挑战。传统方法因任务分离与静态场景假设，难以在动态杂波抑制与目标特征保留间实现平衡：一方面，独立优化的杂波抑制网络通过滤波器降低全局杂波功率，却易模糊目标边缘与细节特性；另一方面，检测模型在真实场景中易受残余杂波干扰，特别是港口金属物散射伪影，导致检测模型难以区分目标与杂波的电磁散射特性差异。

解决思路：为了增强模型对杂波变化的鲁棒性，本文首先引入了杂波增强机制。在训练过程中，对数据进行杂波污染，模拟实际环境中的复杂杂波变化。这一过程增强模型对不同背景变化的适应性，而且能扩展数据集的多样性。通过这种方式，模型能够在面对未知的杂波模式时，也能保持较强的鲁棒性。整体框架通过将杂波增强、抑制和目标检测任务结合在一起，采用端到端的联合学习策略，使得模型能够在处理复杂背景和强干扰的同时，进行目标检测。具体来说，框架中首先通过杂波注入技术模拟不同背景杂波，然后通过杂波抑制网络对这些杂波进行有效去除，最后利用目标检测网络从去除杂波后的图像中提取舰船目标信息。在训练过程中，通过对抗训练策略优化三个任务的协同作用，确保杂波抑制和目标检测过程的协同提升。通过反向传播的机制，模型能够在目标检测的过程中自动学习到如何最优地去除背景杂波，提升目标检测的精度。实验结果显示，所提方法相比传统的独立训练方法，能够有效提高目标检测的精度。

1.4.1.5 总结

本文通过提出目标检测任务中四个重要的研究方向，从多个层次深入探讨了复杂海上场景中 SAR 舰船检测面临的关键问题。首先，改进的标签分配策略和网络结构优化，解决了小目标易漏检和训练-测试目标不一致的问题；其次，为解决现有检测模型对 SAR 样本分布依赖性强、数据稀疏导致检测泛化能力差的问题，提出杂波增强策略以扩展训练样本空间；第三，为解决数据增强在近岸复杂背景下难以有效抑制干扰的问题，提出背景移除辅助的检测方法以增强特征纯净度与目标识别能力，提高检测精度；最后，为解决背景移除方法在强杂波环境下鲁棒性不足的问题，提出杂波增强-抑制-检测联合优化框架，实现复杂干扰下的鲁棒检测。上述研究为复杂杂波场景 SAR 舰船检测提供了新的解决方案，实验结果验证了所提方法的有效性。本文研究内容与目标如图1.8所示。

1.4.2 章节安排

1.4.2.1 第二章：SAR 舰船检测算法基础

本章旨在介绍深度学习在 SAR 舰船检测中的模型原理、常用的数据集和评价指

标,以便为后续章节中的具体算法实现和实验分析提供理论基础和方法支持。具体而言,本章将重点介绍以基于卷积神经网络的舰船目标检测框架中的关键技术,并对 SAR 舰船检测领域中常用的数据集进行介绍,最后详细讲解用于评估 SAR 舰船检测模型性能的常用评价指标。

1.4.2.2 第三章:预测感知的 SAR 多尺度目标检测模型

首先,本章结合实际 SAR 舰船检测场景,详细讨论当前标签分配存在的不足及小目标检测困难的现状。其次,本章介绍模型预测和先验信息引导的标签分配策略:利用目标先验信息、模型当前对定位精度和置信度的预测,设计动态样本选择机制,从而优化标签分配,确保检测模型训练阶段与测试阶段目标一致性。本章介绍引入 ASFF 与改进的特征金字塔模块,加强对小目标微弱特征的响应。最后,本章通过实验数据、模型计算复杂度等,对比标签分配策略的效果。并通过消融实验分析各个模块的贡献,结合定量指标与可视化检测结果,证明本章提出的预测感知的 SAR 多尺度目标检测模型性能提升方面的有效性。

1.4.2.3 第四章:杂波随机采样迁移的 SAR 数据增强技术

本章提出了一种杂波统计建模和实测杂波数据自适应增强 SAR 数据的舰船检测算法。首先,本章介绍杂波参数化建模获得丰富的杂波集。其次,本章介绍杂波随机采样融合的 SAR 目标检测方法的整体框架,通过伪代码、公式推导和图说明和三种数据增强模式具体实现过程。同时本章会具体介绍数据增强算法的在线和离线机制,其中在线机制使得每次训练迭代均产生不同背景干扰的样本,从而进一步增强训练数据多样性。最后,本章通过一系列实验结果和数据增强的可视化结果来验证所提算法的优越性。并与传统数据增强方法和去噪等方法进行性能对比。

1.4.2.4 第五章: SAR 图像背景移除辅助的目标检测方法

首先,本章讨论近岸场景对检测任务的干扰并且分析传统杂波抑制的局限性,说明需要设计专用网络以实现更高效的背景移除。其次,本章设计背景移除模块,重点介绍多尺度特征提取、跳跃连接和特征融合策略,同时介绍设计的检测辅助一致性损失,利用检测分支输出引导背景移除网络在保持目标信息同时进一步去除杂波干扰。最后,本章利用网络结构、实验数据,展示背景移除前后在检测准确率、定位精度等指标上的改善。通过对比实验和消融实验,验证背景移除辅助的舰船检测方法的有效性。其中近岸场景样本会单独进行实验并分析结果。

1.4.2.5 第六章: SAR 图像杂波抑制与目标检测联合学习策略

本章首先分析困难检测样本的特点,指出在杂波干扰下,目标与背景之间的界限变得模糊,现有检测方法在此类场景下普遍面临稳定性不足。因此本章提出在原始 SAR 图像中引入杂波以模拟极端复杂环境。在此基础上,本章进一步设计了一个融合杂波抑制模块与目标检测模块的联合网络,实现端到端的协同优化。本章详细介

绍了该联合网络的结构设计与优化流程，并通过多组实验验证了所提出策略在提升 SAR 舰船检测性能方面的有效性。

1.4.2.6 第七章：总结与展望

在论文的最后，本章对本文的研究成果进行了总结，回顾了各章节的研究内容与创新点。本文针对复杂海上场景中 SAR 舰船检测的痛点，提出了一套层次化、多任务协同的创新方法，缓解小目标检测、杂波干扰、数据样本单一、训练-测试目标不一致等问题。本文从模型优化-数据增强-训练策略改进-多任务协同，层次化递进展开研究，为 SAR 舰船检测提供了新的思路和技术路线。

尽管本文在复杂场景下的 SAR 舰船检测中取得了进展，未来仍需深化以下研究方向：多模态数据融合需探索跨传感器（如光学、红外）特征协同与轻量化融合网络设计，以提升鲁棒性与抗干扰能力；轻量化与实时性优化应结合网络剪枝、量化及知识蒸馏技术，构建参数量符合要求的嵌入式模型；在线自适应学习需发展基于增量学习或元学习的动态调参机制，以应对环境漂移与数据匮乏挑战；物理模型与深度学习融合可引入雷达电磁散射先验，增强模型解释性与复杂场景适应性。通过上述方向的创新，SAR 舰船检测技术有望在海洋监测、军事侦察等领域实现更广泛的应用，推动雷达感知系统向“智能、实时、高鲁棒性”迈进。

第二章 SAR 舰船检测算法基础

2.1 SAR 舰船检测典型算法原理

随着深度学习技术的迅猛发展,数据驱动的舰船检测方法取得了显著进展。传统的舰船检测方法通常依赖于经验的手工特征提取模型,而深度学习方法能够通过自动特征学习和端到端训练显著提高检测的精度和鲁棒性。本章将详细介绍舰船检测算法的典型模型,重点分析模型结构、算法框架、训练过程以及损失函数等方面。此外,还将对 SAR 舰船检测领域中常用的数据集(如 SSDD^[68] 和 HRSID^[69] 等)进行介绍,涵盖数据来源、目标尺寸分布以及数据规模等内容,并深入探讨平均准确率、召回率(Recall)、精度(Precision)、F1-score 等评价指标的含义,为后续章节中的实验分析提供支持。

2.1.1 统计建模的 SAR 目标检测算法

恒虚警率(Constant False-Alarm Rate, CFAR)算法源于雷达信号处理领域,用于在杂波和噪声环境中保持恒定的虚警概率。在实际环境中,杂波特性往往并不稳定。在不改变目标检测能力的前提下,为了动态适应环境杂波强度的和类型波动,CFAR 算法通过邻域窗口统计背景噪声分布,并根据设定的虚警率自动调整门限。CFAR 算法经过不断改进,核心思路一直是通过背景杂波的统计建模,设定固定虚警率并据此动态调整检测阈值,从而在不同海况与噪声水平下实现自适应检测。幅度 SAR 图像由于仅提供强度信息,相较于多极化或多通道数据,能直接反映目标的散射能量分布。因此在早期远海场景和中低分辨率条件下,CFAR 检测方法具有实现简单、易于工程化的优势。

传统 CFAR 算法在原理上主要包含以下关键步骤:一,根据无目标假设,对局部邻域的海杂波分布进行统计建模,常用的模型包括高斯、K 分布、威布尔分布等;二,根据预先设定的虚警率,通过第一步估计获得的杂波分布确定自适应检测门限;三,将像素强度与第二步计算得到的门限进行比较,若超出门限则判定为目标,否则视为背景。CFAR 方法通常在远海、杂波相对均匀的场景中较为有效。然而,在近岸或海况多变区域,杂波特征的非平稳性与目标散射的多样性常导致检测性能大幅下降。

为解决复杂环境下的检测难题,研究者们通过改进背景估计策略、特征表达方式和后处理机制等手段,持续优化 CFAR 算法的准确率。纪等^[70]提出可变指数切除 CFAR (Variable Index and Excision CFAR, VIE-CFAR),通过动态评估参考单元的均匀性并排除干扰目标。VIE-CFAR 首先利用可变指数(variable index, VI)判断待处理

数据的环境类型, 据此选择 CA-CFAR、GO-CFAR 或 SO-CFAR 模式; 随后通过双边阈值切除异常值, 优化杂波统计模型。马等^[71] 针对射频干扰提出两阶段 CFAR 方法: 首先在频域利用 CFAR 检测射频干扰并自适应加权抑制, 再对重构后的图像进行舰船检测。Salembier^[72] 等提出了一种基于树结构和图信号处理的 SAR 图像舰船检测方法, 通过将辐射与几何属性映射到树节点形成图信号, 结合线性/非线性/形态学滤波策略及新提出的树滤波器和分支滤波器挖掘节点间相关性, 最终构建融合图滤波与机器学习的检测架构。王等^[73] 基于目标 Fisher 向量的密度远低于杂波 Fisher 向量且两者距离大的现象, 设计了两种新的 Fisher 向量全局线索, 以抑制海杂波并显著增强 SAR 图像中的舰船目标强度。王等还设计了一种改进的 Fisher 向量局部线索用于舰船检测, 将超像素的强度对比度纳入现有局部对比度指标以减少虚警。李等^[74] 提出基于幅度强度与纹理特征融合的注意力对比 CFAR 算法。该方法首先通过局部二值模式 (Local Binary Pattern, LBP) 量化目标与海杂波的纹理差异, 并结合强度非相似性构建显著性增强图, 扩大目标与杂波的对比度。随后采用广义伽马分布拟合增强后的杂波统计特性, 并动态计算检测阈值。




图 2.1 杂波统计建模与 CFAR 结果分析, 图片来自 SSDD 数据集

尽管上述方法在取得了多方面的性能改进, CFAR 检测方法仍存在不足。CFAR

依赖对海杂波的精确建模，单一一种统计模型难以精确描述近岸或风暴等非平稳场景下的杂波分布，导致虚警与漏检问题难以解决。舰船目标的大小、横宽比存在极大差异。特别是在高分辨率 SAR 图像中，CFAR 方法往往缺乏对多尺度目标的适配能力，容易出现漏检或虚警。传统特征无法充分表达 SAR 图像中的高维信息，特征提取方法难以很全面的覆盖小目标的细节和弱散射特征。对于弱目标或与背景纹理相似的目标，CFAR 检测仍然依赖于叠加先验信息或高维特征描述，这在高分辨率大场景中会带来显著的计算负担。随着 SAR 分辨率与数据量的增长，CFAR 算法中滑窗统计的操作会在实时性方面面临瓶颈，难以满足大面积海域的快速检测需求。

为直观展示 CFAR 方法存在的问题，下图2.1是从 SSDD 数据集^[68] 中选择的两幅图片并对其进行杂波统计建模和 CFAR 检测的结果。图2.1(a)和图2.1(b)说明单一统计杂波没办法很好拟合实际场景的杂波情况。近岸海域由于受到海浪、潮汐、岸线等多种因素的综合影响，海杂波分布呈现出高度的随机性。海浪的破碎、潮汐的涨落以及岸线附近复杂的地形地貌，都会导致海杂波的局部统计特征发生剧烈变化。在这种情况下，CFAR 算法因无法准确建模杂波的真实分布，使得检测结果的虚警率与漏检率不可避免的升高，如2.1(c)和图2.1(d)所示。海浪波动显著产生的强散射区域可能被误判为舰船目标，导致虚警；而一些小型舰船目标则可能因为各种杂波的干扰而被漏检。

2.1.2 算法框架

深度学习舰船检测算法的框架通常分为两类：单阶段检测框架和两阶段检测框架。单阶段检测算法的代表性进展始于 YOLO，它首次提出通过回归问题来处理目标检测，极大地提高了检测速度。随后，SSD^[38] 提出了多尺度特征融合的策略，有效提升了不同尺寸目标的检测能力。2017 年，RetinaNet 提出了 Focal Loss，解决了单阶段检测中的类别不平衡问题，进一步提升了精度。进入 2019 年，YOLOv4 和 EfficientDet 引入了更多优化策略，提升了网络的泛化能力和计算效率。2020 年，DETR (Detection Transformer) ^[45] 通过自注意力机制彻底改变了目标检测的传统方式，引入了 Transformer 架构，摆脱了区域提议的限制，推动了目标检测的深度学习进化。2021 年，YOLOX^[48] 和 Swin Transformer^[52] 分别在 YOLO 系列和 Transformer 架构上做了优化，逐步增强了检测的精度与速度。

两阶段检测算法自 R-CNN^[32] 提出以来便开创了区域提议网络结合分类和回归的方法，虽然计算开销较大，但其精度优越。随后的 Fast R-CNN^[34] 和 Faster R-CNN^[75] 在 R-CNN 基础上优化了训练流程，尤其是 Faster R-CNN 通过引入 RPN 进一步提升了检测速度。2016 年，Mask R-CNN^[42] 扩展了 Faster R-CNN，引入了语义分割分支，使得检测不仅局限于分类和定位，还能进行精细的像素级分割。随着时间推移，

Cascade R-CNN (2017)^[44] 引入了多阶段级联检测机制, 逐步优化检测框的精度。2019 年, TridentNet^[76] 和 Dynamic R-CNN^[77] 推出了多分支或动态方案, 进一步优化了多尺度目标的检测能力。近年来, D2Det^[78] 和 AdaMixer^[79] 等新方法不断融合新的技术, 如动态头和自适应机制, 使得检测精度和速度得到了进一步的提升。

两阶段与单阶段目标检测算法模型结构如图2.2所示。两阶段目标检测算法首先, 模型生成可能包含目标的候选区域, 并利用特征提取网络提取共享特征, 对这些候选区域进行分类和边界框回归, 最终获得检测结果。而单阶段检测算法则将目标检测视为回归问题, 采用端到端的统一框架, 直接预测目标的类别和位置, 省略了候选区域生成步骤, 提高了检测效率。两阶段检测器通常可以获得更好的检测性能, 而单阶段检测器的实时性更高。目标检测是计算机视觉领域的一个长期课题, 更加精确的检测性能是研究人员一直以来的追求。随着研究人员在 Backbone 网络结构、数据增广策略、损失函数、自注意力机制、NMS 等方向不断提出改进, 单阶段目标检测算法的准确率与两阶段目标检测算法有很强的竞争性, 同时保持推理速度的领先。




图 2.2 单阶段与两阶段检测框架对比图

单阶段检测框架的优点是计算速度快、推理效率高, 适合实时检测任务。常见的单阶段检测框架包括 YOLO (You Only Look Once) 和 SSD (Single Shot Multibox Detector)。这些模型通过单一的网络直接预测目标的位置和类别, 避免了传统两阶段方法中的候选框生成和筛选步骤。

YOLO V1^[36] 将目标检测视为边界框位置和相关类别概率的回归问题, 直接利用整张图像的特征来预测目标属于多个类别的概率和每个边界框的置信度。YOLO V1 利用输入图像的全局信息, 将其划分为 $s \times s$ 个网格。每个网格仅负责检测目标中心位于其对应原图区域内部的目标, 并通过深度神经网络直接预测目标的类别、边界框及其置信度。随后, 利用置信度阈值筛选低置信度的边界框, 并采用非极大值抑制处理, 最终获得精确的检测结果。与传统候选区域方法不同, YOLO V1 采用回归方式进行目标检测, 大幅提升了检测速度。YOLO V1 的主要优点是高效且实时, 但其缺点是对小目标的检测精度较低。

为了克服 YOLO V1 检测速度快,但检测精度低的问题, YOLO 9000^[80] 引入 BN、多尺度训练、anchor 机制和细粒度特征等方法对 YOLO V1 算法进行改进, YOLO V3^[37] 算法在 YOLO 9000 的基础上, 采用更好的 backbone、多尺度预测和 9 个锚框进行检测, 使得检测算法在保证实时性的同时, 精度提高。

YOLO V4^[40] 把深度学习中一些常用的提升模型性能的技术分为两类, 一类是指在离线训练阶段为了提升精度而广泛使用的调优手段, 而这种技巧并不在推理阶段中使用, 所以不会增加推断时间; 另一类是指在推断过程中增加的些许成本但能换来较大精度提升的技巧。通过进行大量的实验, 最终 YOLO V4 选择了对模型性能有提升的方法: WRC、CSP、CmBN、SAT、Mish activation、Mosaic data augmentation、CmBN、DropBlock regularization 和 CIoU loss。YOLO V4 在传统的 YOLO 基础上, 加入了这些实用的技巧, 实现了检测速度和精度的最佳权衡。

Anchor-Based 目标检测算法首先在图像上生成大量预设的锚框, 然后对这些锚框进行类别分类和坐标调整, 以优化其位置和尺度, 从而更精准地匹配目标。上述操作可能会进行一次即单阶段目标检测算法或多次即两阶段目标检测算法, 最后输出这些经过精确修正的 anchor 并做 NMS 等后处理操作得到最终的检测结果。Anchor-Based 检测器通过引入锚框机制, 在图像上生成大量密集的候选框, 并基于这些框直接执行目标分类和边界框回归, 以提高检测精度。这样做的好处是加入先验信息, 同时可以保证网络训练稳定并易于收敛。密集分布的锚框能显著提升网络的目标召回率, 特别是在小目标检测任务中, 其检测性能提升尤为明显。但是 Anchor-Based 检测器需要人工设定大量的超参数, 比如: anchor 的尺度和长宽比、正负样本划分的 IoU 阈值和 feature map 上每个位置分配的 anchor 数量等。此外, Anchor-Based 模型的冗余 anchor 数量非常多。因为一张图像内的目标数量和所占比例十分有限, Anchor-Based 模型基于 feature map 上每个位置都设定大量 anchors, 会导致产生大量的简单负样本, 即完全不包含任何目标信息的背景框。这会造成正负样本不平衡与难易样本严重不平衡的问题。

CenterNet^[81] 将目标看作为一个点预测——即目标的中心点。当模型确定中心点的位置, 就可以回归目标的其他属性, 例如, 目标的尺寸、方向和类别等信息。在 CenterNet 中, 目标检测被转换为一个标准的中心点估计问题 (见图2.3)。具体而言, CenterNet 将输入图像传入全卷积网络 (FCN), 生成一个热力图, 其中的峰值点对应目标的中心位置。同时, 每个特征图的峰值点还用于预测目标的宽度和高度等信息。该模型采用标准的监督学习进行训练, 而推理阶段仅需一次前向传播, 不依赖 NMS 等后处理步骤。此外, 在预测目标时, CenterNet 需要先对中心点的偏置进行修正, 以补偿标注信息在输入图像到输出特征图映射过程中, 由于取整操作导致的坐标误差。由于特征图的分辨率比输入图像低 (通常缩小 4 倍或 8 倍), 导致中心点在特征图

上可能是离散化的，无法与输入图像中的精确像素点一一对应。为了解决这个问题，CenterNet 通过引入偏移回归分支来精细调整中心点的预测位置。偏移回归分支负责得出目标中心位置的偏移量。偏移回归分支输出的是一个二维向量，表示中心点在特征图中相对于真实中心点的偏移。该分支同样基于 L1 损失进行训练。通过偏移量的精细化调整，CenterNet 可以将中心点从特征图的离散位置精确回归到输入图像中的真实像素点位置，从而保证检测的精度。

CenterNet 拥有更广阔且更灵活的解空间，同时摒弃了 anchor 的使用，从而减少计算量，使目标检测朝着更高精度和实时性的方向进一步发展。但 CenterNet 存在正负样本极端不平衡与目标高度重合造成漏检的问题。目前这两者大多是采用 Focal Loss 和 FPN 来缓解。CenterNet 网络结构，首先需要有一个强大的特征提取网络。典型的 Backbone 网络有 ResNet、Hourglass^[82] 网络等，具体选择取决于任务对速度和精度的需求。特征提取网络的主要任务是提取图像中的基础特征，将输入的高分辨率图像逐渐转换为较小尺寸的特征图，为后续的关键点检测和回归任务提供高层次的语义信息。CenterNet 的网络架构是一个典型的多任务学习架构，包括中心点检测、尺寸回归和偏移回归三个任务。这三个任务通过共享 Backbone 网络提取的特征图共同工作，并通过各自的分支进行独立优化。




图 2.3 CenterNet 预测输出结果

相比两阶段检测算法，CenterNet 的单阶段架构极大地减少了中间步骤的计算量，使得它能够满足实时目标检测的需求，尤其在嵌入式设备或需要低延迟的场景中表现出色。CenterNet 的网络架构通过简洁、高效的关键点检测框架，抛弃了传统的锚框机制，同时引入尺寸回归、偏移回归等任务，形成了一个轻量化且实时的检测网络。其多任务学习框架、特征金字塔网络的引入以及创新的损失函数设计，使得 CenterNet 能够在保证高精度的同时可以实现实时检测。

两阶段检测框架通常在目标检测的精度上优于单阶段框架，但其计算复杂度较高。Faster R-CNN 是最为典型的两阶段检测框架，它在 R-CNN 和 Fast R-CNN 的基础上进行了优化，引入了区域提议网络 (Region Proposal Network, RPN)，实现了端

到端的目标检测。其基本流程包括特征提取、候选区域生成、目标分类和位置与尺寸回归四个主要步骤。

2.1.3 模型结构概述

深度学习舰船检测模型通常由多个模块组成，主要包括 backbone、neck、FPN 和 prediction head 等部分。这些模块共同工作，旨在实现从输入 SAR 图像到最终检测结果的完整流程，如图2.4所示，虚线内代表检测模型。以下将详细介绍各个模块的作用和实现。




图 2.4 SAR 深度学习舰船检测算法框图

2.1.3.1 特征提取网络（Backbone）

在数据驱动的舰船检测算法中，特征提取网络负责从原始图像中提取高层次的特征，通常使用预训练后的卷积神经网络作为 backbone。CNN 通过多层卷积、激活函数、正则化、池化操作的逐级堆叠，能够逐步从输入的 SAR 图像中提取多层次的空间特征，实现对包含目标关键信息的有效表达。常见的特征提取网络结构包括 VGG^[83]、ResNet^[84]、DenseNet^[85] 等。VGG^[83] 是一种经典的 CNN 结构，通过堆叠多个卷积层和最大池化层来逐层提取特征，尽管其结构简单，但在图像分类和目标检测任务中取得了良好的效果。MobileNet V1^[86] 采用深度可分离卷积大幅减少了参数量和计算量，使其成为轻量级模型的代表，在移动端和嵌入式设备上的应用较为广泛。MobileNet V2^[87] 在 V1 的基础上引入了线性瓶颈（Linear Bottleneck）和倒残差（Inverted Residuals）结构，有效提升了模型的表达能力，同时保持计算高效性。MobileNet V3^[88] 结合了神经架构搜索（Neural Architecture Search, NAS）和挤压-激励（Squeeze-and-Excitation, SE）注意力机制，在保证轻量级特性的同时进一步提升了模型的准确率和效率。GhostNet^[89] 提出了一种 Ghost 模块，通过生成冗余特征的方式减少计算量，在不显著降低模型性能的情况下大幅减少参数量和计算需求，适用于资源受限的设备。DenseNet121^[85] 通过在每一层与前面所有层之间建立密集连接，使得网络能够更好地传递梯度，提升训练效率，同时减少冗余特征，提高特征复用性。

表2.1展示了在 YOLO V4^[40] 目标检测框架下，替换不同特征提取网络后对舰船检测任务性能的影响。实验结果用来衡量不同特征提取网络在检测性能与计算效率

之间的权衡。从结果来看：YOLO V4（原始特征提取网络）取得最高的 AP（91.09）和 Recall（92.35），但计算复杂度较高（59.97 GFLOPs），FPS 相对较低（28.43）。MobileNet 系列在计算量和模型大小方面表现突出，MobileNet V1 最高 FPS（62.35），但 AP 相对较低。MobileNet V3 在精度（79.19 AP）和计算效率之间取得较好平衡。GhostNet 进一步降低计算量（6.59 GFLOPs），性能略优于 MobileNet 系列，适用于轻量级应用。VGG 和 DenseNet121 具有较高的 AP（86.68 和 86.66），但计算复杂度较大，FPS 相对较低。综合来看，GhostNet 和 MobileNet V3 在计算量、模型大小和精度之间取得了较好的权衡，是轻量化应用的较优选择。YOLO V4 依然在检测精度上占优，适用于计算资源充足的场景。

模型	AP	Precision	Recall	GFLOPs	模型大小	参数量	FPS
Yolo V4	91.09	84.31	92.35	59.97	244.30M	63.95M	28.43
MobileNet V1	75.10	77.53	82.81	10.07	51.00M	12.28M	62.35
MobileNet V2	78.97	73.51	85.90	7.73	46.40M	10.36M	49.94
MobileNet V3	79.19	78.79	85.12	7.12	53.60M	11.32M	41.31
GhostNet	81.72	79.80	85.88	6.59	42.30M	11.01M	33.57
VGG	86.68	85.75	89.71	111.77	89.90M	23.50M	34.76
DenseNet121	86.66	83.55	89.32	25.98	61.70M	16.02M	27.47

表 2.1 不同特征提取网络在 YOLO V4 目标检测框架下的性能对比

2.1.3.2 特征融合模块（Neck）

特征融合模块的作用是将特征提取网络获取的不同尺度特征进行融合，以便在目标检测任务中更好地处理尺度变化较大的目标问题。在舰船检测任务中，由于舰船目标的尺寸可能从小型渔船到大型货轮不等，单一尺度的特征可能无法全面地捕捉所有目标的信息。因此，高效的特征融合模块可以有效提升多尺度目标的检测能力。现有的特征融合模块主要包括 FPN（Feature Pyramid Networks, FPN）^[90]、路径聚合网络（Path Aggregation Network, PANet）^[91] 和双向特征金字塔网络（Bidirectional Feature Pyramid Network, BiFPN）^[39]，它们各有侧重点，并在不同的检测任务中发挥重要作用。

FPN 是一种经典的特征金字塔结构，广泛应用于目标检测任务中，如 Faster R-CNN^[35]、RetinaNet^[43] 等。首先，深层的高语义信息特征图通过上采样进行逐级放大，并与低层特征进行融合，从而增强低层特征的高层语义信息。横向连接（Lateral Connections, LC）即在上采样过程中，每个尺度的高层特征会与对应尺度的底层特征进行元素级加和，确保信息有效传递，避免特征丢失。融合后的特征图在多个尺度上进行预测，使得模型能够同时检测小目标和大目标，提高检测的鲁棒性。FPN 的主要优势是引入了多尺度检测机制，使得模型能够兼顾小目标和大目标的检测。然而，FPN 采用的是固定权重加权方式，不能对不同尺度特征进行自适应调整，可能导致信

息不均衡。PANet 在 FPN 的基础上进一步改进, 增加自底向上的信息流 (Bottom-up Path Augmentation, BPA)。FPN 仅考虑自顶向下的信息传播, 而 PANet 额外增加了一条从低层到高层的路径, 使得底层特征也能向上传递, 有助于保留更多细节信息, 提高小目标的检测能力; 并提出自适应特征池化 (Adaptive Feature Pooling, AFP) 机制, 使得目标特征可以更好地适应检测网络, 提高目标定位精度。

PANet 通过增强信息流的路径聚合, 提升了检测精度, 尤其在小目标检测方面表现更优。但 PANet 仍然依赖固定的特征融合方式, 未能自适应地调整各层特征的重要性。BiFPN 是 EfficientDet 检测框架的核心特征融合模块, 相比于 FPN 和 PANet, 它进一步优化了特征融合方式, 提高了检测精度和计算效率。BiFPN 主要创新包括双向特征融合 (Bidirectional Cross-Scale Fusion, BCF)、可学习的特征融合权重 (Learnable Weighted Fusion, LWF) 和冗余连接优化 (Efficient Feature Refinement, EFR)。在 FPN 仅支持单向传播的基础上, BiFPN 允许特征信息在不同层级间进行双向流动, 确保高层特征可以有效增强低层特征的表现, 同时低层特征也可以补充高层特征的细节信息。BiFPN 采用可学习的融合权重, 使得模型可以自适应调整不同尺度特征的贡献, 而不是简单地采用固定加权或拼接方式。这样可以提升特征的有效性, 使得特征融合更具针对性。BiFPN 移除了 FPN 和 PANet 结构中冗余的特征融合路径, 减少了计算开销, 使得在保证高检测精度的同时降低了计算复杂度, 提高了推理速度。

综上所述, 不同的特征融合模块在目标检测任务中发挥着重要作用, 其结构对比如图2.5所示。FPN 通过自顶向下的信息传递和横向连接, 实现多尺度特征融合, 提高检测能力, 适用于常规目标检测任务。PANet 在 FPN 基础上增加自底向上的特征流, 增强了特征表达能力, 尤其适用于小目标检测。BiFPN 进一步改进了 PANet, 采用可学习的融合权重, 增强了双向信息流, 同时减少计算冗余, 提高了模型的检测精度和计算效率, 适用于轻量级检测任务。

在舰船检测任务中, 由于舰船目标可能具有较大尺度变化, 同时海面背景复杂且杂波干扰强, 采用先进的特征金字塔网络 (如 FPN、PANet 或 BiFPN) 可以在保证检测精度的同时提升计算效率, 使得检测网络更加适应复杂的海上场景。尤其是在处理弱散射的小目标或尺寸多变的大型舰船时, 这些融合模块能够有效捕捉多层次、多尺度的特征信息, 从而在海况多变、目标多样的环境下取得更为稳健的检测表现。

2.1.3.3 预测头 (Prediction Head)

预测头是数据驱动的舰船检测算法中的关键模块, 负责根据网络输出的特征图生成最终的检测结果。它通常由一系列卷积层或子网络组成, 用于完成目标分类、边界框回归以及可能的附加任务 (如关键点检测、分割等)。在舰船检测任务中, 由于目标可能呈现多样的尺度、形状和散射特征, 如何设计一个高效而准确的预测头对整体检测性能至关重要。




图 2.5 FPN、PANet 与 BiFPN 结构对比图

在检测任务中，分类部分的主要目标是判别某个候选区域或特征单元（如锚框、网格单元）是否包含目标。对于舰船检测而言，分类可分为二分类（舰船 / 非舰船）或多分类（区分不同类型的舰船，如货船、渔船、军舰等）。常见的做法是通过一个或多个卷积层将特征图映射到对应的分类通道数上，并在输出端使用 Softmax 或 Sigmoid 激活函数来预测各类别的置信度。以 Faster R-CNN 为例，RoI Pooling 提取的区域特征会在全连接层后接一个分类分支；在 YOLO 等单阶段检测器中，分类和回归往往在同一个输出层进行并行预测。在舰船检测中，背景样本往往远多于目标样本。RetinaNet^[43] 中提出的 Focal Loss 能够缓解正负样本严重不平衡的问题，使模型更聚焦于难以分类的样本，从而提升检测精度。

除了分类外，目标检测的另一个核心任务是预测目标的位置和尺寸信息，即边界框（Bounding Box）。常见的做法是为每个候选框或网格单元（Grid Cell）回归出目标位置的偏移量，从而将候选框映射到更精确的目标位置常用的回归损失包括平滑 L1 损失（Smooth L1）^[75] 和 IoU 系列损失（如 IoU、GIoU、DIoU、CIoU 等）^{[92][93]}。平滑 L1 在偏移量较小的情况下能保持梯度稳定，而 IoU 系列损失直接度量预测框与真实框的重叠程度，更能反映检测性能。它通过计算预测框和真实框的重叠度来评估检测效果，重叠度越大，IoU 值越高，检测结果越好。然而，IoU 只能考虑边界框的重叠区域，并忽略了框的位置和形状之间的差异。这意味着在很多情况下，即使预测框和真实框有较高的重叠，位置的差异仍可能影响检测效果，特别是在处理长宽比差异较大的目标时。距离交并比（Distance Intersection over Union, DIoU）是一种改进的 IoU 系列损失函数，旨在通过加入更多的几何信息来进一步优化目标检测中边界框回归的性能。DIoU 在传统的 IoU 损失的基础上，考虑了预测框与真实框之间的中心点距离，使得边界框回归更加有效，特别是在处理较大偏差的情况下。DIoU 通过

在 IoU 损失中引入了中心点距离这一额外的度量，来解决 IoU 在边界框位置上的缺陷。DIoU 计算其损失值如图2.6所示。




图 2.6 IoU 与 DIoU 计算过程示意图

其中： IoU 是标准的交并比 (Intersection over Union)； $\rho(b, b^*)$ 是预测框 b 和真实框 b^* 的中心点之间的欧氏距离； c 是包围框（即包含预测框和真实框的最小框）的对角线长度。DIoU 提出了在 IoU 损失中加入距离项，以强化模型对边界框位置的关注。相比传统的 IoU 损失，它能够更好地处理框位置偏差，提升目标检测的精度。与传统的平滑 L1 损失相比，DIoU 在检测精度和框的定位上具有更大的优势，尤其在处理难度较大的目标时表现尤为突出。DIoU 考虑了预测框与真实框之间的中心点距离，这使得回归过程更有针对性，尤其是在两个框的重叠较小而位置差异较大的情况下。通过最小化中心点的距离，模型能够更有效地聚焦于目标位置的准确性。IoU 损失在框位置较远时，IoU 值会迅速下降，导致训练过程中的梯度消失或不稳定。DIoU 通过引入中心点距离项，弥补了这一缺陷，使得即使在位置差异较大的情况下，模型仍然可以获得有效的梯度更新。DIoU 在目标检测中能够有效处理目标尺度和形状的变化，特别是对于形状较为复杂或长宽比差异较大的目标，DIoU 具有更好的表现。

Anchor-based 目标检测算法，尤其是基于 Faster R-CNN、RetinaNet 或 YOLO 9000 以后版本，会在输入图像或特征图上生成一系列锚框，这些锚框具有预定义的尺度和长宽比 (Aspect Ratios)。随后，通过网络对这些锚框进行分类和回归，以获得最终的检测结果。对于舰船检测而言，锚框的设计可根据数据集内舰船尺寸的先验统计进行微调。近年来也出现了一些 Anchor-free 的检测范式，如 CenterNet^[81] 等。它们不再依赖预定义锚框，而是直接在特征图上预测目标中心点和边界。在传统 Anchor-base 检测范式中，算法需要设定 IoU 阈值或正负样本的比例来判定一个锚框是否与目标匹配。若阈值设置不当，可能导致大量的误检或漏检。

综上所述，预测头的设计对于深度学习舰船检测的整体性能影响重大。无论是 Anchor-based 的方法（如 Faster R-CNN、SSD、RetinaNet、YOLO 9000 以后版本）还是 Anchor-free 的方法（如 FCOS、CenterNet），都需要在分类和回归两方面进行充分

考虑,以适配多尺度的舰船目标和复杂的海面杂波环境。在舰船检测场景下,如何根据舰船目标大小分布、自身外形特征、SAR 图像信噪比等因素来定制化预测头,是一个值得深入研究的方向。




图 2.7 NMS 结果示意图

2.1.3.4 后处理 (Post-processing)

在数据驱动的舰船检测的流程中,预测头输出的结果通常包含大量的候选框,其中不仅包含正确检测到的目标框,也包含大量高度重叠或重复的框。为了在最终输出中保留最有效的检测结果,需要进行后处理来合并。其中,非极大值抑制 (Non-Maximum Suppression, NMS) 及其改进算法是最为常用的后处理策略,能够在减少冗余检测的同时保持较高的检测精度,其结果如图2.7所示。

NMS 的核心思想是:对于同一目标附近出现的大量候选框,只选择一个最优的保留。NMS 算法通常先根据检测的置信度 (Confidence Score) 或类别概率对候选框进行排序,然后从最高置信度的候选框开始,逐一剔除与其重叠度超过阈值的其他候选框。这样就可以在保留高置信度检测结果的同时,减少重叠过高的冗余框。传统 NMS 的伪代码流程如算法1。

在舰船检测任务中,尤其是高分辨率 SAR 图像中,同一舰船目标可能被多个邻近的锚框检测到,从而产生大量重叠的检测结果。NMS 能够有效去除这种重叠冗余,提升最终的检测表现。尽管 NMS 简单高效,但它存在一些局限:当目标相互紧邻或重叠时,传统 NMS 可能会将其中一个目标抑制掉,从而导致漏检;使用固定的 IoU 阈值在不同尺度或不同形状目标中并不总是最优;当置信度分布不均衡时,过早剔除某些候选框可能会损失有价值的信息。

为了解决这些问题,研究者提出了多种改进策略:Soft-NMS^[94] 将传统 NMS 中“硬抑制”的策略改为“软抑制”,即对重叠框不直接删除,而是根据 IoU 大小对其置信度进行衰减,从而降低了将相邻目标错误删除的概率。这对于舰船紧密排列的场景,能够减少漏检并提升检测精度。在传统 NMS 中仅使用 IoU 进行重叠度判断,有时会

忽略目标中心位置和形状等因素。Weighted-NMS^[95] 并不直接丢弃与最大置信度框重叠的其他框，而是对其进行加权融合（Weighted Averaging），得到一个更加精确的预测位置。对于尺度变化明显的舰船目标，或当多个高置信度框出现时，Weighted-NMS 能够更好地利用多源信息，得到更优的最终检测框。

Algorithm 1 非极大值抑制（NMS）算法示例

Require: 候选框列表 $\mathcal{B}$

Ensure: 最终保留的检测框列表 $\mathcal{S}$

```

1: 将候选框按照置信度从高到低排序
2:  $\mathcal{S} \leftarrow \emptyset$ 
3: for each  $B_i$  in 排序后的候选框列表 do
4:   if  $B_i$  尚未被抑制 then
5:     将  $B_i$  加入到  $\mathcal{S}$ 
6:     for each  $B_j$  in 剩余候选框 do
7:       if  $\text{IoU}(B_i, B_j) > \theta$  then
8:         标记  $B_j$  为被抑制
9:       end if
10:    end for
11:   end if
12: end for
13: return  $\mathcal{S}$ 

```

对于一些 Anchor-free 的检测方法，其输出的预测结果不依赖预先定义的锚框，但在最终阶段仍然需要对重叠预测进行去重。此时也会使用 NMS 或其变体进行后处理。Anchor-free 头与 Anchor-based 头在生成候选框方式上有差异，但在后处理时面临相似的“重叠检测”问题。在舰船检测中，尤其是远海场景下，舰船的分布可能相对稀疏，也可能在港口、编队等情况下密集出现。NMS 家族算法需要结合具体场景特点选择合适的 IoU 阈值或改进策略。若阈值过高，易出现虚警；阈值过低，则可能将相邻的真实舰船错误合并。此外，海面杂波和多路径散射会产生许多“伪目标”，对后处理算法提出更高要求。综上所述，后处理环节在舰船检测算法中不可或缺。无论是传统 NMS，还是 Soft-NMS、Weighted-NMS 等改进算法，都需要结合舰船目标的尺度分布、海面背景的杂波特性以及检测器输出的特征进行选择或微调。对后处理策略的适配和优化，往往能在减少冗余检测的同时，显著提升对弱散射、小目标和密集舰船的检测精度。

2.1.4 学习策略

深度学习舰船检测模型的训练流程一般涵盖数据预处理、前向传播、损失计算、反向传播和优化等关键步骤。训练的目的是通过不断调整模型的参数，使得模型能够在训练数据上学习到有效的特征，从而在测试数据上实现高精度的目标检测。数据

预处理是训练过程中的第一步，主要包括图像的归一化、尺寸调整以及数据增强等。通过数据增强（如随机裁剪、旋转、翻转等）可以扩展训练数据集，提高模型的泛化能力。在前向传播过程中，输入图像通过主干网络进行特征提取，并通过 neck 模块进行多尺度特征融合，最后通过预测头输出检测结果。在训练过程中，损失函数用于评估预测结果与真实标签之间的差异。常见的损失函数包括用于分类的交叉熵损失、用于边界框回归的平滑 L1 损失，以及 IoU 损失等。通过反向传播算法计算梯度，并使用优化算法（如 SGD、Adam 等）更新网络权重。训练过程通过不断优化损失函数，直到模型收敛。

2.2 SAR 舰船检测数据集

2.2.1 SSDD 数据集介绍

本节详细介绍基于深度学习的 SAR 舰船检测领域中最具影响力的数据集之一——SAR Ship Detection Dataset (SSDD)。SSDD 数据集^[68]最早由 Li 等人在 2017 年 12 月 1 日于“BIGSAR DATA”会议上公开发布，是首个专为深度学习 SAR 舰船检测设计的开放数据集。该数据集不仅为后续研究提供了丰富而多样的训练样本，也为不同检测算法的公平比较奠定了基础。

SSDD 数据集由 1,160 幅 SAR 图像组成，这些图像来源于加拿大的 Radarsat-2、德国的 TerraSAR-X 以及欧空局的 Sentinel-1 卫星，图像分辨率范围从 1m 到 15m 不等。数据集中提供了 2,456 个舰船标注实例，涵盖了多种海况与拍摄角度，包括良好海况与恶劣海况、近岸与离岸等多样场景。图像极化方式涉及 HH、VV、VH 和 HV，充分体现了 SAR 成像在不同极化条件下的多样性与复杂性。

SSDD 最初版本仅提供传统的水平-垂直矩形框 (Horizontal-vertical Bounding Boxes, BBox) 标注，但随着研究需求的不断提升，其官方发布版本已扩展为三种标注格式，包括：BBox-SSDD，采用 PASCAL VOC 格式对舰船进行水平矩形框标注，便于传统目标检测算法的训练与评价；RBox-SSDD，针对舰船具有明显旋转角度的特点，提供旋转矩形框 (Rotated Bounding Boxes, RBox) 标注，以实现更精准的目标定位和方向估计；PSeg-SSDD，基于像素级的多边形分割 (Polygon Segmentation) 标注，能够更精细地刻画舰船轮廓，极大减少背景干扰。官方在重新标注过程中剔除了原有错误标签，并制定了严格的使用标准，如训练测试集划分、舰船尺寸定义等，确保数据集在公平性和准确性上的高标准要求。SSDD 具备以下显著特点：一是多源数据与分辨率多样性，不同卫星平台和多种极化模式为研究提供了丰富的图像样本，既适用于低分辨率的全局监测，也能满足高分辨率下的小目标检测需求；二是场景与海况多样性，数据集涵盖从平静海面到复杂靠岸环境的多种场景，有助于评估模型在不同背景条

件下的鲁棒性；三是严格标注与多格式支持，经过重新标注的高质量标签不仅提高了目标检测的精度，也为模型在多任务学习（如旋转检测和实例分割）中提供了理想的数据基础。




图 2.8 SSDD 数据集舰船目标的数据统计分析

本节对 SSDD 数据集进行了详细的数据统计分析，并生成了以下四幅图2.8以直观展示舰船目标的各项特性。图2.8(a)展示了 SSDD 数据集中所有舰船目标框的宽度与高度分布情况。统计数据显示，舰船目标框宽度的最小值为 4 像素，最大值为 382 像素，平均宽度为 36 像素，中位宽度为 24 像素；而高度的最小值为 5 像素，最大值为 298 像素，平均高度为 39 像素，中位高度为 28 像素。散点图中各统计值的明显差异表明，舰船目标框尺寸分布具有较大的多样性，这对多尺度检测算法的设计提出了挑战。图2.8(b)展示了 SSDD 数据集中舰船目标框宽高比的统计分布。统计结果显示，这些目标框的宽高比取值范围为 0.77 到 2.60，平均宽高比约为 1.41。宽高比反映了舰船目标在 SAR 图像中的基本形态。舰船通常呈现出较长或较短的矩形形态，而宽高比的分布范围表明，不同舰船在图像中可能具有不同的比例特征。在图像预处理阶段，保持原始图像尺寸的归一化是关键步骤。由于深度学习模型通常要求固定尺

寸的输入图像，不恰当的尺寸缩放可能会破坏目标的原始比例，从而导致信息损失或形状失真。可针对常见宽高比范围设计专门的 anchor 策略，或采用自适应调整机制来改善不同尺度目标的检测性能。图2.8(c)对舰船目标框的面积进行统计，并将面积单位标准化为 $\times 10^4$ 。直方图显示，大部分舰船目标框的面积集中在 0 到 2×10^4 之间，平均面积约为 0.14×10^4 像素，这表明 SAR 图像中的舰船目标通常尺寸较小，尤其在复杂背景中容易被忽略。图2.8(d)展示了 SSDD 数据集中所有舰船目标框中心坐标的统计分布情况。统计结果显示，舰船目标框中心 x 坐标的范围为 6 到 537，平均值为 227，中位数为 219；而中心 y 坐标的范围为 6 到 453，平均值为 157，中位数为 153。中心坐标数据反映了舰船在 SAR 图像中的空间分布情况，表明大多数舰船目标的中心位置分布较为集中，这有助于后续目标定位和区域候选生成。中心坐标分布较为集中或存在明显偏斜，则可能需要采用区域生成或数据增强策略以平衡训练样本，进而提高模型的鲁棒性。

总的来说，SSDD 数据集凭借其丰富的图像样本、多样的标注格式以及严格的数据使用标准，为深度学习 SAR 舰船检测算法的训练和评价提供了坚实的数据支撑。通过对图像尺寸、目标框尺寸、宽高比和中心分布的全面统计分析，可以更深入地理解数据的内在特性，从而为多尺度、小目标以及复杂背景下的舰船检测算法提供理论支持和实验依据。SSDD 的开放极大地推动了该领域的发展，也为后续算法的改进和新技术的探索提供了宝贵资源。

2.2.2 HRSID 数据集介绍

近年来，基于卷积神经网络的检测方法展现出强大的特征表达能力和自适应性，但现有 SAR 舰船数据集在图像分辨率、样本数量和标注精度等方面均存在局限，进而制约了深度学习方法的发展。HRSID 数据集^[69]正是在这种背景下提出，旨在为基于 CNN 的舰船检测与实例分割任务提供一个高分辨率、标注精细、场景复杂且具有代表性的数据源。

HRSID 数据集主要由 136 幅全景 SAR 影像构成，这些影像来自不同 SAR 平台，如 Sentinel-1B、TerraSAR-X 以及 TanDEM-X，分辨率一般在 1 至 5 米之间。为了充分利用这些高分辨率影像，研究者将原始全景图像裁剪成 800×800 像素的小图，这既保证了输入尺寸与 CNN 模型的匹配，又能保留舰船的细节特征。在预处理阶段，除对影像进行灰度显示外，还采用线性变换及剪切函数对像素值进行预处理，以突出舰船与背景之间的对比度。同时，为减少因港口建筑等干扰因素导致的错误标注，辅以成像日期相近的光学遥感影像进行辅助判断，从而为后续准确标注提供支持。由于全景 SAR 图像覆盖范围广且信息量大，若直接使用会出现冗余或重复问题，因此 HRSID 设计了四步裁剪流程以优化数据处理。首先，进行区域分割，将港口等目标

密集区域与舰船稀疏区域分离，避免重复裁剪。其次，采用 800×800 像素的滑动窗口对图像进行裁剪，在保留足够上下文信息的同时满足卷积神经网络的输入要求。随后，将裁剪窗口的步长设为 600 像素，使相邻图像之间保持约 20% 的重叠，从而保证舰船目标的完整性。最后，通过背景过滤自动剔除纯背景图像，确保数据集中的每幅图像均包含有效的目标信息。

针对 SAR 影像中背景干扰较强的问题，HRSID 采用基于多边形的精细标注方法。与传统的矩形框标注相比，多边形标注可以更准确地描述舰船轮廓，有助于后续实例分割任务。具体标注过程中，专家首先在全景影像上完成舰船目标的整体标注，然后将标注信息与裁剪后的图像对应转换。为避免在裁剪过程中出现重复或断裂的目标，研究者调整了标注与裁剪的顺序：先完成全景图像的标注，再利用滑窗技术生成各子图像的标注文件，从而提高标注精度并降低人工工作量。




图 2.9 HRSID 数据集舰船目标的数据统计分析

本节对 HRSID 数据集进行了详细的数据统计分析，并生成了以下四幅图 2.9，以直观展示舰船目标框的各项特性。图 2.9(a) 展示了数据集中所有舰船目标框的宽度与高度分布情况。统计数据显示，舰船目标框宽度的最小值为 1 像素，最大值达到 800

像素,平均宽度约为 37 像素,中位宽度约为 29 像素;而高度方面,最小值为 1 像素,最大值为 653 像素,平均高度约为 33 像素,中位高度约为 25 像素。不同尺寸指标之间存在较大差异,这表明舰船目标框的尺寸分布较为多样,增加了多尺度目标检测难度。图2.9(b)展示了舰船目标框宽高比的统计分布情况。从统计数据来看,大部分目标框的宽高比集中在约 0.11 至 1.53 之间(即第一个区间内,频数约为 1.13×10^4),而宽高比超出该范围的目标较少,尽管最高值可达 28.5,但这可能代表极少数异常或极端情况。宽高比分布反映了舰船在 SAR 图像中的基本形态,多数舰船呈现出近似正方形或轻微矩形的形状。图2.9(c)对舰船目标框面积进行了统计,面积单位标准化为 $\times 10^4$ 像素。直方图显示,绝大多数舰船目标框的面积集中在 0 到 1×10^4 之间,其中第一组频数达到约 1.67×10^4 ,表明大部分舰船尺寸较小,在复杂背景下容易被忽略。图2.9(d)展示了数据集中所有舰船目标框中心坐标的统计分布情况。统计结果表明,目标框中心 x 坐标的范围为 0 至 799 像素,平均值约为 401 像素,中位数约为 409 像素;中心 y 坐标的范围同样为 0 至 799 像素,平均值约为 399 像素,中位数约为 399 像素。中心坐标的分布反映了舰船在图像中的空间分布情况,显示出较为均衡的分布趋势,有助于后续目标定位和候选区域生成;若中心坐标分布存在明显的部分区域集中,则可能需要采用区域生成或数据增强策略以平衡训练样本,从而提高模型的鲁棒性。

HRSID 数据集中共包含 5604 幅 800×800 像素的 SAR 图像,标注的舰船目标总数达 16951 个,平均每幅图像包含约 3 个目标。按照 MSCOCO 的尺度划分标准,目标大致分为三类:小型舰船目标约占 54.5%;中型舰船目标约占 43.5%;大型舰船目标仅占 2%。这一分布表明数据集主要针对小型和中型目标的检测问题,而大型目标由于样本较少,检测时仍面临一定挑战。HRSID 数据集不仅包含单个目标的简单场景,还特别纳入了多种复杂情形,包括港口区域中的检测任务,此类区域常受到建筑物、起重机等人造设施的干扰,容易引发误检;船群密集区域中,多个相邻舰船目标存在遮挡或重叠,给非极大值抑制算法的准确性带来挑战;水道中簇集的小目标则因在狭窄环境下分布密集,进一步增加了检测的难度;此外,大尺寸舰船目标虽样本较少,但其复杂的外形特征同样对检测器的定位精度提出了更高要求。这些设计使得 HRSID 数据集更贴近实际应用场景,有助于推动模型在复杂环境下的鲁棒性和泛化能力。总体而言,HRSID 数据集弥补了传统 SAR 舰船数据集中分辨率低、样本不足和标注不精的问题,为基于深度学习的目标检测与实例分割提供了坚实的数据基础。

2.3 SAR 舰船检测评价指标

在 SAR 舰船检测任务中,为全面评估检测算法的性能,常用的评价指标包括真阳性(True Positive, TP)、假阳性(False Positive, FP)、假阴性(False Negative, FN)、

准确率 (Precision)、召回率 (Recall)、F1 得分以及平均准确率 (Average Precision, AP)。真阳性 (TP) 表示正确检测出的舰船目标数目。假阳性 (FP) 指错误地将背景或其他非舰船目标误检测为舰船的数目。假阴性 (FN) 指实际存在但未被检测器检测出的舰船目标数目。

表 2.2 SAR 舰船检测中的混淆矩阵指标定义

真实类别	检测为舰船	未检测为舰船
存在舰船 (正样本)	TP (真阳性)	FN (假阴性)
不存在舰船 (负样本)	FP (假阳性)	TN (真阴性)

准确率 (Precision) 表示检测器在检测出的目标中, 真正为舰船的比例, 其计算公式为

$$\text{Precision} = \frac{TP}{TP + FP}. \quad (2-1)$$

召回率 (Recall) 表示所有真实舰船目标中被正确检测出的比例, 其计算公式为

$$\text{Recall} = \frac{TP}{TP + FN}. \quad (2-2)$$

F1 得分是准确率与召回率的调和平均, 兼顾了两者的平衡性, 其计算公式为

$$F1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (2-3)$$

平均准确率 (Average Precision, AP) 用于衡量检测器在不同置信度阈值下的综合性能, 其定义为精确率-召回率曲线下的面积, 公式为

$$AP = \int_0^1 p(r) dr, \quad (2-4)$$

其中 $p(r)$ 表示在召回率为 r 时的准确率。对于多类别检测任务, 通常会计算每个类别的 AP , 然后取平均得到均值平均准确率 (Mean Average Precision, mAP)。本文中所述的 AP 指标, 均指在交并比阈值为 0.5 条件下计算得到的平均准确率。

综上所述, 精准的舰船检测评价通常侧重于准确率、召回率、F1 得分以及平均准确率, 它们分别从检测结果的正确性、覆盖率及整体性能等方面反映算法的优劣, 为后续模型改进提供了重要参考指标。

2.4 本章小结

本章主要围绕深度学习舰船检测的算法原理、数据集、评价指标进行了系统阐述, 首先介绍了深度学习在 SAR 舰船检测中的应用背景, 指出传统方法依赖手工特征提取存在的局限性, 而基于深度神经网络的端到端检测方法则在精度和鲁棒性上取得

了显著进展。随后详细讨论了检测模型的关键模块，包括特征提取网络（Backbone，如 VGG、DenseNet、MobileNet 系列和 GhostNet 等）、特征融合模块（如 FPN、PANet 与 BiFPN）以及预测头的设计与实现。同时，还对后处理算法进行了介绍，强调了它们在消除冗余检测框、提高定位精度方面的重要作用。本章对当前广泛使用的 SAR 舰船检测数据集进行了介绍，重点分析了 SSDD 和 HRSID 两个数据集的构成、标注格式和数据统计特性。通过对目标框宽度、高度、宽高比、面积及中心坐标的统计，揭示了舰船目标在 SAR 图像中的尺寸多样性和分布特点。为了全面评价检测算法的性能，本章详细介绍了常用的评价指标，并给出了相应的数学公式。这些指标从不同角度反映了检测结果的准确性和覆盖率，为后续模型性能比较和优化提供了理论依据。

第三章 预测感知的 SAR 多尺度目标检测模型

数据驱动的舰船检测方法中,区分正样本和负样本决定了网络的优化目标直接影响检测性能。正负样本划分的步骤被称为标签分配策略。在之前的检测模型中,标签分配策略是基于研究人员经验的启发式技术。因此,需要研究人员不断调整超参数,而这些参数不恰当的设置会降低模型性能。此外,训练目标和测试目标之间存在显著差异。为了解决这些问题,本章提出了一种预测感知的 SAR 多尺度目标检测模型。并且本章提出了一种专门用于 SAR 舰船检测的新网络以提高多尺度检测性能。首先,在网络中引入交并比预测并将其结果指定为预测框定位精度的估计。预测感知的 SAR 多尺度目标检测模型提出一种新的基于分类和定位的综合方法来评估候选框的质量。这减少了训练和测试目标之间的差异。本章方法同时利用当前模型的学习状态和预测框的先验信息,以自适应的方式选择最佳正样本。本章设计了一种多尺度舰船检测网络,重点关注小型舰船丰富的上下文信息。在不同尺度上进行特征融合和特征增强后,预测感知的 SAR 多尺度目标检测模型将浅层纹理和深层语义信息相结合,以检测多尺度目标。在 SSDD 和 HRSID 数据集上进行了多次实验,结果表明所提出的方法的优越性。

3.1 引言

在数据驱动的舰船检测领域中,标签分配作为训练阶段的关键步骤,其研究与优化尚不充分。标签分配指的是在训练过程中将特征图上的不同位置标记为正样本或负样本的过程,它直接决定了模型在训练阶段所学习的目标,从而对最终的检测性能产生重要影响。现有检测模型采用了多种标签分配策略。以 FCOS (Fully Convolutional One-Stage Object Detection) 为代表的无锚框检测器,直接将特征图中与真实框 (Ground Truth, GT) 对应的位置视为正样本,从而避免了对先验锚框的依赖,简化了标签分配流程^[96]。这一策略在一定程度上降低了模型的复杂度和冗余计算,但在目标尺度差异大、密集分布或背景复杂的 SAR 场景中,由于缺乏锚框提供的空间约束,检测性能往往难以保证。两阶段检测器如 Faster R-CNN,则通过候选区域生成网络首先提出潜在目标区域,再对这些区域进行分类与回归。该类方法通常将与真实框交并比最大的候选框,或 IoU 超过某一阈值的候选框指定为正样本。这种机制提高了标签划分的合理性与灵活性,使检测模型在不同目标规模下具有更好的适应能力。相较而言,单阶段检测算法则在图像上划分多个网格单元,在每个单元中直接回归目标类别及边界框参数。标签分配通常依据目标中心点所在的网格位置,再结合 Anchor 与真

实框的 IoU 关系确定正样本。这种方式提升了检测效率，但由于其粗粒度的空间分配机制，面对 SAR 图像中目标尺寸变化大或邻近背景强干扰时，鲁棒性仍存在不足。

总体而言，现有标签分配策略大多基于人工经验设定的固定规则^[97]，在复杂 SAR 场景下表现不尽理想。一方面，手工设定的超参数（如正样本数量、IoU 阈值、正负样本比例等）需要反复调试，不仅增加了训练成本，还可能因设定不当而影响检测性能。另一方面，训练与测试阶段目标不一致的问题亦影响模型的稳定性与准确性。训练过程中，模型同时优化分类损失和定位损失，而测试阶段则仅依据分类得分执行非极大值抑制（NMS）以去除冗余框。这种机制可能导致分类置信度高但定位不准的框被保留，反而将定位更准确但分类得分稍低的框剔除。图3.1展示了该问题的具体实例：蓝色边框为真实值，红色边框为 NMS 保留的检测框，绿色边框为被 NMS 抑制的检测框。结果表明，YOLO V4 在处理此类情况时存在性能损失。在图3.1(a)中，若保留下来的检测框与真实目标的 IoU 低于 0.5，则容易导致漏检，从而影响检测准确性；而在图3.1(b)中，即便某些框定位准确，但因其分类得分略低而被 NMS 移除，也会造成检测结果与实际偏离。这些现象表明，现有标签分配策略在应对复杂背景干扰和确保分类置信度与定位精度一致性方面仍有显著改进空间。




图 3.1 训练目标与测试目标严重不一致的可视化实例

为了进一步提升舰船检测的准确性，本章设计自适应的标签分配策略，减少对人工干预的依赖，提高模型的鲁棒性和泛化能力。近期，大量实验结果表明，使标签分配策略具有自适应性和预测感知性具有巨大潜力^{[98][99][100]}。与传统的先选择正样本再计算损失的方法相比，基于损失的方法必须对所有候选框计算损失，其中大部分计算均属冗余，并占用大量内存资源，从而降低了整体效率。为了解决这一问题，本章提出了一种新颖的解决方案——预测感知的 SAR 多尺度目标检测模型，该方法通过整合模型当前的学习状态与锚框的先验信息，以自适应的方式采样高质量正样本，从而实现对标签分配过程的优化，并有效降低不必要的计算开销。

本章其余部分的结构安排如下：第 3.2 节阐述了模型预测与先验信息引导的标签分配策略，重点解析了交并比预测模块以及基于中心规则与预测感知质量的自适应

正样本筛选算法；第 3.3 节提出了多尺度舰船检测网络，详细阐述浅层特征复用策略的细粒度信息保留与自适应空间特征融合模块；第 3.4 节系统展示了模型预测引导的多尺度舰船检测算法在 SSDD 与 HRSID 数据集上的实验结果并进行分析；第 3.5 节为本章小结。




图 3.2 预测和先验信息引导的标签分配

3.2 模型预测与先验信息引导的标签分配策略

3.2.1 原理介绍

训练目标与测试目标之间的显著不一致严重影响了检测性能，这主要源于传统标签分配策略未能充分利用定位信息，导致正样本选择存在偏差，同时大量不必要的计算又占用了宝贵的内存资源，进一步降低了整体效率。为了解决上述问题，本节提出了一种新颖的标签分配方法——预测和先验信息引导的标签分配（A Prediction And Prior Information Guided Label Assignment, PPIG），专门用于 SAR 舰船检测任务，其整体框架如图3.2所示。蓝色箭头指示的是模型训练阶段，红色箭头指示的是模型测试阶段。具体来说，PPIG 从理论和实践两个层面出发，通过以下几个方面改进传统方法：首先，通过添加一个单一的卷积层预测每个锚框的交并比，在不牺牲效率的前提下准确反映候选框的定位精度，从而在训练阶段更精准地选择正样本^[101]。这种方法依赖于深度神经网络对局部特征的捕捉能力，使得具有更多目标信息的候选框获得更高的 IoU 预测值，为后续的正样本筛选提供了有效依据。其次，PPIG 将锚框的分类得分和定位质量得分与先验信息相结合，模型当前的学习状态可以动态指导标签分配过程，先验知识确保训练前期预测结果不准的阶段仍能选择最优质量候选框。

被合理地纳入正样本集合。第三，候选框的质量采用分类和定位双重标准进行综合评价，并在非极大值抑制过程中应用这一标准，以减少训练目标与测试目标之间的差异，从而在降低虚警率的同时，确保检测器输出更为精确和一致的目标框。最后，由于低质量的候选框在正样本采样阶段已被有效剔除，测试阶段的虚警率得以显著降低，进一步提升了整体检测性能。总体而言，PPIG 通过引入 IoU 预测、整合先验信息以及采用模型预测评价候选框，为 SAR 舰船检测提供了一种精确且具有良好扩展性的标签分配解决方案。

3.2.2 交并比预测

在训练阶段，检测模型通常同时优化分类损失和定位损失，以期在学习过程中平衡类别判别与精确定位。然而，在测试阶段，由于仅依赖分类得分并通过非极大值抑制^[102]去除重复边界框，这种训练与测试之间的目标不一致问题便愈发明显，导致分类得分与实际定位质量之间存在显著的失配现象，从而使训练目标次优并降低整体检测性能。具体而言，在训练过程中，由于可以直接利用标注数据计算锚框与舰船目标的交并比，检测器能够获得准确的定位质量；但在测试阶段，检测到的边界框与实际目标之间的 IoU 信息是不可获得的，这就使得单纯依赖分类得分的 NMS 无法充分反映边界框的真实质量，进而影响最终的检测效果。

为了解决这一问题，本节在检测网络中的预测头中添加了一个额外的卷积层，用于预测每个候选框与其对应的舰船的 IoU 值，并通过 Sigmoid 激活函数将预测值归一化。这样一来，检测器便能在测试阶段利用预测的 IoU 信息来弥补传统方法中因缺失定位质量信息而导致的不足。更进一步，为了使 IoU 预测与分类、定位任务达到协同优化的效果，本节将 IoU 预测任务与分类和定位任务采用联合训练的方式进行，并定义了基于 Focal loss^[43] 的 IoU 预测损失，旨在使预测的 IoU 值与真实 IoU 之间的误差最小化，从而提高整体检测精度。

本节设计了一个候选框质量评价函数，该指标同时考虑分类得分和定位估计精度，如公式3-1所示，置信度得分与预测的 IoU 相乘得到一个综合衡量候选框质量的评分。该质量函数能够在训练和测试阶段均为候选框提供更加合理的排序依据，有效缓解训练目标与测试目标之间的差异。通过这种方式，低质量的候选框在正样本采样阶段便被有效排除，既降低了虚警率，又提高了检测器对实际目标的捕捉能力，从而实现了整体检测性能的显著提升。

$$\delta(\omega, i) = \text{conf}(\omega, i) \times \text{pred_IoU}(\omega, i) \quad (3-1)$$

其中， ω 和 i 分别表示候选框和对应舰船目标的索引， $\text{conf}(\omega, i)$ 表示相应候选框的置信度得分，而 $\text{pred_IoU}(\omega, i)$ 则代表该锚框与船只之间的预测交并比。由于检测检测任务本质上只需区分前景（舰船目标）与背景，传统的多类别分类问题被简化为前

景-背景二分类，因此在该场景中，置信度得分便直接代替了复杂的分类分支。为充分反映候选锚框的整体预测质量，本节构造了一个评价函数 $\delta(\omega, i)$ ，该函数通过结合 $\text{conf}(\omega, i)$ 和 $\text{pred_IoU}(\omega, i)$ 来综合衡量每个候选框在分类与定位上的表现，从而为后续的非极大值抑制提供更为合理的排序依据。

具体来说， $\delta(\omega, i)$ 采用将置信度得分与预测的交并比相乘的方式，以此直观地反映候选框的综合质量。这样的设计在理论上实现了训练阶段与测试阶段评价标准的一致性，有效缓解了二者之间因目标定义不同而引发的不匹配问题：在训练过程中可以直接利用真实标注信息计算出准确的 IoU，而在测试过程中，由于真实 IoU 不可获得，通过预测得到的 IoU 与置信度得分的结合能够较好地模拟训练时的目标分布，从而降低误报并提高检测精度。为了在不牺牲效率的前提下进一步提升检测器的准确性，本节在检测模型中仅使用了单个卷积层来预测每个锚框与舰船目标之间的 IoU。该卷积层利用轻量级的结构，在保持较低计算复杂度和内存占用的同时，实现了对候选框定位质量的高效估计。通过将该 IoU 预测与置信度得分进行联合训练，利用 Focal loss 等策略缩小预测值与真实值之间的差距，从而进一步增强了候选框排序的准确性，并在 NMS 过程中使得高质量检测框得以优先保留。




图 3.3 置信度与交并比预测之间的差异

为了直观探究预测交并比与置信度之间的差异，图3.3展示了二者的学习目标。为便于说明，图3.3中的网格尺寸设为 7×7 ，而非实验中使用的最小网格尺寸 19×19 。在该图中，预测的 IoU 和置信度分别与初始锚框一一对应，并且每个特征图匹配三个不同大小的初始锚框，因此本示例中所展示的学习目标对应于初始锚框 $[138, 70]$ 。正样本的网格在舰船中心以红点标记，其学习目标以淡紫色字体显示；而置信度与预测 IoU 的负样本分别用蓝色和橙色标注，没有标注的区域则视为忽略样本。图3.3的结果直观地表明，预测的 IoU 能够学习到比单纯的置信度更多的关于目标的细节信息，

其根本原因类似于标签平滑技术。传统的置信度仅包含网格中是否存在目标的信息，无法反映目标与预测边界框之间的定位精度（即 IoU 信息）；这种信息缺失导致训练阶段无法充分捕捉目标的细微定位特征，从而使得检测器在测试时出现分类得分与定位质量之间的不匹配问题。通过将预测 IoU 与置信度得分相结合构造综合评分函数，检测网络能够在非极大值抑制过程中对所有候选检测框进行更准确的排序，从而有效缓解训练目标与测试目标之间的不一致性。这种策略不仅在理论上实现了分类与定位信息的互补，还在实践中显著提升了检测模型对目标的捕捉精度和鲁棒性，为 SAR 舰船检测任务提供了一种高效且精确的正样本分配方案。

3.2.3 标签分配方法实现

传统的标签分配方法通常依赖于手工设计的固定规则，将候选锚框按照预设阈值或比例划分为正负样本。然而，在复杂的 SAR 场景中，由于舰船目标的纹理、尺寸以及在背景中的分布具有显著的多样性，这种固定规则往往难以覆盖所有情况。如果将低质量的预测强制分配为前景样本，不仅会使网络在训练过程中获得不准确的目标特征，还可能导致网络向次优方向收敛，从而严重影响检测性能。为此，本节设计了预测和先验信息引导的标签分配方法，该方法能够根据预测质量和先验信息自适应地分配正样本，从而在理论上统一了训练目标与测试目标，并在实践中提升了检测器的整体性能。设 N 表示舰船的数量，而 ξ_i 表示距离第 i 艘船中心最近的像素所形成的锚框聚类。对于第 i 艘船，其候选锚框 ω 的质量由公式 3-23-3 决定。

$$\hat{\omega} = \arg \max_{i=1}^N \Phi(\omega, i) \quad (3-2)$$

$$\Phi(\omega, i) = \underbrace{\mathbf{1}[\omega \in \xi_i]}_{\text{中心规则}} \times \left[\underbrace{IoU_{anchor_GT}(\omega, b_i)}_{\text{锚框先验知识}} + \underbrace{conf(\omega, i) \times pred_IoU(\omega, i)}_{\text{预测感知锚框质量得分}} \right] \quad (3-3)$$

其中， $\mathbf{1}[\omega \in \xi_i]$ 表示中心规则，即只有当候选锚框 ω 属于与第 i 艘船中心最近的锚框聚类 ξ_i 时，该项为 1，否则为 0； $IoU_{anchor_GT}(\omega, b_i)$ 表示候选锚框与真实边界框 b_i 之间的交并比，反映了锚框的先验匹配质量；而 $conf(\omega, i) \times pred_IoU(\omega, i)$ 则是检测器基于当前预测计算得到的感知质量得分，用以量化候选锚框在分类和定位方面的综合表现。PPIG 将正样本的选择问题视为在所有候选锚框中寻找使 $\Phi(\omega, i)$ 达到最大值的最优锚框。

这种设计充分整合了三方面信息：首先，通过中心规则，PPIG 有效抑制了那些远离舰船目标中心、质量较低的候选框，从而保证只有具有较高先验匹配度的候选框能够进入正样本集合；其次，利用锚框与真实边界框之间的 IoU 作为先验知识，使得正样本能够包含更多的目标信息；最后，通过结合预测置信度和预测 IoU 所获得的感知质量得分，为正样本的选择提供了动态、实时的评价标准。这种多因素融合的策略

略在理论上不仅缓解了传统固定规则在复杂场景中的局限性，而且在实践中降低了由于低质量预测导致的误差累积，提升了网络训练的收敛速度和最终检测性能。综上所述，PPIG 方法通过自适应地整合中心规则、候选框先验知识以及预测感知质量得分，能够精准地选取高质量的正样本，有效避免低质量预测干扰训练目标，从而实现了训练阶段与测试阶段目标的一致性，为 SAR 舰船检测任务提供了一种高效、鲁棒且具有理论与实践依据的正样本分配方案。




图 3.4 先验知识计算的示意图

在 PPIG 方法中，锚框与对应船只的交并比用于衡量锚框与真实目标在尺度和纵横比上的相似性。当确定舰船目标中心所在的网格后，即可计算该网格中的锚框与目标的 IoU（如图3.4所示）。然而，在训练的早期阶段，由于模型尚未充分收敛，当前学习状态下的 IoU 预测和置信度得分可能较为不准确。如果仅依据预测质量选择正样本，可能导致次优的正样本选择，进而影响模型的整体收敛效果。因此，在 PPIG 方法中，引入先验信息作为补充，以减少因预测误差带来的负面影响，使得正样本的选择更加稳健。

此外，锚框的质量评估应当充分反映当前模型的学习状态，这意味着预测质量应同时基于分类得分和定位精度进行综合考量。为此，PPIG 方法摒弃了繁琐的超参数调整，通过动态分配最优预测结果作为正样本来优化检测器性能。算法2详细描述了 PPIG 在训练阶段的工作流程：对于图像中的每个真实目标 i ，首先根据中心规则在预定义特征图层中找到其候选锚框，即仅从距离船实例中心最近的像素所预测的锚框中进行选择（见算法第 3 行至第 6 行）。接着，在算法第 7 行中计算这些候选锚框与真实边界框 b_i 之间的真实交并比 $IoU_{anchor_GT}(\omega, b_i)$ ；随后，在第 8 行和第 9 行中，从网络预测中分别解码出候选锚框的置信度 $conf(\omega, i)$ 和预测交并比 $pred_IoU(\omega, i)$ 。由

于 PPIG 的目标是使输出反映当前模型的实际学习状态, 因此候选锚框的质量必须同时基于分类与定位指标进行评估, 其质量 $\Phi(\omega, i)$ 按照第 10 行的公式 3 计算。最终, 在算法第 11 行和第 12 行中, 选取质量最高的候选锚框作为最终正样本 $\hat{\omega}$, 且对于每艘船仅选择一个正样本用于损失计算。与为同一艘船分配多个正样本的方法相比, 所提出的策略通过排除低质量样本有效降低了误报率, 从而提升了检测器整体性能。

Algorithm 2 PPIG 算法

Require: I : SAR 图像上船只的真实标注框集合; b_i : 第 i 艘船的边界框; ℓ : 特征金字塔的层数; ω : 候选锚框集合

Ensure: P : 正样本集合

```

1: for 每个真实目标  $i \in I$  do
2:   为真实目标  $i$  构建一个空的候选锚框集合:  $\omega \leftarrow \emptyset$ ;
3:   for 每个层级  $j \in [1, \ell]$  do
4:     从特征图中距离船只实例中心最近的像素所预测的锚框中选取候选锚框:
        $\xi_i \leftarrow$  选取的候选锚框;
5:     更新候选锚框集合:  $\omega = \omega \cup \xi_i$ ;
6:   end for
7:   计算候选锚框  $\omega$  与真实边界框  $b_i$  之间的交并比:  $IoU_{anchor\_GT}(\omega, b_i)$ ;
8:   从网络预测中解码置信度:  $conf(\omega, i)$ ;
9:   从网络预测中解码预测交并比:  $pred\_IoU(\omega, i)$ ;
10:  根据公式计算候选锚框的质量:  $\Phi(\omega, i)$ ;
11:  根据公式  $\hat{\omega} = \arg \max_{i=1}^N \Phi(\omega, i)$  找到最优正样本  $\hat{\omega}$ ;
12:  将最优正样本加入正样本集合:  $P = P \cup \hat{\omega}$ ;
13: end for
14: return  $P$ ;

```

PPIG 方法通过引入先验知识与预测感知质量评估机制, 实现了正样本的自适应分配。其核心思想是: 在模型尚未充分收敛时, 利用 IoU 先验信息避免低质量正样本的干扰; 在模型趋于稳定时, 结合分类置信度和 IoU 预测, 选择最优的正样本进行训练。最终, PPIG 方法在提升目标检测网络的准确性的同时, 显著降低了虚警率。

3.3 多尺度舰船检测框架

3.3.1 可变形卷积的舰船检测网络

随着合成孔径雷达技术的迅速发展, 舰船目标检测问题受到越来越多的关注。SAR 图像由于具有高分辨率和全天候成像能力, 已成为舰船检测的重要数据来源, 但其目标通常尺寸较小且形态多变, 具体数据请见第二章第二节对目标尺度进行详细的分析。目标多尺度变化给传统检测方法带来了严峻挑战。本节针对这一问题, 提出了一种基于可变形卷积网络的小舰船检测方法, 通过自适应采样、浅层特征融合以及组归一化等策略, 力图改善小舰船的检测效果。

3.3.1.1 可变形卷积的理论基础与优势

图3.5中展示了三种情况：3.5(a)为标准 3×3 卷积的规则采样网格（橙色点），3.5(b)为引入偏移后的可变形卷积^[103] 采样示意图，其中浅蓝色点表示经过偏移修正后的采样位置，而蓝色箭头直观地展示了各采样点的偏移量；3.5(c)和3.5(d)则是图3.5(b)的特殊情况，分别说明了在不同尺度、各向异性纵横比和旋转变换下，可变形卷积如何灵活地调整采样位置。在传统的标准卷积中，卷积核按照固定的规则网格在输入特征图上采样，这种方法虽然简单且高效，但其固定的采样结构限制了卷积核在遇到目标形变（如尺度变化、旋转、各向异性变换）时的适应能力。图3.5(a)中的橙色采样点反映了这种规则性，使得当输入目标的形状或位置发生变化时，卷积核可能无法完全覆盖目标的关键信息区域，从而影响后续的特征表达和检测精度。为了解决这一局限性，可变形卷积（Deformable Convolution, DC）引入了可学习的偏移量 Δp_n ，其核心思想是在标准卷积采样点 p_n 的基础上，通过加上偏移量 $p_n + \Delta p_n$ 来自适应调整采样位置。数学上，其计算公式可表述为：

$$y(p_0) = \sum_{p_n \in \mathcal{R}} w(p_n) \cdot x(p_0 + p_n + \Delta p_n),$$

其中， p_0 为输出特征图上某位置的坐标， $\mathcal{R}$ 为卷积核的标准采样区域（如 3×3 网格）， $w(p_n)$ 为卷积核权重，而 Δp_n 则由网络通过反向传播自动学习得到的偏移量。图3.5(c)和图3.5(d)展示了两种特殊情况，分别对应不同尺度、各向异性纵横比以及旋转变换的场景。这说明了可变形卷积具备推广到各种几何变换的能力。当目标尺度发生变化时，偏移量能够使卷积核的采样位置自动扩大或缩小，从而保证感受野与目标尺寸之间的匹配；在处理各向异性（非等比例缩放）的情况下，卷积核可以通过不均匀调整不同方向上的偏移量，捕捉到目标的长宽比变化。

可变形卷积通过学习偏移量 Δp_n ，卷积核能够在不增加额外监督信息的前提下，自动调整采样位置以适应局部特征的变化。这种动态调整机制显著提升了网络在处理形变、尺度变化及旋转目标时的鲁棒性。固定采样网格无法充分捕捉目标的局部细节，而可变形卷积通过引入灵活的采样位置，不仅能够覆盖目标的关键信息区域，还能更准确地描述目标的几何形状与空间分布，进而提高特征表示的判别能力。偏移量作为可训练参数，与卷积核权重一同通过反向传播进行更新，无需额外的手工设计或预处理步骤，使得整个网络在保持高效性的同时具备更强的表达能力和泛化能力。

综上所述，可变形卷积通过对传统卷积采样结构的灵活扩展，有效克服了固定采样网格在捕捉目标局部几何信息时的局限性。可变形卷积在面对不同几何变换（如尺度变化、各向异性变换和旋转）时具有普适性和鲁棒性。其核心思想不仅为深度网络提供了更为丰富的几何表达能力，而且在实际应用中（如 SAR 图像舰船检测）显著提升了小目标检测的精度和稳定性。




图 3.5 3*3 标准卷积和可变形卷积的采样位置示意图

在 SAR 图像中，小舰船目标的尺寸往往仅为 9 到 16 个像素，传统 CNN 在多层特征学习过程中容易丢失低层细节信息，导致对小目标的检测性能不足。为解决这一问题，本节提出了浅层特征融合策略——即在网络结构中引入浅层特征图的有效利用。例如，在 Resblock_body 层（尺寸为 $152 \times 152 \times 128$ ）中提取的低层特征包含丰富的细粒度信息，这些信息对于准确定位小舰船至关重要。通过将浅层细节特征与深层语义特征进行融合（如采用 PANet^[103] 框架进行双向信息传递），可以在保证整体语义表达的同时，弥补小目标特征在深层网络中的稀释问题，从而有效提升检测准确率和召回率。

传统批量归一化（Batch Normalization, BN）^[104] 在大批量训练时能较好地稳定特征分布，但在实际应用中，由于硬件资源（如单 GPU 内存限制）常常导致批量尺寸较小，BN 的统计量估计误差显著增加，从而影响模型收敛和最终性能。为此，本文采用了组归一化（Group Normalization, GN）^[105]，将通道划分为多个组，在每个组内独立计算均值与方差，从而避免对批量尺寸的依赖。实验结果表明，GN 能够在小批量训练下保持较高的稳定性，并有效提升舰船检测任务中的模型表现。

理论上，可变形卷积能够动态调整卷积核的采样位置，有效应对目标在尺度与形变上的多样性，使得网络在面对不同大小的舰船时均能提取到关键特征。同时，浅层特征中蕴含的高分辨率信息对检测微小目标具有不可替代的作用。通过将这两种技术相结合，本方法在理论上显著提高了网络对小舰船的检测敏感性和鲁棒性。

表 3.1 可变形卷积的小舰船检测网络在 SSDD 数据集实验结果

方法	平均准确率	召回率
Yolo V4+BN	90.67%	92.56%
Yolo V4+GN	91.01%	92.85%
PSFF+BN	93.52%	95.75%
PSFF+GN	95.46%	96.53%
SSD-DCN(DCN V2+PSFF+GN)	96.79%	97.31%

实验验证部分如表3.1所示。结果表明，相较于传统的 YOLO V4 及其他检测方

法, 可变形卷积的小舰船检测网络 (Small Ship Detection via Deformable Convolutional Network, SSD-DCN)^[106] 在平均精度和召回率上均有明显提升。例如, 采用可变形卷积与浅层特征融合后, AP 从传统方法的 90.67% 提高至 96.79%, 召回率也由 92.56% 提升至 97.31%。这些数据充分证明了可变形卷积的小舰船检测网络的优越性。

3.3.2 多尺度目标检测网络结构

通用深度学习方法与 SAR 舰船检测算法之间存在显著差异, 这主要源于光学图像与 SAR 图像在成像原理、分辨率、噪声特性及目标尺寸等方面的根本不同。光学图像通常具备高分辨率和丰富的颜色、纹理信息, 因而能有效利用卷积神经网络提取全局与局部特征; 而 SAR 图像依赖微波回波成像, 固有的散斑噪声和低对比度使得图像中的目标尤其是舰船目标显得非常小且边缘模糊^[53]。这种目标尺寸的显著差异使得光学模型在直接应用于 SAR 图像时, 难以捕捉到细微的目标特征, 从而导致检测性能显著下降^{[107][108]}。为了解决这一问题, 必须在特征提取和噪声抑制上采取更为精细的策略, 即充分挖掘多尺度语义与纹理信息。为此, 多尺度舰船检测网络 (Multi-scale Ship Detection Network, MSDNet) 被设计用于从多尺度舰船中提取更丰富的语义和纹理特征。该网络采用多尺度卷积模块和特征金字塔结构, 实现了不同尺度信息的有效融合, 使得检测器能够在保证全局上下文理解的同时, 提升对小型舰船细微特征的敏感性。通过这种设计, MSDNet 不仅在理论上针对 SAR 图像的固有成像特性提出了优化方案, 而且在实验中证明了其对提高检测精度和鲁棒性具有显著优势。




图 3.6 特征金字塔网络设计对比图

鉴于小型舰船检测的难度, MSDNet 是基于可变形网络的小舰船检测^[106]设计的。MSDNet 在原有特征融合和特征增强理念的基础上进一步扩展, 通过引入可变形卷积

模块,使得网络在捕捉小型舰船目标细节方面更为灵活和高效。传统舰船检测网络中,高层特征图通常具有较大的感受野和丰富的语义信息,但往往缺乏对舰船目标细节的精确刻画;相比之下,低层特征图能够提供更多与船只目标相关的细节信息,尤其对于尺寸较小的目标尤为重要。为了充分利用不同层次的特征信息,本文提出了多级特征融合(Multi-Level Feature Fusion, MLFF)策略,以提取多尺度特征。具体而言,MLFF结合了PANet^[91]所提出的自下而上和自上而下的特征融合机制,在此基础上在特征金字塔中引入了P3层作为关键融合节点。P3层主要利用低层特征图中丰富的舰船目标信息,使检测器在多尺度特征中更好地关注小尺寸舰船目标,从而获得包含丰富上下文信息的融合特征。多次特征融合过程中可能导致原始特征图中部分细粒度信息的遗忘,进而影响检测精度。为了解决这一问题,在P4、P5和P6层中,本文引入了特征复用分支(Feature Reuse Branch),以直接利用原始特征图中的细节信息,弥补多次融合中可能丢失的上下文和纹理信息。特征复用分支在提取小型船只的详细特征时,既保留了深层语义信息,又强化了浅层纹理特征,从而实现了目标位置和分类信息的高效整合。如图3.6所示,对比本节所提的MLFF特征金字塔方法与YOLO V4中的特征金字塔PANet的特征连接方式。




图 3.7 MSDNet 网络结构图

MLFF 融合并优化了浅层纹理特征与深层语义特征,通过多尺度特征融合和特征复用策略,不仅提升了检测网络对小型舰船目标的识别和定位能力,而且有效增强了模型在复杂 SAR 场景下的鲁棒性。该方法在理论上充分利用了各层特征的互补优势,并在实践中为 SAR 舰船检测提供了一种高效、精确且可在不同检测框架移植

的解决方案。此外，密集的网络不能提取更多关于舰船的语义信息，反而会产生特征冗余。MSDNet 的结构如图3.7所示。MSDNet 通过去除主干中 Resblock 的重复次数（分别为 2, 8, 8, 4）来提高模型的效率。为了抑制特征金字塔不同尺度之间的一致性，MSDNet 部署自适应空间特征融合模块 (Adaptive Spatial Feature Fusion Module, ASFF) 以提高特征的尺度不变性^[109]。此外，MSDNet 使用 1×1 卷积将 ASFF 处理的输出的通道维度减半。它通过防止特征图的通道数量快速减少来减少语义信息的损失。如图3.8所示，不同层次的特征图在 ASFF 模块的不同层次中聚集，并根据网络学习到的空间权重进行融合。由于不同级别的特征图具有不同的分辨率和通道数量，因此使用卷积和池化操作将它们调整到相同的比例。

在 ASFF 模块中，设 $X^{P_a \rightarrow P_b}$ 表示从层次 P_a 调整到层次 P_b 后的特征图， (i, j) 表示特定位置， $\lambda^{P4}(i, j)$ 、 $\eta^{P4}(i, j)$ 和 $\mu^{P4}(i, j)$ 分别代表在 P4 层上来自不同尺度特征图的自适应空间权重。根据^[109] 中的约束条件，有

$$\lambda^{P4}(i, j) + \eta^{P4}(i, j) + \mu^{P4}(i, j) = 1, \quad \lambda^{P4}(i, j), \eta^{P4}(i, j), \mu^{P4}(i, j) \in [0, 1].$$

因此，P4 层上的特征融合公式可以写为：

$$Y^{P4} = \lambda^{P4}(i, j) \times X^{P6 \rightarrow P4} + \eta^{P4}(i, j) \times X^{P5 \rightarrow P4} + \mu^{P4}(i, j) \times X^{P4 \rightarrow P4}, \quad (3-4)$$

其中， Y^{P4} 表示 ASFF 模块输出的特征图。通过引入 ASFF，不同尺度特征之间的矛盾信息能够被有效过滤，并且在特定位置上更具判别能力的特征将占据主导地位，从而进一步增强了特征表达的鲁棒性。




图 3.8 ASFF 模块示意图

在检测头设计上，MSDNet 将传统的多分类问题转化为舰船检测的二分类问题，并引入了 IoU 预测层来替代传统的分类层。该 IoU 预测层与置信度层、位置回归层联合训练，其损失函数仅针对正负样本计算，从而更精准地反映预测框与真实框之间的重叠程度。整体网络的损失函数可以划分为置信度、位置回归和 IoU 预测三个部分，各部分协同优化，共同提升了小舰船检测的整体性能。

综上所述，MSDNet 通过引入多层特征融合（MLFF）和自适应空间特征融合（ASFF）模块，有效地整合了低层局部细节与高层语义信息，解决了小型舰船检测中

目标尺度差异大、特征丢失和冗余等问题。该方法不仅在理论上通过多尺度特征的互补融合提高了检测器对小目标的敏感性，同时在实验中也展现了优异的检测性能。

3.4 实验结果分析

3.4.1 实验设置

在本实验中，所有的计算均基于 PyTorch 框架实现。为了进行充分的对比分析，本节选取了多种主流目标检测算法，包括 Faster R-CNN、YOLO V3、YOLO V4、YOLO V5、EfficientDet 以及 CenterNet。这些模型均采用 ImageNet 的预训练权重进行训练，以保证实验的公平性。此外，预测感知的 SAR 多尺度目标检测模型则采用从头开始训练的方式，以评估其在无预训练情况下的性能。为了保证训练过程的稳定性和收敛速度，所有模型均采用 Adam 优化器进行训练，初始学习率：0.001；学习率衰减方式：余弦退火（Cosine Annealing）；权重衰减： 1×10^{-4} 。余弦退火学习率衰减策略可有效避免模型陷入局部最优，同时保证在训练后期仍能获得较好的优化效果。所有实验均在同一工作站和虚拟环境下进行，以确保结果的可比性。

3.4.2 消融实验结果与分析

3.4.2.1 IoU 预测模块的原理与实验结果分析

首先，在表3.2 中，本节报告了对比实验结果，以探讨在目标检测中采用 PPIG 方式进行 IoU 预测与仅使用单一 IoU 分支或置信度作为 NMS 过程中待选框得分的差异。实验采用了三种不同的配置：Conf*Pred_IoU (PPIG)：该方法同时利用检测框的置信度与预测的 IoU 值，对检测框进行联合评价，从而更全面地反映目标的检测质量；Conf：仅依赖置信度作为检测框评价指标，该方法只能判断网格中是否存在目标，而无法反映定位的准确性。这也是 NMS 所依据的指标；Pred_IoU：仅依赖 IoU 预测结果作为分类依据，虽然能够一定程度上反映目标与检测框的重叠程度，但忽略了分类置信度中的语义信息。

表 3.2 使用不同指标作为候选框得分的实验结果

方法	平均准确率	准确率	召回率
Conf*Pred_IoU (PPIG)	94.05%	83.44%	95.05%
Conf	92.88%	82.35%	94.59%
Pred_IoU	93.73%	83.33%	94.59%

由表3.2 的数据可以看出，采用 PPIG 方式的 Conf*Pred_IoU 方法在 AP、Precision 和 Recall 上均优于仅依赖单一指标（即仅使用 Confidence 或仅使用 Pred_IoU）的配置。其中，PPIG 的平均精度（AP）达到 94.05%，较仅使用 Confidence 的 92.88% 有

明显提升；同时，在 Precision 和 Recall 上，PPIG 分别取得 83.44% 和 95.05%，表现出更低的误检率与更高的召回能力。这种性能优势说明双重评价机制的潜力。传统的置信度仅包含目标存在与否的判别信息，而 IoU 预测则进一步反映了检测框与真实目标之间的重叠程度。将二者结合（即 PPIG 方法）后，检测框的评价不仅依赖于目标的语义信息，还兼顾了定位精度，从而实现了检测框质量的更准确评估。其次，IoU 预测的引入有助于降低虚警率。在召回率水平相近的情况下，PPIG 方法在准确率上的提升表明，其能够有效过滤掉一些因定位不准而产生的误检，使得检测器更加专注于真实目标。最后，IoU 预测模块能够增强目标特征的提取能力。该模块不仅提供了关于目标存在与否的判断，还能学习目标边界与形状等更为细粒度的信息，从而使模型在复杂场景下能更好地区分目标与背景，提升整体检测性能。综上所述，实验结果与理论分析均表明，通过在目标检测中同时考虑分类置信度和定位质量，能够显著提升检测框的评价准确性和鲁棒性。该方法充分利用了目标的语义信息和空间分布特征。

3.4.2.2 标签分配策略与多尺度舰船检测网络消融实验

本节在 SSDD 数据集上进行了消融实验，以全面评估所提出方法各组成模块对整体检测性能的贡献，实验结果如表3.3 所示。消融实验结果表明，引入 MSDNet 模块后，相较于传统的 YOLO V4 方法，平均精度提高了 3.36%，这一显著提升验证了 MSDNet 在 SAR 舰船检测任务中增强通用检测模型适应性的有效性。进一步地，通过引入 IoU 预测模块，检测器在预测目标框时不仅依赖于传统的分类置信度信息，而且能够同时考虑目标与预测框之间的重叠程度，从而更精确地反映目标的定位质量。实验结果显示，仅引入 IoU 预测模块时，AP 较未引入时略有提升，说明仅凭 IoU 信息虽然可以捕捉部分定位特征，但其优势在与分类信息结合后才能充分发挥。

最为关键的是，采用 PPIG 模块后，AP 由 89.59% 进一步提升至 94.05%。该模块通过自适应地整合当前模型的学习状态与锚框的先验信息，实现了正样本的智能分配，使得模型在训练过程中能够更有效地区分目标与背景，提高了目标检测的准确性和鲁棒性。整体来看，PPIG 模块不仅在降低虚警率方面表现突出，同时也在提升召回率方面取得了显著效果，从而在多项评价指标上均获得了优异的表现。

表 3.3 不同模块对 SSDD 上检测性能的影响

MSDNet	IoU Prediction	PPIG	平均准确率
—	—	—	86.05%
✓	—	—	89.41%
✓	✓	—	89.59%
✓	✓	✓	94.05%

表3.3 的实验结果充分证明了各个模块（MSDNet、IoU 预测及 PPIG）在提升检

测器性能方面的有效性。该结果不仅展示了通过同时考虑分类与定位信息来衡量检测框质量的潜力，而且为如何在实际应用中针对 SAR 舰船检测任务优化正样本分配策略提供了新的解决方案。

3.4.2.3 多层特征融合 (MLFF) 与 PANet 的对比实验分析

在 SSDD 数据集上，本节进行消融实验，以验证多层特征融合 (MLFF) 相对于传统 PANet 在目标检测中的优势，相关实验结果如表3.4 所示。实验结果表明，采用 MLFF 方法后，平均精度由 PANet 的 86.05% 提升至 88.04%，增幅达到 2.01%；同时，检测器的精确率也由 72.87% 提高至 82.50%，提升幅度达到 9.63%。尽管在推理速度上，MLFF 相比 PANet 略有下降，从 19.32 FPS 降至 18.92 FPS，减少了 0.4 FPS，但检测精度的显著提升完全弥补了这一轻微的速度损失。

表 3.4 PANet 与 MLFF 在 SSDD 上检测性能的对比实验结果

方法	平均准确率	准确率	推理速度
基准模型 (PANet)	86.05%	72.87%	19.32
基准模型 + MLFF	88.04%(+2.01%)	82.50%(+9.63%)	18.92

从原理上看，MLFF 通过更充分地融合低层纹理特征与高层语义特征，能够在目标检测过程中捕捉到更丰富的细粒度信息，特别是对小型舰船目标的检测能力得到了明显增强。传统的 PANet 在特征传递过程中可能存在信息冗余或信息丢失的问题，而 MLFF 则通过精细的多尺度融合策略，确保了各层特征信息的互补性与有效利用，进而在检测精度和定位准确性上取得了较大的提升。

进一步地，在 HRSID 数据集上的实验也验证了这一点。图3.9展示了基于 YOLO V4 框架中 PANet 与 MLFF 的检测结果对比：与 PANet 相比，MLFF 在抑制误检方面更为明显，且对小型舰船目标的检测更为敏感，整体检测效果更为理想。这些实验现象说明，通过在检测网络中引入 MLFF 模块，不仅可以提升检测器对多尺度目标的辨识能力，还能够改善特征融合过程中信息丢失的问题，从而使得整个模型在复杂场景下具备更高的鲁棒性和泛化能力。

实验结果与检测样例均表明，采用 MLFF 模块能够显著提高目标检测器的整体性能，特别是在小舰船目标检测任务中，实现了好的检测性能。

3.4.2.4 标签分配策略在不同检测框架上的迁移性验证

为了验证所提出的 PPIG 模块在不同目标检测框架中的通用性与鲁棒性，本节在 SSDD 数据集上针对 YOLO V3、YOLO V5m、YOLO V5l 以及 RetinaNet 这四种检测器进行实验，实验结果如表3.5 所示。通过对比实验可以发现，引入 PPIG 模块后，各检测器的平均精度、精确率以及召回率均得到了显著提升，其中 AP 的提升幅度分别为 4.55%、2.08%、2.45% 和 2.35%，这充分证明了 PPIG 模块对目标检测性能的正向促进作用。具体来说，实验结果显示，在 YOLO V3 检测框架中，加入 PPIG

后 AP 从 83.03% 提升至 87.58%，提高了 4.55%；在 YOLO V5m 中，AP 由 91.66% 提升至 93.74%，提高了 2.08%；在 YOLO V5l 中，AP 由 92.08% 提升至 94.53%，提高了 2.45%；而在 RetinaNet 中，AP 则由 82.87% 提升至 85.22%，提高了 2.35%。此外，精确率与召回率在各个检测器上也均呈现出明显改善，进一步验证了 PPIG 模块在提升检测器综合性能方面的有效性。




图 3.9 不同特征金字塔在 HRSID 数据集上的检测可视化结果。

PPIG 模块通过整合模型当前的学习状态与锚框的先验信息，实现了正样本的自适应分配，从而使得检测器在训练过程中能够更准确地判断预测框的质量。传统检测框架仅依赖于单一的分类置信度信息，往往无法充分反映目标框与真实目标之间的重叠情况；而 PPIG 模块则兼顾了分类与定位信息，使得检测器在判别目标框是否为

正样本时具有更高的精度。这一机制不仅能够有效减少误检，还能在一定程度上提高目标的召回率，从而整体上提升了检测性能。

表 3.5 PPIG 模块在不同检测框架上的实验结果

方法	平均准确率	准确率	召回率
YOLO V3	83.03%	77.59%	85.88%
YOLO V3 + PPIG	87.58%(+4.55%)	80.90%	88.93%
YOLO V5M	91.66%	72.92%	93.51%
YOLO V5M + PPIG	93.74%(+2.08%)	79.05%	95.04%
YOLO V5L	92.08%	81.79%	94.27%
YOLO V5L + PPIG	94.53%(+2.45%)	84.00%	96.18%
RetinaNet	82.87%	68.12%	85.29%
RetinaNet + PPIG	85.22%(+2.35%)	72.82%	87.81%

上述结果不仅表明了 PPIG 模块在提升目标检测准确性和鲁棒性方面的显著优势，也证明了其具有良好的迁移性。即使在不同的检测框架中，PPIG 均能发挥出稳定的性能提升作用，这为其在其他 SAR 目标检测框架提供新颖的解决方案。根据实验结果，所提出的 PPIG 标签分配策略是一种通用且鲁棒的方法，能够广泛适用于各类目标检测任务。

3.4.2.5 先验信息的重要性分析

在目标检测任务中，合理的标签分配策略对于提高检测精度至关重要。为了进一步验证先验信息在标签分配中的必要性，本节分别设计了两种标签分配方法，如公式 (3-5) 和公式 (3-7) 所示。

$$\hat{\omega} = \arg \max_i^N \alpha(\omega, i) \quad (3-5)$$

$$\alpha(\omega, i) = 1[\omega \in \xi_i] \times [\text{conf}(\omega, i) \times \text{pred_IoU}(\omega, i)] \quad (3-6)$$

其中， $\alpha(\omega, i)$ 结合了置信度 $\text{conf}(\omega, i)$ 和预测 IoU $\text{pred_IoU}(\omega, i)$ ，用于衡量候选框 ω 与目标匹配的可能性，但未充分考虑先验信息对正样本分配的影响。

为进一步对比所提出的标签分配策略，本节引入先验信息 $\text{IoU}_{\text{anchor_GT}}$ ，在公式 (3-7) 和公式 (3.4.2) 中定义了另一种标签分配方法：

$$\hat{\omega} = \arg \max_i^N \beta(\omega, i) \quad (3-7)$$

$$\beta(\omega, i) = 1[\omega \in \xi_i] \times [IoU_{anchor_GT}(\omega, b_i) \times conf(\omega, i) \times pred_IoU(\omega, i)] \quad (3-8)$$

该方法通过引入先验信息 IoU_{anchor_GT} ，在综合考虑分类置信度和定位质量的同时，增强了标签分配过程对高质量候选框的选择能力。为了评估不同标签分配方法的有效性，在 SSDD 数据集上进行了对比实验，实验结果如表3.6所示。

表 3.6 不同标签分配方法的性能对比

方法	平均准确率	准确率	召回率	F1-score
MSDNet	89.41%	76.43%	90.54%	82.89%
$\alpha(\omega, i)$	91.04%	75.28%	91.89%	82.76%
$\beta(\omega, i)$	91.42%	71.78%	92.79%	80.94%
PPIG	94.05%	83.44%	95.05%	88.87%

从表3.8的实验结果可以看出， $\alpha(\omega, i)$ 方法仅依赖分类置信度与预测 IoU，虽然相较于基础的 MSDNet 方法在 AP 上有所提升 (+1.63%)，但由于未能引入先验信息，Precision 略有下降 (-1.15%)，F1-score 也下降了 0.13%。相比之下， $\beta(\omega, i)$ 通过引入先验信息 IoU_{anchor_GT} ，在 Recall 上获得了较大提升 (+2.25%)，但 Precision 下降更多 (-4.65%)，导致 F1-score 整体下降。

相比之下，PPIG 方法在 AP、Precision、Recall 和 F1-score 四个指标上均显著优于其他方法，其中 AP 达到 94.05%，较 $\alpha(\omega, i)$ 和 $\beta(\omega, i)$ 分别提升了 +3.01% 和 +2.63%，Precision 提高了 8.16%，Recall 提升了 2.26%。这一结果表明，PPIG 方法在标签分配时能够综合考虑模型当前的学习状态与先验信息，实现最优的正样本分配策略。

上述实验结果验证了先验信息在目标检测标签分配中的重要性。首先，对比公式 (3-5) 与 PPIG 方法的结果可以发现，仅依赖分类置信度和预测 IoU 的标签分配方法，在 Precision 和 F1-score 方面存在一定局限性。其次，对比公式 (3-7) 与 PPIG 的结果可以看出，尽管先验信息有助于提高 Recall，但仅靠先验信息难以实现最优的标签分配策略。PPIG 方法通过结合分类置信度、预测 IoU 以及先验信息，实现了更加合理的正样本分配策略，从而在多个评价指标上均表现最佳。

综上所述，PPIG 方法是一种兼顾模型当前学习状态和先验信息的最优标签分配策略，能够有效提高目标检测的准确性和稳健性。

3.4.2.6 HRSID 数据集上的消融实验与性能分析

为了进一步验证所提出方法在不同数据集复杂场景下的鲁棒性与广泛适用性，本节在 HRSID 数据集上开展了消融实验。相比于 SSDD 数据集，HRSID 数据集在图像数量、单幅图像的像素数量以及目标船只总数上均高出 4 ~ 8 倍，这为评估检测网络

在大规模、高密度数据环境下的性能提供了充分的测试平台。通过对比实验，不仅验证了 MSDNet、IoU 预测模块以及 PPIG 标签分配策略对检测性能的提升作用，而且证明了这些方法在大数据量环境下依然保持出色的迁移性和稳定性。

如表3.7所示，消融实验结果显示，当仅采用 MSDNet 模块时，检测器的平均精度为 82.25%，较基础模型的 AP 有显著提升；而在此基础上引入 IoU 预测模块后，AP 进一步提高至 83.42%；当同时引入 PPIG 模块时，AP 最终达到最高值 **86.11%**。值得注意的是，相较于 SSDD 数据集上 MSDNet 带来的 7.34% 的 AP 提升，HRSID 数据集上 MSDNet 的优势更为明显，这表明在数据量和数据复杂度增加的情况下，设计针对性更强的检测网络能够取得更加显著的性能提升。此外，PPIG 模块在正样本分配策略上的优化作用，使得 AP 额外增加了 2.69% 的收益，充分证明了合理利用先验信息对于提升检测器性能的重要性。

表 3.7 本章所提方法在 HRSID 数据集上的影响

MSDNet	IoU 预测	PPIG	平均准确率
			74.91%
✓			82.25%
✓	✓		83.42%
✓	✓	✓	86.11%

实验结果表明，各模块在检测网络性能提升中具有明显的累积效应：首先，MSDNet 通过优化网络结构设计，显著提高了大数据量场景下的检测准确率，其 AP 提升达 7.34%；其次，IoU 预测模块有助于更准确地评价检测框的定位质量，从而在 AP 上取得了进一步提升；最后，PPIG 模块通过合理整合预测信息和锚框先验信息，实现了更优的正样本分配策略，使得最终 AP 获得额外提升 2.69%。这些结果充分验证了在 HRSID 数据集上部署 MSDNet、IoU 预测和 PPIG 模块是提高 SAR 舰船目标检测性能的关键所在，也证明了所提出方法在不同数据集、不同场景下的广泛适用性和鲁棒性。

3.4.3 对比实验结果与分析

3.4.3.1 标签分配方法的对比实验及性能分析

为了全面评估所提出的 PPIG 标签分配方法的优势，本节在统一的检测框架 MSDNet 上分别部署了当前先进的标签分配方法，包括 ATSS^[98]、o2o^[99] 和 POTA^[100]。在实验中，为了控制变量，除标签分配策略外，其他参数均保持一致，各方法均按照标准实践实现，但各自仍存在一定局限性。

自适应训练样本选择 (Adaptive Training Sample Selection, ATSS) 的核心思想在于自适应地确定正负样本划分的 IoU 阈值，而非采用传统固定阈值。在 ATSS 中，对于

每个目标，首先统计与该目标相关的候选框（anchors 或候选区域）的 IoU 分布，然后利用该分布的均值和标准差动态设定一个最优阈值，以选取那些与目标重叠度较高的候选框作为正样本。该方法充分考虑了不同目标在尺度、形状和密度上的差异，能够较好地适应多样化目标的检测需求。ATSS 的优点在于其自适应能力强，能减少因固定阈值带来的正负样本分配偏差；但其局限性在于，当候选框数量不足或 IoU 分布统计不充分时，动态阈值的设定可能会受到影响，进而导致部分高质量候选框被错误划分。

一对一标签分配 (One-to-One Label Assignment, o2o) 方法采用严格的一对一标签分配策略，即在每个目标与候选框之间实现唯一匹配，通常借助于匈牙利算法等优化手段。该方法的出发点在于消除多对一匹配中可能存在的冗余和冲突，从而使每个目标只对应一个最优候选框。其优势在于能够提高正样本的纯度，减少训练过程中的噪声干扰；然而，由于实际场景中目标往往存在重叠或密集分布，严格的一对一匹配有时会忽略那些与目标具有较高 IoU 但未被选中的候选框，导致部分有效信息的损失，从而影响整体召回率和检测鲁棒性。

预测感知一对一分配 (Prediction-aware One-To-One, POTO) 方法则从概率论角度出发，将候选框与目标之间的匹配问题视为一个在线概率分配问题。该方法综合考虑候选框与真实目标之间的 IoU、候选框自身的预测置信度以及锚框的先验信息，构建一个概率模型，对每个候选框赋予一个匹配概率。最终，通过选择概率最高的候选框作为正样本，实现目标的最优匹配。POTO 方法的一个问题在于引入了复杂的概率计算过程，增加了训练的计算复杂度，并且对概率模型的参数设置较为敏感，可能需要在不同数据集上进行针对性的调优。

表 3.8 标签分配方法的研究结果

方法	平均准确率	准确率	召回率	F1-score
MSDNet	89.41%	76.43%	90.54%	82.89
ATSS	90.69%	80.16%	90.99%	85.23
o2o	91.84%	80.86%	93.24%	86.61
POTO	92.05%	86.16%	92.79%	89.35
PPIG	94.05%	83.44%	95.05%	88.87

表3.8展示了在 MSDNet 框架下，各标签分配方法在平均精度、准确率、召回率和 F1-score 指标上的性能对比。对比结果表明，尽管 ATSS、o2o 和 POTO 方法均在一定程度上改善了标签分配策略，但它们在充分利用锚框先验信息方面存在不足，导致整体性能未能达到最优。而所提出的 PPIG 方法通过同时结合模型当前学习状态与锚框先验信息，实现了对正样本的自适应分配，从而在 AP 和 Recall 等关键指标上表现出明显优势，充分证明了合理的标签分配策略在目标检测中的重要性和必要性。

从表中数据可以看出,基线 MSDNet 在 AP、Precision、Recall 和 F1-score 上分别为 89.41%、76.43%、90.54% 和 82.89%。采用 ATSS 方法后,AP 提升至 90.69%,精确率提高到 80.16%,召回率和 F1-score 分别达到 90.99% 和 85.23%;而 o2o 方法将 AP 进一步提高至 91.84%,精确率与召回率分别为 80.86% 和 93.24%,F1-score 达到 86.61%;采用 POTA 方法时,AP 达到 92.05%,其中精确率和 F1-score 分别为 **86.16%** 和 **89.35%**。相比之下,所提出的 PPIG 方法在 AP 和召回率指标上均取得了最优结果,其 AP 达到 **94.05%**,召回率达到 **95.05%**,精确率为 83.44%,F1-score 为 88.87%。

与基线 MSDNet 相比,部署 PPIG 方法后,模型的 AP 提升了 4.64%,精确率提升了 7.01%,召回率提升了 4.51%,F1-score 提升了 5.98%。这些数据充分说明,仅依赖单一预测信息的标签分配方法(如 ATSS、o2o、POTA)存在一定局限,忽略了锚框先验信息会导致检测性能的下降。而 PPIG 方法通过同时结合模型当前学习状态与锚框先验信息,实现了正样本的自适应分配,从而显著提升了检测器的整体性能。PPIG 方法在标签分配过程中,将预测置信度、预测 IoU 与锚框先验信息进行融合,有效筛选出包含更多目标像素的锚框作为正样本,进而提高了模型在分类和回归任务中的准确性。这不仅能够降低误检率,而且能在一定程度上提升召回率,从而在 AP 等综合指标上取得更好的表现。实验结果验证了这一理论推导,表明同时考虑模型学习状态与锚框先验信息的标签分配策略具有巨大的潜力和实际应用价值。

表 3.9 基于 CNN 方法在 SSDD 数据集上的检测结果对比

方法	平均准确率	准确率	召回率	F1-score
Faster R-CNN (ResNet50)	75.95%	59.68%	83.33%	69.55
CenterNet (ResNet50)	80.36%	76.13%	83.33%	79.57
EfficientDet-d0 (EfficientNet)	84.70%	80.00%	86.49%	83.12
YOLO V3 (DarkNet53)	83.03%	77.59%	85.88%	81.52
YOLO V4 (CSPDarkNet53)	86.05%	72.87%	91.22%	81.02
YOLO V5m	91.66%	72.92%	93.51%	81.94
YOLO V5l	92.08%	81.79%	94.27%	87.59
SSD-DCN	87.28%	82.77%	88.74%	85.05
MSDNet	89.41%	76.43%	90.54%	82.89
MSDNet + PPIG	94.05%	83.44%	95.05%	88.87

3.4.3.2 模型预测引导的多尺度舰船检测性能对比及分析

表3.9展示了本文提出的方法与基于 CNN 的目标检测方法在 SSDD 数据集上的检测结果对比,其中包括 Faster R-CNN(ResNet50)、CenterNet(ResNet50)、EfficientDet-d0 (EfficientNet)、YOLO V3 (DarkNet53)、YOLO V4 (CSPDarkNet53)、YOLO V5m、YOLO V5l 以及 SSD-DCN。由表中数据可以看出,MSDNet 与 PPIG 模块的结合在各

项性能指标上均取得了显著优势：平均准确率高达 94.05%，精确率为 83.44%，召回率达到 95.05%，F1-score 为 88.87%，这些结果均明显优于其他各方法。这种性能提升的主要原因可以归结为两个方面。首先，本文提出的 PPIG 标签分配方法通过同时结合模型当前的学习状态与锚框的先验信息，实现了正样本的自适应分配，从而有效地提高了候选框的正负划分准确率。传统的检测方法在标签分配上通常只依赖于候选框的预测置信度，而忽略了锚框中包含更多目标像素这一关键信息，这在一定程度上会导致误检或漏检问题。而 PPIG 方法则充分利用了先验信息，确保了分配过程更加合理，从而在 AP 和召回率上都获得了显著提升。

MSDNet 网络结构是专门针对 SAR 舰船检测任务设计的。SAR 图像中舰船目标体积较小且背景复杂，传统的检测网络往往难以捕捉到足够的细粒度特征。MSDNet 通过多尺度特征融合、专用卷积模块和定制化的网络层设计，针对性地解决了 SAR 图像中目标尺寸小、分布稀疏等问题，大幅提高了检测器在定位和分类任务中的表现。正是由于 MSDNet 在特征提取和多尺度信息整合方面的优异表现，结合 PPIG 标签分配策略，最终使得检测性能达到了最高。此外，从表中数据还可以看出，其他检测方法在各项指标上均存在不同程度的不足，而 MSDNet + PPIG 方法在这些指标上均表现出较高的鲁棒性和稳定性。这充分验证了合理标签分配策略和专用网络设计对提升 SAR 目标检测性能的重要性。

表 3.10 基于 CNN 方法在 HRSID 数据集上的检测结果对比

方法	平均准确率	精确率	召回率	F1-score
Faster R-CNN (ResNet50)	43.14%	49.89%	51.47%	50.67
CenterNet (ResNet50)	75.92%	71.69%	78.50%	74.94
EfficientDet-d0 (EfficientNet)	72.89%	69.21%	75.43%	72.19
YOLO V3 (DarkNet53)	76.24%	68.54%	79.81%	73.75
YOLO V4 (CSPDarkNet53)	76.92%	68.40%	80.02%	73.76
YOLO V5m	74.87%	80.91%	76.08%	78.42
YOLO V5l	75.68%	81.81%	76.93%	79.29
SSD-DCN	81.53%	80.53%	83.13%	81.81
MSDNet	83.42%	81.54%	84.68%	83.08
MSDNet(PPIG)	86.11%	86.31%	87.22%	86.76

为了全面验证所提出方法在不同数据集上的优势，本节在 HRSID 数据集上对多种检测器进行了性能对比，比较结果如表 3.10 所示。从表中可以看出，各种基于 CNN 的检测方法在 HRSID 数据集上的检测性能存在较大差异，而 MSDNet 结合 PPIG 模块的方法在各项指标上均表现出显著优势。具体而言，MSDNet+PPIG 的平均准确率达到了 86.11%，这一数值较 YOLO V5L 的平均准确率提高了 10.43%；同时，在准确

率和召回率方面, MSDNet+PPIG 分别取得了 86.31% 和 87.22% 的优异表现, F1-score 也达到了 86.76%。这些结果表明, 所提出的方法不仅能够检测出更多的舰船目标, 而且在降低虚警率方面也有明显优势。

这种性能提升的原因主要体现在两个方面。首先, MSDNet 网络结构是针对 SAR 舰船检测任务设计, 其多尺度特征融合和专用卷积模块能够更有效地提取 SAR 图像中的细粒度目标特征, 进而提高目标的定位与分类精度。其次, PPIG 标签分配策略在候选框正负样本分配过程中, 同时融合了模型当前的学习状态与锚框先验信息, 能够更合理地分配正样本, 从而有效减少了由于错误标签分配引起的检测噪声。这两方面的有机结合使得 MSDNet+PPIG 在 AP、Precision 和 Recall 等关键指标上均超越了其他检测模型。




图 3.10 YOLO V4 中所有正确检测到的目标与所提方法的平均 IoU 比较图

根据实验结果分析, MSDNet+PPIG 方法在 HRSID 数据集上的 AP 高达 **86.11%**, 比 YOLO V5L 高出 10.43%, 充分证明了在大数据量、高密度目标检测场景下, 设计匹配 SAR 舰船检测任务特点的标签分配策略是非常必要的。准确率和召回率的进一步提高则表明预测感知的 SAR 多尺度目标检测模型的优越性。为了定量地比较预测框的精度, 本节计算了所有正确检测目标与其对应真实标注之间的平均 IoU。本节提出该指标以评估预测框的质量, 从而能够更客观地反映检测器对目标定位的精细程度。如图 3.10 所示, 本文方法在平均 IoU 指标上较传统 YOLO V4 提高了 0.129。这一数值提升不仅说明了预测框与真实目标之间的匹配度更高, 同时也验证了本文方法在保持较高召回率的同时, 有效提高了检测模型定位的准确性。

如图 3.11 所示, 本节展示了基于 SSDD 数据集上, YOLO V4 与本文提出方法的部分检测结果。绿色矩形表示检测出的目标, 蓝色矩形表示真实目标, 红色矩形表示误检。第 1 行和第 3 行是 YOLO V4 得到的视觉检测结果。第二行和第四行是 MSDNet (PPIG) 获得的视觉检测结果。从图中可以直观地看出, 本章提出的方法在

复杂的 SAR 场景中能够检测出更多的舰船目标，同时产生的误检明显较少。这一现象主要归因于预测感知的 SAR 多尺度目标检测模型方法在网络结构和标签分配策略上的改进，使得对目标特征的提取更加充分，进而提高了检测器的召回率和准确性。




图 3.11 SSDD 数据集上 YOLO V4 与 MSDNet (PPIG) 的可视化检测结果对比

在 HRSID 数据集中，为全面展示所提出方法在复杂场景下的优势，本章选取近岸场景作为难样本进行可视化对比。图3.12展示了 YOLO V4 与 MSDNet(PPIG) 在近岸及港口等复杂背景下的视觉检测结果。离岸场景中，岛屿、陆地等干扰因素使检测任务难度显著增加，传统的 YOLO V4 方法在这些区域容易产生较多误检；而 MSDNet 结合 PPIG 标签分配策略则在有效抑制虚警的同时，检测出更多尺度多样的舰船目标，从而显著提高了目标检测的召回率。在港口及其他复杂场景中，MSDNet(PPIG) 不仅在目标检测数量上占优，更在目标定位精度上展现出明显优势。为了定量评估检测框的定位质量，本文计算了所有正确检测目标与其对应真实标注之间的平均 IoU，将该

指标作为衡量预测框精度的重要依据。如图3.10所示, MSDNet(PPIG) 方法较 YOLO V4 在平均 IoU 指标上提升了 0.026。这一提升表明, 所预测的检测框与真实目标之间的匹配度更高, 进一步验证了本方法在定位准确性方面的优势。




图 3.12 HRSID 数据集上 YOLO V4 与 MSDNet (PPIG) 的可视化检测结果对比

在离岸场景中, MSDNet(PPIG) 方法有效降低了虚警率, 尤其在岛屿和陆地区域表现尤为突出; 并且能够检测出更多尺度多样的舰船目标, 从而大幅提升了目标检测

的召回率；在目标定位方面，MSDNet(PPIG) 所预测的检测框与真实目标之间的平均 IoU 较传统 YOLO V4 方法提升了 0.026，说明预测结果更为精确。

3.4.4 计算复杂度分析

如图3.13所示，本节对比了本文提出的 MSDNet 与七种基于 CNN 的检测方法（包括 Faster R-CNN、YOLO V3、CenterNet、RetinaNet、YOLO V4、YOLO V5m 和 YOLO V5l）的计算复杂度。通常，算法的计算复杂度主要通过浮点运算次数（FLOPs）、模型大小以及参数量来衡量。




图 3.13 不同检测网络的 FLOPs、模型大小和参数大小

实验结果显示，与 YOLO V4 相比，MSDNet 的 FLOPs 降低了 5.36G（约下降 8.37%），这表明在相同硬件平台下，MSDNet 能够大幅减少计算资源的消耗，从而提升实时性并节省能源。同时，MSDNet 的模型体积相比 YOLO V4 减少了 13.95MB，参数量减少了 0.36MB，有效降低了内存占用和模型初始化时间。这些数据充分表明，MSDNet 在保证高检测精度的同时，实现了计算复杂度的显著降低，展现出卓越的轻量化与高效性。较低的 FLOPs 和模型体积不仅提升了算法在嵌入式和移动设备上的应用潜力，也为大规模数据处理和分布式部署提供了有力的技术保障。总之，通过在计算复杂度方面的优化，MSDNet（结合 PPIG 标签分配策略）在检测性能、资源消耗和推理速度之间达到了良好的平衡。

图3.14 展示了本章所提出的 MSDNet 方法与其他检测方法在检测速度、模型参数量以及平均精度等指标上的对比。实验结果显示，MSDNet (PPIG) 的检测速度为 15.19 FPS，且其平均精度高达 94.05%。尽管与 YOLO V4 相比，MSDNet (PPIG) 的推理速度低了 4.13 FPS，但其检测准确性显著提高，AP 提升了约 8%。这一结果表明，在实际应用中，为了获得更高的检测精度，略微牺牲部分推理速度是完全可以接受的。




图 3.14 MSDNet 与其它方法在检测速度、模型参数量及平均精度上的综合对比

3.4.5 失败案例分析

图3.15 展示了本章方法在 SSDD 与 HRSID 数据集上的部分失败案例。第一行和第三行为 SSDD 和 HRSID 数据集上的检测结果，第二行和第四行为对应的真实标注。绿色矩形表示预测的舰船目标，蓝色矩形表示真实标注的舰船目标。首先，从图中可以明显看出，最常见的错误为虚警，尤其在沿海区域（如港口）表现尤为突出。这主要归因于沿海地区海陆分界模糊以及复杂背景杂波的干扰，使得网络难以准确区分舰船与非目标区域，进而导致虚警现象频繁发生。这一问题说明，提升舰船检测网络在海陆分界判别能力上仍然是未来研究的重点方向之一。

图3.15中展示的失败案例揭示了当前检测模型存在的两大主要问题：一是虚警问题，即在沿海区域由于海陆分界模糊和复杂背景杂波干扰，模型容易将非目标区域误判为舰船；二是漏检问题，即在处理极大或极小目标时，由于基于锚框的方法难以覆盖所有尺度，部分船只被错误拆分或漏检。针对这些问题，后三章提出的三种方法正是为了解决上述不足而设计的解决方法。

杂波随机采样融合的 SAR 目标检测方法通过将实测和仿真杂波数据引入训练数据中，极大地扩充了数据的多样性和复杂性。传统的数据增强主要依赖图像几何变换，无法充分反映实际环境中海浪、潮汐等引起的背景变化；而本方法通过加法融合、乘法融合及目标保护三种模式，让模型在训练时能够接触到更多不同场景下的背景杂波，从而增强模型对复杂背景的判别能力。这对于减少沿海区域因背景干扰引发

的虚警具有明显效果，同时也有助于模型在多尺度情况下更准确地区分目标与背景，降低漏检风险。其次，SAR 图像背景移除辅助的目标检测方法采用端到端的背景去除与目标检测联合优化机制，直接针对近岸复杂场景中海浪、港口设施等引起的杂波干扰进行处理。通过背景移除网络提前过滤掉大部分背景噪声，再由检测网络提取舰船目标，这种方法既能够显著降低虚警率，又能在去除背景干扰的同时保留目标的电磁散射特征，提升小目标的召回率。检测辅助一致性损失进一步保证了背景去除过程与检测任务之间的协同，弥补了传统方法在任务分离情况下出现的细节信息丢失问题，从而有效改善漏检现象。最后，SAR 图像杂波抑制与目标检测联合学习策略则通过构建一个融合杂波注入、杂波抑制与目标检测的端到端联合训练框架，进一步增强了模型对动态背景杂波变化的鲁棒性。该方法在训练过程中引入了杂波增强机制，模拟实际复杂环境下的背景变化，再通过反向传播机制使得检测网络在去除杂波的同时能够自动学习如何保留目标的关键特征。这种协同优化方式有效解决了传统静态滤波方法在抑制杂波时可能造成目标边缘模糊的问题，既降低了虚警率，也提升了对极端尺寸目标的检测准确性，缓解了漏检问题。后三章提出的方法分别从数据增强、背景去除和联合学习三个角度出发，有针对性地解决了因背景杂波复杂和尺度不均导致的虚警与漏检问题。




图 3.15 MSDNet (PPIG) 失败案例可视化

3.5 本章小节

本章针对 SAR 舰船检测中正负样本划分不均和多尺度目标检测难题，提出了一种预测引导的 SAR 多尺度目标检测模型。具体而言，首先在网络中引入交并比预测模块，将传统的分类置信度与预测的定位质量有机融合，通过构造评分函数实现候选锚框的智能评价和正样本的自适应分配，有效缓解了训练与测试阶段目标定义不一致带来的性能瓶颈。随后，针对 SAR 图像中小舰船目标尺寸微小且易受噪声干扰的特点，本章设计了多尺度目标检测网络，通过浅层特征与深层语义的深度融合，充分保留低层细节信息，提升了对微小目标的敏感性。进一步地，多尺度舰船检测网络通过整合多级特征融合策略和自适应空间特征融合模块，实现了各尺度特征的优势互补，大幅提高了检测精度和鲁棒性。实验结果充分验证了所提方法在多个数据集上均取得了优异性能，为复杂 SAR 环境下的舰船目标检测提供了一种高效、准确且具备良好扩展性的解决方案。

第四章 杂波随机采样迁移的 SAR 数据增强技术

杂波和噪声是雷达成像固有的现象，不可避免的会妨碍对雷达图像的准确解译。传统的解决方案是对 SAR 图像进行滤波，但这种方法往往会导致电磁散射现象以及目标的细节信息丢失。为了解决这些问题，本章提出了一种杂波随机采样融合的 SAR 目标检测方法。首先，通过将参数化杂波建模与真实杂波数据相结合构建杂波集；随后将所获得的杂波与原始 SAR 样本融合，从而生成了增强的训练数据。杂波数据增强的舰船检测算法在不改变目标位置的前提下使背景更加复杂，从而保留了原始的标注信息。所提方法既增加了训练数据集的困难样本比例，也提升了数据的多样性。增强后的数据随后被用于训练检测网络。因此，统计模型和真实杂波中提取的有价值的背景信息被集成到训练数据中从而被检测模型学习鉴别。杂波随机采样融合的增强技术既可以离线实现，也可在线实施，无需额外的标注提高检测方法在复杂场景下的泛化能力。经过在线杂波数据增强的舰船检测算法处理后，训练样本在每次迭代中会动态变化，有效地缓解了过拟合问题。大量实验结果表明，在 SSDD 和 HRSID 数据集上，采用本章方法分别提高了平均精度 5.27% 和 3.2%。

4.1 引言

第三章针对舰船检测中的正负样本划分问题，提出了一种预测引导的 SAR 多尺度目标检测模型。该方法通过引入交并比预测，结合分类置信度与定位质量，有效缓解了训练目标与测试目标之间的差异，并通过改进特征金字塔和引入 ASFF 模块提升了小型舰船检测的准确性。然而，第三章的研究仍忽略了一些重要问题：现有的训练数据在标注数量和背景复杂性上相对有限，导致模型在真实场景中面对复杂杂波和多样噪声时，其泛化能力和鲁棒性难以充分体现；尽管引入先验信息在标签分配上取得了进步，但受制于数据集中背景干扰信息不足，模型对实际海况中多变杂波的适应性仍有待提升；多尺度特征融合虽然在一定程度上整合了低层纹理与高层语义，但由于训练数据背景较为单一，网络在提取目标与背景微妙差异方面仍显薄弱。为此，本章工作针对这些问题展开研究，提出了一种杂波随机采样融合的 SAR 目标检测方法。本章方法通过将参数化杂波建模与真实杂波数据相结合构建杂波集，并将其与原始 SAR 样本融合生成增强训练数据，在不改变目标位置的前提下，使背景变得更加复杂与多样，从而保留原始标注信息并显著扩充了训练样本的规模。所提出的增强技术既可离线实现，也可在线动态更新，有效缓解过拟合问题。通过本章的研究，期望在保持端到端检测框架不变的前提下，进一步提升模型对复杂海况下目标与背景区

分的鲁棒性。

SAR 是一种先进的主动微波传感器,能够在任何天气条件下连续工作,不受光照和大气条件的影响^[110]。SAR 非常适合监控具有高度变化天气模式的动态海洋环境^[111]。SAR 舰船检测在军事和民用领域均具有重要应用,包括保护海洋生态环境、维护渔业资源以及保障国家海洋权益^[112]。图4.1展示了同类舰船目标的光学图像与 SAR 图像的对比,光学图像取自 FGSC-23^{[113][114]} 数据集,而 SAR 图像则由 FuSAR^[115] 获取。由于 SAR 成像依赖于微波相干处理,其成像原理与光学成像根本不同。SAR 图像主要反映目标的电磁散射特性,缺乏颜色信息,且目标特征往往嵌入在复杂的杂波和噪声中^[116]。这些特性为 SAR 舰船检测带来了相当大的挑战,尤其是在复杂场景下。本章讨论的 SAR 舰船检测主要面临以下三大挑战。



图 4.1 光学图像和 SAR 图像舰船目标的比较

4.1.1 SAR 图像中杂波形成分析

在 SAR 图像中,噪声和杂波均会影响目标检测的效果。噪声主要是指由传感器热效应、量化误差以及信号传输过程中的随机扰动所引起的随机性误差,其特点是分布无规律、幅值较低且呈现均匀分布,通常表现为图像中的随机斑点或细小颗粒,对整个图像的信噪比造成全局性的影响,进而降低目标的显著性和检测精度^[117]。杂波则是由非目标物体反射的信号所构成,例如海浪、建筑物或植被等,由于这些非目标对象的电磁散射特性可能与真实目标相似,故在 SAR 图像中往往表现出一定的结构性和空间相关性,如周期性的条纹或纹理状干扰,这种有结构的背景干扰使得检测器在区分目标与非目标区域时容易产生误判,从而引发虚警现象^{[118][119]}。二者的对比如图4.2所示。总体来说,噪声主要影响图像的整体质量,而杂波则容易在局部区域引起目标与背景特征混淆,这两者共同构成了 SAR 图像处理中必须应对的重要挑战,也是本章与后续章节中提出的杂波随机采样迁移、背景移除辅助以及联合学习策略等方法所针对的关键问题。

由于理想点目标的回波干扰,每个分辨单元内总回波的后向散射系数会出现显著的随机波动。因此,所获取的 SAR 图像中包含大量类似散斑的明暗颗粒,这通常被称为相干散斑噪声^[120]。当完全发展相干散斑的假设满足时,SAR 图像可以采用乘

法模型进行建模，即图像值受到相干散斑分量和后向散射分量的共同调制^[121]。这种噪声的存在降低了信噪比（Signal to Noise Ratio, SNR），掩盖了目标结构和细节特征，进而对检测和识别性能产生负面影响。在海洋环境中，杂波主要来源于风、海面多普勒效应以及其他海上物体（如漂浮物和渔业活动）的干扰^[122]。研究表明，在低 SNR 条件下，目标的散射特性可能与背景杂波非常相似，从而使目标与背景的分离变得尤为困难^[123]。传统的去斑技术（例如 Lee 滤波器和 Frost 滤波器）常用于抑制噪声^{[124][125][126][127][128]}，但这些方法不可避免地会损失目标的重要散射特性和边缘细节，从而降低检测器提取可靠目标特征的能力。此外，杂波还会进一步破坏目标结构，加剧舰船检测的复杂性。相干散斑噪声是 SAR 图像固有的限制，对目标检测提出了重大挑战。已有研究结合去噪与检测网络，力图在抑制噪声的同时保留目标特征。例如，Choi 等人提出了一种深度级联网络用于舰船检测，通过去噪预处理后采用语义保守损失保持关键信息^[129]；Zha 等人引入非局部均值（Non-Local Means, NLM）算法作为预处理技术以提升 SAR 图像质量^[130]；赵等人设计了多级拉普拉斯金字塔自适应去噪方法^[131]；李等人则利用最小池化层进行噪声抑制^[132]。然而，这些方法往往会牺牲目标散射特性和结构信息，进而影响检测性能。




图 4.2 SAR 图像中噪声与杂波的比较

4.1.2 样本分布不均衡问题

现有的 SAR 目标检测数据集由于是人为收集部分传感器的数据，不可避免的存在局限性，这种数据集偏差进一步加剧了杂波和噪声带来的挑战。诸如 SSDD 和 HRSID 等数据集通常以目标为中心，背景较为简单和单一，难以真实模拟实际海洋环境的复杂性^[133]。例如，这些数据集往往描绘高对比度的目标与低杂波背景，但在实际应用中，目标常常被诸如岛屿、海上平台或密集杂波所遮蔽，而这在当前数据集中表现不足^{[134][135]}。为说明这一问题，图4.3展示了简单场景与复杂场景的例子，突

显了两者之间的显著差异。缺乏多样化和复杂场景的数据集会显著降低检测网络在小目标或强干扰情况下的性能。




图 4.3 SAR 舰船检测中的简单和复杂场景

4.1.3 视觉图像的样本增强技术

传统的数据增强技术（如几何变换和裁剪）在模拟 SAR 成像固有的复杂噪声和杂波特性方面存在明显不足，这在一定程度上限制了数据增强的有效性^[136]。此外，传统数据增强技术主要针对光学图像设计，其调整亮度、对比度、色彩等手段并不适用于 SAR 图像，因为 SAR 图像具有独特的成像机制和噪声特性^{[137][138][139][140]}。具体来说，Mixup 方法通过对两张随机选取的图像及其对应标签进行线性加权组合来生成新样本^[141]；Mosaic 方法则将四张图像组合，并对各图像标签进行相应调整^[40]，其结果可视化如图 4.4 所示。Mosaic 方法在 SAR 图像边缘引入了不连续性，破坏了图像的纹理和散射特征，从而容易误导模型学习目标与背景之间的关系，尤其在检测较小目标时会产生负面影响；而 CutMix 方法可能会引入不自然的噪声和异常的背景分布，这与 SAR 图像的统计特性不符，进而可能降低检测性能。考虑到 SAR 图像中目标通常尺寸较小，Mosaic 处理可能进一步加剧小目标检测的难度。




图 4.4 两种常用的光学数据增强技术的可视化结果

传统 SAR 数据增强技术，如几何变换、超分辨率和图像补丁提取，虽然能扩大

样本量,但难以模拟 SAR 图像固有的噪声和杂波特性^[142]。部分研究探索了通过合成图像增强目标识别的可能性^{[143][144][145][146][147]}。例如,杨等人采用 mask 进行损失计算以减缓部分目标裁剪带来的噪声^[148];宋等人提出针对局部信息丢失问题的技术,利用背景噪声块采样来模拟雷达阴影效应^[149];索等人基于 Copy-Paste 框架提出了 BoxPaste 方法以解决目标重叠问题^[150]。然而,以往研究较少关注 SAR 数据中突然噪声和稀有杂波的影响。

为了解决这些问题,本章提出了一种专为 SAR 图像设计的数据增强方法——杂波随机采样融合的 SAR 目标检测方法,该方法通过融合真实杂波与基于统计建模生成的杂波,有效提升了训练样本的复杂性和多样性,从而增强了模型对复杂背景下目标特征的学习能力,从而提升检测模型鲁棒性。深度学习模型在复杂场景下的泛化能力仍然存在显著不足。虽然深度学习模型在目标检测中已展现出卓越性能,但在复杂背景下,其性能常会显著下降。在背景复杂或目标与背景语义信息相似的环境中,传统检测网络的误检和漏检率会明显增加。这主要是由于模型在训练时过拟合于简单场景,导致对复杂样本的表征不足。此外,目标遮挡和密集目标群聚等挑战也进一步降低了检测性能。另一个重要因素是 SAR 噪声与杂波的独特统计特性,如 Rayleigh 分布和 K 分布^[134]。大多数基于深度学习的检测方法忽视了这些统计特性,仅依赖数据驱动的特征提取,降低了模型在复杂环境下的鲁棒性。

本章的剩余内容分为如下部分:第 4.2 节介绍了杂波随机采样融合的 SAR 目标检测方法的整体框架及其数据增强策略,重点阐述了加性融合、乘性融合和目标保护三种模式的设计原理和实现细节,详细说明了杂波集的构建方法,包括利用统计模型生成模拟杂波以及从真实 SAR 图像中提取杂波数据,展示了两者在数据多样性和随机性方面的互补优势,并讲解了 SAR 图像与杂波随机采样和自适应融合算法原理,并通过大量可视化结果展示了不同融合模式下数据增强效果的直观表现;第 4.3 节介绍了实验设置;第 4.4 节介绍了多数据集、多检测网络下的性能对比,重点分析了在标注样本有限条件下,采用杂波随机采样融合的 SAR 目标检测方法如何有效增加数据多样性与随机性,从而提升检测性能;第 4.5 节为本章小结,总结了方法优势、实验结果及未来可能的改进方向。

4.2 杂波迁移的数据增强策略

针对 SAR 舰船检测中的杂波和噪声问题,本章提出了杂波数据增强的舰船检测算法,通过加性与乘性融合技术,结合统计模型与真实杂波数据,丰富了数据集的多样性与复杂性,从而提升了在复杂环境下的检测性能。杂波数据增强的舰船检测算法采用加性、乘性和目标保护三种融合模式,各自具备不同优势。加性融合增加了样本复杂性并生成多样化训练数据;乘性融合通过非线性交互提升图像复杂度;目标保护

模式确保在增强背景杂波的同时保留目标特征。大量实验表明,杂波数据增强的舰船检测算法在不同数据集上均能显著提升检测精度和鲁棒性。作为一种灵活高效的数据增强策略,杂波数据增强的舰船检测算法在不增加推理成本或额外参数的前提下,实现了对复杂背景下目标检测性能的全面提升。

4.2.1 算法整体框架

针对 SAR 图像舰船检测面临的挑战,本章提出了一种杂波随机采样的增强方法 (clutter random sampling augmentation method, CRSA)。CRSA 将真实杂波与模拟杂波融合到 SAR 数据中以增强目标检测。通过利用杂波的统计特性,CRSA 在保持检测网络原始端到端架构的同时增强了训练过程。所提方法的框图如图4.5所示。杂波集由统计模型和真实杂波数据组成。然后基于提出的三种模式对杂波集和原始训练数据进行随机采样并自适应融合。这个过程扩展了数据集的大小和复杂度。由于目标位置保持不变,只有背景变得更加复杂,因此保留了原始的训练标注并用于模型训练。CRSA 采用三种融合模式:加性融合、乘性融合和目标保护。加性融合通过将真实杂波与 SAR 数据相结合,生成多样化的样本,增强模型泛化并缓解过拟合,从而增加了数据集的复杂性。这种融合丰富了背景,使检测任务更具挑战性,并鼓励模型专注于从复杂背景中区分目标。乘性融合引入了 SAR 数据和杂波之间的非线性相互作用,可以模拟更复杂的环境条件。这种融合增加了背景复杂度,增强了特征提取的鲁棒性,增强了不同 SAR 环境下的检测性能。目标保护保证了融合过程中目标区域保持完整,在丰富背景杂波的同时保留了重要的目标信息。该策略使模型能够在不影响目标电磁散射特征的情况下从具有挑战性的背景中学习。




图 4.5 SAR 图像与杂波随机采样与自适应融合的舰船检测算法

自适应融合过程在每次迭代过程中动态演化,通过在每次迭代中引入新的融合模式来增强训练数据集的多样性,并降低过拟合的风险。这确保了模型可以接触到广泛的 SAR 场景,并适应真实的电磁散射条件,其中目标的语义信息往往与复杂背景融合。通过动态多样化数据集,CRSA 提高了模型的鲁棒性,而不需要修改端到端网络架构或在推理过程中引入额外的计算成本。该方法可以无缝集成到多种检测框架

中，具有较高的灵活性。

4.2.2 杂波特性分析

在 SAR 图像中，海杂波的建模对于提取目标散射特性和实现有效检测具有至关重要的作用。海面杂波受多种物理机制（如风驱波、多普勒效应、海洋动态变化等）的综合影响，其统计特性往往表现为高度非均质、非线性且随场景变化显著。为了准确刻画这种复杂性，研究人员采用了多种数学分布模型，包括瑞利分布、威布尔分布、伽马分布、对数正态分布以及 K 分布^[151]。此外，真实杂波指的是通过实际雷达成像采集到的背景杂波，其来源于真实海面环境中风浪、波浪、海流以及海上其他物体等复杂因素。相比于通过统计模型或模拟方法生成的杂波，真实杂波蕴含更丰富的信息，也被用来构建杂波集。统计模型生成的仿真杂波和真实杂波见图4.6所示。下面将对这些杂波模型的原理、适用场景及其数学公式进行详细且深入的介绍。




图 4.6 五种基于统计模型生成的海杂波与真实海杂波的对比

4.2.2.1 统计分布杂波

瑞利分布 (Rayleigh Distribution)^[134] 是描述完全发展相干散斑噪声的经典统计模型，广泛应用于均质海面或理想背景条件下的杂波建模。假设 SAR 图像中散斑噪声由大量独立且均匀分布的散射体产生，经过相干叠加后，根据中心极限定理，幅值服

从瑞利分布。其概率密度函数定义为

$$f(x; \beta) = \frac{x}{\beta^2} \exp\left(-\frac{x^2}{2\beta^2}\right), \quad x \geq 0, \quad (4-1)$$

其中, β 为尺度参数, 反映了散射体的平均散射强度。瑞利分布的数学期望与方差分别为

$$\mu = \beta \sqrt{\frac{\pi}{2}}, \quad \text{Var} = \frac{4 - \pi}{2} \beta^2. \quad (4-2)$$

威布尔分布 (Weibull Distribution)^[152] 通过引入形状参数, 提供了比瑞利分布更高的灵活性, 可用于描述不同海况下杂波强度的变化。采用统一符号记法, 其概率密度函数写为

$$f(x; \alpha, \beta) = \frac{\alpha}{\beta} \left(\frac{x}{\beta}\right)^{\alpha-1} \exp\left[-\left(\frac{x}{\beta}\right)^\alpha\right], \quad x \geq 0, \quad (4-3)$$

其中, α 为形状参数, 决定了分布的陡峭程度和尾部衰减速度; β 为尺度参数。注意, 当 $\alpha = 2$ 时, 威布尔分布在参数选取上与瑞利分布存在一定对应关系, 从而退化为瑞利分布的形式。

伽马分布 (Gamma Distribution)^[133] 是一种常用于描述乘性随机效应的概率模型, 在海杂波建模中尤为有效。统一符号记法下, 其概率密度函数为

$$f(x; \alpha, \beta) = \frac{x^{\alpha-1} \exp\left(-\frac{x}{\beta}\right)}{\beta^\alpha \Gamma(\alpha)}, \quad x > 0, \quad (4-4)$$

其中, α 为形状参数, β 为尺度参数, $\Gamma(\alpha)$ 为伽马函数。通过调整 α 与 β 的值, 可以灵活刻画由多重散射引起的信号幅值变化。

对于受到多重乘性效应影响的目标散射, 通常假设其变量 x 的对数服从正态分布, 从而 x 可用对数正态分布 (Log-normal Distribution) 描述。其概率密度函数为

$$f(x; \mu, \sigma) = \frac{1}{x\sigma\sqrt{2\pi}} \exp\left[-\frac{(\ln x - \mu)^2}{2\sigma^2}\right], \quad x > 0, \quad (4-5)$$

其中, μ 和 σ 分别为对数空间中的均值和标准差, 能够较好地捕捉由多重随机因素叠加导致的非线性变化和偏态分布特性。

K 分布 (K-Distribution)^[153] 被认为是描述复杂、非均质海杂波的一种高级统计模型, 其构造思想是将瑞利分布与伽马分布相结合, 既考虑了相干散斑效应, 又反映了海面底层纹理的随机性。统一符号记法下, 其概率密度函数表示为

$$f(x; \alpha, \beta) = \frac{2}{\Gamma(\alpha)} \left(\frac{\alpha}{\beta^2}\right)^\alpha x^{\alpha-1} K_{\alpha-1}\left(2x\sqrt{\frac{\alpha}{\beta^2}}\right), \quad x \geq 0, \quad (4-6)$$

其中, $\alpha > 0$ 为形状参数, $\beta > 0$ 为尺度参数, $K_{\alpha-1}(\cdot)$ 是 $\alpha - 1$ 阶修正贝塞尔函数。K 分布能够综合反映由于局部不均质性和粗糙度变化所引起的复杂散射特性; 当 α 较

大时, K 分布趋向于瑞利分布, 而当 α 较小时, 则更能捕捉到海杂波中的粗糙特性和非均质性。

上述五种统计模型在描述 SAR 海杂波时各有优缺点。瑞利分布简单且解析解易于计算, 适用于均质海面背景下的相干散斑噪声, 但对非均质和复杂纹理的描述能力有限。威布尔分布通过引入形状参数 k 提供了更高的灵活性, 能够适应不同海况下杂波强度的变化, 适用于风浪较大或海况动态变化明显的情况。伽马分布适合于建模多重散射和乘性效应, 其参数易于从实际数据中估计, 能够较好地反映海面杂波因多路径效应而引起的随机性。对数正态分布在目标散射受到多重乘性效应影响的场景中表现优异, 能够描述非线性和偏态特征, 适用于幅值变化范围较大、分布不均的情况。 K 分布作为一种综合模型, 既考虑了相干散斑效应, 又捕捉了底层纹理的非均质性和粗糙性, 因而在描述复杂海杂波时具有更高的准确性。它能够在参数 ν 和 σ 的调节下灵活适应各种海况, 是实际 SAR 杂波建模中的常用选择。

在实际应用中, 选择何种统计模型取决于具体场景的物理特性和目标需求。例如, 在均质海面且噪声主要由相干散斑构成的情况下, 瑞利分布已经足够; 而在复杂海况下, 可能需要采用威布尔、伽马或 K 分布来更准确地捕捉杂波特性。对数正态分布则适用于当散射信号经历多重乘性效应, 导致数据呈现明显偏态时的建模需求。

4.2.2.2 真实杂波

尽管统计建模提供了丰富的杂波类型, 但仅靠这些方法不能完全模拟现实世界环境的复杂性。因此, 本节提出了一种双重融合方法, 将真实杂波和统计模拟杂波独立地与 SAR 数据进行融合, 用于实验目的。真实杂波直接从 SAR 图像中提取, 反映了海面真实的散射特性, 而利用统计模型生成的模拟杂波弥补了真实杂波数据稀疏或代表性不足的缺点。真实杂波指的是通过实际雷达成像采集到的背景杂波, 其来源于真实海面环境中风浪、波浪、海流以及海上其他物体等复杂因素。相比于通过统计模型或模拟方法生成的杂波, 真实杂波具有独特的优点。真实杂波受多种物理因素(如风驱波、多普勒效应、海面起伏、海流干扰等)的共同作用, 其空间纹理和统计特性呈现出高度的复杂性和非均质性。这种复杂性使得真实杂波在不同区域和不同时间下表现出明显的变化特征。真实杂波能够反映实际海面散射的多种现象, 其分布通常不完全服从单一的理想化模型, 如瑞利、伽马或对数正态分布, 而往往需要采用多模型联合描述。这种真实的统计分布能更准确地揭示海面回波的随机性和动态性。由于海面条件的区域差异, 真实杂波在图像中往往表现为局部统计特性不同, 部分区域可能存在低杂波背景, 而其他区域则可能含有大量高散射信息。这种不均质性对目标与背景的区分提出了更高要求。真实杂波会随着实际海况和气象条件的变化而不断变化, 这使得同一场景在不同时间采集到的杂波具有不同的特征, 从而体现出很强的时变性。真实杂波保留了海面环境中各种复杂散射机制和噪声特性, 为目标检测

任务提供了符合实际应用需求的背景信息，避免了理想化模拟数据可能带来的偏差。通过引入真实杂波，可以显著增加训练样本的复杂性和多样性，使得检测模型在学习过程中接触到更多真实场景中的背景变化，从而提高模型的泛化能力和鲁棒性。

4.2.2.3 GAN 合成杂波

生成对抗网络（Generative Adversarial Networks, GAN）的基本思想在于利用生成器和鉴别器之间的最大最小博弈，不断相互博弈直至达到纳什均衡，从而使生成的数据在分布上逐步逼近真实数据。Wasserstein GAN (WGAN) 作为 GAN 的一种改进形式，通过引入 Wasserstein 距离和梯度惩罚技术，有效缓解了传统 GAN 训练过程中梯度消失和模式崩溃的问题，从而在生成高质量数据方面表现出更稳定和连续的优化特性。在杂波生成任务中，复杂电磁环境下的杂波往往呈现出丰富的统计特性和空间相关性，传统方法难以捕捉其中实部与虚部之间的细微关系。相比之下，基于 WGAN 的杂波生成网络利用最大最小博弈框架，在训练过程中通过不断优化生成器和鉴别器，使得生成的杂波图像能够在统计分布上更贴近真实场景。复数域 WGAN 直接以 SAR 信号的复数数据（包含实部和虚部）作为输入。图4.7展示 WGAN 生成的杂波数据，其中第一行为真实场景杂波，第二行为使用复数据生成杂波，第三行为使用幅度数据生成杂波。由于实部和虚部分别承载了信号的振幅和相位信息，这种方法试图在生成过程中保留完整的信号特性。然而，由于复数数据的内在结构较为复杂，网络在训练过程中需要同时捕捉两部分之间的相互作用和非线性关系。尽管复数域 WGAN 在理论上可以完整表达杂波的统计特性，但在实际训练中，如何有效协调实部与虚部之间的信息传递和特征融合，仍然是一个具有挑战性的问题，这可能导致生成的杂波图像在细节上存在不足，影响最终的仿真效果。




图 4.7 WGAN 生成的杂波数据

与复数域 WGAN 不同,幅度 WGAN 将 SAR 信号的幅度数据作为输入进行训练。幅度是由实部和虚部的平方和开平方得到的,直接反映了信号的强度信息。通过使用幅度数据,模型可以专注于学习杂波在强度分布上的变化,同时隐式捕捉到由实部与虚部交互所蕴含的相位信息。这种方法在训练过程中降低了数据的维度和复杂度,有助于网络更快地收敛,同时在生成结果中展现出更高的细节保真度和统计一致性。从实验可视化结果来看,使用幅度数据训练的复数域杂波仿真框架在各类杂波上均表现出更逼真、更丰富的纹理特征,且生成的杂波图像在真实场景下的适应性更好。

综上所述,真实杂波不仅能够真实还原实际海面环境的复杂背景,还为模型提供了多样化和时变性的训练样本,有助于提高检测网络在实际应用中的适应性和鲁棒性。这也是本章引入真实杂波的重要原因之一。在杂波随机采样融合的 SAR 目标检测方法中,将两类杂波分别与原始训练样本融合,以探索它们的个体和组合效应。每种融合策略都保留了原始标注信息,保证了整个训练过程的一致性。在增广过程中动态调整杂波参数,以匹配复杂环境下观测到的杂波统计特性,如不同海况区域或小尺度干扰区域。通过分析这些独立融合的影响,有助于评估真实杂波和模拟杂波对数据驱动的舰船检测算法的鲁棒性和泛化性的贡献。本章方法避免了构建统一的杂波数据集,突出了检测网络对不同训练场景的适应性,改善了检测模型对目标-背景判别,同时通过跨训练阶段杂波融合的动态迭代更新来减轻过拟合问题。




图 4.8 CRSA 算法框架

4.2.3 杂波随机融合的样本扩充方法

SAR 图像中的海杂波是电磁波与动态海洋表面相互作用的结果。杂波受风、浪和海况变化等因素的影响,呈现出不同的散射形态,给 SAR 检测系统带来了重大挑

战。为了应对这些挑战，CRSA 算法框架如图4.8所示，所提方法集成了三种先进的杂波融合增强策略：加性融合、乘性融合和目标保持融合。这些策略在保留重要目标信息的同时，为训练数据集引入了更多复杂度，从而增强了检测的鲁棒性和泛化性。

4.2.3.1 加性融合：通过线性积分增强数据多样性

通过统计建模全面刻画各类海杂波仍然是一项具有挑战性的任务。因此，充分利用真实海杂波数据中蕴含的丰富信息至关重要。此外，当与 SAR 图像相结合时，统计模型可以提高场景的复杂度。图4.8展示了 CRSA 的加性融合图像分支内的加性融合过程。加性融合方法通过线性融合真实 SAR 图像和纯杂波数据来模拟背景杂波与目标信号的物理共存。CRSA 的加性融合模式在图像加载到深度模型时随机选择一幅 SAR 图像（从训练数据集）和一幅真实杂波图像（从纯杂波数据集，没有任何舰船目标）。调整大小后，这两幅图像按随机生成的比例合并为最终的训练样本，如公式 1 所示：

$$J = I * (1 - \alpha) + cI * \alpha, \alpha \in (0, 0.5) \quad (4-7)$$

其中 J 表示加性融合图像。 I 和 cI 分别表示原始 SAR 图像和真实杂波图像。 α 表示随机确定的融合率。为了加强对船舶相关信息的保存，CRSA 对该比例进行了约束。值得注意的是，训练图像和杂波数据都是随机选择的，融合比率也是随机生成的。为了使检测网络能够从原始训练图像中提取与目标相关的特征，CRSA 以 50% 的概率被激活。在剩余 50% 的情况下，检测网络输入仅由原始 SAR 图像组成。重要的是，通过引入动态的、迭代级的可变性，加性融合确保了跨 epoch 的多样化、无冗余的训练样本，最小化过拟合风险，并增强了模型对未见过场景的适应性。在融合过程中，目标位置保持不变，而背景复杂度增加，使得原始位置标签可以直接用于训练而无需修改。

4.2.3.2 乘性融合：模拟非线性交互增强场景复杂度

在 SAR 系统中，由于相干成像原理的固有特性，雷达回波中的噪声通常以乘性形式出现，这种现象主要表现为散斑噪声。乘性噪声模型认为，观察到的 SAR 图像强度不仅包含目标的真实散射特性，还受到噪声因素的调制，其数学表达形式通常写为

$$I(x, y) = S(x, y) \cdot N(x, y), \quad (4-8)$$

其中， $I(x, y)$ 为观测到的图像强度， $S(x, y)$ 为目标或地物的真实散射系数，而 $N(x, y)$ 则表示乘性噪声或散斑噪声。SAR 成像依赖于微波的相干叠加，由于同一分辨单元内存在大量散射体（如海面小波、海浪等），各散射体的回波相位各不相同。当这些回波在相干叠加后，干涉效应会导致亮暗交替的散斑现象，这就是典型的乘性噪声。该噪声在图像中表现为高频、随机且空间上变化剧烈的纹理特征，与传统的加性高斯噪声有本质区别。在乘性噪声模型中，通常假定噪声分量 $N(x, y)$ 满足一定的统计分

布。对于单视角 (Single-look) SAR 图像, 噪声往往服从负指数分布 (针对强度) 或瑞利分布 (针对幅值), 即:

$$p_I(I) = \frac{1}{\bar{I}} \exp\left(-\frac{I}{\bar{I}}\right), \quad I \geq 0, \quad (4-9)$$

其中 $\bar{I}$ 为均值。对于多视角 (Multi-look) 处理, 噪声的统计分布趋向于伽马分布, 其概率密度函数为

$$p(I; L) = \frac{L^L}{\Gamma(L)\bar{I}^L} I^{L-1} \exp\left(-\frac{LI}{\bar{I}}\right), \quad I \geq 0, \quad (4-10)$$

其中 L 表示视角数, $\Gamma(\cdot)$ 为伽马函数。多视角处理可以有效降低噪声的方差, 改善图像质量。

综上所述, 乘性噪声模型不仅为 SAR 图像中噪声和杂波的统计描述提供了坚实的理论基础, 而且为数据增强技术中乘性融合模式的设计提供了重要依据。通过深入理解并合理利用乘性噪声特性, 可以更好地保留目标细节, 同时丰富背景复杂性, 从而提升 SAR 舰船检测算法在复杂海况下的鲁棒性和准确性。乘性融合模式利用了 SAR 系统中乘性噪声的基本原理, 其核心思想是在不改变目标位置信息的前提下, 使背景变得更加复杂。具体实现时, 通常将真实或模拟得到的杂波信号作为一个乘性因子, 与原始 SAR 图像逐像素相乘, 再以一定的随机比例与原始图像结合, 得到增强后的训练样本。数学上可表示为

$$J = I + I * cI * \alpha, \alpha \in (0, 0.5) \quad (4-11)$$

其中 J 表示加性融合图像。 I 和 cI 分别表示原始 SAR 图像和真实杂波图像, α 表示随机确定的融合率。在乘性融合模式下, CRSA 仍然以 50% 的概率随机触发。对于剩余的 50%, 原始 SAR 图像作为检测网络的输入。如图4.8所示, 该方法遵循与加性融合相同的过程。CRSA 乘性融合模式的概率为 50%。这种方法放大了微妙的杂波模式, 创建了模拟现实世界复杂性的具有挑战性的场景, 如波干扰或可变表面散射。乘性融合通过生成难以检测的样本, 增加了模型对罕见或模糊情况的学习机会, 促使检测网络学习到目标和复杂背景之间更多微妙的区分性特征。与加性融合相比, 乘性融合强调增加检测难度, 直接增强了模型在复杂环境下的鲁棒性。在乘性融合过程中, 目标位置保持不变, 但背景复杂度显著增加。这使得原始位置标签可以直接用于训练而无需修改。与主要增强数据集可变性的加性融合不同, 乘性融合引入了更具挑战性的杂波和噪声, 迫使模型专注于目标更本质、更具判别力的特征, 从而提高了在复杂环境中的鲁棒性。乘性融合方式可以有效增加训练数据的复杂性和多样性, 使得检测网络在训练时能够学习到更多真实场景中的背景特征, 从而提高模型在复杂环境下的泛化能力。

4.2.3.3 目标保护融合：复杂性与特征完整性的平衡

杂波增强增强了背景的真实感，但直接修改目标区域可能会降低其本质特征，如电磁散射模式和轮廓。为了缓解这种情况，保护目标的融合策略包含了基于边界框的保护机制。在融合过程中，边界框外区域进行加性融合或乘性融合，而目标区域保持不变。该方法保持了目标特征的完整性，保证了分类定位的准确性。引入目标周围的局部杂波变化，从而增强网络区分目标边界和复杂背景的能力。目标保护融合方法在背景复杂性和目标信息完整之间取得了平衡。




图 4.9 CRSA 融合过程中统计模型生成的杂波的可视化结果

在统计模型方面，本节利用瑞利分布、威布尔分布和伽马分布等数学模型生成模拟杂波，这些模型能够填补在代表性不足的场景中因极端环境条件或罕见杂乱模式而缺失的信息。图4.9直观展示了利用统计模型生成的模拟杂波在不同融合模式下的效果，证明了统计模型在数据增强中的有效性和灵活性。在该图中，每一行均包含五幅图像，分别展示了原始 SAR 图片、真实杂波图片以及经过加性融合、乘性融合和保护目标融合后的结果。对于采用统计模型的 CRSA，对于采用统计模型的 CRSA 方案，加性融合模式直接将生成的模拟杂波与原始 SAR 图像进行线性叠加，使得背景中原有的简单纹理得到了有效增强，进而引入了额外的随机性和复杂性；乘性融合模式则通过将统计杂波以随机比例与原始图像相乘，显著提升了整体图像的复杂度，从而为检测网络提供了更为挑战性的训练样本；而保护目标融合模式在对背景进行

复杂化处理的同时，确保目标区域的原始散射特性不受干扰，既扩展了数据集的多样性，又保证了目标信息的完整性。图4.9直观展示了各融合模式下背景变化的层次性和差异性，为统计模型在数据增强中的有效性和灵活性提供了有力验证。




图 4.10 CRSA 融合过程中真实杂波的可视化结果

图4.10展示了基于真实杂波的 CRSA 融合效果。真实杂波直接从 SAR 图像中提取，能够捕捉到海面实际的散射模式及复杂环境中的随机噪声特性，从而更真实地反映实际场景的背景特征。在该图中，每一行均包含五幅图像，分别展示了原始 SAR 图片、真实杂波图片以及经过加性融合、乘性融合和保护目标融合后的结果。从图像对比中可以看出，原始 SAR 图片作为基础，保留了目标的基本散射信息；真实杂波图片则展示了自然海面背景的多样性和细节；加性融合结果在保持目标不变的前提下，通过线性叠加真实杂波，使背景细节得到了增强，便于模型识别复杂背景；乘性融合结果由于对真实杂波进行随机比例乘法运算，使图像整体复杂度显著提升，从而在训练时增加了检测难度；保护目标融合结果则在强化背景杂波特征的同时，优先保留目标信息，确保目标特征不会被过度干扰，从而扩展了训练集的多样性与复杂性。图4.10的可视化结果验证了真实杂波在还原实际海面环境变化方面的优势，并证明了在 CRSA 框架中，真实杂波融合能够为检测网络提供更具鲁棒性的训练样本，进而提升检测性能。

通过统计模型和真实杂波两种不同来源的杂波融合结果，本章所提方法能够在

数据增强过程中分别利用模拟杂波和真实杂波各自的优势。统计模型生成的杂波能够补充罕见或极端环境下的背景信息，而真实杂波则确保数据集具有真实场景的代表性。两者相结合为检测网络提供了多层次、多角度的背景复杂性，有效提升了模型在复杂海况下的泛化能力和鲁棒性。

4.3 实验设置说明

遵循通用的随机划分标准，本章实验将 HRSID 和 SSDD 数据集划分为训练子集 (70%)、验证子集 (20%) 和测试子集 (10%)。CRSA 方法是一种通用的数据增强技术，适用于所有检测算法。具体来说，本节选择了 Faster R-CNN、RetinaNet、YOLO V4、CenterNet 和 YOLO V7 作为基线模型进行评估。所有方法均使用预训练的 ImageNet 模型作为初始参数^[154]。ResNet50 被用作 Faster R-CNN、RetinaNet 和 CenterNet 的主干。在 CRSA 框架下，将真实模型和统计模型与 SAR 图像随机融合。真实的杂波来自 HRSID 数据集，其中包含 400 幅近海和近海图像。本节选取高斯分布杂波、伽马分布杂波和 K 分布杂波作为统计模型。为了增强统计模型的多样性，对高斯杂波的均值在 $(-5, +5)$ 范围内和方差在 $(50, 200)$ 范围内进行了随机选择。gamma 分布杂波的形状参数和尺度参数在 $(0, 5)$ 范围内随机选取，k 分布杂波的形状参数在 $(0, 5)$ 范围内随机选取，尺度参数在 $(0, 1)$ 范围内随机选取。

4.4 实验结果与分析

4.4.1 与去斑检测级联策略的性能对比

相干斑抑制技术在 SAR 图像处理和目标检测中具有重要意义，其基本原理在于利用统计噪声模型和局部滤波方法降低由于多路径干涉和相干叠加引起的乘性噪声。然而，传统的滤波操作在降低噪声的同时也不可避免地削弱了图像中与目标相关的结构信息和电磁散射特征，从而导致检测网络在训练过程中无法充分学习到噪声特征，这对目标与背景的辨别产生了负面影响。传统滤波方法（如中值滤波、Lee 滤波和 Frost 滤波）主要依赖于局部窗口内像素值的统计分析。空域滤波通常通过选择合适的滑动窗口，对窗口内的像素进行统计聚合，然后利用估计的噪声模型（通常假设为乘性噪声）的统计特性计算出一个代表性的窗口中心值，再将这一值赋予窗口中心像素。这样的过程虽然能够在一定程度上平滑噪声，但由于仅考虑局部信息，忽略了全局图像的结构和纹理细节，因而在图像细节和边缘保留方面存在局限性。中值滤波作为一种非线性滤波技术，擅长于抑制椒盐噪声，其基本操作是用窗口内的中位数替换中心像素值，从而实现平滑效果。然而，中值滤波并未对噪声分布进行建模或深入分析，因而无法捕捉 SAR 图像中典型的乘性噪声特征，导致其在保持目标细节

和纹理信息方面表现不足。Lee 滤波器则基于局部均值与方差的统计关系，通过近似线性模型实现噪声抑制，其自适应性较好，能在一定程度上区分噪声与信号，从而在不同区域内实现较为平衡的去噪与细节保留。Frost 滤波器进一步提出了一种基于假设背景服从高斯分布的自适应加权平均方法，利用像素间的统计差异进行加权融合，虽然在抑制噪声上具有较好效果，但在图像边缘或结构变化剧烈的区域依然容易出现模糊现象，影响目标的电磁散射特征和轮廓信息。




图 4.11 去斑结果可视化

图4.11是来自 SSDD 数据集的原始 SAR 图像与应用中值滤波、Lee 滤波和 Frost 滤波技术后的结果的对比。上述的滤波算法在相干斑抑制过程中都只考虑了图像的局部性，而忽略了窗口以外的图像信息。因此，它们在图像变化较大的区域表现不佳，容易产生模糊效应，从而影响目标电磁散射特征以及细节和轮廓信息的保持。




图 4.12 不同去斑方法在 SSDD 数据集检测性能比较

从实验结果来看，如图4.12所示，基于 ResNet-50 为骨干的 Faster R-CNN 和 RetinaNet 检测网络在 SSDD 数据集上进行了不同滤波方法的对比。图中通过 AP、召回率和准确率等指标展示了各方法对目标检测性能的影响。实验数据表明，中值滤波由于未能充分利用噪声统计分布信息，其性能提升有限；Lee 滤波器在平衡噪声抑制和细节保留方面表现较优；而 CRSA 采用的乘性融合方法，不仅在抑制相干斑噪声方


面取得了显著效果，更通过数据增强策略增加了训练样本的多样性和随机性，从而在所有指标上均达到了最优表现。

虽然传统空域滤波方法在一定程度上可以降低噪声，但其局限性在于只关注局部统计信息，忽略了全局结构，容易导致图像模糊和目标信息丢失。为了解决这一问题，本研究提出的 CRSA 方法通过将统计模型生成的模拟杂波（如瑞利、威布尔、伽马、对数正态和 K 分布）与真实杂波相结合，并采用加性融合、乘性融合和目标保护等多种策略，有效地弥补了滤波方法在目标细节保留上的不足。CRSA 不仅在抑制噪声上取得了良好的效果，同时保留了目标电磁散射和结构特征，使得检测网络在面对复杂背景时能更准确地识别目标。此外，通过引入随机性和数据多样性，CRSA 进一步解决了标注样本有限带来的训练数据不足问题，增强了模型的鲁棒性和泛化能力。CRSA 有效地保护了目标的电磁散射和剖面信息，同时增加了训练集的多样性。CRSA 为复杂海况下的目标检测提供了有力支持。详细的实验数据将在 4.6 中给出。

4.4.2 与直接叠加杂波策略的性能对比

为了系统地研究杂波对舰船检测网络性能的影响，并增加包含杂波与目标识别任务的训练难度，本文采用统计模型将杂波引入 SAR 图像中，构建了一种数据增强策略。该方法的核心思想在于利用不同统计模型生成的模拟杂波来补充原始数据集，进而提高训练数据的多样性和随机性，迫使检测网络在更具挑战性的环境下提取目标特征，从而提高其对杂波的区分能力和整体鲁棒性。

海杂波源自海水运动和各种表面散射机制，具有复杂、随机、非平稳等特性。在完全发展阶段，依据中心极限定理，海杂波可以较好地用高斯分布进行建模；但当散斑从完全发展过渡到不完全发展时，其统计特性出现显著偏离高斯模型，此时采用非高斯分布模型（如 K 分布和伽马分布）更为合适。K 分布能够反映杂波中的局部不均质性和粗糙特性，适用于描述跨不同地理位置、季节和天气条件下杂波的异质性；而伽马分布则具有可调节的形状参数，能够精准地刻画海杂波中强回波的长尾特性。基于此，为了全面评估杂波对舰船检测网络的影响，实验中分别采用了高斯分布、K 分布和伽马分布生成模拟杂波。



(a) 原始 SAR 图像 (b) 叠加高斯杂波结果 (c) 叠加 K 分布杂波结果 (d) 叠加伽马杂波结果

图 4.13 叠加统计模型生成杂波的结果可视化

图4.13直观地展示了原始 SAR 图像与叠加不同统计模型生成的杂波后的图像效

果。从图中可以看出，叠加后的图像中目标区域受到不同程度的杂波干扰，这种干扰效应在一定程度上放大了目标与背景之间的对比，增加了检测任务的复杂性，同时也迫使检测器学习更鲁棒的特征。通过对杂波进行叠加仿真，网络在训练时能够同时接触到目标信号和来自不同分布的噪声，从而提高其在实际复杂海况下的适应能力。

如图4.14所示，利用 Faster R-CNN 和 RetinaNet 检测网络（均采用 ResNet 50 作为骨干）在 SSDD 数据集上进行了不同模拟杂波模型的性能对比。实验表明，当叠加高斯分布杂波时，检测性能显著提高；而在 K 分布杂波叠加的情况下，性能则出现一定下降，可能是由于 K 分布在表达局部非均质性时过于激进，从而使得模型难以稳定提取目标特征；伽马分布的叠加效果介于两者之间，检测性能略有改善。这一现象表明，单一的分布式仿真杂波模型难以涵盖数据集中所有类型的海杂波，其表达能力存在局限性。相比之下，CRSA 方法通过结合真实杂波与统计模型生成的模拟杂波，采用在线随机融合的策略，有效地扩展了数据集的多样性和随机性，使得训练样本在背景干扰上更为丰富，从而极大地提高了检测器对复杂干扰场景下目标的辨识能力。




图 4.14 SSDD 数据集中叠加不同统计模型杂波的性能比较

利用统计模型对杂波进行建模能够充分利用噪声的统计特性，进而基于数学期望和方差对不同分布的杂波进行精细刻画。高斯分布适用于完全形成的杂波，而 K 分布和伽马分布则在处理不完全散斑和非平稳现象时更具优势。通过引入这些模型，可以构建出一个多层次、涵盖多种物理机制的杂波集，从而在数据增强阶段提供更多的样本变化。这不仅增加了训练样本的数量，还使得样本在空间、统计特性和噪声强度上更加多样化，为检测网络提供了更丰富的学习资源。

CRSA 在所有三个指标上都达到了最佳性能，这将在 4.6 中进一步阐述。因此，单一的分布式仿真杂波模型显然无法准确地表示数据集中所有类型的海杂波。CRSA 的优点在于它是一种结合真实杂波的在线方法。此外，在线融合真实杂波与模拟杂波

的策略使得 CRSA 方法具备较强的适应性。真实杂波来源于实际 SAR 成像数据，其能够捕捉海面散射的真实特性和复杂变化，而统计模型生成的杂波则可以在参数空间上进行灵活调节，模拟出难以在实际数据中完整呈现的极端条件。二者的结合既保证了数据的真实性，又引入了额外的干扰，迫使检测网络在有限的标注样本条件下学习到更为鲁棒和区分性更强的特征。

4.4.3 与通用数据增强方法的性能对比

从表4.1中的数据可以看出，基于 YOLO V7 的基础模型在 SSDD 数据集上已经取得了较高的性能指标：平均精度（AP）达到 95.62%，查准率为 85.58%，查全率高达 96.91%。这一结果充分证明了 YOLO V7 本身在特征提取和目标检测方面具有较强的能力，但在实际海面杂波和噪声干扰条件下，单纯依赖基础模型仍难以实现最优性能。因此，引入数据增强技术成为提升检测效果的关键手段。

传统的数据增强方法如 Mosaic、Mixup 和 Cutmix 分别采用不同策略扩充训练样本，但它们在提高性能方面存在一定局限性。具体来说，Mosaic 方法通过将不同图像拼接在一起增加数据多样性，但在本实验中仅使 AP 略微提升至 95.81%，同时查全率从 96.91% 降至 95.53%，显示出其对背景复杂性改善有限；Mixup 方法虽然通过平滑插值促进模型鲁棒性，但由于在插值过程中目标特征容易被模糊混合，其查准率显著降低至 64.69%，导致 AP 下降至 93.53%；而 Cutmix 方法在一定程度上保留了部分目标信息，但由于目标完整性未能完全保障，其整体性能仅达到 80.86%，且查准率和查全率分别为 80.00% 和 84.31%，均远低于其他方法。

表 4.1 CRSA 与数据增强技术在 SSDD 数据集中的性能比较

方法	平均准确率	准确率	召回率
YOLO V7	95.62%	85.58%	96.91%
+ Mosaic	95.81%	85.41%	95.53%
+ Mixup	93.53%	64.69%	95.14%
+ Cutmix	80.86%	80.00%	84.31%
+ Ours	97.01%	87.40%	98.01%

相比之下，CRSA 方法通过将真实杂波与统计模型生成的模拟杂波相结合，充分利用了真实数据与模拟数据的互补优势，从而更好地模拟复杂 SAR 环境。该方法在保持目标特征完整性的同时，显著增加了背景的复杂性，使得检测器在训练过程中能同时学习到目标与干扰之间更为细致的判别特征。采用 CRSA 后，实验结果显示 AP 提升至 97.01%，查准率提高至 87.40%，查全率达到 98.01%，在所有指标上均优于传统数据增强方法。这些数据充分证明了 CRSA 在处理复杂杂波环境中具有更高的优

越性和鲁棒性。

从原理上看,CRSA 方法设计基于真实杂波与统计模型生成杂波的融合思想。真实杂波直接反映了实际 SAR 成像中海面散射的复杂特性,而统计模型(如瑞利、威布尔、伽马、对数正态和 K 分布)能够灵活模拟出不同物理条件下杂波的统计特性。二者结合,既保证了数据的真实性,又引入了额外的随机干扰,从而迫使检测网络在有限标注样本条件下学习到更具区分性的特征。同时,CRSA 方法通过在线随机融合策略增加了训练样本的多样性和随机性,这对于提高网络在复杂背景下的泛化能力具有重要意义。

4.4.4 真实杂波随机采样融合的实验结果

4.4.4.1 SSDD 数据集实验结果

为了全面验证 CRSA 的先进性和可移植性,本研究在 Faster R-CNN (ResNet 50)、RetinaNet (ResNet 50)、CenterNet (ResNet 50)、YOLO V4 和 YOLO V7 这五种最新检测模型上开展了大量实验。实验中,所有模型均采用一致的网络架构、迭代轮数和超参数设置,且实际杂波均来自 HRSID 数据集,确保了公平性和实验结果的可比性。为研究真实杂波在提高检测性能中的作用,CRSA 设计了三种融合模式:加性融合(AF)、乘性融合(MF)以及目标区域保护融合(ST)。

从表4.2中的数据可以看出,CRSA 在各检测模型上均取得了明显提升。以 Faster R-CNN 为例,其基线 AP 为 76.68%,查准率为 69.75%,查全率为 83.59%;而在引入 CRSA 的加性融合模式后,AP 提升至 79.48% (提升 2.80%),查准率提高到 72.08%,查全率上升至 84.73%。更为显著的是,在 Faster R-CNN 中采用乘性融合模式后,AP 达到了 81.95% (提升 5.27%),查准率和查全率分别提升至 73.46% 和 86.64%。对于 RetinaNet,其基线 AP 为 78.68%,而引入不同融合模式后,AP 分别提高至 79.34%、79.11% 和 79.60% (相应提升分别为 0.68%、0.43% 和 0.92%);在 CenterNet 模型中,基线 AP 为 89.19%,通过 CRSA 的加性、乘性和目标保护融合分别提升到 90.67%、90.62% 和 90.35%。而在 YOLO V4 和 YOLO V7 这两个性能较高的模型中,YOLO V4 基线 AP 为 91.09%,经加性融合后提升至 94.19% (提升 3.10%),而 YOLO V7 的基线 AP 为 95.62%,采用乘性融合模式后达到 97.01% (提升 1.39%),目标保护模式则使 AP 达到 96.73%。此外,不同模型在查准率和查全率方面也都表现出不同程度的改善,例如 YOLO V7 的查准率由 85.58% 提升至最高的 87.40%,查全率则从 96.91% 提高到 98.01%。

从原理角度来看,CRSA 方法的优势在于它充分整合了真实杂波的有效信息。真实杂波能够真实反映 SAR 图像中海面杂波的复杂性和非平稳性。SAR 图像与真实杂波的融合不仅扩充了训练数据集的多样性和随机性,而且在保证目标电磁散射和结

构信息完整性的同时，通过增加背景复杂性迫使检测网络学习到更为鲁棒的特征表达。这种数据增强策略特别适用于标注样本有限的实际场景，因为它在不增加额外推理成本的情况下，通过在线融合机制显著提升了网络对复杂干扰背景的区别能力。

此外，CRSA 不同的融合模式各有侧重：加性融合主要利用线性叠加来增强背景信息，而乘性融合通过非线性交互更真实地模拟 SAR 图像中的乘性噪声特性；目标区域保护模式则在增强背景干扰的同时，有效保护目标区域的关键信息，确保检测器能够准确定位和识别目标。这三种模式在不同检测网络上表现出互补优势，使得 CRSA 在整体提高模型泛化性、检测准确性和鲁棒性方面表现尤为突出。

综上所述，实验结果充分证明了 CRSA 方法在不同检测模型和数据集上的先进性和可移植性。通过在线融合真实杂波和统计模型生成的模拟杂波，CRSA 显著提高了平均精度、查准率和查全率，证明了其在解决复杂海况下 SAR 舰船检测问题中的有效性和实用价值。这种方法为实际应用中标注样本有限、背景复杂的 SAR 目标检测提供了一种高效、可靠且易于推广的解决方案。

表 4.2 融合真实杂波的 CRSA 在 SSDD 上的实验结果

方法	平均准确率	准确率	召回率
Faster R-CNN	76.68%	69.75%	83.59%
Faster R-CNN+AF	79.48%(+2.80%)	72.08%	84.73%
Faster R-CNN+MF	81.95%(+5.27%)	73.46%	86.64%
Faster R-CNN+ST	80.02%(+3.34%)	70.44%	85.50%
RetinaNet	78.68%	82.33%	80.25%
RetinaNet+RF	79.34%(+0.68%)	79.42%	81.09%
RetinaNet+MF	79.11%(+0.43%)	83.84%	80.67%
RetinaNet+ST	79.60%(+0.92%)	84.28%	81.09%
CenterNet	89.19%	83.05%	93.51%
CenterNet+AF	90.67%(+1.48%)	81.33%	93.13%
CenterNet+MF	90.62%(+1.43%)	79.87%	93.89%
CenterNet+ST	90.35%(+1.16%)	81.13%	93.51%
YOLO V4	91.09%	85.42%	93.89%
YOLO V4+AF	94.19%(+3.10%)	85.91%	95.42%
YOLO V4+MF	92.06%(+0.97%)	82.72%	95.04%
YOLO V4+ST	92.71%(+1.62%)	85.22%	94.66%
YOLO V7	95.62%	85.58%	96.91%
YOLO V7+AF	96.29%(+0.67%)	83.55%	97.57%
YOLO V7+MF	97.01%(+1.39%)	87.40%	98.01%
YOLO V7+ST	96.73%(+1.11%)	87.90%	97.79%

4.4.4.2 HRSID 数据集实验结果

为了全面验证 CRSA 的先进性和可移植性,本研究在 Faster R-CNN (ResNet 50)、RetinaNet (ResNet 50)、CenterNet (ResNet 50)、YOLO V4 和 YOLO V7 这五种最新检测模型上开展了大量实验。实验中,所有模型均采用一致的网络架构、迭代轮数和超参数设置,且实际杂波均来自 HRSID 数据集,确保了公平性和实验结果的可比性。为研究真实杂波在提高检测性能中的作用,CRSA 设计了三种融合模式:加性融合 (AF)、乘性融合 (MF) 以及目标区域保护融合 (ST)。CRSA 利用了来自 HRSID 数据集的真实杂波,实验结果如表4.3所示。从表4.2中的数据可以看出,CRSA 在各检测模型上均取得了明显提升。以 Faster R-CNN 为例,其基线 AP 为 76.68%,查准率为 69.75%,查全率为 83.59%;而在引入 CRSA 的加性融合模式后,AP 提升至 79.48% (提升 2.80%),查准率提高到 72.08%,查全率上升至 84.73%。更为显著的是,在 Faster R-CNN 中采用乘性融合模式后,AP 达到了 81.95% (提升 5.27%),查准率和查全率分别提升至 73.46% 和 86.64%。对于 RetinaNet,其基线 AP 为 78.68%,而引入不同融合模式后,AP 分别提高至 79.34%、79.11% 和 79.60% (相应提升分别为 0.68%、0.43% 和 0.92%);在 CenterNet 模型中,基线 AP 为 89.19%,通过 CRSA 的加性、乘性和目标区域保护融合分别提升到 90.67%、90.62% 和 90.35%。而在 YOLO V4 和 YOLO V7 这两个性能较高的模型中,YOLO V4 基线 AP 为 91.09%,经加性融合后提升至 94.19% (提升 3.10%),而 YOLO V7 的基线 AP 为 95.62%,采用乘性融合模式后达到 97.01% (提升 1.39%),目标区域保护模式则使 AP 达到 96.73%。此外,不同模型在查准率和查全率方面也都表现出不同程度的改善,例如 YOLO V7 的查准率由 85.58% 提升至最高的 87.40%,查全率则从 96.91% 提高到 98.01%。所有三种 CRSA 模式都导致 RetinaNet、CenterNet 和 YOLO V7 的性能显著提高。乘性融合模式对 AP 的改进最显著,而加性融合模式的影响更有限。

需要注意的是,与表4.2相比,表4.3得出的结论并不成立。这突出了对跨不同数据集的最佳 CRSA 方法进行详细分析的必要性。实验结果验证了 CRSA 的可移植性和优越性。在不同数据集上的实验结果进一步证实了 CRSA 作为一种 SAR 数据增强技术的广泛适用性。此外,CRSA 不同的融合模式各有侧重:加性融合主要利用线性叠加来增强背景信息,而乘性融合通过非线性交互更真实地模拟 SAR 图像中的乘性噪声特性;目标区域保护模式则在增强背景干扰的同时,有效保护目标区域的关键信息,确保检测器能够准确定位和识别目标。这三种模式在不同检测网络上表现出互补优势,使得 CRSA 在整体提高模型泛化性、检测准确性和鲁棒性方面表现尤为突出。综上所述,实验结果充分证明了 CRSA 方法在不同检测模型和数据集上的先进性和可移植性。通过在线融合真实杂波和统计模型生成的模拟杂波,CRSA 显著提高了平均精度、查准率和查全率,证明了其在解决复杂海况下 SAR 舰船检测问题中的有效

表 4.3 融合真实杂波的 CRSA 在 HRSID 上的实验结果

方法	平均准确率	准确率	召回率
RetinaNet	61.93%	68.15%	63.24%
RetinaNet+AF	62.99%(+1.06%)	67.24%	64.36%
RetinaNet+MF	63.58%(+1.65%)	68.18%	64.90%
RetinaNet+ST	63.23%(+1.30%)	65.45%	64.56%
CenterNet	81.61%	81.90%	85.22%
CenterNet+AF	83.02%(+1.41%)	81.05%	85.07%
CenterNet+MF	84.58%(+2.97%)	84.73%	87.62%
CenterNet+ST	84.24%(+2.63%)	83.49%	87.14%
YOLO V7	88.99%	76.19%	91.45%
YOLO V7+AF	91.57%(+2.58%)	83.32%	92.99%
YOLO V7+MF	92.19%(+3.20%)	78.93%	93.86%
YOLO V7+ST	92.01%(+3.02%)	79.40%	93.49%

性，为实际应用中标注样本有限、背景复杂的 SAR 目标检测提供了一种高效、可靠且易于推广的解决方案。

4.4.5 统计分布采样迁移的实验结果

4.4.5.1 SSDD 数据集实验结果

本实验严格采用统计模型生成的仿真杂波，以验证 CRSA 方法在 SAR 舰船检测任务中的优势。表4.4所示实验中使用的 workstation 与本研究中使用其他平台不同，因此基线有所修改。为增加仿真杂波的多样性，在一定范围内随机选取 SAR 图像融合参数。基于对实测 SAR 数据的统计分析，结合常见杂波模型在典型场景中的参数取值范围，本节实验构建了一个能够涵盖多种杂波类型特征的自适应参数变化区间。高斯分布是描述雷达杂波尤其是热噪声或弱散射背景下杂波分布的经典模型，其统计特性由均值 μ 和方差 σ^2 决定。其中， μ 反映杂波分布的中心位置， σ^2 则刻画其强度波动范围。在实际建模中，为模拟不同强度水平和偏移特征的背景杂波，通常将均值 μ 设定于 $(-5, 5)$ 的范围内，方差 σ^2 设定于 $(50, 200)$ 的范围内，以适应多种典型雷达成像场景下的背景噪声分布特性。K 分布通常用于建模高分辨率 SAR 图像中的海杂波，其概率密度函数由形状参数 ν 和尺度参数 σ 控制。形状参数 ν 反映了杂波的散射强度波动程度，尺度参数 σ 表示杂波的平均功率水平。在实际应用中， ν 通常取值于 $[1, 6]$ 的区间内，以刻画从剧烈波动（低 ν ）到平稳散射（高 ν ）的不同杂波场景；而尺度参数 σ 一般归一化至 $[0, 1]$ 区间，以适应 SAR 图像的强度范围标准化处理。伽玛分布是一种常用于建模 SAR 图像中同质区域杂波的统计模型，其概率密度函数由

形状参数 α 和尺度参数 β 控制。其中, 形状参数 α 表征杂波幅度分布的形状特征, 尺度参数 β 则决定分布的扩展程度。在本章实验中, 为覆盖多种杂波类型, 参数 α 与 β 通常在 (0,5) 的范围内选取, 以反映不同杂波强度波动与功率水平。

表 4.4 融合仿真杂波的 CRSA 在 SSDD 上的实验结果

方法	平均准确率	准确率	召回率
Faster R-CNN	71.33%	69.59%	78.63%
Gaussian Distribution			
Faster R-CNN+AF	73.92%(+2.59%)	71.43%	78.24%
Faster R-CNN+MF	74.64%(+3.31%)	71.19%	80.15%
Faster R-CNN+ST	73.71%(+2.38%)	72.57%	79.77%
K Distribution			
Faster R-CNN+AF	73.13%(+1.80%)	70.27%	79.39%
Faster R-CNN+MF	76.28%(+4.95%)	72.43%	83.21%
Faster R-CNN+ST	74.45%(+3.12%)	72.32%	79.77%
Gamma Distribution			
Faster R-CNN+AF	74.25%(+2.92%)	70.95%	80.15%
Faster R-CNN+MF	76.34%(+5.01%)	74.31%	81.68%
Faster R-CNN+ST	73.24%(+1.91%)	74.37%	78.63%
K Distribution			
RetinaNet	78.68%	82.33%	80.25%
RetinaNet+RF	82.95%(+4.27%)	81.03%	84.68%
RetinaNet+MF	83.16%(+4.48%)	83.26%	85.14%
RetinaNet+ST	83.24%(+4.56%)	84.30%	84.68%
K Distribution			
CenterNet	89.19%	83.05%	93.51%
CenterNet+AF	90.94%(+1.75%)	78.80%	96.03%
CenterNet+MF	92.05%(+2.86%)	78.96%	96.91%
CenterNet+ST	94.07%(+4.88%)	81.89%	95.81%

从表4.4中可以看出, 利用统计模型仿真杂波与 CRSA 的在线融合策略, 在不同融合模式下均显著提升了检测器性能。例如, 在 Faster R-CNN 实验中, 基线 AP 为 71.33%; 在应用高斯分布仿真杂波后, 采用加性融合 (AF)、乘性融合 (MF) 和目标区域保护融合 (ST) 分别将 AP 提升至 73.92% (提升 2.59%)、74.64% (提升 3.31%) 和 73.71% (提升 2.38%)。在 K 分布条件下, 乘性融合模式尤为突出, 将 AP 提升至 76.28% (提升 4.95%); 而在伽马分布条件下, 乘性融合同样表现优异, AP 达到 76.34% (提升 5.01%)。此外, 在 RetinaNet 和 CenterNet 两种检测器上, 均在统计模

型杂波的作用下取得了不同程度的性能提升，体现了 CRSA 方法在多种检测框架中的通用性和稳定性。CRSA 的在线融合机制在不增加额外推理成本的情况下，实时引入仿真杂波干扰，提升了检测器对复杂干扰背景下目标的辨识能力，尤其适用于标注样本有限的实际应用场景。

总体来看，实验结果充分证明，在仅使用统计模型生成的仿真杂波条件下，CRSA 方法通过不同的融合策略（其中乘性融合模式表现尤为突出）显著提高了 SAR 舰船检测的平均精度、查准率和查全率。这种方法不仅保证了目标电磁散射和结构信息的完整性，同时通过增加背景复杂性，迫使网络学习到更加鲁棒的特征表达，为解决复杂海况下的 SAR 目标检测问题提供了一种高效、可靠且易于推广的解决方案。

表 4.5 融合仿真杂波的 CRSA 在 HRSID 上的实验结果

方法	平均准确率	准确率	召回率
YOLO V7	88.99%	76.19%	91.45%
Gaussian Distribution			
YOLO V7+AF	89.55%(+0.56%)	86.69%	90.94%
YOLO V7+MF	89.16%(+0.17%)	86.63%	90.04%
YOLO V7+ST	90.31%(+1.32%)	88.24%	91.22%
K Distribution			
YOLO V7+AF	90.44%(+1.45%)	87.83%	91.75%
YOLO V7+MF	91.26%(+2.27%)	87.31%	92.18%
YOLO V7+ST	74.45%(+3.12%)	72.32%	79.77%
Gamma Distribution			
YOLO V7+AF	91.16%(+2.17%)	85.41%	92.25%
YOLO V7+MF	90.98%(+1.99%)	85.13%	92.31%
YOLO V7+ST	90.82%(+1.83%)	87.89%	91.87%
K Distribution			
CenterNet	81.61%	81.90%	85.22%
CenterNet+AF	82.09%(+0.48%)	77.54%	84.18%
CenterNet+MF	83.22%(+1.61%)	77.20%	85.48%
CenterNet+ST	82.94%(+1.33%)	77.55%	85.05%

4.4.5.2 HRSID 数据集实验结果

为进一步验证 CRSA 在不同数据集上利用统计模型生成仿真杂波的优势,表4.5展示了基于 YOLO V7 和 CenterNet 检测器获得的实验数据。所采用的统计模型参数范围与 SSDD 数据集实验保持一致，以确保实验条件的统一性。实验结果显示，在不同融合策略下，利用高斯分布、K 分布和 Gamma 分布生成的仿真杂波均能提升检测性能，其中 K 分布和 Gamma 分布在某些指标上具有更好的增强效果。统计模型的参

数范围与表4.4保持一致。不同的融合方法以及 CRSA 分布的变化都能提高检测性能。与高斯分布相比, k 分布和 Gamma 分布具有更好的增强效果。将 CRSA 算法与基于 k 分布的乘法融合模式相结合, AP 提高 2.27%, 准确率提高 11.12%。将这些结果与表4.3中 YOLO V7 的结果进行比较, 可以看出, 使用真实杂波的 CRSA 显著提高了召回率, 而使用统计模型的 CRSA 降低了虚警率。

此外, 表4.2至表4.5的结果不仅验证了 CRSA 作为一种数据增强技术的有效性, 也为根据给定检测任务的具体需求选择最合适的融合模式和杂波模型提供了指导。这些实验强调了选择最佳配置来平衡检测性能指标(如 AP、准确率、召回率和误报率)的重要性。利用统计模型可以将杂波的分布参数(如均值、方差、形状参数及尺度参数)严格限定在预设区间内, 从而构建一个高度可控且可重复的实验环境。这种精确控制使得各项检测指标的提能够更直接地归因于融合策略的优化, 而非其他外部干扰因素。统计模型不仅能模拟实际 SAR 图像中存在的噪声特性, 还能够针对不同检测器(如 YOLO V7 与 CenterNet)在性能瓶颈上的不同需求, 优化融合模式。例如, 在本实验中, 基于 K 分布的乘性融合模式对 YOLO V7 的 AP 和准确率均带来显著改善, 证明了该融合策略在捕捉 SAR 图像中乘性噪声细微变化方面的有效性。总结来说, 将 CRSA 与杂波统计模型相结合, 是一种改进 SAR 目标检测系统的有效策略, 为 SAR 图像处理的广泛挑战提供了可扩展和适应性的解决方案。

4.4.6 损失下降情况说明

图4.15所示的损失比较表明, 将 CRSA 结合到 YOLO V7 中, 在两个不同的数据集(即 SSDD 和 HRSID)上的训练和验证损失都得到了更快和更大幅度的降低。这表明 CRSA 显著加快了收敛过程, 对于提高模型训练效率至关重要。CRSA 的引入使得训练过程中噪声对梯度更新的干扰大幅降低, 模型能够更快地捕捉到图像中真实的特征信息, 进而加速收敛。CRSA 模型的快速收敛得益于其通过增强真实 SAR 数据有效地处理杂波, 提高了模型的泛化能力。此外, 验证损失的减少, 特别是在 HRSID 数据集上, 表明 CRSA 在防止过拟合方面特别有效, 过拟合是 SAR 图像检测任务中常见的挑战, 因为带标签的训练数据复杂且往往有限。SAR 图像检测任务中, 由于带标签的训练数据通常复杂且数量有限, 模型极易陷入对特定数据特性的记忆, 即过拟合。CRSA 通过合并统计杂波模型, 模拟出更为广泛的环境条件, 使得训练数据在噪声层面上具有更高的多样性和代表性。部署 CRSA 使检测模型在训练过程中不仅仅依赖于训练集固有的噪声特性, 而是学习到更为稳健和普适的特征。在面对新数据时, 模型能够凭借对真实信号的准确识别, 表现出更高的鲁棒性。

在 SSDD 数据集上, 虽然数据量较小, 但 CRSA 依然能够有效抑制噪声干扰, 加速模型学习真实目标特征。在 HRSID 数据集中, 其对复杂背景和多变环境条件的适

应能力更为明显，验证损失的大幅下降充分说明了 CRSA 在多样化数据环境下的普适性。重要的是，这些改进在较小的 SSDD 数据集和更大、更多样化的 HRSID 数据集上都是一致的，进一步增强了本文对 CRSA 的鲁棒性和可扩展性的信心。这种跨数据集的一致性不仅证明了 CRSA 的鲁棒性，同时也展示了其良好的扩展性。




图 4.15 YOLO V7 模型部署、不部署 CRSA 在不同数据集上损失下降情况

4.4.7 实验小结

结合表4.2、表4.3、表4.4以及表4.5中的实验数据，可以看出，无论是在 SSDD 数据集还是在 HRSID 数据集上，将 CRSA 集成到不同检测模型（如 Faster R-CNN、RetinaNet、CenterNet、YOLO V4 和 YOLO V7）中均显著提升了各项指标的性能。在融合真实杂波的实验中，各模型在引入 CRSA 后均实现了平均精度（AP）、Precision 和 Recall 的提升，其中部分方法（例如 Faster R-CNN 结合 MF 变体）在 SSDD 上 AP 的提升甚至超过了 5 个百分点，而在 HRSID 上 YOLO V7 与 CenterNet 也表现出约 2% 至 3% 的增幅，这表明 CRSA 能够有效增强模型对真实 SAR 数据中杂波的抑制能力，从而加速收敛并提升泛化性能。与此同时，在融合仿真杂波的实验中，通过采用 Gaussian、K 和 Gamma 分布模拟杂波，各检测器均呈现出一致的性能改进趋势：Faster R-CNN、RetinaNet 和 CenterNet 在不同分布条件下均实现了 AP 的稳定提升，

其中部分变体（如 MF 和 ST）在 K 或 Gamma 分布下的表现尤为突出；而在 HRSID 数据集上，YOLO V7 与 CenterNet 在仿真杂波环境中也获得了明显的检测性能改进。总体而言，无论数据集规模如何，CRSA 均展现出高度的鲁棒性和通用性。在标注数据有限的情形下，通过引入 CRSA 显著提高了训练数据的多样性和随机性，同时增加了训练样本中复杂场景的比例，从而为模型提供了更加丰富的特征表达机会。CRSA 在各检测模型中均实现了检测精度的显著提升，并有效防止了因训练数据稀缺与复杂而引发的过拟合问题。这些实验结果为 CRSA 在 SAR 图像检测任务中的应用提供了坚实的依据，并证明了在有限标注数据条件下，通过数据增强能够大幅改善模型，且不增加模型计算复杂度，属于“无痛”涨点。

4.5 本章小结

本章针对由于标注样本有限、海面杂波与噪声引起的 SAR 舰船检测困难问题，提出了一种杂波随机采样迁移的 SAR 数据增强技术。该方法融合了统计模型生成的模拟杂波（包括瑞利、威布尔、伽马、对数正态和 K 分布）与真实杂波，采用加性融合、乘性融合和目标保护三种策略，以随机方式动态扩充训练数据集的样本多样性和随机性。这样不仅有效缓解了标注样本不足的问题，而且在不增加推理成本的前提下，显著提升了检测器对复杂干扰环境下目标的鲁棒性和泛化能力。实验结果在多个数据集（SSDD、HRSID）以及多种检测网络上均表明，CRSA 在提高平均精度、准确率和召回率方面均优于传统的数据增强和去斑方法，同时还能加速模型收敛，充分验证了其在实际复杂海况下的应用优势。

第五章 SAR 图像背景移除辅助的目标检测方法

在实际应用中,近岸合成孔径雷达图像因其独特的成像机制及海洋环境的复杂性,常常表现出杂波干扰强烈、海面动态变化剧烈以及目标反射信号微弱等显著特点,这使得舰船目标检测面临极大的技术挑战。传统的目标检测方法在处理这种复杂背景时,往往难以在有效去除背景干扰的同时兼顾目标细节与电磁特性,导致检测精度和鲁棒性均不尽如人意。为了解决这一难题,本章提出了一种全新的背景移除辅助的 SAR 舰船检测网络 (Background Removal Aided SAR Ship Detection Network, SAR-BRADet), SAR 图像背景移除辅助的舰船检测方法通过将背景移除网络 (Background Removal Network, BRNet) 与检测网络有机结合,构建了统一的端到端检测框架。

具体而言, BRNet 模块采用了多尺度特征提取和自适应噪声抑制策略,旨在有效滤除杂波与噪声,同时保留舰船目标的重要结构信息和电磁特性;其输出特征直接作为检测网络的输入,从而使后续的目标定位与识别工作得以在更为纯净的特征空间中进行。此外,为了进一步增强背景移除与目标检测任务之间的协同效应,本章创新性地引入了检测辅助一致性损失 (Detection-assisted Consistency Loss, DACL),利用检测网络的输出对背景移除模块进行有效引导,进而提升整体网络在复杂背景下的检测性能。SAR-BRADet 采用模块化设计,不仅便于实现不同检测网络之间的无缝切换和灵活扩展,而且为后续针对多种复杂场景的深入研究提供了坚实的技术基础。实验结果显示,在复杂近岸 SAR 场景下, SAR 图像背景移除辅助的舰船检测方法在平均精度上较传统方法提升了 11.06%,充分证明了 SAR-BRADet 在提高检测准确率和鲁棒性方面的显著优势。

5.1 引言

第三章提出了基于模型预测与先验信息引导的标签分配策略,并构建了专门用于 SAR 舰船检测的多尺度检测网络,旨在缓解训练与测试目标间的不一致性以及正负样本划分不合理的问题。然而,由于训练数据标注数量有限、背景复杂性不足以及海况场景多样性欠缺,模型在真实海洋环境中对复杂杂波和噪声干扰的鲁棒性仍显不足;同时,单纯依赖数据增强和多尺度融合虽然在一定程度上提高了检测性能,但对电磁散射特性和目标细节信息的提取仍存在局限,难以在极端复杂背景下同时兼顾目标的细节与全局语义。第四章针对这一问题,提出了一种杂波数据增强的舰船检测算法,通过融合统计建模生成的仿真杂波与真实杂波数据,构建了更加多样和复杂的背景数据集,从而在不改变目标位置信息的前提下丰富了训练样本,并有效缓解了

过拟合问题。但这种方法在一定程度上虽然增加了数据多样性,却依然未能充分解决近岸 SAR 图像中杂波干扰强、海面动态变化剧烈以及目标反射信号微弱等根本性问题,其背景干扰的消除与目标细节的保护之间存在矛盾,导致整体检测性能在极端场景下仍有所欠缺。

因此,为了应对实际应用中近岸 SAR 图像所表现出的杂波干扰严重、目标细节信息稀缺等问题,本章提出了一种全新的背景移除辅助的 SAR 舰船检测方法。该方法通过构建深度背景移除网络,在保留目标关键电磁散射特性的前提下,实现对海面杂波及岸线干扰的高效抑制,并利用检测辅助一致性损失确保背景去除过程中目标信息的完整传递。通过将背景移除与目标检测进行联合训练,形成端到端的协同优化机制,从而进一步提高了复杂海上场景中舰船目标检测的精度与鲁棒性,为解决传统检测方法在极端环境下的检测难题提供了新的解决方案。

5.1.1 问题描述

由于 SAR 图像固有的复杂特性,尤其是在近岸环境中,杂波、噪声和背景干扰问题显著降低了图像的信噪比和细节表现^[155]。在此现象下,舰船检测任务面临着严峻的挑战,其根本原因在于背景的复杂性和异质性。这些复杂背景主要由水面粗糙度、海浪随机性、地物反射以及复杂的后向散射机制共同作用引起^[156]。因此,目标信号常常被背景干扰所掩盖,导致基于深度学习的检测算法难以准确区分舰船目标与周围环境^[157]。在近岸 SAR 场景中,因靠近陆地以及频繁的海上活动,使得背景干扰进一步加剧,检测精度明显下降,如图 5.1 所示^[158]。这种持续存在的杂波和背景噪声不仅使得目标与背景之间的边界模糊,而且极大地阻碍了有效目标提取,是当前复杂海岸环境下舰船检测的主要技术瓶颈。




图 5.1 MSDNet 的近岸场景中检测失败案例

针对上述问题,背景信息包括杂波和噪声的抑制已成为提高 SAR 图像检测性能的首选解决方案^[159]。尽管近年来基于深度学习的目标检测网络在架构优化和特征提取方面取得了显著进展,但多数现有方法主要集中于优化检测网络本身,而对背景

信息干扰问题重视不足。已有的预处理背景去除方法通常将抑制和检测任务割裂开来,未能形成有效的联动机制,这种分离式处理方法容易在杂波去除过程中损失目标特征,进而影响整体检测鲁棒性^[160]。此外,传统方法在面对多变的海上环境和异构背景干扰时,常常缺乏自适应性,无法动态增强舰船目标的清晰度和识别性,从而限制了模型在实际应用中的推广和性能发挥。在此背景下,为了克服复杂背景干扰对 SAR 舰船检测的严重影响,本章将重点研究一种基于背景移除辅助的联合检测方法。该方法旨在通过构建背景移除模块与目标检测模块的端到端联合训练框架,实现杂波和噪声的自适应抑制与目标特征的有效保留。具体而言,本章方法在网络设计上引入了背景移除模块和检测辅助一致性损失,并在不同尺度上对目标进行细粒度描述,从而在背景移除过程中确保目标信息不被破坏。本章方法不仅能够有效提高复杂近岸环境下舰船目标的检测准确率,还能显著增强模型对环境干扰的鲁棒性。




图 5.2 本章提出方法 SAR-BRADet 示意图

针对近岸杂波给检测任务带来的局限性,本章提出了一种背景移除辅助的 SAR 近岸舰船检测网络 (SAR-BRADet) 框架。该框架集成了一个专用的 SAR 背景移除网络 (BRNet) 和一个检测网络,如图 5.2 所示。具体而言, BRNet 模块采用先进的卷积神经网络结构,能够在有效抑制杂波和斑点噪声的同时,精准保留舰船的基本特征和电磁散射特性,从而在降低背景干扰的前提下,显著提升了 SAR 图像的视觉质量与目标表达能力。

与传统方法相比, SAR-BRADet 框架采用了解耦设计,使得杂波抑制和检测网络可以独立运行,各自针对特定任务进行优化。传统的端到端检测方法往往在共享特征的过程中因信息混合而导致性能下降,而本方法通过解耦处理,既避免了干扰信息的累积,又保证了每个子网络能够发挥其最佳功能^[161]。这一设计思路有效解决了复杂海岸环境下,由于杂波特性异构和噪声干扰引发的检测难题。

此外,本框架的另一关键创新在于引入了检测辅助一致性损失。DACL 利用检测网络的预测结果,包括置信度分数和边界框位置,动态地指导杂波抑制过程。这一协作机制在模型训练过程中实现了杂波抑制与检测之间的互补优化,确保抑制后的输

出不仅在视觉上更为清晰,同时与实际检测目标高度一致。通过这一机制,DAFL 不仅提高了特征学习效率,而且有效减少了过拟合风险,进一步提升了模型在不同环境条件下的鲁棒性^[162]。

5.1.2 相关方法简介

近年来,近岸环境下 SAR 舰船检测的研究日益聚焦于克服异质杂波、动态背景以及低对比度目标带来的严峻挑战。在这一领域中,研究者们提出了多种方法,通过引入注意力机制、多模态融合、金字塔特征结构和样本均衡策略等手段,实现了对复杂背景干扰的有效抑制,并在一定程度上提高了目标检测的精度和鲁棒性。

郭等人提出的双向注意力特征金字塔网络 (BAFPN)^[163],通过引入双向注意力机制,在多尺度特征融合过程中对关键特征进行精细增强,有效降低了由复杂岸线和海面杂波引起的干扰。该方法不仅提升了目标的可辨识性,也为后续基于深度学习的特征提取提供了重要的技术支持,其核心思想在于利用双向信息交互来更好地捕捉目标与背景之间的细微差异。陈等人提出的多模态显著性增强方法^[164]则将显著性增强技术与传统的 CFAR 程序相结合,针对高噪声背景下目标信号难以突出的问题,采用多模态信息融合的方式强化了背景噪声的鲁棒性。该方法通过多角度、多尺度的数据融合,有效地抑制了环境噪声对目标检测的负面影响,进而提高了检测精度,为 SAR 图像中低对比度目标的识别提供了新的解决思路。程等人提出的各向异性金字塔差分与 Bhattacharyya-like Distance 的结合方法^[165],从统计距离和金字塔结构的角度出发,通过显著性增强策略降低了大尺度 SAR 图像中背景杂波的干扰。这种方法充分利用了目标与背景在不同尺度下的统计特性差异,为在大范围、复杂场景下实现目标检测提供了坚实的理论基础。

针对场景样本不平衡的问题,张等人提出了平衡场景学习机制^[165]。该机制通过引入样本均衡策略,缓解了由于近海和近岸场景中样本分布不均所导致的检测偏差,从而提高了检测器对各类目标的响应能力。该方法不仅在数据预处理和模型训练阶段起到了关键作用,也为后续构建更具普适性的检测系统提供了有益启示。此外,戴等人提出的 DenoDet 方法^[166],利用基于注意力的可变形多子空间特征去噪技术,在保留显著目标信号的同时有效抑制了噪声。这一方法在深度特征去噪领域表现出色,显著增强了模型在高噪声环境下的鲁棒性,为解决 SAR 图像中目标信号与背景噪声混叠的问题提供了强有力的技术保障。

上述研究方法各具特色:有的侧重于通过注意力机制优化特征表达,有的致力于利用多模态信息融合实现目标与背景的精细区分,还有的专注于解决样本不平衡与噪声抑制问题。这些方法在理论上丰富了近岸 SAR 舰船检测的研究思路,在实验结论上也提供了重要参考。然而,现有方法在面对高度动态和异质背景时,仍存在部分

局限性，如目标特征提取不够精细、环境适应性不足等问题。当前多数方法主要聚焦于提高特征提取能力和显著性增强，通过引入注意力机制、多模态融合和金字塔特征结构等策略，有效提升了目标与背景之间的区分度。然而，这些方法往往忽略了一个至关重要的环节——背景移除，而本章研究发现背景移除正是提高检测性能的关键所在。

如图5.3(a)所示，基于统计模型的杂波抑制方法在处理杂波特性存在显著差异的场景时效果较差。这主要是因为近岸和近海环境中观测到的杂波，其直方图往往表现出复杂且不规则的分布，显著偏离了传统统计建模的假设，导致模型拟合效果不理想。此外，许多现有方法在设计上将杂波抑制与目标检测任务割裂开来，未能充分考虑两者之间的动态关系。这样一来，在复杂背景下，杂波抑制过程中可能会过度削弱目标特征或者未能彻底消除干扰，最终导致检测结果次优。




图 5.3 来自 HRSID 数据集的近岸场景分析

针对上述问题，本章提出的 SAR-BRADet 方法通过构建一个统一框架，创新性地将背景移除与目标检测任务进行端到端联合建模，并引入检测辅助一致性损失以增强两者之间的信息协同。具体而言，SAR-BRADet 中所设计的 BRNet 模块在有效抑制杂波和相干斑噪声的同时，能够充分保留舰船目标的结构和电磁特性，从而大幅提升 SAR 图像的视觉质量和目标特征的表达能力。图5.3(b)5.3(c)5.3(d)进一步验证了该联合方法在应对复杂干扰背景下的优越性能，证明了通过动态协同处理可以显著提高检测精度和鲁棒性。

综上所述，本章所提 SAR-BRADet 模块在有效抑制杂波和相干斑噪声的同时，能够精准保留目标的独特结构和散射特性，从而提升图像整体质量。通过专门设计的背景移除策略，SAR-BRADet 显著减少了背景干扰，增强了目标信号的对比度，特别是在复杂近岸环境下显著提高了检测精度。检测辅助一致性损失实现了背景移除与检测预测之间的紧密融合，确保了两者在端到端训练中的动态协同，从而改善了视觉质量和检测结果的一致性。

在本章的其余小节中，5.2 节详细阐述了背景移除辅助的舰船检测方法。本节介绍 BRNet 通过多尺度特征提取与自适应噪声抑制策略，精准滤除杂波与噪声，并将处理后的特征作为检测网络的输入，构建出一个针对 SAR 近岸舰船的检测框架；5.3

节通过一系列实验结果对所提方法进行了全面评估,包括实验设置细节、消融实验和对比实验、与传统杂波抑制方法进行了性能对比,突出展示了背景移除在提升检测精度与鲁棒性方面的优势。5.4 节对本章工作进行了总结,归纳了背景移除辅助方法在复杂近岸 SAR 场景下对舰船检测性能提升的关键贡献。

5.2 背景移除辅助的目标检测方法

5.2.1 背景移除网络的作用与设计

为有效应对近岸 SAR 图像中异质且杂乱的背景以及相干斑噪声对舰船检测带来的负面影响,本章提出了一种专为 SAR 图像设计的背景移除网络——BRNet。该网络在保持舰船目标基本结构和电磁散射特性的前提下,能够显著抑制背景中的杂波和噪声,同时通过缓解不同场景下样本分布的不平衡,进一步增强检测网络对舰船目标的关注,从而提高整体检测精度和鲁棒性。如图5.4所示,BRNet 基于经典 U-Net 架构进行构建,但在传统结构的基础上引入了多项改进,以适应 SAR 图像复杂的背景特性。DSP(Down-Sampling Process) 和 USP(Up-Sampling Process) 分别表示下采样和上采样阶段。BRNet 采用对称的下采样与上采样路径,通过多阶段特征提取实现全局上下文与局部细节的有效捕获。在下采样路径中,网络共分为五个阶段,每一阶段均利用最大池化进行降维,并通过包含连续 3×3 卷积、批量归一化以及 ReLU 激活函数的 DoubleConv 模块进行细致的特征提取。此过程不仅能够有效区分有意义的目标特征与噪声,还保证了近岸场景中舰船目标边界和形态的完整性,即使在高度异构的背景下也能实现鲁棒的特征学习。

为克服传统 U-Net 在处理复杂 SAR 图像时可能引入的不相关信息干扰,BRNet 引入了选择性跳跃连接机制。这种机制将下采样路径中经过精炼的底层特征有选择性地传递到上采样路径,有效防止了无关背景信息对目标特征的干扰。同时,通过将细粒度的空间细节与高层语义信息进行融合,上采样阶段利用转置卷积与 DoubleConv 模块相结合,逐步细化并恢复特征,确保空间分辨率和边缘锐度的有效恢复,从而实现目标的精准还原与噪声的鲁棒抑制。

BRNet 的另一个重要创新在于其多分辨率输出策略。在不同尺度上生成中间背景抑制结果,实现分层监督,从而为杂波抑制与噪声去除提供了多层次、全方位的指导。这种分层监督机制不仅提高了学习效率,而且确保了跨尺度特征的一致性,为网络在不同分辨率下均能捕捉到关键目标信息提供可能性。

针对复杂 SAR 场景中不同背景分布带来的样本不平衡问题,BRNet 通过设计专门的特征提取与融合策略,有效缓解了这种不平衡现象,从而在整体上增强了检测网络对舰船目标的关注度。该机制确保了在杂波大量存在的背景中,目标信息得以充分

保留,使得后续的目标检测任务能够在更为干净的特征空间中进行,显著提升了检测精度和模型鲁棒性。

BRNet 在继承传统 U-Net 网络结构优势的同时,通过引入多尺度特征提取、选择性跳跃连接、分层监督以及样本不平衡缓解等多项创新设计,实现了对复杂 SAR 图像中异质杂波和斑点噪声的有效抑制,并在保留舰船目标结构和电磁特性的基础上,显著提高了检测网络的整体性能。




图 5.4 背景移除网络具体结构图

5.2.2 SAR 近岸舰船检测框架

针对 SAR 舰船目标检测中普遍存在的异构背景、近岸干扰以及传统方法在任务分离上所面临的局限性,本章提出了一种基于联合优化的新型 SAR-BRADet 框架,该框架通过整合具有创新性的用于背景移除的 BRNet、模块化且交替运作的检测子网络以及全新提出的 DACL 损失函数,实现了背景移除与目标检测任务的深度耦合与协同优化。如图5.5所示,整体框架将 BRNet 与目标检测网络进行有机集成,并在训练过程中采用总损失函数的设计,其中总损失函数由背景移除损失、检测损失以及 DACL 组成,通过多任务协同约束实现模型参数的统一更新。具体来说, P_{GT} 与 P_{DR} 分别代表检测网络在输入经过杂波抑制处理后的真实标签与预测输出,而 DACL 机制则通过引入预测一致性作为监督信号,将背景移除任务与目标检测任务显式关联,从而强制二者在同一共享目标下进行协同优化。与传统上将杂波抑制与目标检测分别独立训练的策略不同,本方法利用二者内在的互补特性,通过 DACL 在网络训练过程中建立起任务间的约束关系,使得背景移除网络不仅能够有效滤除复杂背景干扰,同时其输出特征能够更直接地服务于目标检测模块,从而在提高舰船定位精度的同时大幅降低误检和漏检的可能性。此外, DACL 机制在实现不同子模块之间信息

共享的同时，有效缓解了由任务分离引起的局部最优问题，并在整体优化过程中起到了稳定网络收敛的关键作用。综合来看，该 SAR-BRADet 框架充分挖掘了杂波抑制与目标检测之间的内在联系，通过端到端的联合训练策略实现了多任务协同进化，为复杂海上及近岸环境下的目标检测问题提供了一种高效、鲁棒且具有较强推广能力的解决方案。




图 5.5 背景移除辅助的 SAR 近岸舰船检测框架图

5.2.3 训练策略

5.2.3.1 背景移除损失函数

本章提出的针对 BRNet 的复合损失函数在多尺度监督机制下综合了均方误差 (Mean Square Error, MSE) 损失与结构相似性 (Structural Similarity Index Measure, SSIM) 损失，旨在抑制复杂海上环境中的杂波和噪声，同时保留舰船目标的结构与电磁特性，从而显著提高目标检测的准确性。具体而言，该损失函数定义为

$$L_D = \sum_{i=1}^d \left[\lambda_i L_{mse}(\phi(x_i), x_i^G) + \beta_i L_{SSIM}(\phi(x_i), x_i^G) \right], \quad (5-1)$$

其中， x_i 和 $\phi(x_i)$ 分别表示在尺度 i 下 BRNet 的输入图像与经过网络处理后的输出图像， x_i^G 为对应尺度下的地面真实图像； $L_{mse}(\cdot)$ 用于量化输出图像与真实图像在像素级别上的均方误差，确保数值恢复的精度，而 $L_{SSIM}(\cdot)$ 则侧重于衡量两幅图像在结构、亮度和对比度等方面的相似性，以保证图像整体结构信息的完整性。参数 λ_i 和 β_i 则分别用于平衡不同尺度下 MSE 损失与 SSIM 损失的贡献， d 表示总的尺度数量，通过多尺度下进行监督，该方法不仅能够充分捕捉和利用图像中蕴含的细粒度信息，而且在不同分辨率下实现了对杂波和噪声的有效抑制。更为关键的是，在网络训练过程中，MSE 损失能够确保输出图像在数值上与真实图像保持高度一致，进而减少重构误差，而 SSIM 损失则着眼于图像全局结构的保留，避免因单一数值优化策略而导致的结构信息丢失问题。通过二者的有机结合，复合损失函数在优化过程中实现了对不同尺度特征的全面约束，从而使得模型在面对异构背景、近岸干扰等复杂条件时，既能有效剔除不相关信息，又能保留舰船目标的重要特征。此外，多尺度监

督机制使得网络能够在粗细不同的尺度上同步进行特征提取和重构,这种自底向上的信息融合策略不仅增强了模型对噪声和杂波的鲁棒性,同时也提高了目标检测模块对细微目标特征的敏感性和判别能力。总体来看,该复合损失函数在理论上兼顾了局部像素级误差与全局结构相似性之间的平衡,通过多尺度、多角度的综合监督,有效解决了传统单一损失函数在背景去除与目标特征保持之间存在的矛盾。

5.2.3.2 检测辅助一致性损失

为了弥合背景移除与目标检测任务之间长期存在的割裂问题,本节提出了一种全新的检测辅助一致性损失函数(DACL),旨在通过利用目标检测模块生成的多尺度预测结果,实现对背景移除输出与其对应真实标签之间的严格约束,从而确保背景移除过程能够直接促进后续检测任务的性能提升。具体而言,DACL将经过背景移除处理的真实标签输入(记作 DR_{GT})与背景移除网络的输出(记作 DR_{Det})分别送入目标检测网络,二者均产生包含分类置信度 C 与目标定位边界框 B 的预测结果。由于当前大多数目标检测网络采用多尺度预测头进行特征融合与信息传递,因此在第 i 个尺度下,DACL分别获得来自 DR_{GT} 和 DR_{Det} 的预测结果 C_{GT}^i 、 B_{GT}^i 以及 C_{Det}^i 、 B_{Det}^i 。为此,DACL通过最小化不同尺度下预测结果之间的差异,显式地将杂波抑制任务与目标检测任务的优化目标对齐,促使背景移除模块生成的输出在分类与定位方面均能为检测任务提供最优特征表示。

在此框架下,DACL的损失函数被定义为

$$L_{DACL} = \frac{1}{N} \sum_{i=1}^N \left[L_G(C_{Det}^i, C_{GT}^i) + L_G(B_{Det}^i, B_{GT}^i) \right], \quad (5-2)$$

其中, N 表示多尺度预测头的总数;对于第 i 个尺度, C_{GT}^i 与 B_{GT}^i 分别为由背景移除真实标签输入得到的分类置信度和定位边界框预测, C_{Det}^i 与 B_{Det}^i 则为对应于背景移除输出输入时的预测结果;而 $L_G(\cdot, \cdot)$ 为通用损失函数,其具体形式可根据实验需求进行灵活设定,本章中采用SmoothL1损失函数以兼顾回归任务中误差的平滑性与稳定性。

DACL充分考虑了背景移除与目标检测两项任务之间固有的内在联系。首先,通过对各尺度下分类置信度的约束,DACL确保了由背景移除输出生成的预测在置信度上与真实标签高度一致,从而提高了目标检测模块对舰船目标的识别准确率;其次,通过对定位边界框的约束,DACL保证了目标在空间位置上的准确捕捉,避免了因尺度不一致导致的定位偏差。多尺度监督策略使得网络能够在不同分辨率下同时获得全局与局部信息,实现了从粗到细的层次化特征融合,这不仅增强了模型对复杂海上环境中细微目标的敏感性,同时也大大提升了模型对近岸干扰和背景噪声的鲁棒性。

综上所述,DACL损失函数通过引入基于目标检测预测一致性的双向约束,有效

桥接了背景移除与目标检测之间的断层，使得二者在联合训练过程中形成了紧密耦合的闭环优化体系，从而显著缓解了传统方法中因任务分离所引发的信息流失和误差累积问题。

5.2.3.3 实现细节

本章提出的 SAR-BRADet 框架通过融合检测子网络与 BRNet，有效实现了背景移除与目标检测任务的协同优化。检测子网络从 BRNet 的输出中提取精细化的目标特征，从而在复杂背景下实现对 SAR 图像中目标的精确定位与分类。整个 SAR-BRADet 框架的总损失函数由检测损失、背景移除损失和检测辅助一致性约束损失 (DACL) 构成，这种多任务联合优化策略不仅能够显著降低复杂近岸环境中存在的杂波与噪声干扰，同时确保了检测精度的高水平实现，切实解决了传统方法在信息解耦与误差累积方面存在的不足。

在具体实现过程中，检测子网络首先利用一系列卷积层、归一化层和非线性激活函数对 BRNet 经过预处理后的去背景图像进行提取与融合，进而生成高质量的目标特征表示。该过程保证了目标在不同尺度上的细粒度信息均得到充分保留，并为后续的精确定位与分类提供了坚实的基础。与此同时，检测子网络的设计充分考虑了模块化与可移植性的要求，使其不仅能够独立执行目标检测任务，还可以无缝集成到各类主流检测框架中，如 Faster R-CNN、YOLO 以及 CenterNet 等。这种模块化设计理念极大地增强了 SAR-BRADet 框架的适应性与灵活性，能够充分利用目标检测领域持续不断的技术进步，确保系统在未来应用中的长期可扩展性和鲁棒性。

综上所述，本章提出的 SAR-BRADet 框架通过模块化设计与多任务联合优化实现了对 SAR 图像中目标的高精度检测。其检测子网络的高度可移植性使得该框架可以方便地迁移到不同目标检测算法中，充分利用各检测模型的优势，同时适应不断演进的技术需求。




图 5.6 背景移除标签获取过程

5.3 实验结果分析

5.3.1 实验设置细节

在本章研究中,为了实现高精度的背景移除并确保目标信息的完整保留,本章采用了基于分割标签作为背景移除方法的 GT。具体而言,背景移除的地面真实标签是通过对原始 SAR 图像进行精细分割获得的分割标注生成的。利用这种方法,不仅能够在像素级别上完整保留图像中目标的所有细节信息,而且能够将背景中无关的噪声和干扰区域完全去除,从而为后续目标检测和特征提取提供纯净、可靠的输入数据。如图5.6所示,分割标注在准确定位目标边界的同时,实现了目标与背景的明确分离,这对于提高检测模块的鲁棒性与精度具有重要意义。

在数据集构建方面,本章重点关注近岸场景的数据特性,所选用的近岸数据集由两个常用的 SAR 数据集构成,即 SSDD 和 HRSID。其中,SSDD 数据集中总计包含 1160 张图像,其中经过严格筛选获得了 228 张符合近岸场景标准的图像;而在 HRSID 数据集中,从总计 5604 张图像中筛选出 1031 张近岸场景图像。这样的数据构成充分反映了实际应用中近岸区域复杂多变的背景特性,同时也为所提方法在困难环境下的适用性和泛化能力提供了验证数据。




图 5.7 杂波抑制方法和本章背景抑制结果可视化

5.3.2 与杂波抑制方法的性能对比

在本节中，为深入探讨先进杂波抑制方法与所本章提背景移除联合检测端到端框架之间的性能差异。本节通过展示实验结果，以验证各方法在复杂近岸场景下的实际应用效果。本节选取了三种具有代表性的杂波抑制方法作为对比对象，分别是 NSS-RPCA^[167]、Adaptive Wiener Filter^[168] 以及 SAR-BM3D^[169]。上述三种方法进行杂波抑制的原理都有所区别。NSS-RPCA 采用了非局部自相似性与鲁棒主成分分析相结合的策略，通过捕捉图像内部冗余信息并进行主成分分解，有效分离目标与杂波；为进一步提升输出图像质量，本节在后处理阶段引入了自适应直方图均衡、伽马校正及形态学开运算等技术。自适应维纳滤波器（Adaptive Wiener Filter, AWF）则利用扩展自适应维纳滤波器与扩展引导滤波器的组合，通过对噪声统计特性进行建模，既能够有效抑制斑点噪声，又能在一定程度上保持图像结构细节的完整性。SAR-BM3D 是对传统 BM3D 算法的改进，针对 SAR 图像的特殊性进行了优化调整，实现了竞争性的杂波抑制效果。上述方法与本章背景抑制结果可视化如图5.7所示。

表 5.1 杂波抑制方法与所提方法在 SSDD 性能对比

方法	平均准确率 (%)	准确率 (%)	召回率 (%)
YOLO V5l	91.64	73.80	93.51
NSS-RPCA	91.49	68.04	94.27
Adaptive Wiener Filter	93.21	70.62	95.42
SAR-BM3D	91.91	71.93	93.89
Ours	96.11	81.85	98.09
YOLO V7	92.47	75.45	95.04
NSS-RPCA	89.78	74.15	91.98
Adaptive Wiener Filter	92.59	73.37	94.66
SAR-BM3D	92.82	78.80	95.04
Ours	96.24	92.73	97.33

为了全面评估上述杂波抑制方法在目标检测任务中的实际表现，本节将这三种方法处理后的结果分别作为 YOLO v5l 和 YOLO v7 网络的训练与测试数据，并对比了各方法在 AP、Precision 与 Recall 等指标上的表现，相关实验结果详见表5.1。从表中数据可以看出，无论是在 YOLO v5l 还是 YOLO v7 框架下，单独使用上述传统杂波抑制方法均无法充分兼顾杂波抑制与目标特征的保留，其检测性能存在一定局限。例如，在 YOLO v5l 框架下，AWF 虽然在 AP 和 Recall 上取得了相对较高的数值，但 Precision 的表现却未能达到理想水平；而在 YOLO v7 框架下，各方法在检测指标上表现较为接近，但仍然低于本章所提方法的综合性能。

本章提出的背景移除联合检测端到端框架通过将杂波抑制与目标检测任务进行联合优化，充分利用检测任务提供的监督信号来引导杂波抑制模块生成更适合检测

的特征表达,从而显著提升了目标检测的整体性能。具体而言,本章方法在 YOLO v5l 框架下实现了 96.11% 的 AP、81.85% 的 Precision 以及 98.09% 的 Recall,在 YOLO v7 框架下分别取得了 96.24% 的 AP、92.73% 的 Precision 和 97.33% 的 Recall,均明显优于杂波抑制与检测任务分离设计的实验结果。实验结果充分证明,背景移除联合检测端到端框架不仅能够有效抑制复杂近岸环境中的杂波和噪声,同时通过检测模块的反馈优化,使得目标特征得以更完整地保留,从而在目标定位和分类任务中展现出更高的鲁棒性和准确性。

5.3.3 与海陆分割方法的性能对比

为了进一步验证本章所提出的 SAR 图像背景移除辅助舰船检测方法在近岸场景的有效性,本节设计了一组对比实验,将其与典型的海陆分割预处理策略进行性能比较。海陆分割是 SAR 图像预处理中常见的一种背景简化手段,主要通过区分陆地与水体区域,试图剔除与目标检测无关的背景干扰,从而提升检测的准确性。然而,此类方法通常依赖于图像灰度统计特征,难以适应近岸复杂背景中的多尺度杂波和非结构化噪声,对舰船目标尤其是近岸贴边、小尺寸目标的提取效果存在局限。本节采用的海陆分割方法基于经典的 Otsu 自动阈值分割策略^[170],结合高斯模糊预处理与小区域过滤机制,实现了对 SAR 图像中陆地与水体的粗略分离。该方法的核心流程包括:首先对灰度图像进行高斯模糊以抑制噪声波动,其次通过 Otsu 自适应阈值法进行二值化分割,随后利用轮廓检测与面积阈值筛选策略去除小面积区域,最终得到保留主干区域的二值掩码图像。海陆分割结果与其对应原始 SAR 图片如图 5.8 所示。




图 5.8 海陆分割结果、对应原始 SAR 图像与背景过滤图片实例

为确保对比的公平性,本实验将海陆分割后的掩码图用于背景过滤处理,并将处理后的图像输入相同参数的目标检测网络进行训练与测试。实验对比包括 YOLO V5 和 YOLO V7 两个基线模型,实验结果如表 5.2 所示,数据集是全部 SSDD 数据集。引入海陆分割背景过滤后,AP 提升至 92.39%,说明通过抑制陆地杂波背景,模型能够更专注于海域目标的判别,召回率提升至 95.42%,但准确率仅有微弱提升(+0.16%)。本章所提出的方法在 YOLO V5 框架下进一步提升了各项指标,AP 达到 96.11%,比海陆分割提升了 3.72%,表明本方法不仅有效减少了背景干扰,同时保留了更多有价值的目标特征,提高了检测的准确性与完整性。在 YOLO V7 架构下,本章方法的性能表现更加突出,AP 达到 96.24%,较海陆分割方法提升 2.72%,充分说明本方法具有更强的特征提取能力和目标判别能力。虽然传统海陆分割背景过滤技术能够在一定程度上缓解陆地杂波对检测性能的干扰,但其对真实 SAR 图像中的复杂背景、目标边缘模糊等问题的适应性有限,因此性能提升不显著。相比之下,本章方法通过联合背景移除与目标检测,实现了从训练阶段即对背景和目标特征进行显式建模和区分,具有更强的场景适应能力与目标表示能力,从而在两个不同的检测架构下均获得了显著性能提升。

表 5.2 本章方法与海陆分割方法对比结果

方法	平均准确率 (%)	准确率 (%)	召回率 (%)
YOLO V5l	91.64	73.80	93.51
海陆分割	92.39	73.96	95.42
本章方法	96.11	81.85	98.09
YOLO V7	92.47	75.45	95.04
海陆分割	93.52	77.88	95.02
本章方法	96.24	92.73	97.33

5.3.4 消融实验

为深入探讨所提出的 SAR-BRADet 框架中各模块对整体性能提升的作用,本节通过消融实验对比分析了不同组件对近岸舰船检测精度的影响。实验基于 SSDD 近岸数据集进行,主要评估指标为 AP (平均精度)、Precision (精确率) 和 Recall (召回率)。表 5.3 展示了在不同模块组合下 YOLO V5l 和 YOLO V7 的检测性能,其中包括原始检测网络、引入 BRNet 后的结果以及进一步引入双向一致性约束机制 (DACL) 的联合优化结果。

从表 5.3 中数据可以看出,原始 YOLO V5l 在 SSDD 数据集上的 AP 为 65.39%,而引入 BRNet 模块后,AP 显著提升至 70.74%,增加幅度达 5.35%。这一结果充分验证了背景移除在近岸复杂环境中对改善检测精度的重要作用,其基本原理在于通过有效去除背景噪声与杂波,使得目标特征更加突出,从而为后续的检测模块提供了更

为纯净的输入信号。同样地，原始 YOLO V7 的 AP 为 69.64%，引入 BRNet 后提升至 79.21%，增幅达到 9.57%，进一步证明了在不同检测框架中，背景移除模块均能显著增强目标识别性能。

在此基础上，进一步引入 DACL 模块后，YOLO V5l 的 AP 从 70.74% 增加到 74.22%，提高了 3.48%，而 YOLO V7 的 AP 则由 79.21% 进一步提升至 80.70%，增加 1.49%。这一实验现象揭示了 DACL 在端到端联合优化过程中的关键作用：通过利用检测网络的预测反馈，DACL 能够对背景移除输出进行自适应调整，进一步优化检测结果。该机制使得检测任务与背景移除任务实现了深度耦合，从而在维持目标结构信息的同时，提升了模型对细粒度特征的捕捉能力，进而提高了整体检测系统的准确性和鲁棒性。

综合实验结果表明，SAR-BRADet 框架在保留原有检测网络优良性能的基础上，通过集成 BRNet 和 DACL 模块，不仅在 AP 指标上取得了显著提升，同时在 Precision 与 Recall 两项指标上也展现了更高的数值。这表明该框架不仅能有效降低因背景杂波引起的误检问题，同时也大幅提升了对目标的捕捉率，证明了联合优化策略在实际应用中的优越性。

表 5.3 SAR-BRADet 在 SSDD 近岸数据集上的消融实验结果

方法	平均准确率 (%)	准确率 (%)	召回率 (%)
YOLO V5l	65.39	63.39	71.17
+ BRNet	70.74	68.68	76.69
+ DACL	74.22	70.43	80.37
YOLO V7	69.64	68.13	76.07
+ BRNet	79.21	74.05	84.05
+ DACL	80.70	79.07	83.44

为了验证所提出的 SAR-BRADet 框架在不同 SAR 数据集下的适用性和鲁棒性，本节在 HRSID 近岸数据集上开展了消融实验。表5.4 给出了在 YOLO V5l 和 YOLO V7 两种检测网络上，不同模块对检测性能的影响。实验结果表明，通过引入 BRNet 模块，检测网络在 AP 指标上分别提高了 8.46%（从 61.41% 提升至 69.87%）和 5.46%（从 70.44% 提升至 75.90%）；进一步添加 DACL 模块后，YOLO V5l 和 YOLO V7 的 AP 又分别提升了 1.63% 和 2.36%，最终分别达到了 71.50% 和 78.26%。同时，Precision 与 Recall 也均有所改善，这充分验证了 SAR-BRADet 框架在提升目标检测性能方面的显著优势。

从原理上讲，BRNet 模块主要通过有效的背景移除，降低了背景干扰对目标检测的负面影响。BRNet 利用多尺度特征提取与深度学习模型相结合的方法，从复杂的海上和近岸背景中提取出更加纯净和具有判别性的目标特征，从而使得后续检测模块

能够获得更高质量的输入数据。实验数据表明,单独加入 BRNet 后,无论在 YOLO V5l 还是 YOLO V7 框架中,AP 都有了显著提升,这表明背景移除在复杂环境下对于提高检测精度起到了至关重要的作用。

DACL 模块进一步通过联合优化策略,将检测任务与杂波抑制任务紧密耦合。DACL 利用检测网络的反馈信息作为监督信号,对杂波抑制模块的输出进行自适应调整,进一步减少背景噪声对检测结果的干扰。表中数据显示,添加 DACL 后,YOLO V5l 和 YOLO V7 的 AP 分别提升了 1.63% 和 2.36%,同时 Precision 与 Recall 也均有所改善。这一结果证明,DACL 能够有效地消除残留的背景干扰,并对目标的定位和分类产生积极影响,从而进一步提升了整体检测系统的性能。

实验结果还显示出 SAR-BRADet 框架在应对不同 SAR 数据集特性方面的普适性。尽管 HRSID 数据集的场景复杂性和图像质量与其他数据集存在一定差异,但 SAR-BRADet 仍能在这种多变环境下保持较高的检测精度,这充分验证了该框架的鲁棒性和适应性。总体而言,SAR-BRADet 通过集成 BRNet 和 DACL 模块,实现了背景移除与目标检测任务的深度融合,使得检测网络能够在复杂的近岸环境中获得更为可靠和稳定的检测结果。

表 5.4 SAR-BRADet 在 HRSID 近岸数据集上的消融实验结果

方法	平均准确率 (%)	准确率 (%)	召回率 (%)
YOLO V5l	61.41	63.45	68.03
+ BRNet	69.87	65.29	75.96
+ DACL	71.50	65.71	77.40
YOLO V7	70.44	56.16	78.37
+ BRNet	75.90	64.11	81.37
+ DACL	78.26	65.27	82.21

5.3.5 对比实验

表5.5 展示了在 SSDD 数据集上,所提出的 SAR-BRADet 方法与多种经典目标检测模型的性能比较结果。通过对比 Faster R-CNN、MSDNet、R-YOLO^[171] 以及其他主流检测方法(如 YOLO v5m、CenterNet、YOLO V4、YOLO V5l 和 YOLO V7) 的检测指标,可以明显看出 SAR-BRADet 在 AP、Precision 和 Recall 等关键指标上均取得了显著提升。这些实验数据充分证明了 SAR-BRADet 框架在复杂海上和近岸环境中具有较高的检测精度与鲁棒性,其优势主要源自于两大核心模块——BRNet 与 DACL 的协同作用。

BRNet 模块通过多尺度特征提取和深度背景移除策略,有效降低了原始 SAR 图像中的噪声干扰和背景杂波。具体而言,该模块能够在图像预处理阶段实现对噪声的明显抑制,从而为后续的目标检测提供更为纯净的特征输入。实验结果中,原始检

测模型在无杂波抑制条件下的性能较低，而引入 BRNet 后，检测精度均有大幅提升，如 YOLO V5l 提高了 4.47%。DACL 模块通过利用检测网络输出的反馈信号，对背景移除结果进行自适应调整，进一步减少了因背景干扰导致的误检和漏检问题。表中数据显示，结合 DACL 后，各检测模型在 AP、Precision 和 Recall 上均获得了额外的性能提升，尤其是在 YOLO V7 框架下，AP 增加了 3.77%，这表明 DACL 能够有效地强化目标与背景之间的区分能力，提升整体检测的准确率和稳定性。从表中数据还可以看出，不同检测模型经过 SAR-BRADet 框架优化后，均能获得较高的检测性能。例如，基于 YOLO V5l 的 SAR-BRADet 模型取得了 96.11% 的 AP，而基于 YOLO V7 的 SAR-BRADet 模型则达到 96.24% 的 AP。这些结果不仅表明 SAR-BRADet 能够在不同检测架构中发挥稳定的效果，还体现了其较强的模块化和可移植性，为未来在更多检测系统中的应用提供了有力保障。

表 5.5 不同检测模型在 SSDD 数据集上的性能对比

方法	平均准确率 (%)	准确率 (%)	召回率 (%)
Faster R-CNN	74.15	65.64	81.68
YOLO V5m	91.66	72.92	93.51
MSDNet	89.41	76.43	90.54
MSDNet + PPIG	94.05	83.44	95.05
R-YOLO	94.20	95.00	96.70
CenterNet	77.06	70.74	91.98
YOLO V4	86.05	72.87	91.22
YOLO V5l	91.64	73.80	93.51
YOLO V7	92.47	75.45	95.04
SAR-BRADet (CenterNet)	80.32	81.63	93.89
SAR-BRADet (YOLO V4)	90.33	78.46	93.13
SAR-BRADet (YOLO V5l)	96.11	81.85	98.09
SAR-BRADet (YOLO V7)	96.24	92.73	97.33

图5.9中展示了原始 SAR 图像、背景移除后的图像以及对应的背景移除 GT 图像。从第一列和第四列的结果可以看出，BRNet 在明显降低噪声干扰方面表现突出；第二列和第五列则展示了网络在移除近岸背景杂波方面的有效性，显著提升了图像的清晰度；而第三列所示的极其复杂场景中仍存在部分残留杂波，提示在极端复杂环境下仍需进一步改进。

近岸场景是 SAR 舰船检测任务中的典型难点，岸线结构复杂，背景杂波与目标特征高度相似，容易引发误检。近岸环境中存在大量散射增强区域，干扰目标边界提取。目标与港口或陆地之间距离近，易出现粘连或遮挡，影响目标分离和识别。图 5.10 展示了本章方法 SAR-BRADet(YOLO V7) 在近岸场景下的典型检测结果，展示图片均来自 SSDD 数据集。预测结果中的数字表示模型预测的置信度。从可视化结

果可以看出,本章方法在近岸复杂背景中仍能稳定准确地检测出目标,检测结果与真实标注高度一致,验证了该方法在近岸复杂场景下的鲁棒性和实用性。




图 5.9 比较原始 SAR 图片、背景移除结果与背景移除 GT

5.4 本章小结

本章提出了一种名为 SAR-BRADet 的创新多任务框架,该框架通过集成背景移除与舰船检测技术,针对复杂 SAR 环境中存在的噪声、杂波干扰以及目标分辨率低等问题,提供了一种高效且鲁棒的解决方案。SAR-BRADet 采用联合训练策略,实现了背景移除子网络与检测子网络之间的深度融合,使得两者在共享特征信息的同时,相互促进,从而显著提高了整体检测精度与系统稳定性。通过联合优化,不仅有效缓解了过拟合问题,而且在复杂海况和近岸环境中均表现出优异的检测性能。

本章进一步引入了检测辅助一致性约束机制 (DACL),该模块能够自适应地调整不同子网络之间的特征分布,有效降低背景杂波对检测结果的干扰,进而减少误检率并提升召回率。DACL 利用检测网络的反馈信息,对背景移除模块的输出进行精细校正,实现了目标特征与背景噪声的有效分离,确保了在复杂场景下目标信息的完整保留和高效提取。

同时, SAR-BRADet 框架具有高度的模块化和可移植性,能够灵活适配多种经典




图 5.10 本章方法检测结果示例

目标检测模型（如 Faster R-CNN、YOLO、CenterNet 等），为未来检测算法的进步和扩展提供了坚实的平台。大量实验结果表明，SAR-BRADet 在不同检测架构下均能显著提升 AP、Precision 和 Recall 等关键指标，有效抑制背景杂波和噪声，同时保留关键目标特征，展现出良好的泛化能力和鲁棒性。

第六章 SAR 图像杂波抑制与目标检测联合学习策略

本章提出了一种创新性的杂波增强-抑制-检测联合框架，通过构建端到端的对抗训练机制，实现了杂波注入、杂波抑制与目标检测模块的紧密协同，从而在复杂背景下显著提升目标检测的精度与鲁棒性。为了充分模拟实际场景中可能出现的多种杂波干扰，本章构建了多种杂波注入模型，利用不同的统计模型和空间分布特征，为后续的对抗训练提供了丰富且具有代表性的训练样本，确保模型在多变环境下具有较强的鲁棒性。本章在 Rolling-Unet 基础上，构建了针对杂波抑制任务的专用网络。通过引入多尺度特征融合、残差连接及深层次信息交互机制，所提方法有效地提取目标与杂波间的细微差异，实现了杂波信息的高效抑制。通过在训练过程中主动注入杂波，使模型在对抗复杂背景的同时学会有效抑制杂波，再进行目标检测。相比于直接在原始 SAR 图像上训练检测模型，SAR 杂波抑制与舰船检测联合学习策略的优势在于：杂波增强通过构造多样化的杂波模式，提升了模型对复杂环境的适应性，使其能够学习不同类型杂波的分布特征；杂波抑制网络在对抗训练中不断优化，使得模型不仅能够去除杂波，还能保留关键的目标特征，从而增强检测网络对真实目标的辨别能力；检测网络在抑制后的特征图上进行目标识别，相比于传统方法直接在含杂波的 SAR 图像上检测，能够有效降低背景噪声的干扰，减少误检率并提升检测精度。SAR 杂波抑制与舰船检测联合学习策略实现了杂波干扰建模、抑制优化与目标检测的端到端协同训练，使模型具备更强的抗杂波能力，为 SAR 目标检测提供了一种稳健高效的解决方案。

6.1 引言

前几章的工作分别从标签分配、数据增强和背景移除等角度对 SAR 舰船检测进行了创新与研究。针对深度学习舰船检测中正负样本划分的关键问题，第三章提出了模型预测引导的标签分配策略，并设计了专门用于 SAR 舰船检测的多尺度检测网络。然而，由于数据标注数量有限、样本背景较为单一以及目标与背景之间的差异较小，模型在面对真实复杂海况时，仍存在泛化能力不足和鲁棒性不强的问题。第四章针对这一不足，通过引入杂波数据增强方法，利用参数化杂波模型与真实杂波数据相结合构建杂波集，进一步扩充了训练样本的数量和多样性，从而使背景变得更加复杂。但在实际 SAR 场景中，这种增强策略仍难以完全重现海洋环境中杂波干扰、噪声动态变化及电磁散射细节等关键特性。第五章则聚焦于近岸 SAR 图像的特殊挑战，提出了背景移除辅助的检测网络，该方法通过背景移除网络与检测网络的有机结合，

并引入检测辅助一致性损失来引导背景消除过程,实现了较大幅度的检测性能提升。然而,尽管 SAR-BRADet 在一定程度上缓解了背景干扰问题,但在如何更好地实现杂波抑制、噪声去除与保护目标细节之间的平衡上,仍存在进一步优化的空间。

鉴于上述不足,本章提出了一种创新性的杂波增强-抑制-检测联合框架,通过构建端到端的联合学习机制,实现了杂波注入、杂波抑制与目标检测模块的紧密协同,从而在复杂背景下显著提升目标检测的精度与鲁棒性。为充分模拟实际场景中可能出现的多种杂波干扰,本框架构建了多种杂波注入模型,利用不同的统计模型和空间分布特征生成丰富且具有代表性的杂波样本,确保模型在面对多变环境时具备较强的适应性。本章基于 Rolling-Unet 构建的专用杂波抑制网络,通过多尺度特征融合、残差连接和深层信息交互机制,有效提取目标与杂波间的细微差异,实现高效的杂波信息抑制;在此基础上,检测网络在抑制后的特征图上进行目标定位与识别,有效降低背景噪声干扰、减少误检并提升检测精度。这一整体框架不仅克服了前述方法在数据标注不足、背景复杂性欠缺以及目标细节保护不足等问题,还实现了从杂波建模到目标检测的全流程协同优化。

在雷达目标检测和 SAR 图像处理领域,杂波抑制与目标检测技术经历了从早期基于统计特性和传统滤波方法到现代深度学习技术的飞速演进。早期的工作主要依赖于恒虚警率方法^[172]以及空间-时间自适应处理 (Space-Time Adaptive Processing, STAP) 技术^[173],这些方法在一定程度上奠定了杂波抑制的理论基础,但在应对复杂电磁散射、目标细节保留以及背景噪声干扰等问题时显示出明显局限。

近年来,随着合成孔径雷达成像技术的迅速发展,如何在复杂海洋环境中实现高精度目标检测成为亟待解决的问题。其中,杂波(包括海杂波、波浪干扰及旁瓣效应等)的抑制对提高图像质量和检测精度起着至关重要的作用。传统方法主要依赖于统计滤波和物理模型,但在处理复杂背景下的电磁散射、杂波多样性以及目标细节保护时常常效果不佳^[174]。自深度学习兴起以来,学者们利用神经网络强大的特征表达能力,逐步推动了杂波抑制技术的发展,形成了一系列具有代表性的研究成果。

在 2020 年,袁等人^[175]针对传统鲁棒空间变窗加权函数 (Robust Spatially Variant Apodization, RSVA) 在处理 SAR 旁瓣干扰时存在的目标能量损失问题,提出了一种基于卷积神经网络的旁瓣抑制方法。该方法通过深度学习网络补偿 RSVA 中因相位因素导致的能量不足,在保持主瓣能量的同时,有效降低了旁瓣干扰,从而改善了信噪比和图像质量。艾等人^[176]提出了一种基于改进超分辨率生成对抗网络 (Super Resolution Generation Adversarial Network, SRGAN) 的模糊抑制算法,用于增强 SAR 舰船目标的对比度。该方法通过引入先进的生成对抗机制,有效缓解了因方位歧义引起的目标模糊问题,实现了对目标与背景之间细微差异的捕捉,并为后续目标检测奠定了基础。该方法无需依赖 SAR 系统的先验信息,因此适用于多种观测场景和采集

模式。同时, SRGAN 的生成器采用了残差密集网络 (Residual Dense Network, RDN) 结构, 实现了全局与局部特征的最优融合, 从而显著提升了 SAR 舰船目标对比度增强所需的特征信息完整性。

针对海面杂波的挑战, 朱等人^[177] 利用复值神经网络并结合功率谱密度 (Power Spectral Density, PSD) 优化, 提出了一种海杂波抑制方法。该方法充分挖掘复值信号中蕴含的幅度和相位信息, 通过构造专门的 PSD 损失函数, 有效抑制了海面杂波, 并在保持目标信息完整性方面表现出较高的鲁棒性。华等人^[178] 进一步发展了这一思路, 提出了一种自监督复值深度学习方法来进行海面杂波抑制。该方法利用海杂波的内在统计特性, 在无需大量人工标注数据的情况下, 通过自监督学习实现了杂波与目标特征的有效分离, 为复杂场景下的目标检测提供了更纯净的输入数据。徐等人^[179] 提出的 Wake2Wake 方法。该方法针对 SAR 舰船尾迹检测中常见的海面波浪干扰问题, 采用了特征引导的自监督波抑制策略。通过在训练过程中主动构造多模式杂波样本, 并利用自监督机制引导波抑制模块提取关键特征, Wake2Wake 不仅有效压制了干扰波动, 还为后续的舰船尾迹检测提供了更为干净的背景, 从而在整体检测性能上实现了质的飞跃。

综上所述, 近年来 SAR 杂波抑制技术正经历着从基于生成对抗网络与卷积神经网络的方法, 到复值神经网络和自监督深度学习技术的不断演进。这些方法在各自的创新点上不断突破传统技术的局限, 从最初的模糊抑制、旁瓣能量补偿, 到后来的海杂波特性建模与自监督学习, 再到最新的波抑制策略, 都为实现复杂海洋环境下高精度、鲁棒的目标检测做出了理论创新。

尽管上述方法在杂波抑制任务中取得了显著的性能提升, 但仍存在多方面的不足。传统的统计滤波方法和物理建模虽然为杂波抑制提供了理论依据, 但在面对复杂电磁散射环境与多变背景噪声时, 往往难以在有效抑制背景干扰的同时保留目标细节, 导致小目标边缘模糊或低可见性目标丢失^[180]。现有基于深度学习的检测方法多聚焦于特定类型干扰 (如旁瓣效应或海杂波) 的抑制, 对于实际应用中多种干扰因素叠加的复杂场景适应性不足, 易导致误检或漏检。训练过程中常忽视训练数据与测试数据在分布上的不一致性, 使得模型在部署于真实场景时存在显著的性能退化。在性能表现之外, 另一个不可忽视的问题是现有方法在计算资源消耗上的高成本。传统物理建模方法往往依赖于频域变换、多尺度滤波或迭代优化等计算密集型操作, 难以满足实时性和高效率的要求。即便是基于深度学习的方法, 复杂的网络结构和大规模参数量也导致训练和推理过程耗时较长, 限制了其在边缘设备或资源受限平台上的部署能力。并且大多数方法仍采用“任务分离”的处理范式, 即将杂波抑制与目标检测作为两个独立任务分别建模与优化。这种设计模式所产生的中间结果往往缺乏与下游检测任务的一致性。例如, 过度抑制杂波可能导致目标纹理信息的损失, 抑制

结果的偏差亦可能在检测阶段被误判为背景或伪影,导致检测性能下降。同时,由于前后模块参数不共享、优化目标不同,系统整体难以实现全局最优。综上所述,当前方法在鲁棒性、泛化性、计算效率和任务协同性方面仍存在显著挑战,亟需更高效、协同、可扩展的检测框架,以适应复杂动态的 SAR 海洋环境。

为解决上述问题,本章提出了一种创新性的杂波增强-抑制-检测联合框架。该框架通过构建端到端的对抗训练机制,实现了杂波注入、杂波抑制与目标检测模块的紧密协同。本章首先构建了基于不同统计模型和空间分布特征的杂波注入策略,用以生成具有代表性的多种干扰样本,充分模拟实际复杂海洋环境下的各种杂波干扰,为后续对抗训练提供了丰富且多样的训练数据。基于 Rolling-Unet 架构,结合多尺度特征融合、残差连接和深层信息交互机制,设计了一种专用于杂波抑制的深度网络。该网络能精准提取目标与杂波之间的细微差异,实现对杂波信息的高效抑制,同时确保关键目标特征的完整性。在训练过程中主动注入杂波干扰,使杂波增强、抑制与检测模块实现协同优化,进而提升模型在复杂背景下的鲁棒性和检测精度。相比直接在原始 SAR 图像上进行目标检测,此方法能够显著提高模型鲁棒性,减少误检率。

本章剩余内容分为如下部分:第 6.2 节介绍了杂波增强-抑制-检测联合框架的整体结构,其中详细描述了杂波注入模块、SAR-CSNet 杂波抑制网络和目标检测模块的组成,并阐明了端到端对抗训练机制在提升复杂背景下检测性能方面的作用;第 6.3 节则通过在 SSDD 和 HRSID 数据集上的实验结果与消融分析,验证了所提框架在杂波环境下对舰船检测性能的显著提升。第 6.4 节为本章工作总结。

6.2 杂波抑制与舰船检测联合学习策略

6.2.1 整体框架

如图 6.1 所示,本章提出的杂波增强-抑制-检测联合框架主要包括三个关键模块:杂波注入模块、杂波抑制网络和目标检测模块。该框架通过端到端的对抗训练机制,实现了各模块之间的紧密协同,从而在复杂背景下显著提升目标检测的精度与鲁棒性。杂波注入模块旨在充分模拟实际场景中可能出现的多种杂波干扰。该模块基于多种统计模型和空间分布特征,主动构造出丰富且具有代表性的杂波样本。通过这些杂波样本与原始 SAR 图像进行融合,不仅扩充了训练数据的多样性,还在数据层面上为后续对抗训练提供了极具挑战性的干扰环境,确保模型在实际复杂场景下具备更强的适应能力。

杂波抑制网络 (SAR-CSNet) 基于 Rolling-Unet 架构进行设计,是本框架的核心模块之一。该网络通过引入多尺度特征融合、残差连接以及深层信息交互机制,能够精准提取目标与杂波之间的细微差异,实现高效的杂波抑制。在设计过程中,特别关注

了网络的轻量化问题：通过减少网络参数量和优化计算流程，保证了模型在保持高效抑制能力的同时，也具有较低的运算复杂度和较快的响应速度，便于在资源受限的实际应用中部署。在目标检测模块，本章方法充分考虑了不同应用场景对检测精度与实时性的多样化需求。检测网络可根据具体任务按需选择，例如采用 Faster R-CNN、YOLO 系列等主流检测框架。由于目标检测在整个框架中依赖于经过杂波抑制后获得的高质量图像，因此，该模块在设计上注重与杂波抑制网络的无缝衔接，以便充分利用抑制后的清晰特征，降低背景噪声的干扰，减少误检率并提升检测准确性。




图 6.1 杂波抑制与舰船检测联合框架图

端到端的联合学习机制在整个框架中起到了桥梁作用。通过将杂波注入、抑制和检测模块有机地融合在同一训练流程中，使得整个系统在训练过程中能够相互协同、不断自我优化。具体流程包括：首先，将原始 SAR 图像与注入的多模式杂波样本进行融合，生成增强训练数据；随后，利用杂波抑制损失和检测损失同时引导杂波抑制网络和检测网络进行联合优化；最后，在端到端的训练过程中，实现对杂波干扰的自适应抑制和目标特征的精准提取。该训练策略不仅提高了模型在复杂背景下的鲁棒性，也显著提升了整体检测性能。通过构造多样化的杂波注入模型，使训练数据充分反映复杂环境下的干扰特性，从而增强模型的适应性。杂波抑制网络采用基于 Rolling-Unet 的轻量化架构，既高效去除干扰，又保证了目标特征的完整保留，为实时检测提供了技术保障。检测网络可按需选择，满足不同场景下对检测精度和实时性要求的多样化需求，同时整个框架的模块化设计也便于后续系统的扩展与优化。对抗训练机制使各模块在训练过程中实现了信息共享和协同进化，显著降低了背景噪声的干扰，提高了检测准确率和鲁棒性。综上所述，SAR 图像杂波抑制与目标检测联合学习策略通过数据增强、轻量化设计以及端到端对抗训练策略，实现了杂波干扰建模、抑制优化与目标检测的紧密耦合，为 SAR 图像在复杂海洋环境下的目标检测问题提供了一种全新且高效的解决方案。

6.2.2 杂波抑制网络

本节以 Rolling-Unet^[181] 作为杂波抑制网络，如图 6.2 所示。总体上，网络采用 U-Net 范式的思想，通过跳跃连接实现不同尺度特征的高效融合。在网络较深层，即第四层和瓶颈层，原有的标准卷积块被特征激励模块和 (Long-Local, Lo2) 模块替换，

从而在保证细节信息保留的同时，有效提取图像中的全局长距离依赖和局部上下文信息。下面将从理论原理和模块设计两个方面详细介绍本网络结构的各关键组件。

Rolling-Unet 最早用于医学图像分割，其核心思想在于将传统卷积神经网络与多层感知机（Multilayer Perceptron, MLP）相结合，以弥补纯卷积网络在捕捉长距离依赖方面的不足。传统 CNN 由于卷积操作的局部感受野限制，很难直接建模图像中远程的语义关系；而 Transformer 虽能捕捉全局信息，但计算复杂度较高且局部特征学习不足。Rolling-Unet 通过引入滚动操作，将输入特征在空间维度上进行平移和裁剪，从而利用 MLP 模块在通道维度上的全连接特性，高效提取全局长距离依赖。此外，网络结构保持了 U-Net 中编码器和解码器的对称性，并利用跳跃连接融合不同尺度的特征，确保了细节信息与全局语义的充分交互。




图 6.2 Rolling-Unet 的整体架构图

对于输入尺寸为 $H \times W \times C$ 的特征图，R-MLP 模块首先在每个通道上对特征进行滚动操作（Rolling），即在某一方向（例如宽度方向）上执行平移操作，然后通过裁剪补全，形成新的通道间特征排列。此操作使得原本固定的空间位置关系在不同通道上呈现出不同的排列，从而为后续全连接（MLP）操作提供了多样化的输入，进而实现全局长距离依赖的建模。R-MLP 模块在参数量和计算复杂度上仅为 $O(C^2)$ 和 $O(HWC^2)$ ，并不增加额外计算负担。

为了捕捉图像中不同方向的长距离依赖，R-MLP 模块被进一步扩展为正交滚动模块（Orthogonal Rolling-MLP, OR-MLP）。具体地，首先在一个方向（例如从左到右）应用 R-MLP，然后在正交方向（例如从上到下）再次应用 R-MLP，并在两次操作之

间使用 GELU 激活函数。两个模块的串联形成了一个 OR-MLP 单元，并通过残差连接将输入直接加回，从而保持特征稳定性。该设计不仅扩展了线性依赖的提取范围，还降低了模型对位置敏感性的要求。

在 OR-MLP 的基础上，进一步构造双正交滚动模块（Double Orthogonal Rolling-MLP, DOR-MLP），如图6.3所示。DOR 通过并行执行两个互为补充的 OR-MLP 模块来捕获四个方向（宽度、长度、正对角线和负对角线）的长距离依赖。具体而言，两个 OR-MLP 模块在不同顺序下分别应用于图像，获得的输出在通道维度上进行拼接，随后经过层归一化和通道混合（Channel-mixing, CM）操作，将拼接后的特征压缩回原始通道数。该模块使得模型在提取全局语义信息时能够兼顾多个方向的依赖关系，同时保持了与标准 3×3 卷积相当的参数量和计算复杂度。




图 6.3 DOR 整体架构图

尽管 DOR-MLP 模块在捕捉全局长距离依赖方面表现出色，但其本质上忽略了局部上下文信息，而局部特征对图像中杂波与目标的区分至关重要。为此，刘等提出了 Long-Local (Lo2) 块，该块将 DOR-MLP 模块与深度可分离卷积模块并行结合。具体来说，Lo2 块首先将输入特征分别送入 DOR-MLP 模块和 DSC 模块，前者负责提取全局、线性的长距离依赖信息，后者则利用 3×3 卷积核捕获局部纹理和细节特征。两路特征在通道维度上通过拼接融合，接着使用通道混合操作进一步融合并恢复通道数。理论上，Lo2 块的参数量和计算量与标准 3×3 卷积相当，但其融合了全局与局部特征，为杂波抑制提供了更为丰富的表征能力，如图6.4所示。网络的第四层编码器和瓶颈层还引入了特征激励模块。该模块主要由卷积层、激活函数（如 GELU 或 ReLU）以及归一化层（LayerNorm 或 BatchNorm）组成，旨在对输入特征进行编码和通道数调节，为后续 Lo2 块的高效处理提供合适的特征表示。特征激励模块的设计继承了 MLP 领域的成功经验，使得在深层网络中，特征维度既能得到充分压缩，又能保持丰富的语义信息，从而提高杂波抑制与目标检测的整体效果。

选取杂波抑制网络特别关注了模型的轻量化和模块灵活性。由于杂波抑制任务通常需要在实时或资源受限的场景中运行，网络中各模块的参数量和计算复杂度均被严格控制。具体而言，R-MLP、OR-MLP 和 DOR-MLP 模块的设计使得全局依赖提

取仅需极少额外计算,而 Lo2 块通过并行执行 DSC 和 DOR-MLP,同样保持了与 3×3 卷积相当的计算量。此外,由于网络整体采用 U-Net 框架,目标检测模块可以根据实际需求灵活替换为 Faster R-CNN、YOLO 系列或其他主流检测网络,从而实现从杂波抑制到目标检测的无缝衔接。杂波抑制网络通过引入 R-MLP、OR-MLP、DOR-MLP 以及 Lo2 块,实现了对全局长距离依赖和局部上下文信息的高效融合,为雷达图像中的杂波抑制提供了一种精度高且轻量化的解决方案,同时为后续目标检测任务提供清晰图像。




图 6.4 Lo2 结构图

6.3 实验结果分析

6.3.1 实验设置细节

为验证本章提出的杂波增强-抑制-检测联合框架的有效性,本研究在实验中采用了第三章所介绍的杂波增强算法,针对 SAR 舰船检测任务构建了一个具有多样化杂波干扰的训练数据集。具体来说,本实验在杂波注入阶段采用了第三章算法中的乘法模式,通过 Gamma 统计模型生成仿真杂波,其形状参数设为 1,尺度参数设为 2。在数据预处理阶段,对原始 SAR 图像进行尺度变换、平移等一系列数据增强操作,以充分模拟实际复杂场景中的几何变化和噪声干扰。

在整个数据增强流程中,首先将原始 SAR 图像作为杂波抑制真值 (Clutter Suppression GT),即未经杂波干扰的理想背景;随后,利用 Gamma 统计模型生成的仿真杂波与经过尺度变换和平移的数据增强图像进行乘法融合,形成杂波注入后的图像,该图像作为杂波抑制网络的输入。通过这种方法,不仅在数量上大幅扩充了训练样本,而且显著提升了数据的多样性,使得背景变得更加复杂,同时保持了目标位置和标注信息的准确性。杂波抑制输入与标签如图 6.5 所示。




图 6.5 杂波抑制输入与标签可视化

此外，由于杂波增强技术既可以离线实现，也可在线实施，本方法在训练过程中能够实现动态更新——即每次迭代中，通过实时生成不同参数配置的仿真杂波，进一步缓解了过拟合问题，提升了模型在复杂环境下的泛化能力。实验结果表明，通过这种基于参数化杂波建模与真实杂波数据相结合的注入方式，统计模型中提取的有价值信息被有效地集成到了整体框架中，从而显著提高了舰船检测的准确率和鲁棒性。

6.3.2 实验结果与分析

表6.1 展示了在 SSDD 数据集上，针对不同检测方法策略下的杂波注入与 SAR-CSNet 联合驱动舰船检测算法消融实验结果。实验采用了两种主流的检测网络：YOLO V5l 和 YOLO V7。基线检测网络直接使用 YOLO V5l 或 YOLO V7 进行检测；仅测试注入杂波表示仅在测试阶段对输入图像进行杂波注入，该杂波由乘法模式下的 Gamma 统计模型生成（形状参数为 1，尺度参数为 2），而训练阶段保持原始数据；SAR-CSNet 在上述基础上加入本章提出的 SAR-CSNet 模块，用于联合驱动杂波抑制与舰船检测。从表中数据可以看出，若仅在测试阶段注入杂波，AP 降至 83.90%，精度与召回率均出现明显下降，这反映出训练与测试数据分布不匹配时，检测网络难以有效应对实际杂波干扰；引入 SAR-CSNet 后，AP 显著提升至 93.84%，同时精度和召回率分别提高到 87.72% 和 95.42%，充分证明了 SAR-CSNet 在联合驱动杂波抑制和目标检测中的有效性。对于 YOLO V7，仅测试注入杂波进一步导致 AP 下降到 84.10%，显示出模型在未见过干扰数据时性能的严重退化；加入 SAR-CSNet 后，AP 提升至 93.92%，精度和召回率分别达到 90.25% 和 95.42%，说明该模块能够有效缓解由杂波引起的检测难题，并显著改善检测性能。

表 6.1 SSDD 数据集上的实验结果

方法	平均准确率 (%)	准确率 (%)	召回率 (%)
文献 ^[182]	89.80	—	—
CF-SSD ^[183]	90.30	—	—
文献 ^[184]	90.57	—	—
文献 ^[185]	91.12	94.77	77.85
Cascade R-CNN with BSLM ^[65]	91.53	92.95	92.10
YOLO V5l	89.52	82.70	91.22
只有测试注入杂波	83.90	82.72	85.88
+ SAR-CSNet	93.84	87.72	95.42
YOLO V7	91.01	86.79	92.75
只有测试注入杂波	84.10	82.55	86.64
+ SAR-CSNet	93.92	90.25	95.42

表6.2 展示了在 HRSID 数据集上, 针对不同检测方法策略下的杂波注入与 SAR-CSNet 联合驱动舰船检测算法消融实验结果。SAR-CSNet 模块的引入, 有效抑制了杂波干扰。实验结果中, 无论是基于 YOLO V5l 还是 YOLO V7, 均可见引入 SAR-CSNet 后 AP、精度和召回率均有显著提高, 验证了该方法在提升检测准确性和泛化能力方面的优势。实验同时说明, 通过在训练和测试阶段注入具有代表性的仿真杂波, 再结合 SAR-CSNet 模块, 有效地克服了杂波干扰带来的挑战, 不仅提高了检测的平均精度, 还显著改善了精度和召回率的平衡, 为复杂背景下的舰船检测提供了稳健的解决方案。

表 6.2 HRSID 数据集上的实验结果

方法	平均准确率 (%)	准确率 (%)	召回率 (%)
文献 ^[186]	82.30	—	65.20
SAR-Net ^[66]	78.71	38.40	84.16
YOLO V5l	84.18	80.51	86.33
只有测试注入杂波	80.53	84.03	81.99
+ SAR-CSNet	85.69	84.34	87.28
YOLO V7	84.53	81.10	85.79
只有测试注入杂波	81.92	79.83	83.74
+ SAR-CSNet	85.69	84.34	87.28

实验结果表明, YOLO V5l 和 YOLO V7 在基础情况下均能取得较高的 AP, 但在注入杂波后, AP 下降, 表明杂波对目标检测的干扰较大。引入 SAR-CSNet 后, AP 显著提升, 表明其能够有效增强检测鲁棒性。精确率方面, 杂波的加入导致精确率下降, 而 SAR-CSNet 的增强使其回升, 说明该网络能有效减少误检。召回率分析同样表明 SAR-CSNet 能提高对真实目标的捕捉能力, 在 YOLO V5l 和 YOLO V7 上均达

到了 87.28%。综合来看，SAR-CSNet 在提升目标检测性能方面表现优越，能够有效缓解杂波对检测任务的影响。

6.3.3 计算复杂度分析

从计算复杂度分析表 6.3 可以看出，SAR-CSNet 在 YOLO V5l 和 YOLO V7 这两种检测框架上的引入带来了一定程度的计算量增加。具体而言，YOLO V5l 在未使用 SAR-CSNet 时，模型大小为 85.8 MB，计算复杂度（GFLOPs）为 64.26，参数量为 46.63M，而在结合 SAR-CSNet 之后，模型大小增至 91.8 MB，GFLOPs 增加至 79.01，参数量提升至 48.41M。类似地，YOLO V7 在未使用 SAR-CSNet 时，GFLOPs 仅为 59.13，而结合 SAR-CSNet 后上升至 73.94，参数量也从 37.2M 增长至 38.98M。这表明，SAR-CSNet 在提升检测性能的同时，引入了一定的计算代价。然而，这种计算复杂度的增加是可接受的，因为其带来了显著的检测性能提升。相比于原始 YOLO V5l 和 YOLO V7，结合 SAR-CSNet 后的版本在杂波环境下表现更为鲁棒，能够有效降低误检率并提升目标检测的召回率。此外，参数量的适度增加并未显著影响模型的可部署性，依然可以满足实时检测的需求。

综合来看，SAR-CSNet 在计算复杂度上的增加是合理的权衡，它通过引入杂波增强机制，提高了模型在复杂环境下的检测能力，使其在 SAR 目标检测任务中表现更加稳定可靠。这一框架的端到端设计不仅提升了检测精度，还增强了模型的适应性，为后续 SAR 目标检测算法的优化提供了新的方向。

表 6.3 SAR-CSNet 在 HRSID 数据集上的计算复杂度分析

方法	模型大小 (MB)	GFLOPs	参数量 (M)
YOLO V5l	85.8	64.26	46.63
YOLO V5l + SAR-CSNet	91.8	79.01	48.41
YOLO V7	143	59.13	37.2
YOLO V7 + SAR-CSNet	149	73.94	38.98

图 6.6 展示了本章方法在 HRSID 复杂杂波场景下的检测结果：绿色框表示模型预测结果，蓝色框为真实标注，红色框为虚警。展示图片均为注入杂波后的结果，背景杂波复杂程度明显提升。结果表明，本章方法（YOLO V5l + SAR-CSNet）在高度干扰背景下仍能精准提取目标，显著抑制误检，与真实标注保持高度一致。但是在近岸场景仍易产生虚警，这一现象进一步证明第五章 SAR 图像背景移除辅助的目标检测方法的必要性。




图 6.6 本章方法的检测结果示例

6.4 本章小结

本章提出了 SAR 图像杂波抑制与目标检测联合学习策略，通过构造多样化的仿真杂波和引入轻量化的杂波抑制网络 SAR-CSNet，实现了杂波抑制与目标检测两个任务间的无缝衔接。杂波注入模块通过多模式统计模型生成多样化干扰数据，SAR-CSNet 基于 Rolling-Unet 架构实现全局-局部特征融合，目标检测模块支持灵活替换主流网络。实验结果充分证明了三者协同优化显著提升了检测精度与鲁棒性。通过引入 R-MLP、OR-MLP、DOR-MLP 等模块，以较低的额外计算代价（参数量增幅 <5%）实现全局长距离依赖建模，结合 Lo2 块保留局部纹理特征，平衡了性能与实时性需求。该框架通过杂波注入、轻量化网络设计与模块化协同，实现了杂波抑制与目标检测的高效联合优化，在复杂海洋环境中展现出卓越的检测精度与部署潜力。

第七章 总结与展望

7.1 总结

本文针对复杂海上场景中 SAR 舰船检测面临的背景杂波非平稳性、小目标模糊性、近岸干扰显著及训练-测试目标偏差等核心挑战,提出了一套多层次、多任务协同的创新性解决方案。通过深度融合杂波统计建模、数据增强、多尺度特征融合、任务辅助学习与端到端增强训练技术,系统性地解决了复杂环境下的检测精度不足、鲁棒性差及计算效率低等问题。

1. 第三章探讨了预测感知的 SAR 多尺度目标检测模型。通过将交并比预测作为定位精度的衡量标准,融合分类与定位信息对候选锚框进行综合评估,从而实现了自适应正样本选择,弥补了传统固定标签分配策略在训练与测试目标不一致问题上的不足。该方法特别针对小目标检测的难点,通过多尺度特征融合和特征增强策略,将浅层纹理信息与深层语义信息进行有效整合,使得即便在目标信号模糊且与背景杂波高度相似的情况下,也能实现精准检测。

2. 通过对真实杂波与模拟杂波进行统计建模,第四章构建了一套联合驱动的舰船检测算法,在数据层面上充分利用海浪、风浪、潮汐等自然因素对背景的干扰特性,突破了传统数据增强方法仅依赖目标变换的局限性。具体来说,利用加法融合、乘法融合和目标保护三种融合模式,将统计模型生成的仿真杂波与实际观测的杂波数据有机结合,既丰富了训练数据的背景复杂性,又确保了目标区域信息的完整性,从而为模型提供了更具挑战性的训练样本,有效缓解了过拟合问题,提高了模型对不同海况、天气条件下杂波变化的适应能力。

3. 针对近岸复杂海上环境下由海面杂波、岸线干扰及其他地理特征引发的检测性能下降问题,第五章设计了任务辅助的 SAR 近岸舰船检测方法。该方法通过构建背景移除网络和检测辅助一致性损失函数,将杂波抑制与目标检测任务紧密联结起来,在抑制背景干扰的同时保证目标特征不被丢失,实现了两大任务的协同优化。这种联合训练策略不仅提升了在强背景干扰条件下的目标检测精度,同时大幅降低了误检率,显著提高了召回率,验证了背景与目标信息协同优化在实际应用中的有效性。

4. 为进一步增强模型在各种极端海况下的适应性,第六章提出了一种杂波增强学习与舰船检测的联合学习策略。该框架采用端到端的对抗训练策略,首先通过实时杂波注入机制生成多样化且具有代表性的背景干扰样本,随后利用先进的杂波抑制

网络对杂波进行高效去除，最后由目标检测模块从净化后的图像中提取舰船目标信息。整个训练过程中，各模块通过反向传播实现信息共享和协同进化，不仅提升了检测精度，同时也在一定程度上兼顾了模型的计算复杂度与实时性要求，为复杂海上场景下的 SAR 舰船检测提供了一种高效、稳健且易于实际部署的解决方案。

7.2 展望

本文虽然在 SAR 舰船检测领域取得了一定进展，但仍存在若干不足，为未来研究提供了多角度拓展的方向：

7.2.1 多模态数据融合不足

当前研究主要集中于单一的 SAR 数据处理，忽略了其他传感器数据的互补优势。未来应进一步探索如何将光学图像、雷达数据以及其他高光谱或红外传感器数据进行深度融合，构建多模态特征提取与融合网络。通过设计专门的跨模态注意力机制与联合训练策略，可以在数据层面上实现信息互补，充分利用各类数据在分辨率、频谱、视角等方面的不同特性，从而提高目标检测在复杂海况下的鲁棒性与准确性。与此同时，多模态融合还可缓解因单一传感器局限性引起的数据噪声和干扰问题，为实际应用提供更加丰富和稳定的信息支持。

7.2.2 轻量化网络设计挑战

尽管本文所提出的检测算法在实验室环境下表现出较高的精度，但在实时监控和大规模部署中，模型的计算复杂度和参数量仍然是制约因素。未来研究可以从网络结构压缩、参数剪枝、模型量化以及知识蒸馏等方面入手，构建适合嵌入式系统和边缘计算平台的轻量化网络。通过有效减少模型参数和运算量，同时保持甚至提升检测性能，轻量化设计不仅能满足实时性要求，还能降低能耗和硬件成本，从而推动 SAR 舰船检测技术在实际海上监控和预警系统中的广泛应用。

7.2.3 实时性检测的难题

目前的检测方法主要依赖于离线训练的模型，对于环境变化、数据分布漂移等动态因素的适应能力较弱。在实际海上场景中，光照、气候、海况以及杂波特性均可能发生显著变化，导致模型性能下降。未来的研究应关注在线自适应检测算法，通过增量学习、元学习或强化学习等方法，实现模型参数和决策阈值的实时动态更新。特别是在标注数据匮乏的情况下，半监督或无监督的在线自适应策略将成为研究热点，以充分利用实时数据反馈，提升模型的泛化能力和鲁棒性，从而确保检测系统在长时间运行过程中依然保持高效稳定的性能。

7.2.4 硬件加速与软硬协同设计

在实际应用中，算法的实时性和低能耗是部署的关键。当前的算法在硬件加速方面仍有较大提升空间。未来应深入研究 GPU、FPGA、专用神经网络加速器以及新型 AI 芯片在 SAR 舰船检测系统中的应用，通过硬件友好型算法设计，优化内存管理和数据传输机制，降低延迟和功耗。同时，探索软硬件协同设计策略，实现算法与硬件的高效结合，可使检测系统在保障高精度的同时，实现实时在线处理，为海上安全监控、资源管理和应急响应等任务提供坚实的技术支撑。

参考文献

- [1] SKOLNIK M I. Radar handbook[M]. [S.l.] : McGraw-Hill, 1970.
- [2] XU Y, LANG H. Distribution Shift Metric Learning for Fine-Grained Ship Classification in SAR Images[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2020, 13 : 2276–2285.
- [3] ZHU X X, MONTAZERI S, ALI M, et al. Deep Learning Meets SAR: Concepts, models, pitfalls, and perspectives[J]. IEEE Geoscience and Remote Sensing Magazine, 2021, 9 : 143–172.
- [4] GODRICH H, PETROPULU A P, POOR H V. Power allocation strategies for target localization in distributed multiple-radar architectures[J]. IEEE Transactions on Signal Processing, 2011, 59(7) : 3226–3240.
- [5] YI W, FANG Z, WEN M. An efficient coherent multi-frame track-before-detect algorithm in radar systems[C] // 2017 IEEE Radar Conference (RadarConf). 2017 : 1521–1526.
- [6] 郭婵娟. LFM 脉冲雷达高速目标探测信号处理算法设计与实现 [D]. 南京 : 南京理工大学, 2020.
- [7] UPADHYAY P, KUMAR S, UPADHYAY K, et al. Performance Analysis of AIRBORNE SAR System[C] // 2024 First International Conference on Electronics, Communication and Signal Processing (ICECSP). 2024 : 1–5.
- [8] JIANG Q, WANG Y, WANG J. Design and Experimental Verification of ISAR imaging System for Airborne Maritime Surveillance Radar[C] // 2019 6th Asia-Pacific Conference on Synthetic Aperture Radar (APSAR). 2019 : 1–5.
- [9] LIU J, CHEN H, WANG Y. Multi-Source Remote Sensing Image Fusion for Ship Target Detection and Recognition[J]. Remote Sensing, 2021, 13.
- [10] 姜文. 机载多通道 SAR 运动目标检测与成像算法研究 [D]. 北京 : 中国科学院大学, 2020.
- [11] ZHU X X, WANG Y, MONTAZERI S, et al. A Review of Ten-Year Advances of Multi-Baseline SAR Interferometry Using TerraSAR-X Data[J]. Remote Sensing, 2018, 10(9).
- [12] CERUTTI-MAORI D, KLARE J, BRENNER A R, et al. Wide-Area Traffic Monitoring With the SAR/GMTI System PAMIR[J]. IEEE Transactions on Geoscience and Remote Sensing, 2008, 46(10) : 3019–3030.
- [13] ACHIRI L, GUIDA R, IERVOLINO P. SAR and AIS Fusion for Maritime Surveillance[C] // 2018 IEEE 4th International Forum on Research and Technology for Society and Industry (RTSI). 2018 : 1–4.

- [14] WANG X, LI G, PLAZA A, et al. Ship Detection in SAR Images via Enhanced Nonnegative Sparse Locality-Representation of Fisher Vectors[J]. IEEE Transactions on Geoscience and Remote Sensing, 2021, 59(11): 9424–9438.
- [15] SANTOS J, MARQUES P. Ship Detection Using Sentinel-1 Amplitude SAR Data[C] //EUSAR 2021; 13th European Conference on Synthetic Aperture Radar. 2021 : 1–5.
- [16] WANG Y, WANG C, ZHANG H. Ship Classification in High-Resolution SAR Images Using Deep Learning of Small Datasets[J]. Sensors, 2018, 18.
- [17] ESA. Sentinel-1 Mission Performance Report[J], 2022.
- [18] TAINI G, PANETTI A, SPATARO F, et al. SENTINEL-1 Satellite System architecture: Design, performances and operations[C] // 2012 IEEE International Geoscience and Remote Sensing Symposium. 2012 : 1722–1725.
- [19] WERNINGHAUS R, BUCKREUSS S. The TerraSAR-X Mission and System Design[J]. IEEE Transactions on Geoscience and Remote Sensing, 2010, 48(2): 660–614.
- [20] CALTAGIRONE F, SPERA P, VIGLIOTTI R, et al. SkyMed/COSMO mission overview[C] // IGARSS '98. Sensing and Managing the Environment. 1998 IEEE International Geoscience and Remote Sensing. Symposium Proceedings. (Cat. No.98CH36174): Vol 2. 1998 : 683–685 vol.2.
- [21] ZHAO L, ZHANG Q, LI Y, et al. China's Gaofen-3 Satellite System and Its Application and Prospect[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2021, 14: 11019–11028.
- [22] ROSEN P, HENSLEY S, WHEELER K, et al. UAVSAR: a new NASA airborne SAR system for science and technology research[C] // 2006 IEEE Conference on Radar. 2006 : 8 pp.–.
- [23] ZHANG J, WANG Z, HUANG G, et al. CASMSAR: the first Chinese airborne SAR mapping system[C] // Earth Observing Systems XV : Vol 7807. [S.l.]: SPIE, 2010 : 78070Z.
- [24] MOREIRA A, PRATS-IRAOLA P, YOUNIS M, et al. A tutorial on synthetic aperture radar[J]. IEEE Geoscience and Remote Sensing Magazine, 2013, 1(1): 6–43.
- [25] LIU Z, LIU B, GUO W, et al. Ship Detection in GF-3 NSC Mode SAR Images[J]. Journal of Radars, 2017, 6(R17059): 473.
- [26] PALOMEQUE M, FERREYRA J, THIBEAULT M. Monitoring Results of the SAOCOM-1 Constellation: A mission overview and summary of results[J]. IEEE Geoscience and Remote Sensing Magazine, 2024 : 2–11.
- [27] JORDAN R L. The Seasat-A synthetic aperture radar system[J]. IEEE Journal of Oceanic Engineering, 1980, 5(2): 154–164.
- [28] MCDONALD K, PODEST E, STEINER N, et al. NISAR: Seeing Beyond the Trees to Understand Wetlands, Forests and Biodiversity[C] // IGARSS 2024 - 2024 IEEE International Geoscience and

- Remote Sensing Symposium. 2024 : 6775 – 6778.
- [29] TSUNODA S, PACE F, STENCE J, et al. Lynx: a high-resolution synthetic aperture radar[C] // 2000 IEEE Aerospace Conference. Proceedings (Cat. No.00TH8484): Vol 5. 2000: 51 – 58 vol.5.
- [30] JIAO Y, ZHANG F, LIU X, et al. C-SAR/02 Satellite Polarimetric Calibration and Validation Based on Active Radar Calibrators[J]. Remote Sensing, 2025, 17.
- [31] SERMANET P, EIGEN D, ZHANG X, et al. OverFeat: Integrated Recognition, Localization and Detection using Convolutional Networks[C] // International Conference on Learning Representations. 2014.
- [32] GIRSHICK R, DONAHUE J, DARRELL T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C] // IEEE Conference on Computer Vision and Pattern Recognition. 2014 : 580 – 587.
- [33] HE K, ZHANG X, REN S, et al. Spatial Pyramid Pooling in Deep Convolutional Networks for Visual Recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 37(9): 1904 – 1916.
- [34] GIRSHICK R. Fast R-CNN[C] // 2015 IEEE International Conference on Computer Vision (ICCV). 2015 : 1440 – 1448.
- [35] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137 – 1149.
- [36] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: Unified, real-time object detection[C] // IEEE Conference on Computer Vision and Pattern Recognition. 2016 : 779 – 788.
- [37] REDMON J, FARHADI A. YOLOv3: An Incremental Improvement[J]. arXiv preprint arXiv:1804.02767, 2018.
- [38] LIU W, ANGUELOV D, ERHAN D, et al. SSD: Single shot multibox detector[C] // European Conference on Computer Vision. 2016 : 21 – 37.
- [39] TAN M, PANG R, LE Q V. EfficientDet: Scalable and efficient object detection[C] // 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020 : 10778 – 10787.
- [40] BOCHKOVSKIY A, WANG C-Y, LIAO H-Y M. YOLOv4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv:2004.10934, 2020.
- [41] JOCHER G, STOKEN A, CHAURASIA A. Ultralytics YOLOv5[J], 2020.
- [42] HE K, GKIOXARI G, DOLLÁR P, et al. Mask R-CNN[C] // 2017 IEEE International Conference on Computer Vision (ICCV). 2017 : 2980 – 2988.

- [43] LIN T-Y, GOYAL P, GIRSHICK R, et al. Focal Loss for Dense Object Detection[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 42(2): 318–327.
- [44] CAI Z, VASCONCELOS N. Cascade R-CNN: High Quality Object Detection and Instance Segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2021, 43(5): 1483–1498.
- [45] CARION N, MASSA F, SYNNAEVE G, et al. End-to-End Object Detection with Transformers[C] // European Conference on Computer Vision. 2020: 213–229.
- [46] ZHAO Y, LV W, XU S, et al. DETRs Beat YOLOs on Real-time Object Detection[C] // 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024: 16965–16974.
- [47] ZHOU X, KOLTUN V, KRÄHENBÜHL P. DINO: DETR with Improved DeNoising Anchor Boxes for End-to-End Object Detection[J]. arXiv preprint arXiv:2203.03605, 2022.
- [48] GE Z, LIU S, WANG F, et al. YOLOX: Exceeding YOLO Series in 2021[J]. arXiv preprint arXiv:2107.08430, 2021.
- [49] WANG C-Y, BOCHKOVSKIY A, LIAO H-Y M. YOLOv7: Trainable Bag-of-Freebies Sets New State-of-the-Art for Real-Time Object Detectors[C] // 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 7464–7475.
- [50] VARGHESE R, M. S. YOLOv8: A Novel Object Detection Algorithm with Enhanced Performance and Robustness[C] // 2024 International Conference on Advances in Data Engineering and Intelligent Computing Systems (ADICS). 2024: 1–6.
- [51] WANG C-Y, YE H I-H, LIAO H-Y M. YOLOv9: Learning What You Want to Learn Using Programmable Gradient Information[C] // Computer Vision – ECCV 2024. Cham: Springer Nature Switzerland, 2025: 1–21.
- [52] LIU Z, LIN Y, CAO Y, et al. Swin Transformer: Hierarchical Vision Transformer using Shifted Windows[C] // 2021 IEEE/CVF International Conference on Computer Vision (ICCV). 2021: 9992–10002.
- [53] LIN Z, JI K, LENG X, et al. Squeeze and Excitation Rank Faster R-CNN for Ship Detection in SAR Images[J]. IEEE Geoscience and Remote Sensing Letters, 2019, 16(5): 751–755.
- [54] QIN H, LI Y, LEI J, et al. A Specially Optimized One-Stage Network for Object Detection in Remote Sensing Images[J]. IEEE Geoscience and Remote Sensing Letters, 2021, 18(3): 401–405.
- [55] YANG X, ZHANG X, WANG N, et al. A Robust One-Stage Detector for Multiscale Ship Detection With Complex Background in Massive SAR Images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1–12.

- [56] ZHANG T, ZHANG X. ShipDeNet-20: An Only 20 Convolution Layers and <1-MB Lightweight SAR Ship Detector[J]. IEEE Geoscience and Remote Sensing Letters, 2021, 18(7): 1234–1238.
- [57] ZHANG X, WANG H, XU C, et al. A Lightweight Feature Optimizing Network for Ship Detection in SAR Image[J]. IEEE Access, 2019, 7: 141662–141678.
- [58] HONG Z, YANG T, TONG X, et al. Multi-Scale Ship Detection From SAR and Optical Imagery Via A More Accurate YOLOv3[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2021, 14: 6083–6101.
- [59] CUI Z, LI Q, CAO Z, et al. Dense Attention Pyramid Networks for Multi-Scale Ship Detection in SAR Images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 57(11): 8983–8997.
- [60] 张帆, 陆圣涛, 项德良, et al. 一种改进的高分辨率 SAR 图像超像素 CFAR 舰船检测算法 [J]. 雷达学报, 2023, 12(1): 120–139.
- [61] 吴孙勇, 薛秋条, 朱圣棋, et al. 杂波环境下基于粒子滤波的微弱扩展目标检测前跟踪算法 [J]. 雷达学报, 2017, 6(3): 252–258.
- [62] 崔姗姗, 周建江, 等. 基于半参数化 SLC 的雷达目标识别 [J]. 雷达学报, 2012, 1(4): 414–419.
- [63] 郭子薰, 水鹏朗, 白晓惠, et al. 海杂波中基于可控虚警 K 近邻的海面小目标检测 [J]. 雷达学报, 2020, 9(4): 654–663.
- [64] YANG R, WANG G, PAN Z, et al. A Novel False Alarm Suppression Method for CNN-Based SAR Ship Detector[J]. IEEE Geoscience and Remote Sensing Letters, 2021, 18(8): 1401–1405.
- [65] ZHANG T, ZHANG X, SHI J, et al. Balance Scene Learning Mechanism for Offshore and Inshore Ship Detection in SAR Images[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19: 1–5.
- [66] GAO S, LIU J M, MIAO Y H, et al. A High-Effective Implementation of Ship Detector for SAR Images[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19: 1–5.
- [67] REN Y, LI X, XU H. A Deep Learning Model to Extract Ship Size From Sentinel-1 SAR Images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1–14.
- [68] ZHANG T, ZHANG X, LI J, et al. SAR Ship Detection Dataset (SSDD): Official Release and Comprehensive Data Analysis[J]. Remote Sensing, 2021, 13(18).
- [69] WEI S, ZENG X, QU Q, et al. HRSID: A High-Resolution SAR Images Dataset for Ship Detection and Instance Segmentation[J]. IEEE Access, 2020, 8: 120234–120254.
- [70] JI K, XING X, ZOU H, et al. A Novel Variable Index and Excision CFAR Based Ship Detection Method on SAR Imagery[J]. Journal of Sensors, 2015, 2015(1): 437083.
- [71] MA B, YANG H, YANG J. Ship Detection in Spaceborne SAR Images under Radio Interference Environment Based on CFAR[J]. Electronics, 2022, 11(24).
- [72] SALEMBIER P, LIESEGANG S, LÓPEZ MARTÍNEZ C. Ship Detection in SAR Images Based

- on Maxtree Representation and Graph Signal Processing[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 57(5): 2709–2724.
- [73] WANG X, LI G, PLAZA A, et al. Ship Detection in SAR Images by Aggregating Densities of Fisher Vectors: Extension to a Global Perspective[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 1–13.
- [74] LI N, PAN X, YANG L, et al. Adaptive CFAR Method for SAR Ship Detection Using Intensity and Texture Feature Fusion Attention Contrast Mechanism[J]. Sensors, 2022, 22(21): 8116.
- [75] GIRSHICK R. Fast R-CNN[C] // 2015 IEEE International Conference on Computer Vision (ICCV). 2015: 1440–1448.
- [76] LI Y, CHEN Y, WANG N, et al. Scale-Aware Trident Networks for Object Detection[C] // Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2019.
- [77] ZHANG H, CHANG H, MA B, et al. Dynamic R-CNN: Towards High Quality Object Detection via Dynamic Training[C] // Computer Vision – ECCV 2020. Cham: Springer International Publishing, 2020: 260–275.
- [78] CAO J, CHOLAKKAL H, ANWER R M, et al. D2Det: Towards High Quality Object Detection and Instance Segmentation[C] // 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 11482–11491.
- [79] GAO Z, WANG L, HAN B, et al. AdaMixer: A Fast-Converging Query-Based Object Detector[C] // 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 5354–5363.
- [80] REDMON J, FARHADI A. YOLO9000: Better, Faster, Stronger[C] // 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 6517–6525.
- [81] ZHOU X, WANG D, KRÄHENBÜHL P. Objects as points[J]. arXiv preprint arXiv:1904.07850, 2019.
- [82] NEWELL A, YANG K, DENG J. Stacked Hourglass Networks for Human Pose Estimation[C] // Computer Vision – ECCV 2016. Cham: Springer International Publishing, 2016: 483–499.
- [83] SIMONYAN K, ZISSERMAN A. Very Deep Convolutional Networks for Large-Scale Image Recognition[J]. CoRR, 2014, abs/1409.1556.
- [84] HE K, ZHANG X, REN S, et al. Deep Residual Learning for Image Recognition[C] // 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 770–778.
- [85] HUANG G, LIU Z, VAN DER MAATEN L, et al. Densely Connected Convolutional Networks[C] // 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 2261–2269.
- [86] HOWARD A G, ZHU M, CHEN B, et al. MobileNets: Efficient Convolutional Neural Networks

- for Mobile Vision Applications[J]. ArXiv, 2017, abs/1704.04861.
- [87] SANDLER M, HOWARD A, ZHU M, et al. MobileNetV2: Inverted Residuals and Linear Bottlenecks[C] // 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018 : 4510–4520.
- [88] HOWARD A, SANDLER M, CHEN B, et al. Searching for MobileNetV3[C] // 2019 IEEE/CVF International Conference on Computer Vision (ICCV). 2019 : 1314–1324.
- [89] HAN K, WANG Y, TIAN Q, et al. GhostNet: More Features From Cheap Operations[C] // 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020 : 1577–1586.
- [90] LIN T-Y, DOLLÁR P, GIRSHICK R, et al. Feature Pyramid Networks for Object Detection[C] // 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017 : 936–944.
- [91] LIU S, QI L, QIN H, et al. Path Aggregation Network for Instance Segmentation[C] // 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018 : 8759–8768.
- [92] REZATOFIGHI H, TSOI N, GWAK J, et al. Generalized intersection over union: A metric and a loss for bounding box regression[J]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2019 : 658–666.
- [93] ZHENG Z, WANG P, LIU W, et al. Distance-IoU loss: Faster and better learning for bounding box regression[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020, 34(07) : 12993–13000.
- [94] BODLA N, SINGH B, CHELLAPPA R, et al. Soft-NMS: Improving Object Detection With One Line of Code[C] // Proceedings of the IEEE International Conference on Computer Vision (ICCV). 2017 : 5562–5570.
- [95] NING C, ZHOU H, SONG Y, et al. Inception Single Shot MultiBox Detector for object detection[C] // 2017 IEEE International Conference on Multimedia and Expo Workshops (ICMEW). 2017 : 549–554.
- [96] TIAN Z, SHEN C, CHEN H, et al. FCOS: Fully Convolutional One-Stage Object Detection[C] // 2019 IEEE/CVF International Conference on Computer Vision (ICCV). 2019 : 9626–9635.
- [97] 王思雨, 高鑫, 孙皓, et al. 基于卷积神经网络的高分辨率 SAR 图像飞机目标检测方法 [J]. 雷达学报, 2017, 6(2): 195–203.
- [98] WANG J, SONG L, LI Z, et al. End-to-End Object Detection with Fully Convolutional Network[C] // 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021 : 15844–15853.
- [99] ZHANG S, CHI C, YAO Y, et al. Bridging the Gap Between Anchor-Based and Anchor-Free Detection via Adaptive Training Sample Selection[C] // 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020 : 9756–9765.

- [100] SUN P, JIANG Y, XIE E, et al. What Makes for End-to-End Object Detection?[C] // MEILA M, ZHANG T. Proceedings of Machine Learning Research, Vol 139 : Proceedings of the 38th International Conference on Machine Learning. [S.l.] : PMLR, 2021 : 9934 – 9944.
- [101] WU S, LI X, WANG X. IoU-aware single-stage object detector for accurate localization[J]. Image and Vision Computing, 2020, 97 : 103911.
- [102] NEUBECK A, VAN GOOL L. Efficient Non-Maximum Suppression[C] // 18th International Conference on Pattern Recognition (ICPR'06) : Vol 3. 2006 : 850 – 855.
- [103] DAI J, QI H, XIONG Y, et al. Deformable Convolutional Networks[C] // 2017 IEEE International Conference on Computer Vision (ICCV). 2017 : 764 – 773.
- [104] IOFFE S, SZEGEDY C. Batch normalization: accelerating deep network training by reducing internal covariate shift[C] // Proceedings of the 32nd International Conference on International Conference on Machine Learning : Vol 37. [S.l.] : JMLR.org, 2015 : 448–456.
- [105] WU Y, HE K. Group Normalization[C] // Computer Vision – ECCV 2018. Cham : Springer International Publishing, 2018 : 3 – 19.
- [106] WANG Y, DONG G, LIU H. Small Ship Detection via Deformable Convolutional Network[C] // 2021 IEEE International Geoscience and Remote Sensing Symposium IGARSS. 2021 : 3537 – 3540.
- [107] LI B, LIU B, GUO W, et al. Ship Size Extraction for Sentinel-1 Images Based on Dual-Polarization Fusion and Nonlinear Regression: Push Error Under One Pixel[J]. IEEE Transactions on Geoscience and Remote Sensing, 2018, 56(8) : 4887 – 4905.
- [108] YUE T, ZHANG Y, LIU P, et al. A Generating-Anchor Network for Small Ship Detection in SAR Images[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2022, 15 : 7665 – 7676.
- [109] LIU S, HUANG D. Learning Spatial Fusion for Single-Shot Object Detection[J], 2019.
- [110] 武俊杰, 孙稚超, 吕争, et al. 星源照射双/多基地 SAR 成像 [J]. 雷达学报, 2023, 12(1) : 13 – 35.
- [111] 张晓玲, 张天文, 师君, et al. 基于深度分离卷积神经网络的高速高精度 SAR 舰船检测 [J]. 雷达学报, 2019, 8(6) : 841 – 851.
- [112] YANG X, ZHANG X, WANG N, et al. A Robust One-Stage Detector for Multiscale Ship Detection With Complex Background in Massive SAR Images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60 : 1 – 12.
- [113] ZHANG X, LV Y, LIBO Y, et al. A New Benchmark and an Attribute-Guided Multi-Level Feature Representation Network for Fine-Grained Ship Classification in Optical Remote Sensing Images[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2020, PP(99) : 1 – 1.

- [114] 姚力波, 张筱晗, 吕亚飞, et al. FGSC-23: 面向深度学习精细识别的高分辨率光学遥感图像舰船目标数据集 [J]. 中国图象图形学报, 2021, 26(10): 9.
- [115] HOU X, AO W, SONG Q, et al. FUSAR-Ship: building a high-resolution SAR-AIS matchup dataset of Gaofen-3 for ship detection and recognition[J]. 中国科学: 信息科学 (英文版), 2020, 63(4): 36–54.
- [116] 冷祥光, 计科峰, 熊博莅, et al. 面向舰船目标检测的单通道复值 SAR 图像统计建模方法研究 [J]. 雷达学报, 2020, 9(3): 477–496.
- [117] 刘成城, 刘亚奇, 赵拥军, et al. 基于广义旁瓣对消器的 Laguerre 宽带波束形成 [J]. 雷达学报, 2015, 4(3): 295–300.
- [118] 丁昊, 董云龙, 刘宁波, et al. 海杂波特性认知研究进展与展望 [J]. 雷达学报, 2016, 5(5): 499–516.
- [119] 丁昊, 刘宁波, 董云龙, et al. 雷达海杂波测量试验回顾与展望 [J]. 雷达学报, 2019, 8(3): 281–302.
- [120] AIAZZI B, ALPARONE L, BARONTI S. Multiresolution local-statistics speckle filtering based on a ratio Laplacian pyramid[J]. IEEE Transactions on Geoscience and Remote Sensing, 1998, 36(5): 1466–1476.
- [121] ARGENTI F, LAPINI A, BIANCHI T, et al. A Tutorial on Speckle Reduction in Synthetic Aperture Radar Images[J]. IEEE Geoscience and Remote Sensing Magazine, 2013, 1(3): 6–35.
- [122] YUE D-X, XU F, FRERY A C, et al. Synthetic Aperture Radar Image Statistical Modeling: Part Two-Spatial Correlation Models and Simulation[J]. IEEE Geoscience and Remote Sensing Magazine, 2021, 9(1): 115–138.
- [123] WANIELIK G, STOCK D. A new clutter rejection method using a robust polarimetric CFAR-detector[J]. IEEE Aerospace and Electronic Systems Magazine, 1990, 5(6): 7–10.
- [124] WANG R, SHAO S, AN M, et al. Soft Thresholding Attention Network for Adaptive Feature Denoising in SAR Ship Detection[J]. IEEE Access, 2021, 9: 29090–29105.
- [125] MISHIBA K. Fast Guided Median Filter[J]. IEEE Transactions on Image Processing, 2023, 32: 737–749.
- [126] ZHONG H, ZHANG J, LIU G. Robust Polarimetric SAR Despeckling Based on Nonlocal Means and Distributed Lee Filter[J]. IEEE Transactions on Geoscience and Remote Sensing, 2014, 52(7): 4198–4210.
- [127] SUN Z, ZHANG Z, CHEN Y, et al. Frost Filtering Algorithm of SAR Images With Adaptive Windowing and Adaptive Tuning Factor[J]. IEEE Geoscience and Remote Sensing Letters, 2020, 17(6): 1097–1101.
- [128] CARAFFA L, TAREL J-P, CHARBONNIER P. The Guided Bilateral Filter: When the Joint/Cross

- Bilateral Filter Becomes Robust[J]. IEEE Transactions on Image Processing, 2015, 24(4): 1199–1208.
- [129] CHOI K, SONG T, KIM S, et al. Deep Cascade Network for Noise-Robust SAR Ship Detection With Label Augmentation[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19: 1–5.
- [130] ZHA C, MIN W, HAN Q, et al. SAR ship localization method with denoising and feature refinement[J]. Engineering Applications of Artificial Intelligence, 2023, 123: 106444.
- [131] ZHAO C, FU X, DONG J, et al. LPDNet: A Lightweight Network for SAR Ship Detection Based on Multi-Level Laplacian Denoising[J]. Sensors, 2023, 23(13).
- [132] LI X, ZHOU L, WU H, et al. A Min-Pooling Detection Method for Ship Targets in Noisy SAR Images[J]. IEEE Access, 2023, 11: 31902–31911.
- [133] LI H-C, KRYLOV V A, FAN P-Z, et al. Unsupervised Learning of Generalized Gamma Mixture Model With Application in Statistical Modeling of High-Resolution SAR Images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2016, 54(4): 2153–2170.
- [134] WANG X, CHEN C, PAN Z, et al. Fast and Automatic Ship Detection for SAR Imagery Based on Multiscale Contrast Measure[J]. IEEE Geoscience and Remote Sensing Letters, 2019, 16(12): 1834–1838.
- [135] ZHANG L, LIU Y, ZHAO W, et al. Frequency-Adaptive Learning for SAR Ship Detection in Clutter Scenes[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1–14.
- [136] YANG M, GUO C. Ship Detection in SAR Images Based on Lognormal ρ -Metric[J]. IEEE Geoscience and Remote Sensing Letters, 2018, 15(9): 1372–1376.
- [137] SHI J, GHAZZAI H, MASSOUD Y. Differentiable Image Data Augmentation and Its Applications: A Survey[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 46(2): 1148–1164.
- [138] MUMUNI A, MUMUNI F. Data augmentation: A comprehensive survey of modern approaches[J]. Array, 2022, 16: 100258.
- [139] SHORTEN C, KHOSHGOFTAAR T. A survey on Image Data Augmentation for Deep Learning[J]. Journal of Big Data, 2019, 6.
- [140] HAO X, LIU L, YANG R, et al. A Review of Data Augmentation Methods of Remote Sensing Image Target Recognition[J]. Remote Sensing, 2023, 15(3).
- [141] ZHANG H, CISSE M, DAUPHIN Y, et al. mixup: Beyond Empirical Risk Minimization[J], 2017.
- [142] LI J, YU Z, YU L, et al. A Comprehensive Survey on SAR ATR in Deep-Learning Era[J]. Remote Sensing, 2023, 15(5).
- [143] GENG Z, XU Y, WANG B-N, et al. Target Recognition in SAR Images by Deep Learning with Training Data Augmentation[J]. Sensors, 2023, 23(2).

- [144] AGARWAL T, SUGAVANAM N, ERTIN E. Sparse Signal Models for Data Augmentation in Deep Learning ATR[C] // 2020 IEEE Radar Conference (RadarConf20). 2020 : 1 – 6.
- [145] ZHAI Y, MA H, LIU J, et al. SAR ATR with full-angle data augmentation and feature polymerisation[J]. The Journal of Engineering, 2019, 2019(19) : 6226 – 6230.
- [146] DING J, CHEN B, LIU H, et al. Convolutional Neural Network With Data Augmentation for SAR Target Recognition[J]. IEEE Geoscience and Remote Sensing Letters, 2016, 13(3) : 364 – 368.
- [147] SASAKI H, WILLCOCKS C G, BRECKON T P. Data Augmentation via Mixed Class Interpolation using Cycle-Consistent Generative Adversarial Networks Applied to Cross-Domain Imagery[C] // 2020 25th International Conference on Pattern Recognition (ICPR). 2021 : 5083 – 5090.
- [148] YANG R, WANG R, DENG Y, et al. Rethinking the Random Cropping Data Augmentation Method Used in the Training of CNN-Based SAR Image Ship Detector[J]. Remote Sensing, 2021, 13(1).
- [149] SONG T, KIM S, KIM S, et al. Context - Preserving Instance- Level Augmentation and Deformable Convolution Networks for SAR Ship Detection[C] // 2022 IEEE Radar Conference (RadarConf22). 2022 : 1 – 6.
- [150] SUO Z, ZHAO Y, CHEN S, et al. BoxPaste: An Effective Data Augmentation Method for SAR Ship Detection[J]. Remote Sensing, 2022, 14(22).
- [151] 康健, 童风雨, 白雨松, et al. 基于对数域加性信号分解的时序 SAR 图像相干斑抑制方法 [J]. 雷达学报, 2023, 12(5) : 1031 – 1043.
- [152] TARAVAT A, LATINI D, DEL FRATE F. Fully Automatic Dark-Spot Detection From SAR Imagery With the Combination of Nonadaptive Weibull Multiplicative Model and Pulse-Coupled Neural Networks[J]. IEEE Transactions on Geoscience and Remote Sensing, 2014, 52(5) : 2427 – 2435.
- [153] JOUGHIN I, PERCIVAL D, WINEBRENNER D. Maximum likelihood estimation of K distribution parameters for SAR data[J]. IEEE Transactions on Geoscience and Remote Sensing, 1993, 31(5) : 989 – 999.
- [154] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. ImageNet classification with deep convolutional neural networks[J]. Commun. ACM, 2017, 60(6) : 84–90.
- [155] ZHOU Z, ZHAO L, JI K, et al. A Domain-Adaptive Few-Shot SAR Ship Detection Algorithm Driven by the Latent Similarity Between Optical and SAR Images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62 : 1 – 18.
- [156] WANG Z, HOU G, XIN Z, et al. Detection of SAR Image Multiscale Ship Targets in Complex Inshore Scenes Based on Improved YOLOv5[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2024, 17 : 5804 – 5823.
- [157] 李宁, 郭志顺, 毋琳, et al. River-Net: 面向河道提取的 Refined-Lee Kernel 深度神经网络模型

- [J]. 雷达学报, 2022, 11(3): 324–334.
- [158] SALEEM A, ALVER M B, ÇETIN M. SAR Image Despeckle With CNN Using a Novel Logarithmic Discrete Cosine Transform-Based Loss[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2024, 17: 15525–15542.
- [159] ZHAO C, FU X, DONG J, et al. MLC-Net: A Robust SAR Ship Detector With Speckle Noise and Multiscale Targets[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2024, 17: 19260–19273.
- [160] WANG Y, DONG G, SHAO S, et al. A Prediction and Prior Information Guided SAR Ship Detection Method[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2023, 16: 7076–7088.
- [161] PAN X, HAN M, LIAO G, et al. SFFNet: A Ship Detection Method Using Scattering Feature Fusion for Sea Surface SAR Images[J]. IEEE Geoscience and Remote Sensing Letters, 2024, 21: 1–5.
- [162] ZHANG J, SHENG W, ZHU H, et al. MLBR-YOLOX: An Efficient SAR Ship Detection Network With Multilevel Background Removing Modules[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2023, 16: 5331–5343.
- [163] GUO H, GU D. Closely arranged inshore ship detection using a bi-directional attention feature pyramid network[J]. International Journal of Remote Sensing, 2023, 44(22): 7106–7125.
- [164] CHEN Z, DING Z, ZHANG X, et al. Inshore Ship Detection Based on Multi-Modality Saliency for Synthetic Aperture Radar Images[J]. Remote Sensing, 2023, 15(15).
- [165] CHENG J, XIANG D, TANG J, et al. Inshore Ship Detection in Large-Scale SAR Images Based on Saliency Enhancement and Bhattacharyya-like Distance[J]. Remote Sensing, 2022, 14(12).
- [166] DAI Y, ZOU M, LI Y, et al. DenoDet: Attention as Deformable Multi-Subspace Feature Denoising for Target Detection in SAR Images[J]. IEEE Transactions on Aerospace and Electronic Systems, 2024: 1–17.
- [167] GUO Y, LIAO G, LI J, et al. A Clutter Suppression Method Based on NSS-RPCA in Heterogeneous Environments for SAR-GMTI[J]. IEEE Transactions on Geoscience and Remote Sensing, 2020, 58(8): 5880–5891.
- [168] SALEHI H, VAHIDI J, ABDELJAWAD T, et al. A SAR Image Despeckling Method Based on an Extended Adaptive Wiener Filter and Extended Guided Filter[J]. Remote Sensing, 2020, 12(15).
- [169] MURALIMOCHANBABU Y, SUBRAMANYAM M V, GIRIPRASAD M. A Modified BM3D Algorithm for SAR Image Despeckling[J]. Procedia Computer Science, 2015, 70: 69–75.
- [170] 尹奎英, 刘宏伟, 金林. 快速的 Otsu 双阈值 SAR 图像分割法 [J]. 吉林大学学报 (工学版), 2011, 41(6): 1760–1765.

- [171] WANG L, QIN H, ZHOU X, et al. R-YOLO: A Robust Object Detector in Adverse Weather[J]. IEEE Transactions on Instrumentation and Measurement, 2023, 72 : 1 – 11.
- [172] RICHARDS M A. Fundamentals of Radar Signal Processing, Second Edition[M]. [S.l.] : Fundamentals of Radar Signal Processing, Second Edition, 2005.
- [173] REED I, MALLETT J, BRENNAN L. Rapid Convergence Rate in Adaptive Arrays[J]. IEEE Transactions on Aerospace and Electronic Systems, 1974, AES-10(6) : 853 – 863.
- [174] 张问一, 胡东辉, 丁赤飏. 基于 FABEMD 和 Goldstein 滤波器的 SAR 舰船尾迹图像增强方法[J]. 雷达学报, 2012, 1(4) : 426 – 435.
- [175] YUAN S, YU Z, LI C, et al. A Novel SAR Sidelobe Suppression Method Based on CNN[J]. IEEE Geoscience and Remote Sensing Letters, 2021, 18(1) : 132 – 136.
- [176] AI J, FAN G, MAO Y, et al. An Improved SRGAN Based Ambiguity Suppression Algorithm for SAR Ship Target Contrast Enhancement[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19 : 1 – 5.
- [177] ZHU H, YU Z, YU J. Sea Clutter Suppression Based on Complex-Valued Neural Networks Optimized by PSD[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2022, 15 : 9821 – 9828.
- [178] HUA Q, YUN Z, MU H, et al. An Approach of Sea Clutter Suppression for SAR Images by Self-Supervised Complex-Valued Deep Learning[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19 : 1 – 5.
- [179] XU C, WANG Q, WANG X, et al. Wake2Wake: Feature-Guided Self-Supervised Wave Suppression Method for SAR Ship Wake Detection[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62 : 1 – 14.
- [180] 李光廷, 杨亮, 黄平平, et al. SAR 图像相干斑抑制中的像素相关性测量 [J]. 雷达学报, 2012, 1(3) : 301 – 308.
- [181] LIU Y, ZHU H, LIU M, et al. Rolling-Unet: Revitalizing MLP’ s Ability to Efficiently Extract Long-Distance Dependencies for Medical Image Segmentation[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2024, 38(4) : 3819 – 3827.
- [182] CUI Z, LI Q, CAO Z, et al. Dense Attention Pyramid Networks for Multi-Scale Ship Detection in SAR Images[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 57(11) : 8983 – 8997.
- [183] XU L, PANG C, GUO Y, et al. Combinational Fusion and Global Attention of the Single-Shot Method for Synthetic Aperture Radar Ship Detection[J]. Remote Sensing, 2021, 13(23).
- [184] HAN L, RAN D, YE W, et al. Multi-Size Convolution and Learning Deep Network for SAR Ship Detection From Scratch[J]. IEEE Access, 2020, 8 : 158996 – 159016.

- [185] ZHANG Y, WANG X, JIANG Z, et al. An Efficient Center-Based Method With Multilevel Auxiliary Supervision for Multiscale SAR Ship Detection[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2022, 15 : 7065 – 7075.
- [186] LV Y, LI M, HE Y, et al. Adaptively Center-Shape Sensitive Sample Selection for Ship Detection in SAR Images[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2022, 15 : 6752 – 6765.