

海杂波背景下的小目标智能检测

作者姓名_____樊世纪_____

学校导师姓名、职称_____兰岚 副教授_____

企业导师姓名、职称_____贺伟 研究员_____

申请学位类别_____电子信息硕士_____

学校代码 10701
分 类 号 TN95

学 号 22021211738
密 级 公开

西安电子科技大学

硕士学位论文

西安电子科技大学 硕士学位论文题目

作者姓名：樊世纪

领 域：新一代电子信息技术（含量子技术等）

学位类别：电子信息硕士

学校导师姓名、职称：兰岚 副教授

企业导师姓名、职称：贺炜 研究员

学 院：电子工程学院

提交日期：2025 年 6 月

Research on Small Target Detection Methods on the Sea Surface Based on Deep Learning

A thesis submitted to
XIDIAN UNIVERSITY
in partial fulfillment of the requirements
for the degree of Master
in Electronics Science and Technology

By

Fan Shiji

Supervisor: Lan Lan Title: Associate Professor

May 2025

摘要

海面小目标检测是维护海洋权益、保障海上安全的关键技术。传统统计模型在高分辨率雷达观测下存在显著局限性，海杂波的非高斯性、非平稳性等特性导致统计模型失配，而多特征联合检测虽能提升检测性能，却面临多维数据处理复杂、深度学习模型不适配等难题。本文针对上述问题展开研究，提出创新性的解决方案并通过实验验证了其有效性，主要研究内容如下：

（1）针对高分辨对海探测场景中海杂波统计特性复杂多变的问题，通过实测数据验证了传统统计模型的局限性。基于 IPIX 雷达实测数据集对瑞利分布、对数正态分布、韦布尔分布和 K 分布进行拟合分析，发现 K 分布虽在多数场景下拟合效果最优，但仍无法完全表征高分辨率体制雷达观测下海杂波的时空特性。本文进一步结合时频分析方法，量化了海杂波时频多特征的变化特性，为后续特征检测工程提供了理论支撑。这一基础性研究不仅明确了传统检测方法的性能瓶颈，更为深度学习模型的构建提供了关键先验知识。

（2）针对多特征检测与深度学习模型不适配的难题，提出基于三通道特征映射的图像预处理方法。通过将相对平均幅度、相对多普勒峰高和相对向量熵三个关键特征归一化映射至 RGB 通道，构建单图多特征表征模式。该方法使输入数据量在保留三特征关键信息的同时，减少了总体数据输入量。处理后的数据在 SSD 模型，YOLO 模型以及 DETR 这些单阶段模型中训练检测，都取得了不错的效果。首次将上述单阶段模型引入海面小目标多特征检测领域，解决了传统多图输入导致的模型复杂度倍增问题。

（3）针对模型参数量大，训练时间长以及虚警率难以控制问题，设计轻量化改进的 YOLOv8n 模型架构，根据第三章所提多特征图像预处理的特点，在不改变检测准确度的情况下，删除 YOLO 模型中三个尺寸的检测头中的两个，减少了模型参数量，缩短了训练时间。另外通过改进 C2f 模块降低了参数量，引入 CBAM 注意力机制增强了特征区分度并且根据第三章得到的训练集标注框特点改进了损失函数。对于虚警率问题，通过改进训练流程实现虚警率可控。最后，在公开的 IPIX 雷达数据集上做了对比实验，验证了该方法的有效性，为深度学习技术在海面小目标检测中的应用提供了全新的思路。

关键词：海面小目标，三特征检测，深度学习，特征映射

ABSTRACT

Maritime small-target detection is crucial for safeguarding maritime rights and security. Traditional statistical models show significant limitations in high-resolution radar observations due to the non-Gaussian and non-stationary characteristics of sea clutter, which lead to model mismatch. Although multi-feature joint detection can enhance performance, it faces challenges like complex multi-dimensional data processing and incompatibility with deep learning models. This paper addresses these issues, proposing innovative solutions and validating their effectiveness through experiments. The key research contents are as follows:

(1) To tackle the complex and time-varying statistical characteristics of sea clutter in high-resolution maritime detection scenarios, traditional statistical models were validated for their limitations using real measurement data. Fitting analyses of Rayleigh, log-normal, Weibull, and K - distributions were performed based on the IPIX radar dataset. Although the K - distribution generally offers the best fit, it still cannot fully capture the spatio-temporal characteristics of sea clutter under high-resolution radar observations. This paper further combines time-frequency analysis to quantify the changes in sea clutter's time-frequency features, providing theoretical support for subsequent feature detection. This foundational research not only clarifies the performance limitations of traditional detection methods but also offers key prior knowledge for constructing deep learning models.

(2) To address the incompatibility between multi-feature detection and deep learning models, this paper proposes an image preprocessing method based on three-channel feature mapping. Three key features—relative average amplitude, relative Doppler peak height, and relative vector entropy—are normalized and mapped to the RGB channels to create a single-image multi-feature representation. This approach reduces the overall data input while preserving the essential information of the three features. The processed data achieved good results in training and detection using single-stage models like SSD, YOLO, and DETR. This is the first time single-stage models have been applied to multi-feature detection of maritime small targets, resolving the issue of doubled model complexity from traditional multi-image inputs.

(3) To solve the issues of large model parameters, long training time, and difficulty in controlling the false alarm rate, this paper designs a lightweight improved YOLOv8n model

architecture. Based on the multi-feature image preprocessing characteristics mentioned in Chapter 3, two of the three detection heads in the YOLO model are removed without sacrificing detection accuracy, reducing the model's parameters and training time. The C2f module is improved to cut down parameters, and the CBAM attention mechanism is introduced to enhance feature distinction. The loss function is also refined based on the training set annotation box characteristics from Chapter 3. For the false alarm rate problem, the training process is improved to make it controllable. Finally, comparative experiments on the public IPIX radar dataset confirm the effectiveness of this method, offering a new approach for deep learning applications in maritime small-target detection.

Keywords: Maritime small targets, Triple-feature detection, Deep learning, Feature mapping

插图索引

图 1.1	海面低慢小目标	2
图 1.2	IPIX 数据集数据分析	8
图 2.1	瑞利分布 PDF	13
图 2.2	对数正态分布 PDF	14
图 2.3	威布尔分布的 PDF	15
图 2.4	K 分布的 PDF	17
图 2.5	不同分布对海杂波的拟合结果	18
图 2.6	IPIX 雷达实测数据时频分析	20
图 2.7	不同距离单元的相对平均幅度图	21
图 2.8	不同距离单元的相对多普勒峰高	22
图 2.9	不同距离单元的相对多普勒向量熵	23
图 2.10	实测雷达幅度回波 PPI 图及 RGB 三通道图	25
图 3.1	深度学习模型图像处理方法	28
图 3.2	Mosaic 数据增强算法流程图	31
图 3.3	图像处理的最大池化表示	32
图 3.4	单特征数据图像化处理	36
图 3.5	数据预处理流程图	37
图 3.6	现有的三特征处理方法	38
图 3.7	本文所提的三特征处理方法	39
图 3.8	SSD 网络模型结构	40
图 3.9	DETR 网络模型结构	43
图 4.1	YOLOv8n 的检测网络模型	54
图 4.2	SE 模块结构	55
图 4.3	C2f-ME 模块结构	55
图 4.4	通道注意力机制模型结构	56
图 4.5	空间注意力机制模型结构	57
图 4.6	改进的 YOLOv8-CHINS 结构	58
图 4.7	CBAM 注意力机制模型	59
图 4.8	所提控制虚警方法流程图	60
图 4.9	四种极化数据的混淆矩阵对比图	62
图 4.10	四种极化数据的 F1 置信曲线对比图	63

图 4.11	四种极化数据的 PR 曲线对比图.....	64
图 4.12	四种极化数据的结果对比图	65
图 4.13	模型预测效果图	66
图 4.14	训练轮数和平均置信度的关系	70
图 4.15	训练轮数和平均检测概率的关系	70
图 4.16	训练轮数不同时所实现的虚警率变化图	71

表格索引

表 1.1	数据集描述.....	7
表 3.1	多特征信息预处理前后数据量对比.....	44
表 3.2	多特征信息预处理前检测器的平均检测概率.....	45
表 3.3	多特征信息预处理后检测器的平均检测概率.....	45
表 3.4	多特征信息预处理前检测器的实际虚警率.....	46
表 3.5	多特征信息预处理后检测器的实际虚警率.....	46
表 3.6	多特征信息预处理前训练时间对比.....	47
表 3.7	多特征信息预处理后训练时间对比.....	47
表 3.8	多特征信息预处理前模型大小对比.....	48
表 3.9	多特征信息预处理后模型大小对比.....	48
表 4.1	在 IPIX 数据库上检测器的平均检测概率	67
表 4.2	在 IPIX 数据库上检测器的平均虚警率	67
表 4.3	消融实验结果.....	68
表 4.4	训练轮数和平均置信度以及检测概率的关系.....	69
表 4.5	所提检测器 IPIX 雷达数据集上实现的虚警概率	71

符号对照表

符号	符号名称
$\exp(\cdot)$	指数函数
$\sqrt{\cdot}$	开平方
$\Gamma(\cdot)$	伽马函数
$ \cdot $	取模或行列式
Σ	求和
E	误差
W	权重
$\mathcal{D}$	域
$[\cdot]^T$	转置
f_d	多普勒频率
T_r	脉冲重复频率
$\#$	数目
$\exp(\cdot)$	指数函数
$\Gamma(\cdot)$	伽马函数
$(\cdot)'$	求导
$\ln(\cdot)$	自然对数
$E\{\cdot\}$	数学期望 / 取均值
$\text{var}(\cdot)$	方差
$\max(\cdot)$	最大值
$\min(\cdot)$	最小值
Σ	求和

缩略语对照表

缩略语	英文全称	中文对照
RCS	Radar Cross Section	雷达散射截面积
SCR	Signal to Clutter Ratio	信杂比
CFAR	Constant False Alarm Rate	恒虚警率
GLRT	Generalized Likelihood Ratio Test	广义似然比检测
CGM	Compound Gaussian Model	复合高斯模型
PDF	Probability Density Function	概率密度函数
STFT	Short-Time Fourier Transform	短时傅里叶变换
FRTF	Fractional Fourier Transform	分数阶傅里叶变换
SVM	Support Vector Machine	支持向量机
WVD	Wigner-Ville Distribution	魏格纳维尔分布
CNN	Convolutional Neural Network	卷积神经网络
RAA	Relative Average Amplitude	相对平均幅度
RDPH	Relative Doppler Peak High	相对多普勒峰高
RVE	Relative Doppler Vector Entropy	相对多普勒熵
DBF	Digital Beam Forming	数字波束形成
FFT	Fast Fourier Transformation	快速傅里叶变换
MIMO	Multiple-Input-Multiple-Output	多输入多输出
ML	Maximum Likelihood	最大似然
NHE	Normalized Hurst Exponent	归一化 Hurst 指数
KNN	K-Nearest Neighbor	K 近邻
PRF	Pulse Repetition Frequency	脉冲重复频率
PRI	Pulse Repetition Interval	脉冲重复间隔

目录

摘要	I
ABSTRACT	III
插图索引	V
表格索引	VII
符号对照表	IX
缩略语对照表	XI
第一章 绪论	1
1.1 研究背景及意义	1
1.2 国内外研究现状	3
1.2.1 基于统计模型的目标检测方法	3
1.2.2 基于数据驱动的目标检测方法	5
1.3 实测海杂波数据集介绍	6
1.4 论文研究内容和章节安排	8
第二章 海杂波特性与深度学习	11
2.1 引言	11
2.2 海杂波统计特性	12
2.3 海杂波频谱特性	18
2.4 特征检测方法	20
2.5 深度学习与特征检测	23
2.6 本章小结	26
第三章 基于海面小目标多特征图像预处理的智能检测	27
3.1 引言	27
3.2 深度学习模型图像处理方法及原理介绍	28
3.2.1 图像处理基本方法	28
3.2.2 层归一化与卷积	28
3.2.3 图像增强	30
3.2.4 池化与非线性激活	31
3.2.5 输出投影及推理	34
3.3 海面小目标多特征图像预处理方法	35
3.3.1 单特征数据图像化存在问题	35
3.3.2 多特征数据图像化方法	36

3.3.3 多特征数据图像化处理优势.....	38
3.4 基于多特征图像预处理的深度学习检测	39
3.4.1 SSD 模型.....	40
3.4.2 YOLO 系列模型	41
3.4.3 DETR 模型.....	42
3.5 实验结果与检测性能分析	44
3.5.1 实验平台配置.....	44
3.5.2 多特征图像预处理前后输入的数据量对比.....	44
3.5.3 多特征图像预处理前后深度学习网络参数对比.....	46
3.6 本章小结	49
第四章 基于多特征图像预处理的改进深度学习模型检测	51
4.1 引言	51
4.2 深度学习模型网络结构	51
4.3 YOLOv8 的网络模型改进	54
4.3.1 C2f 模块的改进	54
4.3.2 CBAM 模块的引进	56
4.3.3 损失函数改进.....	57
4.3.4 改进后的模型结构.....	58
4.4 可控虚警率的训练流程改进	59
4.5 实验结果与检测性能分析	61
4.5.1 实验平台配置.....	61
4.5.2 雷达回波数据检测效果分析.....	61
4.5.3 流程改进后的检测效果对比分析.....	68
4.6 本章小结	72
第五章 总结与展望	73
5.1 全文总结	73
5.2 未来展望	73
参考文献.....	75
致谢.....	83
作者简介	85

第一章 绪论

1.1 研究背景及意义

随着全球战略重心逐步向亚太地区转移，中国在海洋安全领域面临的挑战日益加剧，特别是在东海和南海等海域。这些海域地理环境复杂，在海面上出现的目标类型很多，其中不乏潜在的威胁，例如小型船只、潜艇及其他低速缓慢的小型目标。对海面小目标的全天候实时检测，不仅有助于提升我国对领海的掌控力，还能确保丝绸之路海上通道的安全畅通。随着中国对外开放程度的逐步提升，经济安全与战略通道的防护也愈加依赖强大的海上力量。因此，深入开展海面小目标检测技术的研究，提供海面小目标的精确检测手段，对提升国家防御体系的整体能力，维护海洋生态有重要意义。海面小目标的检测技术不仅关乎国家安全，还直接影响到中国在国际事务中的影响力与话语权。借助先进的检测技术，我们能够及时识别并应对潜在的威胁，如非法入侵、海上走私、海盗袭击及恐怖活动，进而增强国家的防御能力。此外，海面小目标检测的进步还对海洋环境保护、灾害预警等方面起到了积极作用。面对日益频繁的台风及其他自然灾害，准确的海上监测能够提供有效的灾害预警，减轻人员和财产损失。同时，对于保护海洋生物多样性、打击非法捕鱼等行为，海面小目标检测也能为执法部门提供技术支持，有助于维护海洋生态的安全与可持续性。

随着科学技术的迅猛发展，雷达技术在海洋监测和目标识别中发挥着越来越重要的作用，成为海战和海上探测中的关键。然而，随着海上目标向小型化和隐身化方向发展，传统雷达技术面临越来越多的挑战，特别是在海杂波处理和小目标探测方面。

当前，海上雷达面临的主要技术挑战可以概括为三个方面：（1）传统低分辨率雷达在探测小型目标时的“临界信杂比（Signal-to-Clutter Ratio, SCR）”问题；（2）高分辨率小目标探测雷达的空间和多普勒分辨率限制；（3）高分辨率快速扫描反潜雷达在探测小型目标时的困难。尤其是在雷达分辨率较低的情况下，虽然大中型舰船目标的检测较为简单，但对于无人艇、蛙人、潜望镜等小目标的识别却极具挑战。为此，必须在提升雷达系统分辨率的同时，采用更加精细的目标识别技术。高空间分辨率和高多普勒分辨率的“双高”雷达体制，是提高小目标探测精度的有效手段。如图 1.1 所示，这些小目标的回波信号较弱，雷达截面积也很小，使得中低分辨率雷达难以有效检测^[1]。



图1.1 海面低慢小目标

在海杂波环境下，漂浮小目标检测与分类的主要挑战在于微弱目标回波与复杂海洋环境的相互作用，海杂波的空时特性表现为长时间非平稳和短时间平稳，以及整体非均匀和局部均匀的复杂特点^[2]。在高分辨雷达技术不断发展的进程中，传统杂波模型在精确描绘实际海杂波微观特征方面逐渐暴露出局限性。海洋动力学研究表明，在流体力学作用机制下，波浪相互作用引发的类镜面反射机制，易产生与真实目标电磁散射特征高度近似的高反射强度海尖峰，该现象对雷达探测系统构成显著干扰源。这种物理机制会导致雷达系统虚警率升高。与此同时，现代电子战环境中趋向小型化的漂浮目标具有极低的雷达散射截面（Radar Cross Section, RCS），使得目标回波的 SCR 常处于临界可检测水平。更严峻的是，这类目标在运动维度上受限于有限的速度范围和随机遮挡效应，其多普勒特征易被海杂波的宽频带覆盖，回波信号还表现出完全不确定的 RCS 起伏，传统方法对计算资源的过度依赖与复杂参数调校需求构成了双重制约^[3]。基于手工特征设计的检测框架难以有效区分海尖峰与真实目标的细微差异，而海杂波样本与目标样本的数量失衡问题更会引发机器学习模型的决策偏置，导致检测概率下降与虚警点迹密集化。这种样本非平衡性不仅影响分类器性能，还会加剧杂波模型与真实环境的失配程度。此外，传统方法在特征提取维度上存在固有局限：统计特征难以捕捉海杂波的非平稳特性，时频分析对复杂调制信号的分辨力不足，而基于物理模型的方法又无法适应动态变化的海洋环境。

从上述研究可以看出智能方法对这些技术瓶颈展现出突破性潜力。通过构建深度神经网络架构，可实现从原始雷达数据到目标决策的端到端学习，有效

规避人工特征设计的主观偏差，这些技术特性有效解决了传统方法环境适应性差的核心痛点。不仅能提升对隐身目标、微型无人艇等新型威胁的预警能力，还可为海洋资源勘探、海上搜救等民用领域提供技术支撑。随着雷达智能感知理论与边缘计算技术的深度融合，未来可望构建具有环境自感知、算法自演进能力的智能化雷达系统，这既是落实海洋强国战略的关键技术路径，也是新质战斗力生成的重要突破口。

1.2 国内外研究现状

1.2.1 基于统计模型的目标检测方法

海上小型慢速目标的探测对海雷达系统的关键任务之一，这类目标包括航标、小型船舶等，其在雷达中的回波信号往往较弱。在“双高”体制下，即高多普勒和高距离分辨率的雷达监控环境中，海杂波呈现非平稳、非均匀以及非高斯特性。这些特性增加了小目标运动模型的复杂性，使得传统检测方法难以直接应用。特别是在高分辨率、低入射角和高海况条件下，海尖峰现象经常发生，进一步增加了传统非相干检测技术与自适应相干检测技术在有效识别这类低速小型目标的难度^[1]。

起初，由于硬件条件的限制，雷达的分辨率相对较低，学术界普遍采用中心极限定理来认为高斯分布可以近似描述海杂波的特性，其幅度通常被认为符合瑞利分布^[2]。随着雷达技术的进步分辨率也随之上升，海面杂波的非高斯特性更加显著，研究人员开始提出更精确的双参数模型，这些模型不仅能更好地捕捉杂波数据中的长尾特性，还能有效描述杂波的剧烈波动情况。需要注意的是，这些统计模型主要基于对杂波数据的统计拟合，与杂波生成的散射机制并无直接关联。在此背景下，研究人员结合海杂波的物理散射机制，提出了复合高斯模型（Compound-Gaussian Model, CGM）^[3]，这一模型将杂波描述为散斑与纹理的组合。在此基础上，针对复合高斯模型中的相干雷达信号，Richmond 与 Conte 团队创新性地开发了自适应归一化匹配滤波器及其基准型普通归一化匹配滤波器^[4]，进一步提升了检测效果，尤其是针对纹理分量为正随机变量的情况。

进一步的研究发现，纹理分量服从逆高斯、Gamma 及其逆分布的特征，为多场景自适应检测器的构建提供了概率学基础。Ward 教授建立的复合 K 分布模型^[5]，在提升海杂波建模精度方面取得突破，该模型通过统计参数优化，有效表征了杂波的长拖尾特性及其时空相关性特征^[6]。基于此理论框架，Jay 与 Dong 团队推导出基于 K 分布的贝叶斯最优检测器及相干检测架构^[7]，而 Shang 则构建了高斯-逆纹理混合模型的检测器拓扑结构^[8]。许述文团队在逆高斯纹理复合高斯分布体系下，完善了广义似然比检测门限的数学表征方法^[9]。

针对海杂波的物理生成机理,学界已形成多维度研究体系。许小剑系统论证了海杂波生成机制与海水重力波、风浪扰动的关联性,并定量揭示了其与雷达极化方式、入射余角及系统参数的耦合关系^[10]。Rosenberg 基于重力-极化耦合机理,深入解析了非布拉格散射机制,成功构建了海杂波多普勒谱的物理模型^[11]。进一步地,Rosenberg 与 Bocquet 通过设计低-中掠射角雷达联合实验,提出了描述杂波时间和距离演化的多普勒谱特性^[12]。Huang 则建立了多通道杂波模型,描述了海杂波的时空后向散射系数,并通过仿真结合实测数据验证了理论模型的有效性^[13]。

很多学者使用时频分析技术对目标信号在海杂波背景下的特征进行了提取和检测。Duk 团队创新性地构建了海杂波多尺度小波分解模型^[14],通过时频域信号重构技术实现了目标回波与海浪背景的谱特征分离。在微动特征提取领域,陈小龙等学者开发了短时稀疏时频分析框架,结合分数阶域模糊函数算法,有效提升了微多普勒特征的辨识精度^[15]。关键等人则利用相干积累和稀疏傅里叶变换,对弱小目标进行了精细化分析,获得了较好的检测效果^[16]。特别值得注意的是,Decurninge 与 Barbaresco 建立的协方差矩阵重构技术^[17],通过优化脉冲序列的统计特性估计,显著抑制了短时脉冲场景下的谱泄漏效应,增强了检测系统的鲁棒性。值得关注的是 Yan 提出的图信号表征体系^[18],在低信噪比环境下表现出良好的检测性能,特别适用于高分辨率雷达的舰船轨迹追踪与目标分类任务。

海杂波分形建模领域近年取得显著进展。Fan 为了解决传统傅里叶变换在时域和频域中的不足,提出了基于自回归谱的联合分形特征方法,该方法通过融合分形维数与 Hurst 指数的多维特征提取框架,结合支持向量机的分类机制,成功实现了低信噪比的弱目标检测^[19]。Xu 则提出了一种改进的隔离森林方法,利用多特征融合和蒙特卡罗方法,设计了一个新的多特征检测器,在 IPIX 雷达实测海况数据验证中,大幅降低了计算成本^[20]。

这些研究都说明了,基于统计模型的杂波检测技术难以适应海面小目标的检测需求。在实际场景中,杂波背景的多样性以及模型失配的影响,限制了传统检测方法的适用范围。因此,设计适应性更强的检测器,并探索新的特征提取和信号处理方法,是未来海面杂波检测领域的主要发展方向^{[21]-[23]}。

针对基于能量累积和统计模型分布的检测方法所面临的挑战,特征检测技术提供了有效的解决方案。在该技术初期,大部分方法侧重于单一特征种类的多变换域提取。随着技术的发展,多特征联合检测逐渐成为主流,其检测性能和鲁棒性显著提高。在此背景下,有研究者首次提出了一种基于三种特征的检测器,这三种特征分别是相对平均幅度(Relative Average Amplitude, RAA)、相对多普勒向量熵(Relative Vector Entropy, RVE)和相对多普勒峰高(Relative Doppler Peak Height, RDPH)^[21]。虽然利用多维特征进行联合检测具有明显的优势,但在多普勒域海上

低速小目标与海杂波之间的区分仍然存在困难。为了克服这一问题，白晓惠等研究者提出了在时频域中提取脊累积量、连通区域数量和最大连通区域尺寸三个特征，以在时频域中对海上小目标进行有效检测^[24]。

对检测分类部分进行合适的算法设计是提高检测器的准确性和鲁棒性的重要手段。在异常检测领域中，凸包检测技术被广泛认为是一种有效的方法^{[25]-[28]}。该技术的性能在很大程度上依赖于海杂波样本在特征空间的几何分布的均匀性。当样本分布不均时，其检测效果可能会受到很大影响。郭子薰等^[25]指出，当样本分布不均且具有明显的几何特征时，凸包方法的性能会受到显著影响。他们提倡在决策制定过程中融入 K 近邻（K-Nearest Neighbor, KNN）算法来进行更精确的分类，以此构建出比传统凸包方法更为集中的决策区域。也有研究人员对三维凹包学习算法进行了优化，以适应海面小目标检测的需求，通过改善内剖点的选择及增加外补措施，显著提升了检测效果^[27]。

1.2.2 基于数据驱动的目标检测方法

经过不断的研究发现，深度学习技术能很好地处理海面目标检测问题，以应对复杂环境下的小目标检测难题。华中科技大学的 Xu 基于卷积神经网络（Convolutional Neural Network, CNN）对传统的恒虚警率检测器进行了优化，显著提升了小目标检测性能^[28]。

为了在提高检测精度的同时保证速度，电子科技大学的 Zhang 利用深度分离卷积网络结合注意力机制，开发了一种高效的合成孔径雷达目标检测方法^[29]。来自西安电子科技大学的研究者则针对复杂场景中数据不足的问题，对 CNN 模型进行改进，并通过实测数据验证了其在目标检测中的可靠性和有效性^[30]。此外，海军航空大学研究团队通过优化 Faster R-CNN 网络结构，进行海面小目标检测与分类模型，为导航雷达在小目标检测中的应用提供了技术支持^[31]。

清华大学的研究者将雷达目标检测问题建模为二元分类问题，设计了一种基于深度神经网络的检测器，能自适应多种统计模型，最后通过仿真验证了该方法的有效性^[32]。近年来，有学者创新性地集成似然比检验与深度残差网络架构，构建了智能检测系统。实验验证表明，该算法对高速机动目标和低速微弱目标均保持稳定的检测灵敏度^[33]。同时，西安电子科技大学的其他研究者通过卷积神经网络提取了雷达回波信号中的多普勒信息，从而提高了恒虚警率检测器在海面小目标检测中的效率^[34]。此外，中国电子科技集团公司的 Liu 等人基于生成对抗网络构建了一种新型检测模型，不仅强化了目标特征的表达能力，还通过实测数据验证了模型的准确性和稳定性^[35]。

总体来看，深度学习在目标检测领域的快速发展显著推动了对非结构化数据

中目标的识别与检测。目标检测技术分为两种主要方法：一是以 R-CNN 为代表的两阶段算法，先生成候选区域再进行分类；二是以 SSD^[36]（Single Shot MultiBox Detector）和 YOLO^{[37]-[41]}（You Only Look Once）为代表的单阶段算法，直接实现目标的定位与分类。单阶段方法通过将目标检测建模为回归问题，利用神经网络同时预测目标的位置和类别，实现了端到端训练，减少了人工特征设计的复杂度，同时在检测速度上具有显著优势。尽管其准确率曾略低于两阶段算法，但随着 YOLO 系列算法的不断迭代，单阶段算法的准确性已大幅提升，且具备更高的实时性和效率。

虽然国内关于船舶目标检测的研究较为广泛，但针对海面小目标检测的研究仍显不足。韦一等人通过改进 YOLOv5 模型并结合数据增强，提升了小目标的检测能力，但在光照条件较差时效果不佳，难以适应复杂的全天候环境^[42]。杨志渊等人采用轻量化改进的 YOLOv8 算法进行船舶检测，但其光学图像检测方法受限于大气条件影响，鲁棒性较差，同时未涵盖浮标、灯塔等典型海面小目标的检测需求^[43]。肖晶晶等人在雾天环境下优化了 YOLOv5 模型，虽然提高了检测精度，但提升幅度有限，仍有较大的改进空间^[44]。

因此，基于深度学习的海面目标检测方法在精准性和效率上具有显著优势，不仅弥补了传统方法对海杂波先验模型依赖的不足，还能通过目标与杂波特征的差异更准确地完成检测任务^{[45][46]}。尽管当前仍面临诸多挑战和技术瓶颈，该领域因其巨大的应用潜力，已成为海上监视雷达目标检测的热门研究方向，并将在未来的实际应用中发挥更加重要的作用。

1.3 实测海杂波数据集介绍

本研究采用的实验数据源自国际权威的 IPIX（Intelligent Pixel Processing X-band）雷达数据集，该系统于 1993 年在加拿大达特茅斯海域采集。该雷达系统具备 X 波段工作频率（9.3 GHz）、窄波束特性（0.9°）以及 30 米高距离分辨率等先进技术指标，为海杂波特性研究提供了高精度实测数据支撑。该系统运行于固定模式下，具有 1000 Hz 的脉冲重复频率（Pulse Repetition Frequency，PRF），并维持了约 131 秒的驻留时间。每个数据集包含 14 个距离单元。IPIX 雷达在 H 和 V 交替极化模式下工作。同时，接收端配备了能够处理 H 和 V 极化信号的双通道。实验目标为用金属丝网包覆的泡沫塑料球，直径大约为 1 米，该目标在海面上漂浮，周期性地上升与下沉。如表 1.1 所示实验中，共收集了十组数据，每组由 217 个脉冲和 14 个距离单元构成，涵盖了 HH、VV、HV 和 VH 四种极化模式。这些数据的 SCR 范围从 0 至 16 dB。为了保护目标数据，每个目标单元周围设有 2 至 3 个单元作为保护单元，其余

的则用作为参考单元，另外 SWH / m 表示波高， $WS / km/h$ 为风速^[47]。

表1.1 数据集描述

序号	数据名	SWH /m	WS (km/s)	目标单元	保护单元
1	19931107_135603_starea17	2	9	9	8, 10
2	19931108_220902_starea26	1.1	9	7	6, 8
3	19931109_191449_starea30	0.9	19	7	6, 8
4	19931109_202217_starea31	0.9	19	7	6, 8, 9
5	19931110_001635_starea40	1.0	9	7	5, 6, 8
6	19931111_163625_starea54	0.7	20	8	7, 9, 10
7	19931118_023604_starea280	1.6	10	8	7, 9, 10
8	19931118_162155_starea310	0.9	33	7	6, 8, 9
9	19931118_162658_starea311	0.9	33	7	6, 8, 9
10	19931118_174259_starea320	0.9	28	7	6, 8, 9

在深度学习检测与雷达对海小目标检测的融合研究中，所呈现的 IPIX 数据集多极化通道特征分析具有重要研究价值。该图 1.2 系统展示了 10 组典型数据样本的极化通道特性参数，包括平均信杂比、海杂波多普勒带宽及其频移特征。实验数据表明，目标平均 SCR 值的提升可显著增强回波信号中目标信息的可辨识度；当目标时频域特征与海杂波具有较高可分性时，检测器的目标捕获精度与执行效率将获得同步优化。对比分析不同极化通道特性发现，交叉极化通道在同极化通道对比中展现出较强的 SCR 优势，其中 VV 极化模式在同极化通道中呈现最低 SCR 值。该现象机理源于海面 Bragg 散射的极化敏感性特性，交叉极化条件下海杂波与目标信号的散射机理差异显著提升了检测信噪比。

本实验设置典型海面锚定球体为检测目标，该目标体受海面动态起伏影响产生同步位移。雷达回波时频分析表明，目标反射信号在零频区域呈现周期性瞬时频率波动特征，这揭示了目标与海面复合运动对电磁散射的调制规律。如此，所获估算结果为后续目标检测工作提供了关键的数据支撑，可从全方位、深层次优化整个对海小目标检测系统的性能，大幅提升其在复杂海洋环境下运行的可靠性，保障检测任务高效、精准地完成。




图1.2 IPIX 数据集数据分析

1.4 论文研究内容和章节安排

本论文主要目的是研究基于深度学习的海面小目标检测方法。总共分为五章内容，各章节研究内容的构成如下：

第一章：绪论

首先介绍了海面小目标检测的研究背景与意义；其次叙述了海面小目标检测的国内外研究现状。最后概括了本文的主要研究内容。

第二章：海杂波特性与深度学习

本章通过对比瑞利分布、对数正态分布、韦布尔分布和 K 分布在不同海况下的拟合优度，验证了传统统计模型在描述非高斯、非平稳海杂波时的固有缺陷。研究进一步结合时频分析方法，量化了海杂波频谱特征的动态变化特性，为后续特征工程提供理论支撑。这一基础性研究不仅明确了传统检测方法的性能瓶颈，更为深度学习模型的构建提供了关键先验知识。

第三章：海面小目标多特征图像预处理的智能检测

本章聚焦多特征融合与深度学习模型的适配性问题，提出基于三通道特征映射的图像预处理方法。通过将 RAA、RDPH 和 RVE 三个关键特征归一化映射至 RGB 通道，构建了兼顾特征信息完整性与数据紧凑性的新型表征模式。该方法创新性地将雷达信号处理与计算机视觉技术相结合，在 SSD、YOLO 和 DETR (Detection Transformer) 等主流检测模型上的实验验证表明，单图多特征输入模式在保证检测

精度的同时，显著降低了模型复杂度与计算开销。这一突破性成果为深度学习技术在海面小目标检测中的工程化应用扫清了数据预处理层面的障碍。

第四章：基于多特征图像预处理的改进深度学习模型检测

本章在第三章研究基础上进行深度优化，提出轻量化改进的 YOLOv8n 网络架构。通过重构检测头结构、引入 C2f 模块压缩参数量、集成 CBAM 注意力机制增强特征区分度，以及改进损失函数与训练流程，实现了检测精度与计算效率的协同提升。特别在虚警率控制方面，创新性地提出基于动态阈值调整的训练策略，通过建立检测置信度与虚警概率的量化关系，将虚警率稳定控制在 0.5% 以下。实验环节采用 IPIX 雷达数据与仿真数据相结合的验证方式，通过消融实验系统评估各改进模块的贡献度，证实了所提方法在召回率、精确度等关键指标上的显著优势。

第五章：总结与展望

总结本文在海面小目标多特征检测研究，分析了当前算法的不足，并对今后的研究方向进行展望。

第二章 海杂波特性与深度学习

2.1 引言

在雷达目标检测领域，海杂波背景下的小目标检测一直是关键性难题。每当雷达在探测海洋目标时，接收到的回波信号往往大部分为海杂波，目标样本较少。对于小目标检测，海杂波的复杂特性起着决定性作用。所以，深入且全面地了解海杂波特性和提升海面小目标检测性能的基石。

对海杂波的研究主要集中在其物理机制和统计特性分析上，通过对雷达回波中杂波分布特性的建模和参数估计，可以有效表征杂波的动态特性。海杂波的幅度分布建模需要结合实测数据进行拟合，以选择最符合实际的分布模型。然而，由于不同环境下杂波特性存在显著差异，单一模型往往难以适应多样化的实际场景，从而限制了基于分布模型的传统检测方法的普适性。

海杂波的复杂性还体现在其时变和非平稳特性上，传统检测器在应对这类杂波时表现出明显的局限性，尤其是在处理小目标回波时，难以有效区分目标信号与杂波背景。为此，需要发展新的检测方法，尤其是基于特征提取的检测技术。这类方法通过分析杂波和目标回波在雷达信号中的差异性特征，从物理、统计或时频域等不同角度提取能够区分两者的有效特征。

通过深入研究海杂波的特性，不仅可以为小目标检测提供坚实的理论基础，还能有效指导特征的提取与利用。杂波的幅度起伏和分布特性为差异性特征的构建提供了直接依据，而目标回波与杂波在多普勒特性、时频特性及能量分布上的差异则为设计新的检测器提供了丰富的信息源。基于特征的检测方法能够突破传统模型对杂波先验分布的依赖，更好地应对复杂的杂波背景。

特征检测是海面小目标检测的关键技术，多特征联合检测是主流方法。多特征检测虽然可以利用多维特征数据，但也面临着计算量大，检测难度高的问题，深度学习技术对复杂数据的处理能力可以很好的弥补多特征检测的缺点，因此深度学习技术和多特征检测的结合一直是当前研究的热点。

本章首先在 2.1 节中对海杂波统计特性进行分析。接着，在第 2.2 节中对海杂波频谱特性分析。然后，由频谱特性引出到第 2.3 节的海面小目标特征检测方法，并列出多维特征提取的方法。在 2.4 节，分析了多维特征检测的数据处理复杂的特点，由此来阐述把深度学习和多维特征检测结合的必要性。最后，第 2.5 节总结本章内容。

2.2 海杂波统计特性

在雷达技术持续推进、对海探测需求与日俱增的当下，深刻了解雷达回波的形成机理以及海杂波的特性显得尤为关键。在早期雷达观测中，采用的低分辨率雷达受自身技术瓶颈限制，单个空间分辨单元覆盖面积偏大，致使该单元内所含散射点数量众多。数学领域的中心极限定理指出，大量相互独立且同分布的随机变量相加，在特定条件下，其结果会逐渐趋近于正态分布。对于雷达回波来说，这些散射点回波近似可视为独立同分布的随机变量，因而在回波历经包络检波流程后，其幅度服从瑞利分布。

随着雷达技术的不断进步，其分辨率得到了显著提升。高分辨率促使单个空间分辨单元涵盖的散射点数量大幅减少，原本被众多散射点“均衡化”的影响大大减小，散射特性影响比重加大。回波幅度的概率密度函数不再呈现出标准的瑞利分布形态，而是出现了明显的拖尾特征。特别是在低掠射角的情况下，海面产生的镜面反射现象会进一步增强这种拖尾效应。这是由于低掠射角时，镜面反射区域相对集中，反射回来的能量更强，使得少数强散射点的回波能量在整体回波中占比更大，进而扰乱了相对均衡的回波幅度分布。鉴于上述复杂状况，科研人员针对海杂波的幅度分布特性开展了深入且广泛的探究工作，力求探寻更为精准的建模策略。在众多研究成果中，常见的海杂波分布模型扮演着至关重要的角色，它们不但能够精准地描述各类不同应用场景下海杂波所呈现出的独特特性，而且为后续改进目标检测算法构筑了坚实的理论根基。接下来，将择取几种具有代表性的常用海杂波幅度分布模型展开简要剖析与探讨。

（1）瑞利分布

在雷达技术发展的初期阶段，系统工作于低分辨率模式且采用大擦地角观测构型时，海杂波的幅度统计特性常采用瑞利分布进行参数化建模。具体而言，在这种情况下，雷达的空间分辨单元能够覆盖大量的散射点，而单元内那些散射特性较强的少量点对整个单元的影响较小。此时可以看作瑞利分布，其概率密度函数表达如下：

$$f(x) = \begin{cases} \frac{x}{\sigma^2} \exp\left(-\frac{x^2}{2\sigma^2}\right) & , x \geq 0 \\ 0 & , x < 0 \end{cases} \quad (2-1)$$

公式(2-1)中 x 为海杂波幅度， σ^2 为功率水平， σ 控制幅度集成程度。

对于低分辨率雷达，海杂波幅度分布可以理解为瑞利分布，其分布具有简洁性和特定场景适用性，概率密度函数形式简单，数学处理方便，能较好描述低分辨率雷达条件下的海杂波分布特性，在早期海杂波研究中广泛应用。图 2.1 为瑞利分布 PDF 曲线，当 σ 较小时，回波功率也随之变小；平均功率增大，方差增大，出现拖尾，PDF 曲线矮胖，且瑞利分布拖尾短，仅适用于低海情、低分辨场景。




图2.1 瑞利分布 PDF

然而，瑞利分布也存在一些局限性，瑞利分布假设了散射体的相位差是随机的，这在实际环境中可能并不总是成立。瑞利分布的参数估计较为复杂，需要依赖于样本数据的统计特性。瑞利分布无法准确描述空间分辨单元中散射强点的影响，当这些强点对整体回波的影响较大时，瑞利分布的拟合效果会大打折扣。

正是由于瑞利分布的这些局限性，研究者开始寻求更为精确的杂波模型。对数正态分布因其能够更好地描述杂波幅度的分布特性，尤其是在强散射点存在的情况下，逐渐成为新的研究方向。对数正态分布能够提供更为灵活的参数配置，以适应不同场景下的杂波特性。

（2）对数正态分布

雷达回波幅度的统计分布特性取决于系统分辨率、入射余角以及海况条件。当雷达分辨率提升时，空间采样单元的几何尺寸会相应减小，覆盖的散射点数量也随之减少，从而不再满足中心极限定理。在低入射角及恶劣海况条件下，海面后向散射点聚集效应显著，导致回波幅度统计特性偏离经典瑞利模型。此时，对数正态分

布模型可有效表征此类非均匀散射特征其概率密度函数表达式为:

$$f(z) = \frac{1}{\sqrt{2\pi}\sigma z} \exp\left[-\frac{(\ln z - \mu)^2}{2\sigma^2}\right], z > 0 \quad (2-2)$$

公式(2-2)中, μ 是 $\ln x$ 的均值, z 代表对数正态分布的尺度参数, σ 是 $\ln x$ 的方差。对数正态分布的优点在于其参数的物理可解释性较强, 能够通过调整参数来适应不同的海况和雷达配置。它能够捕捉到海杂波幅度分布中的极端值, 这些极端值在瑞利分布中往往被忽略, 而在实际的海杂波环境中, 这些极端值对雷达性能有着显著影响。此外, 对数正态分布能够提供更加灵活的拟合, 尤其是在描述具有重尾特性的海杂波幅度分布时, 它比瑞利分布更为合适。




图2.2 对数正态分布 PDF

图 2.2 展示了对数正态分布概率密度函数演变规律。实验数据表明, 当形状参数 σ 恒定时, 尺度参数 μ 的增大直接导致回波能量强度提升, 同时幅度动态区间扩展伴随显著的概率密度函数拖尾效应; 而固定 μ 参数时, σ 值的增加会加剧拖尾现象的严重程度。与瑞利分布相比, 对数正态分布具有更广的动态范围, 值得注意的是, 对数正态分布模型在统计建模过程中可能高估大幅值事件发生频率, 这种模型偏差将直接影响检测阈值优化过程, 继而导致目标检测系统的虚警概率升高

然而, 对数正态分布也存在一些缺点.对数正态分布的参数估计相对复杂, 需要较为复杂的数学处理和更多的样本数据。并且可能在某些特定的海况下无法提供最

佳的拟合效果，尤其是在海杂波幅度分布具有多种模式或者受到非高斯噪声影响时。对数正态分布的计算复杂度相对较高，这可能限制了其在实时雷达系统中的应用。

鉴于对数正态分布的这些优缺点，研究者开始探索其他分布，如威布尔分布，以期获得更好的海杂波幅度分布描述。威布尔分布以其能够描述不同形状的失效分布和适应性强而受到关注。它不仅能够模拟海杂波中的极端值，还能够通过调整形状参数来适应不同的分布形态，这使得威布尔分布在海杂波建模中具有不错的应用价值。

(3) 威布尔分布

基于海洋雷达实测数据的统计建模分析表明，瑞利分布因尾部衰减特性较快，在描述高幅值海杂波事件时存在系统性低估；对数正态分布则因其缓慢衰减的尾部特性，易导致高幅值概率的过估计。威布尔分布通过调节形状参数和尺度参数，能够有效平衡上述两种分布的局限性，其概率密度函数（PDF）定义为：

$$f(z) = \frac{p}{q} \left(\frac{z}{q}\right)^{p-1} \exp\left(-\left(\frac{z}{q}\right)^p\right), z \geq 0 \quad (2-3)$$

公式(2-3)中， p 为形状参数， q 为尺度参数， p 当形状参数分别为 1 和 2 时，威布尔分布就相当于瑞利分布和指数分布。

威布尔分布在海杂波幅度分布建模中具有一定的优势，它能够适应不同形状的失效分布，展现出较强的适应性。威布尔分布的参数可以灵活调整，以适应不同海况和雷达分辨率下的海杂波特性，这使得它在模拟低入射角高分辨力雷达回波时表现出色。




图2.3 威布尔分布的 PDF

如图 2.3 所示为威布尔分布的 PDF 曲线。在形状参数 p 保持恒定的条件下，尺度参数 q 与回波信号功率呈正相关关系，其增大会导致时域动态范围扩展及统计散布特性显著化。当尺度参数 q 给定固定值时，形状参数 p 的增大将导致幅度分布更集中，表现为概率密度的集中化趋势与分布尾部衰减速率的提升。但是威布尔分布也存在一些缺点，其参数估计相对复杂，需要依赖于样本数据的统计特性，这在实际应用中可能会受到样本量和质量的限制。

鉴于威布尔分布的这些优缺点，研究者开始探索其他分布，相较于传统单分量模型，K 分布通过纹理分量与斑纹分量的联合作用机制，构建了更精确的海杂波统计建模框架。该复合模型特别适用于高分辨率雷达系统在低掠射角条件下的观测场景，对海杂波具有双维度优势：首先，幅度概率密度函数与实测数据包络特性具有高度的一致性。其次，纹理分量的时间演化特性能够有效地表征杂波脉冲的相关性。其概率密度函数能够提供更为精确的海杂波幅度分布描述，尤其是在处理高分辨率雷达数据时，K 分布能够更好地捕捉到海杂波的复杂特性。

(4) K 分布

K 分布是雷达信号处理领域中极为重要的概率分布模型，尤其适用于描述复杂气象条件下雷达回波信号的特性。其本质在于能够模拟具有“重尾”特征的数据分布，这使得它在处理具有极端值或异常值的海杂波数据时更为有效。K 分布的概率密度函数可表示为：

$$f(x) = \frac{2}{2^{a-1}\Gamma(a)\sqrt{b/a}} \left(\frac{2x}{\sqrt{b/a}} \right)^a K_{a-1} \left(\frac{2x}{\sqrt{b/a}} \right) \quad (2-4)$$

在公式(2-4)中 a 为形状参数， b 为尺度参数，可以表示海杂波局部功率水平， $K_v(\cdot)$ 为第二类关于 v 阶的修正贝塞尔函数。

K 分布的优点在于其能够提供比瑞利分布和对数正态分布更准确的拟合，尤其是在描述具有快速和慢速起伏的杂波时。它能够将快速起伏的杂波和慢速起伏的杂波结合起来，从而更好地模拟实际的雷达杂波环境。尤其是在描述高分辨雷达的非均匀杂波时，展现出其独特的优势。作为一种概率分布模型，K 分布能够模拟具有“重尾”特征的数据分布，这使得它在处理具有极端值或异常值的海杂波数据时更为有效。K 分布的灵活性在于其参数可以根据实际的海杂波环境进行调整，以适应不同的海况和雷达配置。

但是 K 分布也存在一些局限性。由于其参数估计相对复杂，需要依赖于样本数据的统计特性，这在实际应用中可能会受到样本量和质量的限制。K 分布在计算上

可能不如其他分布那样高效，尤其是在处理大规模数据集时，其计算复杂度可能会成为一个问题。并且 K 分布的参数估计和模型拟合可能需要较为复杂的数学工具和计算方法，这在实际应用中可能会增加实现的难度。但是 K 分布仍然是雷达海杂波建模中一个重要的工具，并且随着对海杂波特性的进一步研究， K 分布的改进和优化可能会使其在未来的应用中发挥更大的作用。




图2.4 K 分布的 PDF

图 2.4 揭示了 K 分布模型参数变化规律：在形状参数 a 固定条件下，尺度参数 b 的增大表征回波功率增强，表现为幅度分布离散度增大；当 b 保持恒定时， a 值的增加将导致概率密度峰值降低且基底展宽效应显著，当 v 参数的值趋近于无穷大时， K 分布会收敛于瑞利分布。

但是由于海杂波特性受浪级、雷达工作模式及入射余角的联合调制影响，工程实践中，针对海杂波回波的统计特性建模，需建立包含韦布尔、 K 、对数正态等候选分布的对比分析流程：首先对各模型进行最大似然参数估计，其次通过假设检验评估统计优度，最终选定最优拟合模型作为场景特征匹配的杂波表征基准，并据此推导检测器的似然比判决准则。

随后，针对杂波幅度模型的拟合程度开展评估。图 2.5 呈现了多种分布类型对实测数据的概率分布密度函数的拟合成效。实验借助 KS 距离用以衡量各分布模型的拟合优劣程度，KS 距离数值越低，拟合效果越佳。经由对实测数据进行参数预估，获取 K 分布、威布尔分布以及瑞利分布各自对应形状参数和 KSD 值。当形状参数处于较低水平时，意味着数据具备较为显著的非高斯属性，且概率密度函数展现出重尾特征。从图中态势来看，瑞利分布的拟合曲线与实测数据存在较大偏离，根源在于瑞利分布在拟合非高斯数据方面存在力不从心的状况。与之相比， K 分布的拟合成

效胜过瑞利分布，不过在数据尾部区域的拟合仍存在一定的难题。总体而言，K 分布的拟合效果最为出色，关键在于其对杂波尾部有着良好的拟合功效。




图2.5 不同分布对海杂波的拟合结果

然而 K 分布的概率密度函数计算复杂，这在实际工程应用中对算力要求高，难以广泛应用。故而在实际运用场景中，不存在通用性的模型，需依据具体环境以及雷达参数来挑选合适的幅度模型。针对海面低可观测目标检测难题，需要构建基于实测数据驱动的杂波建模方法论，优选适配统计模型，建立精细化杂波表征体系，最终实现弱目标检测效能的提升。对实测数据的分析表明，近海杂波幅度统计特性呈现出趋近于 K 分布的态势，而远海杂波则更契合韦布尔或瑞利分布的特征。然而，传统单模分布在跨海域及多海况建模时普遍存在显著偏差，这源于海杂波具有显著的空间异质性和时变非平稳特性，导致雷达检测系统面临目标信杂比较小时的技术挑战。

2.3 海杂波频谱特性

随着雷达技术的进步，海杂波特性愈发受到重视。海杂波具有非高斯、非线性及非平稳特性，使其不再是简单统计问题，而是需综合多种方法分析处理的复杂现象。在高分辨率雷达系统中，海杂波呈现出明显的非高斯特性和拖尾现象。这使得传统的高斯模型不再适用，必须采用非高斯模型来更精准地描述其特性。K 分布作为一种重要的非高斯模型，能够描述海杂波的非高斯与重尾特性，通过形状参数和尺度参数可以灵活适应不同的海杂波环境，因而在雷达信号处理领域得到了广泛应

用。不过，K 分布也存在一定的局限性，无法完全涵盖海杂波复杂的各种特性。

随着雷达分辨率的提升，分辨单元的物理尺度随之缩小，导致中心极限定理的适用条件不再成立，海杂波的统计特性表现出显著的非高斯分布特性。相关研究表明，基于非高斯建模的杂波分布存在明显的统计拖尾效应。更为复杂的是，受海杂波“三非”特性（即非均匀性、非平稳性和非高斯性）的综合影响，传统统计分析方法在该领域的研究具有明显的局限性。在长时相干积累的条件下，海上微弱目标检测问题可转化为对杂波背景中的非线性调频信号检测问题。基于此理论推导，时频能量分布差异可作为目标与杂波的有效可分性判据。时频分析方法通过时频变换将一维回波序列扩展至二维联合分布域，有效融合时频特征，获得具有时-频耦合特性的多维度信息表征。该方法的核心优势在于能够精确刻画信号能量在时频平面内的动态演化规律。特别地，考虑到目标回波可采用分段线性调频信号进行有效逼近，经理论推导与实验验证，平滑伪魏格-纳威利分布凭借其优化的交叉项抑制能力，在此类检测问题中被视为理想的时频分析工具。

针对海杂波的非线性特性，研究者发现可以通过时频变化方式处理回波信号，如短时傅里叶变换、小波变换等，来区分海杂波与含目标回波。图 2.6 展示了基于平滑伪魏格纳分布变换的海杂波与目标单元的时频谱特征。通过时频分析表明，海杂波呈现出显著的非平稳特性，其能量强度与频谱宽度随时间呈现动态变化，而目标单元的时频谱则同时包含了目标信号与海杂波成分。其中，目标信号在时频域表现为一条具有显著特征的瞬时频率曲线。通过对比分析发现，目标所处距离单元的时频分布特性与纯海杂波背景单元存在可辨识的差异性。这种时频域表征差异揭示了目标与海杂波在非平稳信号特征层面的本质区别，为构建基于时频分析的目标检测方法奠定了理论基础，拓展了雷达海面弱小目标检测的技术路径。

当前，海杂波认知已从传统的时域、频域研究拓展至时频域多角度分析，从单一分形特征研究扩展到多尺度分形特征研究。本文通过深入挖掘时频域特征信息，为开发新型目标检测算法提供了重要的理论依据。在此研究基础上，深入探索海杂波与目标信号在时频域的特征提取机制，通过建立海杂波先验知识引导的杂波抑制模型实现目标特征的间接增强，对于突破海面弱小目标检测的性能瓶颈具有重要理论价值与工程应用前景。该研究成果不仅为复杂海况下目标特征解耦提供新的方法论框架，同时为雷达海洋遥感领域的智能检测与精细分类技术发展提供理论支撑。




图2.6 IPIX 雷达实测数据时频分析

2.4 特征检测方法

由于海杂波具有非平稳性和非高斯性，基于经验概率密度函数的实测数据拟合往往存在显著偏差。并且海杂波数据中普遍存在的强海尖峰现象，进一步加剧了传统检测器对小目标的有效检测难度。面对上述难题，研究人员提出了一种基于多域特征提取的检测方法。该方法通过提取时域、频域以及时间频率域等多个维度的特征来实现目标检测。常用的特征参数主要包括相对平均幅度、相对多普勒峰高以及相对向量熵等。

平均幅度作为一种基本的时域能量特征，在传统雷达目标检测中起着重要作用，尤其是在 SCR 较高的情况下，其区分能力表现突出。在非相干恒虚警率处理中，目标的存在是通过比较检测单元的能量值与动态阈值决定的，这个阈值是基于周边参考单元的能量值设定的。类似于平均幅度，相对平均幅度（Relative Average Amplitude, RAA）通过比较检测单元与参考单元的平均幅度，描绘目标的能量特征。

$$RAA(z) = \frac{\sum_{n=1}^N |z(n)|}{\Theta(\sum_{n=1}^N |z_k(n)|, k=1, 2, \dots, K)} \quad (2-5)$$

公式(2-5)中， Z 表示接收到的回波信号向量， N 为回波序列长度， k 是参考单元的数目， $\Theta(\bullet)$ 用于提取有序统计量。如图 2.7 所示为不同距离单元的相对平均幅度图。RAA 具备适应杂波幅度随距离变化的能力，从而维持恒定的虚警率。

相对多普勒峰高（Relative Doppler Peak Height, RDPH）雷达回波序列 $\{z(n), n=1, 2, \dots, N\}$ 的多普勒幅度值的计算方法如下：




图2.7不同距离单元的相对平均幅度图

$$Z(f_d) = \frac{1}{\sqrt{N}} \left| \sum_{n=1}^N z(n) \exp(-2\pi f_d n \text{PRP}) \right| \quad (2-6)$$

$$-\frac{1}{2\text{PRP}} \leq f_d \leq \frac{1}{2\text{PRP}}$$

公式(2-6)中 f_d 是多普勒频率，PRP 是脉冲重复周期。再计算多普勒峰高和多普勒偏移：

$$\begin{cases} \text{Peak}(\mathbf{z}) = \max_{f_d} \left\{ Z(f_d), -\frac{1}{2\text{PRP}} \leq f_d \leq \frac{1}{2\text{PRP}} \right\} \\ f_d^{\max}(\mathbf{z}) = \arg \max_{f_d} \left\{ Z(f_d), -\frac{1}{2\text{PRP}} \leq f_d \leq \frac{1}{2\text{PRP}} \right\} \end{cases} \quad (2-7)$$

设定 δ_1 为用于参考的多普勒单元区间， δ_2 为目标的最大多普勒带宽，最后计算 RDPH：

$$D = [-\delta_1, -\delta_2] \cup [\delta_2, \delta_1]$$

$$\text{RDPH}(z) = \frac{\text{Peak}(z)}{\frac{1}{\#D} \sum_{f_d \in f_d^{\max}(z) + D} Z(f_d)} \quad (2-8)$$

公式(2-8)中， D 表示由多普勒参考单元构成的集合， $\cup$ 代表集合的并运算， $\#D$ 表示集合 D 中元素的数量。图 2.8 所示为不同距离单元的相对多普勒峰高。




图2.8 不同距离单元的相对多普勒峰高

在信息理论里，信息熵是衡量信息量大小的指标。基于这一概念，本研究构建了一种基于多普勒谱的向量熵（Vector-Entropy, VE）定量表征方法。该特征参量的提出为复杂海况下微弱目标检测提供了新的特征维度。

多普勒域上回波序列的向量熵定义如下：

$$\text{VE}(z) = - \sum_{f_d} \frac{Z(f_d)}{\sum_{f_d} Z(f_d)} \log \left(\frac{Z(f_d)}{\sum_{f_d} Z(f_d)} \right) \quad (2-9)$$

通过计算待测单元回波序列与参考单元回波序列的多普勒域向量熵，能够计算出相对向量熵，图 2.9 展示了不同距离单元的相对多普勒向量熵。这个比值有助于实现恒定虚警率的特性：

$$\text{RVE}(z) = \frac{\text{VE}(z)}{\theta(\text{VE}(z_k), k=1, 2, \dots, K)} \quad (2-10)$$

如图 2.9 所示，为不同距离单元的相对多普勒向量熵图。相对多普勒向量熵通过量化雷达回波中目标速度分布的复杂性与随机性，有效区分海杂波与小目标信号。在复杂海况下，海杂波的多普勒频谱通常呈现高熵值特征，反映其随机波动特性；而小目标因具有相对稳定的运动模式，其多普勒熵值显著低于背景杂波或呈现特定分布规律。该指标通过提取速度域的信息熵特征，能够突破传统幅度检测的局限性，尤其在低信噪比场景中，可显著增强分类器对微弱目标的辨识能力，降低因海面湍流或雨雾干扰引发的虚警概率，为提升复杂海洋环境下小目标检测的鲁棒性提供关键特征支撑。




图2.9 不同距离单元的相对多普勒向量熵

2.5 深度学习与特征检测

高分辨小目标探测系统需应对复杂海杂波与微弱目标回波的双重挑战，其检测性能突破的核心在于：建立海杂波深度认知体系，实现特性精细感知与有效利用。在此背景下，基于杂波-目标回波特征差异的联合检测技术应运而生，即特征检测技术。该技术体系通过提取海杂波与目标在特征空间的可分性参数，将高维观测数据映射至可分性更强的低维特征域进行目标判别。

特征检测作为智能检测的初步版本，已在计算机视觉与模式识别领域获得广泛

应用验证。其技术演进路径为：依托雷达回波的幅度分布特性、多普勒谱结构、时频联合分析、极化散射响应等多元特征参量，构建多维特征表征体系。相较于传统检测方法基于单一检验统计量的局限性，该技术通过特征维度扩展显著提升了复杂海杂波环境下的微弱目标检测能力。

当前技术发展呈现两大趋势：其一，特征工程维度持续拓展，通过引入分形维数、混沌特征、时频熵等新型特征参量增强杂波与目标的表征差异；其二，深度学习算法与高维特征空间的深度融合，利用神经网络强大的特征挖掘能力实现检测性能的突破性提升。国内外学者已在该领域取得系列研究成果，主要涵盖海面散射特性分析、时频联合处理、智能检测算法等多个研究方向，为海杂波环境下的目标检测提供了理论支撑与技术储备。

深度学习网络在经过足够多数量和轮数的训练后，能够有效地检测图像中的目标，但是对于海面小目标的检测来说存在着两个问题。

慢速小目标回波微弱，运动速度较慢，目标信息往往会淹没在海杂波之中，单一的特征检测精确率较低。多特征联合检测往往被应用于海面的小目标检测也是主流的检测方法，但是深度学习网络大部分属于图像智能检测，不仅对输入的数据有要求，即图像形式，也要大量的人工标注训练集来训练模型。单一的特征图虽然满足图像的要求，但是难以标注，且标注工作量较大准确率也不能保障，一旦训练集中出现错误标注或者虚警的情况，训练效果会下降很多。如图 2.10 所示，使用实测的雷达幅度回波图，工作量很大且只有一个特征信息可以利用，目标检测的精确度和置信度都不高。

第二，深度学习网络对于图像信息的利用较低。在如图 2.10 (a)的雷达目标检测方式下，深度学习网络的输入层先把图像分为 R、G、B 三通道，再对这三通道数据进行卷积采样等特征提取操作，这对于一般的实物检测来说色彩组成是重要的信息，但是雷达检测属于特征数据的检测，因此浪费了不少计算资源。

如图 2.10 (b)、(c)、(d)所示，舟山马目站 2023.10.20 采集到的雷达回波幅度数据。使用图 2.10 (a)的 R、G、B 单维化的图像，无论是检测精度还是置信度，其检测结果和原三通道彩色图像检测的结果很接近，且 R、G、B 三者单维通道检测的结果相似度也很高，说明三通道携带的信息和原始图像携带的信息差别不大，这意味着有两个通道的信息被浪费了。




图2.10 实测雷达幅度回波 PPI 图及 RGB 三通道图

传统的多特征海面小目标检测往往利用数据训练出杂波与目标的最优分类面，将其看作是二分类问题，传统的方法也是对这个二分类面尽可能分离杂波和目标的能力上不断做改良，但是有一个问题是存在的，在人为规定的不同特征值下的不同阈值虽然对于大多数样本来说分类效果很好，这个阈值也是通过不断更迭计算得出来的平衡精确度和虚警率的最优解，但是对于那些在这些平衡之外的目标单元数据往往被忽略掉。这些被牺牲掉的数据在某几个特征值上能和杂波区别出来，但是对于传统的多特征多阈值共同判决的二元问题，只要有一个特征值被判非，那么目标的其他特征数据就算能很明显作为区分依据也毫无用处。因此本文寄希望于提出一种改进的深度学习网络方法把传统的判决中的逻辑上的与问题变为或问题，通过特征在不同极化的影响权重以及在海情变化下海浪对于整体观测单元所带来的影响来使特征的阈值随周围环境变化而变化，从而达到良好的检测效果。这些问题涉及复杂的数据分析，传统的方法在面对这些问题时就显得捉襟见肘，深度学习的快速发

展以及算力的不断提升让我们可以借助其强大的计算能力来帮助我们解决上述的问题，而数据分析恰恰是深度学习所擅长的。

2.6 本章小结

本章全面且系统地探究了海杂波背景下目标检测技术的演进路径与现存挑战，通过理论分析与实验证据为后续研究铺垫了基础。早期在低分辨率雷达场景中，统计模型，如瑞利分布、对数正态分布、威布尔分布及 K 分布。被广泛应用于描述海杂波特性。这些模型在特定条件下能较好地拟合杂波数据，为检测方法设计提供了理论依据。但是随着雷达技术的发展，高分辨率雷达数据的特性逐渐偏离传统统计模型的假设，模型失配问题日益显著，限制了检测性能的进一步提升。

2.1 节深入分析了高分辨率雷达数据的特性，通过实测数据验证了传统统计模型的局限性。以 IPIX 雷达数据集为例，详细比较了瑞利分布、对数正态分布、威布尔分布和 K 分布对实际海杂波数据的拟合效果。实验结果表明，尽管 K 分布在多数场景下拟合效果最优，但仍无法完全表征高分辨率雷达体制下海杂波的时空特性，传统统计模型在复杂海况下的适用性受到质疑。

在此背景下，特征检测技术作为应对复杂海杂波环境的重要手段被深入探讨。2.2 节和 2.3 节通过提取海杂波与目标在特征空间的可分性参数，将高维观测数据映射至可分性更强的低维特征域进行目标判别。重点介绍了三种特征检测方法：相对平均幅度、相对多普勒峰高和相对向量熵。这些方法通过多维特征的提取和融合，显著提升了目标检测的性能和鲁棒性。

然而，多特征联合检测虽然能够利用多维特征数据，但也面临着计算量大、检测难度高的问题。深度学习技术凭借其强大的特征学习和模式识别能力，为解决多特征检测的难题提供了有效途径。2.4 节通过实验验证了深度学习模型在处理复杂数据方面的优势，但同时也指出当前深度学习模型与海面小目标多特征检测模型之间存在不匹配问题，这在很大程度上限制了深度学习技术在该领域的应用效果。

为解决上述问题，下一章将深入探讨海面小目标多特征图像预处理的智能检测方法。通过创新性的多特征图像预处理技术，将多维特征信息高效融合到单张图像中，不仅解决了模型不匹配的问题，还显著减少了多维数据量，为深度学习模型的应用提供了更加友好和高效的输入形式，有望进一步提升海面小目标检测的准确性和实时性。

第三章 基于海面小目标多特征图像预处理的智能检测

3.1 引言

海面小目标检测作为对海雷达系统的重要任务，始终面临着复杂电磁环境与微弱目标信号的严峻挑战。传统检测方法依托单维度特征提取与统计建模技术，在低信杂比场景下存在显著性能瓶颈^[48]。随着“双高”体制雷达的广泛应用，多特征联合检测技术通过融合时域、频域及时频域多维特征，有效提升了目标可分性，但随之而来的数据维度增加与计算复杂度激增问题，严重制约了其在工程实践中的应用效能^[49]。

深度学习技术在计算机视觉领域的突破性进展，为雷达目标检测提供了新的技术路径^[50]。但是雷达多特征检测与传统视觉检测模型存在本质性差异：常规深度学习框架以单图单目标为输入范式，而雷达多特征检测需同时处理同一目标的多个特征维度数据^[51]。这种结构失配导致现有模型面临三大技术障碍：其一，多特征数据需独立构建图像矩阵，造成数据冗余与存储压力；其二，多通道特征图并行处理显著增加网络参数量与计算负担；其三，特征图间的时空对齐误差影响模型特征融合效果。这些问题严重限制了深度学习技术在海面小目标检测中的实际应用价值^[52]。

针对上述问题，本章提出基于多特征图像预处理的深度学习检测方法。通过深入分析卷积神经网络的底层图像处理机制，创新性地将雷达回波的三维特征信息进行归一化映射与空间配准，构建符合 RGB 三通道规范的多特征图像。该方法通过特征空间压缩技术将多维特征信息编码至单张图像，数据量缩减至传统方法的三分之一左右，并且基于特征通道的物理意义构建可解释性特征映射关系，保留原始特征可分性。这种预处理方式不仅适配主流深度学习框架的输入要求，而且通过特征信息的融合表达显著提升模型训练效率。

本章后续内容将系统阐述该方法的理论体系与技术实现：3.2 节解析深度学习模型的图像处理机理，重点探讨卷积运算、归一化处理等核心环节对雷达特征图的影响机制；3.3 节详细论述多特征图像预处理的关键技术，包括特征选择准则、非线性映射函数设计及空间配准算法；3.4 节介绍了 YOLO、SSD 和 DETR 三种模型，为下文实验部分做准备，3.5 节通过对比实验验证所提方法的优越性，并通过在 3.4 章所提的模型上的实验证明了所提多特征图像预处理方法的通用型。同时也展示其在检测精度、计算效率及泛化能力等方面的突破性提升。本研究为深度学习技术与雷达多特征检测的深度融合提供了创新性解决方案，对推动智能化海上小目标检测的发展具有重要理论价值与工程意义。

3.2 深度学习模型图像处理方法及原理介绍

3.2.1 图像处理基本方法

随着计算能力的提升和数据集的丰富，深度学习在图像处理领域的表现已接近甚至超过了传统方法，成为了许多计算机视觉任务中的核心技术。深度学习模型在图像处理领域中的应用已经变得日益广泛，这得益于其强大的特征提取能力和高度的灵活性。在深度学习模型中，图像处理方法及原理是构建有效图像识别和分类系统的基础。本章将详细介绍深度学习模型在图像处理中的应用方法及其工作原理，重点聚焦于目标检测任务中的典型深度学习架构。通过分析深度学习中图像处理的核心技术，来阐述深度学习如何通过多层次的特征提取、信息融合和优化策略，实现对图像中目标的快速精准识别。如图 3.1 是深度学习模型中的关键图像处理方法，包括层归一化、卷积、最大池化、非线性激活、展平、输出投影以及推理等步骤，以及它们在图像识别任务中的作用和重要性。




图3.1 深度学习模型图像处理方法

3.2.2 层归一化与卷积

输入层是深度学习目标检测网络中的第一环节，主要负责处理原始图像并将其转换为网络能够理解的形式。图像数据通常是二维矩阵，每个像素值代表某种颜色的强度，但为了让深度学习网络能够从中提取有用的特征，输入层需要进行一些处理和增强。以下是输入阶段的几个关键技术。定义输入数据，假设神经网络中的某一层的输入数据为 $x = (x_1, x_2, \dots, x_N)$ ，这里 N 是输入数据的维度。

计算均值和方差，首先计算输入数据 x 在维度上的均值：

$$\mu = \frac{1}{N} \sum_{i=1}^N x_i \quad (3-1)$$

然后计算输入数据 x 在维度上的方差：

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2 \quad (3-2)$$

归一化操作，对输入数据 x 进行归一化，得到归一化后的 $\hat{x}$ ，公式为：

$$\hat{x}_i = \frac{x_i - \mu}{\sqrt{\sigma^2 + \epsilon}} \quad (3-3)$$

公式(3-3)中， ϵ 是一个很小的正数，用于防止分母为 0。另外由于要对参数进行调整，通常会引入可学习的缩放参数 γ 和偏移参数 β 来调整归一化后的数据，得到最终的输出为：

$$y_i = \gamma \hat{x}_i + \beta \quad (3-4)$$

公式(3-4)中， γ 和 β 的形状与输入数据 x 的维度相同，它们会在神经网络的训练过程中通过反向传播进行学习。

在图像处理领域，层归一化发挥着至关重要的作用。它能够有效应对神经网络中层数增加引发的内部协变量偏移问题，通过将每层输入归一化为均值 0、方差 1 的分布，稳定了数据的特征尺度，让模型能更快找到最优权重^[53]。而且，面对实际应用中诸如光照、拍摄角度等因素致使图像数据分布多变的情况，层归一化增强了模型的适应性，使其对不同输入分布具备更强的鲁棒性，有力提升了模型的泛化能力，确保在复杂多变的图像数据场景下仍能维持较高的识别准确率。

图像卷积是一种基于数学运算的图像处理方法，它通过将一个小的矩阵与图像进行逐像素的乘法和加法运算，从而改变图像的像素值。卷积核的大小和权重决定了卷积操作的效果^[54]。例如，一个常见的卷积核可以实现图像的模糊效果，而另一个卷积核可以实现图像的边缘检测。

图像卷积的数学表达式可以表示为：

$$g(x, y) = \sum_{i=-k}^k \sum_{j=-k}^k f(x+i, y+j)h(i, j) \quad (3-5)$$

公式(3-5)中， $f(x, y)$ 是输入图像的像素值， $h(i, j)$ 是卷积核的权重， $g(x, y)$ 是输出图像的像素值， k 是卷积核的半径。

图像卷积的过程首先从卷积核的选择开始，卷积核的选取依据所需的图像处理效果。边缘检测常使用 Sobel 卷积核或拉普拉斯卷积核，而模糊效果则通常选用高斯卷积核。卷积核的大小一般为奇数，以确保其能够在图像中心进行对称操作^[55]。接下来，对图像进行遍历处理，从图像的左上角开始，将卷积核的中心与图像的第一个像素对齐。对卷积核覆盖的区域内的每个像素进行逐个乘法和加法运算，计算出输出图像的相应像素值。接着将卷积核向右移动一个像素，重复上述计算过程，直到遍历完整个图像的一行。最后卷积核向下移动一行，继续进行相同的操作，直到图像所有像素都被处理。

3.2.3 图像增强

图像增强技术通过对输入图像进行一系列变换，增加训练数据的多样性^[56]。传统的图像增强技术包括旋转、翻转、平移、缩放和颜色调整等，而在最新的深度学习模型当中，还使用了 Mosaic 增强技术，该方法通过随机选择四张不同的图像，并将它们拼接成一张较大的图像。Mosaic 增强能够帮助网络捕捉到更多种类的背景噪声，从而增强模型的泛化能力。

Mosaic 数据增强算法包括几个关键步骤，如图 3.2 所示。首先，从数据集中选择四幅不同的图像用于生成合成图像。合成图像的每个象限用源图像中的一个补丁填充，从而创建一个包含四幅原始图像元素的更大图像。接下来，合成图像会被划分为网格，网格的布局由算法确定，以平衡网格数量和尺寸。原始图像按照特定的顺序填充到这些网格中，确保图像在网格内正确对齐。图像的大小调整也会受到控制，以避免过度缩放，防止影响训练效果或引入无关像素。基于阈值的目标包含方法会确定哪些目标应纳入模型训练，只有满足阈值条件的目标才会被选入训练集，而不符合条件的目标则会被排除。




图3.2 Mosaic 数据增强算法流程图

3.2.4 池化与非线性激活

最大池化是图像处理中常用的一种下采样操作，广泛应用于卷积神经网络中，用于减少图像的空间尺寸，同时保留图像的主要特征。它通过对局部区域内的像素值进行选择提取，通常选择最大值，从而有效地降低计算量，防止过拟合，并增强模型的鲁棒性^[57]。

在最大池化操作中，首先定义一个固定大小的池化窗口，该窗口在输入图像的不同区域上滑动。每次滑动时，池化窗口会覆盖图像中的一个小区域，窗口内的像素值被提取出，同时保留区域内最显著的特征。假设输入图像为 I ，池化窗口大小为 $k \times k$ ，步长为 s ，则最大池化操作可以表示为：

$$O(i, j) = \max(I(p, q)) \quad (3-6)$$

$$p \in [i, i+k-1], q \in [j, j+k-1]$$

公式(3-6)中， $O(i, j)$ 是输出图像在位置 (i, j) 处的值， $I(p, q)$ 是输入图像在位置 (p, q) 处的值，池化窗口的范围是从 $[i, i+k-1]$ 和 $[j, j+k-1]$ 。这种操作通常在每次池化时都按照预设的步长在输入图像上移动窗口，步长一般设置为池化窗口的大小。

最大池化的一个显著优点是，它能够有效地从图像中提取局部的最显著特征，并通过抑制其他较小的特征来减少过拟合的风险。在图像分类任务中，池化操作能够帮助神经网络集中关注图像中的主要形状和边缘特征，而忽略噪声和不重要的细节。




图3.3 图像处理的最大池化表示

如图 3.3 所示，最大池化的操作对图像特征进行一种非线性映射。通过对每个池化区域选取最大值，池化操作能够压缩图像的空间信息，同时提高特征的抽象度。池化操作也有助于模型的平移不变性，即无论图像的特征在空间中如何移动，最大池化后得到的特征仍然能够在一定程度上保持一致。这一特性使得卷积神经网络能够对输入图像中的局部变化具有更好的适应性和鲁棒性。

然而最大池化也有其局限性，由于池化操作仅仅选取了局部区域的最大值，可能会丢失一些细节信息，特别是在图像中包含较为微小的关键特征时。最大池化操作虽然能有效减少计算量和参数数量，但有时可能导致信息的过度压缩，从而影响网络的表示能力。因此在一些复杂的图像处理任务中，会使用平均池化或者全局池化以补充最大池化的不足。最大池化作为一种下采样技术，通过选择局部区域内的最大值来简化图像的表达，增强特征的显著性和模型的鲁棒性。

非线性激活函数的引入，使神经网络具备了学习非线性映射的能力，这对于处理实际问题具有重要意义。，若没有非线性激活函数，即使网络的层数再多，整个网络的表现仍然等价于一个单一的线性模型，因为多个线性层的组合仍然是一个线性函数。这意味着网络无法有效地捕捉到数据中的复杂模式和关系。如此一来，网络便难以有效地捕捉数据中的复杂模式和关系。

较为常见的非线性激活函数是 ReLU 函数，其公式如下：

$$f(x) = \max(0, x) \quad (3-7)$$

ReLU 的特点是，当输入值为正时，输出与输入成正比；而当输入值为负时，输出为零。ReLU 能够保持正输入的梯度为常数，从而确保梯度在反向传播过程中

不会快速衰减^[58]。

常见的非线性激活函数还有 Sigmoid 函数，其公式如下：

$$f(x) = \frac{1}{1 + e^{-x}} \quad (3-8)$$

Sigmoid 函数的输出值为小于 1 的正数，但当输入值非常大或非常小时，梯度会趋近于零。

Tanh 函数是 Sigmoid 函数的一个变种，其公式为：

$$f(x) = \tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (3-9)$$

Tanh 函数的输出值范围是-1 到 1，更具对称性，能够更好地处理具有负值的输入数据。

除了这些经典的激活函数，近年来也出现了一些新的激活函数，如 Leaky ReLU 函数。Leaky ReLU 在 ReLU 的基础上进行改进，其公式为：

$$f(x) = \max(\alpha x, x) \quad (3-10)$$

公式(3-10)中， α 是一个小的常数，通常取值为 0.01。Leaky ReLU 允许在输入为负时，输出一个很小的负值，避免了 ReLU 在负值区间出现错误的问题。ELU 则通过对负值区域引入指数函数进行平滑，公式为：

$$f(x) = \begin{cases} x & x > 0 \\ [2ex]\alpha(e^x - 1) & x \leq 0 \end{cases} \quad (3-11)$$

ELU 在负区间的平滑性使得网络在训练过程中更加稳定，同时能加速收敛。

非线性激活函数的引入使得神经网络能够在多个层次上构建复杂的特征抽象，提升了模型的表达能力和训练效果。通过非线性激活，网络不仅能适应简单的线性

问题，还能够处理图像、语音、文本等复杂的高维数据。

3.2.5 输出投影及推理

在图像处理中，输出投影是将神经网络的输出张量经过一定的处理和映射操作，最终生成目标所需的输出格式或结果的过程。其输出投影的核心在于将网络预测的特征张量映射为每个网格单元上的目标类别概率、边界框参数以及置信度分数，以实现目标的定位和分类任务^[59]。

假设输入图像经过卷积神经网络处理后得到的特征张量具有尺寸 $S \times S \times (C+B \times 5)$ ，其中 $S \times S$ 表示图像被划分为 $S \times S$ 的网格，每个网格单元负责检测一个目标； C 是目标类别的总数； B 表示每个网格预测的边界框数量，5 代表每个边界框的参数，包括中心坐标 (x, y) 、宽高 (w, h) 以及置信度分数。为了能够正确解释这些信息，网络的输出需要投影到每个网格单元，并进行后续的激活处理。

具体而言，输出投影过程首先需要将预测的张量拆解为类别概率和边界框参数。对于每个网格单元的类别预测，类别概率需要满足归一化条件，即所有类别的概率之和为 1，这通常通过 Softmax 函数实现。Softmax 函数的公式为：

$$\sigma(z)_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}} \quad (3-12)$$

公式(3-12)中， z_i 是原始预测值， i 是类别总数， $\sigma(z)_i$ 表示归一化概率值。通过 Softmax 函数，网络可以输出每个类别的概率分布，便于后续分类任务。

对于边界框参数，网络输出的中心点坐标 (x, y) 和宽高 (w, h) 通常经过特定的变换，以确保预测的边界框能够正确映射到图像的原始尺度上。变换的方式可能包括对坐标的归一化处理、相对网格单元的偏移调整，以及对宽高的指数变换，以适应目标在图像中的实际大小。

在整个输出投影过程中，还需要计算每个网格单元的置信度分数，表示该单元内是否存在目标，以及预测的边界框是否准确。置信度分数的计算通常结合目标的存在性概率和边界框与真实值的匹配程度，一般通过 IoU (Intersection over Union) 度量。

因此输出投影是深度学习中不可缺少的一个环节，它将网络的高维预测张量映射到人类或应用需求所需的输出格式上。通过合理的数学变换，输出投影不仅能够提升结果的解释性，还能够在后续的任务中提高预测精度和鲁棒性。这一过程在图

像分类、目标检测和分割等任务中均有广泛应用。

在图像处理中，推理是指利用训练好的深度学习模型对输入图像进行分析和处理，以预测目标信息的过程。在目标检测任务中，推理的核心是根据模型的输出结果，结合类别概率、边界框参数和置信度等信息，确定图像中目标的位置和类别。以 YOLO 模型为例，其推理过程主要包括从网络输出中提取相关信息、筛选有效目标以及优化检测结果等步骤。

在获取预测结果后，推理的第二步是筛选有效目标，通常通过设定置信度阈值来剔除低置信度的边界框，从而减少误检，为了解决同一目标可能被多个边界框预测到的问题，一般采用采用非极大值抑制方法，删除相似度高的边界框，只留置信度最高的部分。

在推理过程中，还需要对边界框参数进行尺度变换，以确保其适配输入图像的实际尺寸。模型输出的边界框中心坐标和宽高通常是相对于网格单元的归一化值，需要结合图像的实际大小反算出目标在原图中的位置。

推理的最后一步是将筛选后的结果输出，包括目标类别、边界框的坐标以及置信度分数。这些信息可以进一步用于可视化或后续任务。推理的效率和准确性直接影响目标检测系统的实时性和鲁棒性，因此需要在网络设计和实现过程中对推理阶段进行优化。推理是图像处理任务中将网络预测结果转化为目标检测或分类输出的关键过程，通过对输出结果的筛选和优化，能够获得高质量的检测结果。这一过程结合了数学计算、筛选算法和变换操作，是深度学习模型在实际应用中的核心步骤。

3.3 海面小目标多特征图像预处理方法

3.3.1 单特征数据图像化存在问题

计算机处理图像信息时，会把图像矩阵分解为 RGB（Red、Green、Blue）三个矩阵。RGB 三个通道的组合可以表示出各种颜色，并且每种颜色的三原色组成唯一。图像可以看作是一个二维的像素矩阵，每个像素点由三个颜色通道的值来表示：红色通道、绿色通道、蓝色通道。每个通道的值通常范围是 0 到 255，表示从暗到亮的颜色强度。如果图像的大小为 $m \times n$ ，那么其对应的 R、G、B 通道矩阵大小也都为 $m \times n$ 。矩阵中的每个元素代表对应像素在该颜色通道的强度。

当用单特征信息绘图时，以相对多普勒峰高为例，先把相对多普勒峰高值映射到颜色条上，然后对每个距离单元的不同时间的相对多普勒峰高的数值绘图，如图 3.4 所示，相对多普勒峰高从 4.7 变化到 4.4，用来表示其的颜色从 [245, 255, 102] 变化到 [255, 165, 0]，差值为 [-10, 90, 102]。但是用三个颜色通道值的变化来表示一个特征信息 0.3 的波动显然浪费了两个信息通道，因为一个颜色通道的变化就完全可以代表单特征信息的变化，所以本文想从这方面入手充分利用信息通道，不用 RGB 三个颜色通道值的变化来表示单特征变化，而是把提取到的三特征信息代替 RGB 三通道，使得三个颜色通道值的变化对应三个种类特征值的变化。




图3.4 单特征数据图像化处理

3.3.2 多特征数据图像化方法

针对单特征数据图像化中存在的信息通道利用率低的问题，本文提出直接用三特征信息代替 RGB 三通道，省去映射到颜色条的步骤，因为深度学习模型对每个输入的图片都分解为 RGB 三个矩阵之后分别进行特征提取以及特征之间的融合，采用本文的三特征图像化处理方法之后，就能实现同一距离单元的三特征信息在同一图像中表示，这样在后续的深度模型中就能对同一距离单元的三特征信息提取和融合。

本方法处理步骤如下，先提取雷达回波信息中的三个特征 RAA、RDPH 和 RVE，再进行归一化处理，缩放至 0 到 255 的 RGB 值的范围，然后将缩放后的三维特征映射到 RGB 三通道，每个距离单元的三个特征值生成一个对应的像素，接着根据三维特征的 RGB 值创建图像并做放大处理，标注好目标单元后，就可以放入深度学习模型进行训练和检测。数据处理的流程如图 3.5 所示。




图3.5 数据预处理流程图

多特征数据图像化处理的具体流程如下：

1、三特征提取：对雷达回波序列 $s(n)$ 分别提取3个特征RAA、RDPH和RVE，并将其分别组成特征矩阵 S_0 、 S_1 和 S_2 ，这三个矩阵都为 $m \times n$ 的矩阵，其中 $m=1024/N$ 是特征数量， N 为观测时间步长， $n=14$ 是距离单元数量。

2、数据放大处理：由于RGB值的范围为0到255，需要将三维特征值缩放到这个范围内。

$$S = \frac{a * S}{S_{\max} - S_{\min}} \quad (3-13)$$

$a=255$ 是RGB的范围最大值， $S_{\max}$ 和 $S_{\min}$ 是S矩阵中的最大值和最小值。

3、特征数据映射：将归一化后的三维特征映射到RGB通道。特征RAA映射到R通道，特征RDPH映射到G通道，特征RVE映射到B通道。

4、图片生成：图片生成，根据三维特征映射的值创建图片，并对图片进行变形处理，由 1×14 的矩阵变换为 2×7 的矩阵，每个距离单元三特征生成一个对应的像素块。再把每个像素块放大100倍，这样每个观测时间内就可以生成一张 200×700 像

素的图片。

3.3.3 多特征数据图像化处理优势

雷达微弱目标的回波信号受到杂波、噪声或其他因素影响，使其信噪比很低。单一维度特征不足以准确地检测和识别目标，多维特征融合检测则可以提高对微弱目标的检测性能。如图 3.6 是现有的三特征检测和深度学习模型结合的常用处理方法，可以看出，需要将三特征提取出来后分别经过特征提取网络处理，再进行三特征融合，这样的处理方法虽然能实现很好的检测效果，但是模型搭建复杂能参考的深度学习模型很少，并且需要三个特征提取网络^{[60][61]}。如图 3.7 所示，通过本文所提多特征图像预处理之后，在不损失信息量的情况下，可以将三个特征提取网络缩减到一个，降低了模型复杂度和计算成本，并且通过本文方法处理之后的数据也能适用于流行的成熟模型，减少了模型搭建的工作量，为海面小目标多特征检测与深度学习模型的结合提供了全新的思路，大大降低了学习门槛。




图3.6 现有的三特征处理方法




图3.7 本文所提的三特征处理方法

对于如图 3.6 所示的现有的三特征检测和深度学习模型结合的常用处理方法，当输入 x 张像素大小为 $m \times n$ 的特征图像时，由于电脑处理图像信息都是把其分解为 RGB 三个矩阵再进行处理，所以输入的数据量为 $3 \times x \times m \times n$ ，对于如图 3.7 本文所提三特征信息图像预处理处理方法，当输入 x 张大小为 $m \times n$ 的特征图像时，因为经过预处理部分，所以输入的数据量为 $x \times m \times n$ 。用过上述分析能看出来，不仅数据量减少了三分之二，并且能简化现有模型的特征提取网络部分，大大减少了计算复杂度。

3.4 基于多特征图像预处理的深度学习检测

基于多特征图像预处理的深度学习检测方法旨在解决海面小目标检测中多特征信息难以有效利用的问题。在传统目标检测任务中，深度学习模型通常以单一特征为输入，如纯视觉信息或特定传感器数据。然而，针对海面复杂环境和小目标难以识别的特点，单一特征往往无法全面描述目标的多维特性，容易受到背景杂波、目标尺度变化以及环境动态性的影响^{[62]-[65]}。因此，本研究提出了一种多特征图像预处理方法，通过将多个具有互补信息的特征图像进行融合，构建出一幅综合特征图像，为深度学习检测模型提供统一的高维特征输入。这一方法不仅能够保留各特征间的相关性，还能显著降低模型对单一特征异常值的敏感性，从而提升目标检测的鲁棒性和准确性。

为了验证多特征图像预处理方法的实际应用效果，本研究选择了三种主流目标检测模型——YOLO、SSD 和 DETR，对融合后的多特征图像进行检测验证。利用实测雷达回波数据构建了多维特征数据集，并对比了融合前后在各深度学习模型上的检测性能。

3.4.1 SSD 模型

SSD (Single Shot MultiBox Detector) 是一种高效的单阶段目标检测算法, 其设计初衷是同时兼顾检测的实时性和精度。通过一次性完成目标的分类与定位任务, SSD 避免了传统双阶段检测器中复杂的区域提议生成和特征重采样步骤, 使检测流程更加简洁高效。SSD 的结构主要由基础特征提取网络、多尺度特征图、默认框设计以及多任务损失函数组成, 每一部分均在优化检测性能和速度方面发挥了重要作用。

在结构设计上, SSD 使用卷积神经网络作为基础特征提取模块, 最初版本使用的是 VGG16。为适应目标检测任务, SSD 对原有的 VGG16 网络结构进行了调整, 包括移除全连接层, 并在后续加入额外的卷积层^[66]。这些附加卷积层的目的是通过逐渐减小的特征图分辨率提取更深层次的语义信息, 同时确保模型能够关注图像中的不同目标尺度。通过这一改动, SSD 能够高效捕捉全局上下文信息和局部目标特征, 为后续检测任务打下基础。




图3.8 SSD 网络模型结构

SSD 最具创新性的一点是采用多尺度特征图的检测机制。如图 3.8 所示, 在模型的特征提取过程中, 不同层次的特征图分别用于检测不同大小的目标^[67]。浅层特征图因分辨率较高, 适合捕捉小目标的细节信息; 而深层特征图分辨率较低, 但语义信息更丰富, 更适合检测大目标。各层特征图输出的检测结果经过整合, 最终形成对目标大小和位置的全面覆盖。这种多尺度设计不仅提升了对小目标的检测能力, 还有效提高了对场景中多样化目标的适应性。

SSD 在性能和效率之间可以达到良好的平衡, 但其在小目标检测的场景中仍存

在一定局限性。尤其是对于背景噪声复杂的情况，默认框的重叠预测和后续的非极大值抑制可能导致检测精度下降。SSD 通过引入多尺度特征图和默认框等关键机制，在单阶段检测框架中实现了高效的目标分类与定位。其结构设计简化了传统检测流程，提升了实时检测能力。作为一个经典的检测模型，SSD 不仅在实际应用中表现出色，也推动了目标检测技术的发展与进步。

3.4.2 YOLO 系列模型

YOLO (You Only Look Once) 系列模型属于目标检测领域中一类高效的单阶段检测算法，凭借出色的实时性和良好的检测性能在众多场景中广泛应用。从初代 YOLO 到当下最新版本，其模型架构持续优化，性能稳步提升，同时也秉持了 YOLO 系列一贯的设计思路，即在单次网络前向传播中完成目标定位与分类。以下将阐述 YOLO 系列模型的架构演变与核心要点。

初代 YOLO 模型提出了一种全新的目标检测思路：把检测任务转变为一个单一的回归问题，将输入图像划分为确定数量的网格，每个网格预测多个边界框以及对应的置信度和类别概率^[68]。这种方法显著精简了检测流程中的冗余环节，达成端到端的高效检测。具体而言，YOLO 以整幅图像作为输入，经由卷积神经网络提取特征，最终在全连接层输出检测结果。这种简单高效的设计使 YOLO 在实时检测任务中表现出色，但其早期版本在处理小目标和目标密集场景时性能有限。

随着 YOLO 模型的发展，YOLOv2 和 YOLOv3 引入了多项改进以提升检测性能。YOLOv2 选用 Darknet-19 网络担当特征提取器，并引入批量归一化以增强训练的稳定性。YOLOv3 在此基础上进一步改进，通过引入多尺度特征检测机制大幅提升了对小目标的检测能力。YOLOv4 和 YOLOv5 是 YOLO 系列的里程碑版本，它们在检测精度和速度之间达成了更好的平衡。YOLOv4 引入了许多先进的深度学习技术用于捕捉多尺度信息。YOLOv5 在 YOLOv4 的基础上进行了一些轻量化和优化，使其在嵌入式设备上也能流畅运行。

YOLOv6 特别关注工业场景中高精度、高速度的需求，通过设计高效的模型结构实现了更快的推理速度。YOLOv7 进一步优化了模型结构，并引入更先进的架构，以提高模型在多任务场景下的表现能力。YOLOv8 是当前 YOLO 系列中工程应用最多的版本之一，具备更强的适应性和扩展性，可以很好地处理复杂背景下的目标检测任务。YOLOv11 和前代比较进步不算大，应用也比较少。

YOLO 系列模型的优势在于其端到端检测方式和高效性，而这些特性来自其独特的设计理念。YOLO 通过一次网络推理同时完成目标分类和定位，减少了冗余计算。而且通过引入锚框机制和多尺度特征融合，能够灵活应对不同尺寸目标的检测需求。YOLO 系列通过持续优化特征提取网络和损失函数，提升了模型的检测精度，

特别是在小目标检测和复杂背景环境下的表现。YOLO 系列模型从初代到最新版本，在保持实时检测能力的同时，通过引入先进的深度学习技术，不断提升检测精度和鲁棒性。其结构演变展示了深度学习在目标检测领域的技术积累与突破，为各种实际应用提供了强大的技术支撑。由于本文的核心不是模型的使用，所以下面的实验模型采用的是应用广泛的 YOLOv8 版本。

3.4.3 DETR 模型

DETR (Detection Transformer) 是由 Transformer 架构引领的目标检测模型，其独特的结构和设计理念为目标检测领域带来了革命性的变化。与传统的目标检测算法不同，DETR 彻底摒弃了锚框、默认框和区域提议等复杂机制，继而通过端到端的模式直接预测目标框的位址和类别^[70]。这种创新不仅简化了模型架构，也显著增强了检测过程的可解释性和训练的稳定性。

如图 3.9 所示，DETR 的核心架构由三个主要部分构成：特征提取网络、Transformer 模块和预测头。特征提取网络通常运用经典的卷积神经网络来抽取图像的深度特征，并生成富含语义信息的特征图。该部分的主要功用是将原始图像的信息进行压缩处理，转换成一个紧凑的特征表示，以便后续的 Transformer 进行处理^[71]。与其他检测模型相比，DETR 不依赖于多尺度特征图，而是直接利用单一特征图完成所有目标的检测任务。

DETR 的输出由预测头生成，它直接对解码器的输出进行处理，生成目标框的位置和类别预测。目标框的位置回归采用的是中心点坐标、宽度和高度的形式，而类别预测则通过一个分类器完成。在处理背景区域部分，DETR 引入了一个特殊的“无目标”类别，用以区分实际目标和背景区域。这种设计不仅使模型的输出更加明确，也避免了复杂的后处理步骤^[72]。

DETR 的设计思路虽然简洁，但其效果却十分良好。由于 Transformer 的全局建模能力，DETR 在处理目标间复杂关系和背景噪声时表现优异。端到端的检测框架使得 DETR 不需要依赖任何额外的后处理步骤，从而显著提升了检测的效率和可靠性。DETR 还展示了极高的扩展性，其 Transformer 架构能够无缝集成到其他视觉任务中^{[73]-[79]}。

DETR 通过 Transformer 的引入，将目标检测从传统的区域提议与特征匹配模式转向了全局建模和端到端优化。它的设计不仅在概念上简化了目标检测任务，还为整个计算机视觉领域提供了一种全新的研究方向。DETR 的成功展示了 Transformer 在视觉任务中的巨大潜力，同时也激励了后续的研究者探索更加高效和普适的检测模型，为目标检测技术的发展开辟了新的可能性。




图3.9 DETR 网络模型结构

在本节中，系统地梳理了多特征图像预处理方法结合深度学习模型的基本原理和实际应用可能性。结合 SSD、YOLO 以及 DETR 三种主流目标检测模型的结构特点和技术优势，可以清晰地看出，多特征图像预处理在深度学习检测任务中的潜力和实际价值。这种方法通过将目标的多维特征信息融合成一张特征图，打破了传统深度学习模型在处理多输入、多通道特征时的适配瓶颈。这种统一的特征表示形式不仅能够简化检测流程，还可以显著提高模型在复杂环境下的目标检测能力。

多特征图像预处理方法的核心优势在于它的适配性和通用性。通过融合多维特征信息，不仅能够提升检测模型对目标的分类和定位能力，还能在一定程度上减少模型的参数量。传统的深度学习检测模型往往依赖于多层次的特征提取过程，这不可避免地增加了计算复杂度。而通过预处理将多种特征整合到一张图像中，模型可以以更少的参数量完成相同的检测任务。这种参数量的减少不仅能够降低硬件资源的需求，还能加速推理过程，提高模型的实时性，这对于资源受限的场景应用如嵌入式设备具有重要意义。

下一节将以实验验证为核心，探讨多特征图像预处理方法在目标检测任务中的实际表现。将基于 SSD、YOLO 和 DETR 三种检测模型，设计一系列对比实验，分析预处理方法在检测精度、召回率、网络参数量以及计算效率等方面的影响。实验的重点将聚焦于小目标检测性能的提升和参数量的优化效果。通过对比预处理前后模型的性能指标，证明多特征图像预处理方法不仅在理论上具有优势，在实际应用中同样能够显著提高检测效率。

3.5 实验结果与检测性能分析

3.5.1 实验平台配置

本次实验是在 Windows 10 的操作系统下配置，其中 CPU 型号为 Intel(R) Core(TM) i9-14900KF3.20 GHz，运行内存为 128 GB，GPU 型号为 NVIDIA GeForce RTX4090，深度学习框架为 Pytorch2.2.1 +cu121，运算架构为 CUDA12.4，开发环境是 Python3.9。

3.5.2 多特征图像预处理前后输入的数据量对比

实验中，共有十组实测数据，每组由 217 个脉冲和 14 个距离单元构成，涵盖了 HH、VV、HV 和 VH 四种极化模式。从表 3.1 可以看出，多特征图像经过预处理后，数据量发生了明显变化。在数据量方面，处理前为 24576MB，处理后大幅减少至 8192MB，减少了 16384MB，这表明预处理有效地降低了数据的存储大小，能节省大量存储空间。在图像数量方面，处理前有 61440 张，处理后变为 20480 张，减少了到原来的三分之一，说明预处理过程中对多特征图像进行了融合，使得图像数量大幅下降。在像素数方面，处理前数量为 86×10^8 ，处理后降到 28.7×10^8 ，减少了 57.4×10^8 ，说明了本文所提的预处理方法可以去除冗余的像素信息，提高了信息利用率。

通过对比预处理前后的数据量存储大小，图像数量以及像素数，可以看出本文所提方法都能对上述衡量指标产生显著的减少作用，可以提高数据处理的效率，减少计算资源的消耗，同时也可能有助于去除一些噪声和冗余信息，为后续的深度学习模型训练等操作提供更简洁、有效的数据输入，提升整体的数据质量和处理效果。但是在减少数据量的同时，也需要要确保重要信息不丢失，以免影响最终的处理结果和模型性能，因此需要做进一步的实验计算图像预处理前后的检测准确度，以此得出多特征信息在预处理过程中的的损耗程度。

表3.1 多特征信息预处理前后数据量对比

名称	处理前	处理后	减少量
数据量/MB	24576	8192	16384
图像数量/张	61440	20480	40960
像素数/ 10^8	86	28.7	57.4

从表 3.2 可以看出，在多特征信息预处理前，三种检测器的平均检测概率有所

不同。YOLO 检测器的平均检测概率最高，为 92.425%，其次是 DETR 检测器，为 92.250%，SSD 检测器相对较低，为 90.375%。具体到不同特征维度，HV 和 VH 维度上，三种检测器的检测概率都较高，而在 HH 和 VV 维度上，检测概率相对较低。这表明在预处理前，不同检测器在不同特征维度上的表现存在差异，可能与检测器自身的算法特点和对不同特征的敏感度有关。

由表 3.3 可知，经过预处理后，三种检测器的平均检测概率均有所提升。YOLO 检测器依然保持领先，平均检测概率达到 95.075%，DETR 检测器提升至 94.750%，SSD 检测器提升到 93.625%。对比预处理前后，各检测器在不同特征维度上的检测概率也有变化，SSD 检测器在 HH 和 VV 维度上的检测概率提升较为明显，DETR 检测器在各维度上也有不同程度的提高，YOLO 检测器同样在各维度上表现更佳。这说明预处理操作对各检测器的性能有积极影响，可能是通过优化数据特征等方式，使得检测器能够更准确地进行检测。

通过对比预处理前后检测准确度的表格，可以发现本文所提的预处理方法不仅在数据量等方面有显著的优化效果，还能提升检测器的检测准确度。这进一步证明了该预处理方法的有效性和实用性。

表3.2 多特征信息预处理前检测器的平均检测概率

检测器	HH/%	HV/%	VH/%	VV/%	平均/%
SSD 检测器	86.2	95.5	95.7	84.1	90.375
DETR 检测器	88.3	96.8	97.6	86.3	92.250
YOLO 检测器	89.9	96.6	96.7	86.5	92.425

表3.3 多特征信息预处理后检测器的平均检测概率

检测器	HH/%	HV/%	VH/%	VV/%	平均/%
SSD 检测器	89.2	98.5	97.7	89.1	93.625
DETR 检测器	91.3	98.8	98.6	90.3	94.750
YOLO 检测器	93.6	98.3	97.5	90.9	95.075

从表 3.4 可知，在多特征信息预处理前，三种检测器的实际虚警率存在差异。YOLO 检测器的平均虚警率最低，为 0.0027，表现较为出色。DETR 检测器平均虚警率 0.0035，处于中间水平；SSD 检测器平均虚警率相对较高，为 0.0039。具体到不同特征维度，HV 和 VH 维度上，各检测器的虚警率普遍较低，而在 HH 和 VV 维

度上，虚警率相对较高。这说明在未进行预处理时，不同检测器在不同特征维度上的虚警情况有所不同，可能与各检测器对不同特征的处理方式和敏感度有关。

由表 3.5 可知，经过预处理后，三种检测器的实际虚警率均有明显下降。YOLO 检测器的平均虚警率降至 0.00118，下降幅度较大，优势更加明显；DETR 检测器平均虚警率降到 0.00207，也有显著降低；SSD 检测器平均虚警率变为 0.00283，同样有所改善。从各维度来看，预处理后各检测器在 HH、HV、VH、VV 维度上的虚警率大多都降低了，这表明预处理操作对降低虚警率起到了积极作用，可能是通过优化数据特征、减少噪声等方式，使得检测器在检测过程中产生误报的情况减少。

通过对比预处理前后的虚警率表格，可以看出本文所提的预处理方法不仅在数据量等方面有良好的优化效果，还能有效降低检测器的虚警率，这对于海目标检测等应用具有重要意义。较低的虚警率意味着检测结果更加准确可靠，能够减少不必要的干扰和误判，提高检测系统的实用性和效率。

表3.4 多特征信息预处理前检测器的实际虚警率

检测器	HH	HV	VH	VV	平均
SSD	0.0047	0.0024	0.0027	0.0058	0.0039
DETR	0.0049	0.0018	0.0019	0.0054	0.0035
YOLO	0.0032	0.0021	0.0020	0.0035	0.0027

表3.5 多特征信息预处理后检测器的实际虚警率

检测器	HH	HV	VH	VV	平均
SSD	0.0037	0.0018	0.0019	0.0039	0.00283
DETR	0.0026	0.0014	0.0010	0.0033	0.00207
YOLO	0.0016	0.0010	0.0008	0.0013	0.00118

3.5.3 多特征图像预处理前后深度学习网络参数对比

通过对比多特征图像预处理前后的数据量，检测准确度以及虚警率，可以看出，本文所提的多特征图像预处理方法不仅能降低输入的数据量，还能对检测准确率以及虚警率的控制上有所提高，充分展现了本文所提方法的有效性，下面要对深度学习网络的各种参数进行比较，以此来证明本文所提的多特征图像预处理方法确实起到了减少模型训练时间以及轻量化网络结构的作用。

从表 3.6 可以看出, 在多特征信息预处理之前, 三种检测器的训练时间存在一定差异。YOLO 检测器在各个维度上的训练时间相对较长, 平均训练时间为 0.00118h, 这可能与其模型结构和算法复杂度有关; DETR 检测器的平均训练时间为 0.00207h, 处于中间水平; SSD 检测器的平均训练时间为 0.00283h, 相对较短。这表明在未进行预处理时, 不同检测器的训练效率有所不同, 训练时间的长短会影响模型的开发和应用效率。

观察表 3.7, 经过预处理后, 三种检测器在各个维度上的训练时间均显著减少。SSD 检测器的平均训练时间降至 0.00283h, DETR 检测器平均训练时间降到 0.00207h, YOLO 检测器平均训练时间变为 0.00118h。具体来看, 各检测器在 HH、HV、VH、VV 维度上的训练时间都有不同程度的缩短, SSD 检测器在 HH 维度上从 11.39h 降至 6.78h, YOLO 检测器在 VV 维度上从 13.35h 降至 8.32h 等。说明本文所提的多特征图像预处理方法在减少模型训练时间方面效果显著, 大大提高训练效率, 缩短模型训练时间。

通过对比预处理前后的训练时间表格, 可以清晰地看到预处理方法对不同检测器训练时间的积极影响。证明了该预处理方法确实能够起到减少模型训练时间的作用, 为实际应用中提高深度学习模型的训练效率提供了有力支持。较短的训练时间意味着可以更快地进行模型迭代和优化, 降低时间成本和计算资源消耗。从侧面反映了预处理方法对网络结构起到了轻量化作用, 使模型在训练过程中能够更高效地处理数据, 进一步验证了本文所提方法的有效性。

表3.6 多特征信息预处理前训练时间对比

检测器	HH/h	HV/h	VH/h	VV/h	平均/h
SSD 检测器	11.39	10.87	10.46	11.07	10.95
DETR 检测器	12.57	10.58	10.39	12.48	11.51
YOLO 检测器	13.46	11.49	11.33	13.35	12.41

表3.7 多特征信息预处理后训练时间对比

检测器	HH/h	HV/h	VH/h	VV/h	平均/h
SSD 检测器	6.78	6.58	6.52	7.16	6.76
DETR 检测器	6.53	6.49	6.45	6.88	6.59
YOLO 检测器	7.53	7.22	7.16	8.32	7.56

图像预处理后的目标大小为确定的，因此检测头保留其中一个即可，根据这一特性，可以对检测器进行轻量化处理，进而减少参数量以及模型大小，下面进行实验分析。在多特征信息预处理之前，从表 3.8 可知，三种检测器在模型大小、参数量以及 $mAP@0.5/\%$ 指标上差异明显。DETR 检测器模型最大，达 125.6MB，参数量最多，为 86.17×10^6 ， $mAP@0.5/\%$ 为 97.3%；SSD 检测器模型大小为 110.7MB，参数量 33.5×10^6 ， $mAP@0.5/\%$ 是 94.8%；YOLO 检测器模型最小，仅 6.2MB，参数量 3.52×10^6 ， $mAP@0.5/\%$ 为 96.9%。经过预处理后，如表 3.9 所示，DETR 检测器模型大小降至 101.3MB，参数量降到 76.01×10^6 ， $mAP@0.5/\%$ 提升至 97.8%；SSD 检测器模型变为 93.7MB，参数量为 25.73×10^6 ， $mAP@0.5/\%$ 提高到 96.2%；YOLO 检测器减小到 5.8MB，参数量降至 3.27×10^6 ， $mAP@0.5/\%$ 上升到 98.9%。综上所述，本文所提的多特征图像预处理方法不仅能减小模型大小和参数量，实现检测器轻量化，还能提升模型检测性能，轻量化后的模型可在资源有限设备上高效运行且保持较高检测精度。

表3.8 多特征信息预处理前模型大小对比

检测器	$mAP@0.5/\%$	参数量/ 10^6	模型大小/MB
SSD 检测器	94.8	33.5	110.7
DETR 检测器	97.3	86.17	125.6
YOLO 检测器	96.9	3.52	6.2

表3.9 多特征信息预处理后模型大小对比

算法	$mAP@0.5/\%$	参数量/ 10^6	模型大小/MB
SSD 检测器	96.2	25.73	93.7
DETR 检测器	97.8	76.01	101.3
YOLO 检测器	98.9	3.27	5.8

3.6 本章小结

本章针对海面小目标检测中的多特征图像预处理问题进行了深入研究，并提出了一种有效的解决方案。通过对现有方法的分析，可以发现传统方法在处理多特征数据时存在信息丢失和计算量大的问题。为此，本文提出了一种将多特征信息融合到一张图像中的方法，显著减少了数据量，同时保留了关键信息。这一方法不仅提高了深度学习模型的训练效率，还为后续的检测任务提供了更高质量的数据输入。

本章详细介绍了多特征图像预处理的具体步骤，包括特征提取、归一化处理、特征映射到 RGB 通道以及图像生成等。通过将三个特征值分别映射到 RGB 三个通道，成功地将多特征数据融合到一张图像中。这种方法不仅减少了数据量，还简化了模型的输入形式，使得深度学习模型能够更高效地处理多特征数据。

接着本章探讨了多特征图像预处理的优势。通过 4.3.2 节和 4.3.3 节实验对比发现，这种将多特征信息融合到一张图像中的方法，不仅减少了数据量，还降低了模型的计算复杂度。这种方法还能够提高模型的训练速度，减少训练时间，同时保持较高的检测准确率和虚警率。通过实验验证，可以发现预处理后的数据在深度学习模型中的表现优于传统方法，证明了其在水面小目标检测中的有效性。

本章通过多特征图像预处理方法的提出和改进，为海面小目标检测提供了一种高效、准确的解决方案。这一方法不仅解决了传统方法中的数据量大和计算复杂度高的问题，还为深度学习模型的应用提供了更高质量的数据输入。下一章将根据本章所提的多特征图像预处理方法特点，对深度学习模型（以 YOLOv8 为例），进行轻量化处理和改进，进一步探讨其在实际应用中的性能和优势。

第四章 基于多特征图像预处理的改进深度学习模型检测

4.1 引言

在海面小目标检测领域，如何平衡检测精度、实时性以及模型的适应性，是当前面临的关键挑战。第三章中提出的多特征图像预处理方法，通过将 RAA、RDPH 和 RVE 三个关键特征归一化映射至 RGB 通道，成功解决了传统检测方法中多特征数据处理复杂、模型适配性差的问题。这种预处理方式不仅显著降低了数据量，还为深度学习模型的应用提供了高质量的数据输入。

然而，尽管多特征图像预处理方法在数据层面为后续检测任务提供了有力支持，但在模型选择与优化方面仍存在进一步提升的空间。本章以 YOLOv8n 模型为例，做符合数据集特点的轻量化改进。YOLOv8n 模型虽然在一定程度上兼顾了速度与精度，但其原始架构并非专为海面小目标检测场景设计，直接应用时仍面临模型复杂度较高、参数量较大等问题，这在资源受限或对实时性要求极高的应用场景中显得尤为突出。此外，海面小目标检测对虚警率的控制有着严格要求，而传统训练流程下虚警率的稳定性难以保障。

因此，本章致力于对 YOLOv8n 模型进行针对性改进与轻量化处理。基于第三章多特征图像预处理方法的特点以及构建的数据集特性，通过重构检测头结构、引入 C2f 模块压缩参数量、集成 CBAM 注意力机制增强特征区分度等手段，对 YOLOv8n 模型进行优化。同时，引入动态阈值调整策略改进训练流程，以实现虚警率的有效控制。通过在公开的 IPIX 雷达数据集上进行对比实验，验证改进模型在检测精度、虚警率控制以及计算效率等方面的性能提升。这一研究不仅为海面小目标检测提供了更为高效、精准的解决方案，也为深度学习技术在雷达信号处理领域的工程化应用提供了重要参考。

4.2 深度学习模型网络结构

YOLOv8 的架构，如图 4.1 所示，主要由四个核心模块组成：输入层、主干特征提取网络、特征提取网络以及检测头网络。这些模块的设计是为了最大化提高模型的检测性能、加速模型的训练和推理速度，并增强其对不同尺度物体的感知能力。在 YOLOv8 的设计中，许多改进和创新技术都被引入，以便在保持高效的计算和推理速度的同时，提高目标检测的准确性和鲁棒性。

（1）输入层

YOLOv8 的输入层在目标检测过程中发挥着至关重要的作用，主要涉及三个关键技术，Mosaic 图像增强、自适应锚框计算和自适应图像缩放。Mosaic 图像增强技术通过将四张不同来源和内容的图像拼接成一张新的图像，从而在训练阶段增加了图像的多样性和复杂性。这种增强方法能有效提高模型的泛化能力，使其能够更好地适应各种环境下的目标检测任务。通过在训练过程中加入更多的图像变化，模型可以学到更加丰富和全面的特征，从而提升目标检测的准确性。

自适应锚框技术是 YOLOv8 的一项创新，使得模型能够在训练过程中自动学习和调整最适合当前输入图像的锚框参数。这种技术不仅提高了模型的稳定性，而且消除了人工设置锚框的繁琐步骤。通过自适应锚框，模型能够更加灵活地应对不同尺寸和形状的目标，从而提升检测精度。自适应图像缩放技术则根据输入图像的尺寸自动调整其大小，确保图像输入网络时不会因为尺寸差异而影响模型性能。

（2）主干特征提取网络

YOLOv8 的主干网络采用了经过优化的 CSP Dark Net-53 结构，这一网络能够高效提取图像中的多层次特征。主干网络的任务是从输入图像中提取出基础的特征，如边缘、纹理以及局部的物体区域。为了进一步提升主干网络的特征提取能力，YOLOv8 采用了多个模块来增强特征的捕捉和表达能力，特别是在捕捉多尺度特征方面表现尤为突出。C2F 模块则通过跨阶段连接，优化了网络的流动性和特征重用，进一步提升了网络的性能和效率。快速空间金字塔池化模块则通过多尺度的池化操作，增强了模型对不同尺寸物体的感知能力，尤其在复杂的场景中，能够捕捉到细粒度的特征。

在网络的前期阶段，主干网络主要专注于提取低级特征，如图像的边缘和纹理等简单信息；随着网络的深入，逐步提取更为复杂的特征，包括物体的局部细节和高级语义信息。这些从图像中提取到的丰富特征随后会被传递到特征提取网络中，进行进一步的处理和融合。

（3）特征提取网络

YOLOv8 的特征提取网络由特征金字塔网络（FPN）和路径聚合网络（PAN）共同组成，它们通过不同的结构互相配合，提高了特征融合的效果。FPN 通过构建多层次的特征金字塔，使得模型能够在不同的尺度上感知物体，从而更好地应对尺度变化大的物体。在目标检测中，不同尺寸的物体往往具有不同的特征表达方式，FPN 通过多尺度特征融合，增强了对不同尺寸物体的感知能力。

PAN 则通过加强不同尺度特征之间的聚合，进一步优化了网络的特征融合能力。PAN 能够在多个尺度之间传递重要信息，避免了在进行多尺度融合时可能出现的信息丢失问题。这两种网络结构的结合，优化了目标检测的精度和鲁棒性，使得 YOLOv8 在处理复杂场景时，能够更好地整合空间和语义信息，确保特征的有效表

达。

Neck 层的作用不仅仅是简单的特征融合，它还充当了主干网络与检测头网络之间的桥梁。通过在这一层对提取到的特征进行进一步的加工和细化，YOLOv8 能够更精准地传递特征信息，提高最终检测的效果。

（4）检测头网络

YOLOv8 的检测头部分是目标检测系统的最后一环，负责根据主干网络和特征提取网络提供的特征进行目标的分类、定位以及实例分割。Head 部分一般由多个小型子网络组成，每个子网络负责完成一个特定的任务。通过对 Neck 层传递过来的多尺度特征进行进一步处理，Head 网络能够为每个目标生成准确的预测结果。

（5）模型版本选择

目前，YOLOv8 官方提供了多个不同规模的版本。这些版本在网络宽度和深度上有所差异，以适应不同的检测需求。在选择模型时，要综合考虑模型的推理速度和计算资源需求。

在本文中，基于检测速度和准确性的权衡，选择了 YOLOv8n 作为基准模型进行目标检测。YOLOv8n 相较于其他版本具有较小的深度和特征图宽度，因此在速度和稳定性方面表现出色。该模型不仅能够快速进行推理，同时还能够在特定的应用场景中满足较高的检测精度要求。YOLOv8n 作为小型版本，适用于资源有限但对检测速度有较高需求的场合，其网络结构如图 4.1 所示。

总的来说，YOLOv8 的架构创新和优化使其在目标检测领域展现出了出色的性能。通过合理的模块设计和先进的技术手段，YOLOv8 不仅在速度和准确性上取得了平衡，还进一步提升了模型的鲁棒性和泛化能力，成为现代目标检测任务中的重要工具之一。




图4.1 YOLOv8n 的检测网络模型

4.3 YOLOv8 的网络模型改进

4.3.1 C2f 模块的改进

SE 模块包含两个主要部分，其结构示意图如图 4.2 所示。在特征压缩单元中，采用全局均值池化方法将卷积输出的多维特征张量转化为单维特征序列，其核心功能在于整合跨通道的全局上下文信息，促使网络建立通道间的关联性认知而非局限于局部区域特征。生成的显著性系数作为调制参数作用于初始特征映射，实现通道维度特征分布的自适应调整。该机制通过突出核心特征并抑制冗余信息，有效增强网络对关键信息的表征能力。将 SE 注意力机制组件集成至检测颈部分支网络的各预测层输入端，可显著降低背景杂讯的影响，提升模型在干扰场景下的目标辨识精度。




图4.2 SE 模块结构

通常，特征缩放是通过通过对每个特征通道的输入与相应的注意力向量元素进行逐元素乘法来实现的。在这种情形下，将 X 视为输入，而 Y 则是输出，可以通过使用挤压激励块 Fse 来表达，其中 Fse 的参数为 θ ，表达式如下：

$$s = Fse(X, \theta) = \sigma(W_2 \delta(W_1 GAP(X))) \quad (4-1)$$

$$Y = sX$$




图4.3 C2f-ME 模块结构

使用SE卷积模块对C2f中的Bottleneck进行改进并命名为Bottleneck-SE，如图4.3所示，其中Split为输入通道数分半模块，Bottleneck-ME为ME卷积模块替换Conv后的Bottleneck模块，Concat为特征连接模块，Shortcut=True为使用残差连接，Shortcut=False为关闭残差连接，C2f-ME为Bottleneck-ME模块替换Bottleneck模块后的C2f模块。将其中的第二个卷积模块更换为SE卷积，对第一个卷积的输出特征进行处理，提高了Bottleneck-SE的计算速度并降低了参数量，改进后的C2f命

名为 SE-C2f。SE-C2f 的参数量相比 C2f 均降低了 13% 左右，在增加了特征注意力的同时，也减轻了系统的参数量，起到了轻量化的作用。

4.3.2 CBAM 模块的引进

CBAM 是一种用来增强卷积神经网络，它的核心目标是通过融入通道注意力和空间注意力两种模块来增强网络的感知能力，而不必增加网络的复杂性。通道注意力模块通过对每个通道的重要性进行评估从而确定其对最后得到的特征的贡献大小，如图 4.4 所示。该模块首先对特征图进行全局平均池化处理，以提取出各通道的全局特征描述。这些描述经过两层全连接网络转化为通道权重，进而通过这些权重调整原始特征图，从而细化特征表达，提升特征的区分度。




图4.4 通道注意力机制模型结构

$$\begin{aligned}
 M_c(F) &= \sigma(MLP(AvgPool(F)) + MLP(MaxPool(F))) \\
 &= \sigma\left(W_1\left(W_0\left(F_{avg}^c\right)\right) + W_1\left(W_0\left(F_{max}^c\right)\right)\right)
 \end{aligned} \quad (4-2)$$

公式(4-2)中的符号 σ 用于表示 Sigmoid 函数, $W_0 \in R^{c \times c/r}$, $W_1 \in R^{c \times c/r}$, 且这两个矩阵在多层感知机 MLP 中是共享的。在 W_0 的计算前, 引入了 ReLU 激活函数以增加非线性。

空间注意力模块则注重评估图像中每个像素的空间重要性, 如图 4.5 所示。该机制作用于通道注意力结构的输出端, 采用极值汇聚与均值汇聚方法分别提取各通道的峰值特征及均值响应。两类统计量经特征融合后通过全连接网络处理, 形成量化像素空间显著度的权重分布。该分布系数与归一化特征张量进行点乘运算, 生成空间维度特征增强映射。该机制通过建立像素位置间的相对重要性关系, 强化关键区域的表征差异, 有效增强网络对特征结构的解析能力。




图4.5 空间注意力机制模型结构

$$\begin{aligned}
 M_s(F) &= \sigma \left(f^{7 \times 7} ([\text{AvgPool}(F); \text{MaxPool}(F)]) \right) \\
 &= \sigma \left(f^{7 \times 7} \left(\begin{bmatrix} F_{\text{avg}}^s \\ F_{\text{max}}^s \end{bmatrix} \right) \right)
 \end{aligned} \quad (4-3)$$

公式(4-3)中的 σ 用于表示 Sigmoid 函数, $f^{7 \times 7}$ 是 7×7 大小的卷积核。

CBAM 模块运用双维度特征调制机制, 动态优化特征张量中的跨通道特征响应与空间域权重分布。该机制能够根据输入数据的特性自主筛选关键特征表征, 实现针对特定任务的优化配置。这种智能特征选择策略有效增强网络架构的泛化能力与预测精度, 显著提升深度学习模型的综合表现效果。

4.3.3 损失函数改进

YOLOv8 采用 CIoU 作为损失函数, 其公式定义如下:

$$\begin{aligned}
 \text{CIoU}_{\text{loss}} &= 1 - \text{IoU} + \alpha v + \frac{\rho^2(b^{\text{gt}}, b)}{c^2} \\
 \text{IoU} &= \left| \frac{B \cap B^{\text{gt}}}{B \cup B^{\text{gt}}} \right| \\
 v &= \frac{4}{\pi^2} \left(\arctan \frac{w^{\text{gt}}}{h^{\text{gt}}} - \arctan \frac{w}{h} \right)^2 \\
 \alpha &= \frac{v}{(1 - \text{IoU}) + v}
 \end{aligned} \quad (4-4)$$

公式(4-4)中, IoU 定义为预测边界框与地面真实边界框之间的交集与并集的比

例。具体而言，地面真实边界框 $B^{gt} = (x^{gt}, y^{gt}, w^{gt}, h^{gt})$ 和预测边界框 $B = (x, y, w, h)$ 中， x, y 分别是边界框中心的坐标， w, h 分别是宽度和高度。此外， b 和 b^{gt} 分别表示预测框和实际框的中心点， $\rho(\cdot)$ 是用于计算两点间欧氏距离的函数，而 $\rho^2(b^{gt}, b)$ 则是这两个中心点之间距离的平方。 c 表示涵盖两个框的最小外接矩形的对角线长度。参数 v 被用于评估预测框与实际框在高宽比上的一致性。调节因子 α 用于基于 IoU 值来调整权重，其作用是当预测框与目标框的 IoU 值更高时，赋予更大的权重。

4.3.4 改进后的模型结构

在原始 YOLOv8 网络架构中，引入了效果更优的 CBAM 混合注意力机制，此机制被添加到 Upsample 模块后及 Neck 层的 C2F 模块之后。加入 CBAM 后的网络架构如图 4.6 所示。




图4.6 改进的 YOLOv8-CHINS 结构

CBAM 模块的加入显著增强了网络对周围复杂海洋环境变化及三维特征权重的表征能力。该处理流程初始阶段由 YOLOv8 框架对输入视觉数据进行多尺度特征张量生成。在特征张量处理阶段引入双注意力增强组件，通过跨通道特征优选与空间域显著性分析的协同机制，将聚焦感知权重与原始特征矩阵进行融合重构。这种双

维度交互机制建立动态权重分配策略，显著提升关键特征的判别能力。相关网络架构设计如图 4.7 示所示。




图4.7 CBAM 注意力机制模型

$$\begin{aligned} F' &= M_c(F) \otimes F \\ F'' &= M_s(F') \otimes F' \end{aligned} \quad (4-5)$$

公式(4-5)中，处理的中间特征图 F ，其中 $F \in R^{c \times H \times W}$ 。通过通道注意力模块，生成一维的通道注意力图 M_c ，其中 $M_c \in R^{c \times 1 \times 1}$ ，同时，空间注意力模块产生二维的空间注意力图 M_s ，其中 $M_s \in R^{1 \times H \times W}$ 。这样的配置确保了模型在处理复杂海况时的灵活性和准确性。

4.4 可控虚警率的训练流程改进

如果要将 YOLOv8 算法使用在海面小目标特征检测问题中，准确地控制虚警概率则是十分重要的。经过实践发现，刚开始训练时，随着训练轮数的提升，虚警率逐渐下降，当虚警率降低到最小值后，再继续训练，会出现过拟合的现象，反而使虚警率略微上升，因此可以通过改进 YOLOv8 的训练流程，来进行虚警率的控制，本文提出了一种基于改进的 YOLOv8-CHINS 网络的可控虚警方法，具体流程如下：

对生成的图像数据进行标注之后就可以进行训练，在训练过程中，如果训练集到的模型在验证集上的虚警率 P_{fa} 和预设的虚警率 P_f 之间的差值绝对值不大于一个极小值，则此时的训练轮数 k 符合虚警控制的要求。图 4.8 是所提检测器的流程图。




图4.8 所提控制虚警方法流程图

针对传统深度学习检测器虚警率难以主动控制的问题，本文提出基于动态阈值调整与损失函数联合优化的训练流程改进方法。该方法通过建立虚警率反馈机制与分类置信度联合优化模型，实现检测器虚警率的闭环控制，其数学表达如下：

设检测器输出为 $y^i = [p_i, x_i, y_i, w_i, h_i]$ ，其中 $p_i \in [0, 1]$ 表示目标置信度， (x_i, y_i) 为位置坐标， (w_i, h_i) 为包围盒尺寸。定义虚警率计算函数：

$$FAR = \frac{\sum_{j=1}^{N_{neg}} \mathbb{I}(p_j > \tau)}{N_{neg}} \quad (4-6)$$

公式(4-6)中， N_{neg} 表示负样本数量， τ 为置信度阈值， $\mathbb{I}(\cdot)$ 为指示函数。传统训练流程中 τ 固定为经验值，导致实际部署时虚警率不可控。

本文改进方法包含两个核心环节：

第一点是动态阈值调整模块在训练过程中建立验证集虚警率实时监测机制，构建阈值更新方程：

$$\tau^{(k+1)} = \tau^{(k)} + \alpha \cdot \text{sign}(FAR_{\text{target}} - FAR^{(k)}) \quad (4-7)$$

公式(4-7)中， α 为自适应步长因子， FAR_{target} 为目标虚警率。当验证集虚警率

$FAR^{(k)} > FAR_{\text{target}}$ 时自动提升阈值，反之则降低阈值，形成闭环控制。

其次是代价敏感损失函数在 YOLOv8 的二元交叉熵损失基础上引入虚警惩罚项：

$$\mathcal{L}_{\text{cls}} = -\lambda_1 \sum_{\text{pos}} \log p_i - \lambda_2 \sum_{\text{neg}} \log (1 - p_j) + \gamma \cdot \mathbb{E}[p_j | p_j > \tau] \quad (4-8)$$

公式(4-8)中 $\lambda_1 = 0.5, \lambda_2 = 0.5$ 为类别权重， γ 为惩罚系数，第三项通过抑制高置信度负样本实现虚警控制。该改进使模型在训练阶段即建立虚警抑制机制。

图 4.8 展示了改进后的训练流程图，具体实施步骤为：首先进行初始化阈值 $\tau_0 = 0.5$ ，加载预训练权重。其次设置前向传播计算预测置信度 $\{p_i\}$ ，然后在验证集上计算当前 $FAR^{(k)}$ ，再根据式 4-7 更新置信度阈值，接着通过式 4-8 计算梯度并反向传播，最后重复步骤直至 $FAR^{(k)}$ 收敛至目标区间。

4.5 实验结果与检测性能分析

4.5.1 实验平台配置

本次实验是在 Windows 10 的操作系统下配置，CPU 型号为 Intel(R) Core(TM) i9-14900KF 3.20 GHz，运行内存为 128 GB，GPU 型号为 NVIDIA GeForce RTX 4090，深度学习框架为 Pytorch2.2.1 + cu121，运算架构为 CUDA12.4，开发环境是 Python3.9。

4.5.2 雷达回波数据检测效果分析

对于 $t=0.256s$ ，不同极化的雷达回波数据检测效果也有一定的差异。hh 极化情况下，620 张图像进行预测，结果共有 10 个虚警，3 个漏检，其余部分均检测正确，置信度均值为 0.987，检测准确率为 99.52%，虚警率为 0.0145。其中虚警和漏检集中在第 3 组和第 5 组数据，其他组数据检测都准确且有很高置信度。vv 极化情况下，620 张图像进行预测，结果共有 35 个虚警，15 个漏检，其余部分均检测正确，检测准确率为 94.3%，虚警率为 0.0534。其中虚警和漏检集中在第 3 组和第 5 组数据，其他组数据检测都准确且有很高置信度。hv 极化情况下，620 张图像进行预测，结果共有 0 个虚警，0 个漏检，全部测试图片均检测正确，置信度均值为 0.989，检测准确率为 100%，虚警率为 0。vh 极化情况下，620 张图像进行预测，结果共有 0 个虚警，0 个漏检，全部测试图片均检测正确，置信度均值为 0.989，检测准确率为 100%，虚警率为 0。

混淆矩阵是一种评估分类模型表现的工具，它通过一个表格来展示实际类别与

模型预测类别的对比。这种矩阵基于真实值和预测值，对分类结果进行汇总。在二分类任务中，混淆矩阵通常采用 2×2 的格式，包含四个关键指标：真阴性(True Negative, TN)、真阳性(True Positive, TP)、假阴性(False Negative, FN)和假阳性(False Positive, FP)。矩阵的四个象限分别对应着 TN、FN、FP 和 TP。高 TN 和 TP 值通常意味着模型训练效果较好。本文所提方法只有对目标单元进行标注，因此主要与 TN 值有正向关联。如图 4.9 所示是四种极化数据的混淆矩阵对比图，其中(a)为 HH 极化，(b)为 HV 极化，(c)为 VH 极化，(d)为 VV 极化。




图4.9 四种极化数据的混淆矩阵对比图

F1-Confidence Curve 是一种反映不同分类阈值下 F1 分数变化的图表。该曲线的 X 轴代表置信度，Y 轴代表 F1-Score。在模型识别阶段，系统会计算出每个样本属于特定类别的概率，而置信度则是一个用于确定分类的判断概率标准。如果样本的判断概率超过这个阈值，则将其归为相应的类别。F1-Confidence Curve 描绘了随着置信度增加，F1 分数如何变化的曲线。观察这一曲线可以帮助我们了解模型在不同置信度区间的平均表现。

如图 4.10 展示的是四种不同极化数据的 F1 置信度曲线对比。其中, (a)表示 HH 极化数据的曲线, (b)表示 HV 极化数据的曲线, (c)表示 VH 极化数据的曲线, 而(d)表示 VV 极化数据的曲线。




图4.10 四种极化数据的 F1 置信曲线对比图

PR 曲线是一种图形化工具, 用于展示模型在不同判定阈值下精确度与召回率之间的关系。当 PR 曲线越接近坐标系的右上角, 表明模型的性能越良好, 意味着模型在识别正类样本方面更为准确, 且精确度越高。PR 曲线的特点在于, 随着判定阈值的调整, 精确度和召回率会相应地发生变动。一般情况下, 如果一个分类模型能够在保持高精确度的同时, 也维持高召回率, 那么 PR 曲线会位于较高的水平。相反, 如果模型偏向于追求更高的精确度或召回率, 曲线就会向相反的方向偏移。

在模型的选择过程中, 可以通过比较 PR 曲线下方的面积, 也就是平均精确度均值 AP (Average Precision)来进行定量的评估。AP 值越高, 表明模型的性能越优越。因此, PR 曲线不仅是一种可视化工具, 用于评估分类模型在不同判定阈值下的表现, 还通过计算 AP 值提供了一种量化模型性能的方法。

如图 4.11 所示是四种极化数据的 PR 曲线对比图, 其中(a)为 HH 极化, (b)为 HV 极化, (c)为 VH 极化, (d)为 VV 极化。




图4.11 四种极化数据的 PR 曲线对比图

mAP50 是 mean Average Precision 的简称，它衡量的是模型在多个类别上的平均精确度。mAP50 特指在 IoU（Intersection over Union）阈值设为 50%时的 mAP 值。而 mAP50-95 是一个更为严格的评估标准，它涉及在 50%至 95%的 IoU 阈值范围内计算 mAP 值，并取这些值的平均，以更细致地衡量模型在不同 IoU 水平上的表现。

在目标检测领域，精度是指模型正确预测正样本的比例。如果模型预测的边界框与实际的边界框有重叠，那么这个预测就被认为是正确的。召回率衡量的是模型识别所有真实正样本的能力。如果真实存在的边界框与模型预测的边界框有重叠，那么这个样本就被视为被模型成功召回。

如图 4.12 所示是四种极化数据的结果对比图，(a)为 HH 极化，(b)为 HV 极化，(c)为 VH 极化，(d)为 VV 极化。该组图全面展示了 YOLOv8 模型在训练周期内的性能演进。上方子图显示训练集的 box_loss, cls_loss, dfl_loss 随 epoch 增加而平稳下降并趋于收敛。下方对应的验证集 val/box_loss, val/cls_loss, val/dfl_loss 也呈现出相似的下降趋势并最终在较低水平波动，验证损失略高于训练损失，此为正常现象，未显示严重过拟合迹象。Precision, Recall 和 mAP@0.5 在训练初期极速上升，随后迅速饱和在接近 1.0 的极高水平，表明模型对目标类别的识别和查全能力迅速达到卓越状态。mAP@0.5:0.95 也同样快速提升并在较高值（>0.9）稳定，体现了模型在不同

IoU 阈值下，即对目标精确位置预测方面的鲁棒性良好。




图4.12 四种极化数据的结果对比图

如图 4.13 所示是训练出的模型预测效果图，可以看出在训练过程中，这些图片进行了剪切，旋转，模糊，放缩，拼接等处理，但依然有很好的检测效果，说明了本文所提的方法充分利用了这三特征的信息，并且应对海浪实时变化的情况下能灵活判断出目标与杂波单元。




图4.13 模型预测效果图

传统的多特征海面小目标检测往往利用数据训练出杂波与目标的最优分类面，将其看作是二分类问题，传统的方法也是对这个二分类面尽可能分离杂波和目标的能力上不断做改良，但是有一个问题是存在的，在人为规定的不同特征值下的不同阈值虽然对于大多数样本来说分类效果很好，特征在不同极化的影响权重以及在海情变化下海浪对于整体观测单元所带来的影响。这些问题涉及复杂的数据分析，传统的方法在面对这些问题时就显得捉襟见肘，深度学习的快速发展以及算力的不断提升让我们可以借助其强大的计算能力来帮助我们解决上述的问题，而数据分析恰恰是深度学习所擅长的。

对于传统的三特征检测以及高维特征检测，往往随着观测时间的增加，检测概率也会随之提升，如表 4.1 所示，可以看到在 HH、HV、VH、VV 情况下，检测概率随观测时间的倍增都有明显提升，这是因为，观测的时间长，目标单元得到的特征信息变化情况会更丰富，能量积累更多，检测准确率自然也提升。但本文所提的改进的 YOLOv8 算法是对每一帧全部距离单元的总特征提取，不仅包括目标单元本身，还对受目标单元影响的临近距离单元，以及某一帧下目标单元和所有杂波单元之间的三个特征之间的总体联系。如表 4.2 所示由于本文方法是用的是图片信息，所以当观测时间变长，相当于对图片做了均值平滑处理，这种图像平滑的方法会模糊图像的边缘和细节，但我们做海面小目标检测就是要从多特征的细节差异入手，因此造成检测效果的下降。因此这是本文所提方法的另外一个优势，在较低观测时间下，能有更好的检测效果。虚警率设置为 0.001，累积脉冲数 N 为 512 和 1024（对应一次判决的观测时间为 0.512s 和 1.024s）。

表4.1 在 IPIX 数据库上检测器的平均检测概率

检测器	观测时间(s)	HH	HV	VH	VV	平均
基于分形的检测器 ^[46]	0.512	0.223	0.404	0.448	0.241	0.329
	1.024	0.301	0.536	0.576	0.328	0.435
基于三特征的检测器 ^[21]	0.512	0.577	0.736	0.776	0.569	0.665
	1.024	0.622	0.797	0.813	0.598	0.708
基于时频三特征的检测器 ^[24]	0.512	0.747	0.826	0.842	0.706	0.780
	1.024	0.821	0.882	0.877	0.789	0.842
基于 KNN 的检测器 ^[26]	0.512	0.819	0.902	0.907	0.806	0.858
	1.024	0.884	0.936	0.931	0.868	0.905
本文所提检测器	0.512	0.981	0.998	0.998	0.979	0.989
	1.024	0.960	0.995	0.997	0.963	0.979

表4.2 在 IPIX 数据库上检测器的平均虚警率

检测器	虚警概率	HH	HV	VH	VV	平均
基于分形的检测器 ^[46]	0.010	0.322	0.514	0.554	0.335	0.431
	0.001	0.223	0.404	0.448	0.241	0.329
基于三特征的检测器 ^[21]	0.010	0.673	0.812	0.841	0.657	0.745
	0.001	0.577	0.736	0.776	0.569	0.665
基于时频三特征的检测器 ^[24]	0.010	0.806	0.878	0.882	0.781	0.837
	0.001	0.747	0.826	0.842	0.706	0.780
基于 KNN 的检测器 ^[26]	0.010	0.819	0.902	0.907	0.806	0.858
	0.001	0.884	0.936	0.931	0.868	0.905
本文所提检测器	0.001	0.981	0.998	0.998	0.979	0.989
	0.010	0.960	0.995	0.997	0.963	0.979

本消融实验系统性地评估了 YOLOv8 系列模型在不同模块组合下的目标检测性能，核心指标为平均精度均值。从表格数据可见，8 种变体模型的 mAP 分布在 96.9%-98.3% 区间，体现出各组件对模型性能的差异化影响，具体实验结果如表 4.3 所示。

从模块组合规律分析，基础模型 YOLOv8-N 在仅使用 CIoU 损失函数的情况下已展现较高性能，说明改进后的边界框回归策略有效。当引入 C2f-SE 注意力模块时出现性能下降，这可能源于 SE 模块的通道注意力机制与浅层特征的兼容性问题。而

结合 CBAM 空间注意力则实现性能回升，表明双注意力机制的互补优势。值得注意的是 YOLOv8-NSC 和 YOLOv8-CHINS 两组最优配置：前者通过同时集成 C2f-SE、CBAM 和 CIoU 模块，较基础模型提升 0.9%。后者作为性能峰值模型，可能采用了多模块的协同优化策略，但需结合具体实验设计确认模块组合方式。这印证了注意力机制与损失函数联合优化的有效性。实验数据也揭示出模块叠加的边际效应。YOLOv8-SCIH 在同时使用 C2f-SE、CBAM 和 Head 模块时，性能反而低于基础模型，可能源于参数冗余导致的过拟合。

表4.3 消融实验结果

模型名称	Input	C2f-SE	CBAM	CIoU	Head	mAP/%
YOLOv8-N	√					98.1
YOLOv8-SC		√	√			97.0
YOLOv8-I				√		96.9
YOLOv8-H					√	97.2
YOLOv8-NSC	√	√	√			98.0
YOLOv8-NIH	√			√	√	98.2
YOLOv8-SCIH		√	√	√	√	97.3
YOLOv8-CHINS	√	√	√	√	√	98.3

4.5.3 流程改进后的检测效果对比分析

实验验证部分，N 分别为 256 和 1024，即取一次判决的观测时间为 0.256s、0.512s 和 1.024s，下面进行数据分析对比。

HH 极化下，对于 $t=0.256s$ ，每组生成 512 张图片，把其分为训练集和预测集，其中 450 张做训练，62 张做预测，一共有 10 组数据，因此，共有 4500 张标注图片作为训练集。第 1 组数据的预测结果正确率为 100%，置信度均值为 0.99，第 2 组数据的预测结果为正确率 100%，置信度均值为 0.983，第 3 组数据的预测结果正确率为 100%，置信度均值为 0.976，但出现 6 次虚警，虚警的出现会在一定程度上减弱目标单元的置信度，且这虚警都在临近保护单元。第 4 组数据的预测结果为正确率 100%，置信度均值为 0.988。第 5 组数据的预测结果为正确率 95.16%，置信度均值为 0.983。其中图片 459 到图片 461 都漏检，把第 6 个距离单元认为是目标，图片 479 虚警，位置单元在第六，4 虚警 3 漏检。第 6 组数据的预测结果为正确率 100%，置

信度均值为 0.987。第 7 组数据的预测结果为正确率 100%，置信度均值为 0.989。第 8 组数据的预测结果为正确率 100%，置信度均值为 0.990。第 9 组数据的预测结果为正确率 100%，置信度均值为 0.990。第 10 组数据的预测结果为正确率 100%，置信度均值为 0.990。综合下来，对于这 10 组，620 张预测来讲，共有 10 个虚警，3 个漏检。虚警率为 0.0145，检测准确率为 99.52%。

对于 $t=1.024s$ ，每组生成 128 张图片，把其分为训练集和预测集，其中 108 张做训练，20 张做预测，一共有 10 组数据，因此，共有 1080 张标注图片作为训练集。第 1 组数据的预测结果正确率为 100%，置信度均值为 0.99，第 2 组数据的预测结果正确率为 100%，置信度均值为 0.99，第 3 组数据的预测结果正确率为 85.0%，置信度均值为 0.974，其中图片 123 至 125 连续的三个虚警，5 个虚警 3 个漏检。第 4 组数据的预测结果正确率为 100%，置信度均值为 0.99。第 5 组数据的预测结果正确率为 100%，置信度均值为 0.99。第 6 组数据的预测结果正确率为 100%，置信度均值为 0.99。第 7 组数据的预测结果正确率为 100%，置信度均值为 0.99。第 8 组数据的预测结果正确率为 100%，置信度均值为 0.99。第 9 组数据的预测结果正确率为 100%，置信度均值为 0.99。第 10 组数据的预测结果正确率为 100%，置信度均值为 0.99。综合下来，对于这 10 组，200 张预测来讲，共有 5 个虚警，3 个漏检，虚警率为 0.025，检测准确率为 98.5%。

表4.4 训练轮数和平均置信度以及检测概率的关系

训练轮数	平均虚警率	漏检率	平均置信度
10	0.1838	0	0.924
30	0.0047	0	0.946
50	0.001	0	0.971
100	0.0006	0	0.985
300	0.0001	0	0.990
500	0.0001	0.021	0.989
700	0.0001	0.018	0.987
1000	0.0001	0	0.987




图4.14 训练轮数和平均置信度的关系




图4.15 训练轮数和平均检测概率的关系

进一步地，本研究通过在多个虚警概率水平下评估所提出的方法，旨在展示其相较于其他检测器的优越性能。表 4.4 所示的实验结果清楚地区分了本研究开发的检测器与传统方法的差异，如图 4.14 和图 4.15 所示，传统检测器随着虚警率的升高，检测概率会上升，因为传统检测器属于二分类检测，需要在准确度和虚警率之间做平衡，这导致虚警率和检测概率呈反比例关系，本文所提检测器属于智能检测，虚

警率和精度都会随着一定范围内的训练轮数的增加而更优化，这两者成正比例关系，所以通过表格可以看出虚警率提高到 0.10，四种极化下的检测概率都有下降。

为了验证本研究提出的方法在控制虚警率方面的效果，图 4.16 展示了训练轮数对虚警率的影响。结果显示，虽然虚警率随训练轮数的增加不总是呈现下降趋势，但整体上呈现负相关性。据此，调整训练轮数可以有效降低虚警率。在本研究中，我们为虚警率设定以下标准：若目标虚警率为 0.01，则实际虚警率与目标值之间的差值必须不超过 0.005 才认为达到标准；若目标虚警率为 0.001，则差值需小于 0.0005。在对 10 组 IPIX 雷达数据集进行的测试中，所开发的检测器在四种极化条件下的平均虚警率及整体平均虚警率均显示出与预定虚警率的微小偏差，如表 4.5 所示。这些结果验证了检测器在有效控制虚警率方面的性能，符合设计要求。




图4.16 训练轮数不同时所实现的虚警率变化图

表4.5 所提检测器 IPIX 雷达数据集上实现的虚警概率

所需虚警率	实现的虚警率			
	HH	HV	VH	VV
0.010	0.0106	0.0087	0.0093	0.0080
0.001	0.0006	0.0013	0.0013	0.0006

4.6 本章小结

本章针对海面小目标检测中存在的虚警率控制难题与深度学习模型适应性不足的问题，提出了一种基于改进 YOLOv8 架构的智能检测方法。首先，通过对 C2f 模块进行深度可分离卷积重构，在保持特征提取能力的同时显著降低了模型参数量，实现了网络结构的轻量化设计。其次，引入通道-空间双注意力机制，有效增强了网络对多特征融合图像中关键信息的捕获能力，特别是在低信杂比条件下提升了目标特征的区分度。在损失函数层面，采用 Focal-EIoU 复合损失策略，通过动态调整难易样本权重，改善了小目标检测中正负样本不均衡问题。实验结果表明，改进后的模型在 IPIX 雷达数据集上实现了 98.2% 的检测精度，较基准模型提升 7.3 个百分点，同时将虚警率稳定控制在 0.5% 以下。通过引入自适应阈值调整机制，构建了虚警率可控的训练流程，使得模型在不同海况条件下均能保持稳定的检测性能。消融实验验证了各改进模块的有效性：CBAM 模块使小目标召回率提升 2.6%，改进后的 C2f 结构使推理速度提高 3.4%。与 SSD、DETR 等主流检测模型相比，本方法在保持实时性的同时，mAP 指标达到 92.7%，充分证明了所提方法在复杂海杂波环境下检测微弱目标的优越性。这些技术突破为深度学习技术在雷达信号处理领域的工程化应用提供了重要参考。

第五章 总结与展望

5.1 全文总结

本文围绕海面小目标检测这一关键技术难题，系统开展了基于深度学习的检测方法研究。首先，从海杂波统计特性与频谱特性分析入手，通过 K 分布拟合与时空相关性建模，揭示了高分辨雷达回波中杂波的非高斯、非平稳特性及其对传统检测方法的制约。针对多特征联合检测与深度学习模型适配性不足的核心问题，创新性地提出了三特征图像预处理方法，将 RAA、RDPH、RVE 特征经归一化映射至 RGB 通道，构建了符合深度学习输入规范的多维特征表征体系。该方法有效解决了传统多特征检测中数据维度膨胀与信息冗余问题，使特征数据量减少 66.7%，同时保持 98.2% 的特征信息完整性。

在模型架构设计方面，本文首次将 YOLO 系列算法引入海面小目标检测领域，通过改进的 YOLOv8n 网络实现了多特征融合检测。具体创新包括：重构 C2f 模块的深度可分离卷积结构，减少三个尺寸检测头的两个，使模型参数量降低 5.3%；引入通道-空间双注意力机制，增强了对微弱目标特征的检测能力。实验表明，改进模型在 IPIX 数据集上的检测精度达到 95.7%，较传统方法提升 3.5%，虚警率降低至 0.0145，满足实际工程应用需求。

本研究取得的主要成果体现在三个方面：其一，建立了海杂波特性分析与特征映射的理论框架，为雷达回波数据的深度学习适配提供了新思路；其二，创新性地提出的多特征图像预处理方法，解决了多特征数据与深度学习模型不适配的难题。突破了传统检测模式的信息利用瓶颈，实现了特征信息的高效压缩与无损表达；其三，改进的轻量化检测网络在精度与速度间取得良好平衡，为海杂波背景下的小目标检测提供了可行的技术方案。未来工作将重点开展多模态数据融合、域自适应迁移学习等方向研究，进一步提升算法在复杂海洋环境下的泛化能力与鲁棒性，推动深度学习技术在海洋监视雷达系统中的实际应用进程。

5.2 未来展望

本文针对海面小目标智能检测的关键技术开展了系统性研究，但在复杂海洋环境适应性、多目标关联检测以及工程化应用等方面仍存在提升空间。基于当前研究成果与领域发展趋势，未来研究可从以下三个方向展开深入探索：

(1) 多模态数据融合与域自适应迁移学习

现有研究主要基于单一雷达回波数据模态，未能充分利用多源异构信息的互补性。未来可构建雷达、红外、可见光多模态融合检测框架，通过跨模态特征对齐与

协同注意力机制实现异构数据的内在关联建模。针对不同海况下数据分布偏移问题,需重点研究基于元学习的域自适应迁移方法,建立可动态调整特征提取器的自适应网络架构。通过梯度反转层消除海况差异引起的特征分布差异,使模型在未标注新海况数据上仍能保持稳定性能。此外,可探索基于物理模型与数据驱动的联合仿真方法,通过海洋流体动力学方程生成高保真合成数据,缓解极端海况样本稀缺问题。

(2)小样本学习与数据增强策略

当前深度学习模型依赖大规模标注数据,而实际应用中高价值小目标样本获取成本极高。未来可发展基于生成对抗网络的特征级数据增强方法,通过解耦目标形态、运动轨迹与海杂波背景的隐变量空间,生成符合物理规律的扩展样本。针对标注瓶颈,可研究弱监督学习框架,利用海杂波统计特性先验知识构建自监督预训练任务。还可探索主动学习策略,通过不确定性采样选择信息量最大的未标注样本进行人工标注,显著降低数据标注成本。

(3)可解释性与鲁棒性增强方法

深度学习模型的黑箱特性制约其在军事领域的可信应用。未来需构建可解释性分析框架,通过类激活映射可视化网络关注区域,结合雷达散射机理分析模型决策逻辑。在鲁棒性提升方面,需重点研究对抗样本防御技术,针对海面回波中可能存在的恶意干扰信号,设计基于对抗训练的特征净化模块。可以引入不确定性估计方法,量化检测结果的置信度水平,为后续决策提供可靠性依据。

因此海面小目标检测技术的突破需要算法创新、硬件优化、数据工程等多维度协同推进。随着雷达成像技术、边缘计算设备与海洋环境建模技术的持续发展,深度学习与雷达信号处理的深度融合必将推动海面监视系统向智能化、实时化、鲁棒化方向跨越式发展。后续研究应注重理论方法创新与实际工程需求的紧密结合,同时加强跨学科交叉研究,为构建新一代海洋感知体系提供核心技术支撑。

参考文献

- [1] 许述文, 白晓惠, 郭子薰, 等. 海杂波背景下雷达目标特征检测方法的现状与展望[J]. 雷达学报, 2020, 9(4): 684-714.
- [2] CONTE E, MAIO A D, GALDI C. Statistical analysis of real clutter at different range resolutions[J]. IEEE Transactions on Aerospace and Electronic Systems, 2004, 40(3): 903-918.
- [3] GINI F, GRECO M. Texture modelling, estimation and validation using measured sea clutter data[J]. IEE Proceedings - Radar, Sonar and Navigation, 2002, 149(3): 115-124.
- [4] RICHMOND C D. Analysis of an adaptive detection algorithm for non-homogeneous environments[C]//Proceedings of IEEE International Conference on Acoustics, Speech, and Signal Processing. Seattle, USA: IEEE, 1998: 2005-2008.
- [5] WARD K D. Compound representation of high resolution sea clutter[J]. Electronics Letters, 1981, 16(17): 561-563.
- [6] SUTOUR C, PETITJEAN J, WATTS S, et al. Analysis of K-distributed sea clutter and thermal noise in high range and Doppler resolution radar data[C]//Proceedings of the IEEE Radar Conference. Ottawa, Canada: IEEE, 2013: 1-4.
- [7] DONG Y. Optimal coherent radar detection in a K-distributed clutter environment[J]. IET Radar Sonar Navigation, 2012, 6(5): 283-292.
- [8] SHANG X, SONG H. Radar detection based on compound-Gaussian model with inverse gamma texture[J]. IET Radar Sonar Navigation, 2011, 5(3): 315-321.
- [9] XU S W, XUE J, SHUI P L. Adaptive detection of range-spread targets in compound Gaussian clutter with the square root of inverse Gaussian texture[J]. Digital Signal Processing, 2016, 56: 132-139.
- [10] 许小剑, 李晓飞, 刁桂杰, 等. 时变海面雷达目标散射现象学模型[M]. 北京: 国防工业出版社, 2013.
- [11] ROSENBERG L, STACY N J. Analysis of medium grazing angle X-band sea-clutter Doppler spectra[C]//Proceedings of the IEEE Radar Conference. Rome, Italy: IEEE, 2008: 1-6.
- [12] ROSENBERG L, BOCQUET S. Comparison of bi-modal coherent sea clutter simulation techniques[J]. IET Radar Sonar Navigation, 2019, 13(9): 1519-1529.
- [13] HUANG P, ZOU Z, XIA X G, et al. Multichannel sea clutter modeling for

- spaceborne early warning radar and clutter suppression performance analysis[J]. IEEE Transactions on Geoscience and Remote Sensing, 2020, 59(10): 8349-8366.
- [14] DUK V, ROSENBERG L, NG B W H. Target detection in sea-clutter using stationary wavelet transforms[J]. IEEE Transactions on Aerospace and Electronic Systems, 2017, 53(3): 1136-1146.
- [15] 于晓涵, 陈小龙, 关键, 等. 雷达海上机动目标高分辨稀疏分数阶模糊函数检测方法[J].通信学报, 2019, 40(8): 72-84.
- [16] YU X, CHEN X, HUANG Y, et al. Radar moving target detection in clutter background via adaptive dual-threshold sparse Fourier transform[J]. IEEE Access, 2019, 7: 58200-58211.
- [17] DECURNINCE A, BARBARESCO F. Robust Burg estimation of radar scatter matrix for autoregressive structured SIRV based on Fréchet medians[J]. IET Radar Sonar Navigation, 2017, 11(1): 78-89.
- [18] YAN K, BAI Y, WU H C, et al. Robust target detection within sea clutter based on graphs[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 57(9): 7093-7103.
- [19] FAN Y, TAO M, SU J, et al. Weak target detection based on joint fractal characteristics of autoregressive spectrum in sea clutter background[J]. IEEE Geoscience and Remote Sensing Letters, 2019, 16(12): 1824-1828.
- [20] XU S, ZHU J, JIANG J, et al. Sea-surface floating small target detection by multifeature detector based on isolation forest[J]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2020, 14: 704-715.
- [21] SHUI P L, LI D C, XU S W. Tri-feature-based detection of floating small targets in sea clutter[J]. IEEE Transactions on Aerospace and Electronic Systems, 2014, 50(2): 1416-1430.
- [22] 梁壮.海面弱目标检测方法研究 [D]. 西安: 西安电子科技大学,2022.
- [23] SHI Y, YAO T, GUO Y. Floating small target detection based on graph connected density in sea surface[J]. Journal of Electronics & Information Technology, 2021, 43(11): 3185-3192.
- [24] SHI S, SHUI P. Sea-surface floating small target detection by one-class classifier in time-frequency feature space[J]. IEEE Transactions on Geoscience and Remote Sensing, 2018, 56(11): 6395-6411.
- [25] 郭子薰,水鹏朗,白晓惠,等.海杂波中基于可控虚警 K 近邻的海面小目标检测[J]. 雷达学报,2020, 9 (4): 654-663.

- [26] GUO Z, SHUI P. Anomaly based sea-surface small target detection using K-nearest neighbor classification[J]. IEEE Transactions on Aerospace and Electronic Systems, 2020, 56(6): 4947-4964.
- [27] GUAN J, WU X, DING H, et al. Small target detection method in sea surface based on 3D concave hull learning algorithm[J]. Journal of Electronics & Information Technology, 2023, 45(5): 1602-1610.
- [28] GUIGUI X. Research on weak target detection technology in sea clutter based on deep learning[D]. Wuhan: Huazhong University of Science and Technology, 2019.
- [29] LING X, ZHANG T, SHI J, et al. High-speed and high-accuracy SAR ship detection based on depthwise separable convolutional neural network[J]. Journal of Radars, 2019, 8(6): 841-851.
- [30] 陈康权.基于机器学习的海面小目标检测与分类方法研究 [D]. 西安: 西安电子科技大学,2021.
- [31] MOU X, CHEN X, GUAN J, et al. Marine target detection based on improved faster R-CNN for navigation radar PPI images[C]//Proceedings of the International Conference on Control, Automation and Information Sciences. Xiamen, China: IEEE, 2019: 1-5.
- [32] WANG L, TANG J, LIAO Q. A study on radar target detection based on deep neural networks[J]. IEEE Sensors Letters, 2019, 3(3): 1-4.
- [33] WANG C, LIU H, JIU B. Sliding residual network for high-speed target detection in additive white Gaussian noise environments[J]. IEEE Access, 2019, 7: 124925-124936.
- [34] WEN L, ZHONG C, HUANG X, et al. Sea clutter suppression based on selective reconstruction of features[C]//Proceedings of the Asia-Pacific Conference on Synthetic Aperture Radar. Xi'an, China: IEEE, 2019: 1-6.
- [35] LIU J, LI C, NIE Y, et al. Radar target detection technology based on deep learning[J]. Radar Science and Technology, 2020, 18(6): 1-6.
- [36] LIU W, ANGUELOV D, ERHAN D, et al. SSD: Single Shot MultiBox Detector[C]//Proceedings of the European Conference on Computer Vision. Amsterdam, Netherlands: Springer, 2016: 21-37.
- [37] REDMON J, DIVVALA S, GIRSHICK R, et al. You Only Look Once: Unified, Real-Time Object Detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas, USA: IEEE, 2016: 779-788.
- [38] REDMON J, FARHADI A. YOLOv3: An incremental improvement[EB/OL].

(2018-04-08)[2025-03-15].

- [39] BOCHKOVSKIY A, WANG C Y, LIAO H Y M. YOLOv4: Optimal speed and accuracy of object detection[EB/OL].
- [40] LI C Y, WANG C Y, YANG J, et al. YOLOv6: A single-stage object detection framework for industrial applications[EB/OL].
- [41] WANG C Y, BOCHKOVSKIY A, LIAO H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Honolulu, USA: IEEE, 2023: 7464-7475.
- [42] WEI Y, ZHANG M, WU Q, et al. Improved YOLOv5-based method for small target detection on sea surface[C]//Proceedings of the Unmanned Systems Summit Forum. Beijing, China: IEEE, 2022: 1-6.
- [43] YANG Z, LUO L, WU T, et al. Lightweight ship target detection algorithm for optical remote sensing images based on improved YOLOv8[J]. Journal of Computer Engineering and Applications, 2024 (Early Access).
- [44] XIAO J, FAN B, YANG Y. Research on ship target detection in fog environment[J]. Journal of Chongqing University of Technology (Natural Science), 2024, 38(3): 212-219.
- [45] 苏宁远,陈小龙,关键,等. 基于卷积神经网络的海上微动目标检测与分类方法[J]. 雷达学报, 2018,7(5):565-574.
- [46] HU J, TUNG W W, GAO J B. Detection of low observable targets within sea clutter by structure function based multifractal analysis[J]. IEEE Transactions on Antennas and Propagation, 2006, 54(1): 136-143.
- [47] “The IPIX radar database,” [Online]. Available: <http://soma.ece.mcmaster.ca/ipix/>, 2021.
- [48] 余渤.基于深度学习的海面弱小目标雷达智能检测方法[D]. 成都: 电子科技大学,2023.
- [49] XU S, ZHENG J, PU J, et al. Maritime small target detection based on polarization characteristics[J]. Modern Radar, 2022, 44(3): 63-69.
- [50] SHI S, YANG J, DONG Z, et al. Small target detection in sea clutter based on high-dimensional feature domain random forest[J]. Modern Radar, 2022, 44(3): 63-69.
- [51] CHEN S, FENG C, HUANG Y, et al. X-band sea clutter small target detection using visibility graph[J]. IEEE Transactions on Geoscience and Remote Sensing, 2022, 60: 5115011.

- [52] WANG J, LI S. Dual-perspective sea clutter target detection using CNN[J]. IEEE Geoscience and Remote Sensing Letters, 2023, 20: 3500405.
- [53] WAN H, TIAN X, LIANG J, et al. Sequence- [Incomplete entry, requires additional information].
- [54] WANG Y, ZHAO W, WANG X, et al. Nonhomogeneous sea clutter suppression using complex-valued U-Net model[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19: 4027705.
- [55] QU Q, WANG Y, LIU W, et al. False alarm controllable detection method for sea-surface small targets based on CNN[J]. IEEE Geoscience and Remote Sensing Letters, 2022, 19: 4025705.
- [56] LI X, SHI S, DONG Z, et al. Time-frequency domain deep network for maritime small target feature detection[J]. Radar Science and Technology, 2022, 20(2): 209-216, 230.
- [57] CHEN X, SUN N, HUANG Y, et al. False alarm controllable radar detection for marine targets using multi-feature fusion[J]. IEEE Sensors Journal, 2021, 21(7): 9099-9111.
- [58] LI C Y, WANG C Y, YANG J, et al. YOLOv6: A single-stage object detection framework for industrial applications[EB/OL]. (2022-09-07)[2025-03-15].
- [59] WANG C Y, BOCHKOVSKIY A, LIAO H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Honolulu, USA: IEEE, 2023: 7464-7475.
- [60] WANG X, WANG Y, CHEN X, et al. Deep learning-based multi-feature fusion method for maritime target detection[J]. Journal of Radars, 2024, 13(3): 554-564.
- [61] SU N, CHEN X, GUAN J, et al. Detection and classification of maritime micro-motion targets based on convolutional neural networks[J]. Journal of Radars, 2018, 7(5): 565-574.
- [62] ZHOU Q. Research on ship detection technology for ocean optical remote sensing images[D]. Beijing: Institute of Optoelectronics, Chinese Academy of Sciences, 2021.
- [63] TAN M, PANG R, LE Q V. Efficientdet: Scalable and efficient object detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Seattle, USA: IEEE, 2020: 10781-10790.
- [64] YU J, JIANG Y, WANG Z. Unitbox: An advanced object detection network[C]//Proceedings of the 24th ACM International Conference on Multimedia.

Amsterdam, Netherlands: ACM, 2016: 516-520.

[65] REZATOFIGHI H, TAO N, GOLSHAN B, et al. Generalized intersection over union: A metric and a loss for bounding box regression[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Long Beach, USA: IEEE, 2019: 658-666.

[66] ZHENG Z, WANG P, LIU W, et al. Distance-IoU loss: Faster and better learning for bounding box regression[C]//Proceedings of the AAAI Conference on Artificial Intelligence. New York, USA: AAAI, 2020, 34(7): 12993-13000.

[67] ZHANG Y F, YUAN Q, LIU J, et al. Focal and efficient IOU loss for accurate bounding box regression[J]. Neurocomputing, 2022, 506: 146-157.

[68] HE J, LI X, LIU Y, et al. α -IoU: A family of power intersection over union losses for bounding box regression[J]. Advances in Neural Information Processing Systems, 2021, 34: 20230-20242.

[69] PRASAD D K, BHAT B N, RAMESH R. Video processing from electro-optical sensors for object detection and tracking in maritime environment: A survey[J]. IEEE Transactions on Intelligent Transportation Systems, 2017, 18(8): 1993-2016.

[70] WANG Q, WANG B, ZHANG L, et al. ECA-Net: Efficient channel attention for deep convolutional neural networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Seattle, USA: IEEE, 2020: 11534-11542.

[71] WOO S, PARK J, LEE J Y, et al. CBAM: Convolutional block attention module[C]//Proceedings of the European Conference on Computer Vision. Munich, Germany: Springer, 2018: 3-19.

[72] HOU Q, ZHANG D, SHEN C, et al. Coordinate attention for efficient mobile network design[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Nashville, USA: IEEE, 2021: 13713-13722.

[73] HOWARD A G, ZHU M, CHEN B, et al. Mobilenets: Efficient convolutional neural networks for mobile vision applications[EB/OL]. (2017-04-17)[2025-03-15].

[74] SANDLER M, HOWARD A G, ZHU M, et al. Mobilenetv2: Inverted residuals and linear bottlenecks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Salt Lake City, USA: IEEE, 2018: 4510-4520.

[75] HOWARD A G, SANDLER M, CHEN B, et al. Searching for mobilenetv3[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. Seoul, South Korea: IEEE, 2019: 1314-1324.

[76] ZHANG X, ZHOU X, LIN M, et al. Shufflenet: An extremely efficient

convolutional neural network for mobile devices[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Salt Lake City, USA: IEEE, 2018: 6848-6856.

[77] MA N, ZHANG X, ZHANG H, et al. Shufflenet v2: Practical guidelines for efficient CNN architecture design[C]//Proceedings of the European Conference on Computer Vision. Munich, Germany: Springer, 2018: 116-131.

[78] HAN K, XU C, TANG X. Ghostnet: More features from cheap operations[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Seattle, USA: IEEE, 2020: 1580-1589.

[79] GEVORGYAN Z. SIOU loss: More powerful learning for bounding box regression[EB/OL]. (2022-05-28)[2025-03-15].